

Nome: _____

Quadro de respostas (questões objetivas):


Questão	a	b	c	d	e	f	g	h
1								
2								
3								
4								
5								
6								
7								
8								
9								
10								

Questões Objetivas (10.0 pts)

Cada questão possui apenas uma alternativa correta. Marque a letra escolhida no quadro de respostas.

- 1) (1.0) Um único parâmetro θ é otimizado com Adam (hiperparâmetros $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\eta = 0.01$, $\epsilon \approx 10^{-8}$). Os acumuladores começam zerados ($m_0 = v_0 = 0$). Na primeira iteração ($t = 1$) o gradiente é $g_1 = 3$. Lembrando que Adam aplica correção de viés $\hat{m} = m/(1 - \beta_1^t)$ e $\hat{v} = v/(1 - \beta_2^t)$ e atualiza $\theta \leftarrow \theta - \eta \hat{m}/(\sqrt{\hat{v}} + \epsilon)$, qual é, aproximadamente, o módulo da atualização $|\Delta\theta| = |\theta_1 - \theta_0|$ neste primeiro passo?
- a) 0.0316
 - b) 0.03
 - c) 0.01
 - d) 0.003
 - e) 0.1
 - f) 0.3
 - g) 0.0001
 - h) 1.0

- 2) (1.0) Considere o MLP abaixo, com duas unidades ocultas de ativações a_1 e a_2 (ReLU) e uma unidade de saída $\hat{y}$ com ativação linear (todos os vieses são nulos). As entradas são $X_1 = 1$ e $X_2 = 2$, a saída esperada é $y = 4$ e a função de custo é $J = \frac{1}{2}(y - \hat{y})^2$. Os pesos iniciais são $\theta_{11}^{(1)} = 1$, $\theta_{12}^{(1)} = -1$ (de X_1, X_2 para a_1), $\theta_{21}^{(1)} = 1$, $\theta_{22}^{(1)} = 1$ (de X_1, X_2 para a_2), $\theta_1^{(2)} = 1$, $\theta_2^{(2)} = 2$ (de a_1, a_2 para $\hat{y}$). Após uma atualização de descida de gradiente estocástica com $\eta = 0.1$, quais os novos valores de $\theta_{11}^{(1)}$ e $\theta_{21}^{(1)}$?



- a) $\theta_{11}^{(1)} = 0.8$ e $\theta_{21}^{(1)} = 0.6$
- b) $\theta_{11}^{(1)} = 0.6$ e $\theta_{21}^{(1)} = 0.6$
- c) $\theta_{11}^{(1)} = 1.0$ e $\theta_{21}^{(1)} = 0.8$
- d) $\theta_{11}^{(1)} = 1.0$ e $\theta_{21}^{(1)} = 0.6$
- e) $\theta_{11}^{(1)} = 1.0$ e $\theta_{21}^{(1)} = 1.0$
- f) $\theta_{11}^{(1)} = 0.6$ e $\theta_{21}^{(1)} = 0.8$
- g) $\theta_{11}^{(1)} = 1.0$ e $\theta_{21}^{(1)} = 0.4$
- h) $\theta_{11}^{(1)} = 0.96$ e $\theta_{21}^{(1)} = 0.6$

- 3) (1.0) Avalie as cinco afirmações a seguir sobre otimização em MLPs:

- I. Na descida de gradiente em lote (*batch GD*), cada iteração usa o gradiente médio sobre *todo* o conjunto de treinamento; já no SGD, cada iteração usa o gradiente de uma *única* instância.
- II. O momentum acumula uma média móvel exponencial dos gradientes; com $\beta = 0$, a atualização reduz-se à descida de gradiente padrão.
- III. No AdaGrad, o acumulador de gradientes ao quadrado cresce monotonicamente, de modo que a taxa de aprendizado efetiva por parâmetro tende a diminuir ao longo do treinamento.
- IV. O momentum de Nesterov avalia o gradiente na posição atual θ_t .
- V. Em Adam, a correção de viés ($\hat{m}_t = m_t / (1 - \beta_1^t)$ e $\hat{v}_t = v_t / (1 - \beta_2^t)$) torna-se progressivamente mais relevante à medida que t cresce, pois os denominadores $1 - \beta_1^t$ e $1 - \beta_2^t$ se afastam cada vez mais de 1.

- a) Apenas I, III e V estão corretas.
- b) Apenas I, II, III e IV estão corretas.
- c) Apenas II, III e IV estão corretas.
- d) Apenas I e III estão corretas.
- e) Apenas I, II e III estão corretas.
- f) Apenas I, II e V estão corretas.
- g) Todas as afirmações estão corretas.
- h) Apenas III e V estão corretas.

4) (1.0) Um MLP totalmente conectado recebe entradas com 10 atributos e possui três camadas ocultas com 20, 20 e 10 unidades (todas com ReLU e **com** viés), seguidas de uma camada de saída com 5 unidades (também com viés). Qual o número total de parâmetros *treináveis* da rede?

- a) 1810
- b) 850
- c) 900
- d) 855
- e) 760
- f) 925
- g) 905
- h) 705

5) (1.0) Avalie as cinco afirmações a seguir sobre funções de custo, verossimilhança e ativações:

I. A entropia cruzada binária corresponde à máxima verossimilhança sob a hipótese $y \mid \mathbf{x} \sim \text{Bernoulli}(\hat{y})$, enquanto o erro quadrático médio corresponde à máxima verossimilhança sob hipótese Gaussiana com variância fixa.

II. A derivada da sigmoide atinge seu valor máximo em $z = 0$, com $\sigma'(0) = \frac{1}{4}$, enquanto a da tangente hiperbólica atinge $\tanh'(0) = 1$.

III. Sendo $S_i = \text{softmax}(\mathbf{z})_i$, a matriz Jacobiana da *softmax* em relação aos seus *logits* é diagonal, isto é, $\partial S_i / \partial z_j = 0$ para todo $i \neq j$.

IV. O erro quadrático médio não pode, em hipótese alguma, ser usado como função de custo em classificação binária: a rede não treina.

V. A ReLU satisfaz $\text{ReLU}'(z) = 1$ para $z > 0$ e $\text{ReLU}'(z) = 0$ para $z < 0$; portanto, ao contrário da sigmoide, não satura para entradas positivas grandes, o que ajuda a mitigar o desaparecimento do gradiente.

- a) Apenas I, II e V estão corretas.
- b) Apenas I e II estão corretas.
- c) Apenas I, II, IV e V estão corretas.
- d) Apenas II, III e V estão corretas.
- e) Apenas I, II e III estão corretas.
- f) Apenas I, IV e V estão corretas.
- g) Todas as afirmações estão corretas.
- h) Apenas III e IV estão corretas.

6) (1.0) Uma imagem de entrada 64×64 passa, em sequência, pelas seguintes camadas (todas quadradas):

- (i) convolução $K = 5$, *stride* $S = 1$, *padding* $P = 0$;
- (ii) *max pooling* 2×2 , *stride* $S = 2$, *padding* $P = 0$;
- (iii) convolução $K = 3$, *stride* $S = 1$, *padding* $P = 1$;
- (iv) *max pooling* 2×2 , *stride* $S = 2$, *padding* $P = 0$;
- (v) convolução $K = 3$, *stride* $S = 2$, *padding* $P = 1$.

Qual a dimensão espacial (em *pixels*) do mapa de ativação (*feature map*) na saída da camada (v)?

- a) 9×9

- b) 7×7
- c) 16×16
- d) 15×15
- e) 6×6
- f) 8×8
- g) 4×4
- h) 30×30

7) (1.0) Avalie as cinco afirmações a seguir sobre redes convolucionais:

- I. O número de parâmetros de uma camada convolucional independe das dimensões espaciais $H \times W$ da entrada, dependendo apenas de K , C_{in} , C_{out} (e dos vieses).
- II. A convolução é equivariante à translação, enquanto o *pooling* (por exemplo, *max pooling*) introduz um grau de invariância a pequenas translações locais.
- III. Durante a inferência, a *batch normalization* normaliza cada ativação usando a média e a variância calculadas sobre o próprio *mini-batch* de teste corrente.
- IV. Duas convoluções 3×3 empilhadas têm o mesmo campo receptivo de uma única convolução 5×5 , porém usam *mais* parâmetros do que a 5×5 .
- V. Uma convolução 1×1 preserva as dimensões espaciais e serve, entre outras coisas, para alterar o número de canais (combinação linear entre canais em cada posição).

- a) Apenas I e V estão corretas.
- b) Apenas I, II, IV e V estão corretas.
- c) Apenas II, III e V estão corretas.
- d) Apenas I, II e V estão corretas.
- e) Apenas I, II e III estão corretas.
- f) Apenas I, III e IV estão corretas.
- g) Todas as afirmações estão corretas.
- h) Apenas II e V estão corretas.

8) (1.0) Considere três camadas convolucionais em sequência, com os valores de *kernel* K , *stride* S e dilatação D indicados abaixo:

- camada 1: $K_1 = 3$, $S_1 = 1$, $D_1 = 2$;
- camada 2: $K_2 = 3$, $S_2 = 2$, $D_2 = 1$;
- camada 3: $K_3 = 3$, $S_3 = 1$, $D_3 = 1$.

Qual a dimensão (em *pixels*) do campo receptivo de uma unidade na saída da camada 3?

- a) 9×9
- b) 11×11
- c) 13×13
- d) 7×7
- e) 15×15
- f) 5×5
- g) 17×17
- h) 8×8

- 9) (1.0) Um modelo de linguagem atribui, a uma sequência de $m = 4$ *tokens*, as seguintes probabilidades condicionais $P(y_t \mid y_{<t})$, na ordem: $\frac{1}{2}, \frac{1}{4}, \frac{1}{4}, \frac{1}{8}$. Usando a definição $\text{Perplexidade} = 2^{-\frac{1}{m} \sum_{t=1}^m \log_2 P(y_t \mid y_{<t})}$, qual o valor da perplexidade dessa sequência?
- 1
 - 8
 - 16
 - 2
 - 256
 - 2.83
 - 5.66
 - 4
- 10) (1.0) Avalie as cinco afirmações a seguir sobre redes recorrentes:
- Na RNN *vanilla*, o gradiente retropropagado no tempo carrega o produto $\prod_k \theta_{hh} (1 - \tanh^2(z_k))$; como $|1 - \tanh^2(z_k)| \leq 1$, esse produto tende a zero em sequências longas, caracterizando o desaparecimento do gradiente.
 - Na LSTM, com o *forget gate* $f_t \rightarrow 1$ e o *input gate* $i_t \rightarrow 0$, a atualização $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$ reduz-se a $c_t \approx c_{t-1}$, preservando a memória de longo prazo (*constant error carousel*).
 - Na LSTM, todos os quatro portões e candidatos (f_t , i_t , o_t e o candidato $\tilde{c}_t$) são obtidos por ativação sigmoide.
 - A LSTM faz circular dois estados ao longo do tempo: o estado oculto h_t e o estado de célula (memória) c_t , ao contrário da RNN *vanilla*, que mantém apenas h_t .
 - Um modelo de linguagem extremamente confiante e sempre correto pode atingir perplexidade inferior a 1.
- Apenas II, III e IV estão corretas.
 - Apenas I, II, IV e V estão corretas.
 - Apenas I, II e IV estão corretas.
 - Apenas I e IV estão corretas.
 - Apenas I, II e V estão corretas.
 - Apenas I, III e V estão corretas.
 - Todas as afirmações estão corretas.
 - Apenas II e IV estão corretas.