

Nome: _____

Quadro de respostas (questões objetivas):


Questão	a	b	c	d	e	f	g	h
1								
2								
3								
4								
5								
6								
7								
8								
9								
10								

Questões Objetivas (10.0 pts)

Cada questão possui apenas uma alternativa correta. Marque a letra escolhida no quadro de respostas.

- 1) (1.0) Uma entrada $X \in \mathbb{R}^{n \times d_{\text{model}}}$ com $n = 10$ tokens e $d_{\text{model}} = 512$ passa por uma camada de *multi-head self-attention* com $H = 8$ cabeças (logo $d_k = d_{\text{model}}/H$). Quais são, respectivamente, as dimensões de (i) Q_i de uma cabeça, (ii) da matriz de scores $Q_i K_i^T$ de uma cabeça, e (iii) da saída final da camada (após concatenar as cabeças e aplicar W_O)?
- a) Q_i : 10×512 ; $Q_i K_i^T$: 10×10 ; saída: 10×512 .
 - b) Q_i : 10×64 ; $Q_i K_i^T$: 64×64 ; saída: 10×512 .
 - c) Q_i : 10×64 ; $Q_i K_i^T$: 10×10 ; saída: 10×64 .
 - d) Q_i : 64×64 ; $Q_i K_i^T$: 10×10 ; saída: 10×512 .
 - e) Q_i : 10×64 ; $Q_i K_i^T$: 8×8 ; saída: 10×512 .
 - f) Q_i : 10×64 ; $Q_i K_i^T$: 10×10 ; saída: 10×512 .
 - g) Q_i : 10×8 ; $Q_i K_i^T$: 10×10 ; saída: 10×512 .
 - h) Q_i : 10×64 ; $Q_i K_i^T$: 10×10 ; saída: 512×512 .

- 2) (1.0) Considere **um** bloco Transformer (esquematizado ao lado) com $d_{\text{model}} = 64$. A atenção é *multi-head* com $H = 8$ cabeças e usa as quatro projeções W_Q, W_K, W_V, W_O , cada uma 64×64 **com viés**. A FFN expande para $d_{\text{ff}} = 256$ (ReLU, ambas as camadas **com viés**). Há dois *LayerNorm*, cada um com parâmetros γ e β de dimensão 64. Qual o número total de parâmetros *treináveis* do bloco?



- a) 49 408
- b) 45 824
- c) 49 984
- d) 49 152
- e) 33 088
- f) 16 640
- g) 49 728
- h) 50 240

- 3) (1.0) Avalie as cinco afirmações a seguir sobre *self-attention*:

- I. O fator de escala $\sqrt{d}$ em $\text{softmax}(QK^T/\sqrt{d})V$ mantém a variância dos *scores* em torno de 1 (o produto escalar de vetores com componentes i.i.d. de variância 1 tem variância d), evitando a saturação do *softmax*.
- II. A operação de *self-attention* “crua” (apenas $\text{softmax}(QK^T/\sqrt{d})V$, sem as projeções) não possui parâmetros treináveis.
- III. A *self-attention* é permutação-equivariante; por isso é necessário acrescentar *positional encoding* à entrada.
- IV. Dividir os *scores* por d (em vez de $\sqrt{d}$) também manteria a variância dos *scores* em 1.
- V. A máscara causal atribui o valor 0 às posições futuras *antes* do *softmax*.

- a) Apenas I, II e III estão corretas.
- b) Apenas I, II, III e IV estão corretas.
- c) Apenas I e III estão corretas.
- d) Apenas II, III e IV estão corretas.
- e) Apenas I, III e V estão corretas.
- f) Apenas III, IV e V estão corretas.
- g) Todas as afirmações estão corretas.
- h) Apenas I e II estão corretas.

- 4) (1.0) Avalie as cinco afirmações a seguir sobre *transformers*:

- I. A complexidade da *self-attention* é $O(n^2d)$ no comprimento de sequência n ; portanto dobrar n multiplica por aproximadamente 4 o custo do termo de atenção.
- II. O *KV-cache* reduz o custo de gerar cada novo *token* de $O(n^2)$ para $O(n)$, ao preço de uma memória que cresce linearmente com o comprimento do contexto.
- III. Na *cross-attention* de uma arquitetura *encoder-decoder*, as *queries* vêm do *decoder* e as *keys* e *values* vêm do *encoder*.
- IV. O *positional encoding* sinusoidal de Vaswani et al. (2017) não possui parâmetros treináveis: é uma função fixa da posição.
- V. Aumentar o número de cabeças H (mantendo d_{model} fixo) aumenta o número total de parâmetros das projeções de atenção proporcionalmente a H .

- a) Apenas I, II e III estão corretas.
- b) Apenas I, III e IV estão corretas.
- c) Apenas II, III, IV e V estão corretas.
- d) Apenas I, II e IV estão corretas.
- e) Apenas I, II, III e V estão corretas.
- f) Apenas III e IV estão corretas.
- g) Apenas I, II, III e IV estão corretas.
- h) Todas as afirmações estão corretas.

- 5) (1.0) Na **decodificação especulativa**, o modelo de rascunho M_q propõe γ *tokens* (probabilidades q) e o modelo alvo M_p os verifica em um único passe (probabilidades p). Cada *token* proposto $\tilde{x}$ é **aceito** com probabilidade $\min(1, p(\tilde{x})/q(\tilde{x}))$; se **rejeitado**, reamostra-se da distribuição normalizada $(p - q)_+ = \max(0, p - q)$ e **descartam-se todas as posições seguintes** do rascunho (se todos forem aceitos, amostra-se ainda 1 *token* extra de M_p). A tabela mostra os três *tokens* mais prováveis de M_q e de M_p em cada uma das $\gamma = 5$ posições; o *token* proposto é o primeiro da coluna M_q . Considere apenas os *tokens* listados.

Pos.	M_q (rascunho): 3 mais prováveis	M_p (alvo): 3 mais prováveis
1	tem (0.60), há (0.15), possui (0.10)	tem (0.90), possui (0.05), há (0.03)
2	uma (0.50), a (0.20), sua (0.10)	uma (0.70), a (0.15), sua (0.08)
3	porta (0.80), janela (0.12), parede (0.05)	janela (0.70), porta (0.20), parede (0.05)
4	azul (0.40), branca (0.25), velha (0.15)	azul (0.60), branca (0.20), velha (0.10)
5	grande (0.70), nova (0.15), bonita (0.08)	nova (0.40), grande (0.35), bonita (0.10)

Com base na regra acima, qual afirmação descreve corretamente a verificação?

- a) Todo *token* proposto que aparece entre os três mais prováveis do alvo é aceito; logo apenas a posição 5 pode ser rejeitada na verificação.
- b) A posição 3 é *sempre* rejeitada (pois $p < q$): reamostra-se “janela” e descartam-se as posições 4 e 5 do rascunho.
- c) A posição 3 é aceita com probabilidade $p/q = 0.8/0.2 = 1$ (sempre), bastando o *token* estar entre os mais prováveis do alvo.
- d) As posições 1 e 2 são sempre aceitas ($p \geq q$); a posição 3 ($p < q$) é aceita com probabilidade $p/q = 0.2/0.8 = 0.25$ e, se rejeitada, reamostrada de $(p - q)_+$ para “janela”, descartando-se as posições 4 e 5.
- e) As posições 1 e 2 podem ser rejeitadas com probabilidade p/q ; a posição 3, por ter $p < q$, é a única sempre aceita do conjunto.
- f) Se rejeitada, a posição 3 é reamostrada para “porta” (o *token* do rascunho), e as posições 4 e 5 são reamostradas logo em seguida.
- g) Como $p < q$ nas posições 3 e 5, ambas são reamostradas de forma independente, gerando “janela” e “nova”, respectivamente.
- h) Nenhuma posição pode ser aceita sem reamostragem, pois a regra de verificação exige que $p = q$ exatamente em cada posição.

- 6) (1.0) Em um VAE com latente $D_z = 2$, o *encoder* produz, para certa entrada, $\mu = (2, 0)$ e $\Sigma = \text{diag}(0.5, 2)$. Usando a forma fechada

$$D_{KL}[\mathcal{N}(\mu, \Sigma) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I})] = \frac{1}{2}(\text{Tr}[\Sigma] + \mu^\top \mu - D_z - \log \det \Sigma),$$

qual o valor de D_{KL} ? (Note que $\det \Sigma = 1$.)

- a) 3.25
- b) 2.25
- c) 4.50
- d) 0.25
- e) 1.50
- f) 4.25
- g) 2.00
- h) 5.00

- 7) (1.0) Avalie as cinco afirmações a seguir sobre autoencoders e VAEs:

I. A ELBO se decompõe como $\mathbb{E}_{q(z|x, \phi)} [\log p(x|z, \theta)] - D_{KL}[q(z|x, \phi) \parallel p(z)]$ e é um limite *inferior* de $\log p(x|\theta)$.

II. O *reparametrization trick* ($z = \mu + \Sigma^{1/2}\epsilon$, com $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$) é necessário para permitir a retropropagação através da amostragem do latente.

III. No termo $\frac{1}{2}(\text{Tr}[\Sigma] + \mu^\top \mu - D_z - \log \det \Sigma)$, a parcela $-\log \det \Sigma$ cresce sem limite quando a variância do posterior tende a zero, penalizando o colapso do posterior a uma massa pontual.

IV. Um autoencoder determinístico comum pode gerar novas amostras simplesmente amostrando $z \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ e passando pelo *decoder*, pois seu espaço latente já é gaussiano.

V. A ELBO é um limite *superior* de $\log p(x|\theta)$, e a diferença para $\log p(x|\theta)$ é $D_{KL}[q(z|x, \phi) \parallel p(z|x, \theta)]$.

- a) Apenas I, II, III e IV estão corretas.
- b) Apenas I e II estão corretas.
- c) Apenas II, III e IV estão corretas.
- d) Apenas I, III e V estão corretas.
- e) Apenas I, II, IV e V estão corretas.
- f) Apenas III e IV estão corretas.
- g) Todas as afirmações estão corretas.
- h) Apenas I, II e III estão corretas.

- 8) (1.0) Uma camada *affine coupling* de um *normalizing flow* recebe $h = (h^A, h^B)$, copia h^A e transforma h^B por $y^B = h^B \odot \exp(\mathbf{s}) + \mathbf{t}$, onde $(\mathbf{s}, \mathbf{t})$ são produzidos por uma rede a partir de h^A . Para $h^B = (3, 4)$, $\mathbf{s} = (\ln 2, 0)$ e $\mathbf{t} = (1, -1)$, calcule y^B e o log-determinante $\log|\det J|$ da camada.

- a) $y^B = (7, 3)$ e $\log|\det J| = 2$.
- b) $y^B = (7, 3)$ e $\log|\det J| = 3$.
- c) $y^B = (6, 4)$ e $\log|\det J| = \ln 2 \approx 0.693$.
- d) $y^B = (7, 4)$ e $\log|\det J| = \ln 2 \approx 0.693$.
- e) $y^B = (7, 3)$ e $\log|\det J| = \ln 2 \approx 0.693$.
- f) $y^B = (3, 4)$ e $\log|\det J| = 0$.
- g) $y^B = (7, 3)$ e $\log|\det J| = 0$.
- h) $y^B = (7, 3)$ e $\log|\det J| = 0.5$.

9) (1.0) Avalie as cinco afirmações a seguir sobre GANs:

I. O discriminador ótimo é $D^*(x) = \frac{P(x)}{P(x) + P^*(x)}$, em que P é a densidade dos dados reais e P^* a dos dados gerados.

II. Sob o discriminador ótimo, a *loss* do GAN equivale (a menos de uma constante aditiva) à divergência de Jensen–Shannon entre P e P^* .

III. A *loss* não-saturante do gerador, $-\ln \sigma(f[\cdot])$, fornece gradiente útil mesmo quando o discriminador vence ($\sigma \rightarrow 0$), ao contrário da *loss* original $\ln(1 - \sigma(f[\cdot]))$.

IV. Quando os suportes de P e P^* são disjuntos, a divergência de Jensen–Shannon satura em seu valor máximo $\ln 2$ e o gradiente para o gerador desaparece.

V. O *mode collapse* ocorre porque o termo de cobertura da Jensen–Shannon gera um gradiente forte que força o gerador a cobrir as modas ignoradas.

- a) Apenas I, II e III estão corretas.
- b) Apenas I, III e IV estão corretas.
- c) Apenas I, II, III e IV estão corretas.
- d) Apenas II, III, IV e V estão corretas.
- e) Apenas I, II e IV estão corretas.
- f) Apenas I e II estão corretas.
- g) Todas as afirmações estão corretas.
- h) Apenas III, IV e V estão corretas.

10) (1.0) Em um modelo difusor com *classifier-free guidance*, a estimativa de ruído guiada é $\tilde{g}_t = (1 + w) g_t[z_t, c] - w g_t[z_t, \emptyset]$, com peso de guiamento $w \geq 0$, onde $g_t[z_t, c]$ é a predição *condicionada* (ao *prompt* c) e $g_t[z_t, \emptyset]$ a predição *sem condição*. Para $g_t[z_t, c] = 2$, $g_t[z_t, \emptyset] = 0.5$ e $w = 3$, qual o valor de $\tilde{g}_t$?

- a) 6.5
- b) 5.0
- c) 4.0
- d) 8.0
- e) 6.0
- f) 4.5
- g) 2.0
- h) 0.5