

Nome: _____


Quadro de respostas (questões objetivas):

Questão	a	b	c	d	e	f	g	h
1								
2								
3								
4								
5								
6								
7								
8								

Questões Objetivas (8,0 pts)

Cada questão possui apenas uma alternativa correta. Marque a letra escolhida no quadro de respostas.

- 1) (1,0) Você treina o mesmo MLP quatro vezes, alterando apenas a taxa de aprendizado η entre os treinos. As curvas A, B, C e D abaixo mostram a evolução da função de custo $\mathcal{L}$ ao longo das iterações em cada treino (todas partem da mesma inicialização). Assinale a alternativa que associa corretamente cada curva ao regime da taxa de aprendizado.



- a) A: η alta; B: η muito alta (divergência); C: η adequada; D: η muito baixa.
- b) A: η muito alta (divergência); B: η adequada; C: η alta; D: η muito baixa.
- c) A: η muito baixa; B: η alta; C: η adequada; D: η muito alta (divergência).
- d) A: η muito alta (divergência); B: η alta; C: η muito baixa; D: η adequada.
- e) A: η muito alta (divergência); B: η alta; C: η adequada; D: η muito baixa.
- f) A: η alta; B: η muito baixa; C: η adequada; D: η muito alta (divergência).
- g) A: η muito alta (divergência); B: η muito baixa; C: η alta; D: η adequada.
- h) A: η adequada; B: η alta; C: η muito alta (divergência); D: η muito baixa.

2) (1,0) Considere um Perceptron de Rosenblatt com duas entradas $X_1, X_2 \in \{-1, +1\}$ e saída $\hat{y} = \text{sin}(\theta_0 + \theta_1 X_1 + \theta_2 X_2)$, em que $\text{sin}(z) = +1$ se $z \geq 0$ e -1 caso contrário. Codificando *verdadeiro* como $+1$ e *falso* como -1 , qual configuração de pesos $(\theta_0, \theta_1, \theta_2)$ implementa a porta lógica **OR**, isto é, $\hat{y} = +1$ se e somente se $X_1 = +1$ ou $X_2 = +1$?

- a) $(\theta_0, \theta_1, \theta_2) = (-3, 1, 1)$
- b) $(\theta_0, \theta_1, \theta_2) = (-1, -1, -1)$
- c) $(\theta_0, \theta_1, \theta_2) = (-1, 1, 1)$
- d) $(\theta_0, \theta_1, \theta_2) = (1, 1, 1)$
- e) $(\theta_0, \theta_1, \theta_2) = (1, 1, -1)$
- f) $(\theta_0, \theta_1, \theta_2) = (1, -1, -1)$
- g) $(\theta_0, \theta_1, \theta_2) = (-1, 1, -1)$
- h) $(\theta_0, \theta_1, \theta_2) = (3, 1, 1)$

3) (1,0) Um único parâmetro θ é otimizado por descida de gradiente com *momentum*, na formulação vista em aula:

$$v_{t+1} = \beta v_t + (1 - \beta) \nabla_{\theta} \mathcal{L}(\theta_t), \quad \theta_{t+1} = \theta_t - \eta v_{t+1},$$

com $\eta = 0,1$, $\beta = 0,5$, $v_0 = 0$ e $\theta_0 = 1$. Os gradientes observados nas duas primeiras iterações são $\nabla_{\theta} \mathcal{L}(\theta_0) = 4$ e $\nabla_{\theta} \mathcal{L}(\theta_1) = 2$. Qual o valor de θ_2 após **duas** atualizações?

- a) 0,2
- b) 0,4
- c) 0,5
- d) 0,6
- e) 0,7
- f) 0,8
- g) 1,0
- h) 1,4

4) (1,0) Assinale a alternativa que preenche corretamente as lacunas do parágrafo abaixo.

“Para medir a qualidade de uma *bounding box* predita em relação ao *ground truth*, utiliza-se tipicamente a métrica **(1)**. A tarefa que atribui um rótulo de classe a cada *pixel* da imagem, sem distinguir objetos diferentes de uma mesma classe, chama-se segmentação **(2)**. Ao adaptar uma VGG-16 pré-treinada no ImageNet para um novo problema com poucos dados, a prática usual de *transfer learning* é congelar **(3)** e treinar o restante da rede.”

- a) (1) entropia cruzada; (2) semântica; (3) o *backbone* convolucional
- b) (1) IoU; (2) de instâncias; (3) o *backbone* convolucional
- c) (1) entropia cruzada; (2) de instâncias; (3) a cabeça densa
- d) (1) IoU; (2) semântica; (3) a cabeça densa
- e) (1) entropia cruzada; (2) semântica; (3) a cabeça densa
- f) (1) IoU; (2) de instâncias; (3) a cabeça densa
- g) (1) IoU; (2) semântica; (3) o *backbone* convolucional
- h) (1) entropia cruzada; (2) de instâncias; (3) o *backbone* convolucional

5) (1,0) Considere as asserções abaixo e a relação proposta entre elas.

I. Ao aumentar muito a profundidade de uma rede convolucional **sem** conexões residuais (por exemplo, de 20 para 56 camadas), a rede mais profunda pode apresentar desempenho **pior** que a mais rasa; esse fenômeno, conhecido como problema da degradação, não é um caso de *overfitting*.

PORQUE

II. Na degradação, o erro elevado da rede mais profunda aparece já no conjunto de **treino**, enquanto o *overfitting* se caracteriza por erro de treino baixo acompanhado de erro de validação alto.

Assinale a alternativa correta:

- a) As asserções I e II são verdadeiras, e a II é uma justificativa correta da I.
 - b) As asserções I e II são verdadeiras, mas a II não é uma justificativa correta da I.
 - c) As asserções I e II são verdadeiras, e a I é uma justificativa correta da II, mas não o contrário.
 - d) A asserção I é verdadeira, e a II é falsa.
 - e) A asserção I é falsa, e a II é verdadeira.
 - f) As asserções I e II são falsas.
 - g) A asserção I é verdadeira somente quando a rede usa *batch normalization*, e a II é verdadeira.
 - h) A asserção I é falsa somente para redes treinadas com SGD sem *momentum*, e a II é falsa.
- 6) (1,0) Você treina uma RNN *vanilla* (ativação tanh nas conexões recorrentes) para modelagem de linguagem em sequências longas. A curva da função de custo cai durante algumas centenas de iterações, mas de tempos em tempos **salta abruptamente** para valores muito altos e, em uma dessas ocasiões, passa a registrar NaN. Ao imprimir a norma do gradiente $\|g\|$ a cada iteração, você observa que ela ocasionalmente atinge valores na ordem de 10^6 . Qual a explicação mais consistente e a melhor mitigação?
- a) Os gradientes se dissipam ao longo dos passos de tempo; substituir a RNN por uma LSTM elimina os saltos, pois os portões impedem qualquer crescimento da norma do gradiente.
 - b) A variância do gradiente está alta por causa do tamanho do *batch*; reduzir o *batch size* para 1 torna as atualizações mais estáveis e elimina os saltos e o NaN observados.
 - c) O gradiente explode ocasionalmente; aplicar *clipping* por valor em cada componente é preferível ao *clipping* por norma, pois somente o primeiro preserva a direção do vetor gradiente.
 - d) O modelo está em *overfitting* nas sequências longas; adicionar *dropout* nas conexões recorrentes reduz a variância do gradiente e impede que a norma atinja valores extremos.
 - e) A saturação da tanh é a causa dos saltos; trocá-la por ReLU nas conexões recorrentes limita o crescimento das ativações e, portanto, o crescimento da norma do gradiente.
 - f) O gradiente explode: a retropropagação no tempo multiplica fatores $\theta_{hh} (1 - \tanh^2(z_k))$ que podem ter módulo maior que 1; aplicar *clipping* por norma ($g \leftarrow c g / \|g\|$ quando $\|g\| > c$) limita o passo preservando a direção.
 - g) O NaN indica erro numérico interno do *framework* de autodiferenciação; reexecutar o treinamento com outra semente aleatória, sem alterar hiperparâmetros, é suficiente para eliminar o problema.
 - h) O treinamento com *teacher forcing* acumula erros de exposição; alimentar o modelo com as próprias previsões durante o treino estabiliza a norma do gradiente e evita os saltos.

7) (1,0) Associe cada estratégia de decodificação de um modelo de linguagem (coluna da esquerda) à descrição correspondente (coluna da direita).

- | | |
|--|--|
| 1. Greedy search | (i) mantém, a cada passo, as b hipóteses de maior probabilidade conjunta e retorna a melhor ao final. |
| 2. Beam search (largura b) | (ii) escolhe deterministicamente, a cada passo, o <i>token</i> de maior probabilidade condicional. |
| 3. Amostragem com temperatura $\tau \rightarrow 0^+$ | (iii) torna-se equivalente à escolha determinística do <i>token</i> mais provável a cada passo. |
| 4. Amostragem Top-P (<i>nucleus</i>) | (iv) amostra apenas do menor conjunto de <i>tokens</i> cuja probabilidade acumulada atinge um limiar p . |

- a) 1-(ii); 2-(i); 3-(iv); 4-(iii)
- b) 1-(iii); 2-(i); 3-(ii); 4-(iv)
- c) 1-(ii); 2-(i); 3-(iii); 4-(iv)
- d) 1-(i); 2-(ii); 3-(iii); 4-(iv)
- e) 1-(ii); 2-(iv); 3-(iii); 4-(i)
- f) 1-(i); 2-(ii); 3-(iv); 4-(iii)
- g) 1-(iii); 2-(iv); 3-(ii); 4-(i)
- h) 1-(iv); 2-(i); 3-(iii); 4-(ii)

8) (1,0) Em um modelo *seq2seq* com atenção de produto escalar, o estado do decodificador no passo t é $h_t = (1; 1)$ e os estados do codificador são $s_1 = (2; 2)$, $s_2 = (1; 1)$ e $s_3 = (0; -1)$. Os *scores* são $\text{score}(h_t, s_k) = h_t^\top s_k$ e os pesos de atenção são

$$a_k^{(t)} = \frac{\exp(\text{score}(h_t, s_k))}{\sum_{i=1}^3 \exp(\text{score}(h_t, s_i))}.$$

Qual o valor aproximado de $a_1^{(t)}$?

- a) 0,006
 - b) 0,118
 - c) 0,333
 - d) 0,571
 - e) 0,800
 - f) 0,876
 - g) 0,881
 - h) 0,982
-

Questões Dissertativas (2,0 pts)

- 9) (1,0) Considere uma célula LSTM **escalar** (todas as dimensões iguais a 1), com as equações vistas em aula:

$$f_t = \sigma(\theta_f [h_{t-1}, x_t] + b_f), \quad i_t = \sigma(\theta_i [h_{t-1}, x_t] + b_i), \quad \tilde{c}_t = \tanh(\theta_c [h_{t-1}, x_t] + b_c),$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \quad o_t = \sigma(\theta_o [h_{t-1}, x_t] + b_o), \quad h_t = o_t \odot \tanh(c_t).$$

O estado inicial é $c_0 = -0,2$ e $h_0 = 0,4$, e a entrada no passo 1 é $x_1 = 0,5$, de modo que $[h_0, x_1] = [0,4, 0,5]$. Os parâmetros são:

$$\theta_f = [0,5, -0,4], \quad b_f = 0,2; \quad \theta_i = [-0,3, 0,6], \quad b_i = -0,1;$$

$$\theta_c = [0,2, 0,8], \quad b_c = 0; \quad \theta_o = [0,7, 0,1], \quad b_o = -0,3.$$

Pode arredondar para 4 casas decimais.

- a) (0,5) Compute f_1 , i_1 , $\tilde{c}_1$ e o novo estado de célula c_1 .

- b) (0,5) Compute o_1 e h_1 . Em seguida, explique em uma frase, a partir de $\frac{\partial c_t}{\partial c_{t-1}} = f_t$, por que a LSTM mitiga a dissipação do gradiente em sequências longas.

- 10) (1,0) Um colega propõe usar um MLP para classificar imagens RGB de dimensão $64 \times 64 \times 3$, achatando a imagem em um vetor de entrada e usando uma primeira camada oculta totalmente conectada com 256 unidades.

- a) (0,5) Compute o número de parâmetros treináveis (pesos e vieses) dessa primeira camada totalmente conectada e compare-o com o número de parâmetros de uma camada convolucional 3×3 com 32 filtros (com viés), *stride* 1 e *padding* 1, aplicada à mesma imagem. Mostre o cálculo dos dois valores.

- b) (0,5) Além da mudança no número de parâmetros, aponte **duas** propriedades estruturais da convolução que a tornam adequada para imagens, explicando em uma ou duas frases por que cada uma delas ajuda nessa tarefa.