

Nome: _____

Quadro de respostas (questões objetivas):

Questão	a	b	c	d	e	f	g	h
1								
2								
3								
4								
5								
6								
7								
8								

Questões Objetivas (8,0 pts)

Cada questão possui apenas uma alternativa correta. Marque a letra escolhida no quadro de respostas.

- 1) (1,0) No LoRA, uma matriz congelada $W_0 \in \mathbb{R}^{d \times k}$ recebe a correção *low rank* $h = W_0x + \frac{\alpha}{r}BAx$, com $B \in \mathbb{R}^{d \times r}$ e $A \in \mathbb{R}^{r \times k}$; apenas B e A são treináveis. Você aplica LoRA com $r = 8$ às projeções W_Q e W_V (ambas 1024×1024) de **cada uma** das 12 camadas de um *transformer*. Quantos parâmetros treináveis o ajuste introduz no total?
- a) 16 384
 - b) 32 768
 - c) 98 304
 - d) 196 608
 - e) 393 216
 - f) 589 824
 - g) 786 432
 - h) 25 165 824

2) (1,0) Sobre as asserções abaixo a respeito do treinamento e alinhamento de LLMs:


I. No *SFT* (*supervised fine-tuning*) com *prompt masking*, a função de perda é computada apenas sobre os *tokens* da resposta; os *tokens* do *prompt* são mascarados e não contribuem para o gradiente.

II. O DPO otimiza diretamente sobre pares de preferência (y_w, y_l) , dispensando o treinamento de um *reward model* explícito e o loop de *policy gradient* usado no RLHF com PPO.

III. No RLHF com PPO, o termo de penalização $KL(\pi_\theta \parallel \pi_{\text{ref}})$ tem como função principal acelerar a convergência, permitindo o uso de taxas de aprendizado maiores na atualização da política.

- a) Apenas I está correta.
- b) Apenas II está correta.
- c) Apenas III está correta.
- d) Apenas I e II estão corretas.
- e) Apenas I e III estão corretas.
- f) Apenas II e III estão corretas.
- g) Todas estão corretas.
- h) Nenhuma está correta.

3) (1,0) Você faz *fine-tuning* completo (todos os pesos) de um LLM pré-treinado em um corpus jurídico, com taxa de aprendizado $3 \cdot 10^{-4}$ por 10 épocas. As curvas abaixo mostram a acurácia ao longo das épocas em duas avaliações, ambas sobre dados de teste não vistos no treino: um *benchmark* da tarefa jurídica alvo (linha cheia) e um *benchmark* de conhecimentos gerais que o modelo dominava antes do ajuste (linha tracejada). Qual o diagnóstico mais consistente e a melhor mitigação?



- a) O modelo está em *overfitting* no corpus jurídico; treinar por mais épocas no mesmo corpus faria as duas curvas de acurácia voltarem a subir simultaneamente.
- b) Há vazamento de dados entre treino e teste jurídicos; refazer a divisão dos dados corrige tanto a curva da tarefa jurídica quanto a do *benchmark* geral.
- c) Trata-se de esquecimento catastrófico do pré-treino; mitigações incluem taxa de aprendizado menor, menos épocas, misturar dados gerais ao *fine-tuning* ou usar PEFT (LoRA) com os pesos base congelados.
- d) Trata-se de *reward hacking*: o modelo explora falhas da métrica de avaliação; substituir o *benchmark* geral por outro conjunto de tarefas resolve o problema observado.
- e) O *tokenizer* não cobre o vocabulário jurídico e fragmenta os termos técnicos; retrainar o *tokenizer* recupera simultaneamente as duas curvas de acurácia.
- f) A janela de contexto foi excedida pelos documentos jurídicos longos; truncar as entradas do *fine-tuning* evita a degradação observada no *benchmark* geral.
- g) A taxa de aprendizado alta causou explosão de gradiente e NaN nos pesos; nesse caso ambas as curvas deveriam despencar, logo o gráfico é inconsistente com um treino real.
- h) O modelo está subtreinado no regime de Chinchilla ($D^* \approx 20N$); aumentar o volume de dados jurídicos melhora as duas curvas por leis de escala.

4) (1,0) Associe cada método de *positional encoding* (coluna da esquerda) ao seu mecanismo (coluna da direita).

- | | |
|--------------------------|---|
| 1. PE sinusoidal | (i) tabela de <i>embeddings</i> treináveis somada à entrada, limitada ao comprimento máximo $L_{\max}$ visto no treino. |
| 2. PE absoluto aprendido | (ii) função fixa e determinística da posição, somada à entrada, sem nenhum parâmetro treinável. |
| 3. RoPE | (iii) não altera a entrada: subtrai do <i>score</i> de atenção uma penalidade proporcional à distância $ i - j $, com inclinação própria por cabeça. |
| 4. ALiBi | (iv) rotaciona os vetores q e k dentro da atenção, fazendo o <i>score</i> depender apenas do deslocamento relativo $j - i$. |

- a) 1-(ii); 2-(i); 3-(iii); 4-(iv)
- b) 1-(i); 2-(ii); 3-(iv); 4-(iii)
- c) 1-(ii); 2-(iv); 3-(i); 4-(iii)
- d) 1-(i); 2-(ii); 3-(iii); 4-(iv)
- e) 1-(iv); 2-(i); 3-(ii); 4-(iii)
- f) 1-(ii); 2-(iii); 3-(iv); 4-(i)
- g) 1-(ii); 2-(i); 3-(iv); 4-(iii)
- h) 1-(iii); 2-(i); 3-(iv); 4-(ii)

5) (1,0) Em uma GAN, seja $d = f[g[z, \theta], \phi]$ o *logit* do discriminador para uma amostra gerada; a *loss* original do gerador contribui com $L = \ln(1 - \sigma(d))$ e a *non-saturating* com $L_{\text{ns}} = -\ln \sigma(d)$. No início do treino o discriminador rejeita as amostras geradas: $\sigma(d) = 0,05$. Sabendo que $\sigma'(d) = \sigma(d)(1 - \sigma(d))$, quais os módulos de $|\partial L / \partial d|$ e $|\partial L_{\text{ns}} / \partial d|$, e qual *loss* fornece sinal útil ao gerador?

- a) 0,05 e 0,95; a *loss* original fornece o maior sinal de aprendizado.
- b) 0,95 e 0,05; a *loss* original fornece o maior sinal de aprendizado.
- c) 0,05 e 0,05; as duas *losses* saturam igualmente no início do treino.
- d) 0,05 e 0,95; a *loss non-saturating* fornece o maior sinal de aprendizado.
- e) 0,95 e 0,05; a *loss non-saturating* fornece o maior sinal de aprendizado.
- f) 0,0475 e 0,0475; as duas *losses* fornecem exatamente o mesmo sinal.
- g) 0,95 e 0,95; as duas *losses* fornecem sinal forte no início do treino.
- h) 0 e 1; apenas a *loss non-saturating* tem gradiente definido nesse ponto.

6) (1,0) Considere as asserções abaixo e a relação proposta entre elas.

I. No treinamento de um modelo difusor com *classifier-free guidance*, a condição c é descartada (substituída por $\emptyset$) em uma pequena fração dos exemplos, tipicamente com probabilidade próxima de 0,1.

PORQUE

II. Desse modo uma única rede aprende tanto a predição condicional $g_t[z_t, c]$ quanto a incondicional $g_t[z_t, \emptyset]$, que são combinadas na amostragem como $\tilde{g}_t = (1 + w) g_t[z_t, c] - w g_t[z_t, \emptyset]$, com $w \geq 0$.

Assinale a alternativa correta:

- a) As asserções I e II são verdadeiras, e a II é uma justificativa correta da I.

- b) As asserções I e II são verdadeiras, mas a II não é uma justificativa correta da I.
 - c) As asserções I e II são verdadeiras, e a I é uma justificativa correta da II, mas não o contrário.
 - d) A asserção I é verdadeira, e a II é falsa.
 - e) A asserção I é falsa, e a II é verdadeira.
 - f) As asserções I e II são falsas.
 - g) A asserção I é verdadeira somente quando o peso de guiamento é $w = 0$, e a II é verdadeira.
 - h) A asserção I é falsa para modelos de difusão latente, e a II é falsa.
- 7) (1,0) Considere os passos abaixo de **uma** iteração de treinamento de um modelo difusor (DDPM), conforme o algoritmo visto em aula:

- I. Amostrar uma instância x do conjunto de treinamento.
- II. Amostrar $t \sim \text{Uniforme}\{1, \dots, T\}$ e $\epsilon \sim \mathcal{N}(0, \mathbf{I})$.
- III. Computar $z_t = \sqrt{\alpha_t} x + \sqrt{1 - \alpha_t} \epsilon$ (kernel de difusão).
- IV. Computar a perda $\|g_t[z_t, \theta_t] - \epsilon\|^2$.
- V. Atualizar os parâmetros por descida de gradiente.

Assinale a alternativa que apresenta uma ordem válida para os passos:

- a) I, III, II, IV, V
 - b) II, III, I, IV, V
 - c) I, II, IV, III, V
 - d) III, I, II, IV, V
 - e) I, II, III, V, IV
 - f) V, I, II, III, IV
 - g) II, I, IV, III, V
 - h) I, II, III, IV, V
- 8) (1,0) Um *normalizing flow* de camada única usa a transformação linear $Y = 3X + 1$ sobre a variável de base $X \sim \mathcal{N}(0, 1)$. Usando a fórmula de mudança de variável e sabendo que $p_X(0) = \frac{1}{\sqrt{2\pi}} \approx 0,399$, qual o valor aproximado da densidade $p_Y(1)$?
- a) 1,197
 - b) 0,798
 - c) 0,399
 - d) 0,242
 - e) 0,199
 - f) 0,133
 - g) 0,081
 - h) 0,044
-

Questões Dissertativas (2,0 pts)

- 9) (1,0) No alinhamento de LLMs por preferências, o *reward model* é treinado com a perda de Bradley–Terry

$$\mathcal{L}_{RM} = -\log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l)),$$

e o DPO otimiza diretamente

$$\mathcal{L}_{DPO} = -\log \sigma\left(\beta \left[\log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right]\right),$$

em que y_w é a resposta preferida e y_l a preterida. Pode arredondar para 4 casas decimais.

- a) (0,5) Para um par com $r_\phi(x, y_w) = 2,2$ e $r_\phi(x, y_l) = 0,7$, compute a probabilidade de o *reward model* preferir y_w (modelo de Bradley–Terry) e o valor de $\mathcal{L}_{RM}$.

- b) (0,5) No DPO com $\beta = 0,2$, os *log-ratios* valem $\log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} = 1,5$ e $\log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} = -1,0$. Compute $\mathcal{L}_{DPO}$ e explique em uma frase o que o DPO dispensa em relação ao *pipeline* completo do RLHF.

- 10) (1,0) Considere um modelo difusor com $T = 2$ e *noise schedule* $\beta = (0,4; 0,25)$. Pode arredondar para 4 casas decimais.

- a) (0,5) Compute α_1 e α_2 e, para a instância $x = 2$ com ruído $\epsilon = 0,5$, o valor de z_2 obtido pelo kernel de difusão.

- b) (0,5) Com a estimativa de ruído $g_2[z_2, \theta_2] = 0,6$ e tomando $\sigma_2 = 0$ (amostragem determinística), compute $\hat{z}_1$ pela equação de amostragem reversa. Em seguida, explique em uma frase o papel do termo $\sigma_t \epsilon$ que foi ignorado.