

- I) Por que usamos arquiteturas baseadas em *encoder-decoder* para realizar segmentação semântica?
- II) Explique como as tarefas de localização e detecção de objetos são diferentes.
- III) Explique como aproveitar uma VGG-16 pré-treinada no ImageNET para realizar classificação de cães e gatos. Sua explicação deve contemplar quais as camadas da VGG-16 você deveria manter e quais você deveria treinar novamente. Suponha que você dispõe de um conjunto de dados relativamente pequeno, com cerca de 250 instâncias para cada classe.
- IV) Considere a tarefa de localização de um único objeto, em que a cabeça de localização produz uma *bounding box* $\mathbf{y} = (x, y, h, w)$. Suponha uma caixa de *ground truth* A com canto superior esquerdo em $(1, 1)$ e canto inferior direito em $(5, 4)$, e uma caixa prevista B com canto superior esquerdo em $(3, 2)$ e canto inferior direito em $(7, 5)$. Calcule a *Intersection over Union* (IoU) e o *Dice Score* entre A e B .
- V) Na arquitetura usada para localização, a cabeça densa termina em 4 unidades com ativação sigmoide e a função de custo é o erro quadrático médio (MSE).
- a) Por que usamos 4 unidades sigmoide e MSE, em vez de uma *softmax* com entropia cruzada como na classificação?
 - b) Qual hipótese implícita sobre a posição da caixa essa parametrização assume?
 - c) Como você adaptaria a saída para representar caixas que ultrapassam as bordas da imagem?
- VI) Para resolver classificação e localização simultaneamente, compartilhamos o *backbone* convolucional e usamos duas cabeças densas independentes, com a função de custo combinada $\mathcal{L} = \mathcal{L}_{\text{classif.}} + \lambda \mathcal{L}_{\text{loc.}}$. Explique o papel do hiperparâmetro λ e descreva o que tende a acontecer com o treinamento se λ for muito grande ou muito pequeno.
- VII) A detecção de objetos não pode ser resolvida com a mesma cabeça de saída de tamanho fixo (uma *softmax* mais 4 unidades sigmoide) usada na tarefa de classificação com localização.
- a) Qual é a dificuldade central da detecção que torna uma saída de tamanho fixo inadequada?
 - b) Contraste detectores de dois estágios (como o Faster R-CNN) com detectores de estágio único (como o YOLO) quanto à forma de propor regiões e ao compromisso entre velocidade e precisão.
- VIII) Explique a diferença entre segmentação semântica e segmentação de instâncias. Use como exemplo uma imagem com dois gatos lado a lado e descreva como cada tarefa representaria esses dois animais na saída.

Gabarito

- I) Teríamos duas alternativas se não fossemos fazer com *encoder-decoder*: 1 - Usar convoluções sem fazer *downsampling*, o que ficaria inviável devido ao número de parâmetros necessários e quantidade de processamento gasto; 2 - Fazer uma rede convolucional que tem *downsampling* e rodar ela várias vezes em diferentes patches da imagem, o que seria proibitivo também em termos de custo computacional. Para realizar a segmentação da imagem em apenas uma passada, a arquitetura *encoder-decoder* possibilita toda a segmentação ser realizada em uma passada e mantém o número de parâmetros baixo.
- II) A localização é uma tarefa mais simples que detecção de objetos pois só estamos trabalhando com a posição do objeto de interesse na imagem, não com a determinação de sua classe. Por outro lado, na detecção de objetos tipicamente realizamos tanto a classificação e quanto a localização de objetos em uma imagem.
- III) As camadas convolucionais da VGG-16 são responsáveis por extrair características básicas de baixo nível, como bordas e texturas, não necessitam de novo treinamento. Por outro lado, as camadas densas finais estão intimamente relacionadas ao conjunto de dados original (ImageNet). Uma abordagem usual é manter as camadas convolucionais e treinar novamente as camadas densas na extremidade da rede. Isso é um exemplo de *transfer learning* pois estamos aproveitando um aprendizado realizado em um vasto conjunto de dados para ajustar para o nosso problema específico.
- IV) Áreas e sobreposição: $Area(A) = 4 \times 3 = 12$ e $Area(B) = 4 \times 3 = 12$. A interseção ocorre em $x \in [3, 5]$ (largura 2) e $y \in [2, 4]$ (altura 2), logo $A \cap B = 2 \times 2 = 4$. A união é $A \cup B = Area(A) + Area(B) - A \cap B = 12 + 12 - 4 = 20$.
- $$IoU = \frac{A \cap B}{A \cup B} = \frac{4}{20} = 0.2 \quad Dice = \frac{2 \cdot (A \cap B)}{Area(A) + Area(B)} = \frac{2 \cdot 4}{12 + 12} = \frac{8}{24} \approx 0.333$$
- V) a. Porque a *bounding box* é um problema de regressão multivariada de 4 valores contínuos e independentes, não uma escolha entre classes mutuamente exclusivas. A sigmoide mantém cada saída em $[0, 1]$, compatível com coordenadas normalizadas, e o MSE mede o erro de regressão. Uma *softmax* forçaria as 4 saídas a competir e somar 1, o que não faz sentido para coordenadas.
- b. Assume que a caixa cabe inteiramente dentro da imagem, com $(x, y) \in [0, 1]^2$ e $h, w \in [0, 1]$.
- c. Usando outra parametrização, por exemplo *logits* sem ativação (permitindo valores fora de $[0, 1]$) ou regredindo *offsets* em relação a uma *anchor*.
- VI) O *backbone* convolucional extrai *features* compartilhadas pelas duas cabeças. O λ equilibra os dois termos de custo, que vivem em escalas diferentes (entropia cruzada para a classe e MSE para a caixa). Se λ for muito grande, o treinamento prioriza a localização e a acurácia de classificação tende a piorar; se for muito pequeno, a regressão da caixa fica subtreinada e a localização fica imprecisa. O objetivo é manter os gradientes das duas tarefas em magnitudes comparáveis.
- VII) a. Não sabemos de antemão quantos objetos aparecem em cada imagem, então o número de caixas e classes a prever é variável. Uma cabeça de tamanho fixo só consegue representar um número predeterminado de saídas.

- b. Detectores de dois estágios (Faster R-CNN) primeiro propõem regiões candidatas (via *Region Proposal Network*) e depois classificam e refinam cada uma; são tipicamente mais precisos, porém mais lentos. Detectores de estágio único (YOLO) dividem a imagem em uma grade e preveem classe e caixa em uma única passada; são muito mais rápidos, operando em tempo real, ao custo de menor precisão, especialmente em objetos pequenos.
- VIII) Na segmentação semântica cada pixel recebe uma classe, e todas as instâncias de uma mesma classe compartilham o mesmo rótulo. Os dois gatos apareceriam como uma única máscara da classe “gato”. Na segmentação de instâncias, instâncias diferentes da mesma classe são diferenciadas, então cada gato receberia uma máscara distinta. A segmentação de instâncias combina a separação de objetos (como na detecção) com a classificação em nível de pixel.