

Questões de Múltipla Escolha

- I) Uma célula LSTM recebe entradas de dimensão $is = 10$ e mantém um estado oculto de dimensão $hs = 20$. Cada uma das quatro camadas densas internas tem pesos $\theta_{\bullet} \in \mathbb{R}^{(hs+is) \times hs}$ e *bias* $b_{\bullet} \in \mathbb{R}^{hs}$. Quantos parâmetros treináveis (pesos e *bias*) a célula possui no total?
- a) 2480.
 - b) 2400.
 - c) 1860.
 - d) 1240.
- II) Considere a atualização da memória $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$. Qual configuração das *gates* faz a célula **preservar integralmente** a memória de longo prazo e **ignorar** a entrada do passo atual?
- a) $f_t \rightarrow 1$ e $i_t \rightarrow 0$.
 - b) $f_t \rightarrow 0$ e $i_t \rightarrow 1$.
 - c) $f_t \rightarrow 1$ e $i_t \rightarrow 1$.
 - d) $f_t \rightarrow 0$ e $i_t \rightarrow 0$.
- III) Em um passo de uma LSTM o *output gate* resultou em $o_t = 0,6$ e a memória atualizada foi $c_t = 0,5$. Usando $h_t = o_t \odot \tanh(c_t)$, qual é o valor de h_t ?
- a) $\approx 0,2773$.
 - b) $\approx 0,3000$.
 - c) $\approx 0,2913$.
 - d) $\approx 0,4621$.
- IV) Na GRU, o estado oculto é atualizado por $h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$. Quando o *update gate* satisfaz $z_t \rightarrow 0$, o que ocorre com o estado oculto?
- a) $h_t \approx h_{t-1}$.
 - b) $h_t \approx \tilde{h}_t$.
 - c) $h_t \approx 0$.
 - d) $h_t \approx r_t \odot h_{t-1}$.

Gabarito - Objetivas

- I) **a.** Cada *gate* tem $(h_s + i_s) \cdot h_s$ pesos mais h_s *bias*, isto é, $(30)(20) + 20 = 620$ parâmetros. Com quatro camadas densas, $4 \cdot 620 = 2480$. A alternativa (b) 2400 esquece os *bias* ($4 \cdot 600$); (c) 1860 usa apenas três camadas (é a conta de uma GRU); (d) 1240 conta apenas duas camadas.
- II) **a.** Para manter c_{t-1} e bloquear a contribuição nova é preciso $f_t \rightarrow 1$ (preserva a memória) e $i_t \rightarrow 0$ (zera $i_t \odot \tilde{c}_t$). As demais ou apagam a memória ($f_t \rightarrow 0$) ou deixam a entrada atualizar o estado ($i_t \rightarrow 1$).
- III) **a.** $h_t = 0,6 \cdot \tanh(0,5) = 0,6 \cdot 0,4621 \approx 0,2773$. A alternativa (b) 0,3000 esquece o $\tanh$; (c) 0,2913 aplica $\tanh$ *depois* do produto, $\tanh(0,3)$; (d) 0,4621 esquece de multiplicar por o_t .
- IV) **a.** Com $z_t \rightarrow 0$, $h_t = 1 \cdot h_{t-1} + 0 \cdot \tilde{h}_t = h_{t-1}$: o estado anterior é copiado. A alternativa (b) corresponde a $z_t \rightarrow 1$; (c) e (d) não correspondem à equação de atualização.

Questões Dissertativas

- I) Considere uma célula LSTM *escalar* com estado inicial $c_0 = 0,2$, $h_0 = 0,5$ e entrada $x_0 = -0,4$, de modo que o vetor concatenado é $[h_0, x_0] = [0,5, -0,4]$. Cada camada densa interna tem pesos $\theta_\bullet = [\theta_h, \theta_x]$ que multiplicam $[h_{t-1}, x_t]^T$:

$$\theta_f = [0,4, 0,6], \quad b_f = -0,1; \quad \theta_i = [0,5, -0,2], \quad b_i = 0,1;$$

$$\theta_c = [-0,3, 0,5], \quad b_c = 0,4; \quad \theta_o = [0,2, 0,3], \quad b_o = 0.$$

Calcule, passo a passo (use 4 casas decimais):

- (a) o *forget gate* f_t e o *input gate* i_t ;
- (b) o candidato $\tilde{c}_t$;
- (c) a nova memória $c_t = f_t c_0 + i_t \tilde{c}_t$;
- (d) o *output gate* o_t e o estado oculto $h_t = o_t \tanh(c_t)$.

- II) A LSTM foi projetada para mitigar o *vanishing gradient* das RNNs simples.

- (a) A partir da atualização $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$, mostre que, pelo *caminho direto* no tempo, $\frac{\partial c_t}{\partial c_{t-1}} = f_t$. Explique por que isso evita o desaparecimento do gradiente, comparando com a RNN *vanilla*, cujo gradiente acumula o produto $\prod_k \theta_{hh} (1 - \tanh^2(z_k))$.
- (b)  A GRU não mantém um estado de memória c_t separado; o estado é atualizado por $h_t = (1 - z_t) h_{t-1} + z_t \tilde{h}_t$. Identifique qual termo desempenha, na GRU, o papel análogo ao do *forget gate* da LSTM na preservação do gradiente e diga sob qual condição do *update gate* z_t o gradiente é carregado quase sem atenuação.

Gabarito

- I) *Forward pass* escalar de um passo da LSTM.

- (a) *Forget* e *input gates*:

$$f_t = \sigma(0,4 \cdot 0,5 + 0,6 \cdot (-0,4) - 0,1) = \sigma(-0,14) \approx 0,4651$$

$$i_t = \sigma(0,5 \cdot 0,5 + (-0,2) \cdot (-0,4) + 0,1) = \sigma(0,43) \approx 0,6059$$

- (b) Candidato:

$$\tilde{c}_t = \tanh(-0,3 \cdot 0,5 + 0,5 \cdot (-0,4) + 0,4) = \tanh(0,05) \approx 0,0500$$

- (c) Nova memória:

$$c_t = 0,4651 \cdot 0,2 + 0,6059 \cdot 0,0500 \approx 0,0930 + 0,0303 = 0,1233$$

- (d) *Output gate* e estado oculto:

$$o_t = \sigma(0,2 \cdot 0,5 + 0,3 \cdot (-0,4) + 0) = \sigma(-0,02) \approx 0,4950$$

$$h_t = 0,4950 \cdot \tanh(0,1233) \approx 0,4950 \cdot 0,1227 \approx 0,0607$$

II) Por que o caminho da memória preserva o gradiente.

- (a) Derivando $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$ em relação a c_{t-1} , o termo direto $f_t \odot c_{t-1}$ contribui com f_t ; os fatores f_t , i_t e $\tilde{c}_t$ dependem de c_{t-1} apenas indiretamente, através de h_{t-1} , formando caminhos secundários menores. Logo, pelo caminho direto, $\partial c_t / \partial c_{t-1} = f_t$. Ao longo de T passos esse caminho acumula $\prod_k f_k$: são multiplicações por portas aprendidas e **somas**, sem $\tanh'$ repetido. Quando o *forget gate* aprende $f_k \approx 1$, o produto permanece ≈ 1 e o gradiente é preservado (*constant error carousel*). Na RNN *vanilla*, cada passo multiplica por $\theta_{hh} (1 - \tanh^2(z_k))$; como $1 - \tanh^2 \leq 1$, o produto tende a 0 (*vanishing*) ou, com $|\theta_{hh}|$ grande, explode.
- (b) Na GRU, o fator $(1 - z_t)$ multiplica h_{t-1} no caminho direto, então $\partial h_t / \partial h_{t-1} = (1 - z_t)$ por esse caminho, papel análogo ao f_t da LSTM. Quando $z_t \approx 0$ (*update gate* “fechado”), tem-se $(1 - z_t) \approx 1$ e o estado é carregado com gradiente ≈ 1 , preservando a informação ao longo do tempo.