

Questões de Múltipla Escolha

- I) Um *Language Model* atribui $P(\text{The}) = 0.5$, $P(\text{dog} \mid \text{The}) = 0.4$ e $P(\text{runs} \mid \text{The dog}) = 0.3$. Qual é a probabilidade conjunta da frase *The dog runs*?
- 0.06.
 - 0.12.
 - 1.20.
 - 0.20.
- II) A camada de saída de um LM calcula logits $= Wh + b$ a partir de um vetor de contexto $h \in \mathbb{R}^d$, com $W \in \mathbb{R}^{|V| \times d}$. Para $d = 8$ e vocabulário $|V| = 50$, quantos parâmetros treináveis (pesos e *bias*) essa camada possui?
- 450.
 - 400.
 - 408.
 - 58.
- III) Em um passo de treino, o modelo atribui probabilidade $p(y_t \mid y_{<t}) = 0.25$ ao *token* correto. Usando $\mathcal{L} = -\ln(p(y_t \mid y_{<t}))$, qual é o valor da *cross-entropy* nesse passo?
- ≈ 1.386 .
 - 2.
 - ≈ -1.386 .
 - 0.25.
- IV) Aplicando *Beam Search* com *beam size* $b = 2$ a partir de *The*, com as probabilidades abaixo (o *token car* é podado no primeiro passo):

1º passo	2º passo
nice (0.6)	→ woman (0.4), guy (0.3), house (0.3)
dog (0.3)	→ has (0.9), runs (0.05), and (0.05)
car (0.1)	(podado)

Qual sequência o *Beam Search* seleciona como a mais provável?

- The dog has.
 - The nice woman.
 - The nice guy.
 - The dog runs.
- V) Um vocabulário de dois *tokens* produz logits $z = [2, 1]$. Aplicando temperatura $\tau = 0.5$ na *softmax*, qual é a probabilidade do *token* de maior *logit*?
- ≈ 0.881 .

- b) ≈ 0.731 .
- c) ≈ 0.622 .
- d) ≈ 0.500 .

VI) Em *Top-P (nucleus) sampling*, a distribuição do próximo *token* é, em ordem decrescente:

<i>token</i>	w_1	w_2	w_3	w_4	w_5
P	0.50	0.25	0.15	0.07	0.03

Para $p = 0.90$, quantos *tokens* compõem o núcleo do qual se amostra?

- a) 3.
- b) 2.
- c) 4.
- d) 5.

VII) Um modelo avalia uma sentença de $m = 3$ *tokens*, atribuindo probabilidades $p(y_t | y_{<t}) = 0.5, 0.5, 0.125$. Usando $\text{Perplexidade} = 2^{-\frac{1}{m}L}$ com $L = \sum_t \log_2 p(y_t | y_{<t})$, qual é a perplexidade?

- a) ≈ 3.17 .
- b) ≈ 5.00 .
- c) ≈ 2.38 .
- d) ≈ 1.67 .

VIII) Em um passo do *decoder*, os *scores* de atenção para três estados do *encoder* são $\text{score}(h_t, s_k) = [3, 1, 0]$. Usando $a_k^{(t)} = \frac{\exp(\text{score}(h_t, s_k))}{\sum_i \exp(\text{score}(h_t, s_i))}$, qual é o peso de atenção $a_1^{(t)}$ do primeiro estado?

- a) ≈ 0.844 .
- b) ≈ 0.750 .
- c) ≈ 0.114 .
- d) ≈ 0.333 .

IX) Os pesos de atenção de um passo são $a^{(t)} = [0.6, 0.3, 0.1]$ e os estados do *encoder* são $s_1 = (2; 0)$, $s_2 = (0; 4)$ e $s_3 = (-2; -2)$. Qual é o *context vector* $c^{(t)} = \sum_k a_k^{(t)} s_k$?

- a) (1.0; 1.0).
- b) (1.2; 1.2).
- c) (0.0; 0.67).
- d) (0.0; 2.0).

X) 🧠 Para reduzir o viés do *Beam Search* a favor de sequências curtas, usa-se o *score* normalizado $\frac{1}{n^\alpha} \sum_{t=1}^n \log(P(y_t | y_{<t}))$. Um candidato B tem $n = 4$ *tokens* e $\sum_t \log P(y_t | y_{<t}) = -1.6$. Com $\alpha = 1$, qual é o *score* normalizado de B ?

- a) -0.40 .
- b) -0.80 .
- c) -1.60 .
- d) -6.40 .

Gabarito - Objetivas

- I) a. Pela regra da cadeia, $P = 0.5 \cdot 0.4 \cdot 0.3 = 0.06$. A alternativa (b) 0.12 esquece o primeiro fator $P(\text{The})$; (c) 1.20 soma as probabilidades em vez de multiplicar; (d) 0.20 usa apenas os dois primeiros fatores.
- II) a. A matriz W tem $|V| \cdot d = 50 \cdot 8 = 400$ pesos e o *bias* $b \in \mathbb{R}^{|V|}$ acrescenta 50, totalizando 450. A alternativa (b) 400 ignora o *bias*; (c) 408 usa um *bias* de dimensão d (entrada) em vez de $|V|$ (saída); (d) 58 soma $|V| + d$ em vez de multiplicar.
- III) a. $\mathcal{L} = -\ln(0.25) \approx 1.386$. A alternativa (b) 2 usa $-\log_2(0.25)$ em vez de logaritmo natural; (c) -1.386 esquece o sinal negativo da *cross-entropy*; (d) 0.25 devolve a própria probabilidade sem aplicar $-\ln$.
- IV) a. Com $b = 2$ sobrevivem *nice* e *dog*. As melhores expansões dão $P(\text{The dog has}) = 0.3 \cdot 0.9 = 0.27$ e $P(\text{The nice woman}) = 0.6 \cdot 0.4 = 0.24$, logo *The dog has* vence. A alternativa (b) escolhe pelo *token* localmente mais provável (*nice*), erro do *greedy search*; (c) $0.6 \cdot 0.3 = 0.18$ e (d) $0.3 \cdot 0.05 = 0.015$ têm probabilidade conjunta menor.
- V) a. Dividir os *logits* por $\tau = 0.5$ equivale a multiplicá-los por 2: $z/\tau = [4, 2]$. Então $\frac{e^4}{e^4 + e^2} = \frac{54.60}{54.60 + 7.39} \approx 0.881$. A alternativa (b) 0.731 usa $\tau = 1$ (sem temperatura); (c) 0.622 multiplica os *logits* por τ em vez de dividir, obtendo $[1; 0.5]$; (d) 0.500 supõe distribuição uniforme.
- VI) a. As probabilidades acumuladas são 0.50, 0.75, 0.90, 0.97, 1.00. O menor conjunto cuja massa acumulada atinge 0.90 é $\{w_1, w_2, w_3\}$, isto é, 3 *tokens*. A alternativa (b) 2 para em 0.75, antes de atingir p ; (c) 4 e (d) 5 incluem *tokens* além do necessário para alcançar 0.90.
- VII) a. $\log_2 p = [-1, -1, -3]$, então $L = -5$ e $-\frac{1}{m}L = \frac{5}{3} \approx 1.667$; logo Perplexidade $= 2^{1.667} \approx 3.17$. A alternativa (b) 5.00 devolve $|L|$ sem exponenciar; (c) 2.38 é o resultado do exemplo dos slides ($m = 4$, expoente 1.25), com parâmetros diferentes; (d) 1.67 devolve apenas o expoente $-\frac{1}{m}L$.
- VIII) a. $\exp(\text{scores}) = [20.09; 2.72; 1.00]$, com soma ≈ 23.80 ; então $a_1^{(t)} = 20.09/23.80 \approx 0.844$. A alternativa (b) 0.750 normaliza os *scores* linearmente ($3/(3+1+0)$) em vez de aplicar *softmax*; (c) 0.114 é o peso $a_2^{(t)}$ do segundo estado; (d) 0.333 supõe pesos uniformes.
- IX) a. $c^{(t)} = 0.6(2; 0) + 0.3(0; 4) + 0.1(-2; -2) = (1.2 - 0.2; 1.2 - 0.2) = (1.0; 1.0)$. A alternativa (b) (1.2; 1.2) ignora a contribuição de s_3 ; (c) (0.0; 0.67) faz a média simples dos vetores sem os pesos; (d) (0.0; 2.0) soma os vetores sem ponderar.
- X) a. $\frac{1}{n\alpha} \sum_t \log P = \frac{1}{41}(-1.6) = -0.40$. A alternativa (b) -0.80 divide por 2 (comprimento errado); (c) -1.60 não aplica normalização alguma; (d) -6.40 multiplica por n em vez de dividir. Como o candidato B fica com -0.40 , ele pode superar uma sequência curta como A ($n = 2$, $\sum \log P = -1.0$, *score* -0.50), que venceria sem a normalização.

Questões Dissertativas

- I) No mecanismo de atenção de *Bahdanau*, o estado do *decoder* é $h_t = (1; 2)$ e há três estados do *encoder*: $s_1 = (2; 0)$, $s_2 = (0; 2)$ e $s_3 = (-1; 1)$. Use $\text{score}(h_t, s_k) = h_t^\top s_k$ e $a_k^{(t)} = \frac{\exp(\text{score}(h_t, s_k))}{\sum_i \exp(\text{score}(h_t, s_i))}$. Calcule, passo a passo (use 4 casas decimais quando necessário):
- os três *scores* $\text{score}(h_t, s_k)$;
 - os pesos de atenção $a_k^{(t)}$;
 - o *context vector* $c^{(t)} = \sum_k a_k^{(t)} s_k$.
- II) Considere a perplexidade $\text{Perplexidade}(y_{1:m}) = 2^{-\frac{1}{m}L}$, com $L = \sum_{t=1}^m \log_2 p(y_t | y_{<t})$.
- Para uma sentença de $m = 4$ *tokens* com $p(y_t | y_{<t}) = 0.25, 0.5, 0.5, 0.25$, calcule L e a perplexidade.
 - Interprete o valor obtido em termos do “número médio efetivo de *tokens*” entre os quais o modelo está em dúvida.
 - ☠️ Mostre que um modelo que atribui distribuição **uniforme** sobre o vocabulário ($p = 1/|V|$ em todos os passos) tem perplexidade exatamente igual a $|V|$, justificando assim o limite superior $\text{Perplexidade} \leq |V|$.
- III) Um *decoder* parte de The e atribui as seguintes probabilidades:

1º passo	2º passo
nice (0.6)	→ woman (0.45), house (0.30), guy (0.25)
dog (0.3)	→ has (0.95), runs (0.03), and (0.02)
car (0.1)	...

- Determine a sequência de duas palavras gerada por *Greedy Search* e sua probabilidade conjunta.
 - Determine a sequência escolhida por *Beam Search* com $b = 2$ e sua probabilidade conjunta.
 - Explique por que as duas estratégias divergem, relacionando o resultado com a natureza *local* da decisão do *Greedy Search*.
- IV) Um modelo produz *logits* $z = [2, 1, 0]$ para três *tokens*.
- Calcule a distribuição *softmax* com $\tau = 1$ e com $\tau = 2$, e mostre numericamente que a temperatura maior torna a distribuição mais *plana*.
 - Explique o *tradeoff* entre coerência e diversidade controlado por τ , descrevendo o comportamento limite quando $\tau \rightarrow 0$ e quando $\tau \rightarrow \infty$.
 - ☠️ O *Top-K* amostra sempre dos K *tokens* mais prováveis, enquanto o *Top-P* amostra do menor conjunto cuja massa acumulada atinge p . Explique por que o *Top-P* se adapta melhor quando a distribuição varia entre passos muito *nítidos* e passos muito *planos*, citando uma situação em que um K fixo seria inadequado.

- V) A métrica **BLEU** compara uma tradução candidata a uma referência usando a precisão modificada com contagens clipadas

$$p_n = \frac{\sum_{g \in G_n} \min(\text{cont}_{\text{cand}}(g), \text{cont}_{\text{ref}}(g))}{\sum_{g \in G_n} \text{cont}_{\text{cand}}(g)},$$

a penalidade por brevidade ($\text{BP} = 1$ se $c > r$, e $\text{BP} = e^{1-r/c}$ se $c \leq r$) e $\text{BLEU} = \text{BP} \cdot \exp(\sum_{n=1}^4 \frac{1}{4} \ln p_n)$, em que c e r são os tamanhos do candidato e da referência. Considere:

Referência: the cat sat on the mat ($r = 6$)

Candidato: the cat sat on a mat ($c = 6$)

- Calcule as precisões modificadas p_1, p_2, p_3 e p_4 .
 - Calcule a penalidade por brevidade e o valor final de BLEU.
 - Se o candidato fosse encurtado para the cat sat on ($c = 4$), qual seria a nova penalidade por brevidade?
- VI) A métrica **ROUGE** avalia um resumo candidato comparando-o a uma referência, com ênfase em *recall*. Para cada variante, calcule *recall* (R), precisão (P) e $F_1 = \frac{2PR}{P+R}$. Considere:

Referência: the boy quickly opened the door

Candidato: the boy opened the door

- ROUGE-1**: sobreposição de unigramas, com contagem clipada.
- ROUGE-2**: sobreposição de bigramas.
- ROUGE-L**: maior subsequência comum (*Longest Common Subsequence*, LCS).

Gabarito

I) Passo completo de atenção.

- (a) *Scores* (produto interno $h_t^\top s_k$ com $h_t = (1; 2)$):

$$\text{score}(h_t, s_1) = 1 \cdot 2 + 2 \cdot 0 = 2,$$

$$\text{score}(h_t, s_2) = 1 \cdot 0 + 2 \cdot 2 = 4,$$

$$\text{score}(h_t, s_3) = 1 \cdot (-1) + 2 \cdot 1 = 1.$$

- (b) Exponenciais: $\exp(2) = 7.3891$, $\exp(4) = 54.5982$, $\exp(1) = 2.7183$, com soma 64.7056. Logo

$$a^{(t)} = \left[\frac{7.3891}{64.7056}; \frac{54.5982}{64.7056}; \frac{2.7183}{64.7056} \right] \approx [0.1142; 0.8438; 0.0420].$$

- (c) *Context vector*:

$$\begin{aligned} c^{(t)} &= 0.1142(2; 0) + 0.8438(0; 2) + 0.0420(-1; 1) \\ &= (0.2284 - 0.0420; 1.6876 + 0.0420) \approx (0.186; 1.730). \end{aligned}$$

O peso domina em s_2 , o estado de maior *score*, e o contexto é puxado nessa direção.

II) Perplexidade.

- (a) $\log_2 p = [-2, -1, -1, -2]$, então $L = -6$ e $-\frac{1}{m}L = \frac{6}{4} = 1.5$. Portanto Perplexidade $= 2^{1.5} \approx 2.828$.
- (b) O modelo se comporta, em média, como se estivesse em dúvida entre cerca de 2.8 *tokens* a cada passo: quanto menor a perplexidade, mais “decidido” (e melhor) é o modelo; o mínimo 1 corresponde a um modelo determinístico e sempre certo.
- (c) Com $p = 1/|V|$ em todos os m passos,

$$L = \sum_{t=1}^m \log_2 \left(\frac{1}{|V|} \right) = -m \log_2 |V|, \quad -\frac{1}{m}L = \log_2 |V|,$$

logo Perplexidade $= 2^{\log_2 |V|} = |V|$. Como a distribuição uniforme é a de maior incerteza, esse é o pior caso e justifica Perplexidade $\in [1, |V|]$.

III) Greedy vs. Beam Search.

- (a) *Greedy*: no 1º passo escolhe nice (0.6, o mais provável) e no 2º escolhe woman (0.45). Sequência The nice woman, com probabilidade $0.6 \cdot 0.45 = 0.27$.
- (b) *Beam* ($b = 2$): mantém nice (0.6) e dog (0.3). As melhores expansões são $0.6 \cdot 0.45 = 0.27$ (The nice woman) e $0.3 \cdot 0.95 = 0.285$ (The dog has). A maior é 0.285, então o *Beam* devolve The dog has.
- (c) O *Greedy* comprometeu-se com nice por ser o *token* localmente mais provável, sem considerar que dog, embora menos provável no 1º passo, leva a uma continuação (has, 0.95) que torna a sequência inteira mais provável. Por manter b hipóteses em paralelo, o *Beam* consegue recuperar essa sequência de maior probabilidade conjunta.

IV) Temperatura e amostragem.

- (a) Com $\tau = 1$: $\exp(z) = [7.389; 2.718; 1.000]$, soma 11.107, $\log p \approx [0.665; 0.245; 0.090]$. Com $\tau = 2$: $z/\tau = [1; 0.5; 0]$, $\exp = [2.718; 1.649; 1.000]$, soma 5.367, $\log p \approx [0.506; 0.307; 0.186]$. A probabilidade do *token* dominante caiu de 0.665 para 0.506 e a do menos provável subiu de 0.090 para 0.186: a distribuição ficou mais plana.
- (b) Temperatura baixa concentra a massa nos *tokens* de maior *logit*: mais coerência, menos diversidade. Temperatura alta espalha a massa: mais diversidade, menos coerência. No limite $\tau \rightarrow 0$ a *softmax* tende ao *argmax* (geração determinística); no limite $\tau \rightarrow \infty$ tende à distribuição uniforme sobre o vocabulário.
- (c) O *Top-P* ajusta o tamanho do conjunto à forma da distribuição: quando ela é *nítida* (um ou dois *tokens* concentram quase toda a massa), o núcleo fica pequeno; quando é *plana* (massa espalhada por muitos *tokens*), o núcleo cresce. Um K fixo não tem essa adaptação: por exemplo, com The light was __, em que on e off somam ≈ 0.89 , um $K = 4$ obrigaria a incluir *tokens* ruidosos (in, at) que mal contribuem; já com uma distribuição plana sobre muitas cores plausíveis, esse mesmo $K = 4$ descartaria opções válidas. O *Top-P* resolve ambos os casos com um único p .

V) BLEU passo a passo.

- (a) Contagens clipadas dos n -grams do candidato the cat sat on a mat contra a referência the cat sat on the mat:
- Unigramas (6 no candidato): casam the, cat, sat, on, mat (= 5); a não aparece na referência. Logo $p_1 = 5/6 \approx 0.833$.

- Bigramas (5): casam the cat, cat sat, sat on (= 3); on a e a mat não casam. Logo $p_2 = 3/5 = 0.6$.
 - Trigramas (4): casam the cat sat, cat sat on (= 2). Logo $p_3 = 2/4 = 0.5$.
 - 4-gramas (3): casa apenas the cat sat on (= 1). Logo $p_4 = 1/3 \approx 0.333$.
- (b) Como $c = r = 6$, a penalidade é $BP = e^{1-6/6} = e^0 = 1$. Então

$$BLEU = 1 \cdot \exp\left(\frac{1}{4}\left(\ln \frac{5}{6} + \ln \frac{3}{5} + \ln \frac{1}{2} + \ln \frac{1}{3}\right)\right) = \exp(-0.621) \approx 0.537.$$

- (c) Com $c = 4$ e $r = 6$, como $c \leq r$, $BP = e^{1-6/4} = e^{-0.5} \approx 0.607$. A penalidade reduz a nota para compensar a saída mais curta.

VI) ROUGE passo a passo. A referência the boy quickly opened the door tem 6 *tokens* (com the duas vezes) e o candidato the boy opened the door tem 5 *tokens*, omitindo quickly.

- (a) **ROUGE-1**: unigramas em comum (clipados) the×2, boy, opened, door = 5; apenas quickly fica de fora.

$$R = \frac{5}{6} \approx 0.833, \quad P = \frac{5}{5} = 1.0, \quad F_1 = \frac{2 \cdot 1.0 \cdot 0.833}{1.0 + 0.833} \approx 0.909.$$

- (b) **ROUGE-2**: bigramas da referência the boy, boy quickly, quickly opened, opened the, the door (5); do candidato the boy, boy opened, opened the, the door (4). Em comum: the boy, opened the, the door = 3.

$$R = \frac{3}{5} = 0.6, \quad P = \frac{3}{4} = 0.75, \quad F_1 = \frac{2 \cdot 0.75 \cdot 0.6}{0.75 + 0.6} \approx 0.667.$$

- (c) **ROUGE-L**: a LCS the boy opened the door tem comprimento 5 (pula quickly, preservando a ordem dos demais *tokens*).

$$R = \frac{5}{6} \approx 0.833, \quad P = \frac{5}{5} = 1.0, \quad F_1 \approx 0.909.$$