

### Questões de Múltipla Escolha

- I) Um *Language Model* atribui  $P(\text{The}) = 0,5$ ,  $P(\text{dog} \mid \text{The}) = 0,4$  e  $P(\text{runs} \mid \text{The dog}) = 0,3$ . Usando a regra da cadeia, qual é a probabilidade conjunta da frase *The dog runs*?
- 0,06.
  - 0,12.
  - 1,20.
  - 0,20.
- II) A camada de saída de um LM calcula logits  $= Wh + b$  a partir de um vetor de contexto  $h \in \mathbb{R}^d$ , com  $W \in \mathbb{R}^{|V| \times d}$ . Para  $d = 8$  e vocabulário  $|V| = 50$ , quantos parâmetros treináveis (pesos e *bias*) essa camada possui?
- 450.
  - 400.
  - 408.
  - 58.
- III) Em um passo de treino, o modelo atribui probabilidade  $p(y_t \mid y_{<t}) = 0,25$  ao *token* correto. Usando  $\mathcal{L} = -\ln(p(y_t \mid y_{<t}))$ , qual é o valor da *cross-entropy* nesse passo?
- $\approx 1,386$ .
  - 2.
  - $\approx -1,386$ .
  - 0,25.
- IV) Aplicando *Beam Search* com *beam size*  $b = 2$  a partir de *The*, com as probabilidades abaixo (o *token car* é podado no primeiro passo):

| 1º passo   | 2º passo                              |
|------------|---------------------------------------|
| nice (0,6) | → woman (0,4), guy (0,3), house (0,3) |
| dog (0,3)  | → has (0,9), runs (0,05), and (0,05)  |
| car (0,1)  | (podado)                              |

Qual sequência o *Beam Search* seleciona como a mais provável?

- The dog has.
  - The nice woman.
  - The nice guy.
  - The dog runs.
- V) Um vocabulário de dois *tokens* produz logits  $z = [2, 1]$ . Aplicando temperatura  $\tau = 0,5$  na *softmax*, qual é a probabilidade do *token* de maior *logit*?
- $\approx 0,881$ .

b)  $\approx 0,731$ .

c)  $\approx 0,622$ .

d)  $\approx 0,500$ .

VI) Em *Top-P (nucleus) sampling*, a distribuição do próximo *token* é, em ordem decrescente:

| <i>token</i> | $w_1$ | $w_2$ | $w_3$ | $w_4$ | $w_5$ |
|--------------|-------|-------|-------|-------|-------|
| <i>P</i>     | 0,50  | 0,25  | 0,15  | 0,07  | 0,03  |

Para  $p = 0,90$ , quantos *tokens* compõem o núcleo do qual se amostra?

a) 3.

b) 2.

c) 4.

d) 5.

VII) Um modelo avalia uma sentença de  $m = 3$  *tokens*, atribuindo probabilidades  $p(y_t | y_{<t}) = 0,5, 0,5, 0,125$ . Usando  $\text{Perplexidade} = 2^{-\frac{1}{m}L}$  com  $L = \sum_t \log_2 p(y_t | y_{<t})$ , qual é a perplexidade?

a)  $\approx 3,17$ .

b)  $\approx 5,00$ .

c)  $\approx 2,38$ .

d)  $\approx 1,67$ .

VIII) Em um passo do *decoder*, os *scores* de atenção para três estados do *encoder* são  $\text{score}(h_t, s_k) = [3, 1, 0]$ . Usando  $a_k^{(t)} = \frac{\exp(\text{score}(h_t, s_k))}{\sum_i \exp(\text{score}(h_t, s_i))}$ , qual é o peso de atenção  $a_1^{(t)}$  do primeiro estado?

a)  $\approx 0,844$ .

b)  $\approx 0,750$ .

c)  $\approx 0,114$ .

d)  $\approx 0,333$ .

IX) Os pesos de atenção de um passo são  $a^{(t)} = [0,6, 0,3, 0,1]$  e os estados do *encoder* são  $s_1 = (2; 0)$ ,  $s_2 = (0; 4)$  e  $s_3 = (-2; -2)$ . Qual é o *context vector*  $c^{(t)} = \sum_k a_k^{(t)} s_k$ ?

a)  $(1,0; 1,0)$ .

b)  $(1,2; 1,2)$ .

c)  $(0,0; 0,67)$ .

d)  $(0,0; 2,0)$ .

X) 🦴 Para reduzir o viés do *Beam Search* a favor de sequências curtas, usa-se o *score* normalizado  $\frac{1}{n^\alpha} \sum_{t=1}^n \log(P(y_t | y_{<t}))$ . Um candidato  $B$  tem  $n = 4$  *tokens* e  $\sum_t \log P(y_t | y_{<t}) = -1,6$ . Com  $\alpha = 1$ , qual é o *score* normalizado de  $B$ ?

- a)  $-0,40$ .
- b)  $-0,80$ .
- c)  $-1,60$ .
- d)  $-6,40$ .

### Gabarito - Objetivas

- I) a. Pela regra da cadeia,  $P = 0,5 \cdot 0,4 \cdot 0,3 = 0,06$ . A alternativa (b)  $0,12$  esquece o primeiro fator  $P(\text{The})$ ; (c)  $1,20$  soma as probabilidades em vez de multiplicar; (d)  $0,20$  usa apenas os dois primeiros fatores.
- II) a. A matriz  $W$  tem  $|V| \cdot d = 50 \cdot 8 = 400$  pesos e o *bias*  $b \in \mathbb{R}^{|V|}$  acrescenta 50, totalizando 450. A alternativa (b) 400 ignora o *bias*; (c) 408 usa um *bias* de dimensão  $d$  (entrada) em vez de  $|V|$  (saída); (d) 58 soma  $|V| + d$  em vez de multiplicar.
- III) a.  $\mathcal{L} = -\ln(0,25) \approx 1,386$ . A alternativa (b) 2 usa  $-\log_2(0,25)$  em vez de logaritmo natural; (c)  $-1,386$  esquece o sinal negativo da *cross-entropy*; (d)  $0,25$  devolve a própria probabilidade sem aplicar  $-\ln$ .
- IV) a. Com  $b = 2$  sobrevivem *nice* e *dog*. As melhores expansões dão  $P(\text{The dog has}) = 0,3 \cdot 0,9 = 0,27$  e  $P(\text{The nice woman}) = 0,6 \cdot 0,4 = 0,24$ , logo *The dog has* vence. A alternativa (b) escolhe pelo *token* localmente mais provável (*nice*), erro do *greedy search*; (c)  $0,6 \cdot 0,3 = 0,18$  e (d)  $0,3 \cdot 0,05 = 0,015$  têm probabilidade conjunta menor.
- V) a. Dividir os *logits* por  $\tau = 0,5$  equivale a multiplicá-los por 2:  $z/\tau = [4, 2]$ . Então  $\frac{e^4}{e^4 + e^2} = \frac{54,60}{54,60 + 7,39} \approx 0,881$ . A alternativa (b)  $0,731$  usa  $\tau = 1$  (sem temperatura); (c)  $0,622$  multiplica os *logits* por  $\tau$  em vez de dividir, obtendo  $[1; 0,5]$ ; (d)  $0,500$  supõe distribuição uniforme.
- VI) a. As probabilidades acumuladas são  $0,50, 0,75, 0,90, 0,97, 1,00$ . O menor conjunto cuja massa acumulada atinge  $0,90$  é  $\{w_1, w_2, w_3\}$ , isto é, 3 *tokens*. A alternativa (b) 2 para em  $0,75$ , antes de atingir  $p$ ; (c) 4 e (d) 5 incluem *tokens* além do necessário para alcançar  $0,90$ .
- VII) a.  $\log_2 p = [-1, -1, -3]$ , então  $L = -5$  e  $-\frac{1}{m}L = \frac{5}{3} \approx 1,667$ ; logo Perplexidade  $= 2^{1,667} \approx 3,17$ . A alternativa (b)  $5,00$  devolve  $|L|$  sem exponenciar; (c)  $2,38$  é o resultado do exemplo dos slides ( $m = 4$ , expoente  $1,25$ ), com parâmetros diferentes; (d)  $1,67$  devolve apenas o expoente  $-\frac{1}{m}L$ .
- VIII) a.  $\exp(\text{scores}) = [20,09; 2,72; 1,00]$ , com soma  $\approx 23,80$ ; então  $a_1^{(t)} = 20,09/23,80 \approx 0,844$ . A alternativa (b)  $0,750$  normaliza os *scores* linearmente ( $3/(3+1+0)$ ) em vez de aplicar *softmax*; (c)  $0,114$  é o peso  $a_2^{(t)}$  do segundo estado; (d)  $0,333$  supõe pesos uniformes.
- IX) a.  $c^{(t)} = 0,6(2; 0) + 0,3(0; 4) + 0,1(-2; -2) = (1,2 - 0,2; 1,2 - 0,2) = (1,0; 1,0)$ . A alternativa (b)  $(1,2; 1,2)$  ignora a contribuição de  $s_3$ ; (c)  $(0,0; 0,67)$  faz a média simples dos vetores sem os pesos; (d)  $(0,0; 2,0)$  soma os vetores sem ponderar.
- X) a.  $\frac{1}{n} \sum_t \log P = \frac{1}{41}(-1,6) = -0,40$ . A alternativa (b)  $-0,80$  divide por 2 (comprimento errado); (c)  $-1,60$  não aplica normalização alguma; (d)  $-6,40$  multiplica por  $n$  em vez de dividir. Como o candidato  $B$  fica com  $-0,40$ , ele pode superar uma sequência curta como  $A$  ( $n = 2$ ,  $\sum \log P = -1,0$ , *score*  $-0,50$ ), que venceria sem a normalização.

## Questões Dissertativas

- I) No mecanismo de atenção de *Bahdanau*, o estado do *decoder* é  $h_t = (1; 2)$  e há três estados do *encoder*:  $s_1 = (2; 0)$ ,  $s_2 = (0; 2)$  e  $s_3 = (-1; 1)$ . Use  $\text{score}(h_t, s_k) = h_t^\top s_k$  e  $a_k^{(t)} = \frac{\exp(\text{score}(h_t, s_k))}{\sum_i \exp(\text{score}(h_t, s_i))}$ . Calcule, passo a passo (use 4 casas decimais quando necessário):
- os três *scores*  $\text{score}(h_t, s_k)$ ;
  - os pesos de atenção  $a_k^{(t)}$ ;
  - o *context vector*  $c^{(t)} = \sum_k a_k^{(t)} s_k$ .
- II) Considere a perplexidade  $\text{Perplexidade}(y_{1:m}) = 2^{-\frac{1}{m}L}$ , com  $L = \sum_{t=1}^m \log_2 p(y_t | y_{<t})$ .
- Para uma sentença de  $m = 4$  *tokens* com  $p(y_t | y_{<t}) = 0,25, 0,5, 0,5, 0,25$ , calcule  $L$  e a perplexidade.
  - Interprete o valor obtido em termos do “número médio efetivo de *tokens*” entre os quais o modelo está em dúvida.
  - ☠️ Mostre que um modelo que atribui distribuição **uniforme** sobre o vocabulário ( $p = 1/|V|$  em todos os passos) tem perplexidade exatamente igual a  $|V|$ , justificando assim o limite superior  $\text{Perplexidade} \leq |V|$ .
- III) Um *decoder* parte de The e atribui as seguintes probabilidades:
- | 1º passo   | 2º passo                                 |
|------------|------------------------------------------|
| nice (0,6) | → woman (0,45), house (0,30), guy (0,25) |
| dog (0,3)  | → has (0,95), runs (0,03), and (0,02)    |
| car (0,1)  | ...                                      |
- Determine a sequência de duas palavras gerada por *Greedy Search* e sua probabilidade conjunta.
  - Determine a sequência escolhida por *Beam Search* com  $b = 2$  e sua probabilidade conjunta.
  - Explique por que as duas estratégias divergem, relacionando o resultado com a natureza *local* da decisão do *Greedy Search*.
- IV) Um modelo produz *logits*  $z = [2, 1, 0]$  para três *tokens*.
- Calcule a distribuição *softmax* com  $\tau = 1$  e com  $\tau = 2$ , e mostre numericamente que a temperatura maior torna a distribuição mais *plana*.
  - Explique o *tradeoff* entre coerência e diversidade controlado por  $\tau$ , descrevendo o comportamento limite quando  $\tau \rightarrow 0$  e quando  $\tau \rightarrow \infty$ .
  - ☠️ O *Top-K* amostra sempre dos  $K$  *tokens* mais prováveis, enquanto o *Top-P* amostra do menor conjunto cuja massa acumulada atinge  $p$ . Explique por que o *Top-P* se adapta melhor quando a distribuição varia entre passos muito *nítidos* e passos muito *planos*, citando uma situação em que um  $K$  fixo seria inadequado.

- V) A métrica **BLEU** compara uma tradução candidata a uma referência usando a precisão modificada com contagens clipadas

$$p_n = \frac{\sum_{g \in G_n} \min(\text{cont}_{\text{cand}}(g), \text{cont}_{\text{ref}}(g))}{\sum_{g \in G_n} \text{cont}_{\text{cand}}(g)},$$

a penalidade por brevidade ( $\text{BP} = 1$  se  $c > r$ , e  $\text{BP} = e^{1-r/c}$  se  $c \leq r$ ) e  $\text{BLEU} = \text{BP} \cdot \exp(\sum_{n=1}^4 \frac{1}{4} \ln p_n)$ , em que  $c$  e  $r$  são os tamanhos do candidato e da referência. Considere:

Referência: the cat sat on the mat ( $r = 6$ )

Candidato: the cat sat on a mat ( $c = 6$ )

- Calcule as precisões modificadas  $p_1$ ,  $p_2$ ,  $p_3$  e  $p_4$ .
  - Calcule a penalidade por brevidade e o valor final de BLEU.
  - Se o candidato fosse encurtado para the cat sat on ( $c = 4$ ), qual seria a nova penalidade por brevidade?
- VI) A métrica **ROUGE** avalia um resumo candidato comparando-o a uma referência, com ênfase em *recall*. Para cada variante, calcule *recall* ( $R$ ), precisão ( $P$ ) e  $F_1 = \frac{2PR}{P+R}$ . Considere:

Referência: the boy quickly opened the door

Candidato: the boy opened the door

- ROUGE-1**: sobreposição de unigramas, com contagem clipada.
- ROUGE-2**: sobreposição de bigramas.
- ROUGE-L**: maior subsequência comum (*Longest Common Subsequence*, LCS).

## Gabarito

### I) Passo completo de atenção.

- (a) *Scores* (produto interno  $h_t^T s_k$  com  $h_t = (1; 2)$ ):

$$\text{score}(h_t, s_1) = 1 \cdot 2 + 2 \cdot 0 = 2,$$

$$\text{score}(h_t, s_2) = 1 \cdot 0 + 2 \cdot 2 = 4,$$

$$\text{score}(h_t, s_3) = 1 \cdot (-1) + 2 \cdot 1 = 1.$$

- (b) Exponenciais:  $\exp(2) = 7,3891$ ,  $\exp(4) = 54,5982$ ,  $\exp(1) = 2,7183$ , com soma 64,7056. Logo

$$a^{(t)} = \left[ \frac{7,3891}{64,7056}; \frac{54,5982}{64,7056}; \frac{2,7183}{64,7056} \right] \approx [0,1142; 0,8438; 0,0420].$$

- (c) *Context vector*:

$$\begin{aligned} c^{(t)} &= 0,1142(2; 0) + 0,8438(0; 2) + 0,0420(-1; 1) \\ &= (0,2284 - 0,0420; 1,6876 + 0,0420) \approx (0,186; 1,730). \end{aligned}$$

O peso domina em  $s_2$ , o estado de maior *score*, e o contexto é puxado nessa direção.

### II) Perplexidade.

- (a)  $\log_2 p = [-2, -1, -1, -2]$ , então  $L = -6$  e  $-\frac{1}{m}L = \frac{6}{4} = 1,5$ . Portanto Perplexidade =  $2^{1,5} \approx 2,828$ .
- (b) O modelo se comporta, em média, como se estivesse em dúvida entre cerca de 2,8 *tokens* a cada passo: quanto menor a perplexidade, mais “decidido” (e melhor) é o modelo; o mínimo 1 corresponde a um modelo determinístico e sempre certo.
- (c) Com  $p = 1/|V|$  em todos os  $m$  passos,

$$L = \sum_{t=1}^m \log_2 \left( \frac{1}{|V|} \right) = -m \log_2 |V|, \quad -\frac{1}{m}L = \log_2 |V|,$$

logo Perplexidade =  $2^{\log_2 |V|} = |V|$ . Como a distribuição uniforme é a de maior incerteza, esse é o pior caso e justifica Perplexidade  $\in [1, |V|]$ .

### III) Greedy vs. Beam Search.

- (a) *Greedy*: no 1º passo escolhe nice (0,6, o mais provável) e no 2º escolhe woman (0,45). Sequência The nice woman, com probabilidade  $0,6 \cdot 0,45 = 0,27$ .
- (b) *Beam* ( $b = 2$ ): mantém nice (0,6) e dog (0,3). As melhores expansões são  $0,6 \cdot 0,45 = 0,27$  (The nice woman) e  $0,3 \cdot 0,95 = 0,285$  (The dog has). A maior é 0,285, então o *Beam* devolve The dog has.
- (c) O *Greedy* comprometeu-se com nice por ser o *token* localmente mais provável, sem considerar que dog, embora menos provável no 1º passo, leva a uma continuação (has, 0,95) que torna a *sequência inteira* mais provável. Por manter  $b$  hipóteses em paralelo, o *Beam* consegue recuperar essa sequência de maior probabilidade conjunta.

### IV) Temperatura e amostragem.

- (a) Com  $\tau = 1$ :  $\exp(z) = [7,389; 2,718; 1,000]$ , soma 11,107, logo  $p \approx [0,665; 0,245; 0,090]$ . Com  $\tau = 2$ :  $z/\tau = [1; 0,5; 0]$ ,  $\exp = [2,718; 1,649; 1,000]$ , soma 5,367, logo  $p \approx [0,506; 0,307; 0,186]$ . A probabilidade do *token* dominante caiu de 0,665 para 0,506 e a do menos provável subiu de 0,090 para 0,186: a distribuição ficou mais plana.
- (b) Temperatura baixa concentra a massa nos *tokens* de maior *logit*: mais coerência, menos diversidade. Temperatura alta espalha a massa: mais diversidade, menos coerência. No limite  $\tau \rightarrow 0$  a *softmax* tende ao *argmax* (geração determinística); no limite  $\tau \rightarrow \infty$  tende à distribuição uniforme sobre o vocabulário.
- (c) O *Top-P* ajusta o tamanho do conjunto à forma da distribuição: quando ela é *nítida* (um ou dois *tokens* concentram quase toda a massa), o núcleo fica pequeno; quando é *plana* (massa espalhada por muitos *tokens*), o núcleo cresce. Um  $K$  fixo não tem essa adaptação: por exemplo, com The light was \_\_, em que on e off somam  $\approx 0,89$ , um  $K = 4$  obrigaria a incluir *tokens* ruidosos (in, at) que mal contribuem; já com uma distribuição plana sobre muitas cores plausíveis, esse mesmo  $K = 4$  descartaria opções válidas. O *Top-P* resolve ambos os casos com um único  $p$ .

### V) BLEU passo a passo.

- (a) Contagens clipadas dos  $n$ -grams do candidato the cat sat on a mat contra a referência the cat sat on the mat:
- Unigramas (6 no candidato): casam the, cat, sat, on, mat (= 5); a não aparece na referência. Logo  $p_1 = 5/6 \approx 0,833$ .

- Bigramas (5): casam the cat, cat sat, sat on (= 3); on a e a mat não casam. Logo  $p_2 = 3/5 = 0,6$ .
  - Trigramas (4): casam the cat sat, cat sat on (= 2). Logo  $p_3 = 2/4 = 0,5$ .
  - 4-gramas (3): casa apenas the cat sat on (= 1). Logo  $p_4 = 1/3 \approx 0,333$ .
- (b) Como  $c = r = 6$ , a penalidade é  $BP = e^{1-6/6} = e^0 = 1$ . Então

$$BLEU = 1 \cdot \exp\left(\frac{1}{4}\left(\ln \frac{5}{6} + \ln \frac{3}{5} + \ln \frac{1}{2} + \ln \frac{1}{3}\right)\right) = \exp(-0,621) \approx 0,537.$$

- (c) Com  $c = 4$  e  $r = 6$ , como  $c \leq r$ ,  $BP = e^{1-6/4} = e^{-0,5} \approx 0,607$ . A penalidade reduz a nota para compensar a saída mais curta.

VI) ROUGE passo a passo. A referência the boy quickly opened the door tem 6 *tokens* (com the duas vezes) e o candidato the boy opened the door tem 5 *tokens*, omitindo quickly.

- (a) **ROUGE-1**: unigramas em comum (clipados) the×2, boy, opened, door = 5; apenas quickly fica de fora.

$$R = \frac{5}{6} \approx 0,833, \quad P = \frac{5}{5} = 1,0, \quad F_1 = \frac{2 \cdot 1,0 \cdot 0,833}{1,0 + 0,833} \approx 0,909.$$

- (b) **ROUGE-2**: bigramas da referência the boy, boy quickly, quickly opened, opened the, the door (5); do candidato the boy, boy opened, opened the, the door (4). Em comum: the boy, opened the, the door = 3.

$$R = \frac{3}{5} = 0,6, \quad P = \frac{3}{4} = 0,75, \quad F_1 = \frac{2 \cdot 0,75 \cdot 0,6}{0,75 + 0,6} \approx 0,667.$$

- (c) **ROUGE-L**: a LCS the boy opened the door tem comprimento 5 (pula quickly, preservando a ordem dos demais *tokens*).

$$R = \frac{5}{6} \approx 0,833, \quad P = \frac{5}{5} = 1,0, \quad F_1 \approx 0,909.$$