

Questões de Múltipla Escolha

- I) Um *Language Model* atribui $P(\text{The}) = 0,5$, $P(\text{dog} \mid \text{The}) = 0,4$ e $P(\text{runs} \mid \text{The dog}) = 0,3$. Usando a regra da cadeia, qual é a probabilidade conjunta da frase *The dog runs*?
- 0,06.
 - 0,12.
 - 1,20.
 - 0,20.
- II) A camada de saída de um LM calcula logits $= Wh + b$ a partir de um vetor de contexto $h \in \mathbb{R}^d$, com $W \in \mathbb{R}^{|V| \times d}$. Para $d = 8$ e vocabulário $|V| = 50$, quantos parâmetros treináveis (pesos e *bias*) essa camada possui?
- 450.
 - 400.
 - 408.
 - 58.
- III) Em um passo de treino, o modelo atribui probabilidade $p(y_t \mid y_{<t}) = 0,25$ ao *token* correto. Usando $\mathcal{L} = -\ln(p(y_t \mid y_{<t}))$, qual é o valor da *cross-entropy* nesse passo?
- $\approx 1,386$.
 - 2.
 - $\approx -1,386$.
 - 0,25.
- IV) Aplicando *Beam Search* com *beam size* $b = 2$ a partir de *The*, com as probabilidades abaixo (o *token* *car* é podado no primeiro passo):

1º passo	2º passo
nice (0,6)	→ woman (0,4), guy (0,3), house (0,3)
dog (0,3)	→ has (0,9), runs (0,05), and (0,05)
car (0,1)	(podado)

Qual sequência o *Beam Search* seleciona como a mais provável?

- The dog has.
 - The nice woman.
 - The nice guy.
 - The dog runs.
- V) Um vocabulário de dois *tokens* produz logits $z = [2, 1]$. Aplicando temperatura $\tau = 0,5$ na *softmax*, qual é a probabilidade do *token* de maior *logit*?
- $\approx 0,881$.

b) $\approx 0,731$.

c) $\approx 0,622$.

d) $\approx 0,500$.

VI) Em *Top-P (nucleus) sampling*, a distribuição do próximo *token* é, em ordem decrescente:

<i>token</i>	w_1	w_2	w_3	w_4	w_5
<i>P</i>	0,50	0,25	0,15	0,07	0,03

Para $p = 0,90$, quantos *tokens* compõem o núcleo do qual se amostra?

a) 3.

b) 2.

c) 4.

d) 5.

VII) Um modelo avalia uma sentença de $m = 3$ *tokens*, atribuindo probabilidades $p(y_t | y_{<t}) = 0,5, 0,5, 0,125$. Usando $\text{Perplexidade} = 2^{-\frac{1}{m}L}$ com $L = \sum_t \log_2 p(y_t | y_{<t})$, qual é a perplexidade?

a) $\approx 3,17$.

b) $\approx 5,00$.

c) $\approx 2,38$.

d) $\approx 1,67$.

VIII) Em um passo do *decoder*, os *scores* de atenção para três estados do *encoder* são $\text{score}(h_t, s_k) = [3, 1, 0]$. Usando $a_k^{(t)} = \frac{\exp(\text{score}(h_t, s_k))}{\sum_i \exp(\text{score}(h_t, s_i))}$, qual é o peso de atenção $a_1^{(t)}$ do primeiro estado?

a) $\approx 0,844$.

b) $\approx 0,750$.

c) $\approx 0,114$.

d) $\approx 0,333$.

IX) Os pesos de atenção de um passo são $a^{(t)} = [0,6, 0,3, 0,1]$ e os estados do *encoder* são $s_1 = (2; 0)$, $s_2 = (0; 4)$ e $s_3 = (-2; -2)$. Qual é o *context vector* $c^{(t)} = \sum_k a_k^{(t)} s_k$?

a) $(1,0; 1,0)$.

b) $(1,2; 1,2)$.

c) $(0,0; 0,67)$.

d) $(0,0; 2,0)$.

X) 🦴 Para reduzir o viés do *Beam Search* a favor de sequências curtas, usa-se o *score* normalizado $\frac{1}{n^\alpha} \sum_{t=1}^n \log(P(y_t | y_{<t}))$. Um candidato B tem $n = 4$ *tokens* e $\sum_t \log P(y_t | y_{<t}) = -1,6$. Com $\alpha = 1$, qual é o *score* normalizado de B ?

- a) $-0,40$.
- b) $-0,80$.
- c) $-1,60$.
- d) $-6,40$.

Gabarito - Objetivas

- I) a. Pela regra da cadeia, $P = 0,5 \cdot 0,4 \cdot 0,3 = 0,06$. A alternativa (b) $0,12$ esquece o primeiro fator $P(\text{The})$; (c) $1,20$ soma as probabilidades em vez de multiplicar; (d) $0,20$ usa apenas os dois primeiros fatores.
- II) a. A matriz W tem $|V| \cdot d = 50 \cdot 8 = 400$ pesos e o *bias* $b \in \mathbb{R}^{|V|}$ acrescenta 50, totalizando 450. A alternativa (b) 400 ignora o *bias*; (c) 408 usa um *bias* de dimensão d (entrada) em vez de $|V|$ (saída); (d) 58 soma $|V| + d$ em vez de multiplicar.
- III) a. $\mathcal{L} = -\ln(0,25) \approx 1,386$. A alternativa (b) 2 usa $-\log_2(0,25)$ em vez de logaritmo natural; (c) $-1,386$ esquece o sinal negativo da *cross-entropy*; (d) $0,25$ devolve a própria probabilidade sem aplicar $-\ln$.
- IV) a. Com $b = 2$ sobrevivem *nice* e *dog*. As melhores expansões dão $P(\text{The dog has}) = 0,3 \cdot 0,9 = 0,27$ e $P(\text{The nice woman}) = 0,6 \cdot 0,4 = 0,24$, logo *The dog has* vence. A alternativa (b) escolhe pelo *token* localmente mais provável (*nice*), erro do *greedy search*; (c) $0,6 \cdot 0,3 = 0,18$ e (d) $0,3 \cdot 0,05 = 0,015$ têm probabilidade conjunta menor.
- V) a. Dividir os *logits* por $\tau = 0,5$ equivale a multiplicá-los por 2: $z/\tau = [4, 2]$. Então $\frac{e^4}{e^4 + e^2} = \frac{54,60}{54,60 + 7,39} \approx 0,881$. A alternativa (b) $0,731$ usa $\tau = 1$ (sem temperatura); (c) $0,622$ multiplica os *logits* por τ em vez de dividir, obtendo $[1; 0,5]$; (d) $0,500$ supõe distribuição uniforme.
- VI) a. As probabilidades acumuladas são $0,50, 0,75, 0,90, 0,97, 1,00$. O menor conjunto cuja massa acumulada atinge $0,90$ é $\{w_1, w_2, w_3\}$, isto é, 3 *tokens*. A alternativa (b) 2 para em $0,75$, antes de atingir p ; (c) 4 e (d) 5 incluem *tokens* além do necessário para alcançar $0,90$.
- VII) a. $\log_2 p = [-1, -1, -3]$, então $L = -5$ e $-\frac{1}{m}L = \frac{5}{3} \approx 1,667$; logo Perplexidade $= 2^{1,667} \approx 3,17$. A alternativa (b) $5,00$ devolve $|L|$ sem exponenciar; (c) $2,38$ é o resultado do exemplo dos slides ($m = 4$, expoente $1,25$), com parâmetros diferentes; (d) $1,67$ devolve apenas o expoente $-\frac{1}{m}L$.
- VIII) a. $\exp(\text{scores}) = [20,09; 2,72; 1,00]$, com soma $\approx 23,80$; então $a_1^{(t)} = 20,09/23,80 \approx 0,844$. A alternativa (b) $0,750$ normaliza os *scores* linearmente ($3/(3+1+0)$) em vez de aplicar *softmax*; (c) $0,114$ é o peso $a_2^{(t)}$ do segundo estado; (d) $0,333$ supõe pesos uniformes.
- IX) a. $c^{(t)} = 0,6(2; 0) + 0,3(0; 4) + 0,1(-2; -2) = (1,2 - 0,2; 1,2 - 0,2) = (1,0; 1,0)$. A alternativa (b) $(1,2; 1,2)$ ignora a contribuição de s_3 ; (c) $(0,0; 0,67)$ faz a média simples dos vetores sem os pesos; (d) $(0,0; 2,0)$ soma os vetores sem ponderar.
- X) a. $\frac{1}{n} \sum_t \log P = \frac{1}{41}(-1,6) = -0,40$. A alternativa (b) $-0,80$ divide por 2 (comprimento errado); (c) $-1,60$ não aplica normalização alguma; (d) $-6,40$ multiplica por n em vez de dividir. Como o candidato B fica com $-0,40$, ele pode superar uma sequência curta como A ($n = 2$, $\sum \log P = -1,0$, *score* $-0,50$), que venceria sem a normalização.

Questões Dissertativas

- I) No mecanismo de atenção de *Bahdanau*, o estado do *decoder* é $h_t = (1; 2)$ e há três estados do *encoder*: $s_1 = (2; 0)$, $s_2 = (0; 2)$ e $s_3 = (-1; 1)$. Use $\text{score}(h_t, s_k) = h_t^\top s_k$ e $a_k^{(t)} = \frac{\exp(\text{score}(h_t, s_k))}{\sum_i \exp(\text{score}(h_t, s_i))}$. Calcule, passo a passo (use 4 casas decimais quando necessário):
- os três *scores* $\text{score}(h_t, s_k)$;
 - os pesos de atenção $a_k^{(t)}$;
 - o *context vector* $c^{(t)} = \sum_k a_k^{(t)} s_k$.
- II) Considere a perplexidade $\text{Perplexidade}(y_{1:m}) = 2^{-\frac{1}{m}L}$, com $L = \sum_{t=1}^m \log_2 p(y_t | y_{<t})$.
- Para uma sentença de $m = 4$ *tokens* com $p(y_t | y_{<t}) = 0,25, 0,5, 0,5, 0,25$, calcule L e a perplexidade.
 - Interprete o valor obtido em termos do “número médio efetivo de *tokens*” entre os quais o modelo está em dúvida.
 - ☠️ Mostre que um modelo que atribui distribuição **uniforme** sobre o vocabulário ($p = 1/|V|$ em todos os passos) tem perplexidade exatamente igual a $|V|$, justificando assim o limite superior $\text{Perplexidade} \leq |V|$.
- III) Um *decoder* parte de The e atribui as seguintes probabilidades:
- | 1º passo | 2º passo |
|------------|--|
| nice (0,6) | → woman (0,45), house (0,30), guy (0,25) |
| dog (0,3) | → has (0,95), runs (0,03), and (0,02) |
| car (0,1) | ... |
- Determine a sequência de duas palavras gerada por *Greedy Search* e sua probabilidade conjunta.
 - Determine a sequência escolhida por *Beam Search* com $b = 2$ e sua probabilidade conjunta.
 - Explique por que as duas estratégias divergem, relacionando o resultado com a natureza *local* da decisão do *Greedy Search*.
- IV) Um modelo produz *logits* $z = [2, 1, 0]$ para três *tokens*.
- Calcule a distribuição *softmax* com $\tau = 1$ e com $\tau = 2$, e mostre numericamente que a temperatura maior torna a distribuição mais *plana*.
 - Explique o *tradeoff* entre coerência e diversidade controlado por τ , descrevendo o comportamento limite quando $\tau \rightarrow 0$ e quando $\tau \rightarrow \infty$.
 - ☠️ O *Top-K* amostra sempre dos K *tokens* mais prováveis, enquanto o *Top-P* amostra do menor conjunto cuja massa acumulada atinge p . Explique por que o *Top-P* se adapta melhor quando a distribuição varia entre passos muito *nítidos* e passos muito *planos*, citando uma situação em que um K fixo seria inadequado.

Gabarito**I) Passo completo de atenção.**

(a) *Scores* (produto interno $h_t^\top s_k$ com $h_t = (1; 2)$):

$$\text{score}(h_t, s_1) = 1 \cdot 2 + 2 \cdot 0 = 2,$$

$$\text{score}(h_t, s_2) = 1 \cdot 0 + 2 \cdot 2 = 4,$$

$$\text{score}(h_t, s_3) = 1 \cdot (-1) + 2 \cdot 1 = 1.$$

(b) Exponenciais: $\exp(2) = 7,3891$, $\exp(4) = 54,5982$, $\exp(1) = 2,7183$, com soma 64,7056. Logo

$$a^{(t)} = \left[\frac{7,3891}{64,7056}; \frac{54,5982}{64,7056}; \frac{2,7183}{64,7056} \right] \approx [0,1142; 0,8438; 0,0420].$$

(c) *Context vector*:

$$\begin{aligned} c^{(t)} &= 0,1142(2; 0) + 0,8438(0; 2) + 0,0420(-1; 1) \\ &= (0,2284 - 0,0420; 1,6876 + 0,0420) \approx (0,186; 1,730). \end{aligned}$$

O peso domina em s_2 , o estado de maior *score*, e o contexto é puxado nessa direção.

II) Perplexidade.

(a) $\log_2 p = [-2, -1, -1, -2]$, então $L = -6$ e $-\frac{1}{m}L = \frac{6}{4} = 1,5$. Portanto Perplexidade = $2^{1,5} \approx 2,828$.

(b) O modelo se comporta, em média, como se estivesse em dúvida entre cerca de 2,8 *tokens* a cada passo: quanto menor a perplexidade, mais “decidido” (e melhor) é o modelo; o mínimo 1 corresponde a um modelo determinístico e sempre certo.

(c) Com $p = 1/|V|$ em todos os m passos,

$$L = \sum_{t=1}^m \log_2 \left(\frac{1}{|V|} \right) = -m \log_2 |V|, \quad -\frac{1}{m}L = \log_2 |V|,$$

logo Perplexidade = $2^{\log_2 |V|} = |V|$. Como a distribuição uniforme é a de maior incerteza, esse é o pior caso e justifica Perplexidade $\in [1, |V|]$.

III) Greedy vs. Beam Search.

(a) *Greedy*: no 1º passo escolhe nice (0,6, o mais provável) e no 2º escolhe woman (0,45). Sequência The nice woman, com probabilidade $0,6 \cdot 0,45 = 0,27$.

(b) *Beam* ($b = 2$): mantém nice (0,6) e dog (0,3). As melhores expansões são $0,6 \cdot 0,45 = 0,27$ (The nice woman) e $0,3 \cdot 0,95 = 0,285$ (The dog has). A maior é 0,285, então o *Beam* devolve The dog has.

(c) O *Greedy* comprometeu-se com nice por ser o *token* localmente mais provável, sem considerar que dog, embora menos provável no 1º passo, leva a uma continuação (has, 0,95) que torna a sequência inteira mais provável. Por manter b hipóteses em paralelo, o *Beam* consegue recuperar essa sequência de maior probabilidade conjunta.

IV) Temperatura e amostragem.

- (a) Com $\tau = 1$: $\exp(z) = [7,389; 2,718; 1,000]$, soma 11,107, logo $p \approx [0,665; 0,245; 0,090]$. Com $\tau = 2$: $z/\tau = [1; 0,5; 0]$, $\exp = [2,718; 1,649; 1,000]$, soma 5,367, logo $p \approx [0,506; 0,307; 0,186]$. A probabilidade do *token* dominante caiu de 0,665 para 0,506 e a do menos provável subiu de 0,090 para 0,186: a distribuição ficou mais plana.
- (b) Temperatura baixa concentra a massa nos *tokens* de maior *logit*: mais coerência, menos diversidade. Temperatura alta espalha a massa: mais diversidade, menos coerência. No limite $\tau \rightarrow 0$ a *softmax* tende ao *argmax* (geração determinística); no limite $\tau \rightarrow \infty$ tende à distribuição uniforme sobre o vocabulário.
- (c) O *Top-P* ajusta o tamanho do conjunto à forma da distribuição: quando ela é *nítida* (um ou dois *tokens* concentram quase toda a massa), o núcleo fica pequeno; quando é *plana* (massa espalhada por muitos *tokens*), o núcleo cresce. Um K fixo não tem essa adaptação: por exemplo, com `The light was __`, em que `on` e `off` somam $\approx 0,89$, um $K = 4$ obrigaria a incluir *tokens* ruidosos (`in`, `at`) que mal contribuem; já com uma distribuição plana sobre muitas cores plausíveis, esse mesmo $K = 4$ descartaria opções válidas. O *Top-P* resolve ambos os casos com um único p .