


ATENÇÃO E TRANSFORMERS

MODELOS ENCODER-ONLY

INSTRUÇÕES: Cada questão possui exatamente uma alternativa correta.

QUESTÕES

- I) Um *encoder* bidirecional e um *decoder* causal processam sequências de $N = 5$ tokens. O diagrama abaixo mostra as matrizes de atenção das duas arquiteturas ($\bullet$ = ativo, $\circ$ = mascarado).



Quantas entradas **ativas** ($\bullet$) há na matriz de atenção de cada arquitetura?

- a) Encoder: 25; Decoder: 15.
 - b) Encoder: 25; Decoder: 10 (somente atenção ao passado, excluindo o próprio token).
 - c) Encoder: 20 (sem autoatenção); Decoder: 15.
 - d) Ambos têm 25 entradas ativas.
- II) Na tarefa de *Named Entity Recognition* (NER) com esquema **BIO**, as categorias são: **B**egin (início de entidade), **I**nside (continuação) e **O**utside. Para a frase

Lucas trabalha na PUCRS em Porto Alegre

considerando as entidades *Lucas* (pessoa), *PUCRS* (organização) e *Porto Alegre* (local, dois *tokens*), qual sequência de *tags* é correta?

- a) B-PER, 0, 0, B-ORG, 0, B-LOC, I-LOC
 - b) B-PER, 0, 0, B-ORG, 0, I-LOC, I-LOC
 - c) B-PER, 0, 0, I-ORG, 0, B-LOC, I-LOC
 - d) I-PER, 0, 0, B-ORG, 0, B-LOC, I-LOC
- III) O BERT-Base tem $L = 12$ camadas, dimensão oculta $d = 768$ e $H = 12$ cabeças de atenção com $d_k = d/H = 64$ por cabeça. Em uma única camada de *self-attention*, as projeções são:

$$W^Q, W^K, W^V \in \mathbb{R}^{d \times (H \cdot d_k)}, \quad W^O \in \mathbb{R}^{(H \cdot d_k) \times d}.$$

Ignorando vieses, quantos parâmetros treináveis existem nessas **quatro** matrizes em uma única camada?

- a) 589 824 — apenas W^Q .
 - b) 1 769 472 — W^Q, W^K, W^V sem a projeção de saída W^O .
 - c) 2 359 296 — as quatro matrizes W^Q, W^K, W^V, W^O .
 - d) 4 718 592 — dupla contagem ao considerar dimensões de entrada e saída separadamente para cada projeção.
- IV) No pré-treino do BERT, a estratégia MLM seleciona aleatoriamente 15% dos *tokens*. Um estudante propõe simplificar a regra 80/10/10 substituindo 100% dos *tokens* selecionados pelo *token* especial [MASK] (em vez de 80% por [MASK], 10% por palavra aleatória e 10% mantidos inalterados). Qual é a principal desvantagem dessa simplificação?
- a) O modelo nunca aprende a representar *tokens* reais durante o pré-treino; ao fazer *fine-tuning*, jamais encontra [MASK], criando um desalinhamento entre as duas fases.
 - b) A perda MLM fica indefinida porque [MASK] não faz parte do vocabulário padrão do modelo.
 - c) Os gradientes da posição [MASK] se anulam quando todas as posições selecionadas recebem o mesmo *token*.
 - d) O modelo aprende a ignorar a posição dos *tokens*, pois [MASK] é sempre o mesmo símbolo, independentemente da posição.
- V) A representação de entrada do BERT é $\mathbf{x}_i = E_{\text{token}}(w_i) + E_{\text{segmento}}(s_i) + E_{\text{posição}}(i)$, onde E_{segmento} assume o valor E_A para *tokens* da primeira sentença e E_B para *tokens* da segunda. Um pesquisador remove o componente E_{segmento} para simplificar o modelo. Em qual das seguintes tarefas essa remoção causaria a **maior degradação** de desempenho?
- a) *POS tagging* em uma única sentença.
 - b) Classificação de sentimento em uma única sentença (SST-2).
 - c) *Extractive QA* (SQuAD): identificar o trecho que responde a uma pergunta dado um parágrafo de contexto.
 - d) *Named Entity Recognition* (NER) em uma única sentença.
- VI) O ELECTRA (Clark et al., 2020) substitui o objetivo MLM do BERT pelo *Replaced Token Detection* (RTD): um gerador pequeno cria *tokens* substitutos para $\approx 15\%$ das posições, e o discriminador ELECTRA deve classificar **cada posição** da sequência como “real” ou “substituído”. Comparado ao BERT com MLM, qual é a principal vantagem do ELECTRA em eficiência de treinamento?
- a) O ELECTRA não precisa de uma camada de vocabulário na saída (custo $d \times |V|$), pois a classificação RTD é binária.
 - b) O ELECTRA gera sinal de gradiente em **todas** as posições da sequência — não apenas nos $\approx 15\%$ mascarados do MLM — obtendo desempenho equivalente com $\approx 25\%$ do *compute*.
 - c) O ELECTRA não precisa de *fine-tuning*, pois o RTD já otimiza diretamente tarefas discriminativas como NER.
 - d) O ELECTRA usa *batches* menores que o BERT por precisar do gerador auxiliar, reduzindo o consumo de memória e acelerando o treino por passo.
- VII) Um engenheiro extrai $\mathbf{h}_{[\text{CLS}]}^{(L)}$ (estado oculto final do [CLS]) de um BERT pré-treinado **sem fine-tuning** para medir a similaridade semântica entre sentenças via cosseno. No experimento de Reimers & Gurevych (2019), esse método obtém 20,29 de correlação de Spearman no STS-Benchmark, abaixo do GloVe (58,02). Qual raciocínio explica corretamente esse fenômeno?

- a) O [CLS] foi treinado no NSP, um objetivo binário e ruidoso que não incentiva a organização do espaço para similaridade cosseno; o espaço resultante é anisotrópico (vetores concentrados em um cone estreito), tornando as distâncias cosseno pouco discriminativas.
- b) O BERT usa *position embeddings* aprendidos, logo o [CLS] captura apenas informação posicional e perde a semântica do restante da sentença.
- c) O [CLS] usa apenas os *tokens* da última camada, enquanto o GloVe usa toda a hierarquia de *n*-grams — mais informação leva ao melhor desempenho.
- d) O BERT foi pré-treinado apenas em inglês, e o STS-Benchmark contém sentenças em múltiplos idiomas, favorecendo o GloVe multilíngue.

VIII) No SBERT, o *mean pooling* converte os L vetores de *tokens* $\mathbf{h}_1, \dots, \mathbf{h}_L \in \mathbb{R}^d$ em um único vetor de sentença, ignorando posições [PAD]:

$$\mathbf{u} = \frac{\sum_{i=1}^L m_i \mathbf{h}_i}{\sum_{i=1}^L m_i}, \quad m_i \in \{0, 1\}.$$

Qual é a dimensão de $\mathbf{u}$?

- a) $L \times d$ (concatenação de todos os vetores de *tokens*).
 - b) d (mesma dimensão de cada vetor de *token*).
 - c) d/L (a média reduz a dimensão proporcionalmente ao comprimento).
 - d) 1 (a operação produz um único escalar de similaridade).
- IX) Um sistema de busca semântica precisa classificar $n = 100\,000$ documentos em relação a uma consulta. Um **cross-encoder** requer 1 *forward pass* por par (consulta, documento); um **bi-encoder** pré-computa os documentos *offline* e, no momento da consulta, realiza apenas 1 *forward pass* (para a consulta) seguido de busca vetorial. Cada *forward pass* demora $t = 10$ ms. Qual é a redução de latência no momento da consulta ao usar o bi-encoder?
- a) $\approx 100\times$ — o bi-encoder ainda precisa de 1 *forward pass* por documento durante a consulta.
 - b) $\approx 1\,000\times$ — eliminando o processamento par-a-par para os primeiros 1 000 documentos filtrados.
 - c) $\approx 100\,000\times$ — a consulta requer apenas 10 ms (um único *forward pass*) em vez de $100\,000 \times 10 \text{ ms} = 1\,000 \text{ s}$.
 - d) Equivalente; a busca vetorial requer um produto escalar por documento, igualando o custo do *forward pass*.
- X) Na perda InfoNCE com *in-batch negatives*, um *batch* de $N = 4$ pares (x_i, x_i^+) fornece $N - 1 = 3$ negativos por âncora. Um engenheiro aumenta o *batch* para $N = 1\,024$. Qual é o efeito esperado desse aumento?
- a) O treino fica mais lento por *token*, mas os gradientes são mais informativos: cada âncora deve distinguir seu positivo de 1 023 competidores, melhorando a qualidade dos *embeddings*.
 - b) O treino produz resultado equivalente ao de $N = 4$: a perda InfoNCE é normalizada pelo número de negativos e compensa automaticamente o aumento.
 - c) O treino diverge com N grande porque o denominador do *softmax* fica muito grande, zerando os gradientes.
 - d) O benefício de N grande é apenas computacional (melhor utilização de GPU), sem impacto na qualidade final dos *embeddings*.

- XI)  Considere três *embeddings* (já normalizados) e a *triplet loss* com margem $\alpha = 0,5$:

$$f(x) = [1, 0, 0, 0], \quad f(x^+) = [0, 6, 0, 8], \quad f(x^-) = [-0, 6, 0, 8],$$

$$\mathcal{L}_{\text{triplet}} = \max(0, \|f(x) - f(x^+)\|_2^2 - \|f(x) - f(x^-)\|_2^2 + \alpha).$$

Qual é o valor de $\mathcal{L}_{\text{triplet}}$?

- 0 — a margem já é satisfeita: o positivo está suficientemente mais próximo que o negativo.
- 0,50 — a perda iguala exatamente a margem α quando as duas distâncias são iguais.
- 1,90 — diferença das distâncias quadráticas (sem aplicar o $\max(0, \cdot)$).
- 1,90 — resultado antes do truncamento por zero.

- XII)  O BERT pré-treina com a perda MLM:

$$\mathcal{L}_{\text{MLM}} = -\frac{1}{|M|} \sum_{i \in M} \log p(w_i | \mathbf{w}_{\setminus M}).$$

Em um passo de treino, $|M| = 3$ posições são mascaradas. O modelo atribui as seguintes probabilidades ao *token* correto em cada posição: $p_1 = 0,50$, $p_2 = 0,25$, $p_3 = 0,125$. Qual é o valor de $\mathcal{L}_{\text{MLM}}$?

- $\approx 0,693$ — $-\ln(0,50)$: considera apenas a primeira posição mascarada sem a média.
- $\approx 1,386$ — $2 \ln 2$: média correta das três contribuições.
- $\approx 2,079$ — usa $|M| = 2$ no denominador em vez de $|M| = 3$.
- $\approx 4,159$ — $6 \ln 2$: esquece a normalização $1/|M|$.

SOLUÇÕES

I — Resposta: (a)

No **encoder bidirecional**, cada token pode atender a todos os $N = 5$ tokens (incluindo a si mesmo): $5 \times 5 = 25$ entradas ativas. No **decoder causal**, o token na posição i atende apenas às posições $1, \dots, i$ (passado + si mesmo): $\sum_{i=1}^5 i = 1+2+3+4+5 = 15$ entradas ativas. A opção (b) erra ao excluir a autoatenção do decoder ($5 \times 4/2 = 10$). A opção (c) erra ao excluir a autoatenção do encoder ($5 \times 4 = 20$). A opção (d) iguala os dois padrões, ignorando a máscara causal.

II — Resposta: (a)

O esquema BIO exige que o **primeiro token** de qualquer entidade receba a tag **B-** (Begin), e os tokens subsequentes da mesma entidade recebam **I-** (Inside). Tokens fora de entidades recebem **O**. Na frase:

- “Lucas” → B-PER (inicia a entidade pessoa).
- “PUCRS” → B-ORG (inicia a entidade organização).
- “Porto” → B-LOC (inicia a entidade local de dois tokens).
- “Alegre” → I-LOC (continua a mesma entidade local).

A opção (b) usa I-LOC para “Porto” — erro: nunca se inicia uma entidade com I-. A opção (c) usa I-ORG para “PUCRS” — mesmo erro para organização. A opção (d) usa I-PER para “Lucas” — mesmo erro para pessoa.

III — Resposta: (c)

Como $H \cdot d_k = 12 \times 64 = 768 = d$, todas as quatro matrizes são $\mathbb{R}^{768 \times 768}$. O número de parâmetros em cada uma é $768 \times 768 = 589\,824$, e no total:

$$4 \times 589\,824 = 2\,359\,296.$$

A opção (a) conta apenas W^Q . A opção (b) omite a projeção de saída W^O , que transforma a concatenação das cabeças de volta à dimensão d e é tão grande quanto as demais. A opção (d) duplica o resultado correto — erro de dupla contagem.

IV — Resposta: (a)

O [MASK] é um token **exclusivo do pré-treino**: ele nunca aparece na fase de *fine-tuning* nem na inferência. Se todos os tokens selecionados fossem substituídos por [MASK], o modelo **nunca aprenderia a representar tokens reais**; ao encontrá-los no *fine-tuning*, suas representações seriam subótimas. A regra 80/10/10 mitiga esse desalinhamento ao forçar o modelo a lidar com tokens reais (intactos ou aleatórios) mesmo durante o pré-treino. A opção (b) é falsa: [MASK] é um token do vocabulário do BERT. A opção (c) é falsa: posições com o mesmo *token* ainda produzem gradiente distinto, pois os estados ocultos dependem do contexto. A opção (d) confunde mascaramento com ignorância de posição; a *position embedding* é somada antes de qualquer mascaramento.

V — Resposta: (c)

No formato SQuAD, a entrada é [CLS] pergunta [SEP] contexto [SEP], com os tokens da pergunta recebendo E_A e os do contexto recebendo E_B . Sem *segment embeddings*, o modelo **não distingue** quais tokens são a pergunta e quais são o contexto, degradando drasticamente a tarefa de identificação de *spans*. As tarefas (a), (b) e (d) operam em uma única sentença, portanto todos os tokens compartilhariam E_A — a remoção de E_{segmento} não altera o comportamento nessas tarefas.

VI — Resposta: (b)

No MLM do BERT, o gradiente só flui pelas $\approx 15\%$ das posições mascaradas. No ELECTRA, o discriminador classifica **todas** as L posições (“real” ou “substituído”), gerando gradiente **denso** a cada passo. Esse sinal mais rico permite que o ELECTRA alcance o mesmo desempenho do BERT com $\approx 25\%$ do *compute* de pré-treino. A opção (a) é parcialmente verdadeira (a cabeça de saída é binária), mas a camada de vocabulário do gerador ainda existe; a vantagem principal é o sinal denso. A opção (c) é falsa: o ELECTRA ainda requer *fine-tuning*. A opção (d) inverte o raciocínio: o gerador aumenta o custo por passo, mas o ganho em eficiência vem do sinal mais informativo.

VII — Resposta: (a)

O [CLS] é treinado no NSP — classificação binária “é ou não é a próxima sentença” — sem nenhum incentivo para estruturar o espaço de *embeddings* de forma que **frases similares fiquem próximas**. O resultado é um espaço **anisotrópico**: todos os vetores se concentram em um cone estreito do hiperespaço, tornando as distâncias cosseno pouco discriminativas (frases totalmente diferentes podem ter cosseno $> 0,9$). O GloVe, embora estático, captura co-ocorrências e produz um espaço mais isotrópico, o que o torna superior para STS *vanilla*. A opção (b) confunde *position embeddings* com o objetivo do [CLS]. A opção (c) inventa um mecanismo inexistente. A opção (d) é

falsa: o BERT original foi pré-treinado em inglês, assim como o GloVe mais comum, e o STS-Benchmark é predominantemente em inglês.

VIII — Resposta: (b)

O *mean pooling* calcula a média **ponderada pela máscara de atenção** dos L vetores de tokens, cada um em $\mathbb{R}^d$. A operação de média não altera a dimensão de cada componente; o resultado é um único vetor em $\mathbb{R}^d$ — a mesma dimensão de cada *token embedding* individual. A opção (a) descreve uma **concatenação**, não uma média. A opção (c) é incoerente: médias não reduzem a dimensão de vetores. A opção (d) descreve um produto escalar de similaridade, não um *pooling*.

IX — Resposta: (c)

O cross-encoder requer 1 *forward pass* por par, logo $n = 100\,000$ passes no momento da consulta:

$$100\,000 \times 10 \text{ ms} = 1\,000\,000 \text{ ms} = 1\,000 \text{ s}.$$

O bi-encoder pré-computa todos os documentos *offline*. Na consulta, basta 1 *forward pass* para a *query* (10 ms) seguido de busca vetorial (produto escalar em hardware SIMD, $\ll 1$ ms para 10^5 vetores). Redução de latência:

$$\frac{1\,000\,000 \text{ ms}}{10 \text{ ms}} = 100\,000 \times .$$

A opção (a) erra ao supor que o bi-encoder ainda faz um *forward pass* por documento em tempo de consulta (documentos estão pré-computados). A opção (b) chega a $1\,000\times$ por confundir $n = 100\,000$ com $n = 1\,000$. A opção (d) subestima a diferença de velocidade entre um produto escalar e um *forward pass* completo por um transformer (fator de $\sim 10^4$ – 10^6).

X — Resposta: (a)

Na perda InfoNCE, para cada âncora x_i o positivo x_i^+ deve ser identificado entre todos os x_j^+ do *batch*:

$$\mathcal{L}_{\text{NCE}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{\text{sim}(f(x_i), f(x_i^+))/\tau}}{\sum_{j=1}^N e^{\text{sim}(f(x_i), f(x_j^+))/\tau}}.$$

Com $N = 1\,024$, cada âncora compete com $1\,023$ negativos simultâneos, gerando gradiente mais rico e discriminativo. Empiricamente, o desempenho escala com $\log N$, motivando *batches* de $1\,024$ – $16\,384$ em modelos SOTA. A opção (b) erra: a normalização pelo N no denominador da média **não** é equivalente a neutralizar o efeito de mais negativos — o denominador do *softmax* cresce com N , tornando o problema de classificação mais difícil. A opção (c) erra: o *softmax* com denominador grande concentra gradiente nos negativos mais difíceis, não o zero. A opção (d) erra: mais negativos melhoram a qualidade, não apenas a eficiência.

XI — Resposta: (a)

Cálculo das distâncias quadráticas:

$$\|f(x) - f(x^+)\|_2^2 = (1,0 - 0,6)^2 + (0,0 - 0,8)^2 = 0,16 + 0,64 = 0,80,$$

$$\|f(x) - f(x^-)\|_2^2 = (1,0 - (-0,6))^2 + (0,0 - 0,8)^2 = 2,56 + 0,64 = 3,20.$$

Aplicando a fórmula:

$$\mathcal{L}_{\text{triplet}} = \max(0, 0,80 - 3,20 + 0,50) = \max(0, -1,90) = 0.$$

O positivo ($d^2 = 0,80$) já está 2,40 unidades mais próximo que o negativo ($d^2 = 3,20$), excedendo a margem $\alpha = 0,50$ — o par não viola a restrição e não gera gradiente. A opção (b) ocorreria se as duas distâncias fossem iguais ($d^+ = d^-$); nesse caso $\mathcal{L} = \alpha = 0,50$. A opção (c) é o argumento antes do $\max(0, \cdot)$. A opção (d) é o mesmo sem o valor absoluto.

XII — Resposta: (b)

As probabilidades dos tokens corretos são $p_1 = \frac{1}{2}$, $p_2 = \frac{1}{4}$, $p_3 = \frac{1}{8}$. Aplicando a fórmula com $|M| = 3$:

$$\begin{aligned}\mathcal{L}_{\text{MLM}} &= -\frac{1}{3} \left(\ln \frac{1}{2} + \ln \frac{1}{4} + \ln \frac{1}{8} \right) \\ &= -\frac{1}{3} (-\ln 2 - 2\ln 2 - 3\ln 2) \\ &= \frac{6\ln 2}{3} = 2\ln 2 \approx 1,386.\end{aligned}$$

Análise das alternativas incorretas:

- (a) $\approx 0,693$: considera apenas $-\ln(0,50) = \ln 2$, ou seja, somente a primeira posição, sem a média.
- (c) $\approx 2,079$: usa $|M| = 2$ no denominador ($6\ln 2/2 = 3\ln 2$), como se apenas duas posições fossem mascaradas.
- (d) $\approx 4,159$: omite a normalização $1/|M|$ por completo ($-(\ln \frac{1}{2} + \ln \frac{1}{4} + \ln \frac{1}{8}) = 6\ln 2$).