

# ATENÇÃO E TRANSFORMERS

---

## POSITION ENCODING

**INSTRUÇÕES:** Cada questão possui exatamente uma alternativa correta.

## QUESTÕES

- I) Por que o mecanismo de self-attention padrão precisa de positional encoding?
- a) Porque a função softmax não é diferenciável sem informação de posição.
  - b) Porque o score de atenção  $\mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d}$  depende apenas dos valores dos vetores  $\mathbf{q}_i$  e  $\mathbf{k}_j$ , e não dos índices  $i$  e  $j$ .
  - c) Porque a multiplicação de matrizes não é comutativa.
  - d) Porque os token embeddings são inicializados com zero e precisam de um sinal não nulo.
- II) Qual das seguintes alternativas apresenta a fórmula correta do positional encoding senoidal para a dimensão *par*  $2k$  na posição  $i$ , dada a dimensão de embedding  $d$ ?
- a)  $\cos(i \cdot 10000^{-2k/d})$
  - b)  $\sin(k/10000^{2i/d})$
  - c)  $\sin(i/10000^{2k/d})$
  - d)  $\cos(i/10000^{2k/d})$
- III) Qual método de positional encoding injeta a informação posicional *dentro* da cabeça de atenção, modificando os vetores de query e key, em vez de somar um vetor ao token embedding de entrada?
- a) Positional encoding senoidal (Vaswani et al., 2017)
  - b) Positional encoding absoluto aprendido (BERT)
  - c) Rotary Position Embedding (RoPE)
  - d) No Positional Encoding (NoPE)
- IV) No **ALiBi**, qual modificação é feita no logit de atenção pré-softmax  $A(i, j) = \mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d}$ ?
- a) Um vetor aprendido é somado a cada query.
  - b) Um escalar fixo  $m_h \cdot |i - j|$  é *subtraído* do logit.
  - c) O logit é multiplicado por um fator  $e^{-|i-j|}$ .
  - d) O vetor key é rotacionado por um ângulo proporcional a  $j$ .
- V) Qual é a principal razão pela qual o **NoPE** (No Positional Encoding) generaliza melhor para sequências mais longas do que o positional encoding absoluto?
- a) O NoPE utiliza uma dimensão de embedding maior, aumentando a capacidade do modelo.

- b) O positional encoding absoluto adiciona vetores que ficam fora da distribuição de treinamento para posições além do comprimento treinado, enquanto o NoPE não adiciona nada que possa se tornar fora da distribuição.
  - c) O NoPE aplica um decaimento cosseno a todos os pesos de atenção.
  - d) O NoPE requer um embedding aprendido para cada posição, o que é mais flexível.
- VI) Qual estratégia de positional encoding absoluto possui um *limite rígido*: posições além de  $L_{\max}$  simplesmente não existem no modelo?
- a) Positional encoding senoidal
  - b) ALiBi
  - c) RoPE
  - d) Positional encoding absoluto aprendido (ex.: BERT, GPT original)
- VII) A memória da matriz de atenção em um Transformer escala como  $O(L^2)$  no comprimento da sequência  $L$ . Aproximadamente quantas vezes mais memória de atenção é necessária ao dobrar o comprimento de contexto de  $L$  para  $2L$ ?
- a)  $\sqrt{2}$ × mais memória.
  - b) 2× mais memória.
  - c) 4× mais memória.
  - d) 8× mais memória.
- VIII) No RoPE com  $d = 64$  e  $\theta_k = 10000^{-2k/d}$ , qual dimensão possui a *rotação mais rápida* (maior incremento angular por unidade de posição)?
- a)  $k = 0$ , com  $\theta_0 = 1$ .
  - b)  $k = 8$ , no meio do espectro.
  - c)  $k = 31$ , com  $\theta_{31} \approx 10^{-4}$ .
  - d) Todas as dimensões giram à mesma velocidade angular.
- IX) Qual método de positional encoding produz, *por construção*, um decaimento *essencialmente linear* da contribuição posicional em função de  $|i - j|$ ?
- a) Positional encoding senoidal (Vaswani et al., 2017).
  - b) RoPE (Su et al., 2024).
  - c) ALiBi (Press et al., 2022).
  - d) NoPE (Kazemnejad et al., 2023).
- X) Para o positional encoding senoidal com  $d = 4$ , quais são os valores das dimensões 0 e 1 na posição  $i = 0$ ?
- a)  $PE(0,0) = 1, \quad PE(0,1) = 0$
  - b)  $PE(0,0) = 0, \quad PE(0,1) = 1$
  - c)  $PE(0,0) = 0, \quad PE(0,1) = 0$
  - d)  $PE(0,0) = 0,5, \quad PE(0,1) = 0,5$
- XI) Qual propriedade do positional encoding senoidal permite teoricamente que uma camada de atenção *aprenda offsets relativos*, mesmo que o encoding seja absoluto?
- a) Todos os valores são limitados ao intervalo  $[-1, 1]$ , mantendo os gradientes estáveis.

- b) O encoding usa base 10 000, compatível com tamanhos típicos de vocabulário.
  - c)  $PE(i + \delta)$  pode ser escrito como uma transformação linear fixa (multiplicação de matriz) de  $PE(i)$  para qualquer offset  $\delta$ .
  - d) As funções seno e cosseno são ortogonais, tornando cada dimensão independente.
- XII) No ALiBi com  $n = 4$  cabeças de atenção, qual é o slope  $m_h$  atribuído à cabeça  $h = 1$  usando a fórmula  $m_h = 2^{-8h/n}$ ?
- a) 0,5000
  - b) 0,1250
  - c) 0,2500
  - d) 0,0625
- XIII) Qual é a principal diferença algorítmica entre o **Position Interpolation (PI)** e o **YaRN** para estender a janela de contexto de um modelo baseado em RoPE?
- a) O PI usa busca evolutiva para encontrar escalas por dimensão; o YaRN usa escalonamento uniforme.
  - b) O PI aplica um fator de escala uniforme a todas as posições; o YaRN aplica fatores de escala diferentes por dimensão de frequência do RoPE.
  - c) O PI não requer fine-tuning; o YaRN requer dois estágios de fine-tuning.
  - d) O PI modifica a máscara de atenção; o YaRN modifica apenas os vetores key.
- XIV) Por que a máscara de atenção causal em um decoder autorregressivo funciona como informação posicional implícita no **NoPE**?
- a) Cada token na posição  $i$  atende exatamente a  $i + 1$  tokens, criando um padrão único por linha que se estende naturalmente além do comprimento de treinamento.
  - b) A máscara introduz um padrão senoidal nos pesos de atenção.
  - c) Mascaram tokens futuros força o modelo a memorizar posições absolutas.
  - d) A máscara triangular inferior é equivalente a subtrair as penalidades do ALiBi.
- XV) Qual método de positional encoding oferece extrapolação de comprimento **zero-shot** (*medida apenas por perplexidade*), ou seja, mantém perplexidade baixa em sequências mais longas do que o comprimento de treinamento *sem nenhum fine-tuning adicional*?
- a) Positional encoding senoidal
  - b) RoPE
  - c) Position Interpolation (PI)
  - d) ALiBi
- XVI) Qual mecanismo melhor explica o *efeito de primazia* (alta acurácia quando o documento relevante está no início do contexto) observado em LLMs decoder-only no fenômeno **Lost in the Middle**?
- a) O positional encoding senoidal atribui valores especiais à posição 0 que aumentam a magnitude dos embeddings iniciais.
  - b) A máscara causal força que todos os tokens posteriores possam atender aos tokens iniciais, fazendo com que o início da sequência receba alta atenção acumulada ao longo da sequência.

- c) Os primeiros tokens são processados por uma camada de atenção dedicada em paralelo com as demais.
- d) A função softmax assume valores maiores nos primeiros índices devido à ordem de cálculo numérico.

XVII) Por que o **NoPE** (No Positional Encoding) *não* pode ser aplicado diretamente a modelos *encoder-only* como o BERT?

- a) Porque o BERT utiliza tokenização de subpalavras, que é incompatível com a ausência de positional encoding.
- b) Porque modelos encoder-only não possuem máscara causal; sem ela, o sinal posicional implícito que torna o NoPE viável em decoders desaparece e o modelo se torna invariante a permutações.
- c) Porque o BERT possui um vocabulário pequeno demais para inferir posição a partir do contexto.
- d) Porque o NoPE requer uma camada de normalização especial ausente nos modelos da família BERT.

XVIII) Considerando o fenômeno **Lost in the Middle**, qual estratégia prática é *mais eficaz* para mitigar o vale de desempenho no centro do contexto em sistemas de produção?

- a) Sempre preencher todo o contexto disponível com a maior quantidade de documentos possível.
- b) Trocar o positional encoding do modelo de RoPE para senoidal absoluto.
- c) Usar Retrieval-Augmented Generation (RAG) para trazer apenas os trechos relevantes, ou posicionar deliberadamente o conteúdo crítico no início ou no final do prompt.
- d) Aumentar a temperatura de amostragem para forçar o modelo a explorar mais regiões do contexto.

XIX)  Considere o RoPE com  $d = 4$  e frequências  $\theta_0 = 1,0$ ,  $\theta_1 = 0,01$ . A query é  $\mathbf{q} = [1, 0, 1, 0]$  na posição  $i = 1$ , e a key é  $\mathbf{k} = [0, 1, 0, 1]$  na posição  $j = 3$ . Usando  $\cos(1,0) \approx 0,540$ ,  $\sin(1,0) \approx 0,841$ ,  $\cos(3,0) \approx -0,990$ ,  $\sin(3,0) \approx 0,141$ , qual é  $\text{score}(1, 3) = \tilde{\mathbf{q}}_1^\top \tilde{\mathbf{k}}_3$ ?

- a) +0,929
- b) -0,929
- c) 0,000
- d) -0,540

XX)  No RoPE, o produto interno dos vetores de query e key rotacionados para um único bloco de frequência 2D com parâmetro  $\theta$  se expande como:

$$\tilde{\mathbf{q}}_i \cdot \tilde{\mathbf{k}}_j = (q_0 k_0 + q_1 k_1) \cos((j - i)\theta) + (q_1 k_0 - q_0 k_1) \sin((j - i)\theta).$$

Qual é a principal implicação teórica dessa expressão?

- a) O score é sempre zero quando  $i = j$ , impedindo o self-attention.
- b) O score depende apenas do offset relativo  $(j - i)$ , e não das posições absolutas  $i$  ou  $j$  separadamente, confirmando que o RoPE é um positional encoding relativo.
- c) O score é limitado entre  $-1$  e  $+1$  para qualquer query e key.
- d) A expressão mostra que o RoPE é equivalente ao positional encoding senoidal somado à entrada.

- XXI) 🦴 O Position Interpolation reescala posições como  $i \leftarrow i \cdot (L_{\text{train}}/L_{\text{test}})$ . Suponha  $L_{\text{train}} = 2048$  e  $L_{\text{test}} = 8192$  (fator de escala = 0,25). Quais dimensões de frequência do RoPE são *mais prejudicadas* por essa compressão uniforme, e por quê?
- Dimensões de  $k$  alto (baixa frequência), pois não completaram muitas rotações e a compressão as empurra ainda mais para fora do intervalo treinado.
  - Dimensões de  $k$  baixo (alta frequência), pois já completam muitas rotações completas dentro de  $L_{\text{train}}$ ; comprimir o espaço de índices super-comprime essas dimensões e destrói a resolução posicional fina.
  - Todas as dimensões são igualmente afetadas, pois o mesmo fator é aplicado uniformemente.
  - Dimensões de  $k$  médio, pois suas frequências estão mais próximas da taxa de Nyquist.
- XXII) 🦴 No **ALiBi** com  $n = 8$  cabeças de atenção, a fórmula dos slopes é  $m_h = 2^{-8h/n} = 2^{-h}$  para  $h \in \{1, \dots, 8\}$ . Seja  $h = 1$  a cabeça com maior slope ( $m_1 = 2^{-1} = 0,5$ ). Calcule a penalidade ALiBi ( $m_h |i - j|$ ) para essa cabeça nas distâncias  $|i - j| = 128$  e  $|i - j| = 512$ , e determine a diferença entre as duas penalidades.
- Penalidade em 128: 64; penalidade em 512: 256; diferença: 192.
  - Penalidade em 128: 0,5; penalidade em 512: 2,0; diferença: 1,5.
  - Penalidade em 128: 128; penalidade em 512: 512; diferença: 384.
  - Penalidade em 128: 2,0; penalidade em 512: 8,0; diferença: 6,0.
- XXIII) 🦴 Considere o positional encoding senoidal  $\text{PE}(i) \in \mathbb{R}^d$  com  $d = 512$  para posições inteiras  $i \geq 0$ . É possível recuperar univocamente a posição  $i$  a partir do vetor  $\text{PE}(i)$ ?
- Não, pois as funções seno e cosseno são periódicas com período  $2\pi$ ; posições separadas por um múltiplo inteiro de  $2\pi$  teriam o mesmo encoding, causando colisões inevitáveis já para posições inteiras pequenas.
  - Sim, para posições práticas ( $i \ll 10^4$ ): as frequências  $\omega_k = 10000^{2k/d}$  crescem geometricamente e as combinações  $(\sin(i/\omega_k), \cos(i/\omega_k))$  são virtualmente distintas para posições inteiras dentro do intervalo de uso típico, tornando o mapeamento  $i \mapsto \text{PE}(i)$  injetivo nesse domínio.
  - Não, pois a norma de  $\text{PE}(i)$  é constante igual a  $\sqrt{d}/2$  para todo  $i$ , tornando impossível distinguir posições distintas.
  - Sim, mas somente utilizando a primeira dimensão  $\text{PE}(i, 0) = \sin(i)$ , que determina a posição de forma única para qualquer inteiro não negativo.
- XXIV) 🦴 Um modelo com positional encoding absoluto **aprendido** (estilo BERT), treinado com comprimento máximo  $L_{\text{max}} = 512$ , recebe na inferência uma sequência de comprimento  $L = 600$ . O que ocorre com os tokens nas posições 513 a 600?
- O modelo extrapola suavemente os embeddings posicionais usando interpolação linear entre  $\text{PE}(511)$  e  $\text{PE}(0)$ .
  - Essas posições não possuem embeddings treinados; a implementação típica lançará um erro de índice (*index out of bounds*) ou, se o índice for truncado, reutilizará vetores de posições iniciais, gerando representações completamente fora da distribuição de treinamento.
  - O modelo truncará silenciosamente a entrada para os primeiros 512 tokens e ignorará os demais sem erro.
  - Os embeddings posicionais para  $i > 512$  serão automaticamente inicializados com vetores nulos, preservando o processamento sem degradação de desempenho.

XXV)  Tanto o RoPE quanto o positional encoding senoidal (Vaswani et al., 2017) utilizam frequências da forma  $\theta_k = 10000^{-2k/d}$ . Qual afirmação descreve com mais precisão a relação matemática entre os dois métodos?

- a) São algebraicamente equivalentes: rotacionar os vetores de query e key com RoPE produz exatamente o mesmo logit de atenção que somar o PE senoidal ao embedding de entrada.
- b) Compartilham o mesmo espectro de frequências, mas diferem fundamentalmente: o PE senoidal codifica posição *absoluta* por adição ao embedding de entrada (antes das projeções lineares  $W_Q, W_K$ ), enquanto o RoPE codifica posição *relativa* via rotação dos vetores de query e key (após as projeções). Não existe configuração de pesos que torne os dois métodos equivalentes em geral.
- c) São equivalentes quando  $W_Q = W_K = I$  (projeções identidade), pois nesse caso adição e rotação têm o mesmo efeito sobre o produto interno.
- d) O PE senoidal é um caso especial do RoPE aplicado somente às duas primeiras dimensões do embedding.

XXVI)  Para o RoPE com  $d = 2$  e parâmetro  $\theta$ , a matriz de rotação na posição  $i$  é

$$R(i) = \begin{pmatrix} \cos(i\theta) & -\sin(i\theta) \\ \sin(i\theta) & \cos(i\theta) \end{pmatrix}.$$

Dado que matrizes de rotação satisfazem  $R(i)^\top R(j) = R(j-i)$ , e que  $\tilde{\mathbf{q}}_i = R(i) \mathbf{q}$  e  $\tilde{\mathbf{k}}_j = R(j) \mathbf{k}$ , como o score de atenção  $\tilde{\mathbf{q}}_i^\top \tilde{\mathbf{k}}_j$  pode ser reescrito?

- a)  $\mathbf{q}^\top \mathbf{k} + (i-j)\theta$ , mostrando dependência linear na posição relativa.
- b)  $\mathbf{q}^\top R(j-i) \mathbf{k}$ , mostrando que o score depende apenas do offset relativo  $(j-i)$  e não das posições absolutas  $i$  ou  $j$  individualmente.
- c)  $\mathbf{q}^\top R(i+j) \mathbf{k}$ , mostrando dependência na posição absoluta somada.
- d)  $\|\mathbf{q}\| \|\mathbf{k}\| \cos((i-j)\theta)$ , válido apenas quando  $\mathbf{q}$  e  $\mathbf{k}$  são vetores unitários paralelos.

## GABARITO

I, Resposta:(b)

O score de atenção  $\mathbf{q}_i^\top \mathbf{k}_j / \sqrt{d}$  é um produto interno que depende apenas dos *valores* dos dois vetores, e não das posições  $i$  ou  $j$ . Permutar os tokens em qualquer ordem produz os mesmos padrões de atenção, de modo que o modelo é invariante a permutações sem positional encoding.

II, Resposta:(c)

O artigo original do Transformer (Vaswani et al., 2017) define:

$$\text{PE}(i, 2k) = \sin\left(\frac{i}{10000^{2k/d}}\right), \quad \text{PE}(i, 2k+1) = \cos\left(\frac{i}{10000^{2k/d}}\right).$$

Dimensões pares usam *seno*; dimensões ímpares usam *cosseno* na mesma frequência. As opções (a) e (d) invertem seno e cosseno; a opção (b) troca  $i$  e  $k$ .

### III, Resposta:(c)

O RoPE (Su et al., 2024) aplica uma matriz de rotação  $R_\theta(i)$  diretamente aos vetores de query  $\mathbf{q}_i$  e key  $\mathbf{k}_j$  dentro de cada cabeça de atenção:  $\tilde{\mathbf{q}}_i = R_\theta(i) \mathbf{q}_i$ . O token embedding  $\mathbf{x}_i$  *não* é modificado. O positional encoding senoidal e o aprendido somam um vetor ao embedding de entrada; o NoPE não faz nada.

### IV, Resposta:(b)

O ALiBi (Press et al., 2022) modifica o logit pré-softmax para:

$$A_h(i, j) = \frac{\mathbf{q}_i^\top \mathbf{k}_j}{\sqrt{d}} - m_h |i - j|.$$

A penalidade  $m_h \cdot |i - j|$  *cresce com a distância*, induzindo cada cabeça a focar em tokens próximos. Nenhum vetor é somado ao embedding.

### V, Resposta:(b)

O positional encoding absoluto atribui um vetor distinto a cada índice de posição visto durante o treinamento. Posições  $i \geq L_{\text{train}}$  nunca aparecem no treinamento, portanto esses vetores ficam fora da distribuição no momento do teste, causando degradação. O NoPE não adiciona vetores posicionais, logo nada fica fora da distribuição; apenas a máscara causal muda, e ela o faz de forma previsível e suave.

### VI, Resposta:(d)

O positional encoding absoluto aprendido (usado no BERT e nos primeiros GPTs) armazena uma matriz treinável  $E \in \mathbb{R}^{L_{\text{max}} \times d}$ . Uma posição  $i > L_{\text{max}}$  simplesmente não tem linha em  $E$ : o embedding não existe. O encoding senoidal possui fórmula fechada para qualquer posição; RoPE e ALiBi são relativos e escalam naturalmente.

### VII, Resposta:(c)

A memória da matriz de atenção contém todos os  $L \times L$  pares, escalando como  $O(L^2)$ . Ao dobrar o comprimento de  $L$  para  $2L$ , o número de pares passa de  $L^2$  para  $(2L)^2 = 4L^2$ , ou seja, **quatro vezes** mais memória. É exatamente esse crescimento quadrático que torna o treinamento em sequências longas economicamente caro e motiva os métodos de extensão de contexto e PEs com boa extrapolação.

### VIII, Resposta:(a)

No RoPE,  $\theta_k = 10000^{-2k/d}$ . Para  $k = 0$  tem-se  $\theta_0 = 10000^0 = 1$ , o valor *máximo* do espectro. Conforme  $k$  aumenta,  $\theta_k$  decai exponencialmente, atingindo  $\theta_{31} \approx 10^{-4}$  em  $d = 64$ . Portanto, a dimensão  $k = 0$  rotaciona o vetor a uma velocidade angular muito maior por unidade de posição (rotação rápida  $\rightarrow$  posição relativa fina), enquanto  $k$  alto rotaciona lentamente (posição relativa grosseira).

### IX, Resposta:(c)

O ALiBi adiciona um termo  $-m_h \cdot |i - j|$  ao logit de atenção, ou seja, uma função estritamente linear da distância  $|i - j|$ . RoPE produz decaimento suave mas dependente da frequência (combinação de senos/cossenos), o senoidal absoluto tem contribuição

imprevisível ao multiplicar embeddings, e o NoPE não impõe forma alguma: o decaimento, se existir, é puramente aprendido. Apenas o ALiBi garante decaimento linear por construção.

X, Resposta:(b)

Com  $d = 4$  e  $i = 0$ :

$$\text{PE}(0,0) = \sin(0 \cdot \omega_0) = \sin(0) = 0, \quad \text{PE}(0,1) = \cos(0 \cdot \omega_0) = \cos(0) = 1.$$

Na posição 0, toda dimensão de seno vale 0 e toda dimensão de cosseno vale 1, pois todos os argumentos são iguais a 0.

XI, Resposta:(c)

Usando fórmulas de adição trigonométricas, pode-se demonstrar que  $\text{PE}(i + \delta) = M(\delta) \text{PE}(i)$  para uma matriz de rotação em blocos *fixa*  $M(\delta)$  que depende apenas de  $\delta$ . Como essa relação linear vale para qualquer  $\delta$ , uma camada de atenção pode, em princípio, aprender a calcular offsets relativos aplicando a transformação inversa.

XII, Resposta:(c)

$$m_1 = 2^{-8 \cdot 1/4} = 2^{-2} = 0,25.$$

Os quatro slopes para  $n = 4$  são:  $m_1 = 0,25$ ,  $m_2 = 0,0625$ ,  $m_3 = 0,0156$ ,  $m_4 = 0,0039$ . A cabeça 1 tem o *slope mais acentuado* e, portanto, atende mais localmente.

XIII, Resposta:(b)

O Position Interpolation (Chen et al., 2023) reescala todos os índices de posição pelo mesmo fator  $L_{\text{train}}/L_{\text{test}}$ , comprimindo todas as frequências do RoPE uniformemente. O YaRN (Peng et al., 2024) reconhece que dimensões de alta frequência já estão bem representadas e não precisam de escalonamento, enquanto as de baixa frequência precisam de grande escalonamento. Ele aplica uma estratégia de escala por dimensão (não uniforme) inspirada em interpolação NTK-aware, resultando em melhor retenção do contexto curto.

XIV, Resposta:(a)

Em um decoder causal (autorregressivo), o token  $i$  só pode atender às posições  $j \leq i$ . A linha  $i$  da máscara de atenção possui exatamente  $i + 1$  entradas não mascaradas, criando um padrão binário *único* para cada posição. Conforme o comprimento da sequência cresce além de  $L_{\text{train}}$ , novas linhas simplesmente estendem esse padrão suavemente, nada fica fora da distribuição, ao contrário dos vetores posicionais explícitos.

XV, Resposta:(d)

O ALiBi penaliza a atenção com  $-m_h \cdot |i - j|$ . Quando a sequência ultrapassa  $L_{\text{train}}$ , a penalidade simplesmente fica maior para tokens distantes, comportamento *inteiramente dentro da distribuição* de treinamento. Press et al. (2022) demonstraram que modelos com ALiBi treinados em 1K tokens *mantêm perplexidade baixa* até 8K tokens sem nenhum fine-tuning. Vale notar que essa afirmação de extrapolação é medida apenas por *perplexidade*: trabalhos posteriores mostraram que o desempenho em tarefas de recuperação de longo alcance (por exemplo, *needle in a haystack*) degrada bem antes do que a perplexidade sugere.

### XVI, Resposta:(b)

Em um decoder autorregressivo, a máscara causal impõe que cada token na posição  $i$  só possa atender a posições  $j \leq i$ . Como consequência, os tokens *iniciais* são visíveis a *todos* os tokens posteriores, enquanto tokens do meio só são visíveis a uma fração da sequência. Esse acúmulo desigual de atenção dá aos primeiros tokens um peso médio elevado, manifestando-se como o efeito de primazia. Não há nada de “especial” no positional encoding ou nos embeddings da posição 0: trata-se de uma propriedade emergente da máscara combinada com padrões de atenção aprendidos.

### XVII, Resposta:(b)

O NoPE depende inteiramente da máscara causal para gerar um sinal posicional implícito: é a estrutura triangular inferior, com cada linha vendo  $i + 1$  tokens, que quebra a invariância a permutações do self-attention. Modelos encoder-only como o BERT usam atenção *bidirecional sem máscara*, de modo que sem nenhum positional encoding eles voltam a ser literalmente invariantes a permutações dos tokens, não conseguindo distinguir “o gato comeu o rato” de “o rato comeu o gato”. Por isso o NoPE é uma técnica restrita a decoders.

### XVIII, Resposta:(c)

A curva de desempenho em U mostra que o modelo ignora informação no meio do contexto, mesmo dentro da janela suportada. As estratégias eficazes na prática são: (i) **RAG** (*Retrieval-Augmented Generation*), que recupera apenas o trecho relevante e o coloca em uma posição privilegiada do prompt; e (ii) **posicionamento deliberado**, colocando o conteúdo crítico no início ou no final do contexto, onde os efeitos de primazia/recência o favorecem. Apenas aumentar o contexto, trocar o PE ou alterar a temperatura de amostragem não corrige o vale central, que é uma propriedade aprendida da atenção e não do positional encoding.

### XIX, Resposta:(b)

**Passo 1: Rotacionar a query  $\mathbf{q} = [1, 0, 1, 0]$  em  $i = 1$ :**

Bloco  $k = 0$  ( $i\theta_0 = 1,0 \text{ rad}$ ) :  $(\cos(1) \cdot 1 - \sin(1) \cdot 0, \sin(1) \cdot 1 + \cos(1) \cdot 0) = (0,540, 0,841)$

Bloco  $k = 1$  ( $i\theta_1 = 0,01 \text{ rad}$ ) :  $(\cos(0,01) \cdot 1, \sin(0,01) \cdot 1) \approx (1,000, 0,010)$

Portanto  $\tilde{\mathbf{q}}_1 = [0,540, 0,841, 1,000, 0,010]$ .

**Passo 2: Rotacionar a key  $\mathbf{k} = [0, 1, 0, 1]$  em  $j = 3$ :**

Bloco  $k = 0$  ( $j\theta_0 = 3,0 \text{ rad}$ ) :  $(\cos(3) \cdot 0 - \sin(3) \cdot 1, \sin(3) \cdot 0 + \cos(3) \cdot 1) = (-0,141, -0,990)$

Bloco  $k = 1$  ( $j\theta_1 = 0,03 \text{ rad}$ ) :  $(\cos(0,03) \cdot 0 - \sin(0,03) \cdot 1, \sin(0,03) \cdot 0 + \cos(0,03) \cdot 1) \approx (-0,030, 1,000)$

Portanto  $\tilde{\mathbf{k}}_3 = [-0,141, -0,990, -0,030, 1,000]$ .

**Passo 3: Produto interno:**

$\text{score}(1, 3) = 0,540 \cdot (-0,141) + 0,841 \cdot (-0,990) + 1,000 \cdot (-0,030) + 0,010 \cdot 1,000 \approx -0,076 - 0,832 - 0,030 + 0,010 = -$

### XX, Resposta:(b)

O produto interno expandido:

$$(q_0 k_0 + q_1 k_1) \cos((j - i)\theta) + (q_1 k_0 - q_0 k_1) \sin((j - i)\theta)$$

contém as posições absolutas  $i$  e  $j$  apenas por meio da combinação  $(j - i)$ . Os termos  $q_0k_0 + q_1k_1$  e  $q_1k_0 - q_0k_1$  dependem apenas do conteúdo vetorial de  $\mathbf{q}$  e  $\mathbf{k}$ , não das posições. Portanto, o score de atenção codifica posição *relativa*: dois pares de tokens com o mesmo offset relativo  $\delta = j - i$  sempre recebem a mesma contribuição posicional, independentemente de onde apareçam na sequência.

### XXI, Resposta:(b)

Com fator de escala  $s = L_{\text{train}}/L_{\text{test}} = 0,25$ , a posição  $i$  é substituída por  $0,25i$ . O ângulo de rotação efetivo para a dimensão  $k$  torna-se:

$$\phi'(i, k) = 0,25i \cdot \theta_k.$$

Para dimensões de  $k$  **baixo** (alta frequência),  $\theta_k \approx 1$ : essas dimensões já completam muitas rotações completas dentro de  $L_{\text{train}}$ . Multiplicar por 0,25 comprime quatro tokens de variação angular em um único token, *super-comprimindo* a resolução e fazendo com que tokens próximos recebam sinais posicionais quase idênticos, destruindo as distinções posicionais finas.

As dimensões de  $k$  alto ( $\theta_k \ll 1$ ) mal se movem dentro de qualquer comprimento de sequência razoável e são, portanto, o alvo principal da interpolação. Essa é exatamente a motivação do YaRN e do LongRoPE: manter as dimensões de alta frequência intactas e reescalar apenas as de baixa frequência.

### XXII, Resposta:(a)

Com  $n = 8$  cabeças e  $m_h = 2^{-h}$ , a cabeça  $h = 1$  possui  $m_1 = 2^{-1} = 0,5$ .

$$\text{Penalidade em } |i - j| = 128 : \quad m_1 \times 128 = 0,5 \times 128 = 64.$$

$$\text{Penalidade em } |i - j| = 512 : \quad m_1 \times 512 = 0,5 \times 512 = 256.$$

$$\text{Diferença: } 256 - 64 = 192.$$

Para comparação, a cabeça  $h = 8$  tem  $m_8 = 2^{-8} \approx 0,0039$ , produzindo penalidades de apenas  $\approx 0,5$  e  $\approx 2,0$  nas mesmas distâncias: essa cabeça tolera contexto longo quase sem penalidade, enquanto a cabeça 1 é fortemente local. Esse espectro de slopes é o mecanismo pelo qual o ALiBi cobre ao mesmo tempo atenção local e global com diferentes cabeças.

### XXIII, Resposta:(b)

A primeira dimensão de seno usa frequência  $\omega_0 = 1$ , com período  $2\pi \approx 6,28$ . Para que dois inteiros  $i \neq j$  produzam o mesmo PE, seria necessário que  $(j - i)/\omega_k$  fosse múltiplo de  $2\pi$  para *todos* os  $k$  simultaneamente. Como  $2\pi$  é irracional e as frequências  $\omega_k = 10000^{2k/d}$  são multiplicativamente incomensuráveis (para  $k$  distintos), isso não acontece para nenhum par de inteiros na faixa de uso prático ( $i < 10^4$ ): o mapeamento é injetivo. A opção (a) erra ao afirmar que inteiros próximos colidem —  $2\pi$  é irracional, portanto  $\lfloor i \rfloor$  nunca repete o seno de  $\lfloor j \rfloor$  para  $i, j$  inteiros com  $|i - j| < 2\pi$ . A opção (c) erra ao afirmar norma constante: em geral  $\|\text{PE}(i)\| \neq \sqrt{d}/2$  exatamente para inteiros finitos. A opção (d) erra porque  $\sin(i)$  repete com período irracional; entre inteiros, não há repetição, mas tampouco unicidade garantida por uma única dimensão.

## XXIV, Resposta:(b)

Positional encoding aprendido é implementado tipicamente como `nn.Embedding(L_max, d)`, uma tabela com  $L_{\max}$  linhas. Consultar o índice  $i \geq L_{\max}$  é equivalente a acessar uma linha inexistente:

- Em frameworks como PyTorch, isso gera `IndexError: index out of range`.
- Em implementações que truncam o índice (*clamping*), a posição 600 receberia o embedding da posição 511, repetindo-o para todos os tokens além de  $L_{\max}$ : o modelo passa a ver múltiplos tokens com a mesma “posição 511”, produzindo representações incoerentes e fora de distribuição.

Esse limite rígido é a principal desvantagem do PE aprendido em relação ao PE senoidal (fórmula fechada para qualquer  $i$ ), ao ALiBi e ao RoPE, que extrapolam naturalmente sem consultar tabelas.

## XXV, Resposta:(b)

O PE senoidal e o RoPE compartilham o espectro  $\theta_k = 10000^{-2k/d}$  por design — ambos precisam de frequências variadas para distinguir um amplo intervalo de posições. Contudo as operações realizadas são fundamentalmente distintas:

- **PE senoidal:** adiciona  $PE(i)$  ao token embedding *antes* das projeções  $W_Q, W_K$ . O score de atenção contém termos cruzados conteúdo-posição e termos de posição absoluta.
- **RoPE:** aplica  $R_\theta(i)$  *após* a projeção  $W_Q \mathbf{x}_i$ , resultando em  $\mathbf{q}^\top R(j-i) \mathbf{k}$  — dependência exclusivamente relativa, sem termos de posição absoluta no score.

Mesmo com  $W_Q = W_K = I$ , os dois scores diferem: o PE senoidal ainda gera termos cruzados  $\mathbf{x}_i^\top PE(j)$  que o RoPE não possui. Não existe, portanto, equivalência algébrica entre os dois métodos.

## XXVI, Resposta:(b)

Aplicando a definição dos vetores rotacionados:

$$\tilde{\mathbf{q}}_i^\top \tilde{\mathbf{k}}_j = (R(i) \mathbf{q})^\top (R(j) \mathbf{k}) = \mathbf{q}^\top R(i)^\top R(j) \mathbf{k}.$$

Usando  $R(i)^\top = R(-i)$  (matrizes de rotação são ortogonais) e a propriedade de composição  $R(-i) R(j) = R(j-i)$ :

$$\tilde{\mathbf{q}}_i^\top \tilde{\mathbf{k}}_j = \mathbf{q}^\top R(j-i) \mathbf{k}.$$

As posições absolutas  $i$  e  $j$  aparecem apenas por meio do offset relativo  $(j-i)$ . Dois pares de tokens com o mesmo offset relativo  $\delta = j-i$  recebem exatamente a mesma contribuição posicional, independentemente de onde estejam na sequência. Isso distingue o RoPE do PE senoidal e é a base teórica para sua generalização zero-shot a sequências mais longas que as do treinamento: o produto  $\mathbf{q}^\top R(\delta) \mathbf{k}$  é bem definido para qualquer  $\delta$ , não dependendo de uma tabela de embeddings pré-treinada.

## GABARITO DETALHADO — QUESTÕES DIFÍCEIS DE POSITIONAL ENCODING

**SOBRE ESTE APÊNDICE.** Esta seção apresenta derivações completas para as questões de nível **Difícil** (marcadas com 🧠). Para cada questão são fornecidos: o enunciado, a alternativa correta e todos os passos intermediários.

Os temas centrais são:

- Prova algébrica da propriedade de posição relativa do **RoPE** (questões XIX, XX e XXVI);
- Cálculo dos *slopes* e das penalidades do **ALiBi** (questão XXII);
- Argumento de injetividade do **positional encoding senoidal** (questão XXIII);
- Análise das consequências da compressão uniforme no **Position Interpolation** (questão XXI);
- Comportamento do PE aprendido além de  $L_{\max}$  (questão XXIV);
- Comparação matemática entre RoPE e PE senoidal (questão XXV).

### XIX 🧠 — Cálculo Numérico do Score RoPE

**ENUNCIADO.** Considere o RoPE com  $d = 4$  e frequências  $\theta_0 = 1,0$ ,  $\theta_1 = 0,01$ . A query é  $\mathbf{q} = [1, 0, 1, 0]$  na posição  $i = 1$ , e a key é  $\mathbf{k} = [0, 1, 0, 1]$  na posição  $j = 3$ . Usando os valores trigonométricos

$$\cos(1,0) \approx 0,540, \quad \sin(1,0) \approx 0,841, \quad \cos(3,0) \approx -0,990, \quad \sin(3,0) \approx 0,141,$$

calcule  $\text{score}(1, 3) = \tilde{\mathbf{q}}_1^\top \tilde{\mathbf{k}}_3$ .

**Resposta correta**

Alternativa (b):  $-0,929$ .

**DERIVAÇÃO COMPLETA.** O RoPE com  $d = 4$  opera em dois blocos 2D independentes, um para cada par de dimensões  $(2k, 2k + 1)$ .

**Bloco  $k = 0$  — ângulo de rotação  $\alpha = i\theta_0 = 1 \times 1,0 = 1,0$  rad:**

A rotação no plano  $[q_0, q_1]$  aplica a matriz

$$R(i\theta_0) = \begin{pmatrix} \cos(1,0) & -\sin(1,0) \\ \sin(1,0) & \cos(1,0) \end{pmatrix} = \begin{pmatrix} 0,540 & -0,841 \\ 0,841 & 0,540 \end{pmatrix}.$$

Como  $\mathbf{q}_{[0:2]} = [1, 0]^\top$ :

$$\tilde{\mathbf{q}}_{1,[0:2]} = \begin{pmatrix} 0,540 & -0,841 \\ 0,841 & 0,540 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0,540 \\ 0,841 \end{pmatrix}.$$

**Bloco  $k = 1$  — ângulo de rotação  $\alpha = i\theta_1 = 1 \times 0,01 = 0,01$  rad:**

Para ângulos pequenos,  $\cos(0,01) \approx 1,000$  e  $\sin(0,01) \approx 0,010$ . Como  $\mathbf{q}_{[2:4]} = [1, 0]^\top$ :

$$\tilde{\mathbf{q}}_{1,[2:4]} = \begin{pmatrix} 1,000 & -0,010 \\ 0,010 & 1,000 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 1,000 \\ 0,010 \end{pmatrix}.$$

**Query rotacionada:**  $\tilde{\mathbf{q}}_1 = [0,540, 0,841, 1,000, 0,010]$ .

**Bloco  $k = 0$  para key — ângulo de rotação  $\beta = j\theta_0 = 3 \times 1,0 = 3,0$  rad:**

$$R(j\theta_0) = \begin{pmatrix} -0,990 & -0,141 \\ 0,141 & -0,990 \end{pmatrix}.$$

Como  $\mathbf{k}_{[0:2]} = [0, 1]^\top$ :

$$\tilde{\mathbf{k}}_{3,[0:2]} = \begin{pmatrix} -0,990 & -0,141 \\ 0,141 & -0,990 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -0,141 \\ -0,990 \end{pmatrix}.$$

**Bloco  $k = 1$  para key — ângulo de rotação  $\beta = j\theta_1 = 3 \times 0,01 = 0,03$  rad:**

$\cos(0,03) \approx 1,000$ ,  $\sin(0,03) \approx 0,030$ . Como  $\mathbf{k}_{[2:4]} = [0, 1]^\top$ :

$$\tilde{\mathbf{k}}_{3,[2:4]} = \begin{pmatrix} 1,000 & -0,030 \\ 0,030 & 1,000 \end{pmatrix} \begin{pmatrix} 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -0,030 \\ 1,000 \end{pmatrix}.$$

**Key rotacionada:**  $\tilde{\mathbf{k}}_3 = [-0,141, -0,990, -0,030, 1,000]$ .

**Produto interno:**

$$\text{score}(1, 3) = \underbrace{0,540 \times (-0,141)}_{\approx -0,076} + \underbrace{0,841 \times (-0,990)}_{\approx -0,832} + \underbrace{1,000 \times (-0,030)}_{=-0,030} + \underbrace{0,010 \times 1,000}_{=+0,010} \approx -0,929.$$

**VERIFICAÇÃO VIA EXPANSÃO ANALÍTICA.** O bloco  $k = 0$  sozinho contribui com  $(q_0k_0 + q_1k_1) \cos((j-i)\theta_0) + (q_1k_0 - q_0k_1) \sin((j-i)\theta_0)$ :

$$(1 \cdot 0 + 0 \cdot 1) \cos(2) + (0 \cdot 0 - 1 \cdot 1) \sin(2) = 0 - \sin(2) \approx -0,909.$$

O bloco  $k = 1$  contribui com valor próximo de zero (ângulo muito pequeno):

$$(1 \cdot 0 + 0 \cdot 1) \cos(0,02) + (0 \cdot 0 - 1 \cdot 1) \sin(0,02) \approx -0,020.$$

Soma:  $-0,909 + (-0,020) \approx -0,929 \checkmark$

## XX 🦴 — Expansão Algébrica do Score RoPE e Posição Relativa

**ENUNCIADO.** No RoPE, o produto interno dos vetores de query e key rotacionados para um único bloco de frequência 2D com parâmetro  $\theta$  se expande como:

$$\tilde{\mathbf{q}}_i \cdot \tilde{\mathbf{k}}_j = (q_0k_0 + q_1k_1) \cos((j-i)\theta) + (q_1k_0 - q_0k_1) \sin((j-i)\theta).$$

Qual é a principal implicação teórica dessa expressão?

### Resposta correta

Alternativa (b): O score depende apenas do offset relativo  $(j-i)$ , e não das posições absolutas  $i$  ou  $j$  separadamente, confirmando que o RoPE é um positional encoding relativo.

**DERIVAÇÃO COMPLETA DA EXPANSÃO.** Definindo a rotação para o bloco 2D:

$$\tilde{\mathbf{q}}_i = \begin{pmatrix} \cos(i\theta) & -\sin(i\theta) \\ \sin(i\theta) & \cos(i\theta) \end{pmatrix} \begin{pmatrix} q_0 \\ q_1 \end{pmatrix} = \begin{pmatrix} q_0 \cos(i\theta) - q_1 \sin(i\theta) \\ q_0 \sin(i\theta) + q_1 \cos(i\theta) \end{pmatrix},$$

$$\tilde{\mathbf{k}}_j = \begin{pmatrix} \cos(j\theta) & -\sin(j\theta) \\ \sin(j\theta) & \cos(j\theta) \end{pmatrix} \begin{pmatrix} k_0 \\ k_1 \end{pmatrix} = \begin{pmatrix} k_0 \cos(j\theta) - k_1 \sin(j\theta) \\ k_0 \sin(j\theta) + k_1 \cos(j\theta) \end{pmatrix}.$$

Calculando o produto interno componente a componente:

$$\begin{aligned}\tilde{\mathbf{q}}_i \cdot \tilde{\mathbf{k}}_j &= (q_0 \cos(i\theta) - q_1 \sin(i\theta))(k_0 \cos(j\theta) - k_1 \sin(j\theta)) \\ &\quad + (q_0 \sin(i\theta) + q_1 \cos(i\theta))(k_0 \sin(j\theta) + k_1 \cos(j\theta)).\end{aligned}$$

Expandindo e agrupando os termos com  $q_0k_0$ ,  $q_1k_1$ ,  $q_0k_1$  e  $q_1k_0$ :

$$\begin{aligned}q_0k_0 &: \cos(i\theta) \cos(j\theta) + \sin(i\theta) \sin(j\theta) = \cos((j-i)\theta), \\ q_1k_1 &: \sin(i\theta) \sin(j\theta) + \cos(i\theta) \cos(j\theta) = \cos((j-i)\theta), \\ q_0k_1 &: -\cos(i\theta) \sin(j\theta) + \sin(i\theta) \cos(j\theta) = -\sin((j-i)\theta), \\ q_1k_0 &: -\sin(i\theta) \cos(j\theta) + \cos(i\theta) \sin(j\theta) = \sin((j-i)\theta),\end{aligned}$$

onde foram usadas as identidades trigonométricas  $\cos(A-B) = \cos A \cos B + \sin A \sin B$  e  $\sin(A-B) = \sin A \cos B - \cos A \sin B$ .

Portanto:

$$\tilde{\mathbf{q}}_i \cdot \tilde{\mathbf{k}}_j = (q_0k_0 + q_1k_1) \cos((j-i)\theta) + (q_1k_0 - q_0k_1) \sin((j-i)\theta).$$

**IMPLICAÇÃO TEÓRICA.** Os dois coeficientes  $(q_0k_0 + q_1k_1)$  e  $(q_1k_0 - q_0k_1)$  dependem apenas do *conteúdo vetorial* de  $\mathbf{q}$  e  $\mathbf{k}$ . As posições absolutas  $i$  e  $j$  aparecem exclusivamente no argumento  $(j-i)$  das funções trigonométricas. Portanto:

1. O score é invariante a translações: substituir  $(i, j)$  por  $(i + \Delta, j + \Delta)$  não altera o resultado, pois o argumento  $(j + \Delta) - (i + \Delta) = j - i$  é idêntico.
2. Dois pares de tokens com o mesmo *offset relativo*  $\delta = j - i$  recebem exatamente a mesma contribuição posicional, onde quer que estejam na sequência.
3. Isso confirma que o RoPE é um *positional encoding relativo*: a informação posicional codificada não é “estou na posição absoluta  $i$ ”, mas sim “a distância relativa entre mim e o outro token é  $\delta$ ”.

## XXI 🧠 — Compressão Uniforme no Position Interpolation

**ENUNCIADO.** O Position Interpolation reescala posições como  $i \leftarrow i \cdot (L_{\text{train}}/L_{\text{test}})$ . Supondo  $L_{\text{train}} = 2048$  e  $L_{\text{test}} = 8192$  (fator = 0,25), quais dimensões de frequência do RoPE são *mais prejudicadas* por essa compressão?

### Resposta correta

Alternativa (b): Dimensões de  $k$  **baixo** (alta frequência), pois já completam muitas rotações em  $L_{\text{train}}$ ; a compressão super-comprime essas dimensões e destrói a resolução posicional fina.

**ANÁLISE DETALHADA.** O ângulo de rotação acumulado na dimensão  $k$  para a posição  $i$  é:

$$\phi(i, k) = i \cdot \theta_k = i \cdot 10000^{-2k/d}.$$

Após a interpolação  $i \rightarrow si$  com fator  $s = 0,25$ :

$$\phi'(i, k) = si \cdot \theta_k = 0,25 \cdot i \cdot \theta_k.$$

O número de rotações completas realizadas até a posição  $L_{\text{train}}$ , na dimensão  $k$ , é:

$$N_k = \frac{L_{\text{train}} \cdot \theta_k}{2\pi}.$$

**Dimensões de  $k$  baixo (alta frequência,  $\theta_k \approx 1$ ):**

$$N_0 = \frac{2048 \times 1}{2\pi} \approx 326 \text{ rotações completas dentro de } L_{\text{train}}.$$

Cada token ocupa um arco de  $\approx 1,0$  rad, proporcionando alta resolução posicional local. Com o fator de compressão  $s = 0,25$ , cada token passa a ocupar apenas  $0,25$  rad: quatro tokens que antes eram distinguíveis por posição agora ficam “comprimidos” no mesmo intervalo que antes representava um único token, tornando os sinais posicionais indistinguíveis.

**Dimensões de  $k$  alto (baixa frequência,  $\theta_k \ll 1$ ):** Para  $k = d/2 - 1$  com  $d = 64$ ,  $\theta_{31} = 10000^{-2 \times 31/64} \approx 10^{-4}$ .

$$N_{31} = \frac{2048 \times 10^{-4}}{2\pi} \approx 0,033 \text{ rotações em } L_{\text{train}}.$$

Essas dimensões mal se movem e não fornecem resolução posicional fina de qualquer forma; a compressão afeta muito menos a qualidade do sinal nestas dimensões.

**MOTIVAÇÃO DO YARN.** Essa assimetria motivou o YaRN (Peng et al., 2024): ao invés de comprimir todas as dimensões uniformemente, o YaRN aplica:

- **Dimensões de  $k$  baixo** (alta frequência): mantém sem compressão, pois já fornecem resolução fina e seriam super-comprimidas.
- **Dimensões de  $k$  alto** (baixa frequência): aplica compressão agressiva, pois mal se movem e toleram a reescala.

Esse escalonamento não-uniforme permite que o modelo mantenha a resolução posicional de curto alcance (dependente das dimensões de alta frequência) enquanto estende o alcance global.

## XXII — Cálculo dos Slopes e Penalidades ALiBi

**ENUNCIADO.** No ALiBi com  $n = 8$  cabeças de atenção, a fórmula dos slopes é  $m_h = 2^{-8h/n} = 2^{-h}$  para  $h \in \{1, \dots, 8\}$ . Para  $h = 1$  (cabeça com maior slope), calcule as penalidades em  $|i - j| = 128$  e  $|i - j| = 512$  e a diferença entre elas.

### Resposta correta

Alternativa (a): Penalidade em 128: 64; penalidade em 512: 256; diferença: 192.

**DERIVAÇÃO DETALHADA. Passo 1 — Tabela completa de slopes.**

Para  $n = 8$  cabeças,  $m_h = 2^{-8h/n} = 2^{-8h/8} = 2^{-h}$ :

| Cabeça $h$ | Slope $m_h = 2^{-h}$ | Forma fracionária |
|------------|----------------------|-------------------|
| 1          | 0,500000             | 1/2               |
| 2          | 0,250000             | 1/4               |
| 3          | 0,125000             | 1/8               |
| 4          | 0,062500             | 1/16              |
| 5          | 0,031250             | 1/32              |
| 6          | 0,015625             | 1/64              |
| 7          | 0,007813             | 1/128             |
| 8          | 0,003906             | 1/256             |

A cabeça  $h = 1$  possui o maior slope ( $m_1 = 0,5$ ) e, portanto, a maior penalidade por unidade de distância: essa cabeça é a *mais local* do conjunto. A cabeça  $h = 8$  tem o menor slope ( $m_8 \approx 0,0039$ ) e é a *mais global*.

**Passo 2 — Cálculo das penalidades para  $h = 1$ .**

$$\text{Penalidade}(|i - j|) = m_1 \times |i - j| = \frac{1}{2} \times |i - j|.$$

$$\text{Em } |i - j| = 128 : \quad \frac{1}{2} \times 128 = \mathbf{64}.$$

$$\text{Em } |i - j| = 512 : \quad \frac{1}{2} \times 512 = \mathbf{256}.$$

$$\text{Diferença: } 256 - 64 = \mathbf{192}.$$

**Passo 3 — Interpretação no logit de atenção.**

O logit pré-softmax com ALiBi é:

$$A_h(i, j) = \frac{\mathbf{q}_i^\top \mathbf{k}_j}{\sqrt{d}} - m_h \cdot |i - j|.$$

Para  $h = 1$  e  $|i - j| = 128$ , a penalidade de  $-64$  subtrai 64 do logit bruto. Após o softmax, se o logit sem penalidade fosse  $\sim 0$ , a atenção efetiva para esse token seria  $\propto e^{-64}$ , praticamente zero: a cabeça 1 ignora tokens a mais de  $\sim 10$  posições de distância de forma efetiva.

Para comparação, a cabeça  $h = 8$  subtrairia apenas  $\approx 0,5$  em  $|i - j| = 128$ : essa cabeça consegue “ver” contexto de centenas de tokens com penalidade mínima.

**POR QUE ESPECTRO DE SLOPES?** O conjunto de slopes  $\{2^{-1}, 2^{-2}, \dots, 2^{-8}\}$  cobre múltiplas escalas de atenção: atenção local extrema (cabeça 1) até atenção quase global (cabeça 8). Isso permite que o modelo, em camadas profundas, componha relações locais (sintaxe) e globais (semântica de longo alcance) simultaneamente, sem nenhum parâmetro adicional além dos já existentes em cada cabeça de atenção.

**XXIII**  — Injetividade do Positional Encoding Senoidal

**ENUNCIADO.** Considere o positional encoding senoidal  $\text{PE}(i) \in \mathbb{R}^d$  com  $d = 512$  para posições inteiras  $i \geq 0$ . É possível recuperar univocamente a posição  $i$  a partir do vetor  $\text{PE}(i)$ ?

**Resposta correta**

Alternativa (b): Sim, para posições práticas ( $i \ll 10^4$ ): as frequências crescem geometricamente e as combinações  $(\sin(i/\omega_k), \cos(i/\omega_k))$  são virtualmente distintas para posições inteiras dentro do intervalo de uso típico.

**ARGUMENTO FORMAL DE INJETIVIDADE.** **Definição.** O positional encoding senoidal é:

$$\text{PE}(i, 2k) = \sin\left(\frac{i}{\omega_k}\right), \quad \text{PE}(i, 2k+1) = \cos\left(\frac{i}{\omega_k}\right), \quad \omega_k = 10000^{2k/d}, \quad k = 0, 1, \dots, \frac{d}{2}-1.$$

**Condição de colisão.** Dois inteiros  $i \neq j$  com  $i, j \geq 0$  produzem  $\text{PE}(i) = \text{PE}(j)$  se e somente se, para *todo*  $k$ :

$$\frac{i}{\omega_k} \equiv \frac{j}{\omega_k} \pmod{2\pi},$$

ou seja,  $\frac{i-j}{\omega_k}$  é múltiplo inteiro de  $2\pi$  para todo  $k$ .

**Análise para  $k = 0$ .** Com  $\omega_0 = 10000^0 = 1$ :

$$(i - j) \cdot 1 = 2\pi m \quad \text{para algum inteiro } m.$$

Portanto  $i - j = 2\pi m$ . Como  $i - j$  é um inteiro (diferença de dois inteiros) e  $2\pi \approx 6,28318 \dots$  é **irracional**, a única solução é  $m = 0$ , o que implica  $i = j$ .

**Conclusão.** A frequência  $k = 0$  *por si só* é suficiente para garantir que nenhuma colisão existe entre posições inteiras não-negativas distintas quaisquer. O mapeamento  $i \mapsto \text{PE}(i)$  é **estritamente injetivo** para todo  $i, j \in \mathbb{Z}_{\geq 0}$  com  $i \neq j$ .

**POR QUE A ALTERNATIVA (B) DIZ “PARA POSIÇÕES PRÁTICAS”?** A formulação “para posições práticas ( $i \ll 10^4$ )” na alternativa (b) é conservadora e reflete a abordagem do artigo original (Vaswani et al., 2017), que usou bases de frequência  $\omega_k = 10000^{2k/d}$  esperando que posições  $i \lesssim 10^4$  fossem suficientes para aplicações de NLP. O argumento acima mostra que a injetividade é, na verdade, *universal* sobre os inteiros não-negativos — a irracionalidade de  $2\pi$  garante isso matematicamente.

#### ANÁLISE DAS ALTERNATIVAS INCORRETAS.

- (a) — **Errada.** A alternativa afirma que posições separadas por um múltiplo inteiro de  $2\pi$  teriam o mesmo encoding. Contudo,  $2\pi$  é irracional, então nenhum múltiplo não-nulo de  $2\pi$  é inteiro. A premissa da opção (a) nunca é satisfeita para posições inteiras.
- (c) — **Errada.** A norma de  $\text{PE}(i)$  é:

$$\|\text{PE}(i)\|^2 = \sum_{k=0}^{d/2-1} \left[ \sin^2\left(\frac{i}{\omega_k}\right) + \cos^2\left(\frac{i}{\omega_k}\right) \right] = \sum_{k=0}^{d/2-1} 1 = \frac{d}{2}.$$

A norma é constante igual a  $\sqrt{d/2}$  para *todo*  $i$ . Isso é correto e decorre da identidade pitagórica, mas a norma constante é indiferente à questão de injetividade: o que importa para distinguir  $i$  de  $j$  é a *direção* do vetor  $\text{PE}(i)$ , não sua magnitude. Dois vetores podem ter a mesma norma e ainda assim ser distintos.

- (d) — **Errada.**  $\sin(i)$  é periódica em  $i \in \mathbb{R}$  com período  $2\pi$  irracional; portanto, para inteiros  $i, j$ ,  $\sin(i) \neq \sin(j)$  sempre que  $i \neq j$  e  $|i - j| < 2\pi$ , mas é possível que  $\sin(i) = \sin(j)$  para inteiros distantes — a única dimensão não é suficiente por si só para toda a faixa de inteiros. Contudo, o *par*  $(\sin(i), \cos(i))$  identifica  $i \bmod 2\pi$  univocamente, e como  $2\pi$  é irracional, nenhum inteiro positivo tem a mesma representação que  $i = 0$ .

#### XXIV — PE Aprendido Além de $L_{\max}$

**ENUNCIADO.** Um modelo com positional encoding absoluto aprendido (estilo BERT), treinado com  $L_{\max} = 512$ , recebe na inferência uma sequência de comprimento  $L = 600$ . O que ocorre com os tokens nas posições 513 a 600?

##### Resposta correta

Alternativa (b): Essas posições não possuem embeddings treinados; a implementação típica lançará um erro de índice ou, se o índice for truncado, reutilizará vetores de posições iniciais, gerando representações fora da distribuição de treinamento.

**ANÁLISE DA IMPLEMENTAÇÃO.** O positional encoding aprendido é implementado como uma tabela de consulta (*lookup table*):

```
position_embeddings = nn.Embedding(L_max, d)
```

Essa camada armazena uma matriz treinável  $E \in \mathbb{R}^{L_{\max} \times d}$ , com uma linha por posição  $i \in \{0, 1, \dots, L_{\max} - 1\}$ .

**Cenário 1 — Erro de índice.** Em frameworks padrão como PyTorch, consultar `position_embeddings[512]` (com `L_max=512`) acessa o índice 512 de uma tabela com 512 linhas (índices 0–511), produzindo:

```
IndexError: index out of range in self
```

**Cenário 2 — Clamping de índice.** Algumas implementações aplicam `position_ids = position_ids.clamp(max=L_max-1)`, que força qualquer posição  $i \geq L_{\max}$  a usar o vetor treinado para  $i = L_{\max} - 1 = 511$ . Os tokens nas posições 512 a 599 recebem todos o *mesmo* embedding posicional (o da posição 511), resultando em:

- Perda completa da distinção posicional para os últimos 88 tokens;
- Atenção entre esses tokens afetada como se todos fossem equidistantes (mesma posição);
- Representações fortemente fora da distribuição de treinamento, pois o modelo nunca viu dois tokens simultâneos com posição 511.

#### Contraste com outros métodos.

- **PE senoidal:** possui fórmula fechada  $\sin(i/\omega_k)$ , calculável para qualquer  $i$ . Não consulta tabela.
- **RoPE:** aplica matrizes de rotação parametrizadas por  $\theta_k$ , válidas para qualquer  $i$ .
- **ALiBi:** computa  $m_h|i - j|$  para qualquer distância, sem tabela.

### XXV — Relação Matemática entre RoPE e PE Senoidal

**ENUNCIADO.** Tanto o RoPE quanto o PE senoidal utilizam frequências da forma  $\theta_k = 10000^{-2k/d}$ . Qual afirmação descreve com mais precisão a relação matemática entre os dois métodos?

#### Resposta correta

Alternativa (b): Compartilham o mesmo espectro de frequências, mas diferem fundamentalmente: o PE senoidal codifica posição *absoluta* por adição ao embedding de entrada, enquanto o RoPE codifica posição *relativa* via rotação dos vetores de query e key. Não existe configuração de pesos que torne os dois métodos equivalentes em geral.

**ANÁLISE COMPARATIVA. Espectro de frequências compartilhado.** Ambos os métodos utilizam o conjunto de frequências  $\{\theta_k\}_{k=0}^{d/2-1}$  com  $\theta_k = 10000^{-2k/d}$ . Isso não é coincidência: ambos precisam de um espectro que permita distinguir posições em um amplo intervalo (da resolução de token único até o comprimento máximo da sequência).

#### Diferenças fundamentais.

| Característica     | PE Senoidal (Vaswani et al.)            | RoPE (Su et al.)                             |
|--------------------|-----------------------------------------|----------------------------------------------|
| Ponto de aplicação | Antes de $W_Q, W_K$ (na entrada)        | Após $W_Q, W_K$                              |
| Operação           | Adição: $\mathbf{x}_i + \text{PE}(i)$   | Rotação: $R(i) \mathbf{q}_i$                 |
| Tipo de encoding   | Posição absoluta                        | Posição relativa                             |
| Score de atenção   | Contém termos cruzados conteúdo-posição | Apenas $\mathbf{q}^\top R(j - i) \mathbf{k}$ |

**Por que não são equivalentes mesmo com  $W_Q = W_K = I$ ?**

Com PE senoidal, o logit de atenção é:

$$A_{\text{seno}}(i, j) = (\mathbf{x}_i + \text{PE}(i))^\top (\mathbf{x}_j + \text{PE}(j)) = \mathbf{x}_i^\top \mathbf{x}_j + \mathbf{x}_i^\top \text{PE}(j) + \text{PE}(i)^\top \mathbf{x}_j + \text{PE}(i)^\top \text{PE}(j).$$

O último termo  $\text{PE}(i)^\top \text{PE}(j)$  se simplifica via identidades trigonométricas:

$$\text{PE}(i)^\top \text{PE}(j) = \sum_k \cos\left(\frac{j-i}{\omega_k}\right),$$

que depende apenas de  $(j-i)$ . Contudo, os termos cruzados  $\mathbf{x}_i^\top \text{PE}(j)$  e  $\text{PE}(i)^\top \mathbf{x}_j$  introduzem dependência de posição absoluta misturada com conteúdo vetorial.

Com RoPE:

$$A_{\text{RoPE}}(i, j) = (R(i)\mathbf{x}_i)^\top (R(j)\mathbf{x}_j) = \mathbf{x}_i^\top R(j-i)\mathbf{x}_j.$$

Não há termos cruzados conteúdo-posição absoluta: a posição entra exclusivamente como offset relativo  $R(j-i)$ .

Portanto, mesmo quando  $W_Q = W_K = I$ , os dois logits contêm termos estruturalmente distintos e os dois métodos não são equivalentes para nenhuma escolha de pesos.

## XXVI — Prova da Propriedade de Posição Relativa do RoPE

**ENUNCIADO.** Para o RoPE com  $d = 2$  e parâmetro  $\theta$ , a matriz de rotação é

$$R(i) = \begin{pmatrix} \cos(i\theta) & -\sin(i\theta) \\ \sin(i\theta) & \cos(i\theta) \end{pmatrix}.$$

Dado que  $R(i)^\top R(j) = R(j-i)$  e que  $\tilde{\mathbf{q}}_i = R(i)\mathbf{q}$  e  $\tilde{\mathbf{k}}_j = R(j)\mathbf{k}$ , como o score  $\tilde{\mathbf{q}}_i^\top \tilde{\mathbf{k}}_j$  pode ser reescrito?

### Resposta correta

Alternativa **(b)**:  $\mathbf{q}^\top R(j-i)\mathbf{k}$ , mostrando que o score depende apenas do offset relativo  $(j-i)$ .

**PROVA COMPLETA EM TRÊS PARTES. Parte 1 — Ortogonalidade de  $R(i)$ .**

$R(i)$  é uma matriz de rotação plana e, portanto, ortogonal:

$$R(i)^\top R(i) = I \implies R(i)^\top = R(i)^{-1} = R(-i).$$

Verificação explícita:

$$R(i)^\top = \begin{pmatrix} \cos(i\theta) & \sin(i\theta) \\ -\sin(i\theta) & \cos(i\theta) \end{pmatrix} = R(-i).$$

**Parte 2 — Propriedade de composição  $R(a)R(b) = R(a+b)$ .**

$$\begin{aligned} R(a)R(b) &= \begin{pmatrix} \cos a\theta & -\sin a\theta \\ \sin a\theta & \cos a\theta \end{pmatrix} \begin{pmatrix} \cos b\theta & -\sin b\theta \\ \sin b\theta & \cos b\theta \end{pmatrix} \\ &= \begin{pmatrix} \cos a\theta \cos b\theta - \sin a\theta \sin b\theta & -\cos a\theta \sin b\theta - \sin a\theta \cos b\theta \\ \sin a\theta \cos b\theta + \cos a\theta \sin b\theta & -\sin a\theta \sin b\theta + \cos a\theta \cos b\theta \end{pmatrix} \\ &= \begin{pmatrix} \cos(a+b)\theta & -\sin(a+b)\theta \\ \sin(a+b)\theta & \cos(a+b)\theta \end{pmatrix} = R(a+b). \end{aligned}$$

**Parte 3 — Reescrita do score de atenção.**

$$\begin{aligned}
 \tilde{\mathbf{q}}_i^\top \tilde{\mathbf{k}}_j &= (R(i) \mathbf{q})^\top (R(j) \mathbf{k}) \\
 &= \mathbf{q}^\top R(i)^\top R(j) \mathbf{k} && \text{(transposição de produto)} \\
 &= \mathbf{q}^\top R(-i) R(j) \mathbf{k} && \text{(Parte 1)} \\
 &= \mathbf{q}^\top R(-i + j) \mathbf{k} && \text{(Parte 2 com } a = -i, b = j) \\
 &= \mathbf{q}^\top R(j - i) \mathbf{k}.
 \end{aligned}$$

**INTERPRETAÇÃO TEÓRICA.** O resultado  $\mathbf{q}^\top R(j - i) \mathbf{k}$  mostra que:

1. As posições absolutas  $i$  e  $j$  cancelam-se durante a derivação; apenas o offset relativo  $\delta = j - i$  permanece.
2. A matriz  $R(\delta)$  é uma rotação *fixa* por ângulo  $\delta\theta$  que pondera o produto interno entre  $\mathbf{q}$  e  $\mathbf{k}$  de forma dependente da separação entre os tokens.
3. Para  $\delta = 0$  (self-attention em  $i = j$ ):  $R(0) = I$ , e o score reduz-se ao produto interno simples  $\mathbf{q}^\top \mathbf{k}$  sem penalidade posicional.
4. O resultado generaliza para  $d > 2$ : o RoPE aplica blocos de rotação 2D independentes  $\{R_k(\delta)\}_{k=0}^{d/2-1}$  a cada par de dimensões, e a mesma argumentação se aplica a cada bloco individualmente.

**EXTENSÃO PARA  $d$  ARBITRÁRIO.** Para  $d = 2M$  (dimensão geral), o RoPE aplica:

$$\tilde{\mathbf{q}}_i^\top \tilde{\mathbf{k}}_j = \sum_{k=0}^{M-1} [\mathbf{q}_{[2k:2k+2]}]^\top R_k(j - i) [\mathbf{k}_{[2k:2k+2]}],$$

onde  $R_k(\delta) = R(\delta\theta_k)$  usa a frequência  $\theta_k = 10000^{-2k/d}$ . Cada bloco  $k$  contribui com uma dependência relativa de frequência  $\theta_k$  distinta, e a soma sobre todos os blocos é o score completo de atenção RoPE, cujo valor depende apenas de  $\delta = j - i$  e dos vetores de conteúdo  $\mathbf{q}$  e  $\mathbf{k}$ .