

ATENÇÃO E TRANSFORMERS

MODELOS ENCODER-ONLY

INSTRUÇÕES: Cada questão possui exatamente uma alternativa correta.

QUESTÕES

- I) Na tarefa de *Named Entity Recognition* (NER) com esquema **BIO**, as categorias são: **B**egin (início de entidade), **I**nside (continuação) e **O**utside. Para a frase

Lucas trabalha na PUCRS em Porto Alegre

considerando as entidades *Lucas* (pessoa), *PUCRS* (organização) e *Porto Alegre* (local, dois *tokens*), qual sequência de *tags* é correta?

- a) B-PER, 0, 0, B-ORG, 0, B-LOC, I-LOC
 - b) B-PER, 0, 0, B-ORG, 0, I-LOC, I-LOC
 - c) B-PER, 0, 0, I-ORG, 0, B-LOC, I-LOC
 - d) I-PER, 0, 0, B-ORG, 0, B-LOC, I-LOC
- II) O BERT-Base tem $L = 12$ camadas, dimensão oculta $d = 768$ e $H = 12$ cabeças de atenção com $d_k = d/H = 64$ por cabeça. Em uma única camada de *self-attention*, as projeções são:

$$W^Q, W^K, W^V \in \mathbb{R}^{d \times (H \cdot d_k)}, \quad W^O \in \mathbb{R}^{(H \cdot d_k) \times d}.$$

Ignorando vieses, quantos parâmetros treináveis existem nessas **quatro** matrizes em uma única camada?

- a) 589 824: apenas W^Q .
 - b) 1 769 472: W^Q, W^K, W^V sem a projeção de saída W^O .
 - c) 2 359 296: as quatro matrizes W^Q, W^K, W^V, W^O .
 - d) 4 718 592: dupla contagem ao considerar dimensões de entrada e saída separadamente para cada projeção.
- III) No pré-treino do BERT, a estratégia MLM seleciona aleatoriamente 15% dos *tokens*. Um estudante propõe simplificar a regra 80/10/10 substituindo **100%** dos *tokens* selecionados pelo *token* especial [MASK] (em vez de 80% por [MASK], 10% por palavra aleatória e 10% mantidos inalterados). Qual é a principal desvantagem dessa simplificação?
- a) O modelo nunca aprende a representar *tokens* reais durante o pré-treino; ao fazer *fine-tuning*, jamais encontra [MASK], criando um desalinhamento entre as duas fases.
 - b) A perda MLM fica indefinida porque [MASK] não faz parte do vocabulário padrão do modelo.
 - c) Os gradientes da posição [MASK] se anulam quando todas as posições selecionadas recebem o mesmo *token*.

- d) O modelo aprende a ignorar a posição dos *tokens*, pois [MASK] é sempre o mesmo símbolo, independentemente da posição.
- IV) A representação de entrada do BERT é $\mathbf{x}_i = E_{\text{token}}(w_i) + E_{\text{segmento}}(s_i) + E_{\text{posição}}(i)$, onde E_{segmento} assume o valor E_A para tokens da primeira sentença e E_B para tokens da segunda. Um pesquisador remove o componente E_{segmento} para simplificar o modelo. Em qual das seguintes tarefas essa remoção causaria a **maior degradação** de desempenho?
- POS tagging* em uma única sentença.
 - Classificação de sentimento em uma única sentença (SST-2).
 - Extractive QA* (SQuAD): identificar o trecho que responde a uma pergunta dado um parágrafo de contexto.
 - Named Entity Recognition* (NER) em uma única sentença.
- V) O ELECTRA (Clark et al., 2020) substitui o objetivo MLM do BERT pelo *Replaced Token Detection* (RTD): um gerador pequeno cria *tokens* substitutos para $\approx 15\%$ das posições, e o discriminador ELECTRA deve classificar **cada posição** da sequência como “real” ou “substituído”. Comparado ao BERT com MLM, qual é a principal vantagem do ELECTRA em eficiência de treinamento?
- O ELECTRA não precisa de uma camada de vocabulário na saída (custo $d \times |V|$), pois a classificação RTD é binária.
 - O ELECTRA gera sinal de gradiente em **todas** as posições da sequência (não apenas nos $\approx 15\%$ mascarados do MLM), obtendo desempenho equivalente com $\approx 25\%$ do *compute*.
 - O ELECTRA não precisa de *fine-tuning*, pois o RTD já otimiza diretamente tarefas discriminativas como NER.
 - O ELECTRA usa *batches* menores que o BERT por precisar do gerador auxiliar, reduzindo o consumo de memória e acelerando o treino por passo.
- VI) Um engenheiro extrai $\mathbf{h}_{[\text{CLS}]}^{(L)}$ (estado oculto final do [CLS]) de um BERT pré-treinado **sem fine-tuning** para medir a similaridade semântica entre sentenças via cosseno. No experimento de Reimers & Gurevych (2019), esse método obtém 20,29 de correlação de Spearman no STS-Benchmark, abaixo do GloVe (58,02). Qual raciocínio explica corretamente esse fenômeno?
- O [CLS] foi treinado no NSP, um objetivo binário e ruidoso que não incentiva a organização do espaço para similaridade cosseno; o espaço resultante é anisotrópico (vetores concentrados em um cone estreito), tornando as distâncias cosseno pouco discriminativas.
 - O BERT usa *position embeddings* aprendidos, logo o [CLS] captura apenas informação posicional e perde a semântica do restante da sentença.
 - O [CLS] usa apenas os *tokens* da última camada, enquanto o GloVe usa toda a hierarquia de *n*-grams (mais informação leva ao melhor desempenho).
 - O BERT foi pré-treinado apenas em inglês, e o STS-Benchmark contém sentenças em múltiplos idiomas, favorecendo o GloVe multilíngue.
- VII) No SBERT, o *mean pooling* mascarado calcula o vetor de sentença excluindo posições [PAD]:

$$\mathbf{u} = \frac{\sum_{i=1}^L m_i \mathbf{h}_i}{\sum_{i=1}^L m_i}, \quad m_i \in \{0, 1\}.$$

Uma sentença tem $L = 3$ tokens com os seguintes *embeddings* $\mathbf{h}_i \in \mathbb{R}^2$ e máscara de atenção:

Token	$\mathbf{h}_i$	m_i
w_1	[2, 0]	1
w_2	[0, 2]	1
w_3 ([PAD])	[1, 3]	0

Qual é o vetor de sentença $\mathbf{u}$ produzido pelo *mean pooling* mascarado?

- a) [1, 1]: média dos tokens reais w_1 e w_2 , excluindo o [PAD].
- b) $[1, \frac{5}{3}] \approx [1,00, 1,67]$: inclui $\mathbf{h}_3$ do [PAD] no numerador e usa $L = 3$ no denominador.
- c) [2, 2]: soma correta dos tokens mascarados, sem dividir por $\sum m_i$.
- d) $[\frac{2}{3}, \frac{2}{3}] \approx [0,67, 0,67]$: exclui o [PAD] do numerador, mas divide por $L = 3$ em vez de $\sum m_i = 2$.

VIII) Um sistema de busca semântica precisa classificar $n = 100\,000$ documentos em relação a uma consulta. Um **cross-encoder** requer 1 *forward pass* por par (consulta, documento); um **bi-encoder** pré-computa os documentos *offline* e, no momento da consulta, realiza apenas 1 *forward pass* (para a consulta) seguido de busca vetorial. Cada *forward pass* demora $t = 10$ ms. Qual é a redução de latência no momento da consulta ao usar o bi-encoder?

- a) $\approx 100\times$: o bi-encoder ainda precisa de 1 *forward pass* por documento durante a consulta.
- b) $\approx 1\,000\times$: eliminando o processamento par-a-par para os primeiros 1\,000 documentos filtrados.
- c) $\approx 100\,000\times$: a consulta requer apenas 10 ms (um único *forward pass*) em vez de $100\,000 \times 10 \text{ ms} = 1\,000 \text{ s}$.
- d) Equivalente; a busca vetorial requer um produto escalar por documento, igualando o custo do *forward pass*.

IX) Na perda *InfoNCE* com *in-batch negatives*, um *batch* de $N = 4$ pares (x_i, x_i^+) fornece $N - 1 = 3$ negativos por âncora. Um engenheiro aumenta o *batch* para $N = 1\,024$. Qual é o efeito esperado desse aumento?

- a) O treino fica mais lento por *token*, mas os gradientes são mais informativos: cada âncora deve distinguir seu positivo de 1\,023 competidores, melhorando a qualidade dos *embeddings*.
- b) O treino produz resultado equivalente ao de $N = 4$: a perda *InfoNCE* é normalizada pelo número de negativos e compensa automaticamente o aumento.
- c) O treino diverge com N grande porque o denominador do *softmax* fica muito grande, zerando os gradientes.
- d) O benefício de N grande é apenas computacional (melhor utilização de GPU), sem impacto na qualidade final dos *embeddings*.

X)  Considere três *embeddings* (já normalizados) e a *triplet loss* com margem $\alpha = 0,5$:

$$f(x) = [1,0, 0,0], \quad f(x^+) = [0,6, 0,8], \quad f(x^-) = [-0,6, 0,8],$$

$$\mathcal{L}_{\text{triplet}} = \max(0, \|f(x) - f(x^+)\|_2^2 - \|f(x) - f(x^-)\|_2^2 + \alpha).$$

Qual é o valor de $\mathcal{L}_{\text{triplet}}$?

- a) 0 (a margem já é satisfeita: o positivo está suficientemente mais próximo que o negativo).

- b) 0,50 (a perda iguala exatamente a margem α quando as duas distâncias são iguais).
- c) 1,90 (diferença das distâncias quadráticas, sem aplicar o $\max(0, \cdot)$).
- d) -1,90 (resultado antes do truncamento por zero).

XI) 🧠 O BERT pré-treina com a perda MLM:

$$\mathcal{L}_{\text{MLM}} = -\frac{1}{|M|} \sum_{i \in M} \log p(w_i | \mathbf{w}_{\setminus M}).$$

Em um passo de treino, $|M| = 3$ posições são mascaradas. O modelo atribui as seguintes probabilidades ao *token* correto em cada posição: $p_1 = 0,50$, $p_2 = 0,25$, $p_3 = 0,125$. Qual é o valor de $\mathcal{L}_{\text{MLM}}$?

- a) $\approx 0,693$
- b) $\approx 1,386$
- c) $\approx 2,079$
- d) $\approx 4,159$

SOLUÇÕES

I — Resposta: (a)

O esquema BIO exige que o **primeiro token** de qualquer entidade receba a *tag* **B-** (Begin), e os tokens subsequentes da mesma entidade recebam **I-** (Inside). Tokens fora de entidades recebem **O**. Na frase:

- “Lucas” $\rightarrow$ B-PER (inicia a entidade pessoa).
- “PUCRS” $\rightarrow$ B-ORG (inicia a entidade organização).
- “Porto” $\rightarrow$ B-LOC (inicia a entidade local de dois tokens).
- “Alegre” $\rightarrow$ I-LOC (continua a mesma entidade local).

A opção (b) usa I-LOC para “Porto” (erro: nunca se inicia uma entidade com I-). A opção (c) usa I-ORG para “PUCRS” (mesmo erro para organização). A opção (d) usa I-PER para “Lucas” (mesmo erro para pessoa).

II — Resposta: (c)

Como $H \cdot d_k = 12 \times 64 = 768 = d$, todas as quatro matrizes são $\mathbb{R}^{768 \times 768}$. O número de parâmetros em cada uma é $768 \times 768 = 589\,824$, e no total:

$$4 \times 589\,824 = 2\,359\,296.$$

A opção (a) conta apenas W^Q . A opção (b) omite a projeção de saída W^O , que transforma a concatenação das cabeças de volta à dimensão d e é tão grande quanto as demais. A opção (d) duplica o resultado correto (erro de dupla contagem).

III — Resposta: (a)

O [MASK] é um token **exclusivo do pré-treino**: ele nunca aparece na fase de *fine-tuning* nem na inferência. Se todos os tokens selecionados fossem substituídos por [MASK], o modelo **nunca aprenderia a representar tokens reais**; ao encontrá-los no *fine-tuning*,

suas representações seriam subótimas. A regra 80/10/10 mitiga esse desalinhamento ao forçar o modelo a lidar com tokens reais (intactos ou aleatórios) mesmo durante o pré-treino. A opção (b) é falsa: [MASK] é um token do vocabulário do BERT. A opção (c) é falsa: posições com o mesmo *token* ainda produzem gradiente distinto, pois os estados ocultos dependem do contexto. A opção (d) confunde mascaramento com ignorância de posição; a *position embedding* é somada antes de qualquer mascaramento.

IV — Resposta: (c)

No formato SQuAD, a entrada é [CLS] pergunta [SEP] contexto [SEP], com os tokens da pergunta recebendo E_A e os do contexto recebendo E_B . Sem *segment embeddings*, o modelo **não distingue** quais tokens são a pergunta e quais são o contexto, degradando drasticamente a tarefa de identificação de *spans*. As tarefas (a), (b) e (d) operam em uma única sentença, portanto todos os tokens compartilhariam E_A : a remoção de E_{segmento} não altera o comportamento nessas tarefas.

V — Resposta: (b)

No MLM do BERT, o gradiente só flui pelas $\approx 15\%$ das posições mascaradas. No ELECTRA, o discriminador classifica **todas** as L posições (“real” ou “substituído”), gerando gradiente **denso** a cada passo. Esse sinal mais rico permite que o ELECTRA alcance o mesmo desempenho do BERT com $\approx 25\%$ do *compute* de pré-treino. A opção (a) é parcialmente verdadeira (a cabeça de saída é binária), mas a camada de vocabulário do gerador ainda existe; a vantagem principal é o sinal denso. A opção (c) é falsa: o ELECTRA ainda requer *fine-tuning*. A opção (d) inverte o raciocínio: o gerador aumenta o custo por passo, mas o ganho em eficiência vem do sinal mais informativo.

VI — Resposta: (a)

O [CLS] é treinado no NSP (classificação binária “é ou não é a próxima sentença”), sem nenhum incentivo para estruturar o espaço de *embeddings* de forma que **frases similares fiquem próximas**. O resultado é um espaço **anisotrópico**: todos os vetores se concentram em um cone estreito do hiperespaço, tornando as distâncias cosseno pouco discriminativas (frases totalmente diferentes podem ter cosseno $> 0,9$). O GloVe, embora estático, captura co-ocorrências e produz um espaço mais isotrópico, o que o torna superior para STS *vanilla*. A opção (b) confunde *position embeddings* com o objetivo do [CLS]. A opção (c) inventa um mecanismo inexistente. A opção (d) é falsa: o BERT original foi pré-treinado em inglês, assim como o GloVe mais comum, e o STS-Benchmark é predominantemente em inglês.

VII — Resposta: (a)

A máscara zera a contribuição de w_3 ; o numerador é $m_1\mathbf{h}_1 + m_2\mathbf{h}_2 + m_3\mathbf{h}_3 = [2, 0] + [0, 2] + \mathbf{0} = [2, 2]$ e o denominador é $\sum m_i = 1 + 1 + 0 = 2$:

$$\mathbf{u} = \frac{[2, 2]}{2} = [1, 1].$$

A opção (b) inclui $\mathbf{h}_3 = [1, 3]$ do [PAD] no numerador e usa $L = 3$: $([2, 0] + [0, 2] + [1, 3])/3 = [3, 5]/3 = [1, \frac{5}{3}]$: resultado distorcido pela posição de *padding*. A opção (c) aplica corretamente a máscara ao numerador, mas omite a divisão por $\sum m_i$, produzindo a soma bruta $[2, 2]$. A opção (d) exclui o [PAD] do numerador (correto),

mas divide por $L = 3$ em vez de $\sum m_i = 2$, gerando $[2, 2]/3 = [\frac{2}{3}, \frac{2}{3}]$: erro de normalização.

VIII — Resposta: (c)

O cross-encoder requer 1 *forward pass* por par, logo $n = 100\,000$ passes no momento da consulta:

$$100\,000 \times 10 \text{ ms} = 1\,000\,000 \text{ ms} = 1\,000 \text{ s}.$$

O bi-encoder pré-computa todos os documentos *offline*. Na consulta, basta 1 *forward pass* para a *query* (10 ms) seguido de busca vetorial (produto escalar em hardware SIMD, $\ll 1$ ms para 10^5 vetores). Redução de latência:

$$\frac{1\,000\,000 \text{ ms}}{10 \text{ ms}} = 100\,000 \times .$$

A opção (a) erra ao supor que o bi-encoder ainda faz um *forward pass* por documento em tempo de consulta (documentos estão pré-computados). A opção (b) chega a $1\,000\times$ por confundir $n = 100\,000$ com $n = 1\,000$. A opção (d) subestima a diferença de velocidade entre um produto escalar e um *forward pass* completo por um transformer (fator de $\sim 10^4$ – 10^6).

IX — Resposta: (a)

Na perda InfoNCE, para cada âncora x_i o positivo x_i^+ deve ser identificado entre todos os x_j^+ do *batch*:

$$\mathcal{L}_{\text{NCE}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{\text{sim}(f(x_i), f(x_i^+))/\tau}}{\sum_{j=1}^N e^{\text{sim}(f(x_i), f(x_j^+))/\tau}}.$$

Com $N = 1\,024$, cada âncora compete com $1\,023$ negativos simultâneos, gerando gradiente mais rico e discriminativo. Empiricamente, o desempenho escala com $\log N$, motivando *batches* de $1\,024$ – $16\,384$ em modelos SOTA. A opção (b) erra: a normalização pelo N no denominador da média **não** é equivalente a neutralizar o efeito de mais negativos: o denominador do *softmax* cresce com N , tornando o problema de classificação mais difícil. A opção (c) erra: o *softmax* com denominador grande concentra gradiente nos negativos mais difíceis, não o zera. A opção (d) erra: mais negativos melhoram a qualidade, não apenas a eficiência.

X — Resposta: (a)

Cálculo das distâncias quadráticas:

$$\begin{aligned} \|f(x) - f(x^+)\|_2^2 &= (1,0 - 0,6)^2 + (0,0 - 0,8)^2 = 0,16 + 0,64 = 0,80, \\ \|f(x) - f(x^-)\|_2^2 &= (1,0 - (-0,6))^2 + (0,0 - 0,8)^2 = 2,56 + 0,64 = 3,20. \end{aligned}$$

Aplicando a fórmula:

$$\mathcal{L}_{\text{triplet}} = \max(0, 0,80 - 3,20 + 0,50) = \max(0, -1,90) = 0.$$

O positivo ($d^2 = 0,80$) já está 2,40 unidades mais próximo que o negativo ($d^2 = 3,20$), excedendo a margem $\alpha = 0,50$: o par não viola a restrição e não gera gradiente. A opção (b) ocorreria se as duas distâncias fossem iguais ($d^+ = d^-$); nesse caso $\mathcal{L} = \alpha = 0,50$. A opção (c) é o argumento antes do $\max(0, \cdot)$. A opção (d) é o mesmo sem o valor absoluto.

XI — Resposta: (b)

As probabilidades dos tokens corretos são $p_1 = \frac{1}{2}$, $p_2 = \frac{1}{4}$, $p_3 = \frac{1}{8}$. Aplicando a fórmula com $|M| = 3$:

$$\begin{aligned}\mathcal{L}_{\text{MLM}} &= -\frac{1}{3} \left(\ln \frac{1}{2} + \ln \frac{1}{4} + \ln \frac{1}{8} \right) \\ &= -\frac{1}{3} (-\ln 2 - 2 \ln 2 - 3 \ln 2) \\ &= \frac{6 \ln 2}{3} = 2 \ln 2 \approx 1,386.\end{aligned}$$

Análise das alternativas incorretas:

- (a) $\approx 0,693$: considera apenas $-\ln(0,50) = \ln 2$, ou seja, somente a primeira posição, sem a média.
- (c) $\approx 2,079$: usa $|M| = 2$ no denominador ($6 \ln 2 / 2 = 3 \ln 2$), como se apenas duas posições fossem mascaradas.
- (d) $\approx 4,159$: omite a normalização $1/|M|$ por completo ($-(\ln \frac{1}{2} + \ln \frac{1}{4} + \ln \frac{1}{8}) = 6 \ln 2$).