

# TREINAMENTO DE LLMS

---

## PRÉ-TREINAMENTO, ALINHAMENTO, OTIMIZAÇÕES E PEFT

**INSTRUÇÕES:** Cada questão possui exatamente uma alternativa correta.

### QUESTÕES

- I) Um escalonador *cosine decay* sem *warm-up* é configurado com  $\eta_{\max} = 10^{-3}$ ,  $\eta_{\min} = 10^{-4}$  e duração total  $T = 10\,000$  passos, seguindo a fórmula vista em aula:

$$\eta_t = \eta_{\min} + \frac{\eta_{\max} - \eta_{\min}}{2} \left( 1 + \cos \frac{\pi t}{T} \right).$$

Qual o valor de  $\eta_t$  na metade do treinamento ( $t = 5\,000$ )?

- a)  $5,5 \times 10^{-4}$ .
- b)  $1,0 \times 10^{-3}$ .
- c)  $4,5 \times 10^{-4}$ .
- d)  $1,0 \times 10^{-4}$ .

- II) Um modelo possui  $N = 2 \times 10^9$  parâmetros (2B). Um *fine-tuning* completo com AdamW em *mixed precision* mantém simultaneamente em VRAM:

- pesos em fp16 (2 B/par)
- gradientes em fp16 (2 B/par)
- cópia mestre dos pesos em fp32 (4 B/par)
- primeiro momento Adam  $m$  em fp32 (4 B/par)
- segundo momento Adam  $v$  em fp32 (4 B/par)

Qual o total de VRAM requerido por esses componentes (sem contar ativações)?

- a) 32 GB.
- b) 4 GB.
- c) 8 GB.
- d) 24 GB.

- III) A perda do SFT é

$$\mathcal{L}_{\text{SFT}}(\theta) = - \sum_{t \in \mathcal{R}} \log P_{\theta}(x_t | x_{<t}),$$

ou seja, somente os tokens da resposta ( $\mathcal{R}$ ) contribuem. Um estudante sugere calcular a perda em *todos* os tokens (prompt + resposta), argumentando que “mais supervisão = melhor aprendizado”. Qual a principal falha desse raciocínio?

- a) O gradiente passa a incluir contribuições dos tokens de instrução, que seguem formatos repetitivos em todos os exemplos; o modelo gastaria capacidade aprendendo a *gerar instruções* em vez de aprender a *responder* a elas.

- b) A perda ficaria numericamente indefinida porque os tokens do prompt não pertencem ao vocabulário do modelo.
- c) O *teacher forcing* falharia, pois tokens especiais como  $\langle \text{im\_start} \rangle$  não podem ser previstos.
- d) A normalização por  $|\mathcal{R}|$  resultaria em divisão por zero, já que todos os tokens passariam a contar.

IV) Uma equipe treina um modelo de 7B em fp16 *mixed precision* e observa NaN frequentes nos gradientes. Ao trocar para bf16, o problema desaparece sem precisar de *loss scaling*. Qual a explicação correta para esse comportamento?

- a) BF16 tem 8 bits de expoente (mesma faixa dinâmica do fp32:  $\sim 10^{-38}$  a  $\sim 10^{38}$ ), enquanto fp16 tem 5 bits de expoente e satura próximo de 65 504. Gradientes de redes profundas extrapolam esse limite, causando Inf/NaN; a faixa larga do bf16 elimina o *overflow* sem necessidade de escalonamento.
- b) BF16 tem 16 bits de mantissa, oferecendo mais precisão que os 10 bits do fp16, eliminando os erros de arredondamento que causavam os NaN.
- c) BF16 é *lossless* para pesos de redes neurais, ao contrário do fp16, que sempre introduz erros de quantização.
- d) BF16 usa o dobro de bits do fp16 (32 vs. 16), o que explica o ganho de estabilidade numérica.

V) O *Reward Model* (RM) é treinado com a perda de Bradley-Terry:

$$\mathcal{L}_{\text{RM}} = -\log \sigma(r_{\phi}(x, y_w) - r_{\phi}(x, y_l)).$$

Para um par de treino, o RM atribui  $r_{\phi}(x, y_w) = 1,8$  e  $r_{\phi}(x, y_l) = 0,3$ . Usando  $\sigma(1,5) \approx 0,818$ , qual o valor de  $\mathcal{L}_{\text{RM}}$ ?

- a)  $\approx 0,201$ .
- b)  $\approx 1,702$ .
- c)  $\approx 0,693$ .
- d)  $\approx 1,5$ .

VI) Durante o alinhamento de um modelo de 7B, o RLHF-PPO mantém **4 modelos** simultâneos em VRAM (política, referência SFT, *reward model*, *value function*); o DPO mantém apenas **2** (política + referência congelada). Suponha cada cópia bf16  $\approx 14$  GB e que o estado do otimizador AdamW apenas da *política* ocupa  $\approx 100$  GB (ignorando ativações). Quanto cada método consome e qual a economia do DPO?

- a) PPO  $\approx 156$  GB, DPO  $\approx 128$  GB (economia  $\approx 28$  GB).
- b) PPO  $\approx 114$  GB, DPO  $\approx 114$  GB (economia  $\approx 0$ ).
- c) PPO  $\approx 56$  GB, DPO  $\approx 28$  GB (economia  $\approx 28$  GB).
- d) PPO  $\approx 28$  GB, DPO  $\approx 14$  GB (economia  $\approx 14$  GB).

VII) Um *transformer* com  $d_{\text{model}} = 2048$  possui quatro projeções de atenção por camada ( $Q, K, V, O$ ), cada uma de formato  $2048 \times 2048$ . Aplicando LoRA com *rank*  $r = 16$  nas quatro projeções ( $h = W_0x + \frac{\alpha}{r} B A x$ , com  $B \in \mathbb{R}^{d \times r}$ ,  $A \in \mathbb{R}^{r \times k}$ ), quantos parâmetros treináveis são adicionados por camada e que fração representam dos pesos originais de atenção?

- a) 262 144 params ( $\approx 1,56\%$  dos 16,78 M originais).
- b) 131 072 params ( $\approx 0,78\%$ ).
- c) 524 288 params ( $\approx 3,12\%$ ).

d) 65 536 params ( $\approx 0,39\%$ ).

VIII) No LoRA,  $A$  é inicializado com distribuição normal gaussiana e  $B$  com **zeros**. Um estudante pergunta: “por que não inicializar *ambos* aleatoriamente?”. Qual a justificativa correta para a escolha  $B = 0$ ?

- a) Com  $B = 0$ , temos  $\Delta W = \frac{\alpha}{r}BA = 0$  no passo inicial, logo o modelo adaptado começa *exatamente* do pré-treinamento. Se  $B$  fosse aleatório,  $\Delta W \neq 0$  adicionaria ruído às projeções pré-treinadas, degradando o ponto de partida.
- b) Inicializar  $B$  aleatoriamente faria com que o adaptador LoRA competisse com os pesos originais, reduzindo o número de parâmetros treináveis efetivos.
- c)  $B = 0$  é matematicamente necessário para que a decomposição  $\Delta W = BA$  tenha *rank* exatamente  $r$ : inicialização aleatória quebraria a restrição de baixo *rank*.
- d) Com  $B$  aleatório, o fator  $\alpha/r$  causaria explosão de gradiente nas primeiras iterações.

IX) Um bloco do Flash Attention processa os escores  $s = [1, 2, 0, 3]$  em dois tiles:  $B_1 = [1, 2]$  e  $B_2 = [0, 3]$ . A recursão do *online softmax* é

$$m^{\text{new}} = \max(m^{\text{old}}, \max_j s_j), \quad \ell^{\text{new}} = e^{m^{\text{old}} - m^{\text{new}}} \ell^{\text{old}} + \sum_j e^{s_j - m^{\text{new}}}.$$

Qual o valor de  $\ell$  após processar os dois tiles? (Use  $e^{-1} \approx 0,368$ ,  $e^{-2} \approx 0,135$ ,  $e^{-3} \approx 0,050$ .)

- a)  $\approx 1,553$ .
- b)  $\approx 2,418$ .
- c)  $\approx 1,368$ .
- d)  $\approx 1,050$ .

X) Uma equipe faz SFT de um modelo usando  $\eta = 3 \times 10^{-4}$  (mesma LR usada no pré-treino) por 10 épocas. A perda SFT no conjunto de treino cai normalmente, mas *benchmarks* gerais (MMLU, HellaSwag) **degradam visivelmente** ao longo das épocas. Qual diagnóstico e correção são adequados?

- a) *Catastrophic forgetting*: LR alto por muitas épocas sobrescreve representações adquiridas no pré-treinamento, mesmo com a perda SFT em queda. Correção: reduzir LR para  $10^{-6}$ – $2 \times 10^{-5}$  e limitar a 1–3 épocas.
- b) Comportamento esperado: SFT sempre descarta conhecimento do pré-treinamento; a correção é treinar do zero com os dados SFT.
- c) *Overfitting* nos próprios *benchmarks*; a correção é adicionar mais *benchmarks* ao conjunto de avaliação.
- d) Explosão de gradiente causada pelo LR alto; a correção é aumentar o *weight decay* para 1,0.

XI) 🧠 Em uma iteração de GRPO para um problema com *reward* binário (1 = correto, 0 = errado), um prompt produz um grupo de  $G = 6$  respostas com recompensas  $r = [1, 1, 0, 1, 0, 1]$ . A vantagem é

$$\hat{A}_i = \frac{r_i - \bar{r}}{\sigma_r},$$

onde  $\bar{r}$  e  $\sigma_r$  são a média e o desvio-padrão do grupo. Quais os valores de  $\hat{A}$  para as respostas corretas e incorretas?

- a)  $\hat{A}_{\text{correto}} \approx +0,707$ ;  $\hat{A}_{\text{errado}} \approx -1,414$ .

- b)  $\hat{A}_{\text{correto}} = +1,000$ ;  $\hat{A}_{\text{errado}} = -1,000$ .
- c)  $\hat{A}_{\text{correto}} = +1/3$ ;  $\hat{A}_{\text{errado}} = -2/3$ .
- d)  $\hat{A}_{\text{correto}} = +0,500$ ;  $\hat{A}_{\text{errado}} = 0$ .

XII)  A perda do DPO é

$$\mathcal{L}_{\text{DPO}} = -\log \sigma \left( \beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right).$$

Em um exemplo com  $\beta = 0,1$ ,  $\log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} = 2$  e  $\log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} = -1$ , qual o valor de  $\mathcal{L}_{\text{DPO}}$ ? (Use  $\sigma(0,3) \approx 0,574$ ,  $\sigma(3) \approx 0,953$ ,  $\sigma(-0,3) \approx 0,426$ .)

- a)  $\approx 0,555$ .
- b)  $\approx 0,048$ .
- c)  $\approx 0,853$ .
- d)  $\approx 0,300$ .

## SOLUÇÕES

I — Resposta: (a)

Em  $t = T/2$ :  $\cos(\pi \cdot 0,5) = \cos(\pi/2) = 0$ , logo  $1 + \cos(\pi/2) = 1$ . Portanto,

$$\eta_{T/2} = 10^{-4} + \frac{10^{-3}-10^{-4}}{2} \cdot 1 = 10^{-4} + 4,5 \times 10^{-4} = 5,5 \times 10^{-4}.$$

A opção (b) ignora totalmente o termo com cosseno. A opção (c) omite a parcela  $\eta_{\min}$  da fórmula. A opção (d) confunde  $\cos(\pi/2) = 0$  com  $\cos(\pi) = -1$ , obtendo  $\eta_{\min}$ , valor correto apenas no fim do treino ( $t = T$ ).

II — Resposta: (a)

Somando os componentes em bytes por parâmetro:  $2 + 2 + 4 + 4 + 4 = 16$  B/par. Aplicando a  $N = 2 \times 10^9$ :  $2 \times 10^9 \times 16 = 3,2 \times 10^{10}$  bytes = 32 GB. As opções (b), (c) e (d) ignoram subconjuntos dos componentes: somente pesos, pesos+gradientes e um dos momentos do Adam, respectivamente.

III — Resposta: (a)

Os tokens de instrução seguem padrões repetitivos (`<|im_start|>user, "Explique..."`, etc.). Se forem incluídos na perda, o gradiente é dominado por eles e o modelo gasta capacidade modelando a *distribuição das instruções* em vez de aprender a gerar boas respostas. Mascaram o prompt garante que o aprendizado se concentre em  $P(\text{resposta} | \text{instrução})$ , não em  $P(\text{instrução})$ . A opção (b) é falsa: tokens de prompt estão no vocabulário (caso contrário, não poderiam sequer ser alimentados como entrada). A opção (c) confunde mascaramento de *loss* com ausência do token no vocabulário. A opção (d) é falsa: a normalização é por  $|\mathcal{R}|$  (tokens da resposta), e incluir os tokens do prompt apenas aumentaria  $|\mathcal{R}|$ , não o zeraria.

IV — Resposta: (a)

A diferença essencial entre fp16 e bf16 é o número de bits de expoente: fp16 usa 5 (limite  $\approx 65504$ ) e bf16 usa 8 (mesmo limite do fp32,  $\approx 3,4 \times 10^{38}$ ). Gradientes grandes provocam *overflow* em fp16, gerando Inf/NaN; a faixa larga do bf16 elimina

esse problema sem exigir *loss scaling*. A opção (b) inverte o trade-off: bf16 tem *menos* mantissa (7 bits) que o fp16 (10). O ganho não é precisão, é faixa. A opção (c) é falsa: ambos são lossy. A opção (d) é falsa: ambos ocupam 16 bits.

V — Resposta: (a)

$\Delta r = r_\phi(x, y_w) - r_\phi(x, y_l) = 1,8 - 0,3 = 1,5$ .  $\sigma(1,5) \approx 0,818$ , portanto  $\mathcal{L}_{\text{RM}} = -\ln(0,818) \approx 0,201$ . A opção (b) inverte o sinal da diferença, aplicando  $\sigma(-1,5) \approx 0,182$  ( $-\ln(0,182) \approx 1,702$ ): seria a perda se o RM ordenasse *incorretamente*. A opção (c) usa  $\sigma(0) = 0,5$ , equivalente a ignorar totalmente  $\Delta r$ . A opção (d) retorna o *logit* sem passá-lo pelo  $\sigma$  nem aplicar  $-\ln$ .

VI — Resposta: (a)

**PPO:** 4 cópias em bf16 + estado do otimizador da política =  $4 \cdot 14 + 100 = 56 + 100 = 156$  GB.

**DPO:** 2 cópias em bf16 + estado do otimizador da política =  $2 \cdot 14 + 100 = 28 + 100 = 128$  GB.

**Economia:**  $156 - 128 = 28$  GB, exatamente o custo das duas cópias que o DPO dispensa (*reward model* e *value function*). A opção (b) é falsa: o PPO *inclui* duas cópias adicionais frozen, portanto sua memória é maior. A opção (c) ignora o estado do otimizador da política (100 GB). A opção (d) reduz incorretamente cada método a uma única cópia.

VII — Resposta: (a)

Cada projeção LoRA adiciona  $|B| + |A| = d \cdot r + r \cdot k = 2 \cdot d \cdot r$  parâmetros (como  $d = k = 2048$ ). Para quatro projeções:

$$4 \times 2 \cdot 2048 \cdot 16 = 4 \times 65536 = 262144 \text{ params.}$$

Pesos originais:  $4 \times 2048^2 = 16777216 \approx 16,78$  M. Fração:  $262144/16777216 \approx 1,56\%$ . A opção (b) conta apenas  $d \cdot r$  por projeção, esquecendo a segunda matriz. A opção (c) duplica erroneamente o resultado. A opção (d) considera apenas uma das quatro projeções.

VIII — Resposta: (a)

O ponto de partida do LoRA é o modelo pré-treinado intacto: exige-se  $\Delta W = \frac{\alpha}{r} BA = 0$  na inicialização. Zerar  $B$  (com  $A$  aleatório) satisfaz essa condição. Se *ambos* fossem aleatórios,  $\Delta W \neq 0$  adicionaria ruído aos pesos congelados, destruindo o ponto de partida calibrado do pré-treinamento. O modelo teria de “reaprender” antes mesmo de começar a se adaptar aos dados de ajuste. A opção (b) não faz sentido dimensional: inicialização não altera contagem de parâmetros treináveis. A opção (c) é falsa: o *rank* de  $BA$  é determinado pela forma das matrizes, não pelos valores iniciais. A opção (d) confunde o papel de  $\alpha/r$  (fator de escala constante, não amplificador de gradiente).

IX — Resposta: (a)

**Processando**  $B_1 = [1, 2]$ :

$$\begin{aligned} m^{(1)} &= \max(1, 2) = 2 \\ \ell^{(1)} &= e^{1-2} + e^{2-2} = 0,368 + 1 = 1,368. \end{aligned}$$

Processando  $B_2 = [0, 3]$ :

$$\begin{aligned} m^{(2)} &= \max(2, 3) = 3 \\ \ell^{(2)} &= e^{m^{(1)} - m^{(2)}} \cdot \ell^{(1)} + e^{0-3} + e^{3-3} \\ &= e^{-1} \cdot 1,368 + e^{-3} + e^0 \\ &\approx 0,368 \cdot 1,368 + 0,050 + 1 \\ &\approx 0,503 + 0,050 + 1 = \mathbf{1,553}. \end{aligned}$$

Conferência (softmax global):  $e^{1-3} + e^{2-3} + e^{0-3} + e^{3-3} = 0,135 + 0,368 + 0,050 + 1 = 1,553$ . ✓ A opção (b) omite o fator de rescala  $e^{m^{\text{old}} - m^{\text{new}}}$ , tratando  $\ell^{(1)}$  como se já estivesse normalizado para  $m^{(2)}$ . A opção (c) ignora  $B_2$ . A opção (d) ignora o histórico  $\ell^{(1)}$ .

X — Resposta: (a)

O padrão é clássico de *catastrophic forgetting*: a perda SFT decresce porque o modelo aprende o *formato* dos dados de ajuste, mas as muitas atualizações com LR alto modificam significativamente os pesos, apagando representações úteis para tarefas gerais. O remédio canônico é LR muito menor que no pré-treinamento ( $10^{-6}$ – $2 \times 10^{-5}$ ) e apenas 1–3 épocas. A opção (b) contradiz a hipótese do alinhamento superficial (LIMA): o SFT ensina formato e estilo, não substitui o pré-treinamento. A opção (c) é implausível: *benchmarks* não estão no conjunto de treino, então *overfitting* neles não faz sentido. A opção (d) descreve um sintoma diferente: explosão de gradiente geraria NaN agudos, não degradação gradual. Além disso, aumentar *weight decay* não corrige explosões e pioraria o *forgetting*.

XI — Resposta: (a)

Com rewards  $[1, 1, 0, 1, 0, 1]$  e  $G = 6$ :

$$\begin{aligned} \bar{r} &= \frac{4}{6} = \frac{2}{3} \approx 0,667, \\ \sigma_r^2 &= \mathbb{E}[r^2] - \bar{r}^2 = \frac{4}{6} - \frac{4}{9} = \frac{6}{9} - \frac{4}{9} = \frac{2}{9}, \\ \sigma_r &= \frac{\sqrt{2}}{3} \approx 0,471. \end{aligned}$$

Portanto,

$$\begin{aligned} \hat{A}_{\text{correto}} &= \frac{1 - 2/3}{\sqrt{2}/3} = \frac{1/3}{\sqrt{2}/3} = \frac{1}{\sqrt{2}} \approx +0,707, \\ \hat{A}_{\text{errado}} &= \frac{0 - 2/3}{\sqrt{2}/3} = -\frac{2}{\sqrt{2}} = -\sqrt{2} \approx -1,414. \end{aligned}$$

A magnitude maior para as respostas erradas (minoritárias) é esperada: o z-score pesa mais a cauda menos populosa. A opção (b) usa os valores do slide, que valem apenas quando *metade* do grupo acerta ( $G = 4$ , 2 corretos, 2 errados), situação em que  $\sigma_r = 0,5$ . A opção (c) esquece a normalização por  $\sigma_r$ . A opção (d) substitui a *baseline* correta (média) por  $\max(r) = 1$ .

XII — Resposta: (a)

Argumento do  $\sigma$ :

$$\beta \left( \log \frac{\pi_\theta(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \log \frac{\pi_\theta(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) = 0,1 \cdot (2 - (-1)) = 0,3.$$

$\sigma(0,3) \approx 0,574$ , portanto  $\mathcal{L}_{\text{DPO}} = -\ln(0,574) \approx 0,555$ . A opção (b) esquece o  $\beta$ , aplicando  $\sigma(3) \approx 0,953$ , subestimando dramaticamente a perda. A opção (c) inverte o sinal, usando  $\sigma(-0,3)$  (corresponderia a uma *preferência errada*:  $y_l$  mais provável que  $y_w$ ). A opção (d) retorna o argumento do  $\sigma$  sem aplicar  $-\log \sigma$ .