

**Instruções:** Responda às questões de múltipla escolha assinalando apenas uma alternativa. Nas dissertativas, apresente o raciocínio passo a passo, incluindo fórmulas e cálculos intermediários quando solicitado. Mantenha a notação dos slides:  $g[z, \theta]$  para o gerador (com latente  $z$  e parâmetros  $\theta$ ),  $f[x, \phi]$  para o discriminador/crítico,  $\sigma(\cdot)$  para a sigmóide,  $P(x)$  para a distribuição real,  $P^*(x)$  para a distribuição gerada,  $M(x) = \frac{1}{2}(P + P^*)$  para a mistura,  $D^*(x) = \frac{P(x)}{P(x) + P^*(x)}$  para o discriminador ótimo,  $D_{JS}$  para a divergência de Jensen–Shannon e  $D_w$  para a distância de Wasserstein. Questões marcadas com 🧠 são consideradas difíceis.

### Questões de Múltipla Escolha.

- I) Considere a categoria  $a$ , com  $P(a) = 0,40$  e  $P^*(a) = 0,10$ . Qual é o valor do discriminador ótimo  $D^*(a)$  nesse ponto?
- (a) 0,80.
  - (b) 0,20.
  - (c) 0,40.
  - (d) 0,50.
- II) Para uma única amostra **real** ( $y = 1$ ), o discriminador devolve  $\sigma(f[x, \phi]) = 0,20$ . Qual é a contribuição dessa amostra à *loss* de entropia cruzada binária do discriminador?
- (a) 0,200.
  - (b)  $\approx 0,223$ .
  - (c)  $\approx 1,609$ .
  - (d) 0,800.
- III) Seja  $d = f[g(z), \theta]$  o logit do discriminador na amostra gerada. No ponto  $d = -3$ , quais são, respectivamente, as magnitudes dos gradientes da *loss* original do gerador  $L_{\text{orig}} = \ln[1 - \sigma(d)]$  e da *loss non-saturating*  $L_{\text{NS}} = -\ln[\sigma(d)]$  em relação a  $d$ ? Use  $\sigma(-3) \approx 0,047$ .
- (a) 0,953 e 0,047.
  - (b) 0,047 e 0,953.
  - (c) 0,500 e 0,500.
  - (d) 0,047 e 0,047.
- IV) Sobre o suporte  $\{a, b\}$ , considere  $P = (0,5, 0,5)$  e  $P^* = (0,0, 1,0)$ . Qual é o valor de  $D_{JS}(P^*||P)$  em nats? Use  $\ln 2 \approx 0,693$  e  $\ln(4/3) \approx 0,288$ .
- (a)  $\approx 0,14$ .
  - (b)  $\approx 0,43$ .
  - (c)  $\approx 0,69$ .
  - (d)  $\approx 0,22$ .
- V) Sobre o suporte  $\{0, 1, 2\}$ , considere  $Pr = (0,5, 0,3, 0,2)$  e  $Qr = (0,2, 0,3, 0,5)$ . Usando o custo  $|i - j|$ , qual é o valor de  $D_w(Pr||Qr)$  obtido pelo plano de transporte ótimo?
- (a) 0,6.

- (b) 1,2.  
(c) 0,3.  
(d) 0,0.
- VI) Você implementa uma DCGAN cujas imagens reais estão normalizadas em  $[-1, 1]$ . Por engano, troca a ativação *Tanh* da última camada do gerador por *ReLU*, mantendo o resto da arquitetura. Qual o efeito mais provável no treinamento?
- (a) ReLU produz amostras de qualidade semelhante à *Tanh* desde que haja *BatchNorm* imediatamente antes da última convolução.  
(b) O gerador fica restrito a  $[0, \infty)$  e nunca produz os valores negativos das imagens reais, e o treinamento degenera.  
(c) ReLU acelera o treinamento por eliminar o *vanishing gradient* típico da *Tanh* em saturação.  
(d) Como o gerador da DCGAN não usa camadas *fully connected*, a ativação da última convolução não influencia o intervalo da saída.
- VII) Em *WGAN-GP*, o termo de penalidade adicionado à *loss* é  $\lambda (\|\nabla_{\hat{x}} f[\hat{x}, \phi]\|_2 - 1)^2$  avaliado em um ponto interpolado  $\hat{x}$ . Para  $\lambda = 10$  e  $\|\nabla_{\hat{x}} f[\hat{x}, \phi]\|_2 = 3$ , qual é a contribuição desse ponto à *loss*?
- (a) 4.  
(b) 90.  
(c) 40.  
(d) 20.
- VIII)  Sobre o suporte  $\{a, b, c, d\}$ , considere  $P = (0,5, 0,5, 0, 0)$  e  $P^* = (0, 0, 0,4, 0,6)$ . Qual é o valor de  $D_{JS}(P^*||P)$  em nats? Use a convenção  $0 \ln 0 = 0$ .
- (a)  $\approx 0,35$ .  
(b)  $\approx 1,39$ .  
(c) 0.  
(d)  $\approx 0,69$ .
- IX) Em uma equipe de pesquisa, alguém descreve um modelo gerador com a seguinte combinação de propriedades: (i) gera amostras nítidas em uma única passagem pela rede, (ii) frequentemente ignora modas inteiras do conjunto real durante o treinamento, (iii) o ajuste de hiperparâmetros é notoriamente instável. A qual família o modelo descrito corresponde, dentro do trilema apresentado nos slides?
- (a) GAN.  
(b) Modelo difusor (*diffusion model*).  
(c) VAE.  
(d) *Normalizing flow*.
- X)  Considere  $Pr = (0,6, 0,3, 0,1)$  e  $Qr = (0,1, 0,3, 0,6)$  sobre o suporte  $\{0, 1, 2\}$ , cuja distância de Wasserstein é  $D_w = 1$ . Qual dos candidatos abaixo para o crítico  $f = (f_0, f_1, f_2)$  satisfaz a restrição 1-Lipschitz  $|f_{i+1} - f_i| \leq 1$  e atinge  $D_w$  no dual  $\sum_i Pr(i) f_i - \sum_j Qr(j) f_j$ ?

- (a)  $f = (0, 1, 2)$ .
- (b)  $f = (2, 1, 0)$ .
- (c)  $f = (10, 5, 0)$ .
- (d)  $f = (1, 1, 1)$ .

### Gabarito - Objetivas

- I) a
- II) c
- III) b
- IV) d
- V) a
- VI) b
- VII) c
- VIII) d
- IX) a
- X) b

### Resoluções - Objetivas

- I)  $D^*(a) = \frac{P(a)}{P(a)+P^*(a)} = \frac{0,40}{0,40+0,10} = \frac{0,40}{0,50} = 0,80$ . A (b) corresponde a inverter os papéis no numerador,  $\frac{P^*}{P+P^*} = 0,20$ . A (c) corresponde a devolver  $P(a)$  sem normalizar pela soma. A (d) corresponde ao palpitar *chance* de 0,5, ignorando os dados.
- II) Como o rótulo é  $y = 1$  (real), a contribuição é  $-\ln[\sigma(f[x, \phi])] = -\ln(0,20) \approx 1,609$  (alternativa c). A (a) reporta  $\sigma$  diretamente, sem aplicar o logaritmo. A (b) usa  $-\ln(1 - \sigma) = -\ln(0,80) \approx 0,223$ , que seria correto se a amostra fosse gerada ( $y = 0$ ). A (d) reporta  $1 - \sigma$ , também sem logaritmo.
- III) Diferenciando termo a termo:  $\partial L_{\text{orig}}/\partial d = -\sigma(d)$ , com módulo  $\sigma(d) = 0,047$ . Para a *non-saturating*,  $\partial L_{\text{NS}}/\partial d = -(1 - \sigma(d))$ , com módulo  $1 - 0,047 = 0,953$  (alternativa b). A (a) troca os dois rótulos. A (c) assume gradiente constante de 0,5, que vale apenas no equilíbrio  $\sigma = \frac{1}{2}$ . A (d) atribui o mesmo valor a ambas, ignorando que a NS foi construída exatamente para não saturar quando  $\sigma \rightarrow 0$ .
- IV) Com  $M = (0,25, 0,75)$ :  $D_{KL}(P\|M) = 0,5 \ln 2 + 0,5 \ln(2/3) \approx 0,347 - 0,203 = 0,144$ , e  $D_{KL}(P^*\|M) = \ln(4/3) \approx 0,288$  (o termo em  $a$  vale 0 pela convenção  $0 \ln 0 = 0$ ). Logo  $D_{JS} = \frac{1}{2}(0,144+0,288) \approx 0,22$  nats (alternativa d). A (b) corresponde a somar as duas KL sem o fator  $\frac{1}{2}$  externo. A (c) corresponde a tratar as distribuições como suporte disjunto e usar o limite  $\ln 2$ . A (a) corresponde a usar apenas  $D_{KL}(P\|M)$ .

- V) As diferenças  $P - Qr = (+0,3, 0, -0,3)$  indicam que 0,3 de massa deve sair do índice 0 e chegar ao índice 2. O plano ótimo concentra esse movimento em uma única rota, custo  $0,3 \cdot |0 - 2| = 0,6$ . A (b) corresponde a contabilizar duas vezes o mesmo transporte (origem e destino). A (c) corresponde a usar distância 1 em vez de 2 entre os extremos. A (d) corresponde ao plano *diagonal* ( $P_{ij}$  não-nulo apenas em  $i = j$ ), que viola as restrições marginais quando  $P \neq Qr$ .
- VI) Imagens reais ocupam  $[-1, 1]$ ; um gerador com *ReLU* na saída só consegue produzir valores em  $[0, \infty)$ , e em particular nunca em  $[-1, 0)$ . O discriminador descobre essa pista determinística (qualquer pixel negativo  $\Rightarrow$  real) e fica próximo de  $\sigma \approx 0$  nas amostras geradas, fazendo o gradiente da *loss* original do gerador colapsar (alternativa b). A (a) ignora a incompatibilidade entre o intervalo de saída e o domínio dos dados. A (c) confunde *vanishing gradient* de saturação interna com o problema de *range* da saída, são fenômenos distintos. A (d) confunde a recomendação da DCGAN, ausência de *fully connected* ocultas, com indiferença em relação à ativação final (que determina o intervalo da saída).
- VII) Penalidade  $= \lambda (\|\nabla f\|_2 - 1)^2 = 10 \cdot (3 - 1)^2 = 10 \cdot 4 = 40$  (alternativa c). A (b) corresponde a  $\lambda \|\nabla f\|^2 = 10 \cdot 9 = 90$ , esquecendo o  $-1$  dentro do quadrado. A (a) corresponde a  $(3 - 1)^2 = 4$ , esquecendo  $\lambda$ . A (d) corresponde a  $\lambda(3 - 1) = 20$ , esquecendo de elevar ao quadrado.
- VIII) Com  $M = (0,25, 0,25, 0,20, 0,30)$ : nos pontos em que  $P > 0$ ,  $\frac{P}{M} = 2$ ; nos pontos em que  $P^* > 0$ ,  $\frac{P^*}{M} = 2$ . Logo  $D_{KL}(P\|M) = (0,5+0,5) \ln 2 = \ln 2$  e, analogamente,  $D_{KL}(P^*\|M) = (0,4+0,6) \ln 2 = \ln 2$ . Portanto  $D_{JS} = \frac{1}{2}(\ln 2 + \ln 2) = \ln 2 \approx 0,69$  nats, o teto da Jensen–Shannon (alternativa d). A (b) corresponde a somar as duas KL sem o fator  $\frac{1}{2}$ . A (c) corresponde a confundir suporte disjunto com distribuições iguais. A (a) corresponde a aplicar o fator  $\frac{1}{2}$  duas vezes.
- IX) A combinação “rápido na amostragem + má cobertura + instável” é o canto *qualidade + velocidade* do trilema, ocupado por GANs. A (b) descreve difusores, que estão no canto *qualidade + cobertura* (custosos na amostragem). A (c) e a (d) descrevem famílias do canto *velocidade + cobertura*, que costumam ter cobertura boa e estabilidade alta, em troca de qualidade mais limitada.
- X) Verificando cada candidato:  $f = (2, 1, 0)$  (alternativa b) é 1-Lipschitz ( $|1 - 2| = |0 - 1| = 1$ ) e produz  $(2 \cdot 0,6 + 1 \cdot 0,3 + 0 \cdot 0,1) - (2 \cdot 0,1 + 1 \cdot 0,3 + 0 \cdot 0,6) = 1,5 - 0,5 = 1$ , atingindo  $D_w$ . A (a) é 1-Lipschitz mas tem orientação invertida,  $0,5 - 1,5 = -1$ ; o dual exige o máximo, não o mínimo. A (c) atinge soma 5, porém viola Lipschitz ( $|5 - 10| = 5 > 1$ ), ficando fora da região viável. A (d) é constante: 1-Lipschitz, mas produz soma 0, não distinguindo  $Pr$  de  $Qr$ .

## Questões Dissertativas.

I) Partindo da *loss* normalizada do discriminador,

$$L[\phi] = \mathbb{E}_{x^*} [\ln[1 - \sigma(f[x^*, \phi])]] + \mathbb{E}_x [\ln[\sigma(f[x, \phi])]],$$

mostre, em passos algébricos, que com o discriminador ótimo  $D^*(x) = \frac{P(x)}{P(x) + P^*(x)}$  a *loss* se reduz a

$$L[\phi] = 2 D_{JS}(P^* \| P) - 2 \ln 2.$$

Indique explicitamente: (a) onde a hipótese de iguais prioris ( $P(\text{real}) = P(\text{gen}) = \frac{1}{2}$ ) entra; (b) onde aparece o “truque do fator 2”; (c) por que a constante  $-2 \ln 2$  não afeta o  $\arg \min$  em relação a  $\phi$  nem o  $\arg \max$  em relação a  $\theta$ .

II) Considere  $Pr = (\frac{1}{2}, \frac{1}{2}, 0, 0)$  e  $Pg = (0, 0, \frac{1}{2}, \frac{1}{2})$  sobre o suporte  $\{0, 1, 2, 3\}$ , com custo  $|i - j|$ . Um plano de transporte ótimo  $P_{ij}$  (respeitando as marginais  $\sum_j P_{ij} = Pr(i)$  e  $\sum_i P_{ij} = Pg(j)$ ) preserva a ordem, transportando  $\frac{1}{2}$  de  $0 \rightarrow 2$  (custo 2) e  $\frac{1}{2}$  de  $1 \rightarrow 3$  (custo 2):

$$P = \begin{pmatrix} 0 & 0 & \frac{1}{2} & 0 \\ 0 & 0 & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}, \quad D_w(Pr \| Pg) = \frac{1}{2} \cdot 2 + \frac{1}{2} \cdot 2 = 2.$$

(a) Considere o crítico  $f = (3, 2, 1, 0)$ . Verifique a restrição 1-Lipschitz, calcule  $\sum_i Pr(i) f_i - \sum_j Pg(j) f_j$  e compare com o valor primal  $D_w(Pr \| Pg) = 2$  dado acima.

(b) Mostre que  $D_{JS}(Pr \| Pg) = \ln 2$  para esse par. Em uma frase, relacione esse fato ao problema de *vanishing gradient* que motiva o uso da distância de Wasserstein no WGAN.

III)  Seja  $d = f[g(z), \theta]$  o logit do discriminador na amostra gerada. Defina

$$L_{\text{orig}}[\theta] = \ln[1 - \sigma(d)] \quad \text{e} \quad L_{\text{NS}}[\theta] = -\ln[\sigma(d)],$$

ambas a serem minimizadas pelo gerador.

(a) Derive, mostrando todos os passos, que  $\partial L_{\text{orig}} / \partial d = -\sigma(d)$  e  $\partial L_{\text{NS}} / \partial d = -(1 - \sigma(d))$ . (Lembre que  $\sigma'(d) = \sigma(d)(1 - \sigma(d))$ .)

(b) Mostre que as duas formulações apontam o gradiente *na mesma direção* (ambas aumentam  $d$ ). Conclua que o equilíbrio adversarial  $\sigma(d) = \frac{1}{2}$  é ponto fixo das duas dinâmicas, e que nele as magnitudes dos gradientes valem  $\frac{1}{2}$  em ambos os casos.

(c) Avalie ambas as magnitudes em  $d \in \{-6, 0, +6\}$  e organize em uma pequena tabela. Comente, em uma frase, o caso  $d \rightarrow -\infty$  (discriminador vencendo o jogo): qual das duas *losses* produz gradiente útil para treinar o gerador?

IV) A divergência de Jensen–Shannon entre real e gerada decompõe-se como

$$D_{JS}(P^* \| P) = \underbrace{\frac{1}{2} D_{KL}[P^* \| M]}_{\text{qualidade}} + \underbrace{\frac{1}{2} D_{KL}[P \| M]}_{\text{cobertura}}, \quad M = \frac{1}{2}(P + P^*).$$

(a) Para  $P = (0,5, 0,3, 0,2)$  e  $P^* = (0,2, 0,5, 0,3)$  sobre  $\{a, b, c\}$ , calcule  $M$ ,  $D_{KL}(P \| M)$ ,  $D_{KL}(P^* \| M)$  e  $D_{JS}$ . Use  $\ln 2 \approx 0,693$  e apresente o resultado em nats com três casas decimais.

- (b) Suponha que, em alguma região  $R$ ,  $P^*(x) \ll P(x)$  (o gerador ignora uma moda). Mostre que, nessa região, o integrando do termo de *cobertura* é aproximadamente  $P(x) \ln 2$ , ou seja, fica **limitado e pouco sensível** a pequenos aumentos de  $P^*(x)$ .
- (c) Em duas ou três frases, conecte (b) ao fenômeno de *mode collapse*: por que o gerador prefere “ganhar qualidade” nas modas que já cobre a “ganhar cobertura” em modas que ignora?

## Gabarito

### I) Partimos de

$$L[\phi] = \mathbb{E}_{x^*} [\ln[1 - \sigma(f[x^*, \phi])]] + \mathbb{E}_x [\ln[\sigma(f[x, \phi])]] = \int P^*(x) \ln[1 - \sigma(f)] dx + \int P(x) \ln[\sigma(f)] dx.$$

O discriminador ótimo é obtido pela regra de Bayes assumindo  $P(\text{real}) = P(\text{gen}) = \frac{1}{2}$  (**item (a)**), o que cancela os *priors* e produz  $\sigma(f[x, \phi]) = \frac{P(x)}{P(x) + P^*(x)}$ , com complemento  $1 - \sigma = \frac{P^*(x)}{P(x) + P^*(x)}$ . Substituindo,

$$L = \int P^* \ln \left[ \frac{P^*}{P + P^*} \right] dx + \int P \ln \left[ \frac{P}{P + P^*} \right] dx.$$

Multiplicando e dividindo por 2 dentro de cada logaritmo (**item (b)**):

$$L = \int P^* \left( \ln \left[ \frac{2P^*}{P + P^*} \right] - \ln 2 \right) dx + \int P \left( \ln \left[ \frac{2P}{P + P^*} \right] - \ln 2 \right) dx.$$

Os termos  $-\ln 2$  saem das integrais e somam  $-2 \ln 2$ , pois  $\int P^* dx = \int P dx = 1$ . As integrais restantes são  $D_{KL}(P^* \| M)$  e  $D_{KL}(P \| M)$ , com  $M = \frac{1}{2}(P + P^*)$ . Logo

$$L = D_{KL}(P^* \| M) + D_{KL}(P \| M) - 2 \ln 2 = 2 D_{JS}(P^* \| P) - 2 \ln 2.$$

**Item (c):**  $-2 \ln 2$  é constante em  $\phi$  e em  $\theta$ , logo não altera  $\arg \min_{\phi}$  nem  $\arg \max_{\theta}$ .

- II) **(a)**  $f = (3, 2, 1, 0)$  satisfaz  $|f_{i+1} - f_i| = 1$  em todo par adjacente, portanto é 1-Lipschitz. O dual vale

$$\sum_i Pr(i) f_i - \sum_j Pg(j) f_j = \left( \frac{1}{2} \cdot 3 + \frac{1}{2} \cdot 2 \right) - \left( \frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 0 \right) = 2,5 - 0,5 = 2,$$

coincidindo com o valor primal  $D_w = 2$  dado no enunciado, como prevê a dualidade de Kantorovich–Rubinstein.

**(b)**  $Pr$  e  $Pg$  têm suportes disjuntos ( $\{0, 1\}$  contra  $\{2, 3\}$ ), então em todo ponto  $x$  vale  $\frac{Pr(x)}{M(x)} = 2$  (onde  $Pr > 0$ ) ou  $\frac{Pg(x)}{M(x)} = 2$  (onde  $Pg > 0$ ). Cada  $D_{KL}$  vale  $\ln 2$ , e  $D_{JS} = \frac{1}{2}(\ln 2 + \ln 2) = \ln 2$ . Como  $D_{JS}$  é constante quando os suportes são disjuntos,  $\partial D_{JS} / \partial \theta = 0$  e o gerador não recebe sinal de gradiente, o que motiva substituir  $D_{JS}$  pela distância de Wasserstein, que ainda varia (decrecentemente) quando se aproximam as massas.

- III) **(a)** Usando  $\sigma'(d) = \sigma(d)(1 - \sigma(d))$ :

$$\frac{\partial L_{\text{orig}}}{\partial d} = \frac{\partial}{\partial d} \ln[1 - \sigma(d)] = \frac{-\sigma'(d)}{1 - \sigma(d)} = \frac{-\sigma(1 - \sigma)}{1 - \sigma} = -\sigma(d).$$

$$\frac{\partial L_{\text{NS}}}{\partial d} = -\frac{\partial}{\partial d} \ln[\sigma(d)] = -\frac{\sigma'(d)}{\sigma(d)} = -\frac{\sigma(1 - \sigma)}{\sigma} = -(1 - \sigma(d)).$$

**(b)** Ambas as derivadas são *negativas* para  $\sigma(d) \in (0, 1)$ , portanto a descida de gradiente em  $d$  aumenta  $d$  em ambos os casos. No ponto  $\sigma(d) = \frac{1}{2}$ ,  $|\partial L_{\text{orig}} / \partial d| = \frac{1}{2}$  e  $|\partial L_{\text{NS}} / \partial d| = \frac{1}{2}$ , logo o equilíbrio é o mesmo ponto fixo das duas dinâmicas.

**(c)**

| $d$ | $\sigma(d)$      | $ \partial L_{\text{orig}}/\partial d  = \sigma(d)$ | $ \partial L_{\text{NS}}/\partial d  = 1 - \sigma(d)$ |
|-----|------------------|-----------------------------------------------------|-------------------------------------------------------|
| -6  | $\approx 0,0025$ | $\approx 0,0025$                                    | $\approx 0,9975$                                      |
| 0   | 0,5000           | 0,5000                                              | 0,5000                                                |
| +6  | $\approx 0,9975$ | $\approx 0,9975$                                    | $\approx 0,0025$                                      |

Quando  $d \rightarrow -\infty$  (discriminador vencendo,  $\sigma \rightarrow 0$ ),  $|\partial L_{\text{orig}}/\partial d| \rightarrow 0$  e a *loss* original satura, ao passo que  $|\partial L_{\text{NS}}/\partial d| \rightarrow 1$  e o gerador continua recebendo gradiente útil; por isso a NS é o *default* na prática.

IV) (a)  $M = \frac{1}{2}(P + P^*) = (0,35, 0,40, 0,25)$ .

$$D_{KL}(P\|M) = 0,5 \ln \frac{0,5}{0,35} + 0,3 \ln \frac{0,3}{0,40} + 0,2 \ln \frac{0,2}{0,25} \approx 0,178 - 0,086 - 0,045 = 0,047.$$

$$D_{KL}(P^*\|M) = 0,2 \ln \frac{0,2}{0,35} + 0,5 \ln \frac{0,5}{0,40} + 0,3 \ln \frac{0,3}{0,25} \approx -0,112 + 0,112 + 0,055 = 0,054.$$

$$D_{JS}(P^*\|P) = \frac{1}{2}(0,047 + 0,054) \approx 0,051 \text{ nats}.$$

(b) Em região  $R$  onde  $P^*(x) \ll P(x)$ , temos  $M(x) = \frac{P(x)+P^*(x)}{2} \approx \frac{P(x)}{2}$ . Logo  $\frac{P(x)}{M(x)} \approx 2$ , e o integrando da cobertura fica

$$P(x) \ln \frac{P(x)}{M(x)} \approx P(x) \ln 2,$$

**limitado** (cresce apenas com  $P(x)$ , não com a discrepância em si) e **pouco sensível** a pequenas perturbações em  $P^*(x)$  (a derivada em  $P^*$  envolve  $\frac{1}{P+P^*}$ , que é pequena quando  $P$  domina).

(c) O termo de qualidade ( $D_{KL}(P^*\|M)$ ) explode se o gerador colocar massa em pontos onde  $P$  é baixa: o gradiente pune **fortemente** amostras implausíveis. O termo de cobertura, pelo argumento de (b), é **quase insensível** a aumentos pequenos de  $P^*$  em modas ignoradas. Diante dessa assimetria, o caminho de menor custo durante o treinamento é *melhorar a qualidade nas modas já cobertas* (penalidade alta e gradiente forte) em vez de *cobrir novas modas* (penalidade baixa e gradiente fraco), produzindo *mode collapse*.