

Instruções: Responda às questões de múltipla escolha assinalando apenas uma alternativa. Nas dissertativas, apresente o raciocínio passo a passo, incluindo fórmulas e cálculos intermediários quando solicitado. Mantenha a notação dos slides: $g[z, \theta]$ para o gerador (com latente z e parâmetros θ), $f[x, \phi]$ para o discriminador/crítico, $\sigma(\cdot)$ para a sigmóide, $P(x)$ para a distribuição real, $P^*(x)$ para a distribuição gerada, $M(x) = \frac{1}{2}(P + P^*)$ para a mistura, $D^*(x) = \frac{P(x)}{P(x) + P^*(x)}$ para o discriminador ótimo, D_{JS} para a divergência de Jensen–Shannon e D_w para a distância de Wasserstein. Questões marcadas com 🦴 são consideradas difíceis.

Questões de Múltipla Escolha.

- I) Considere a categoria a , com $P(a) = 0,40$ e $P^*(a) = 0,10$. Qual é o valor do discriminador ótimo $D^*(a)$ nesse ponto?
- (a) 0,80.
 - (b) 0,20.
 - (c) 0,40.
 - (d) 0,50.
- II) Para uma única amostra **real** ($y = 1$), o discriminador devolve $\sigma(f[x, \phi]) = 0,20$. Qual é a contribuição dessa amostra à *loss* de entropia cruzada binária do discriminador?
- (a) $\approx 1,609$.
 - (b) $\approx 0,223$.
 - (c) 0,200.
 - (d) 0,800.
- III) Seja $d = f[g(z), \theta]$ o logit do discriminador na amostra gerada. No ponto $d = -3$, quais são, respectivamente, as magnitudes dos gradientes da *loss* original do gerador $L_{\text{orig}} = \ln[1 - \sigma(d)]$ e da *loss non-saturating* $L_{\text{NS}} = -\ln[\sigma(d)]$ em relação a d ? Use $\sigma(-3) \approx 0,047$.
- (a) 0,047 e 0,953.
 - (b) 0,953 e 0,047.
 - (c) 0,500 e 0,500.
 - (d) 0,047 e 0,047.
- IV) Sobre o suporte $\{a, b\}$, considere $P = (0,5, 0,5)$ e $P^* = (0,0, 1,0)$. Qual é o valor de $D_{JS}(P^*||P)$ em nats? Use $\ln 2 \approx 0,693$ e $\ln(4/3) \approx 0,288$.
- (a) $\approx 0,22$.
 - (b) $\approx 0,43$.
 - (c) $\approx 0,69$.
 - (d) $\approx 0,14$.
- V) Sobre o suporte $\{0, 1, 2\}$, considere $Pr = (0,5, 0,3, 0,2)$ e $Qr = (0,2, 0,3, 0,5)$. Usando o custo $|i - j|$, qual é o valor de $D_w(Pr||Qr)$ obtido pelo plano de transporte ótimo?
- (a) 0,6.

- (b) 1,2.
(c) 0,3.
(d) 0,0.
- VI) Você implementa uma DCGAN cujas imagens reais estão normalizadas em $[-1, 1]$. Por engano, troca a ativação *Tanh* da última camada do gerador por *ReLU*, mantendo o resto da arquitetura. Qual o efeito mais provável no treinamento?
- (a) O gerador fica restrito a $[0, \infty)$ e nunca emite os valores negativos presentes nas imagens reais; o discriminador separa reais de geradas trivialmente e o gradiente que chega ao gerador some.
(b) ReLU produz amostras de qualidade semelhante à *Tanh* desde que haja *BatchNorm* imediatamente antes da última convolução.
(c) ReLU acelera o treinamento por eliminar o *vanishing gradient* típico da *Tanh* em saturação.
(d) Como o gerador da DCGAN não usa camadas *fully connected*, a ativação da última convolução não influencia o intervalo da saída.
- VII) Em *WGAN-GP*, o termo de penalidade adicionado à *loss* é $\lambda (\|\nabla_{\hat{x}} f[\hat{x}, \phi]\|_2 - 1)^2$ avaliado em um ponto interpolado $\hat{x}$. Para $\lambda = 10$ e $\|\nabla_{\hat{x}} f[\hat{x}, \phi]\|_2 = 3$, qual é a contribuição desse ponto à *loss*?
- (a) 40.
(b) 90.
(c) 4.
(d) 20.
- VIII)  Sobre o suporte $\{a, b, c, d\}$, considere $P = (0,5, 0,5, 0, 0)$ e $P^* = (0, 0, 0,4, 0,6)$. Qual é o valor de $D_{JS}(P^*||P)$ em nats? Use a convenção $0 \ln 0 = 0$.
- (a) $\approx 0,69$.
(b) $\approx 1,39$.
(c) 0.
(d) $\approx 0,35$.
- IX) Em uma equipe de pesquisa, alguém descreve um modelo gerador com a seguinte combinação de propriedades: (i) gera amostras nítidas em uma única passagem pela rede, (ii) frequentemente ignora modas inteiras do conjunto real durante o treinamento, (iii) o ajuste de hiperparâmetros é notoriamente instável. A qual família o modelo descrito corresponde, dentro do trilema apresentado nos slides?
- (a) GAN.
(b) Modelo difusor (*diffusion model*).
(c) VAE.
(d) *Normalizing flow*.
- X)  Considere $Pr = (0,6, 0,3, 0,1)$ e $Qr = (0,1, 0,3, 0,6)$ sobre o suporte $\{0, 1, 2\}$, cuja distância de Wasserstein é $D_w = 1$. Qual dos candidatos abaixo para o crítico $f = (f_0, f_1, f_2)$ satisfaz a restrição 1-Lipschitz $|f_{i+1} - f_i| \leq 1$ e atinge D_w no dual $\sum_i Pr(i) f_i - \sum_j Qr(j) f_j$?

- (a) $f = (2, 1, 0)$.
- (b) $f = (0, 1, 2)$.
- (c) $f = (10, 5, 0)$.
- (d) $f = (1, 1, 1)$.

Gabarito - Objetivas

- I) a
- II) a
- III) a
- IV) a
- V) a
- VI) a
- VII) a
- VIII) a
- IX) a
- X) a

Resoluções - Objetivas

- I) $D^*(a) = \frac{P(a)}{P(a)+P^*(a)} = \frac{0,40}{0,40+0,10} = \frac{0,40}{0,50} = 0,80$. A (b) corresponde a inverter os papéis no numerador, $\frac{P^*}{P+P^*} = 0,20$. A (c) corresponde a devolver $P(a)$ sem normalizar pela soma. A (d) corresponde ao palpitar *chance* de 0,5, ignorando os dados.
- II) Como o rótulo é $y = 1$ (real), a contribuição é $-\ln[\sigma(f[x, \phi])] = -\ln(0,20) \approx 1,609$. A (b) usa $-\ln(1 - \sigma) = -\ln(0,80) \approx 0,223$, que seria correto se a amostra fosse gerada ($y = 0$). A (c) reporta σ diretamente, sem aplicar o logaritmo. A (d) reporta $1 - \sigma$, também sem logaritmo.
- III) Diferenciando termo a termo: $\partial L_{\text{orig}}/\partial d = -\sigma(d)$, com módulo $\sigma(d) = 0,047$. Para a *non-saturating*, $\partial L_{\text{NS}}/\partial d = -(1 - \sigma(d))$, com módulo $1 - 0,047 = 0,953$. A (b) troca os dois rótulos. A (c) assume gradiente constante de 0,5, que vale apenas no equilíbrio $\sigma = \frac{1}{2}$. A (d) atribui o mesmo valor a ambas, ignorando que a NS foi construída exatamente para não saturar quando $\sigma \rightarrow 0$.
- IV) Com $M = (0,25, 0,75)$: $D_{KL}(P||M) = 0,5 \ln 2 + 0,5 \ln(2/3) \approx 0,347 - 0,203 = 0,144$, e $D_{KL}(P^*||M) = \ln(4/3) \approx 0,288$ (o termo em a vale 0 pela convenção $0 \ln 0 = 0$). Logo $D_{JS} = \frac{1}{2}(0,144+0,288) \approx 0,22$ nats. A (b) corresponde a somar as duas KL sem o fator $\frac{1}{2}$ externo. A (c) corresponde a tratar as distribuições como suporte disjunto e usar o limite $\ln 2$. A (d) corresponde a usar apenas $D_{KL}(P||M)$.
- V) As diferenças $P - Qr = (+0,3, 0, -0,3)$ indicam que 0,3 de massa deve sair do índice 0 e chegar ao índice 2. O plano ótimo concentra esse movimento em uma única rota, custo $0,3 \cdot |0 - 2| = 0,6$. A (b) corresponde a contabilizar duas vezes o mesmo transporte (origem e destino). A (c) corresponde a usar distância 1 em vez de 2 entre os extremos. A (d) corresponde ao plano *diagonal* (P_{ij} não-nulo apenas em $i = j$), que viola as restrições marginais quando $P \neq Qr$.

- VI) Imagens reais ocupam $[-1, 1]$; um gerador com *ReLU* na saída só consegue produzir valores em $[0, \infty)$, e em particular nunca em $[-1, 0)$. O discriminador descobre essa pista determinística (qualquer pixel negativo $\Rightarrow$ real) e fica próximo de $\sigma \approx 0$ nas amostras geradas, fazendo o gradiente da *loss* original do gerador colapsar. A (b) ignora a incompatibilidade entre o intervalo de saída e o domínio dos dados. A (c) confunde *vanishing gradient* de saturação interna com o problema de *range* da saída, são fenômenos distintos. A (d) confunde a recomendação da DCGAN, ausência de *fully connected* ocultas, com indiferença em relação à ativação final (que determina o intervalo da saída).
- VII) Penalidade $= \lambda (\|\nabla f\|_2 - 1)^2 = 10 \cdot (3 - 1)^2 = 10 \cdot 4 = 40$. A (b) corresponde a $\lambda \|\nabla f\|^2 = 10 \cdot 9 = 90$, esquecendo o -1 dentro do quadrado. A (c) corresponde a $(3 - 1)^2 = 4$, esquecendo λ . A (d) corresponde a $\lambda(3 - 1) = 20$, esquecendo de elevar ao quadrado.
- VIII) Com $M = (0,25, 0,25, 0,20, 0,30)$: nos pontos em que $P > 0$, $\frac{P}{M} = 2$; nos pontos em que $P^* > 0$, $\frac{P^*}{M} = 2$. Logo $D_{KL}(P\|M) = (0,5+0,5) \ln 2 = \ln 2$ e, analogamente, $D_{KL}(P^*\|M) = (0,4+0,6) \ln 2 = \ln 2$. Portanto $D_{JS} = \frac{1}{2}(\ln 2 + \ln 2) = \ln 2 \approx 0,69$ nats, o teto da Jensen–Shannon. A (b) corresponde a somar as duas KL sem o fator $\frac{1}{2}$. A (c) corresponde a confundir suporte disjunto com distribuições iguais. A (d) corresponde a aplicar o fator $\frac{1}{2}$ duas vezes.
- IX) A combinação “rápido na amostragem + má cobertura + instável” é o canto *qualidade + velocidade* do trilema, ocupado por GANs. A (b) descreve difusores, que estão no canto *qualidade + cobertura* (custosos na amostragem). A (c) e a (d) descrevem famílias do canto *velocidade + cobertura*, que costumam ter cobertura boa e estabilidade alta, em troca de qualidade mais limitada.
- X) Verificando cada candidato: $f = (2, 1, 0)$ é 1-Lipschitz ($|1 - 2| = |0 - 1| = 1$) e produz $(2 \cdot 0,6 + 1 \cdot 0,3 + 0 \cdot 0,1) - (2 \cdot 0,1 + 1 \cdot 0,3 + 0 \cdot 0,6) = 1,5 - 0,5 = 1$, atingindo D_w . A (b) é 1-Lipschitz mas tem orientação invertida, $0,5 - 1,5 = -1$; o dual exige o máximo, não o mínimo. A (c) atinge soma 5, porém viola Lipschitz ($|5 - 10| = 5 > 1$), ficando fora da região viável. A (d) é constante: 1-Lipschitz, mas produz soma 0, não distinguindo P_r de Q_r .

Questões Dissertativas.

I) Partindo da *loss* normalizada do discriminador,

$$L[\phi] = \mathbb{E}_{x^*} [\ln[1 - \sigma(f[x^*, \phi])]] + \mathbb{E}_x [\ln[\sigma(f[x, \phi])]],$$

mostre, em passos algébricos, que com o discriminador ótimo $D^*(x) = \frac{P(x)}{P(x) + P^*(x)}$ a *loss* se reduz a

$$L[\phi] = 2 D_{JS}(P^* \| P) - 2 \ln 2.$$

Indique explicitamente: (a) onde a hipótese de iguais prioris ($P(\text{real}) = P(\text{gen}) = \frac{1}{2}$) entra; (b) onde aparece o “truque do fator 2”; (c) por que a constante $-2 \ln 2$ não afeta o $\arg \min$ em relação a ϕ nem o $\arg \max$ em relação a θ .

II) Considere $Pr = (\frac{1}{2}, \frac{1}{2}, 0, 0)$ e $Pg = (0, 0, \frac{1}{2}, \frac{1}{2})$ sobre o suporte $\{0, 1, 2, 3\}$, com custo $|i - j|$. Um plano de transporte ótimo P_{ij} (respeitando as marginais $\sum_j P_{ij} = Pr(i)$ e $\sum_i P_{ij} = Pg(j)$) preserva a ordem, transportando $\frac{1}{2}$ de $0 \rightarrow 2$ (custo 2) e $\frac{1}{2}$ de $1 \rightarrow 3$ (custo 2):

$$P = \begin{pmatrix} 0 & 0 & \frac{1}{2} & 0 \\ 0 & 0 & 0 & \frac{1}{2} \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}, \quad D_w(Pr \| Pg) = \frac{1}{2} \cdot 2 + \frac{1}{2} \cdot 2 = 2.$$

(a) Considere o crítico $f = (3, 2, 1, 0)$. Verifique a restrição 1-Lipschitz, calcule $\sum_i Pr(i) f_i - \sum_j Pg(j) f_j$ e compare com o valor primal $D_w(Pr \| Pg) = 2$ dado acima.

(b) Mostre que $D_{JS}(Pr \| Pg) = \ln 2$ para esse par. Em uma frase, relacione esse fato ao problema de *vanishing gradient* que motiva o uso da distância de Wasserstein no WGAN.

III)  Seja $d = f[g(z), \theta]$ o logit do discriminador na amostra gerada. Defina

$$L_{\text{orig}}[\theta] = \ln[1 - \sigma(d)] \quad \text{e} \quad L_{\text{NS}}[\theta] = -\ln[\sigma(d)],$$

ambas a serem minimizadas pelo gerador.

(a) Derive, mostrando todos os passos, que $\partial L_{\text{orig}} / \partial d = -\sigma(d)$ e $\partial L_{\text{NS}} / \partial d = -(1 - \sigma(d))$. (Lembre que $\sigma'(d) = \sigma(d)(1 - \sigma(d))$.)

(b) Mostre que as duas formulações apontam o gradiente *na mesma direção* (ambas aumentam d). Conclua que o equilíbrio adversarial $\sigma(d) = \frac{1}{2}$ é ponto fixo das duas dinâmicas, e que nele as magnitudes dos gradientes valem $\frac{1}{2}$ em ambos os casos.

(c) Avalie ambas as magnitudes em $d \in \{-6, 0, +6\}$ e organize em uma pequena tabela. Comente, em uma frase, o caso $d \rightarrow -\infty$ (discriminador vencendo o jogo): qual das duas *losses* produz gradiente útil para treinar o gerador?

IV) A divergência de Jensen–Shannon entre real e gerada decompõe-se como

$$D_{JS}(P^* \| P) = \underbrace{\frac{1}{2} D_{KL}[P^* \| M]}_{\text{qualidade}} + \underbrace{\frac{1}{2} D_{KL}[P \| M]}_{\text{cobertura}}, \quad M = \frac{1}{2}(P + P^*).$$

(a) Para $P = (0,5, 0,3, 0,2)$ e $P^* = (0,2, 0,5, 0,3)$ sobre $\{a, b, c\}$, calcule M , $D_{KL}(P \| M)$, $D_{KL}(P^* \| M)$ e D_{JS} . Use $\ln 2 \approx 0,693$ e apresente o resultado em nats com três casas decimais.

- (b) Suponha que, em alguma região R , $P^*(x) \ll P(x)$ (o gerador ignora uma moda). Mostre que, nessa região, o integrando do termo de *cobertura* é aproximadamente $P(x) \ln 2$, ou seja, fica **limitado e pouco sensível** a pequenos aumentos de $P^*(x)$.
- (c) Em duas ou três frases, conecte (b) ao fenômeno de *mode collapse*: por que o gerador prefere “ganhar qualidade” nas modas que já cobre a “ganhar cobertura” em modas que ignora?

Gabarito

I) Partimos de

$$L[\phi] = \mathbb{E}_{x^*} [\ln[1 - \sigma(f[x^*, \phi])]] + \mathbb{E}_x [\ln[\sigma(f[x, \phi])]] = \int P^*(x) \ln[1 - \sigma(f)] dx + \int P(x) \ln[\sigma(f)] dx.$$

O discriminador ótimo é obtido pela regra de Bayes assumindo $P(\text{real}) = P(\text{gen}) = \frac{1}{2}$ (**item (a)**), o que cancela os *priors* e produz $\sigma(f[x, \phi]) = \frac{P(x)}{P(x) + P^*(x)}$, com complemento $1 - \sigma = \frac{P^*(x)}{P(x) + P^*(x)}$. Substituindo,

$$L = \int P^* \ln \left[\frac{P^*}{P + P^*} \right] dx + \int P \ln \left[\frac{P}{P + P^*} \right] dx.$$

Multiplicando e dividindo por 2 dentro de cada logaritmo (**item (b)**):

$$L = \int P^* \left(\ln \left[\frac{2P^*}{P + P^*} \right] - \ln 2 \right) dx + \int P \left(\ln \left[\frac{2P}{P + P^*} \right] - \ln 2 \right) dx.$$

Os termos $-\ln 2$ saem das integrais e somam $-2 \ln 2$, pois $\int P^* dx = \int P dx = 1$. As integrais restantes são $D_{KL}(P^* \| M)$ e $D_{KL}(P \| M)$, com $M = \frac{1}{2}(P + P^*)$. Logo

$$L = D_{KL}(P^* \| M) + D_{KL}(P \| M) - 2 \ln 2 = 2 D_{JS}(P^* \| P) - 2 \ln 2.$$

Item (c): $-2 \ln 2$ é constante em ϕ e em θ , logo não altera $\arg \min_{\phi}$ nem $\arg \max_{\theta}$.

- II) **(a)** $f = (3, 2, 1, 0)$ satisfaz $|f_{i+1} - f_i| = 1$ em todo par adjacente, portanto é 1-Lipschitz. O dual vale

$$\sum_i Pr(i) f_i - \sum_j Pg(j) f_j = \left(\frac{1}{2} \cdot 3 + \frac{1}{2} \cdot 2 \right) - \left(\frac{1}{2} \cdot 1 + \frac{1}{2} \cdot 0 \right) = 2,5 - 0,5 = 2,$$

coincidindo com o valor primal $D_w = 2$ dado no enunciado, como prevê a dualidade de Kantorovich–Rubinstein.

(b) Pr e Pg têm suportes disjuntos ($\{0, 1\}$ contra $\{2, 3\}$), então em todo ponto x vale $\frac{Pr(x)}{M(x)} = 2$ (onde $Pr > 0$) ou $\frac{Pg(x)}{M(x)} = 2$ (onde $Pg > 0$). Cada D_{KL} vale $\ln 2$, e $D_{JS} = \frac{1}{2}(\ln 2 + \ln 2) = \ln 2$. Como D_{JS} é constante quando os suportes são disjuntos, $\partial D_{JS} / \partial \theta = 0$ e o gerador não recebe sinal de gradiente, o que motiva substituir D_{JS} pela distância de Wasserstein, que ainda varia (decrecentemente) quando se aproximam as massas.

- III) **(a)** Usando $\sigma'(d) = \sigma(d)(1 - \sigma(d))$:

$$\frac{\partial L_{\text{orig}}}{\partial d} = \frac{\partial}{\partial d} \ln[1 - \sigma(d)] = \frac{-\sigma'(d)}{1 - \sigma(d)} = \frac{-\sigma(1 - \sigma)}{1 - \sigma} = -\sigma(d).$$

$$\frac{\partial L_{\text{NS}}}{\partial d} = -\frac{\partial}{\partial d} \ln[\sigma(d)] = -\frac{\sigma'(d)}{\sigma(d)} = -\frac{\sigma(1 - \sigma)}{\sigma} = -(1 - \sigma(d)).$$

(b) Ambas as derivadas são *negativas* para $\sigma(d) \in (0, 1)$, portanto a descida de gradiente em d aumenta d em ambos os casos. No ponto $\sigma(d) = \frac{1}{2}$, $|\partial L_{\text{orig}} / \partial d| = \frac{1}{2}$ e $|\partial L_{\text{NS}} / \partial d| = \frac{1}{2}$, logo o equilíbrio é o mesmo ponto fixo das duas dinâmicas.

(c)

d	$\sigma(d)$	$ \partial L_{\text{orig}}/\partial d = \sigma(d)$	$ \partial L_{\text{NS}}/\partial d = 1 - \sigma(d)$
-6	$\approx 0,0025$	$\approx 0,0025$	$\approx 0,9975$
0	0,5000	0,5000	0,5000
+6	$\approx 0,9975$	$\approx 0,9975$	$\approx 0,0025$

Quando $d \rightarrow -\infty$ (discriminador vencendo, $\sigma \rightarrow 0$), $|\partial L_{\text{orig}}/\partial d| \rightarrow 0$ e a *loss* original satura, ao passo que $|\partial L_{\text{NS}}/\partial d| \rightarrow 1$ e o gerador continua recebendo gradiente útil; por isso a NS é o *default* na prática.

IV) (a) $M = \frac{1}{2}(P + P^*) = (0,35, 0,40, 0,25)$.

$$D_{KL}(P\|M) = 0,5 \ln \frac{0,5}{0,35} + 0,3 \ln \frac{0,3}{0,40} + 0,2 \ln \frac{0,2}{0,25} \approx 0,178 - 0,086 - 0,045 = 0,047.$$

$$D_{KL}(P^*\|M) = 0,2 \ln \frac{0,2}{0,35} + 0,5 \ln \frac{0,5}{0,40} + 0,3 \ln \frac{0,3}{0,25} \approx -0,112 + 0,112 + 0,055 = 0,054.$$

$$D_{JS}(P^*\|P) = \frac{1}{2}(0,047 + 0,054) \approx 0,051 \text{ nats}.$$

(b) Em região R onde $P^*(x) \ll P(x)$, temos $M(x) = \frac{P(x)+P^*(x)}{2} \approx \frac{P(x)}{2}$. Logo $\frac{P(x)}{M(x)} \approx 2$, e o integrando da cobertura fica

$$P(x) \ln \frac{P(x)}{M(x)} \approx P(x) \ln 2,$$

limitado (cresce apenas com $P(x)$, não com a discrepância em si) e **pouco sensível** a pequenas perturbações em $P^*(x)$ (a derivada em P^* envolve $\frac{1}{P+P^*}$, que é pequena quando P domina).

(c) O termo de qualidade ($D_{KL}(P^*\|M)$) explode se o gerador colocar massa em pontos onde P é baixa: o gradiente pune **fortemente** amostras implausíveis. O termo de cobertura, pelo argumento de (b), é **quase insensível** a aumentos pequenos de P^* em modas ignoradas. Diante dessa assimetria, o caminho de menor custo durante o treinamento é *melhorar a qualidade nas modas já cobertas* (penalidade alta e gradiente forte) em vez de *cobrir novas modas* (penalidade baixa e gradiente fraco), produzindo *mode collapse*.