

**Instruções:** Responda às questões de múltipla escolha assinalando apenas uma alternativa. Nas questões dissertativas, apresente o raciocínio passo a passo, incluindo fórmulas e cálculos intermediários quando solicitado. Mantenha a notação utilizada em aula:  $p_X(x)$  para a densidade modelada,  $p_Z(z)$  para a distribuição base,  $f$  para a transformação inversível com parâmetros  $\theta$ , e  $J = \partial f / \partial z$  para a Jacobiana. Em camadas *coupling*,  $x^A$  é a metade copiada e  $x^B$  é a metade transformada. Questões marcadas com 🧠 são consideradas mais difíceis.

### Questões de Múltipla Escolha.

- I) Quatro funções  $f : \mathbb{R}^d \rightarrow \mathbb{R}^d$  são candidatas a compor uma camada de *normalizing flow*. Para que a camada permita treinar por máxima verossimilhança e amostrar pela inversa,  $f$  deve satisfazer simultaneamente um conjunto específico de propriedades. Qual conjunto abaixo é o mínimo necessário?
  - (a) Inversível, diferenciável, com Jacobiana cujo determinante seja eficiente de computar, e paramétrica.
  - (b) Linear por partes, contínua, com determinante igual a 1, e paramétrica.
  - (c) Estritamente convexa, suave, com Jacobiana ortogonal, e paramétrica.
  - (d) Inversível, monótona crescente em cada coordenada, com gradiente limitado, e linear.
- II) Considere uma camada *affine coupling* aplicada a  $x \in \mathbb{R}^6$  com partição  $x^A \in \mathbb{R}^3$  e  $x^B \in \mathbb{R}^3$ . A *coupling network* produziu, a partir de  $x^A$ , o vetor de log-escala  $s = (0.2, -0.5, 0.7)$ . Qual é o valor de  $\log |\det J|$  para essa camada?
  - (a) 1.4.
  - (b) 0.4.
  - (c)  $\approx 1.49$ .
  - (d)  $\approx 0.13$ .
- III) Você precisa de um modelo gerador que, para qualquer ponto  $x$  no espaço de dados, devolva o valor exato de  $\log p_X(x)$  (e não apenas um limite inferior ou um sinal de discriminador). Considerando as famílias VAE, GAN e *Normalizing Flow*, qual afirmação descreve corretamente o que cada uma oferece nesse aspecto?
  - (a) VAE fornece  $\log p_X(x)$  exato pelo *decoder*; GAN fornece um limite inferior; NF, apenas amostras.
  - (b) GAN fornece  $\log p_X(x)$  exato via discriminador; VAE fornece apenas amostras; NF, um limite inferior.
  - (c) NF fornece  $\log p_X(x)$  exato via mudança de variável; VAE fornece um limite inferior; GAN, apenas amostras.
  - (d) As três famílias fornecem  $\log p_X(x)$  exato, diferindo apenas na qualidade visual das amostras.
- IV) Em uma camada *affine coupling* aplicada a  $x = (x^A, x^B) = (2, 3)$ , a *coupling network* produz  $s(x^A) = -0.5$  e  $t(x^A) = 1.0$ . Aplicando a regra *forward*  $y^B = x^B \odot \exp(s) + t$ ,  $y^A = x^A$ , qual é o valor de  $y = (y^A, y^B)$ ? Use  $e^{-0.5} \approx 0.607$ .
  - (a)  $(2, 2.82)$ .

- (b) (2, 1.82).
- (c) (2, 5.95).
- (d) (2, 3.50).

V) Em uma camada *coupling*, a Jacobiana tem a forma por blocos

$$Df = \begin{bmatrix} \mathbf{I} & 0 \\ \frac{\partial \hat{f}}{\partial \mathbf{x}^A} & \frac{\partial \hat{f}}{\partial \mathbf{x}^B} \end{bmatrix}.$$

Qual conclusão sobre  $\det(Df)$  segue dessa estrutura?

- (a)  $\det(Df) = \det(\partial \hat{f} / \partial \mathbf{x}^A)$ , pois o bloco fora da diagonal domina.
- (b)  $\det(Df) = \det(\partial \hat{f} / \partial \mathbf{x}^B)$ , pois o determinante de uma matriz triangular por blocos é o produto dos determinantes dos blocos diagonais e  $\det(\mathbf{I}) = 1$ .
- (c)  $\det(Df) = \det(\partial \hat{f} / \partial \mathbf{x}^A) \cdot \det(\partial \hat{f} / \partial \mathbf{x}^B)$ .
- (d)  $\det(Df) = 1$ , pois o bloco superior é a identidade.

VI) A perda treinada por máxima verossimilhança num *flow* tem a forma

$$\mathcal{L}(\theta) = \sum_{i=1}^N \left[ \log \left| \det \frac{\partial f(z^{(i)}, \theta)}{\partial z^{(i)}} \right| - \log p_Z(z^{(i)}) \right],$$

onde  $p_Z$  é a distribuição base (gaussiana padrão) e  $z^{(i)} = f^{-1}(x^{(i)}, \theta)$ . Sobre os dois termos, qual afirmação é correta?

- (a) O termo  $\log |\det J|$  depende de  $\theta$ ; o termo  $-\log p_Z(z^{(i)})$  é constante em  $\theta$  e pode ser omitido do gradiente sem alterar o treino.
- (b) Ambos os termos dependem de  $\theta$ : o primeiro pela Jacobiana da rede e o segundo pelo ponto de avaliação  $z^{(i)} = f^{-1}(x^{(i)}, \theta)$ .
- (c) O termo  $-\log p_Z(z^{(i)})$  depende de  $\theta$  pela parametrização da média e variância da gaussiana base;  $\log |\det J|$  permanece constante.
- (d) Nenhum dos dois termos depende de  $\theta$ , pois ambos são avaliados em pontos  $z^{(i)}$  fixados antes do treinamento começar.

VII) Uma camada *affine coupling* produziu  $y = (y^A, y^B) = (1, 2.20)$  a partir da entrada  $x$ . A *coupling network* (reavaliada em  $x^A = y^A = 1$ ) devolve  $s = 0.3$  e  $t = -0.5$ . Use  $e^{-0.3} \approx 0.741$ . Qual é o valor recuperado de  $x^B$  pela inversa?

- (a) 2.00.
- (b) 1.26.
- (c) 3.64.
- (d) 1.63.

VIII) 🧠 Seja  $X \sim \mathcal{N}(0, 1)$  e  $Y = 2X + 3$ . Pela fórmula de mudança de variável, qual é o valor de  $p_Y(y)$  em  $y = 3$ ? Use  $1/\sqrt{2\pi} \approx 0.399$ .

- (a)  $\approx 0.399$ .

- (b)  $\approx 0.200$ .
- (c)  $\approx 0.798$ .
- (d)  $\approx 0.133$ .
- IX) Em um *Real NVP*, intercala-se **permutações** (ou *linear flows* estruturados) entre camadas *coupling* sucessivas. Qual é o motivo principal?
- (a) Reduzir o custo computacional do cálculo do determinante, que cresceria com a profundidade.
- (b) Forçar a Jacobiana global a ser ortogonal, o que zera o termo de log-determinante na perda.
- (c) Estabilizar o treino normalizando a magnitude dos vetores  $s$  e  $t$  produzidos pela *coupling network*.
- (d) Garantir que todas as dimensões da entrada sejam efetivamente transformadas ao longo da rede, e não apenas a metade  $x^B$  de uma única partição.
- X) Em um *linear flow*  $f(x) = \theta x + b$  com  $x \in \mathbb{R}^d$  e  $\theta$  densa, calcular  $\det(\theta)$  e  $\theta^{-1}$  a cada passo de treino custa  $O(d^3)$ . Estruturas como decomposição LU ou convoluções  $1 \times 1$  (Glow) são adotadas porque:
- (a) Aumentam a expressividade da camada, permitindo que ela modele relações não lineares entre as dimensões.
- (b) Garantem que o determinante seja sempre igual a 1, eliminando o termo  $\log |\det J|$  da perda.
- (c) Reduzem o custo de determinante e inversa para  $O(d)$  ou  $O(d^2)$ , mantendo a inversibilidade exigida pelo *flow*.
- (d) Eliminam a necessidade de uma distribuição base  $p_Z$ , pois a transformação fica isométrica.

### Gabarito - Objetivas

- I) a
- II) b
- III) c
- IV) a
- V) b
- VI) b
- VII) a
- VIII) b
- IX) d
- X) c

### Questões Dissertativas.

I) (**Derivação da NLL para flows**) Partindo do *framework* de máxima verossimilhança

$$\hat{\theta} = \arg \max_{\theta} \prod_{i=1}^N p_X(x^{(i)} | \theta),$$

derive a perda treinada em *normalizing flows* em três etapas explícitas:

- Transforme o  $\arg \max$  do produto em  $\arg \min$  de uma soma negativa de log-verossimilhanças. Justifique em uma frase a vantagem numérica dessa troca.
- Substitua  $p_X(x^{(i)} | \theta)$  usando a fórmula de mudança de variável  $p_X(x) = p_Z(z) |\partial f / \partial z|^{-1}$ , com  $z = f^{-1}(x, \theta)$ .
- Apresente a forma final como soma de dois termos, explicando como cada um deles depende de  $\theta$ . Comente o papel intuitivo do termo  $\log |\det J|$  (qual comportamento da rede ele penaliza).

II) (**Camada *affine coupling* em 4D**) Considere  $x = (x_1, x_2, x_3, x_4) = (0.5, 1.0, -1.0, 2.0)$ , com  $x^A = (x_1, x_2)$  e  $x^B = (x_3, x_4)$ . A *coupling network* produz, a partir de  $x^A$ , os vetores  $s = (0.1, -0.2)$  e  $t = (0.3, -0.4)$ .

- Calcule o *forward pass*  $y = f(x)$  usando  $y^B = x^B \odot \exp(s) + t$  e  $y^A = x^A$ . Use  $e^{0.1} \approx 1.105$  e  $e^{-0.2} \approx 0.819$ .
- Calcule  $\log |\det J|$  para essa camada. Mostre que o resultado depende apenas de  $s$ .
- Recupere  $x^B$  aplicando a inversa  $x^B = (y^B - t) \odot \exp(-s)$ . Confirme que os valores originais  $(-1.0, 2.0)$  são reconstruídos.
- 🧠 Suponha que a *coupling network* fosse uma rede neural arbitrária, possivelmente não inversível (por exemplo, com camadas ReLU que descartam informação). Explique por que isso **não** compromete a inversibilidade da camada *coupling* como um todo. Em que sentido o "preço" da inversibilidade global recai apenas sobre a função elemento a elemento  $\hat{f}$ , e não sobre a sub-rede que produz  $(s, t)$ ?

III) (**NF, VAE e GAN no trilema**) Considere três eixos para avaliar uma família de modelos geradores: (i) *avaliação* de  $p_X(x)$  para um ponto dado, (ii) custo computacional de *amostragem*, (iii) *qualidade visual* típica em datasets de imagens naturais. Para cada um dos três modelos abaixo, indique em que ponto do espaço (eixos i, ii, iii) ele se posiciona e justifique a partir do mecanismo de treino e da arquitetura:

- GAN.
- VAE.
- Normalizing Flow*.

Conclua identificando qual canto do trilema é ocupado pelos NFs e cite uma aplicação prática em que esse canto é preferível ao dos GANs ou modelos difusores.

IV) 🧠 (**Mudança de variável 1D**) Seja  $X \sim \mathcal{N}(0, 1)$  e defina  $Z = \exp(X)$ . O objetivo é derivar a densidade  $p_Z(z)$ .

- Escreva  $p_X(x)$  explicitamente.

- (b) Determine a função inversa  $x = f^{-1}(z)$  e calcule  $|dx/dz|$ .
- (c) Aplique a fórmula  $p_Z(z) = p_X(f^{-1}(z)) |dx/dz|$  e escreva  $p_Z(z)$  em forma fechada. Indique o suporte ( $z > 0$ ) e o nome dessa distribuição.
- (d) Calcule numericamente  $p_Z(z = 1)$ . Use  $1/\sqrt{2\pi} \approx 0.399$ .

## Gabarito

### Múltipla Escolha.

- I) (a) As quatro propriedades essenciais discutidas em aula são: paramétrica (para haver o que aprender), inversível (para suportar amostragem e avaliação), diferenciável (para *backprop*) e Jacobiana com determinante eficiente (para tornar a NLL tratável). A alternativa (b) impõe  $\det = 1$ , perdendo a deformação de volume que é justamente o que carrega a densidade. (c) e (d) acrescentam restrições gratuitas (ortogonalidade, monotonicidade coordenada a coordenada, linearidade) que limitam fortemente a expressividade.
- II) (b) Para *affine coupling*,  $\log |\det J| = \sum_i s_i = 0.2 + (-0.5) + 0.7 = 0.4$ . A alternativa (a) seria  $\sum_i |s_i| = 1.4$ , um erro comum de quem aplica módulo a cada  $s_i$ . A (c) corresponde a  $\prod_i \exp(s_i) \approx \exp(0.4) \approx 1.49$ , ou seja, devolve  $|\det J|$  em vez de seu log. A (d) é a média dos  $s_i$ .
- III) (c) *Normalizing flows* fornecem  $\log p_X(x)$  exato porque a mudança de variável devolve uma fórmula fechada em função de  $p_Z(z)$  e do log-determinante. VAEs maximizam o ELBO, que é apenas um limite inferior de  $\log p_X(x)$ , não o valor exato. GANs treinam por jogo entre gerador e discriminador e não dão acesso a uma densidade.
- IV) (a)  $y^A = x^A = 2$ .  $y^B = 3 \cdot e^{-0.5} + 1 \approx 3 \cdot 0.607 + 1 = 1.82 + 1 = 2.82$ . A (b) esquece o termo  $+t$  ( $3 \cdot 0.607 \approx 1.82$ ). A (c) usa  $\exp(+0.5) \approx 1.649$  no lugar de  $\exp(-0.5)$ , dando  $3 \cdot 1.649 + 1 \approx 5.95$ . A (d) aplica  $x^B + s + t = 3 - 0.5 + 1 = 3.5$ , somando em vez de escalar por  $\exp(s)$ .
- V) (b) Para uma matriz triangular inferior por blocos  $\begin{bmatrix} A & 0 \\ C & D \end{bmatrix}$ , o determinante é  $\det(A) \det(D)$ . Como o bloco superior é  $I$  (com  $\det = 1$ ), sobra  $\det(\partial \hat{f} / \partial x^B)$ . O bloco fora da diagonal  $\partial \hat{f} / \partial x^A$  é exatamente o que *não importa* para o determinante. As alternativas (a) e (c) trocam essa propriedade.
- VI) (b) Ambos os termos recebem gradiente. O  $\log |\det J|$  depende de  $\theta$  diretamente, pela Jacobiana da rede, e penaliza camadas que contraem volume de forma exagerada para "trapacear"empurrando toda a massa para uma região pequena. O termo  $-\log p_Z(z)$  tem forma fechada fixa (gaussiana padrão), mas o ponto de avaliação  $z^{(i)} = f^{-1}(x^{(i)}, \theta)$  se move quando  $\theta$  muda; é esse termo que puxa os latentes para a região de alta densidade da base. A (a) é o erro clássico: se o termo da base fosse omitido do gradiente, a rede minimizaria a perda apenas contraindo volume, sem ajustar a distribuição aos dados. A (c) inverte os papéis, a base é fixa e a Jacobiana não é constante. A (d) é falsa,  $z^{(i)}$  é recalculado a cada passo de treino.
- VII) (a)  $x^B = (y^B - t) \cdot e^{-s} = (2.20 - (-0.5)) \cdot e^{-0.3} = 2.70 \cdot 0.741 \approx 2.00$ . A (b) usa  $(y^B - 0.5) \cdot 0.741 = 1.70 \cdot 0.741 \approx 1.26$ , esquecendo que  $t = -0.5$  e portanto  $y^B - t = y^B + 0.5$ . A (c) aplica  $e^{+s}$  em vez de  $e^{-s}$ , dando  $2.70 \cdot 1.350 \approx 3.64$ . A (d) usa  $y^B \cdot e^{-s} = 2.20 \cdot 0.741 \approx 1.63$ , omitindo  $t$  por completo.

- VIII) (b)  $Y = aX + b$  com  $a = 2$ ,  $b = 3$  é a transformação afim padrão. Pela mudança de variável,  $p_Y(y) = p_X((y-b)/a) \cdot |1/a|$ . Em  $y = 3$ ,  $(y-b)/a = 0$ , então  $p_X(0) = 1/\sqrt{2\pi} \approx 0.399$ . Multiplicando por  $|1/a| = 1/2$ ,  $p_Y(3) \approx 0.200$ . A (a) esquece o fator Jacobiano  $1/|a|$  e devolve  $p_X(0)$  direto. A (c) multiplica por  $|a| = 2$  no lugar de dividir, obtendo  $\approx 0.798$ . A (d) divide por  $|a + b| = 3$  no lugar de  $|a|$ , confundindo a estrutura da fórmula.
- IX) (d) Uma única camada *coupling* mantém  $x^A$  idêntico, então nada acontece com essas dimensões. Alternar permutações entre camadas faz com que diferentes subconjuntos de coordenadas alternem entre o papel de "A"(copiadas) e "B"(transformadas), garantindo que toda dimensão seja eventualmente afetada. As demais alternativas descrevem efeitos que não correspondem ao papel da permutação.
- X) (c) A inversibilidade é uma exigência da família *flow*, então estruturas como LU ou convoluções  $1 \times 1$  não a comprometem. O ganho é puramente computacional: matrizes estruturadas têm determinante e inversa em tempo subcúbico (LU custa  $O(d)$  no determinante depois de fatorada;  $1 \times 1$  convolução tem custo proporcional ao número de canais). A (a) é falsa, transformações lineares continuam lineares mesmo estruturadas. A (b) zera o termo da NLL e perde expressividade. A (d) confunde com mapas isométricos.

### Dissertativas.

- I) (a) Tomando o logaritmo e trocando o sinal,  $\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^N [-\log p_X(x^{(i)} | \theta)]$ . A vantagem é numérica: o produto de  $N$  probabilidades pequenas sofre *underflow* rapidamente em ponto flutuante; somar logaritmos é estável e produz gradientes bem condicionados.
- (b) Pela mudança de variável,  $p_X(x) = p_Z(f^{-1}(x, \theta)) |\partial f / \partial z|^{-1}$ . Aplicando  $-\log$ , obtém-se  $-\log p_X(x) = -\log p_Z(z) + \log |\partial f / \partial z|$ , com  $z = f^{-1}(x, \theta)$ .

(c) Soma final:

$$\mathcal{L}(\theta) = \sum_{i=1}^N \left[ \log \left| \frac{\partial f(z^{(i)}, \theta)}{\partial z^{(i)}} \right| - \log p_Z(z^{(i)}) \right].$$

O termo  $\log |\det J|$  depende de  $\theta$  diretamente (via a Jacobiana da rede  $f$ ) e penaliza configurações que comprimem volume excessivamente, que de outra forma deixariam a verossimilhança artificialmente alta. O termo  $-\log p_Z(z)$  tem densidade em forma fechada e fixa (gaussiana padrão, em geral), mas também depende de  $\theta$ , através do ponto de avaliação  $z = f^{-1}(x, \theta)$ ; é ele que puxa os latentes para a região de alta densidade da base.

- II) (a)  $y^A = (0.5, 1.0)$ . Para  $y^B$ :  $y_3 = x_3 \cdot e^{s_1} + t_1 = (-1.0)(1.105) + 0.3 = -1.105 + 0.3 = -0.805$ .  $y_4 = x_4 \cdot e^{s_2} + t_2 = (2.0)(0.819) + (-0.4) = 1.638 - 0.4 = 1.238$ . Logo  $y \approx (0.5, 1.0, -0.805, 1.238)$ .
- (b)  $\log |\det J| = \sum_i s_i = 0.1 + (-0.2) = -0.1$ . Como a Jacobiana é triangular por blocos com bloco superior I e bloco inferior-direito diagonal  $\text{diag}(e^{s_1}, e^{s_2})$ , o determinante é  $\prod_i e^{s_i}$  e seu log é  $\sum_i s_i$ . Os elementos do bloco inferior-esquerdo (derivadas de  $\hat{f}$  em  $x^A$  via  $s$  e  $t$ ) não aparecem.
- (c)  $x_3 = (y_3 - t_1) \cdot e^{-s_1} = (-0.805 - 0.3) \cdot e^{-0.1} = (-1.105)(0.905) \approx -1.000$ .  $x_4 = (y_4 - t_2) \cdot e^{-s_2} = (1.238 - (-0.4)) \cdot e^{0.2} = (1.638)(1.221) \approx 2.000$ . Os valores originais são reconstruídos, confirmando que a inversa é exata.

- (d) A inversibilidade da camada *coupling* depende de duas coisas:  $x^A$  ser copiada para  $y^A$  (portanto recuperável trivialmente) e  $\hat{f}(\cdot | \theta(x^A))$  ser inversível como função de  $x^B$  **dado**  $\theta(x^A)$ . A sub-rede que produz  $(s, t)$  a partir de  $x^A$  *nunca é invertida*, ela é apenas reavaliada na passagem inversa (note que  $x^A = y^A$  está disponível em ambas as direções). Assim, o "preço" da inversibilidade global recai apenas sobre a forma fechada de  $\hat{f}$  (no caso afim, exponencial mais translação, trivialmente inversível), e a *coupling network* pode ser qualquer MLP/CNN com ReLU, *batch norm*, etc.
- III) (a) **GAN**: (i) avaliação inviável (não há densidade explícita, apenas um discriminador que aproxima razões de probabilidades); (ii) amostragem rápida (uma passagem pelo gerador); (iii) qualidade visual historicamente alta em imagens naturais, ao custo de *mode collapse* e cobertura ruim da distribuição.
- (b) **VAE**: (i) avaliação aproximada via ELBO (limite inferior de  $\log p_X(x)$ , não o valor exato); (ii) amostragem rápida (uma passagem pelo *decoder*); (iii) qualidade visual em geral inferior à de GANs e modelos difusores, com tendência a amostras borradas devido à perda de reconstrução pixel a pixel.
- (c) **Normalizing Flow**: (i) avaliação exata de  $\log p_X(x)$  pela fórmula de mudança de variável; (ii) amostragem rápida (uma passagem direta pelo *flow*); (iii) qualidade visual inferior a GANs e modelos difusores em *datasets* grandes como ImageNet/FFHQ, em parte pela restrição arquitetural (inversibilidade) que limita a expressividade por parâmetro.

Conclusão: NFs ocupam o canto *velocidade + cobertura* (com avaliação exata) do trilema. Aplicações em que esse canto é preferível: detecção de anomalias (precisamos de  $\log p_X(x)$  para definir limiar), inferência variacional (substituir  $q(z | x)$  por uma distribuição expressiva e ainda tratável), física computacional e *Boltzmann generators* (amostragem em equilíbrio com densidade exata para reponderação).

- IV) (a)  $p_X(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$ .
- (b) Como  $z = \exp(x)$ , então  $x = \ln(z)$ , definido para  $z > 0$ . A derivada é  $dx/dz = 1/z$ , e como  $z > 0$ ,  $|dx/dz| = 1/z$ .
- (c) Aplicando a fórmula:

$$p_Z(z) = p_X(\ln z) \cdot \frac{1}{z} = \frac{1}{z\sqrt{2\pi}} \exp\left(-\frac{(\ln z)^2}{2}\right), \quad z > 0.$$

Essa é a distribuição **log-normal** (com parâmetros  $\mu = 0$ ,  $\sigma = 1$ ).

- (d) Em  $z = 1$ :  $\ln(1) = 0$ , então  $\exp(-0/2) = 1$  e  $p_Z(1) = (1/1) \cdot (1/\sqrt{2\pi}) \cdot 1 \approx 0.399$ .