

Instruções: Responda às questões de múltipla escolha assinalando apenas uma alternativa. Nas questões dissertativas, apresente o raciocínio passo a passo, incluindo fórmulas e cálculos intermediários quando solicitado. Mantenha a notação utilizada em aula: $p_X(x)$ para a densidade modelada, $p_Z(z)$ para a distribuição base, f para a transformação inversível com parâmetros θ , e $J = \partial f / \partial z$ para a Jacobiana. Em camadas *coupling*, x^A é a metade copiada e x^B é a metade transformada. Questões marcadas com 🧠 são consideradas mais difíceis.

Questões de Múltipla Escolha.

- I) Quatro funções $f : \mathbb{R}^d \rightarrow \mathbb{R}^d$ são candidatas a compor uma camada de *normalizing flow*. Para que a camada permita treinar por máxima verossimilhança e amostrar pela inversa, f deve satisfazer simultaneamente um conjunto específico de propriedades. Qual conjunto abaixo é o mínimo necessário?
 - (a) Inversível, diferenciável, com Jacobiana cujo determinante seja eficiente de computar, e paramétrica.
 - (b) Linear por partes, contínua, com determinante igual a 1, e paramétrica.
 - (c) Estritamente convexa, suave, com Jacobiana ortogonal, e paramétrica.
 - (d) Inversível, monótona crescente em cada coordenada, com gradiente limitado, e linear.
- II) Considere uma camada *affine coupling* aplicada a $x \in \mathbb{R}^6$ com partição $x^A \in \mathbb{R}^3$ e $x^B \in \mathbb{R}^3$. A *coupling network* produziu, a partir de x^A , o vetor de log-escala $s = (0,2, -0,5, 0,7)$. Qual é o valor de $\log |\det J|$ para essa camada?
 - (a) 1,4.
 - (b) 0,4.
 - (c) 0,97.
 - (d) -0,1.
- III) Você precisa de um modelo gerador que, para qualquer ponto x no espaço de dados, devolva o valor exato de $\log p_X(x)$ (e não apenas um limite inferior ou um sinal de discriminador). Considerando as famílias VAE, GAN e *Normalizing Flow*, qual afirmação descreve corretamente o que cada uma oferece nesse aspecto?
 - (a) VAE fornece $\log p_X(x)$ exato; GAN e NF fornecem apenas amostras.
 - (b) GAN fornece $\log p_X(x)$ exato via discriminador; VAE e NF fornecem apenas limites.
 - (c) NF fornece $\log p_X(x)$ exato via mudança de variável; VAE fornece o ELBO (limite inferior); GAN não fornece densidade.
 - (d) As três famílias fornecem $\log p_X(x)$ exato, diferindo apenas em qualidade visual.
- IV) Em uma camada *affine coupling* aplicada a $x = (x^A, x^B) = (2, 3)$, a *coupling network* produz $s(x^A) = -0,5$ e $t(x^A) = 1,0$. Aplicando a regra *forward* $y^B = x^B \odot \exp(s) + t$, $y^A = x^A$, qual é o valor de $y = (y^A, y^B)$? Use $e^{-0,5} \approx 0,607$.
 - (a) (2, 2,82).
 - (b) (2, 1,82).

(c) (2, 5,95).

(d) (2, 3,50).

V) Em uma camada *coupling*, a Jacobiana tem a forma por blocos

$$Df = \begin{bmatrix} I & 0 \\ \frac{\partial \hat{f}}{\partial x^A} & \frac{\partial \hat{f}}{\partial x^B} \end{bmatrix}.$$

Qual conclusão sobre $\det(Df)$ segue dessa estrutura?

(a) $\det(Df) = \det(\partial \hat{f} / \partial x^A)$, pois o bloco fora da diagonal domina.

(b) $\det(Df) = \det(\partial \hat{f} / \partial x^B)$, pois o determinante de uma matriz triangular por blocos é o produto dos determinantes dos blocos diagonais e $\det(I) = 1$.

(c) $\det(Df) = \det(\partial \hat{f} / \partial x^A) \cdot \det(\partial \hat{f} / \partial x^B)$.

(d) $\det(Df) = 1$, pois o bloco superior é a identidade.

VI) A perda treinada por máxima verossimilhança num *flow* tem a forma

$$\mathcal{L}(\theta) = \sum_{i=1}^N \left[\log \left| \det \frac{\partial f(z^{(i)}, \theta)}{\partial z^{(i)}} \right| - \log p_Z(z^{(i)}) \right],$$

onde p_Z é a distribuição base (gaussiana padrão). Sobre os dois termos, qual afirmação é correta?

(a) Ambos dependem de θ e são otimizados conjuntamente em cada passo de *backprop*.

(b) O termo $\log |\det J|$ depende de θ , enquanto $-\log p_Z(z^{(i)})$ depende apenas da distribuição base e é tratável em forma fechada.

(c) O termo $-\log p_Z(z^{(i)})$ depende de θ via a parametrização da gaussiana base; $\log |\det J|$ é constante.

(d) Nenhum dos dois depende de θ , pois ambos envolvem apenas a distribuição base e seus pontos.

VII) Uma camada *affine coupling* produziu $y = (y^A, y^B) = (1, 2, 20)$ a partir da entrada x . A *coupling network* (reavaliada em $x^A = y^A = 1$) devolve $s = 0,3$ e $t = -0,5$. Use $e^{-0,3} \approx 0,741$. Qual é o valor recuperado de x^B pela inversa?

(a) 2,00.

(b) 1,26.

(c) 3,64.

(d) 1,63.

VIII) 🦋 Seja $X \sim \mathcal{N}(0, 1)$ e $Y = 2X + 3$. Pela fórmula de mudança de variável, qual é o valor de $p_Y(y)$ em $y = 3$? Use $1/\sqrt{2\pi} \approx 0,399$.

(a) $\approx 0,399$.

(b) $\approx 0,200$.

(c) $\approx 0,798$.

(d) $\approx 0,133$.

- IX) Em um *Real NVP*, intercala-se **permutações** (ou *linear flows* estruturados) entre camadas *coupling* sucessivas. Qual é o motivo principal?
- (a) Reduzir o custo computacional do cálculo do determinante, que cresceria com a profundidade.
 - (b) Garantir que todas as dimensões da entrada sejam efetivamente transformadas ao longo da rede, e não apenas a metade x^B de uma única partição.
 - (c) Estabilizar o treino normalizando a magnitude dos vetores s e t produzidos pela *coupling network*.
 - (d) Forçar a Jacobiana global a ser ortogonal, o que zera o termo de log-determinante na perda.
- X) Em um *linear flow* $f(x) = \theta x + b$ com $x \in \mathbb{R}^d$ e θ densa, calcular $\det(\theta)$ e θ^{-1} a cada passo de treino custa $O(d^3)$. Estruturas como decomposição LU ou convoluções 1×1 (Glow) são adotadas porque:
- (a) Aumentam a expressividade da camada, permitindo que ela modele relações não lineares entre as dimensões.
 - (b) Reduzem o custo de determinante e inversa para $O(d)$ ou $O(d^2)$, mantendo a inversibilidade exigida pelo *flow*.
 - (c) Garantem que o determinante seja sempre igual a 1, eliminando o termo $\log |\det J|$ da perda.
 - (d) Eliminam a necessidade de uma distribuição base p_Z , pois a transformação fica isométrica.

Gabarito - Objetivas

- I) a
- II) b
- III) c
- IV) a
- V) b
- VI) b
- VII) a
- VIII) b
- IX) b
- X) b

Questões Dissertativas.

I) (**Derivação da NLL para flows**) Partindo do *framework* de máxima verossimilhança

$$\hat{\theta} = \arg \max_{\theta} \prod_{i=1}^N p_X(x^{(i)} | \theta),$$

derive a perda treinada em *normalizing flows* em três etapas explícitas:

- Transforme o $\arg \max$ do produto em $\arg \min$ de uma soma negativa de log-verossimilhanças. Justifique em uma frase a vantagem numérica dessa troca.
- Substitua $p_X(x^{(i)} | \theta)$ usando a fórmula de mudança de variável $p_X(x) = p_Z(z) |\partial f / \partial z|^{-1}$, com $z = f^{-1}(x)$.
- Apresente a forma final como soma de dois termos, identificando qual depende de θ e qual depende apenas de p_Z . Comente o papel intuitivo do termo $\log |\det J|$ (qual comportamento da rede ele penaliza).

II) (**Camada affine coupling em 4D**) Considere $x = (x_1, x_2, x_3, x_4) = (0,5, 1,0, -1,0, 2,0)$, com $x^A = (x_1, x_2)$ e $x^B = (x_3, x_4)$. A *coupling network* produz, a partir de x^A , os vetores $s = (0,1, -0,2)$ e $t = (0,3, -0,4)$.

- Calcule o *forward pass* $y = f(x)$ usando $y^B = x^B \odot \exp(s) + t$ e $y^A = x^A$. Use $e^{0,1} \approx 1,105$ e $e^{-0,2} \approx 0,819$.
- Calcule $\log |\det J|$ para essa camada. Mostre que o resultado depende apenas de s .
- Recupere x^B aplicando a inversa $x^B = (y^B - t) \odot \exp(-s)$. Confirme que os valores originais $(-1,0, 2,0)$ são reconstruídos.
- 🧠 Suponha que a *coupling network* fosse uma rede neural arbitrária, possivelmente não inversível (por exemplo, com camadas ReLU que descartam informação). Explique por que isso **não** compromete a inversibilidade da camada *coupling* como um todo. Em que sentido o "preço" da inversibilidade global recai apenas sobre a função elemento a elemento $\hat{f}$, e não sobre a sub-rede que produz (s, t) ?

III) (**NF, VAE e GAN no trilema**) Considere três eixos para avaliar uma família de modelos geradores: (i) *avaliação* de $p_X(x)$ para um ponto dado, (ii) custo computacional de *amostragem*, (iii) *qualidade visual* típica em datasets de imagens naturais. Para cada um dos três modelos abaixo, indique em que ponto do espaço (eixos i, ii, iii) ele se posiciona e justifique a partir do mecanismo de treino e da arquitetura:

- GAN.
- VAE.
- Normalizing Flow*.

Conclua identificando qual canto do trilema é ocupado pelos NFs e cite uma aplicação prática em que esse canto é preferível ao dos GANs ou modelos difusores.

IV) 🧠 (**Mudança de variável 1D**) Seja $X \sim \mathcal{N}(0, 1)$ e defina $Z = \exp(X)$. O objetivo é derivar a densidade $p_Z(z)$.

- Escreva $p_X(x)$ explicitamente.

- (b) Determine a função inversa $x = f^{-1}(z)$ e calcule $|dx/dz|$.
- (c) Aplique a fórmula $p_Z(z) = p_X(f^{-1}(z)) |dx/dz|$ e escreva $p_Z(z)$ em forma fechada. Indique o suporte ($z > 0$) e o nome dessa distribuição.
- (d) Calcule numericamente $p_Z(z = 1)$. Use $1/\sqrt{2\pi} \approx 0,399$.

Gabarito

Múltipla Escolha.

- I) (a) As quatro propriedades essenciais discutidas em aula são: paramétrica (para haver o que aprender), inversível (para suportar amostragem e avaliação), diferenciável (para *backprop*) e Jacobiana com determinante eficiente (para tornar a NLL tratável). A alternativa (b) impõe $\det = 1$, perdendo a deformação de volume que é justamente o que carrega a densidade. (c) e (d) acrescentam restrições gratuitas (ortogonalidade, monotonicidade coordenada a coordenada, linearidade) que limitam fortemente a expressividade.
- II) (b) Para *affine coupling*, $\log |\det J| = \sum_i s_i = 0,2 + (-0,5) + 0,7 = 0,4$. A alternativa (a) seria $\sum_i |s_i| = 1,4$, um erro comum de quem aplica módulo a cada s_i . A (c) corresponde a $\prod_i \exp(s_i) \approx \exp(0,4) \approx 1,49$, ou seja, devolve $|\det J|$ em vez de seu log. A (d) é a média dos s_i .
- III) (c) *Normalizing flows* fornecem $\log p_X(x)$ exato porque a mudança de variável devolve uma fórmula fechada em função de $p_Z(z)$ e do log-determinante. VAEs maximizam o ELBO, que é apenas um limite inferior de $\log p_X(x)$, não o valor exato. GANs treinam por jogo entre gerador e discriminador e não dão acesso a uma densidade.
- IV) (a) $y^A = x^A = 2$. $y^B = 3 \cdot e^{-0,5} + 1 \approx 3 \cdot 0,607 + 1 = 1,82 + 1 = 2,82$. A (b) esquece o termo $+t$ ($3 \cdot 0,607 \approx 1,82$). A (c) usa $\exp(+0,5) \approx 1,649$ no lugar de $\exp(-0,5)$, dando $3 \cdot 1,649 + 1 \approx 5,95$. A (d) aplica $x^B + s + t = 3 - 0,5 + 1 = 3,5$, somando em vez de escalar por $\exp(s)$.
- V) (b) Para uma matriz triangular inferior por blocos $\begin{bmatrix} A & 0 \\ C & D \end{bmatrix}$, o determinante é $\det(A) \det(D)$. Como o bloco superior é I (com $\det = 1$), sobra $\det(\partial \hat{f} / \partial x^B)$. O bloco fora da diagonal $\partial \hat{f} / \partial x^A$ é exatamente o que *não importa* para o determinante. As alternativas (a) e (c) trocam essa propriedade.
- VI) (b) Como p_Z é fixa (gaussiana padrão), $-\log p_Z(z)$ envolve apenas a norma de $z = f^{-1}(x; \theta)$ e a constante de normalização da gaussiana. O termo $\log |\det J|$ depende de θ via a rede f e é o que penaliza camadas que contraem volume de forma exagerada para "trapacear" empurrando toda a massa para uma região pequena.
- VII) (a) $x^B = (y^B - t) \cdot e^{-s} = (2,20 - (-0,5)) \cdot e^{-0,3} = 2,70 \cdot 0,741 \approx 2,00$. A (b) usa $(y^B - 0,5) \cdot 0,741 = 1,70 \cdot 0,741 \approx 1,26$, esquecendo que $t = -0,5$ e portanto $y^B - t = y^B + 0,5$. A (c) aplica e^{+s} em vez de e^{-s} , dando $2,70 \cdot 1,350 \approx 3,64$. A (d) usa $y^B \cdot e^{-s} = 2,20 \cdot 0,741 \approx 1,63$, omitindo t por completo.
- VIII) (b) $Y = aX + b$ com $a = 2$, $b = 3$ é a transformação afim padrão. Pela mudança de variável, $p_Y(y) = p_X((y-b)/a) \cdot |1/a|$. Em $y = 3$, $(y-b)/a = 0$, então $p_X(0) = 1/\sqrt{2\pi} \approx 0,399$. Multiplicando por $|1/a| = 1/2$, $p_Y(3) \approx 0,200$. A (a) esquece o fator Jacobiano $1/|a|$ e devolve $p_X(0)$ direto. A (c) multiplica por $|a| = 2$ no lugar de dividir, obtendo $\approx 0,798$. A (d) divide por $|a + b| = 3$ no lugar de $|a|$, confundindo a estrutura da fórmula.

- IX) (b) Uma única camada *coupling* mantém x^A idêntico, então nada acontece com essas dimensões. Alternar permutações entre camadas faz com que diferentes subconjuntos de coordenadas alternem entre o papel de "A" (copiadas) e "B" (transformadas), garantindo que toda dimensão seja eventualmente afetada. As demais alternativas descrevem efeitos que não correspondem ao papel da permutação.
- X) (b) A inversibilidade é uma exigência da família *flow*, então estruturas como LU ou convoluções 1×1 não a comprometem. O ganho é puramente computacional: matrizes estruturadas têm determinante e inversa em tempo subcúbico (LU custa $\mathcal{O}(d)$ no determinante depois de fatorada; 1×1 convolução tem custo proporcional ao número de canais). A (a) é falsa, transformações lineares continuam lineares mesmo estruturadas. A (c) zera o termo da NLL e perde expressividade. A (d) confunde com mapas isométricos.

Dissertativas.

- I) (a) Tomando o logaritmo e trocando o sinal, $\hat{\theta} = \arg \min_{\theta} \sum_{i=1}^N [-\log p_X(x^{(i)} | \theta)]$. A vantagem é numérica: o produto de N probabilidades pequenas *underflow*-a rapidamente em ponto flutuante; somar logaritmos é estável e produz gradientes bem condicionados.
- (b) Pela mudança de variável, $p_X(x) = p_Z(f^{-1}(x)) |\partial f / \partial z|^{-1}$. Aplicando $-\log$, obtém-se $-\log p_X(x) = -\log p_Z(z) + \log |\partial f / \partial z|$, com $z = f^{-1}(x)$.
- (c) Soma final:

$$\mathcal{L}(\theta) = \sum_{i=1}^N \left[\log \left| \frac{\partial f(z^{(i)}, \theta)}{\partial z^{(i)}} \right| - \log p_Z(z^{(i)}) \right].$$

O termo $\log |\det J|$ depende de θ (via a rede f) e penaliza configurações que comprimem volume excessivamente, que de outra forma deixariam a verossimilhança artificialmente alta. O termo $-\log p_Z(z)$ depende apenas da distribuição base (gaussiana padrão, em geral), ficando em forma fechada e computável a partir de $z = f^{-1}(x)$.

- II) (a) $y^A = (0,5, 1,0)$. Para y^B : $y_3 = x_3 \cdot e^{s_1} + t_1 = (-1,0)(1,105) + 0,3 = -1,105 + 0,3 = -0,805$. $y_4 = x_4 \cdot e^{s_2} + t_2 = (2,0)(0,819) + (-0,4) = 1,638 - 0,4 = 1,238$. Logo $y \approx (0,5, 1,0, -0,805, 1,238)$.
- (b) $\log |\det J| = \sum_i s_i = 0,1 + (-0,2) = -0,1$. Como a Jacobiana é triangular por blocos com bloco superior I e bloco inferior-direito diagonal $\text{diag}(e^{s_1}, e^{s_2})$, o determinante é $\prod_i e^{s_i}$ e seu log é $\sum_i s_i$. Os elementos do bloco inferior-esquerdo (derivadas de $\hat{f}$ em x^A via s e t) não aparecem.
- (c) $x_3 = (y_3 - t_1) \cdot e^{-s_1} = (-0,805 - 0,3) \cdot e^{-0,1} = (-1,105)(0,905) \approx -1,000$. $x_4 = (y_4 - t_2) \cdot e^{-s_2} = (1,238 - (-0,4)) \cdot e^{0,2} = (1,638)(1,221) \approx 2,000$. Os valores originais são reconstruídos, confirmando que a inversa é exata.
- (d) A inversibilidade da camada *coupling* depende de duas coisas: x^A ser copiada para y^A (portanto recuperável trivialmente) e $\hat{f}(\cdot | \theta(x^A))$ ser inversível como função de x^B **dado** $\theta(x^A)$. A sub-rede que produz (s, t) a partir de x^A *nunca é invertida*, ela é apenas reavaliada na passagem inversa (note que $x^A = y^A$ está disponível em ambas as direções). Assim, o "preço" da inversibilidade global recai apenas sobre a forma fechada de $\hat{f}$ (no caso afim, exponencial mais translação, trivialmente inversível), e a *coupling network* pode ser qualquer MLP/CNN com ReLU, *batch norm*, etc.

- III) (a) **GAN**: (i) avaliação inviável (não há densidade explícita, apenas um discriminador que aproxima razões de probabilidades); (ii) amostragem rápida (uma passagem pelo gerador); (iii) qualidade visual historicamente alta em imagens naturais, ao custo de *mode collapse* e cobertura ruim da distribuição.
- (b) **VAE**: (i) avaliação aproximada via ELBO (limite inferior de $\log p_X(x)$, não o valor exato); (ii) amostragem rápida (uma passagem pelo *decoder*); (iii) qualidade visual em geral inferior à de GANs e modelos difusores, com tendência a amostras borradas devido à perda de reconstrução pixel a pixel.
- (c) **Normalizing Flow**: (i) avaliação exata de $\log p_X(x)$ pela fórmula de mudança de variável; (ii) amostragem rápida (uma passagem direta pelo *flow*); (iii) qualidade visual inferior a GANs e modelos difusores em *datasets* grandes como ImageNet/FFHQ, em parte pela restrição arquitetural (inversibilidade) que limita a expressividade por parâmetro.

Conclusão: NFs ocupam o canto *velocidade + cobertura* (com avaliação exata) do trilema. Aplicações em que esse canto é preferível: detecção de anomalias (precisamos de $\log p_X(x)$ para definir limiar), inferência variacional (substituir $q(z | x)$ por uma distribuição expressiva e ainda tratável), física computacional e *Boltzmann generators* (amostragem em equilíbrio com densidade exata para reponderação).

IV) (a) $p_X(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right).$

- (b) Como $z = \exp(x)$, então $x = \ln(z)$, definido para $z > 0$. A derivada é $dx/dz = 1/z$, e como $z > 0$, $|dx/dz| = 1/z$.

- (c) Aplicando a fórmula:

$$p_Z(z) = p_X(\ln z) \cdot \frac{1}{z} = \frac{1}{z\sqrt{2\pi}} \exp\left(-\frac{(\ln z)^2}{2}\right), \quad z > 0.$$

Essa é a distribuição **log-normal** (com parâmetros $\mu = 0$, $\sigma = 1$).

- (d) Em $z = 1$: $\ln(1) = 0$, então $\exp(-0/2) = 1$ e $p_Z(1) = (1/1) \cdot (1/\sqrt{2\pi}) \cdot 1 \approx 0,399$.