

**Instruções:** Responda às questões de múltipla escolha assinalando apenas uma alternativa. Nas questões dissertativas, apresente o raciocínio passo a passo, incluindo fórmulas e cálculos intermediários quando solicitado. Mantenha a notação  $f$  para o *encoder*,  $g$  para o *decoder*,  $\theta$  e  $\phi$  para os parâmetros,  $q(z | x, \phi)$  para o posterior aproximado e  $p(z) = \mathcal{N}(0, I)$  para o *prior*, conforme apresentadas em aula. Questões marcadas com 🧠 são consideradas difíceis.

### Questões de Múltipla Escolha.

- I) Um pesquisador treina um *autoencoder* sobre imagens  $28 \times 28$  (entrada com 784 *features*) e observa erro de reconstrução próximo de zero, mas as representações latentes não capturam estrutura semântica útil. Ao inspecionar a arquitetura, ele percebe que o vetor latente possui dimensão 1024 e que todas as camadas usam ativações lineares. Qual é a causa mais provável do problema?
- a) A função de perda escolhida não é compatível com imagens em escala de cinza.
  - b) O *decoder* possui parâmetros insuficientes para reconstruir a entrada.
  - c) Não há gargalo de informação, então a rede aprende a copiar a entrada.
  - d) A inicialização dos pesos foi feita com valores muito pequenos, causando colapso.
- II) Em um *denoising autoencoder*, qual é o procedimento correto de treinamento por amostra?
- a) Corromper  $x$  gerando  $\tilde{x}$ , passar  $\tilde{x}$  pela rede e comparar a saída com  $\tilde{x}$ .
  - b) Corromper  $x$  gerando  $\tilde{x}$ , passar  $\tilde{x}$  pela rede e comparar a saída com  $x$  original.
  - c) Passar  $x$  pela rede e comparar a saída com uma versão corrompida  $\tilde{x}$  do mesmo  $x$ .
  - d) Passar  $x$  pela rede e adicionar ruído na representação latente antes do *decoder*.
- III) Considere um *autoencoder* vanilla treinado para minimizar o erro de reconstrução. Por que esse modelo, sozinho, não pode ser usado para gerar amostras novas e plausíveis, ainda que reconstrua bem o conjunto de treino?
- a) O *decoder* é determinístico e, portanto, não admite a injeção de ruído necessária para variabilidade.
  - b) Não há distribuição conhecida sobre o latente, então amostrar  $z$  ao acaso pode cair em regiões sem suporte aprendido pelo *decoder*.
  - c) O erro de reconstrução tende a zero, o que elimina qualquer diversidade na saída do *decoder*.
  - d) O *encoder* não é diferenciável em relação a  $\theta$ , impedindo a propagação do gradiente até a entrada.
- IV) O *encoder* de um VAE com latente bidimensional ( $D_z = 2$ ) produz, para uma entrada  $x$ , os parâmetros  $\mu = (2, 0)$  e  $\Sigma = \text{diag}(1, 1)$ . Considerando  $p(z) = \mathcal{N}(0, I)$ , qual é o valor de  $D_{KL}[q(z | x, \phi) || p(z)]$ ?
- a) 0.
  - b) 1.
  - c) 2.
  - d) 4.

- V) Durante o *forward pass* de um VAE com latente bidimensional, o *encoder* produz  $\mu = (1, -2)$  e desvios-padrão  $\sigma = (0,5, 1,5)$  (assumindo  $\Sigma$  diagonal). Foi amostrado  $\epsilon^* = (0,4, -0,2)$  a partir de  $\mathcal{N}(0, I)$ . Qual é o valor de  $z^*$  produzido pelo *reparametrization trick*?
- $(1,2, -2,3)$ .
  - $(1,4, -2,2)$ .
  - $(0,9, -1,7)$ .
  - $(1,5, -1,7)$ .
- VI) Por que o *reparametrization trick* é necessário durante o treinamento de um VAE?
- Para garantir que o *prior*  $p(z)$  seja exatamente  $\mathcal{N}(0, I)$  durante toda a otimização.
  - Para que a amostragem de  $z^*$  permaneça no caminho diferenciável em relação aos parâmetros do *encoder*.
  - Para reduzir o custo computacional da estimativa *Monte Carlo* do termo de reconstrução.
  - Para forçar a distribuição posterior  $q(z | x, \phi)$  a ter média zero e variância unitária.
- VII) O ELBO usado no treinamento de um VAE pode ser escrito como a soma de dois termos. Qual alternativa identifica corretamente o papel de cada termo na função objetivo?
- Termo de reconstrução:  $-D_{KL}[q(z | x, \phi) || p(z)]$ . Termo de regularização:  $\mathbb{E}_q[\log p(x | z, \theta)]$ .
  - Termo de reconstrução:  $\mathbb{E}_q[\log p(x | z, \theta)]$ . Termo de regularização:  $-D_{KL}[q(z | x, \phi) || p(z)]$ .
  - Termo de reconstrução:  $\mathbb{E}_{p(z)}[\log p(x | z, \theta)]$ . Termo de regularização:  $D_{KL}[p(z) || q(z | x, \phi)]$ .
  - Termo de reconstrução:  $\log p(x | \theta)$ . Termo de regularização:  $\mathbb{E}_q[\log q(z | x, \phi)]$ .
- VIII) Após treinar um VAE com *decoder* muito expressivo, observa-se que  $D_{KL}[q(z | x, \phi) || p(z)]$  tende a zero para todas as entradas, enquanto o erro de reconstrução do *decoder* permanece elevado. O que esse padrão indica?
- A taxa de aprendizado está alta demais e o gradiente do termo KL está dominando o gradiente da reconstrução.
  - O *encoder* aprendeu a igualar  $q(z | x, \phi)$  ao *prior* e o latente carrega pouca informação sobre  $x$ .
  - O ruído  $\epsilon^*$  do *reparametrization trick* não está sendo amostrado de forma independente para cada exemplo.
  - A dimensão do latente  $D_z$  está pequena demais para representar a distribuição dos dados.
- IX) Depois de treinar um VAE, deseja-se gerar uma nova amostra  $x^*$  que se assemelhe aos dados de treino. Qual procedimento corresponde à amostragem ancestral correta?
- Tomar um  $x$  qualquer do conjunto de treino, passar pelo *encoder* para obter  $\mu, \Sigma$  e produzir  $x^*$  via *decoder* aplicado em  $\mu$ .
  - Amostrar  $z^* \sim \mathcal{N}(0, I)$  e passar  $z^*$  pelo *decoder* para obter os parâmetros de  $p(x | z^*, \theta)$ .
  - Amostrar  $z^*$  uniformemente em um cubo de aresta 1 centrado na origem e passar pelo *decoder*.
  - Amostrar  $z^*$  de  $q(z | x, \phi)$  com  $x$  tirado do conjunto de treino e copiar a saída do *decoder*.

- X)  Considere a fronteira entre um *autoencoder* clássico e um *variational autoencoder*. Qual afirmação abaixo descreve mais precisamente o papel da inferência variacional no VAE, dado que  $p(x | \theta) = \int p(x | z, \theta) p(z) dz$  é, em geral, intratável?
- A inferência variacional substitui o termo  $\log p(x | \theta)$  por um limite inferior tratável envolvendo  $q(z | x, \phi)$ , que é otimizado em conjunto com  $\theta$ .
  - A inferência variacional fornece uma forma exata de calcular  $p(x | \theta)$  via uma única amostra de  $z$ , dispensando integração numérica.
  - A inferência variacional transforma o problema em uma classificação binária entre amostras reais e amostras geradas pelo *decoder*.
  - A inferência variacional garante que o *encoder* aprenda exatamente a distribuição posterior verdadeira  $p(z | x, \theta)$ .
- XI)  Considere dois *encoders* A e B de um VAE com latente bidimensional, ambos produzindo  $\mu = (0, 0)$ . O *encoder* A devolve  $\Sigma_A = \text{diag}(0,01, 0,01)$ , enquanto o B devolve  $\Sigma_B = \text{diag}(1, 1)$ . Comparando  $D_{KL}[q_A || p(z)]$  e  $D_{KL}[q_B || p(z)]$  contra  $p(z) = \mathcal{N}(0, I)$ , qual afirmação está correta?
- $D_{KL}^A < D_{KL}^B$ , pois variâncias menores aproximam  $q$  de uma massa pontual e reduzem a divergência.
  - $D_{KL}^A = D_{KL}^B = 0$ , pois ambas as médias coincidem com a média do *prior*.
  - $D_{KL}^A > D_{KL}^B$ , pois o termo  $-\log \det \Sigma$  cresce quando as variâncias se aproximam de zero.
  - $D_{KL}^A \approx D_{KL}^B$ , pois o termo dominante é  $\mu^\top \mu$ , que se anula em ambos os casos.
- XII) Um *autoencoder* *esparso* é uma variante em que a dimensão do latente pode ser *maior* que a da entrada (*overcomplete*), mas ainda assim a rede aprende representações úteis. Como essa configuração evita a solução trivial de cópia?
- Penalizando a ativação do latente para que poucas unidades fiquem ativas simultaneamente.
  - Aplicando *dropout* apenas no *decoder* para impedir a passagem direta da informação.
  - Reduzindo a taxa de aprendizado sempre que o erro de reconstrução fica abaixo de um limiar.
  - Substituindo o erro quadrático médio por entropia cruzada categórica no *decoder*.

### Gabarito - Objetivas

- I) c
- II) b
- III) b
- IV) c
- V) a
- VI) b
- VII) b
- VIII) b

IX) b

X) a

XI) c

XII) a

**Questões Dissertativas.**

- I) Considere um *autoencoder* aplicado a imagens em escala de cinza com  $D_x = 784 \text{ pixels}$  (entrada vetorizada de  $28 \times 28$ ). Para cada uma das configurações abaixo, indique se o modelo é *undercomplete* ou *overcomplete*, e discuta brevemente o efeito esperado sobre a representação aprendida.
- (a) Latente com  $D_z = 32$  unidades, sem outras regularizações.
  - (b) Latente com  $D_z = 2000$  unidades, sem outras regularizações.
  - (c) Latente com  $D_z = 2000$  unidades, treinado com penalidade de esparsidade na ativação do latente.
- II) Seja um VAE com latente  $D_z = 2$ . Para uma entrada  $x$ , o *encoder* produz  $\mu = (1, -1)$  e  $\Sigma = \text{diag}(0,5, 2)$ . Calcule, passo a passo,  $D_{KL}[q(z | x, \phi) \parallel \mathcal{N}(0, I)]$  usando a fórmula fechada apresentada em aula. Em seguida, comente qual dos quatro termos ( $\text{Tr}[\Sigma]$ ,  $\mu^\top \mu$ ,  $D_z$ ,  $\log \det \Sigma$ ) mais contribuiu para o valor obtido.
- III) Explique o *reparametrization trick* respondendo aos itens abaixo.
- (a) Qual é o problema do ponto de vista da *backpropagation* ao amostrar  $z^* \sim q(z | x, \phi)$  diretamente?
  - (b) Escreva a forma reparametrizada de  $z^*$  usada em VAEs com posterior gaussiano de média  $\mu$  e covariância diagonal  $\Sigma$ , identificando claramente quais variáveis ficam no caminho diferenciável e qual variável é a fonte de estocasticidade.
  - (c) 🧠 Mostre, usando a forma reparametrizada, que  $\mathbb{E}[z^*] = \mu$  e que  $\text{Cov}[z^*] = \Sigma$ .
- IV) Compare um *autoencoder* clássico e um *variational autoencoder* respondendo:
- (a) O que cada *encoder* produz para uma mesma entrada  $x$ ?
  - (b) Por que somente o VAE permite *amostragem ancestral* de novos  $x^*$  após o treinamento?
  - (c) Qual é a função objetivo otimizada em cada caso e por que o VAE não otimiza diretamente  $\log p(x | \theta)$ ?
- V) Considere um VAE treinado em MNIST cuja loss de treino apresenta o seguinte comportamento ao longo das épocas: o termo  $D_{KL}[q(z | x, \phi) \parallel p(z)]$  cai rapidamente para perto de zero, enquanto o termo de reconstrução estagna em um valor alto. As amostras geradas a partir de  $z^* \sim p(z)$  resultam em imagens de aparência média, com pouca variação entre amostras distintas.
- (a) Nomeie o fenômeno observado e explique o que ele significa em termos da informação que o latente  $z$  carrega sobre  $x$ .
  - (b) Por que esse fenômeno é especialmente comum quando o *decoder* é muito expressivo (por exemplo, autoregressivo)?
  - (c) Cite uma estratégia conhecida para mitigar o problema e explique, em uma frase, como ela age sobre o ELBO.

**Gabarito**

## I) Configurações.

- (a) *Undercomplete* ( $D_z = 32 < 784$ ). O gargalo força o *encoder* a comprimir, descartando informações redundantes; tende a produzir representações úteis para tarefas posteriores.
- (b) *Overcomplete* ( $D_z = 2000 > 784$ ), sem regularização. A rede pode aprender uma cópia trivial ou indexar as instâncias do treino (memorização), com representação latente pouco informativa.
- (c) *Overcomplete* ( $D_z = 2000$ ), porém regularizado por esparsidade. A penalidade obriga que poucas unidades do latente fiquem ativas por exemplo, recuperando a utilidade da representação mesmo sem gargalo dimensional.

## II) Cálculo passo a passo.

$$\begin{aligned}
 \text{Tr}[\Sigma] &= 0,5 + 2 = 2,5 \\
 \mu^\top \mu &= 1^2 + (-1)^2 = 2 \\
 \log \det \Sigma &= \log(0,5) + \log(2) \approx -0,693 + 0,693 = 0 \\
 D_z &= 2 \\
 D_{KL} &= \frac{1}{2} (\text{Tr}[\Sigma] + \mu^\top \mu - D_z - \log \det \Sigma) \\
 &= \frac{1}{2} (2,5 + 2 - 2 - 0) = \frac{1}{2} (2,5) = 1,25.
 \end{aligned}$$

Os dois termos que mais contribuem são  $\text{Tr}[\Sigma] = 2,5$  (dispersão acima do *prior* unitário, sobretudo pela segunda coordenada com  $\sigma^2 = 2$ ) e  $\mu^\top \mu = 2$  (desvio da origem). O termo  $\log \det \Sigma$  acaba se anulando porque as variâncias 0,5 e 2 se compensam em escala logarítmica.

## III) Reparametrization trick.

- (a) A operação de amostragem é estocástica e não tem derivada bem definida com respeito aos parâmetros que produzem a distribuição. Sem reparametrização, o gradiente de  $\mathcal{L}$  não consegue fluir do *decoder* de volta até  $\phi$  através do nó de amostragem.
- (b) Escrevemos  $z^* = \mu + \Sigma^{1/2} \epsilon^*$ , com  $\epsilon^* \sim \mathcal{N}(0, I)$ . As quantidades  $\mu$  e  $\Sigma^{1/2}$  (saídas do *encoder*, função de  $\phi$ ) permanecem no caminho diferenciável; a estocasticidade fica concentrada em  $\epsilon^*$ , que é amostrado de uma distribuição fixa e não depende de  $\phi$ .
- (c) Como  $\epsilon^* \sim \mathcal{N}(0, I)$  é independente de  $\mu$  e  $\Sigma$ :

$$\begin{aligned}
 \mathbb{E}[z^*] &= \mu + \Sigma^{1/2} \mathbb{E}[\epsilon^*] = \mu + 0 = \mu. \\
 \text{Cov}[z^*] &= \mathbb{E}[(z^* - \mu)(z^* - \mu)^\top] \\
 &= \mathbb{E}[\Sigma^{1/2} \epsilon^* \epsilon^{*\top} \Sigma^{1/2}] \\
 &= \Sigma^{1/2} \mathbb{E}[\epsilon^* \epsilon^{*\top}] \Sigma^{1/2} \\
 &= \Sigma^{1/2} I \Sigma^{1/2} = \Sigma.
 \end{aligned}$$

Logo  $z^*$  é distribuído como  $\mathcal{N}(\mu, \Sigma)$ , conforme desejado.

## IV) Comparação AE versus VAE.

- (a) O *encoder* de um AE clássico produz um ponto no espaço latente,  $z = f(x, \theta)$ , determinístico dada a entrada. O *encoder* de um VAE produz os parâmetros de uma distribuição sobre o latente,  $q(z | x, \phi) = \mathcal{N}(\mu, \Sigma)$ .

- (b) No AE clássico não há uma distribuição conhecida sobre o latente, então amostrar  $z$  ao acaso pode cair em regiões sem suporte aprendido pelo *decoder*. No VAE o termo KL aproxima  $q(z | x, \phi)$  do *prior*  $p(z)$ , garantindo que amostras  $z^* \sim p(z)$  permaneçam em regiões plausíveis para o *decoder*.
- (c) O AE clássico minimiza apenas o erro de reconstrução,  $J(x, g(f(x, \theta), \phi))$ . O VAE maximiza o ELBO, que é um limite inferior de  $\log p(x | \theta)$ . Não otimizamos  $\log p(x | \theta)$  diretamente porque a marginal  $p(x | \theta) = \int p(x | z, \theta) p(z) dz$  envolve uma integral intratável devido à não linearidade do *decoder*.

V) Diagnóstico do treino.

- (a) O fenômeno é o *posterior collapse*: o *encoder* aprendeu a igualar  $q(z | x, \phi)$  ao *prior* para qualquer  $x$ , de modo que o latente  $z$  deixa de carregar informação sobre a entrada. A consequência é que amostras geradas a partir do *prior* se concentram em torno de uma reconstrução média, com pouca diversidade.
- (b) Quando o *decoder* é poderoso o bastante para modelar  $p(x | z, \theta)$  ignorando  $z$  (por exemplo, modelos autoregressivos sobre os *pixels*), o otimizador encontra um ótimo barato em zerar o termo KL: a contribuição de  $z$  para o ELBO fica marginal e o gradiente empurra  $q$  na direção de  $p(z)$ .
- (c) Estratégias comuns incluem *KL annealing* (introduzir o termo KL gradualmente, começando com peso baixo) e *free bits* (não penalizar a KL abaixo de um limiar por dimensão do latente). Ambas reduzem a pressão do termo de regularização nas fases iniciais, permitindo que o *decoder* aprenda a usar  $z$  antes que o KL force o colapso.