

**Instruções:** Responda às questões de múltipla escolha assinalando apenas uma alternativa. Nas dissertativas, apresente o raciocínio passo a passo, incluindo fórmulas e cálculos intermediários quando solicitado. Mantenha a notação dos slides:  $\beta_t$  para o *noise schedule*,  $\alpha_t = \prod_{s=1}^t (1 - \beta_s)$  para o produto acumulado,  $z_t$  para o estado em  $t$ ,  $\epsilon$  para o ruído gaussiano e  $g_t[z_t, \theta_t]$  para a rede que estima o ruído. Questões marcadas com 🧠 são consideradas difíceis.

### Questões de Múltipla Escolha.

- I) Considere o kernel de difusão  $z_t = \sqrt{\alpha_t} x + \sqrt{1 - \alpha_t} \epsilon$ , com  $\epsilon \sim \mathcal{N}(0, I)$ . Dado  $\alpha_t = 0,64$ ,  $x = 2$  e  $\epsilon = 0,5$ , qual é o valor amostrado de  $z_t$ ?
- (a) 1,90.
  - (b) 1,60.
  - (c) 1,46.
  - (d) 2,10.
- II) Para um *schedule*  $\beta = (0,05, 0,10, 0,20)$  com  $T = 3$ , qual é o valor de  $\alpha_3$ ?
- (a) 0,684.
  - (b) 0,350.
  - (c) 0,650.
  - (d) 0,001.
- III) No processo de difusão,  $q(z_t | x) = \mathcal{N}_{z_t}[\mu, \Sigma]$ . Para  $\alpha_t = 0,49$  e  $x = 4$ , quais são, respectivamente, a média  $\mu$  e a variância  $\Sigma$  (esta última como múltiplo de I)?
- (a)  $\mu = 2,80$  e  $\Sigma = 0,51 I$ .
  - (b)  $\mu = 1,96$  e  $\Sigma = 0,49 I$ .
  - (c)  $\mu = 2,80$  e  $\Sigma = 0,70 I$ .
  - (d)  $\mu = 2,00$  e  $\Sigma = 0,51 I$ .
- IV) Após a reparametrização que faz a rede  $g_t[z_t, \theta_t]$  predizer o ruído, a função de custo do modelo difusor (excluindo o termo de reconstrução) assume qual forma?
- (a)  $\sum_{i,t} |g_t[z_t, \theta_t] - x^{(i)}|^2$ .
  - (b)  $\sum_{i,t} |g_t[z_t, \theta_t] - z_{t-1}|^2$ .
  - (c)  $\sum_{i,t} |g_t[z_t, \theta_t] - \epsilon_t|^2$ .
  - (d)  $\sum_{i,t} -\log g_t[z_t, \theta_t] \epsilon_t$ .
- V) Sobre o processo de difusão (*forward*) definido nos slides, qual afirmação é correta?
- (a) A transição  $q(z_t | z_{t-1})$  depende explicitamente de  $x$  e de todos os estados anteriores.
  - (b) A cadeia é markoviana, com  $q(z_t | z_{t-1}, x) = q(z_t | z_{t-1})$ , e a variância da transição é  $\beta_t I$ .
  - (c) A transição é determinística e a aleatoriedade entra somente em  $z_T \sim \mathcal{N}(0, I)$ .
  - (d) A média de  $q(z_t | z_{t-1})$  é  $\sqrt{\alpha_t} z_{t-1}$ , com variância  $(1 - \alpha_t) I$ .

- VI) 🦴 Considere o *schedule*  $\beta = (0,1, 0,2, 0,3, 0,4)$  com  $T = 4$ , que produz  $\alpha = (0,900, 0,720, 0,504, 0,302)$ . Definindo a razão sinal-ruído como  $\text{SNR}(t) = \alpha_t / (1 - \alpha_t)$ , em qual passo  $\text{SNR}(t)$  é o primeiro a se aproximar de 1 (i.e.,  $|\text{SNR}(t) - 1|$  é mínimo)?
- (a) Em  $t = 2$ .
  - (b) Em  $t = 3$ .
  - (c) Em  $t = 4$ .
  - (d) Em  $t = 1$ .
- VII) Nos slides, a rede  $g_t$  é treinada para prever o ruído  $\epsilon$  adicionado, e não  $x$  ou  $z_{t-1}$  diretamente. Qual a justificativa apresentada para essa escolha?
- (a) Prever o ruído evita o uso de *skip connections* na U-Net.
  - (b) Prever o ruído elimina a necessidade de *noise schedule* no *forward process*.
  - (c) Prever o ruído é uma observação empírica: na prática produz melhores resultados que prever  $x$  diretamente.
  - (d) Prever o ruído torna a *loss* numericamente equivalente a uma entropia cruzada.
- VIII) A distribuição condicional  $q(z_{t-1} | z_t, x)$ , derivada no curso, é uma gaussiana cuja média é uma combinação linear de  $z_t$  e  $x$ . Para  $\beta_t = 0,2$ ,  $\alpha_{t-1} = 0,9$  e  $\alpha_t = 0,72$ , qual é, respectivamente, o coeficiente de  $z_t$  e o coeficiente de  $x$  na média?
- (a) Coef.  $z_t \approx 0,319$ ; coef.  $x \approx 0,678$ .
  - (b) Coef.  $z_t \approx 0,894$ ; coef.  $x \approx 0,200$ .
  - (c) Coef.  $z_t \approx 0,357$ ; coef.  $x \approx 0,678$ .
  - (d) Coef.  $z_t \approx 0,849$ ; coef.  $x \approx 0,300$ .
- IX) No trilema apresentado nos slides (qualidade, cobertura, velocidade de amostragem), em qual canto os modelos difusores se posicionam por padrão?
- (a) Qualidade alta e cobertura alta, com amostragem lenta.
  - (b) Qualidade alta e amostragem rápida, com cobertura baixa.
  - (c) Cobertura alta e amostragem rápida, com qualidade baixa.
  - (d) Qualidade alta, cobertura alta e amostragem rápida simultaneamente.
- X) *Latent Diffusion Models* (base do *Stable Diffusion*) aplicam a difusão no espaço latente de um VAE. Qual é a principal motivação dessa escolha?
- (a) Permitir treino sem uso de *classifier-free guidance*.
  - (b) Reduzir o custo computacional, já que o latente tem dimensionalidade muito menor que a imagem em pixels.
  - (c) Tornar a *loss* convexa em relação aos parâmetros da U-Net.
  - (d) Eliminar a necessidade da arquitetura U-Net no estimador de ruído.

**Gabarito - Objetivas**

- I) a
- II) a
- III) a
- IV) c
- V) b
- VI) b
- VII) c
- VIII) a
- IX) a
- X) b

**Resoluções - Objetivas**

- I)  $z_t = \sqrt{0,64} \cdot 2 + \sqrt{0,36} \cdot 0,5 = 0,8 \cdot 2 + 0,6 \cdot 0,5 = 1,60 + 0,30 = 1,90$ . A (b) corresponde a trocar os papéis dos coeficientes,  $\sqrt{1 - \alpha_t} \cdot x + \sqrt{\alpha_t} \cdot \epsilon = 0,6 \cdot 2 + 0,8 \cdot 0,5 = 1,60$ . A (c) corresponde a usar  $\alpha_t$  e  $1 - \alpha_t$  sem aplicar as raízes,  $0,64 \cdot 2 + 0,36 \cdot 0,5 = 1,46$ . A (d) corresponde a aplicar  $\sqrt{\alpha_t}$  no sinal, mas esquecer de escalar o ruído,  $0,8 \cdot 2 + 0,5 = 2,10$ .
- II)  $\alpha_3 = (1 - 0,05)(1 - 0,10)(1 - 0,20) = 0,95 \cdot 0,90 \cdot 0,80 = 0,684$ . A (b) corresponde a somar os  $\beta_t$  em vez de aplicar o produto  $\prod(1 - \beta_s)$ . A (c) corresponde a  $1 - \sum \beta_t$ . A (d) corresponde ao produto direto  $\prod \beta_t$ .
- III) Como  $q(z_t | x) = \mathcal{N}[\sqrt{\alpha_t} x, (1 - \alpha_t) I]$ , temos  $\mu = \sqrt{0,49} \cdot 4 = 0,7 \cdot 4 = 2,80$  e  $\Sigma = (1 - 0,49) I = 0,51 I$ . A (b) usa  $\alpha_t$  em vez de  $\sqrt{\alpha_t}$  na média. A (c) confunde a variância com  $1 - \sqrt{\alpha_t}$ . A (d) divide  $x$  por  $\sqrt{\alpha_t}$  em vez de multiplicar.
- IV) Substituindo a reparametrização da rede no termo quadrático da *loss*, todos os termos em  $z_t$  e  $x$  se cancelam, restando  $|g_t[z_t, \theta_t] - \epsilon_t|^2$ , conforme caixa final no slide “Reparametrizando a rede, Loss final”. A (a) ignora a reparametrização. A (b) corresponde ao alvo da formulação anterior. A (d) tem forma de log-verossimilhança e não corresponde a um MSE.
- V) Pela definição  $q(z_t | z_{t-1}) = \mathcal{N}[\sqrt{1 - \beta_t} z_{t-1}, \beta_t I]$ , vale a propriedade de Markov com variância  $\beta_t I$ . A (a) viola a propriedade de Markov. A (c) descreve um processo determinístico, o que não é o caso. A (d) confunde a média da transição passo a passo (que usa  $\sqrt{1 - \beta_t}$ ) com a do kernel acumulado (que usa  $\sqrt{\alpha_t}$ ).
- VI) Calculando  $\text{SNR}(t) = \alpha_t / (1 - \alpha_t)$ :  $\text{SNR}(1) = 0,900 / 0,100 = 9,00$ ;  $\text{SNR}(2) = 0,720 / 0,280 \approx 2,57$ ;  $\text{SNR}(3) = 0,504 / 0,496 \approx 1,016$ ;  $\text{SNR}(4) = 0,302 / 0,698 \approx 0,433$ . O cruzamento de  $\text{SNR} = 1$  acontece em  $t = 3$  (onde  $\sqrt{\alpha_t} \approx \sqrt{1 - \alpha_t}$ ). A (a) confunde com o passo em que  $\alpha_t$  cai pela metade. A (c) é o ponto em que  $\text{SNR}$  já é claramente menor que 1. A (d) corresponde ao início, onde o sinal ainda domina.

- VII) No slide “Porém... um detalhe empírico” fica explícito: a escolha de prever  $\epsilon$  é uma observação empírica de que treinar a rede para estimar o ruído produz melhores resultados que estimar  $x$  diretamente. As alternativas (a), (b) e (d) descrevem consequências falsas dessa reparametrização.
- VIII) Pelo slide “Distribuição condicional, Produto de gaussianas”, a média é  $\frac{(1-\alpha_{t-1})\sqrt{1-\beta_t}}{1-\alpha_t} z_t + \frac{\sqrt{\alpha_{t-1}}\beta_t}{1-\alpha_t} x$ . Substituindo os valores dados, o coeficiente de  $z_t$  é  $\frac{(1-0,9)\sqrt{1-0,2}}{1-0,72} = \frac{0,1 \cdot 0,8944}{0,28} \approx 0,319$ , e o coeficiente de  $x$  é  $\frac{\sqrt{0,9} \cdot 0,2}{0,28} = \frac{0,9487 \cdot 0,2}{0,28} \approx 0,678$ . A (b) confunde o coeficiente de  $z_t$  com  $\sqrt{1-\beta_t}$  e o de  $x$  com  $\beta_t$  puro (esquece a normalização por  $1-\alpha_t$ ). A (c) inflaciona o coeficiente de  $z_t$  ao usar  $1-\beta_t$  no lugar de  $\sqrt{1-\beta_t}$ . A (d) confunde com a média de  $q(z_{t-1} | x)$  derivada do kernel direto, sem a correção bayesiana introduzida pela condição em  $z_t$ .
- IX) Pelo slide “Onde modelos difusores ficam no trilema”, modelos difusores ocupam o canto qualidade + cobertura, com amostragem tipicamente lenta ( $T \approx 1000$  passos pela U-Net). A (b) confunde com GANs. A (c) confunde com modelos autoregressivos rápidos de baixa fidelidade. A (d) descreveria um modelo ideal que ainda não existe.
- X) No slide “Latent Diffusion Models”, a motivação central é o custo computacional, o latente é  $\sim 64 \times 64$  contra  $1024 \times 1024$  em pixels. A (a) é falsa: *Latent Diffusion* é compatível com *classifier-free guidance*. A (c) é falsa: a *loss* continua não convexa. A (d) é falsa: a U-Net continua sendo a arquitetura padrão para o estimador de ruído no espaço latente.

### Questões Dissertativas.

- I) Seja o *noise schedule*  $\beta = (0,1, 0,3)$  com  $T = 2$  e  $x = 1$ .
- Calcule  $\alpha_1$  e  $\alpha_2$ .
  - Usando o kernel de difusão, escreva  $q(z_2 | x)$  explicitamente (média e variância).
  - Para  $\epsilon = -1,0$ , calcule o valor amostrado de  $z_2$  via kernel.
  - Compare  $z_2$  com a média da distribuição  $q(z_2 | x)$ . Em uma frase, interprete o resultado.
- II)  Partindo das definições passo a passo  $z_1 = \sqrt{1 - \beta_1} x + \sqrt{\beta_1} \epsilon_1$  e  $z_2 = \sqrt{1 - \beta_2} z_1 + \sqrt{\beta_2} \epsilon_2$ , com  $\epsilon_1, \epsilon_2 \sim \mathcal{N}(0, I)$  independentes, mostre algebricamente que existe um único ruído  $\epsilon \sim \mathcal{N}(0, I)$  tal que  $z_2 = \sqrt{\alpha_2} x + \sqrt{1 - \alpha_2} \epsilon$ , onde  $\alpha_2 = (1 - \beta_1)(1 - \beta_2)$ . Indique claramente onde a propriedade “soma de gaussianas independentes” é usada.
- III) Compare modelos difusores, VAEs e GANs em três eixos: (i) estabilidade do treinamento, (ii) qualidade da amostra, (iii) custo de amostragem. Apresente a comparação como uma tabela ou três parágrafos curtos, justificando cada entrada com base no objetivo de treinamento de cada família (ELBO, jogo adversarial, MSE sobre o ruído).
- IV)  Em *classifier-free guidance*, treina-se uma única rede que pode operar em modo condicional, isto é,  $g_t(z_t, c)$ , ou incondicional,  $g_t(z_t, \emptyset)$ . Na amostragem, define-se um estimador guiado  $\tilde{g}_t = (1 + w) g_t(z_t, c) - w g_t(z_t, \emptyset)$ , com  $w \geq 0$ .
- Explique como o treinamento incondicional é obtido a partir do mesmo modelo (sem treinar duas redes separadas).
  - Para  $w = 0$ , qual amostrador é recuperado? E para  $w \rightarrow \infty$  (ou valores muito grandes), qual o efeito esperado nas amostras geradas?
  - Justifique, em uma ou duas frases, por que valores intermediários de  $w$  (e.g.,  $w \in [1, 7]$ ) costumam produzir amostras com maior aderência à condição, mesmo sem usar um classificador externo.

### Gabarito

- I) (a)  $\alpha_1 = 1 - 0,1 = 0,9$ ;  $\alpha_2 = (1 - 0,1)(1 - 0,3) = 0,9 \cdot 0,7 = 0,63$ .
- (b) Pelo kernel,  $q(z_2 | x) = \mathcal{N}_{z_2}[\sqrt{\alpha_2} x, (1 - \alpha_2) I] = \mathcal{N}_{z_2}[\sqrt{0,63} \cdot 1, 0,37 I] \approx \mathcal{N}_{z_2}[0,794, 0,37 I]$ .
- (c)  $z_2 = \sqrt{0,63} \cdot 1 + \sqrt{0,37} \cdot (-1,0) \approx 0,794 + 0,608 \cdot (-1,0) \approx 0,794 - 0,608 \approx 0,186$ .
- (d) O valor amostrado  $z_2 \approx 0,186$  está abaixo da média  $\approx 0,794$  por aproximadamente um desvio-padrão ( $\sqrt{0,37} \approx 0,608$ ), o que reflete a contribuição de um ruído  $\epsilon = -1,0$  no kernel. Em uma população grande de amostras com o mesmo  $x$ , a média empírica de  $z_2$  convergiria para 0,794.
- II) Partindo de  $z_2 = \sqrt{1 - \beta_2} z_1 + \sqrt{\beta_2} \epsilon_2$  e substituindo  $z_1$ :

$$z_2 = \sqrt{1 - \beta_2} \left( \sqrt{1 - \beta_1} x + \sqrt{\beta_1} \epsilon_1 \right) + \sqrt{\beta_2} \epsilon_2.$$

Distribuindo,

$$z_2 = \sqrt{(1 - \beta_1)(1 - \beta_2)} x + \sqrt{(1 - \beta_2)\beta_1} \epsilon_1 + \sqrt{\beta_2} \epsilon_2.$$

Como  $\epsilon_1$  e  $\epsilon_2$  são gaussianas independentes de média zero e variância 1, a soma  $\sqrt{(1-\beta_2)\beta_1}\epsilon_1 + \sqrt{\beta_2}\epsilon_2$  é uma gaussiana de média zero e variância

$$(1-\beta_2)\beta_1 + \beta_2 = \beta_1 + \beta_2 - \beta_1\beta_2 = 1 - (1-\beta_1)(1-\beta_2) = 1 - \alpha_2.$$

Portanto existe um único  $\epsilon \sim \mathcal{N}(0, I)$  tal que  $\sqrt{(1-\beta_2)\beta_1}\epsilon_1 + \sqrt{\beta_2}\epsilon_2 = \sqrt{1-\alpha_2}\epsilon$ , e segue

$$z_2 = \sqrt{\alpha_2}x + \sqrt{1-\alpha_2}\epsilon, \quad \alpha_2 = (1-\beta_1)(1-\beta_2). \quad \square$$

A propriedade “soma de gaussianas independentes é gaussiana com variâncias somadas” é usada exatamente no passo onde combinamos  $\epsilon_1$  e  $\epsilon_2$  em um único  $\epsilon$ .

### III) Tabela comparativa:

| Eixo                   | Difusores          | VAEs            | GANs            |
|------------------------|--------------------|-----------------|-----------------|
| Estabilidade do treino | alta               | alta            | baixa           |
| Qualidade da amostra   | muito alta         | moderada        | alta            |
| Custo de amostragem    | alto ( $T$ passos) | baixo (1 passo) | baixo (1 passo) |

**Justificativa.** Difusores otimizam um MSE sobre o ruído (objetivo bem comportado, sem competição entre redes), o que confere estabilidade. VAEs maximizam o ELBO, também estável, mas o termo de KL e a fatoração gaussiana costumam suavizar as amostras (qualidade moderada, amostras tendem a borrar). GANs jogam um *min-max* adversarial, suscetível a *mode collapse* e oscilações (baixa estabilidade), mas, quando convergem, geram amostras nítidas. No custo de amostragem, difusores precisam de  $T$  passos da U-Net (tipicamente  $T = 1000$ ), enquanto VAEs e GANs amostram com uma única passada do decoder ou gerador.

IV) (a) Durante o treinamento, com probabilidade  $p$  (tipicamente  $p \approx 0,1$ ) o vetor de condicionamento  $c$  é substituído por um *token* ou *embedding* especial  $\emptyset$ , “descondicionando” o exemplo. A mesma rede aprende a operar tanto em modo condicional quanto incondicional, sem necessidade de treinar uma segunda rede separada.

(b) Para  $w = 0$ ,  $\tilde{g}_t = g_t(z_t, c)$ , ou seja, o amostrador condicional puro. Para  $w \rightarrow \infty$ , o estimador guiado afasta-se cada vez mais da estimativa incondicional na direção da estimativa condicional, exagerando os traços da condição  $c$ . Na prática isso aumenta a aderência à condição (e.g., *prompt* de texto) ao preço de menor diversidade e, em valores muito altos, artefatos visuais.

(c) O estimador guiado equivale, na perspectiva de *score matching*, a amostrar de uma distribuição proporcional a  $p(z_t | c) [p(z_t | c)/p(z_t)]^w$ , que reforça a razão de verossimilhança da condição. Valores intermediários de  $w$  amplificam essa razão sem destruir o suporte da distribuição original, produzindo amostras mais alinhadas com  $c$  sem precisar de um classificador externo treinado separadamente.