

## Descrição

Neste projeto você deverá projetar e implementar um Multilayer Perceptron (MLP) inteiramente em Numpy (ou biblioteca análoga de computação numérica), capaz de resolver tanto problemas de classificação quanto problemas de regressão. Não é permitido utilizar *frameworks* de *deep learning* (PyTorch, TensorFlow, JAX, ...) em nenhuma etapa: o *backward pass* da rede deve ser computado por um motor de diferenciação automática desenvolvido por você, também em Numpy.

A diferenciação automática é um dos recursos centrais de todos os *frameworks* modernos de redes neurais artificiais. Sua principal funcionalidade é permitir que qualquer função que possa ser computada no *framework* possa também ser derivada. O MLP deste projeto deve ser construído sobre esse recurso: o *forward pass* é expresso com as operações do motor e os gradientes usados no treinamento são obtidos pelo *backward pass* do motor, sem derivadas codificadas manualmente por camada.

## Requisitos do motor de diferenciação automática

O motor de diferenciação automática deverá suportar operações com escalares e operações matriciais. No mínimo, as seguintes operações devem estar disponíveis, com seus respectivos *backward passes*:

- 1) Soma, subtração, produto e divisão entre escalares ou entre escalar e matriz;
- 2) Multiplicação de matrizes;
- 3) Exponenciação, radiciação e logaritmos (de escalares ou com *broadcast* para matrizes);
- 4) Somatório.

Serão observadas a completude e a corretude do motor: para toda operação suportada, o gradiente produzido pelo *backward pass* deve estar correto.

## Requisitos do MLP

O MLP desenvolvido deverá possibilitar, no mínimo, as seguintes hiperparametrizações:

- 1) Número de camadas ocultas;
- 2) Número de unidades em cada camada oculta;
- 3) Funções de ativação: *Sigmoid*, *Tanh*, *ReLU*, *Leaky ReLU* e *Linear*;
- 4) Função de custo: *BCE* e *Mean Squared Error*;
- 5) Otimizador: *SGD* e *Adam*;
- 6) Método de inicialização dos pesos: *He*, *Xavier*, *Normal* ou *Uniforme*.

Além disso, deve ser possível exportar um arquivo (em formato definido por você) que contenha tanto a topologia da rede (camadas, funções de ativação, ...) quanto os pesos do modelo treinado. Também deve ser possível importar um desses arquivos e fazer inferência com a rede pré-treinada, sem novo treinamento.

## Conjuntos de dados

O MLP deverá ser testado em pelo menos 2 conjuntos de dados. Obrigatoriamente devem ser explorados um problema de classificação e um problema de regressão. Abaixo constam algumas sugestões, mas outros conjuntos podem ser utilizados:

- 1) Boston Housing;
- 2) IRIS;
- 3) MNIST 1D;
- 4) MNIST;
- 5) Fashion MNIST.

## Experimentos

Além de buscar bons resultados nos conjuntos de dados escolhidos, você deverá mostrar na prática o problema do gradiente que se dissipa ou do gradiente explosivo, provocando o fenômeno em uma configuração adequada da rede e evidenciando o comportamento nos gráficos de monitoramento.

## Monitoramento

Durante o treinamento das redes, os seguintes gráficos deverão ser produzidos:

- 1) Histograma das ativações e dos gradientes ao longo do treinamento (auxilia na identificação do problema do gradiente que se dissipa);
- 2) Função de custo vs. iteração (ou época), tanto em treino quanto em validação;
- 3) Métrica de avaliação (acurácia,  $R^2$ , ...) vs. iteração (ou época), tanto em treino quanto em validação.