

Deep Learning

Graph Neural Networks

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory
PUCRS

julho de 2026

Visão Geral

1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados


Visão Geral

1. **Motivação**
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados

O Mundo é Cheio de Grafos

Muitos dados naturais não vivem em uma grade regular:

- **Redes sociais:** usuários e suas conexões
- **Moléculas:** átomos ligados por ligações químicas
- **Citações científicas:** artigos referenciando uns aos outros
- **Sistemas de recomendação:** bipartido usuário–item
- **Grafos de conhecimento:** entidades e relações
- **Tráfego e logística:** cidades conectadas por rotas




Notação e Tipos de Grafos

Definição básica

Um grafo é $G = (V, E)$ com $|V| = n$ nós e $|E| = m$ arestas. A *adjacency matrix* $A \in \{0, 1\}^{n \times n}$ codifica E . Atributos de nó vivem em $X \in \mathbb{R}^{n \times d}$.

- **Dirigido vs não-dirigido:** A simétrica ou não.
- **Ponderado vs não-ponderado:** $A_{ij} \in \mathbb{R}$ ou $\{0, 1\}$.
- **Homogêneo vs heterogêneo:** tipos únicos de nó/aresta ou múltiplos (e.g., paciente, doença, fármaco em uma KG médica).
- **Estático vs dinâmico:** G fixo ou evoluindo no tempo.

Exemplo: Matriz de Adjacência



$$V = \{1, 2, 3, 4\}$$
$$E = \{(1, 2), (2, 3), (2, 4), (3, 4)\}$$

$$A = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 \\ 0 & 1 & 0 & 1 \\ 0 & 1 & 1 & 0 \end{bmatrix}$$

- Linha i : vizinhança de i .
- $A_{ij} = 1$ se $(i, j) \in E$.
- Não-dirigido $\Rightarrow A$ **simétrica**.
- Soma da linha i = grau d_i .

Esse mesmo grafo será o exemplo numérico para GCN mais à frente.

O Que Queremos Aprender

- Representações vetoriais $h_v \in \mathbb{R}^{d'}$ para cada nó v .
- Que essas representações sejam úteis em tarefas *downstream*: classificar nós, prever arestas, classificar o grafo inteiro.
- E que respeitem a estrutura do grafo: vizinhança, simetrias, escala.

O desafio

Diferente de imagens (grade regular) e texto (sequência), um grafo **não tem ordem canônica** nem **vizinhança de tamanho fixo**. Não dá para empilhar uma CNN diretamente em cima.


Visão Geral

1. Motivação
- 2. Por Que Grafos São Difíceis**
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados

Domínio Euclidiano vs Não-Euclidiano

Imagens, áudio, séries temporais

- Grade regular, ordem natural.
- Vizinhança de tamanho fixo (e.g., 3×3).
- Translação é uma simetria do domínio.
- CNNs/RNNs aproveitam isso.



Grafos

- Estrutura irregular.
- Cada nó tem grau diferente.
- Sem ordem canônica entre os nós.
- Translação não faz sentido.



Sem Ordem Canônica


Um mesmo grafo G pode ser representado por matrizes de adjacência A **diferentes**, dependendo de como rotulamos os nós.

Se P é qualquer permutação dos nós, então A e PAP^T descrevem o **mesmo grafo**, apenas com etiquetas trocadas.

Implicação

Qualquer modelo $f(A, X)$ que veja G deve ser indiferente a essa permutação:

$$f(PAP^T, PX) = f(A, X) \text{ (no caso invariante).}$$



Mesmo grafo, duas rotulagens, duas matrizes A distintas.

Invariância e Equivariância à Permutação

Seja P uma matriz de permutação $n \times n$.

- Função **invariante** (saída no nível-grafo, e.g., classe da molécula):

$$f(PAP^T, PX) = f(A, X)$$

- Função **equivariante** (saída no nível-nó, e.g., embedding por nó):

$$f(PAP^T, PX) = P f(A, X)$$

Princípio de projeto

Uma GNN deve ser **equivariante por construção** no estágio de message passing, e tornar-se **invariante** apenas no *readout* final quando a tarefa exige saída por grafo.

Paralelo: CNNs codificam invariância/equivariância à translação. GNNs codificam invariância/equivariância à permutação.

(*Message passing* e *readout* são detalhados adiante; por ora: “trocar informação entre vizinhos” e “produzir a saída final da tarefa”).

Visão Geral

1. Motivação
2. Por Que Grafos São Difíceis
- 3. Tarefas em Grafos**
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados

Três Tarefas Canônicas


Tarefa	O que se prevê	Exemplo
<i>Node classification</i>	Rótulo de um nó	Categoria de artigo em rede de citações
<i>Link prediction</i>	Existe/existirá uma aresta (u, v) ?	Recomendar item para usuário; completar KG
<i>Graph classification</i>	Rótulo do grafo inteiro	Toxicidade de molécula; propriedade química

Cada tarefa demanda uma estratégia de *readout* diferente:

- Nó: usar diretamente h_v .
- Aresta: combinar h_u e h_v (concatenação, produto interno, MLP).
- Grafo: agregação (*pooling*) sobre todos os h_v (soma, média, máx, atenção).

As Três Tarefas, Visualmente


Node classification



De qual **classe** é o nó “?”

readout: usar h_v direto


Link prediction



A aresta **tracejada** existe ou existirá?

readout: combinar h_u e h_v

Graph classification



O **grafo inteiro** é tóxico?

readout: pooling sobre $\{h_v\}$

Transdutivo vs Indutivo

Transdutivo


- Treino e teste no **mesmo grafo**.
- Vemos todos os nós, mas só rótulos de alguns.
- Caso clássico: rede de citações.



● treino ○ teste: **mesmo grafo**

Indutivo

- Treino em um conjunto de grafos, teste em **grafos novos** (ou subgrafos não vistos).
- Casos: moléculas novas; usuários novos em uma rede que cresce.



● grafos de treino ● **grafo novo** no teste

Por que importa

GCN precisa do grafo todo; GraphSAGE nasce indutivo via *sampling*.

Visão Geral

1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
- 4. Datasets e Métricas**
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados

Open Graph Benchmark¹

- Conjunto de **benchmarks padronizados** para tarefas em grafos.
- Splits, métricas e protocolos de avaliação **fixos e públicos** $\Rightarrow$ leaderboard reproduzível.
- Três famílias, uma por tarefa:
 - ogbn-*: classificação de nó.
 - ogbl-*: predição de aresta (*link prediction*).
 - ogbg-*: classificação de grafo.
- Escala realista: ogbn-papers100M tem ~ 111 M nós e ~ 1.6 B arestas. **Não cabe em GPU.**

Por que precisamos de OGB

Sem benchmarks padronizados, splits arbitrários e datasets pequenos geram rankings instáveis: comparações entre modelos viram ruído.

¹Weihua Hu et al. “Open Graph Benchmark: Datasets for Machine Learning on Graphs”. Em: [NeurIPS](#). 2020.

Um Exemplo OGB Por Tarefa

Família	Dataset	Tarefa	Métrica
ogbn-*	ogbn-arxiv	Classificar artigo do arXiv por subárea	Accuracy
ogbl-*	ogbl-ddi	Prever interação fármaco-fármaco	Hits@20
ogbg-*	ogbg-molhiv	Prever se molécula inibe HIV	ROC-AUC

- Cada dataset vem com **split fixo**: treino, validação, teste.
- Para link prediction, o split também inclui um **conjunto fixo de negativos amostrados**, sem isso comparações não seriam reproduzíveis.
- Pipeline padrão em *PyTorch Geometric* (PyG) ou *DGL*.

Métricas por Tarefa

Tarefa	Métrica padrão	Específica de grafo?
<i>Node classification</i>	Accuracy, F1 (macro/micro)	Não
<i>Graph classification</i>	ROC-AUC, Accuracy, AP (multi-task)	Não
<i>Link prediction</i>	Hits@K, MRR	Sim

Por que link prediction é diferente

Em um grafo com n nós existem $O(n^2)$ arestas possíveis. Calcular AUC contra todas as não-arestas é caro e o desbalanceamento é absurdo ($> 99.99\%$ de negativos). A solução é **negative sampling**: avaliamos cada positivo contra um subconjunto fixo de negativos amostrados.

Hits@K e MRR

Definições

Setup: para cada query (nó ou par), o modelo recebe 1 positivo v^* e N negativos amostrados, produz um *score* para cada candidato e ordena de modo decrescente. Seja r a posição (*rank*) do positivo nesse ranking ($r = 1$ no topo).

Hits@K

$$\text{Hits@K}_q = \mathbb{1}[r_q \leq K]$$

Média sobre todas as queries:

$$\text{Hits@K} = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{1}[r_q \leq K]$$

Mean Reciprocal Rank

$$\text{MRR} = \frac{1}{|Q|} \sum_{q \in Q} \frac{1}{r_q}$$

Sensível ao topo: cair de rank 1 $\rightarrow$ 2 vale 0.5; de 10 $\rightarrow$ 11 vale apenas ~ 0.009 .

Exemplo Trabalhado: 3 Queries

Estilo ogbl-ddi: cada query tem 1 positivo e 4 negativos.

Query	Score v^*	Scores neg.	Rank v^*	Hits@1	Hits@3	RR
u_1	0.70	0.90, 0.80, 0.50, 0.40	3	0	1	1/3
u_2	0.95	0.60, 0.50, 0.30, 0.10	1	1	1	1
u_3	0.20	0.90, 0.80, 0.70, 0.60	5	0	0	1/5

- Hits@1 = $(0 + 1 + 0)/3 \approx \mathbf{0.333}$
- Hits@3 = $(1 + 1 + 0)/3 \approx \mathbf{0.667}$
- MRR = $(1/3 + 1 + 1/5)/3 \approx \mathbf{0.511}$

Note como a query u_2 (rank 1) puxa o MRR para cima sozinha, enquanto Hits@K apenas conta acertos binários.

Visão Geral


1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
- 5. Embeddings de Nós: Antes das GNNs**
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados

Random Walks como Sinal Supervisor²

Antes das GNNs, a abordagem dominante era **aprender embeddings** de nós via *random walks*.

DeepWalk (Perozzi, Al-Rfou e Skiena, 2014)

1. Para cada nó v , gere γ *random walks* de comprimento ℓ .
2. Trate cada walk como uma “sentença” de nós.
3. Aplique *skip-gram* (Word2Vec) sobre essas sentenças: maximize $P(v_j | v_i)$ para nós que coocorrem em uma janela.



“sentença”: $(v_1, v_2, v_4, v_5, v_3)$

skip-gram: maximizar $P(v_4 | v_2), P(v_5 | v_4), \dots$

Resultado: vizinhanças similares $\Rightarrow$ embeddings próximos.

²Bryan Perozzi, Rami Al-Rfou e Steven Skiena. “DeepWalk: Online Learning of Social Representations”. Em: KDD. 2014, pp. 701–710.

node2vec e o Limite dos Embeddings Pré-GNN

node2vec (Grover e Leskovec, 2016)

generaliza DeepWalk com random walks parametrizados por (p, q) :

- p (*return*) controla a probabilidade de voltar ao nó anterior.
- q (*in-out*) interpola entre busca local (tipo BFS, homofilia) e exploração distante (tipo DFS, equivalência estrutural).

Permite balancear *homofilia* vs *equivalência estrutural*.

Limites fundamentais

- **Transdutivo:** embeddings só existem para nós vistos no treino.
- **Sem atributos:** ignora X .
- **Não generaliza entre grafos.**
- Sem fim-a-fim com tarefas *downstream*.

Para onde queremos ir

Um modelo que (i) seja **indutivo**, (ii) use atributos X , (iii) treine fim-a-fim, e (iv) compartilhe pesos entre grafos. $\Rightarrow$ **GNNs**.

Visão Geral

1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
- 6. Message Passing**
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados

O Framework de Message Passing³

Praticamente todas as GNNs populares se encaixam em um único esquema:

Para cada camada $k = 1, \dots, K$ e cada nó v :

1. **Message:** cada vizinho u envia uma mensagem

$$m_{u \rightarrow v}^{(k)} = M^{(k)}(h_u^{(k-1)}, h_v^{(k-1)}, e_{uv})$$

2. **Aggregate:** v combina mensagens dos vizinhos $\mathcal{N}(v)$

$$a_v^{(k)} = \text{AGG}(\{m_{u \rightarrow v}^{(k)} : u \in \mathcal{N}(v)\})$$


3. **Update:** v atualiza seu próprio embedding

$$h_v^{(k)} = U^{(k)}(h_v^{(k-1)}, a_v^{(k)})$$

Convenções: $h_v^{(0)} = X_v$ (atributos iniciais do nó), $\mathcal{N}(v)$ é a vizinhança de v e e_{uv} é o atributo (opcional) da aresta.


³Justin Gilmer et al. “Neural Message Passing for Quantum Chemistry”. Em: [ICML](#). 2017, pp. 1263–1272.

Uma Camada de Message Passing




- A estrutura do grafo define **quem fala com quem**.
- Cada vizinho envia uma mensagem; v agrega e atualiza.
- Após K camadas, h_v contém informação a até K saltos: empilhar camadas $\approx$ aumentar o *receptive field*.

Uma Camada de Message Passing



- A estrutura do grafo define **quem fala com quem**.
- Cada vizinho envia uma mensagem; v agrega e atualiza.
- Após K camadas, h_v contém informação a até K saltos: empilhar camadas $\approx$ aumentar o *receptive field*.

Uma Camada de Message Passing




- A estrutura do grafo define **quem fala com quem**.
- Cada vizinho envia uma mensagem; v **agrega e atualiza**.
- Após K camadas, h_v contém informação a até K saltos: empilhar camadas $\approx$ aumentar o *receptive field*.

Receptive Field e Profundidade

- Camada 1: v vê seus vizinhos imediatos.
- Camada 2: v vê vizinhos dos vizinhos (2-hops).
- Camada K : v vê todos os nós a até K saltos.

Em grafos com pequeno diâmetro (e.g., redes sociais, “6 graus de separação”), $K=3$ a 5 já cobre quase todo o grafo a partir de cada nó.



1-hop 2-hops

Visão Geral

1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
- 7. Graph Convolutional Network (GCN)**
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados

GCN

Intuição⁴

(Kipf e Welling, 2017) propõem a forma mais simples de message passing: **média ponderada dos vizinhos**.

Forma por nó

$$h_v^{(k)} = \sigma \left(W^{(k)} \cdot \sum_{u \in \mathcal{N}(v) \cup \{v\}} \frac{1}{\sqrt{\tilde{d}_v \tilde{d}_u}} h_u^{(k-1)} \right)$$

onde $\tilde{d}_v$ é o grau de v no grafo com auto-laços adicionados.

- Mensagem = identidade (h_u).
- Agregação = soma normalizada simétrica.
- Update = projeção linear $W^{(k)}$ + não-linearidade σ .

A normalização simétrica (não a média $1/\tilde{d}_v$) evita que vizinhos de grau alto dominem a agregação.

⁴Thomas N. Kipf e Max Welling. "Semi-Supervised Classification with Graph Convolutional Networks". Em: [ICLR](#). 2017.

GCN

Forma Matricial

Definindo $\tilde{A} = A + I$ (auto-laços, para v manter a própria informação) e $\tilde{D} = \text{diag}(\tilde{A}\mathbf{1})$:


Camada GCN inteira de uma vez

$$H^{(k)} = \sigma\left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(k-1)} W^{(k)}\right)$$

- $H^{(k)} \in \mathbb{R}^{n \times d_k}$: matriz de embeddings por nó.
- $\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$: **depende apenas do grafo**, é constante durante o treino.
- Implementação eficiente: multiplicação esparsa-densa.
- **Limitação**: precisa do grafo todo em memória $\Rightarrow$ transdutivo e custoso em escala.

Exemplo Numérico: GCN em 4 Nós (1/2)

Mesmo grafo da Seção 1. Atributos iniciais 1D: $h^{(0)} = (1, 2, 3, 4)^\top$. Para clareza fazemos $W^{(1)} = 1$ (escalar) e $\sigma = \text{Id}$.



$$\tilde{A} = A + I = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 \end{bmatrix}$$

Graus em $\tilde{A}$:

$$\tilde{d} = (2, 4, 3, 3)$$

$$\tilde{D}^{-1/2} = \text{diag}\left(\frac{1}{\sqrt{2}}, \frac{1}{2}, \frac{1}{\sqrt{3}}, \frac{1}{\sqrt{3}}\right)$$

Próximo passo: aplicar $\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$ a $h^{(0)}$.

Exemplo Numérico: GCN em 4 Nós (2/2)

Matriz normalizada $\hat{A} = \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$ com entrada $(i, j) = \tilde{A}_{ij} / \sqrt{\tilde{d}_i \tilde{d}_j}$:

$$\hat{A} \approx \begin{bmatrix} 0.50 & 0.35 & 0 & 0 \\ 0.35 & 0.25 & 0.29 & 0.29 \\ 0 & 0.29 & 0.33 & 0.33 \\ 0 & 0.29 & 0.33 & 0.33 \end{bmatrix}$$

Aplicando a $h^{(0)} = (1, 2, 3, 4)^\top$, por exemplo $h_1^{(1)} = 0.50 \cdot 1 + 0.354 \cdot 2 \approx 1.21$:

$$h^{(1)} = \hat{A} h^{(0)} \approx (1.21, 2.87, 2.91, 2.91)^\top$$

Observação

$h_3^{(1)} = h_4^{(1)}$ porque os nós 3 e 4 são **simétricos no grafo**. GNNs não distinguem nós com a mesma estrutura local quando os atributos não os diferenciam; voltaremos a essa ideia em *expressividade*.

Visão Geral

1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
- 8. GraphSAGE**
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados

GraphSAGE

Motivação⁵

GCN tem duas limitações que importam em escala:

- **Transdutivo:** precisa do grafo todo para computar $H^{(k)}$.
- **Custo de memória:** A esparsa de ogbn-papers100M tem ~ 1.6 B entradas. Não cabe em GPU.

A ideia de (Hamilton, Ying e Leskovec, 2017)

Em vez de operar no grafo todo, **amostrar uma vizinhança fixa** $S_k(v) \subseteq \mathcal{N}(v)$ por nó por camada. O custo por minibatch passa a depender de $|S_k|^K$, não de n .

Bônus: como o modelo aprende uma função $f(\cdot)$ que age sobre vizinhanças locais, ele é naturalmente **indutivo**: pode ser aplicado a grafos novos.

⁵William L. Hamilton, Rex Ying e Jure Leskovec. “Inductive Representation Learning on Large Graphs”. Em: [NeurIPS](#). 2017.

GraphSAGE

Algoritmo

Funções AGG comuns

- **Mean:** média dos vizinhos.
- **Pool:** max-pool de $\text{MLP}(h_u)$.
- **LSTM:** LSTM sobre vizinhos (com ordem aleatória, para preservar permutação).

Concatenação no update


GraphSAGE **concatena** h_v com a agregação, em vez de fundi-los como GCN. Isso preserva melhor a identidade do nó central.

Require: Grafo G , atributos X , K camadas, tamanhos $S_1, \dots, S_K$

```
1:  $h_v^{(0)} \leftarrow X_v$  para todo  $v$ 
2: for  $k = 1, \dots, K$  do
3:   for cada nó  $v$  no minibatch do
4:      $S_k(v) \leftarrow$  amostra de  $S_k$  vizinhos de  $\mathcal{N}(v)$ 
5:      $a_v^{(k)} \leftarrow \text{AGG}(\{h_u^{(k-1)} : u \in S_k(v)\})$ 
6:      $h_v^{(k)} \leftarrow \sigma(W^{(k)} [h_v^{(k-1)} \parallel a_v^{(k)}])$ 
7:      $h_v^{(k)} \leftarrow h_v^{(k)} / \|h_v^{(k)}\|_2$ 
8:   end for
9: end for
10: return  $\{h_v^{(K)}\}$ 
```

Neighbor Sampling, Visualmente

Árvore de computação de **um** nó v com $K = 2$ camadas e $S_1 = S_2 = 2$:



saída: $h_v^{(2)}$

camada 1: $S_1 = 2$ dos 4 vizinhos

camada 2: $S_2 = 2$ por nó amostrado

- Custo por nó: no máximo $1 + S_1 + S_1 S_2 = 7$ nós visitados, **independente de n** .
- A amostra é redesenhada a cada época: a variância extra também age como regularização.

Visão Geral

1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
- 9. Graph Attention Networks (GAT)**
10. Oversmoothing
11. Expressividade das GNNs
12. Tópicos Avançados

GAT

Vizinhos Não São Iguais⁶

GCN dá peso fixo $1/\sqrt{\tilde{d}_v \tilde{d}_u}$ a cada vizinho, depende só do grau. (Veličković et al., 2018) propõem **aprender** o peso a partir do conteúdo dos embeddings.

Coeficientes de atenção

$$e_{vu} = \text{LeakyReLU}(\mathbf{a}^\top [Wh_v \parallel Wh_u])$$

$$\alpha_{vu} = \text{softmax}_{u \in \mathcal{N}(v)}(e_{vu}) = \frac{\exp(e_{vu})}{\sum_{u' \in \mathcal{N}(v)} \exp(e_{vu'})}$$

$$h_v^{(k)} = \sigma \left(\sum_{u \in \mathcal{N}(v)} \alpha_{vu} Wh_u^{(k-1)} \right)$$

Os pesos α_{vu} dependem dos embeddings $\Rightarrow$ ajustam-se à tarefa.

⁶Petar Veličković et al. “Graph Attention Networks”. Em: [ICLR](#). 2018.

Multi-Head e Ligação com Transformers

Como em Transformers, **múltiplas cabeças** de atenção são empilhadas:

$$h_v^{(k)} = \parallel_{i=1}^H \sigma \left(\sum_{u \in \mathcal{N}(v)} \alpha_{vu}^{(i)} W^{(i)} h_u^{(k-1)} \right)$$

Na camada final costuma-se **tirar a média** das cabeças em vez de concatenar.

Multi-head dá ao modelo a chance de aprender diferentes “tipos de relação” entre vizinhos no mesmo nível.

Ligação com Transformers

- *Self-attention* é GAT em um **grafo completamente conectado** (cada token vê todos os tokens).
- GAT é o caso onde a estrutura do grafo **limita** a atenção aos vizinhos.
- Voltaremos a esse paralelo em Graph Transformers.

Exemplo Numérico: Coeficientes de Atenção em GAT

Nó v com 3 vizinhos. Após projeção, $Wh_v = (1, 0)$ e

$$Wh_{u_1} = (1, 0), \quad Wh_{u_2} = (0, 1), \quad Wh_{u_3} = (0.5, 0.5).$$

Vetor de atenção (parâmetro aprendido): $\mathbf{a} = (1, 0, 1, 0)$, de dimensão 4 ($2 \times$ a dos embeddings projetados, por causa da concatenação).

Scores $e_{v,u_k} = \mathbf{a}^\top [Wh_v \parallel Wh_{u_k}]$ (todos positivos, LeakyReLU é identidade):

$$e_{v,u_1} = (1, 0, 1, 0) \cdot (1, 0, 1, 0) = 2$$

$$e_{v,u_2} = (1, 0, 1, 0) \cdot (1, 0, 0, 1) = 1$$

$$e_{v,u_3} = (1, 0, 1, 0) \cdot (1, 0, 0.5, 0.5) = 1.5$$

Softmax sobre os scores:


$$\alpha \approx (0.51, 0.19, 0.31)$$

Embedding final de v

$$\begin{aligned} h_v^{\text{nov}} &= \sum_k \alpha_{v,u_k} Wh_{u_k} \\ &\approx 0.51 (1, 0) + 0.19 (0, 1) + 0.31 (0.5, 0.5) \\ &\approx (0.66, 0.34) \end{aligned}$$


u_1 (mais “parecido” com v na 1ª coordenada) recebe maior peso α .

Visualizando: Pesos Fixos (GCN) vs Aprendidos (GAT)



Peso $1/\sqrt{\tilde{d}_v \tilde{d}_u}$ depende **só dos graus**: igual para qualquer tarefa e entrada.

A espessura da aresta é o quanto cada vizinho “fala” na agregação.



Pesos α_{vu} do exemplo anterior: dependem do **conteúdo** dos embeddings.

Visão Geral


1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
- 10. Oversmoothing**
11. Expressividade das GNNs
12. Tópicos Avançados

O Fenômeno do *Oversmoothing*

Empilhar muitas camadas de message passing tende a fazer todos os nós convergirem para o **mesmo embedding**.

- Após K camadas, cada nó vê informação a K -hops.
- Em grafos pequenos (diâmetro $\leq K$), todos veem o grafo inteiro.
- Mensagens repetidas $\Rightarrow$ embeddings se misturam.


Resultado: GCN/GAT clássicos param de ganhar com mais de ~ 3 a 4 camadas; em alguns casos, pioram.



Tendência típica em GCN.

Visualizando o Oversmoothing

Cor do nó = embedding. O mesmo grafo após k camadas de média com os vizinhos:



A cada camada, cada nó vira uma média dos vizinhos: a **distância entre embeddings cai** até todos ficarem indistinguíveis (ilustração esquemática).

Mitigações

- **Skip connections** (estilo ResNet): $h_v^{(k)} = h_v^{(k-1)} + \text{GNN}^{(k)}(\dots)$.
- **Jumping Knowledge** (JK-Net): concatena ou faz max-pool das ativações de *todas* as camadas no final.
- **DropEdge**: descarta arestas aleatoriamente a cada época, análogo a dropout para a estrutura.
- **Normalização**: *LayerNorm*, *GraphNorm*, *PairNorm* ajudam a estabilizar magnitudes.
- **Atenção esparsa global** (Graph Transformers): rota mensagens de longo alcance sem precisar empilhar muitas camadas locais.

Trade-off central

Profundidade $\leftrightarrow$ *receptive field* $\leftrightarrow$ diversidade de embeddings. Não dá para maximizar os três simultaneamente.

Visão Geral

1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
- 11. Expressividade das GNNs**
12. Tópicos Avançados

Quão Poderosa é uma GNN?

Pergunta formal: que pares de grafos uma GNN consegue distinguir?

- Se duas estruturas produzem embeddings idênticos, a GNN não pode separá-las em nenhuma tarefa *downstream*.
- Algumas estruturas (e.g., contar triângulos, ciclos longos) são surpreendentemente difíceis para message passing puro.

Roteiro da seção

(i) Um teste clássico de isomorfismo, o **1-WL**; (ii) o resultado de que toda MPNN é **no máximo** tão poderosa quanto ele; (iii) um par de grafos concreto em que ambos falham; (iv) a arquitetura que **atinge** esse teto, a GIN.

Teste de Weisfeiler-Lehman (1-WL)

Heurística clássica (1968) para **testar isomorfismo de grafos**. Para cada nó v :

1. Inicialize com um rótulo $c_v^{(0)}$ (e.g., grau).
2. Em cada iteração ($\{\!\{ \cdot \}\!\}$ é um *multiset*: um conjunto que conta repetições):

$$c_v^{(k)} = \text{HASH}(c_v^{(k-1)}, \{\!\{ c_u^{(k-1)} : u \in \mathcal{N}(v) \}\!\})$$

3. Repita até estabilizar; compare os **multisets** de rótulos entre dois grafos. Diferentes $\Rightarrow$ não isomorfos; iguais $\Rightarrow$ **inconclusivo**.

Conexão com message passing

Compare a equação acima com a forma genérica **message-aggregate-update**. É **exatamente o mesmo padrão**, com HASH substituindo $U(\cdot, \text{AGG}(\cdot))$. WL é message passing com hash injetivo.

Exemplo: Rodando 1-WL à Mão

Dois grafos com 4 nós; rotulamos todos com $c_v^{(0)} = 1$ inicialmente.

G_1 : caminho




Iter 1, $\text{hash}(c_v, \{c_u\}_{u \in \mathcal{N}(v)})$:

- Nó 1: $\text{hash}(1, \{1\}) = A$
- Nó 2: $\text{hash}(1, \{1, 1\}) = B$
- Nó 3: $\text{hash}(1, \{1, 1\}) = B$
- Nó 4: $\text{hash}(1, \{1\}) = A$

Multiset: $\{A, A, B, B\}$

G_2 : triângulo + pendant



Iter 1:

- Nó 1: $\text{hash}(1, \{1, 1\}) = B$
- Nó 2: $\text{hash}(1, \{1, 1, 1\}) = C$
- Nó 3: $\text{hash}(1, \{1, 1\}) = B$
- Nó 4: $\text{hash}(1, \{1\}) = A$


Multiset: $\{A, B, B, C\}$

Multisets diferem $\Rightarrow$ 1-WL distingue G_1 e G_2 em uma única iteração.


Onde o 1-WL (e Toda MPNN) Falha

Dois grafos **não isomorfos** em que todo nó tem grau 2:

G_1 : ciclo de 6



G_2 : dois triângulos



Por que o teste empata

Em **toda** iteração, todo nó dos dois grafos computa o mesmo $\text{HASH}(c, \{c, c\})$: os multisets nunca diferem. Com atributos iguais, nenhuma GNN de message passing produz embeddings diferentes para G_1 e G_2 .

Consequência prática: MPNNs puras **não contam triângulos nem ciclos**.

GIN

Tão Poderoso Quanto WL⁷

(Xu et al., 2019) mostram:

- Toda GNN baseada em message passing é **no máximo tão poderosa** quanto o teste 1-WL.
- Para alcançar esse teto, AGG precisa ser **injetivo** sobre multisets.
- Soma é injetiva (a menos de medida zero); média e máximo **não são**.

Camada GIN


$$h_v^{(k)} = \text{MLP}^{(k)}\left((1 + \epsilon^{(k)}) h_v^{(k-1)} + \sum_{u \in \mathcal{N}(v)} h_u^{(k-1)}\right)$$

Soma + MLP $\Rightarrow$ injetividade. Em prática, GIN frequentemente vence GCN/GAT em tarefas de classificação de grafo.

⁷Keyulu Xu et al. "How Powerful are Graph Neural Networks?" Em: [ICLR](#). 2019.

Por Que Soma, e Não Média ou Máximo?

Dois nós com vizinhanças **diferentes**; todos os vizinhos carregam o mesmo atributo a :



$\{a, a\}$



$\{a\}$

AGG	v	v'	distingue?
média	a	a	não
máximo	a	a	não
soma	$2a$	a	sim

Média e máximo **descartam a multiplicidade** do multiset; a soma a preserva. É exatamente a injetividade que o teto 1-WL exige.

Visão Geral

1. Motivação
2. Por Que Grafos São Difíceis
3. Tarefas em Grafos
4. Datasets e Métricas
5. Embeddings de Nós: Antes das GNNs
6. Message Passing
7. Graph Convolutional Network (GCN)
8. GraphSAGE
9. Graph Attention Networks (GAT)
10. Oversmoothing
11. Expressividade das GNNs
- 12. Tópicos Avançados**

Graph Transformers

Motivação⁸

Message passing local tem dois limites estruturais:

- Mensagens de longo alcance exigem muitas camadas $\Rightarrow$ *oversmoothing*.
- *Bottlenecks* topológicos (*over-squashing*): metades do grafo se comunicam por poucas arestas.



Tudo entre as metades é espremido em **uma aresta**.

Ideia: atenção global, mas estruturada

Tratar cada nó como um *token* e aplicar *self-attention* sobre o grafo todo. Risco: perde-se a estrutura, é equivalente a um grafo completo.

Solução: injetar a estrutura via **positional encoding** ou **bias** de atenção.

⁸Ladislav Rampášek et al. "Recipe for a General, Powerful, Scalable Graph Transformer". Em: [NeurIPS](#). 2022.

Positional Encodings em Grafos

Em sequências, $PE(t)$ é função do índice t . Em grafos, não há índice canônico; precisamos de PEs invariantes à permutação:

- **Laplacian PE**: usar os k primeiros autovetores do Laplaciano $L = D - A$ como coordenadas espectrais. Capturam estrutura global do grafo.
- **Random Walk PE (RWPE)**: probabilidade de estar em v após t passos partindo de u (1 a T passos).
- **Shortest-path bias**: adicionar termo na atenção proporcional à distância $d(u, v)$ no grafo.

GPS (Rampášek et al., 2022)

Combina **message passing local** + **atenção global** + **PE**, em camadas paralelas. Vence vários benchmarks OGB.

Geração de Grafos

GraphRNN⁹

Tarefa: aprender uma distribuição $p(G)$ e amostrar grafos novos (e.g., moléculas com propriedades desejadas).

Abordagem autorregressiva de (You et al., 2018)

1. Defina uma ordem dos nós (BFS a partir de um nó aleatório).
 2. Para $i = 1, \dots, n$:
 - Gere o nó v_i via uma RNN “nó-a-nó”.
 - Para cada $j < i$, decida se a aresta (v_j, v_i) existe via uma segunda RNN “aresta-a-aresta”.
-
- Vantagem: trata a geração como sequência, reaproveita arquitetura RNN.
 - Desafio: a ordenação introduz viés. Modelos mais recentes (e.g., difusão sobre grafos) tentam contornar isso.

⁹Jiaxuan You et al. “GraphRNN: Generating Realistic Graphs with Deep Auto-Regressive Models”. Em: [ICML](#). 2018.

LLMs + Grafos

Tendência Atual

Linha de pesquisa em forte expansão (2023–2026):

- **Text-attributed graphs:** nós têm conteúdo textual (artigos, descrições de produto). LLM produz embeddings, GNN agrega via grafo.
- **GraphRAG:** extrair grafos de conhecimento de coleções de documentos para alimentar *retrieval-augmented generation*.
- **Reasoning sobre grafos com LLMs:** descrever o grafo em linguagem natural ou via tokens estruturais e deixar o LLM “raciocinar” sobre conexões.
- **Foundation models para grafos:** pré-treinar uma única GNN em muitos domínios e adaptar via *fine-tuning* ou *in-context learning*.

O curso Stanford CS224W dedica cerca de 3 aulas inteiras a esse tópico.

Aplicações em Destaque

- **AlphaFold** (Jumper et al., 2021): proteínas como grafos com message passing especializado; referência mundial em biologia computacional.
- **Descoberta de fármacos:** ogbg-molhiv e variantes, screening em escala industrial.
- **Recomendação:** PinSage (Pinterest), grafos usuário–item com bilhões de arestas.
- **Detecção de fraude:** redes de transações como grafos, detecção de comunidades suspeitas.

Onde aprofundar

- **Stanford CS224W** (Leskovec): curso semestral, vídeos públicos no YouTube.
- **OGB:** datasets, leaderboards e código de referência.
- **PyTorch Geometric (PyG)** e **DGL:** bibliotecas de implementação.
- **Hamilton**, Graph Representation Learning (livro 2020).

Resumo

- Grafos são domínio não-euclidiano sem ordem canônica; **permutação** é a simetria central.
- Tarefas: **node** / **link** / **graph classification**; transdutivo vs indutivo muda o que o modelo precisa.
- **OGB** é o benchmark padrão; **Hits@K** e **MRR** são as métricas específicas para link prediction.
- Quase toda GNN é uma instância de **message passing**: M , AGG, U .
- Modelos canônicos: **GCN** (média normalizada), **GraphSAGE** (indutivo + amostragem), **GAT** (atenção sobre vizinhos).
- **Oversmoothing** limita profundidade; mitigações: skip, JK, DropEdge, atenção global.
- **GIN** alcança o teto do teste 1-WL; soma + MLP é o que dá expressividade.
- **Graph Transformers** e **LLMs** + **grafos** são as fronteiras ativas atuais.

Leituras Recomendadas

- **Curso:** Stanford CS224W, *Machine Learning with Graphs* (Jure Leskovec). Slides e vídeos em `web.stanford.edu/class/cs224w`.
- **Livro:** Hamilton, *Graph Representation Learning* (2020), introdução acessível e abrangente.
- **Artigos seminais** (em ordem sugerida): GCN (Kipf e Welling, 2017); GraphSAGE (Hamilton, Ying e Leskovec, 2017); GAT (Veličković et al., 2018); MPNN (Gilmer et al., 2017); GIN (Xu et al., 2019).
- **Benchmark:** OGB (Hu et al., 2020), em `ogb.stanford.edu`.
- **Bibliotecas:** *PyTorch Geometric* (PyG) e *Deep Graph Library* (DGL).

Referências I

- [1] Justin Gilmer et al. “Neural Message Passing for Quantum Chemistry”. Em: [ICML](#). 2017, pp. 1263–1272.
- [2] Aditya Grover e Jure Leskovec. “node2vec: Scalable Feature Learning for Networks”. Em: [KDD](#). 2016, pp. 855–864.
- [3] William L. Hamilton, Rex Ying e Jure Leskovec. “Inductive Representation Learning on Large Graphs”. Em: [NeurIPS](#). 2017.
- [4] Weihua Hu et al. “Open Graph Benchmark: Datasets for Machine Learning on Graphs”. Em: [NeurIPS](#). 2020.
- [5] John Jumper et al. “Highly Accurate Protein Structure Prediction with AlphaFold”. Em: [Nature](#) 596 (2021), pp. 583–589.
- [6] Thomas N. Kipf e Max Welling. “Semi-Supervised Classification with Graph Convolutional Networks”. Em: [ICLR](#). 2017.
- [7] Bryan Perozzi, Rami Al-Rfou e Steven Skiena. “DeepWalk: Online Learning of Social Representations”. Em: [KDD](#). 2014, pp. 701–710.
- [8] Ladislav Rampásek et al. “Recipe for a General, Powerful, Scalable Graph Transformer”. Em: [NeurIPS](#). 2022.
- [9] Petar Veličković et al. “Graph Attention Networks”. Em: [ICLR](#). 2018.
- [10] Keyulu Xu et al. “How Powerful are Graph Neural Networks?” Em: [ICLR](#). 2019.
- [11] Jiaxuan You et al. “GraphRNN: Generating Realistic Graphs with Deep Auto-Regressive Models”. Em: [ICML](#). 2018.