

# Deep Learning

## Revisão de *Machine Learning*

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory  
PUCRS

junho de 2026

# Overview

---

1. Por que precisamos de Machine Learning?

2. Conceitos Básicos de *Machine Learning*

3. Modelos Lineares

3.1 Regressão Linear

3.2 Regressão Logística

## 1. Por que precisamos de Machine Learning?

## 2. Conceitos Básicos de *Machine Learning*

## 3. Modelos Lineares

3.1 Regressão Linear

3.2 Regressão Logística

# A importância de Machine Learning

---

- “A breakthrough in machine learning would be worth ten Microsofts” (Bill Gates)
- “Machine learning is the next Internet” (Tony Tether, Director, DARPA)
- “Machine learning is going to result in a real revolution” (Greg Papadopoulos, Former CTO, Sun)
- “Machine learning is today’s discontinuity” (Jerry Yang, Founder, Yahoo)
- “Machine learning is the new electricity” (Andrew NG, Stanford Professor and Coursera founder)

## *Software sem Machine Learning*

---

É uma sequência de instruções que:

- Recebe uma entrada
- Realiza um processamento
- Retorna uma saída

## *Software sem Machine Learning*

### Exemplo

---

1. Se você ou o seu oponente tiverem dois em sequência, jogue no espaço restante
2. Caso contrário, se existir um movimento que crie duas sequencias de dois, faça essa jogada
3. Caso contrário, se o centro estiver vazio, jogue no centro
4. Caso contrário, se o seu oponente jogou em um canto, jogue no canto oposto
5. Caso contrário, se houver um canto livre jogue nesse canto
6. Caso contrário, jogue em uma posição vazia qualquer

# Algumas vezes não sabemos como resolver

---

- Complexidade de Tempo
- Complexidade de Espaço
- Complexidade “Humana”



# E no Aprendizado de Máquina?

---

- Mesmo quando não é possível criar um algoritmo para resolver o problema diretamente, pode ser possível criar algoritmos que *encontram padrões*
- Usamos raciocínio **indutivo** para resolver os problemas

## Definição de *Machine Learning*

“A computer program is said to learn from experience **E** with respect to some class of tasks **T** and performance measure **P**, if its performance at tasks in **T**, as measured by **P**, improves with experience **E**” (Mitchell, 1997)



# Tipos de Raciocínio

---

- **Dedutivo**

- Assumindo algumas premissas, a conclusão obrigatoriamente segue

- **Não-dedutivo**

- **Abdução**

- “Raciocínio do Detetive”

- **Indução**

- Dadas observações (limitadas em escopo e quantidade), podemos chegar a conclusões plausíveis

## Exemplo de Dedução

- Premissa 1: Todos os humanos são mortais
- Premissa 2: Sócrates é humano
- Conclusão: Sócrates é mortal

# Tipos de Raciocínio

- **Dedutivo**

- Assumindo algumas premissas, a conclusão obrigatoriamente segue

- **Não-dedutivo**

- **Abdução**


- “Raciocínio do Detetive”

- **Indução**

- Dadas observações (limitadas em escopo e quantidade), podemos chegar a conclusões plausíveis

## Exemplo de Abdução

- Tem restos de frango assado pelo chão
- O cachorro está com restos de frango no pelo, especialmente ao redor da boca
- Logo, o cachorro comeu o frango assado



# Tipos de Raciocínio

- **Dedutivo**

- Assumindo algumas premissas, a conclusão obrigatoriamente segue

- **Não-dedutivo**

- **Abdução**

- “Raciocínio do Detetive”


- **Indução**

- Dadas observações (limitadas em escopo e quantidade), podemos chegar a conclusões plausíveis

## Exemplo de Indução

Qual o próximo número na sequência abaixo?

1, 3, 5, 7, x



# Tipos de Raciocínio

- **Dedutivo**

- Assumindo algumas premissas, a conclusão obrigatoriamente segue

- **Não-dedutivo**

- **Abdução**

- “Raciocínio do Detetive”

- **Indução**

- Dadas observações (limitadas em escopo e quantidade), podemos chegar a conclusões plausíveis

## Exemplo de Indução

Qual o próximo número na sequência abaixo?

1, 3, 5, 7, **217341**

$$f(x) = \frac{18111}{2}x^4 - 90555x^3 + \frac{633885}{2}x^2 - 452773x + 217331$$



1. Por que precisamos de Machine Learning?

2. Conceitos Básicos de *Machine Learning*

3. Modelos Lineares

3.1 Regressão Linear

3.2 Regressão Logística

# Desenvolvimento de uma aplicação com AM

---

O projeto de um sistema que usa *Machine Learning* pode ser descrito pela figura abaixo<sup>1</sup>




Figura: Representação simplificada do processo de *Machine Learning*. Adaptado de (Braga-Neto, 2020)

---

<sup>1</sup>Fluxos diferentes existem na literatura de *Knowledge Discovery in Databases* e em Mineração de Dados.

# Desenvolvimento de uma aplicação com AM

## Experimental Design

- Modelar o problema como uma tarefa de *Machine Learning*
- Como você definiria o problema de treinar um reconhecedor de rostos que é capaz de reconhecer 100 pessoas diferentes?
  - Como um problema de **classificação multiclasse** com 100 classes será muito difícil coletar uma base dados grande o bastante
  - Como um problema de **classificação binário** onde o sistema recebe um par de imagens é mais fácil coletar dados




Figura: Representação simplificada do processo de *Machine Learning*. Adaptado de (Braga-Neto, 2020)

# Desenvolvimento de uma aplicação com AM

---

## Data Collection

- É possível coletar dados que sejam representativos do problema em questão?
- Existe algum dataset aberto que pode nos auxiliar?
- Quando a coleta de dados ou a anotação é cara, existem alternativas?




Figura: Representação simplificada do processo de *Machine Learning*. Adaptado de (Braga-Neto, 2020)



# Desenvolvimento de uma aplicação com AM

## Dimensionality Reduction

- Todos os atributos coletados são úteis para resolver a tarefa?
- Como selecionar apenas os atributos relacionados a variável alvo?
- Existem formas de criar novos atributos que sejam melhores preditores para a variável alvo?
- Posso resumir meus atributos em um espaço menor?




Figura: Representação simplificada do processo de *Machine Learning*. Adaptado de (Braga-Neto, 2020)

# Desenvolvimento de uma aplicação com AM

---

## Predictor Design

- Existe algum modelo cujo viés indutivo seja aderente ao meu problema?
- Qual será a métrica utilizada para avaliação do desempenho do modelo?
- Qual meu *budget* computacional?
- Qual a melhor hiperparametrização dos modelos selecionados?




Figura: Representação simplificada do processo de *Machine Learning*. Adaptado de (Braga-Neto, 2020)

# Desenvolvimento de uma aplicação com AM

---

## Error Estimation

- Meu modelo treinado generaliza?
- Qual é o erro esperado do meu modelo para novos dados?
- Coletar mais dados pode melhorar meus resultados?




Figura: Representação simplificada do processo de *Machine Learning*. Adaptado de (Braga-Neto, 2020)

# Tipos de Aprendizado

---

- **Supervisionado**

- Dados de treino possuem rótulos
- *Exemplo:* classificar fotos como gato ou cachorro a partir de 10 mil imagens rotuladas

- **Não Supervisionado**

- Dados de treino não possuem rótulos
- *Exemplo:* agrupar clientes em segmentos a partir do histórico de compras, sem rótulos

- **Semi Supervisionado**

- Alguns dados de treino possuem rótulo outros não
- *Exemplo:* detecção de fraude com poucas transações rotuladas e milhões sem rótulo

- **Aprendizado por Reforço**

- Agente recebe “recompensa” devido a uma série de ações
- *Exemplo:* AlphaGo aprende a jogar Go ganhando recompensa ao final da partida

- **Auto Supervisionado**

- Parte das entradas servem como “supervisão”
- *Exemplo:* pré-treino do BERT prevendo palavras mascaradas em uma frase

# Notação

---

Considerando um dataset formado por exemplos de uma relação  $(X^{(i)}, y^{(i)})$

- $X$  é nossa matriz de atributos  $N \times M$  onde  $N$  é o número de instâncias e  $M$  é o número de atributos indexada por  $X_m^{(n)}$
- $y$  é nossa variável alvo  $N \times 1$
- Objetivo é estimar  $y^{(i)}$  para uma instância desconhecida  $X^{(i)}$ 
  - Quando  $y^{(i)}$  é uma variável discreta: *Problema de Classificação*
  - Quando  $y^{(i)}$  é uma variável contínua: *Problema de Regressão*

# Viés Indutivo

---




Figura: Regressão Linear




Figura: SVM




Figura: Árvore de Decisão




Figura: *Random Forest*

## Efeito tesoura (*Scissor Effect*)

- Quando temos um conjunto de dados pequeno, regras de classificação mais simples tendem a obter erros de classificação menores
- Quando temos um conjunto de dados grande, regras de classificação mais complexas tendem a obter erros menores





Figura: Adaptado de (Braga-Neto, 2020)

## Efeito tesoura, exemplo numérico



Em  $x = 6$ : reta prediz 12,1 (acerta), polinômio prediz 27,5 (erra muito).




Figura: Adaptado de (Braga-Neto, 2020)



# Trade-off Viés-Variância




Figura: Adaptado de (Braga-Neto, 2020).

## Decomposição

$$\text{Erro}_{\text{teste}}(x) = \text{Viés}^2(x) + \text{Variância}(x) + \sigma^2$$

- **Viés alto:** modelo simples demais, não captura o padrão.
- **Variância alta:** modelo sensível à amostra de treino.
- **Ruído ( $\sigma^2$ ):** limite irreduzível.

Derivação completa em *Regularização* (Aula 07).

1. Por que precisamos de Machine Learning?

2. Conceitos Básicos de *Machine Learning*

### 3. Modelos Lineares

3.1 Regressão Linear

3.2 Regressão Logística

# Modelos Lineares

---

- Modelos lineares baseados em variações dos Método dos Mínimos Quadrados talvez sejam o tipo de modelo mais estudado por todas as áreas do conhecimento.
- Faremos uma breve revisão com viés de *Machine Learning*

# Intuição

---

Queremos ajustar um *hiperplano*<sup>1</sup> aos nossos dados

$$\hat{y} = X_1 \cdot \theta_1 + \theta_0$$

---

<sup>1</sup>No  $\mathcal{R}^2$  um hiperplano é equivalente a uma reta


# Intuição

Queremos ajustar um *hiperplano*<sup>1</sup> aos nossos dados

$$\hat{y} = X_1 \cdot \theta_1 + \theta_0$$

| X | y  |
|---|----|
| 1 | 20 |
| 2 | 10 |
| 3 | 30 |

Tabela:  
Conjunto  
de Dados



## Hipótese 1

$$\theta_0 = 20, \theta_1 = 0$$

$$\hat{y} = 0X_1 + 20$$

## Hipótese 2

$$\theta_0 = 15, \theta_1 = 5$$

$$\hat{y} = 5X_1 + 15$$

<sup>1</sup>No  $\mathcal{R}^2$  um hiperplano é equivalente a uma reta


# Intuição

Qual é a melhor hipótese?

$$J_{\text{SSR}} = \sum_{i=1}^N \left( \hat{y}^{(i)} - y^{(i)} \right)^2$$

| X | y  |
|---|----|
| 1 | 20 |
| 2 | 10 |
| 3 | 30 |

Tabela:  
Conjunto  
de Dados



## Hipótese 1

$$\theta_0 = 20, \theta_1 = 0$$

$$\hat{y} = 0X_1 + 20$$

## Hipótese 2

$$\theta_0 = 15, \theta_1 = 5$$

$$\hat{y} = 5X_1 + 15$$


# Intuição

Qual é a melhor hipótese?

$$J_{SSR} = \sum_{i=1}^N \left( \hat{y}^{(i)} - y^{(i)} \right)^2$$

| X | y  |
|---|----|
| 1 | 20 |
| 2 | 10 |
| 3 | 30 |

Tabela:  
Conjunto  
de Dados



## ✓ Hipótese 1

$$\theta_0 = 20, \theta_1 = 0$$

$$\hat{y} = 0X_1 + 20$$

$$J_{SSR} = (20 - 20)^2 + (10 - 20)^2 + (30 - 20)^2 = 200$$

## ✗ Hipótese 2

$$\theta_0 = 15, \theta_1 = 5$$

$$\hat{y} = 5X_1 + 15$$

$$J_{SSR} = (20 - 20)^2 + (10 - 25)^2 + (30 - 30)^2 = 225$$

# Treinamento

---

Como encontrar a melhor hipótese?

- $\operatorname{argmin}_{\theta_0, \theta_1} [J_{\text{SSR}}]$
- $J_{\text{SSR}} = \sum_{i=1}^N (\hat{y}^{(i)} - y^{(i)})^2 = (\hat{y} - y)^\top (\hat{y} - y)$
- $\hat{y} = X_1 \cdot \theta_1 + \theta_0$

| $X_1$ | $y$ |            |            |
|-------|-----|------------|------------|
| 1     | 20  | $\theta_0$ | $\theta_1$ |
| 2     | 10  |            |            |
| 3     | 30  |            |            |



## Notation Trick

---

- Colocamos o parâmetro livre junto do vetor  $\theta$  fazendo um *truque de notação*
- Imagine que existe um novo atributo cujo valor é 1 para todas as instâncias
- Assim todos os parâmetros treináveis podem ser tratados da mesma forma.
- $\hat{y} = X\theta$

| $X_0$        | $X_1$ |              |              |
|--------------|-------|--------------|--------------|
| 1            | 1     | $y$          | $\theta$     |
| 1            | 2     | 20           | $\theta_0$   |
| 1            | 3     | 10           | $\theta_1$   |
|              |       | 30           |              |
| $N \times M$ |       | $N \times 1$ | $M \times 1$ |

# Treinamento

Como encontrar a melhor hipótese?

- $\operatorname{argmin}_{\theta_0, \theta_1} [J_{\text{SSR}}]$
- $J_{\text{SSR}} = \sum_{i=1}^N (\hat{y}^{(i)} - y^{(i)})^2 = (\hat{y} - y)^\top (\hat{y} - y)$
- $\hat{y} = X\theta$

| $X_0$        | $X_1$ | $y$          | $\theta$     |
|--------------|-------|--------------|--------------|
| 1            | 1     | 20           | $\theta_0$   |
| 1            | 2     | 10           | $\theta_1$   |
| 1            | 3     | 30           |              |
| $N \times M$ |       | $N \times 1$ | $M \times 1$ |

Sabendo que..

- A soma dos quadrados dos resíduos é uma *função de custo convexa* para o problema da regressão linear
- Logo, *possui apenas um mínimo*
- Podemos utilizar o gradiente da função de custo em um processo iterativo de otimização

# Treinamento

---

Vamos derivar  $J_{\text{SSR}}$  em relação a  $\theta$  e igualar a 0

$$\begin{aligned}\frac{\partial J_{\text{SSR}}}{\partial \theta} &= \frac{\partial ((\hat{y} - y)^\top (\hat{y} - y))}{\partial \theta} \\&= \frac{\partial (\hat{y}^\top \hat{y} - \hat{y}^\top y - y^\top \hat{y} + y^\top y)}{\partial \theta} \\&= \frac{\partial (\hat{y}^\top \hat{y} - 2\hat{y}^\top y + y^\top y)}{\partial \theta} \\&= \frac{\partial (\boldsymbol{\theta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\theta} - 2\boldsymbol{\theta}^\top \mathbf{X}^\top y + y^\top y)}{\partial \theta} \\&= \frac{\partial (\boldsymbol{\theta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\theta})}{\partial \theta} - \frac{\partial (2\boldsymbol{\theta}^\top \mathbf{X}^\top y)}{\partial \theta} \\&= 2\mathbf{X}^\top \mathbf{X} \boldsymbol{\theta} - 2\mathbf{X}^\top y \\&= 2\mathbf{X}^\top (\mathbf{X} \boldsymbol{\theta} - y)\end{aligned}$$

Vamos derivar  $J_{SSR}$  em relação a  $\theta$  e igualar a 0

$$2X^T(X\theta - y) = 0$$

$$X^T(X\theta - y) = 0$$

$$X^TX\theta - X^Ty = 0$$

$$X^TX\theta = X^Ty$$

$$\theta = (X^TX)^{-1}X^Ty$$

## Solução analítica para $\theta$

---

$$\theta = (X^T X)^{-1} X^T y$$

$$\left( \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 2 & 3 \\ \hline \end{array} \right)_{M \times N} \times \begin{array}{|c|c|} \hline 1 & 1 \\ \hline 1 & 2 \\ \hline 1 & 3 \\ \hline \end{array}_{N \times M} \Big)^{-1} \times \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 2 & 3 \\ \hline \end{array}_{M \times N} \times \begin{array}{|c|} \hline 20 \\ \hline 10 \\ \hline 30 \\ \hline \end{array}_{N \times 1} = \theta_{M \times 1}$$

## Solução analítica para $\theta$

---

$$\theta = (X^T X)^{-1} X^T y$$

$$\left( \begin{array}{|c|c|} \hline 3 & 6 \\ \hline 6 & 14 \\ \hline \end{array} \right)_{M \times M}^{-1} \times \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 2 & 3 \\ \hline \end{array}_{M \times N} \times \begin{array}{|c|} \hline 20 \\ \hline 10 \\ \hline 30 \\ \hline \end{array}_{N \times 1} = \theta_{M \times 1}$$

## Solução analítica para $\theta$

---

$$\theta = (X^T X)^{-1} X^T y$$

$$\begin{array}{|c|c|} \hline 2.33 & -1 \\ \hline -1 & 0.5 \\ \hline \end{array} \underset{M \times M}{\times} \begin{array}{|c|c|c|} \hline 1 & 1 & 1 \\ \hline 1 & 2 & 3 \\ \hline \end{array} \underset{M \times N}{\times} \begin{array}{|c|} \hline 20 \\ \hline 10 \\ \hline 30 \\ \hline \end{array} \underset{N \times 1}{\times} = \underset{M \times 1}{\theta}$$

## Solução analítica para $\theta$

---

$$\theta = (X^T X)^{-1} X^T y$$

$$\begin{array}{|c|c|c|} \hline 1.33 & 0.333 & -0.666 \\ \hline -0.5 & 0 & 0.5 \\ \hline \end{array} \underset{M \times N}{\times} \begin{array}{|c|} \hline 20 \\ \hline 10 \\ \hline 30 \\ \hline \end{array} \underset{N \times 1}{=} \underset{M \times 1}{\theta}$$



## Solução analítica para $\theta$

---

$$\theta = (X^T X)^{-1} X^T y$$

$$\begin{array}{|c|} \hline 10 \\ \hline 5 \\ \hline \end{array} = \underset{M \times 1}{\theta}$$


### Sobre a solução analítica para $\theta$

- Esse é o vetor de pesos que minimiza a soma dos quadrados dos resíduos ( $J_{SSR}$ ).
- Repare que existe uma operação de inversão da matrix  $X^T X$ . Essa operação gera um custo computacional  $O(n^3)$  em relação a quantidade de atributos do problema
- Esse custo pode inviabilizar a solução analítica

# Qual é a melhor hipótese?

| X | y  |
|---|----|
| 1 | 20 |
| 2 | 10 |
| 3 | 30 |

Tabela:  
Conjunto  
de Dados



## ❌ Hipótese 1

$$\theta_0 = 20, \theta_1 = 0, \hat{y} = 0X_1 + 20$$

$$J_{SSR} = (20 - 20)^2 + (10 - 20)^2 + (30 - 20)^2 = 200$$

## ❌ Hipótese 2

$$\theta_0 = 15, \theta_1 = 5, \hat{y} = 5X_1 + 15$$

$$J_{SSR} = (20 - 20)^2 + (10 - 25)^2 + (30 - 30)^2 = 225$$

## ✅ Hipótese 3

$$\theta_0 = 10, \theta_1 = 5, \hat{y} = 5X_1 + 10$$

$$J_{SSR} = (20 - 15)^2 + (10 - 20)^2 + (30 - 25)^2 = 150$$

# Descida de Gradiente

---

- Algoritmo Iterativo
- $\theta_{t+1} = \theta_t - \eta \nabla_J$
- $\theta_0$  inicializado com valores aleatórios
- $\eta \in (0, 1]$  taxa de aprendizado
- Valores típicos para  $\eta$  são  $10^{-3}$ ,  $10^{-4}$  ou  $10^{-5}$

# Descida de Gradiente

---

- Ao lado temos um algoritmo para *Batch Gradient Descent*
- Se selecionarmos apenas uma instância  $X^{(i)}$  para estimar o valor do gradiente teremos o *Stochastic Gradient Descent*
- A diferença entre  $J_{SSR}$  de diferentes iterações pode ser usado como condição de convergência

**Require:**  $X_{n \times m}$  matriz de instâncias

**Require:**  $y_{n \times 1}$  variável alvo

**Require:**  $\eta \in (0, 1]$  taxa de aprendizado

```
1: procedure GRADIENT DESCENT
2:    $\theta \sim \mathcal{N}(0, 1)$ 
3:   repeat
4:      $\theta \leftarrow \theta - \eta X^\top (X\theta - y)$ 
5:      $\hat{y} \leftarrow X\theta$ 
6:      $J_{SSR} \leftarrow (y - \hat{y})^\top (y - \hat{y})$ 
7:   until Condição de convergência
8:   return  $\theta$ 
9: end procedure
```

# Descida de Gradiente

---

| Descida de Gradiente                                    | Equação Normal                        |
|---------------------------------------------------------|---------------------------------------|
| $\theta_{t+1} = \theta_t - \eta X^\top (X\theta_t - y)$ | $\theta = (X^\top X)^{-1} X^\top y$   |
| solução iterativa                                       | solução analítica                     |
| Possui o hiperparâmetro $\eta$                          | Sem hiperparâmetros                   |
| arbitrariamente próxima ao melhor $\theta$              | encontra exatamente o melhor $\theta$ |
| $O(i \cdot n)$ em implementações vetoriais              | $O(m^3)$                              |

# Como aplicar Regressão Linear para Classificação?

---

A *imagem* da Regressão Linear é incompatível com uma classificação

- $p(\hat{y}^{(i)} = c | X^{(i)}) \in [0, 1]$
- $X^{(i)}\theta \in (-\infty, +\infty)$

Precisamos encontrar algum valor relacionado a probabilidade de pertencimento a uma classe  $p(\hat{y}^{(i)} = c | X^{(i)})$  que tenha um contradomínio similar a Regressão Linear  $X^{(i)}\theta$

# Como aplicar Regressão Linear para Classificação?

---

- $p(\hat{y}^{(i)} = c | X^{(i)}) \in [0, 1]$ : probabilidade de pertencimento a classe  $c$
- $\frac{p(\hat{y}^{(i)} = c | X^{(i)})}{1 - p(\hat{y}^{(i)} = c | X^{(i)})} \in [0, +\infty)$ : chance de pertencimento a classe  $c$
- $\ln \left( \frac{p(\hat{y}^{(i)} = c | X^{(i)})}{1 - p(\hat{y}^{(i)} = c | X^{(i)})} \right) \in (-\infty, +\infty)$ : log da chance de pertencimento a classe  $c$ :

# Como aplicar Regressão Linear para Classificação?

---

- $p(\hat{y}^{(i)} = c | X^{(i)}) \in [0, 1]$ : probabilidade de pertencimento a classe  $c$
- $\frac{p(\hat{y}^{(i)} = c | X^{(i)})}{1 - p(\hat{y}^{(i)} = c | X^{(i)})} \in [0, +\infty)$ : chance de pertencimento a classe  $c$
- $\ln \left( \frac{p(\hat{y}^{(i)} = c | X^{(i)})}{1 - p(\hat{y}^{(i)} = c | X^{(i)})} \right) \in (-\infty, +\infty)$ : log da chance de pertencimento a classe  $c$ :



# Como aplicar Regressão Linear para Classificação?

---

- $p(\hat{y}^{(i)} = c | X^{(i)}) \in [0, 1]$ : probabilidade de pertencimento a classe  $c$
- $\frac{p(\hat{y}^{(i)} = c | X^{(i)})}{1 - p(\hat{y}^{(i)} = c | X^{(i)})} \in [0, +\infty)$ : chance de pertencimento a classe  $c$
- $\ln \left( \frac{p(\hat{y}^{(i)} = c | X^{(i)})}{1 - p(\hat{y}^{(i)} = c | X^{(i)})} \right) \in (-\infty, +\infty)$ : log da chance de pertencimento a classe  $c$ :

## Aplicando Regressão Linear para estimar o log das chances

---

$$\ln \left( \frac{p(\hat{y}^{(i)} = c | X^{(i)})}{1 - p(\hat{y}^{(i)} = c | X^{(i)})} \right) = X^{(i)} \theta$$

$$\frac{p(\hat{y}^{(i)} = c | X^{(i)})}{1 - p(\hat{y}^{(i)} = c | X^{(i)})} = e^{X^{(i)} \theta}$$

$$p(\hat{y}^{(i)} = c | X^{(i)}) = e^{X^{(i)} \theta} (1 - p(\hat{y}^{(i)} = c | X^{(i)}))$$

$$p(\hat{y}^{(i)} = c | X^{(i)}) + p(\hat{y}^{(i)} = c | X^{(i)}) e^{X^{(i)} \theta} = e^{X^{(i)} \theta}$$

$$p(\hat{y}^{(i)} = c | X^{(i)}) (1 + e^{X^{(i)} \theta}) = e^{X^{(i)} \theta}$$

$$p(\hat{y}^{(i)} = c | X^{(i)}) = \frac{e^{X^{(i)} \theta}}{(1 + e^{X^{(i)} \theta})} = \frac{1}{e^{-X^{(i)} \theta} (1 + e^{X^{(i)} \theta})}$$

$$p(\hat{y}^{(i)} = c | X^{(i)}) = \frac{1}{(1 + e^{-X^{(i)} \theta})}$$

# Regressão Logística

---

- Ao adaptar a Regressão Linear para a tarefa de classificação binária obtemos a Regressão Logística
- $\hat{y} = \frac{1}{(1+e^{-X^{(i)}\theta})}$
- Precisamos de uma nova função de custo
  - $J_{SSR}$  não é convexo para a Regressão Logística
  - $J_{BCE} = -\frac{1}{N} \sum_{i=1}^N \left[ y^{(i)} \ln \hat{y}^{(i)} + (1 - y^{(i)}) \ln (1 - \hat{y}^{(i)}) \right]$

# Treinamento

---

Vamos derivar  $J_{\text{BCE}}$  em relação aos  $\theta$

$$\begin{aligned}\frac{\partial J_{\text{BCE}}}{\partial \theta} &= \frac{\partial (-y \ln \hat{y} - (1 - y) \ln (1 - \hat{y}))}{\partial \theta} \\&= -\frac{\partial (y \ln \hat{y})}{\partial \theta} - \frac{\partial ((1 - y) \ln (1 - \hat{y}))}{\partial \theta} \\&= -y \frac{\partial (\ln \hat{y})}{\partial \theta} - (1 - y) \frac{\partial \ln (1 - \hat{y})}{\partial \theta} \\&= -y \frac{\partial (\ln \hat{y})}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial \theta} - (1 - y) \frac{\partial \ln (1 - \hat{y})}{\partial \hat{y}} \frac{\partial \hat{y}}{\partial \theta} \\&= -X^\top y \frac{1}{\hat{y}} \hat{y} (1 - \hat{y}) - X^\top (1 - y) \left( -\frac{1}{1 - \hat{y}} \right) \hat{y} (1 - \hat{y}) \\&= X^\top (-y + y\hat{y} + \hat{y} - \hat{y}y) \\&= X^\top (\hat{y} - y)\end{aligned}$$

# Regressão Logística

---

- Função de Custo  $J_{\text{BCE}}$  é convexa, mas não admite solução analítica
- O gradiente tem exatamente a mesma forma da Regressão Linear
- Gera uma fronteira de decisão linear (hiperplano) no espaço de atributos

# Leituras Recomendadas

---

- Seções 3.1 a 3.3 de: Y.S. Abu-Mostafa, M. Magdon-Ismail e H.T. Lin. Learning from Data: A Short Course. AMLBook.com, 2012. ISBN: 978-1-60049-006-4

# Referências

---

- [1] Y.S. Abu-Mostafa, M. Magdon-Ismail e H.T. Lin. Learning from Data: A Short Course. AMLBook.com, 2012. ISBN: 978-1-60049-006-4.
- [2] U. Braga-Neto. Fundamentals of Pattern Recognition and Machine Learning. Springer International Publishing AG, 2020. ISBN: 978-3-030-27655-3.
- [3] T.M. Mitchell. Machine Learning. McGraw-Hill International Editions. McGraw-Hill, 1997. ISBN: 978-0-07-115467-3.