

Deep Learning

LSTMs e GRUs

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory
PUCRS

maio de 2026

Overview

1. Problemas em Redes Recorrentes

2. LSTMs

3. GRUs

4. Referências

Overview

1. Problemas em Redes Recorrentes

2. LSTMs

3. GRUs


4. Referências

Memória de Curto Prazo

- Considere a frase a seguir, em que existe uma quebra de sentimento entre as duas partes:
- *“O filme é péssimo e ninguém deveria perder tempo assistindo. Contudo eu admiro a tentativa de Hollywood de aumentar a representatividade em termos de história e atores, certamente será possível colher frutos sobre essa tentativa em outras obras no futuro.”*
- Para classificar o sentimento global, a rede precisa lembrar do início da frase quando chega ao final.
- Com uma RNN simples, esse tipo de **dependência de longo alcance** é difícil de manter.

Estado Interno é Sobrescrito a Cada Passo

- Em uma RNN *vanilla*, o estado interno h_t é totalmente recalculado a cada passo de tempo.



- Em cada célula a entrada **atualiza completamente** o estado.
- Manter informação por muitos passos de tempo é difícil, esse é o problema da **memória de curto prazo**.

Solução: Aprender Quando Atualizar e Quando Esquecer

- A ideia é deixar a própria rede aprender, a cada passo, quanta informação anterior deve ser mantida e quanta informação nova deve entrar no estado.
- Essa é a motivação da arquitetura *Long Short-Term Memory*¹ (LSTM).
- É a arquitetura com mais “partes” que veremos até agora, mas todas as partes se reduzem a operações já conhecidas:
 - multiplicação de matrizes,
 - funções de ativação (sigmoid, tanh),
 - operações ponto a ponto (soma, multiplicação).

¹Sepp Hochreiter e Jürgen Schmidhuber. “Long short-term memory”. Em: [Neural Computation](#) 9.8 (1997), pp. 1735–1780.

Overview

1. Problemas em Redes Recorrentes


2. LSTMs

3. GRUs

4. Referências


Revisitando RNNs

- Em uma RNN *vanilla* o estado oculto h_{t-1} é combinado com a entrada x_t por uma camada densa com ativação $\tanh$.
- Repare que dentro da célula recorrente existe “uma rede densa”.
- A LSTM mantém essa ideia, porém com mais camadas internas e um caminho separado para a memória de longo prazo.



Visão Geral da Célula LSTM

- A célula carrega **dois** sinais ao longo do tempo: o estado oculto h_t (*hidden state*) e a memória de longo prazo c_t (*cell state*).
- No diagrama, a linha **superior** conduz c_t e a **inferior** conduz h_t .
- *Gates* (camadas densas com *sigmoid*, saída em $[0, 1]$) controlam o quanto de cada informação é mantido, atualizado ou exposto, multiplicando vetores ponto a ponto.



 camada densa  operação ponto a ponto

 transferência de vetor

 concatenação

Quatro Camadas Densas Dentro da Célula


- Dentro da célula LSTM existem **quatro** camadas densas que recebem $[h_{t-1}, x_t]$:
 - três delas funcionam como *gates*, com ativação *sigmoid*:
 - *forget gate* (f_t): decide o quanto da memória c_{t-1} deve ser **esquecido**.
 - *input gate* (i_t): decide quais partes da nova informação devem **atualizar** a memória.
 - *output gate* (o_t): decide quais partes da memória devem **compor** o novo estado oculto.
 - a quarta camada usa $\tanh$ e produz uma proposta de atualização $\tilde{c}_t$ para a memória.
- As três *gates* aprendem a regular o fluxo de informação ao longo do tempo.

Forget Gate

- Decide quanto da memória c_{t-1} deve ser esquecida.
- Recebe $[h_{t-1}, x_t]$, passa por uma camada densa e por uma *sigmoid*:

$$f_t = \sigma(\theta_f [h_{t-1}, x_t] + b_f)$$

- $f_t \in [0, 1]$, multiplica c_{t-1} ponto a ponto.
 - $f_t \approx 1$: mantém a memória.
 - $f_t \approx 0$: esquece.
- No exemplo do filme, o *forget gate* pode aprender a **manter** o sinal de “péssimo” enquanto a segunda parte da frase é processada.




Atualização da Memória c_t

- A nova memória combina o que foi mantido da anterior com a nova proposta filtrada:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

- O símbolo $\odot$ indica multiplicação ponto a ponto (*Hadamard*).
- Repare que c_t tem uma rota direta no tempo, sem ativação não linear no caminho principal.
 - Isso ajuda a mitigar o *vanishing gradient*.



Por que a LSTM Preserva o Gradiente

- Na RNN *vanilla*, o gradiente entre passos distantes acumula um **produto** de fatores que saturam:

$$\frac{\partial h_t}{\partial h_{t-1}} \propto \theta_{hh} (1 - \tanh^2(z_t)) \quad \Rightarrow \quad \prod_k \theta_{hh} (1 - \tanh^2(z_k))$$

- Como $1 - \tanh^2 \leq 1$, esse produto tende a **desaparecer** em sequências longas.
- Na LSTM, a memória tem uma rota direta no tempo, $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$. Pelo **caminho direto**:

$$\frac{\partial c_t}{\partial c_{t-1}} = f_t \quad \Rightarrow \quad \prod_k f_k$$

- Nesse caminho não há $\tanh'$ repetido nem multiplicação por matrizes, apenas a porta f_k e uma **soma**.
- Quando o *forget gate* aprende $f_k \approx 1$, o gradiente é preservado por muitos passos (*constant error carousel*). As demais rotas, pelas *gates*, contribuem com termos menores.


Output Gate e Estado Oculto h_t

- Decide quais partes da memória devem ser **expostas** no estado oculto:

$$o_t = \sigma(\theta_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \odot \tanh(c_t)$$

- h_t é o que sai da célula a cada passo, e também alimenta a próxima célula.
- c_t continua circulando como memória de longo prazo, em paralelo a h_t .



Resumo das Equações da LSTM

<i>Forget gate</i>	$f_t = \sigma(\theta_f [h_{t-1}, x_t] + b_f)$
<i>Input gate</i>	$i_t = \sigma(\theta_i [h_{t-1}, x_t] + b_i)$
Candidato $\tilde{c}_t$	$\tilde{c}_t = \tanh(\theta_c [h_{t-1}, x_t] + b_c)$
Memória c_t	$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$
<i>Output gate</i>	$o_t = \sigma(\theta_o [h_{t-1}, x_t] + b_o)$
Estado oculto h_t	$h_t = o_t \odot \tanh(c_t)$

- Cada peso $\theta_\bullet$ é uma matriz que opera sobre o vetor concatenado $[h_{t-1}, x_t]$.
- Os *bias* $b_\bullet$ são vetores com a mesma dimensão da saída da *gate*.
- Sendo h_{size} a dimensão do estado oculto e x_{size} a dimensão da entrada, os *shapes* esperados são:

$$\theta_\bullet \in \mathbb{R}^{(h_{\text{size}} + x_{\text{size}}) \times h_{\text{size}}}, \quad b_\bullet \in \mathbb{R}^{h_{\text{size}}}.$$

Exemplo Numérico: Configuração

- Vamos rodar um passo da LSTM com valores concretos.
- Estado inicial e entrada (escalares para simplificar):

$$c_0 = 0,5 \quad h_0 = -0,6 \quad x_0 = 0,8$$

- Pesos das quatro camadas densas, cada $\theta_{\bullet} = [\theta_h, \theta_x]$ multiplica $[h_{t-1}, x_t]^T$:

$$\theta_f = [0,5, -0,5],$$

$$b_f = 0,3$$

$$\theta_i = [0,3, -0,4],$$


$$b_i = 0,5$$

$$\theta_c = [0,1, -0,3],$$

$$b_c = 0,7$$

$$\theta_o = [-0,5, 0,4],$$

$$b_o = 0,5$$



Exemplo: *Forget Gate*

- Usando $[h_0, x_0]^T = [-0,6, 0,8]^T$:

$$f_t = \sigma([0,5, -0,5] \cdot [-0,6, 0,8]^T + 0,3)$$

$$f_t = \sigma(0,5 \cdot (-0,6) + (-0,5) \cdot 0,8 + 0,3) = \sigma(-0,4)$$

- Aplicando a *sigmoid*:

$$f_t \approx 0,4013$$

- Esse valor multiplicará $c_0 = 0,5$, mantendo cerca de 40% da memória anterior.

Exemplo: *Input Gate* e Candidato

- *Input gate*:

$$i_t = \sigma([0,3, -0,4] \cdot [-0,6, 0,8]^T + 0,5) = \sigma(0) \approx 0,5000$$

- Candidato $\tilde{c}_t$:

$$\tilde{c}_t = \tanh([0,1, -0,3] \cdot [-0,6, 0,8]^T + 0,7) = \tanh(0,4) \approx 0,3799$$

- i_t filtra cerca da metade do candidato, e $\tilde{c}_t$ é a contribuição em si.

Exemplo: Atualização da Memória

$$c_t = f_t \cdot c_{t-1} + i_t \cdot \tilde{c}_t$$

$$c_t = 0,4013 \cdot 0,5 + 0,5000 \cdot 0,3799$$

$$c_t \approx 0,2007 + 0,1900 \approx 0,3907$$

- A nova memória c_t combina parte da memória antiga (filtrada por f_t) com parte da nova proposta (filtrada por i_t).
- No caminho de c_t não há $\tanh$ nem multiplicação por matrizes, apenas operações ponto a ponto.

Exemplo: *Output Gate* e h_t

- *Output gate*:

$$o_t = \sigma([-0,5, 0,4] \cdot [-0,6, 0,8]^T + 0,5) = \sigma(1,12) \approx 0,7540$$

- Estado oculto:

$$h_t = o_t \cdot \tanh(c_t) = 0,7540 \cdot \tanh(0,3907) \approx 0,7540 \cdot 0,3719$$

$$h_t \approx 0,2804$$

- O sinal de h_t inverteu em relação a $h_0 = -0,6$, refletindo a entrada positiva $x_0 = 0,8$ filtrada pelas *gates*.

Forward Pass Otimizado

- As quatro camadas densas internas operam sobre o mesmo vetor $[h_{t-1}, x_t]$.
- Em vez de quatro multiplicações de matrizes, agrupamos os pesos das quatro camadas $(\theta_i, \theta_f, \theta_c, \theta_o)$ e separamos o resultado depois:
 - i : dimensão da entrada x_t , h : dimensão do estado oculto h_t .
 - W reúne as colunas que multiplicam x_t ; U , as que multiplicam h_{t-1} .

$$W \in \mathbb{R}^{is \times 4hs}, \quad U \in \mathbb{R}^{hs \times 4hs}, \quad b \in \mathbb{R}^{4hs}$$

$$A_t = x_t W + h_{t-1} U + b$$

$$i_t = \sigma(A_t[:, 0 : hs])$$

$$f_t = \sigma(A_t[:, hs : 2hs])$$

$$\tilde{c}_t = \tanh(A_t[:, 2hs : 3hs])$$

$$o_t = \sigma(A_t[:, 3hs : 4hs])$$

- Essa é a convenção do PyTorch (`nn.LSTM`): `weight_ih` (W) e `weight_hh` (U) concatenam as *gates* na ordem i, f, g, o (o candidato $\tilde{c}_t$ é o g_t), com dois bias $b_{ih} + b_{hh}$.

Implementação em PyTorch (1/2)

```
1 class MyLSTM(nn.Module):
2     def __init__(self, input_sz, hidden_sz):
3         super().__init__()
4         self.input_sz = input_sz
5         self.hidden_sz = hidden_sz
6         self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
7         self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
8         self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
9         self.init_weights() # nao mostrado
```

- As matrizes W e U contêm os pesos das quatro camadas internas concatenadas.
- Uma única chamada matricial substitui as quatro multiplicações originais.

Implementação em PyTorch (2/2)

```
1 def forward(self, x):
2     bs, seq_sz, _ = x.size()
3     HS = self.hidden_sz
4     h_t = torch.zeros(bs, HS, device=x.device)
5     c_t = torch.zeros(bs, HS, device=x.device)
6     hidden_seq = []
7     for t in range(seq_sz):
8         x_t = x[:, t, :]
9         gates = x_t @ self.W + h_t @ self.U + self.bias
10        i_t = torch.sigmoid(gates[:, :HS])
11        f_t = torch.sigmoid(gates[:, HS:HS*2])
12        g_t = torch.tanh(gates[:, HS*2:HS*3])
13        o_t = torch.sigmoid(gates[:, HS*3:])
14        c_t = f_t * c_t + i_t * g_t
15        h_t = o_t * torch.tanh(c_t)
16        hidden_seq.append(h_t.unsqueeze(0))
17    hidden_seq = torch.cat(hidden_seq, dim=0).transpose(0, 1).contiguous()
18    return hidden_seq, (h_t, c_t)
```


Overview

1. Problemas em Redes Recorrentes


2. LSTMs

3. GRUs

4. Referências

Gated Recurrent Unit

- Introduzida por Cho et al. em 2014^a.
- É considerada uma versão **simplificada** da LSTM.
- Não mantém um estado de memória c_t separado do estado oculto h_t , ambos viram um único vetor.
- Em vez das três *gates* da LSTM, a GRU tem apenas duas:
 - *reset gate* r_t ,
 - *update gate* z_t .
- Menos parâmetros, treinamento mais rápido, com desempenho competitivo em muitas tarefas.



^aKyunghyun Cho et al. "Learning phrase representations using RNN encoder-decoder for statistical machine translation". Em: [arXiv preprint arXiv:1406.1078](https://arxiv.org/abs/1406.1078) (2014).

Equações da GRU

- *Reset gate*: decide quanto do estado anterior é usado para computar o candidato.

$$r_t = \sigma(\theta_r [h_{t-1}, x_t] + b_r)$$

- *Update gate*: decide a mistura entre o estado anterior e o candidato.

$$z_t = \sigma(\theta_z [h_{t-1}, x_t] + b_z)$$

- Candidato a estado oculto:

$$\tilde{h}_t = \tanh(\theta_h [r_t \odot h_{t-1}, x_t] + b_h)$$

- Novo estado oculto:

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

Exemplo de GRU: *Reset* e *Update Gates*

- Reusando $h_0 = -0,6$ e $x_0 = 0,8$, logo $[h_0, x_0] = [-0,6, 0,8]$, com pesos:

$$\theta_r = [0,5, -0,4], \quad b_r = 0,2 \quad \theta_z = [-0,3, 0,6], \quad b_z = 0,1 \quad \theta_h = [0,4, 0,5], \quad b_h = 0$$

- *Reset gate*:

$$r_t = \sigma(0,5 \cdot (-0,6) + (-0,4) \cdot 0,8 + 0,2) = \sigma(-0,42) \approx 0,3965$$

- *Update gate*:

$$z_t = \sigma((-0,3) \cdot (-0,6) + 0,6 \cdot 0,8 + 0,1) = \sigma(0,76) \approx 0,6814$$

Exemplo de GRU: Candidato e Novo Estado

- O *reset gate* filtra o estado anterior **antes** de entrar no candidato:

$$r_t \odot h_0 = 0,3965 \cdot (-0,6) \approx -0,2379$$

- Candidato a estado oculto, usando $[r_t \odot h_0, x_0] = [-0,2379, 0,8]$:

$$\tilde{h}_t = \tanh(0,4 \cdot (-0,2379) + 0,5 \cdot 0,8 + 0) = \tanh(0,3048) \approx 0,2957$$

- Novo estado oculto, mistura controlada por z_t :

$$h_t = (1 - z_t) h_0 + z_t \tilde{h}_t = 0,3186 \cdot (-0,6) + 0,6814 \cdot 0,2957 \approx 0,0103$$

- Diferente da LSTM, não há memória c_t separada: a **mesma** porta z_t decide quanto manter de h_0 e quanto usar do candidato.


LSTM vs GRU

	LSTM	GRU
Estados que circulam	h_t e c_t	apenas h_t
Quantidade de <i>gates</i>	3 (f, i, o)	2 (r, z)
Camadas densas internas	4	3
Parâmetros (relativo)	$4 \cdot d$	$3 \cdot d$

- A linha de parâmetros conta apenas as matrizes densas internas (ignora *bias*). Em prática, uma GRU acaba tendo aproximadamente 75% dos parâmetros de uma LSTM com a mesma dimensão oculta.
- Em sequências longas a LSTM costuma se comportar um pouco melhor por ter o caminho dedicado para c_t .
- A GRU é mais leve e converge mais rápido, sendo uma boa escolha quando há restrição de memória ou de *compute*.


Variantes Comuns: *Bidirectional* e *Stacked*

Bidirectional RNN



- Combina *forward pass* e *backward pass*. Saída é a concatenação dos dois estados ocultos.
- Útil quando toda a sequência está disponível (e.g., *encoders*). Não se aplica a geração autoregressiva.
- Ambas variantes voltam a aparecer no contexto de *encoder-decoder* no próximo deck.

Stacked RNN



- Várias camadas recorrentes empilhadas. A saída da camada ℓ vira a entrada da camada $\ell + 1$.
- Usado em *encoders* profundos para enriquecer a representação. Cada camada pode ter sua própria LSTM ou GRU.

Overview

1. Problemas em Redes Recorrentes

2. LSTMs

3. GRUs

4. Referências

Referências I

- Sugere-se a leitura do Capítulo 10 de *Deep Learning*².
 - Disponível em <https://www.deeplearningbook.org/>.
- Material baseado em:
 - Capítulo 10 de *Deep Learning*, Ian Goodfellow, Yoshua Bengio e Aaron Courville.
 - *Understanding LSTM Networks*, Christopher Olah, 2015.
 - *MIT Introduction to Deep Learning*, Ava Amini, 2023.

- [1] Kyunghyun Cho et al. “Learning phrase representations using RNN encoder-decoder for statistical machine translation”. Em: [arXiv preprint arXiv:1406.1078](https://arxiv.org/abs/1406.1078) (2014).
- [2] Ian Goodfellow, Yoshua Bengio e Aaron Courville. Deep Learning. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [3] Sepp Hochreiter e Jürgen Schmidhuber. “Long short-term memory”. Em: Neural Computation 9.8 (1997), pp. 1735–1780.

²Ian Goodfellow, Yoshua Bengio e Aaron Courville. Deep Learning. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.