

# Deep Learning

LSTMs e GRUs

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory  
PUCRS

maio de 2026

# Overview

---

**1. Problemas em Redes Recorrentes**

**2. LSTMs**

**3. GRUs**

**4. Referências**

# Overview

---

## 1. Problemas em Redes Recorrentes

## 2. LSTMs

## 3. GRUs

## 4. Referências


# Memória de Curto Prazo

---

- Considere a frase a seguir, em que existe uma quebra de sentimento entre as duas partes:
- *“O filme é péssimo e ninguém deveria perder tempo assistindo. Contudo eu admiro a tentativa de Hollywood de aumentar a representatividade em termos de história e atores, certamente será possível colher frutos sobre essa tentativa em outras obras no futuro.”*
- Para classificar o sentimento global, a rede precisa lembrar do início da frase quando chega ao final.
- Com uma RNN simples, esse tipo de **dependência de longo alcance** é difícil de manter.

# Estado Interno é Sobrescrito a Cada Passo

- Em uma RNN *vanilla*, o estado interno  $h_t$  é totalmente recalculado a cada passo de tempo.



- Em cada célula a entrada **atualiza completamente** o estado.
- Manter informação por muitos passos de tempo é difícil, esse é o problema da **memória de curto prazo**.

# Solução: Aprender Quando Atualizar e Quando Esquecer

---

- A ideia é deixar a própria rede aprender, a cada passo, quanta informação anterior deve ser mantida e quanta informação nova deve entrar no estado.
- Essa é a motivação da arquitetura *Long Short-Term Memory*<sup>1</sup> (LSTM).
- É a arquitetura com mais “partes” que veremos até agora, mas todas as partes se reduzem a operações já conhecidas:
  - multiplicação de matrizes,
  - funções de ativação (sigmoid, tanh),
  - operações ponto a ponto (soma, multiplicação).

---

<sup>1</sup>Sepp Hochreiter e Jürgen Schmidhuber. “Long short-term memory”. Em: Neural Computation 9.8 (1997), pp. 1735–1780.

# Overview

---

1. Problemas em Redes Recorrentes

**2. LSTMs**


3. GRUs

4. Referências

# Revisitando RNNs

---


- Em uma RNN *vanilla* o estado oculto  $h_{t-1}$  é combinado com a entrada  $x_t$  por uma camada densa com ativação  $\tanh$ .
- Repare que dentro da célula recorrente existe “uma rede densa”.
- A LSTM mantém essa ideia, porém com mais camadas internas e um caminho separado para a memória de longo prazo.





# Visão Geral da Célula LSTM

- A LSTM mantém a recorrência, mas agora a célula carrega **dois** sinais ao longo do tempo:
  - o estado oculto  $h_t$  (*hidden state*),
  - a memória de longo prazo  $c_t$  (*cell state*).
- Dentro da célula, *gates* controlam o quanto de cada informação é mantido, atualizado ou exposto.
- Cada *gate* é uma camada densa com ativação *sigmoid*: produz valores em  $[0, 1]$  que multiplicam outro vetor ponto a ponto.



# Quatro Camadas Densas Dentro da Célula

---


- Dentro da célula LSTM existem **quatro** camadas densas que recebem  $[h_{t-1}, x_t]$ :
  - três delas funcionam como *gates*, com ativação *sigmoid*:
    - *forget gate* ( $f_t$ ): decide o quanto da memória  $c_{t-1}$  deve ser **esquecido**.
    - *input gate* ( $i_t$ ): decide quais partes da nova informação devem **atualizar** a memória.
    - *output gate* ( $o_t$ ): decide quais partes da memória devem **compor** o novo estado oculto.
  - a quarta camada usa  $\tanh$  e produz uma proposta de atualização  $\tilde{c}_t$  para a memória.
- As três *gates* aprendem a regular o fluxo de informação ao longo do tempo.

## Forget Gate

- Decide quanto da memória  $c_{t-1}$  deve ser esquecida.
- Recebe  $[h_{t-1}, x_t]$ , passa por uma camada densa e por uma *sigmoid*:

$$f_t = \sigma(\theta_f [h_{t-1}, x_t] + b_f)$$

- $f_t \in [0, 1]$ , multiplica  $c_{t-1}$  ponto a ponto.
  - $f_t \approx 1$ : mantém a memória.
  - $f_t \approx 0$ : esquece.




## Input Gate e Candidato $\tilde{c}_t$

- Decide quais partes da nova entrada devem **atualizar** a memória.
- Duas camadas trabalham juntas:

$$i_t = \sigma(\theta_i [h_{t-1}, x_t] + b_i)$$

$$\tilde{c}_t = \tanh(\theta_c [h_{t-1}, x_t] + b_c)$$

- $i_t \in [0, 1]$  filtra a contribuição.
- $\tilde{c}_t \in [-1, 1]$  é a proposta de atualização.




## Atualização da Memória $c_t$

- A nova memória combina o que foi mantido da anterior com a nova proposta filtrada:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

- O símbolo  $\odot$  indica multiplicação ponto a ponto (*Hadamard*).
- Repare que  $c_t$  tem uma rota direta no tempo, sem ativação não linear no caminho principal.
  - Isso ajuda a mitigar o *vanishing gradient*.




## Output Gate e Estado Oculto $h_t$

- Decide quais partes da memória devem ser **expostas** no estado oculto:

$$o_t = \sigma(\theta_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \odot \tanh(c_t)$$

- $h_t$  é o que sai da célula a cada passo, e também alimenta a próxima célula.
- $c_t$  continua circulando como memória de longo prazo, em paralelo a  $h_t$ .



# Resumo das Equações da LSTM

---

---

|                         |                                                      |
|-------------------------|------------------------------------------------------|
| <i>Forget gate</i>      | $f_t = \sigma(\theta_f [h_{t-1}, x_t] + b_f)$        |
| <i>Input gate</i>       | $i_t = \sigma(\theta_i [h_{t-1}, x_t] + b_i)$        |
| Candidato $\tilde{c}_t$ | $\tilde{c}_t = \tanh(\theta_c [h_{t-1}, x_t] + b_c)$ |
| Memória $c_t$           | $c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$    |
| <i>Output gate</i>      | $o_t = \sigma(\theta_o [h_{t-1}, x_t] + b_o)$        |
| Estado oculto $h_t$     | $h_t = o_t \odot \tanh(c_t)$                         |

---

- Cada peso  $\theta_\bullet$  é uma matriz que opera sobre o vetor concatenado  $[h_{t-1}, x_t]$ .
- Os *bias*  $b_\bullet$  são vetores com a mesma dimensão da saída da *gate*.

## Exemplo Numérico: Configuração

- Vamos rodar um passo da LSTM com valores concretos.
- Estado inicial e entrada (escalares para simplificar):

$$c_0 = 0,5 \quad h_0 = -0,6 \quad x_0 = 0,8$$

- Pesos das quatro camadas densas, cada  $\theta_{\bullet} = [\theta_h, \theta_x]$  multiplica  $[h_{t-1}, x_t]^T$ :

$$\theta_f = [0,5, -0,5],$$

$$b_f = 0,3$$

$$\theta_i = [0,3, -0,4],$$


$$b_i = 0,5$$

$$\theta_c = [0,1, -0,3],$$

$$b_c = 0,7$$

$$\theta_o = [-0,5, 0,4],$$

$$b_o = 0,5$$





## Exemplo: *Forget Gate*

---

- Usando  $[h_0, x_0]^T = [-0,6, 0,8]^T$ :

$$f_t = \sigma([0,5, -0,5] \cdot [-0,6, 0,8]^T + 0,3)$$

$$f_t = \sigma(0,5 \cdot (-0,6) + (-0,5) \cdot 0,8 + 0,3) = \sigma(-0,4)$$

- Aplicando a *sigmoid*:

$$f_t \approx 0,4013$$

- Esse valor multiplicará  $c_0 = 0,5$ , mantendo cerca de 40% da memória anterior.

## Exemplo: *Input Gate* e Candidato

---

- *Input gate*:

$$i_t = \sigma([0,3, -0,4] \cdot [-0,6, 0,8]^T + 0,5) = \sigma(0) \approx 0,5000$$

- Candidato  $\tilde{c}_t$ :

$$\tilde{c}_t = \tanh([0,1, -0,3] \cdot [-0,6, 0,8]^T + 0,7) = \tanh(0,4) \approx 0,3799$$

- $i_t$  filtra cerca da metade do candidato, e  $\tilde{c}_t$  é a contribuição em si.

## Exemplo: Atualização da Memória

---

$$c_t = f_t \cdot c_{t-1} + i_t \cdot \tilde{c}_t$$

$$c_t = 0,4013 \cdot 0,5 + 0,5000 \cdot 0,3799$$

$$c_t \approx 0,2007 + 0,1900 \approx 0,3907$$

- A nova memória  $c_t$  combina parte da memória antiga (filtrada por  $f_t$ ) com parte da nova proposta (filtrada por  $i_t$ ).
- No caminho de  $c_t$  não há tanh nem multiplicação por matrizes, apenas operações ponto a ponto.

## Exemplo: *Output Gate* e $h_t$

---

- *Output gate*:

$$o_t = \sigma([-0,5, 0,4] \cdot [-0,6, 0,8]^T + 0,5) = \sigma(1,12) \approx 0,7540$$

- Estado oculto:

$$h_t = o_t \cdot \tanh(c_t) = 0,7540 \cdot \tanh(0,3907) \approx 0,7540 \cdot 0,3719$$

$$h_t \approx 0,2804$$

- O sinal de  $h_t$  inverteu em relação a  $h_0 = -0,6$ , refletindo a entrada positiva  $x_0 = 0,8$  filtrada pelas *gates*.

# Forward Pass Otimizado

---

- As quatro camadas densas internas operam sobre o mesmo vetor  $[h_{t-1}, x_t]$ .
- Em vez de fazer quatro multiplicações de matrizes, agrupamos os pesos em uma única matriz e separamos depois:
  - $is$ : dimensão da entrada  $x_t$ ,
  - $hs$ : dimensão do estado oculto  $h_t$ .
- Pesos agrupados:

$$W \in \mathbb{R}^{is \times 4hs}, \quad U \in \mathbb{R}^{hs \times 4hs}, \quad b \in \mathbb{R}^{4hs}$$

$$A_t = x_t W + h_{t-1} U + b$$

$$f_t = \sigma(A_t[:, 0 : hs])$$

$$i_t = \sigma(A_t[:, hs : 2hs])$$

$$o_t = \sigma(A_t[:, 2hs : 3hs])$$

$$\tilde{c}_t = \tanh(A_t[:, 3hs : 4hs])$$

# Implementação em PyTorch (1/2)

---

```
1 class MyLSTM(nn.Module):
2     def __init__(self, input_sz, hidden_sz):
3         super().__init__()
4         self.input_sz = input_sz
5         self.hidden_sz = hidden_sz
6         self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
7         self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
8         self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
9         self.init_weights() # nao mostrado
```

- As matrizes  $W$  e  $U$  contêm os pesos das quatro camadas internas concatenadas.
- Uma única chamada matricial substitui as quatro multiplicações originais.

## Implementação em PyTorch (2/2)

---

```
1 def forward(self, x):
2     bs, seq_sz, _ = x.size()
3     HS = self.hidden_sz
4     h_t = torch.zeros(bs, HS, device=x.device)
5     c_t = torch.zeros(bs, HS, device=x.device)
6     hidden_seq = []
7     for t in range(seq_sz):
8         x_t = x[:, t, :]
9         gates = x_t @ self.W + h_t @ self.U + self.bias
10        i_t = torch.sigmoid(gates[:, :HS])
11        f_t = torch.sigmoid(gates[:, HS:HS*2])
12        g_t = torch.tanh(gates[:, HS*2:HS*3])
13        o_t = torch.sigmoid(gates[:, HS*3:])
14        c_t = f_t * c_t + i_t * g_t
15        h_t = o_t * torch.tanh(c_t)
16        hidden_seq.append(h_t.unsqueeze(0))
17    hidden_seq = torch.cat(hidden_seq, dim=0).transpose(0, 1).contiguous()
18    return hidden_seq, (h_t, c_t)
```

# Overview

---

1. Problemas em Redes Recorrentes

2. LSTMs


**3. GRUs**

4. Referências



# Gated Recurrent Unit

- Introduzida por Cho et al. em 2014<sup>a</sup>.
- É considerada uma versão **simplificada** da LSTM.
- Não mantém um estado de memória  $c_t$  separado do estado oculto  $h_t$ , ambos viram um único vetor.
- Em vez das três *gates* da LSTM, a GRU tem apenas duas:
  - *reset gate*  $r_t$ ,
  - *update gate*  $z_t$ .
- Menos parâmetros, treinamento mais rápido, com desempenho competitivo em muitas tarefas.



<sup>a</sup>Kyunghyun Cho et al. "Learning phrase representations using RNN encoder-decoder for statistical machine translation". Em: [arXiv preprint arXiv:1406.1078](https://arxiv.org/abs/1406.1078) (2014).

## Equações da GRU

---

- *Reset gate*: decide quanto do estado anterior é usado para computar o candidato.

$$r_t = \sigma(\theta_r [h_{t-1}, x_t] + b_r)$$

- *Update gate*: decide a mistura entre o estado anterior e o candidato.

$$z_t = \sigma(\theta_z [h_{t-1}, x_t] + b_z)$$

- Candidato a estado oculto:

$$\tilde{h}_t = \tanh(\theta_h [r_t \odot h_{t-1}, x_t] + b_h)$$

- Novo estado oculto:

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

# LSTM vs GRU

---

|                            | LSTM          | GRU          |
|----------------------------|---------------|--------------|
| Estados que circulam       | $h_t$ e $c_t$ | apenas $h_t$ |
| Quantidade de <i>gates</i> | 3 $(f, i, o)$ | 2 $(r, z)$   |
| Camadas densas internas    | 4             | 3            |
| Parâmetros (relativo)      | $4 \cdot d$   | $3 \cdot d$  |

- Em sequências longas a LSTM costuma se comportar um pouco melhor por ter o caminho dedicado para  $c_t$ .
- A GRU é mais leve e converge mais rápido, sendo uma boa escolha quando há restrição de memória ou de *compute*.

# Overview

---

1. Problemas em Redes Recorrentes

2. LSTMs

3. GRUs

**4. Referências**

# Referências I

---

- Sugere-se a leitura do Capítulo 10 de *Deep Learning*<sup>2</sup>.
  - Disponível em <https://www.deeplearningbook.org/>.
- Material baseado em:
  - Capítulo 10 de *Deep Learning*, Ian Goodfellow, Yoshua Bengio e Aaron Courville.
  - *Understanding LSTM Networks*, Christopher Olah, 2015.
  - *MIT Introduction to Deep Learning*, Ava Amini, 2023.

- [1] Kyunghyun Cho et al. “Learning phrase representations using RNN encoder-decoder for statistical machine translation”. Em: [arXiv preprint arXiv:1406.1078](#) (2014).
- [2] Ian Goodfellow, Yoshua Bengio e Aaron Courville. Deep Learning. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [3] Sepp Hochreiter e Jürgen Schmidhuber. “Long short-term memory”. Em: [Neural Computation](#) 9.8 (1997), pp. 1735–1780.

---

<sup>2</sup>Ian Goodfellow, Yoshua Bengio e Aaron Courville. Deep Learning. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.