

Deep Learning

LSTMs e GRUs

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory
PUCRS

maio de 2026

Overview

1. Problemas em Redes Recorrentes

2. LSTMs

3. GRUs

4. Referências

Overview

1. Problemas em Redes Recorrentes

2. LSTMs

3. GRUs


4. Referências

Memória de Curto Prazo

- Considere a frase a seguir, em que existe uma quebra de sentimento entre as duas partes:
- *“O filme é péssimo e ninguém deveria perder tempo assistindo. Contudo eu admiro a tentativa de Hollywood de aumentar a representatividade em termos de história e atores, certamente será possível colher frutos sobre essa tentativa em outras obras no futuro.”*
- Para classificar o sentimento global, a rede precisa lembrar do início da frase quando chega ao final.
- Com uma RNN simples, esse tipo de **dependência de longo alcance** é difícil de manter.

Estado Interno é Sobrescrito a Cada Passo

- Em uma RNN *vanilla*, o estado interno h_t é totalmente recalculado a cada passo de tempo.



- Em cada célula a entrada **atualiza completamente** o estado.
- Manter informação por muitos passos de tempo é difícil, esse é o problema da **memória de curto prazo**.

Solução: Aprender Quando Atualizar e Quando Esquecer

- A ideia é deixar a própria rede aprender, a cada passo, quanta informação anterior deve ser mantida e quanta informação nova deve entrar no estado.
- Essa é a motivação da arquitetura *Long Short-Term Memory*¹ (LSTM).
- É a arquitetura com mais “partes” que veremos até agora, mas todas as partes se reduzem a operações já conhecidas:
 - multiplicação de matrizes,
 - funções de ativação (sigmoid, tanh),
 - operações ponto a ponto (soma, multiplicação).

¹Sepp Hochreiter e Jürgen Schmidhuber. “Long short-term memory”. Em: Neural Computation 9.8 (1997), pp. 1735–1780.

Overview

1. Problemas em Redes Recorrentes


2. LSTMs

3. GRUs

4. Referências


Revisitando RNNs

- Em uma RNN *vanilla* o estado oculto h_{t-1} é combinado com a entrada x_t por uma camada densa com ativação $\tanh$.
- Repare que dentro da célula recorrente existe “uma rede densa”.
- A LSTM mantém essa ideia, porém com mais camadas internas e um caminho separado para a memória de longo prazo.



Visão Geral da Célula LSTM

- A LSTM mantém a recorrência, mas agora a célula carrega **dois** sinais ao longo do tempo:
 - o estado oculto h_t (*hidden state*),
 - a memória de longo prazo c_t (*cell state*).
- Dentro da célula, *gates* controlam o quanto de cada informação é mantido, atualizado ou exposto.
- Cada *gate* é uma camada densa com ativação *sigmoid*: produz valores em $[0, 1]$ que multiplicam outro vetor ponto a ponto.



Quatro Camadas Densas Dentro da Célula


- Dentro da célula LSTM existem **quatro** camadas densas que recebem $[h_{t-1}, x_t]$:
 - três delas funcionam como *gates*, com ativação *sigmoid*:
 - *forget gate* (f_t): decide o quanto da memória c_{t-1} deve ser **esquecido**.
 - *input gate* (i_t): decide quais partes da nova informação devem **atualizar** a memória.
 - *output gate* (o_t): decide quais partes da memória devem **compor** o novo estado oculto.
 - a quarta camada usa $\tanh$ e produz uma proposta de atualização $\tilde{c}_t$ para a memória.
- As três *gates* aprendem a regular o fluxo de informação ao longo do tempo.

Forget Gate

- Decide quanto da memória c_{t-1} deve ser esquecida.
- Recebe $[h_{t-1}, x_t]$, passa por uma camada densa e por uma *sigmoid*:

$$f_t = \sigma(\theta_f [h_{t-1}, x_t] + b_f)$$

- $f_t \in [0, 1]$, multiplica c_{t-1} ponto a ponto.
 - $f_t \approx 1$: mantém a memória.
 - $f_t \approx 0$: esquece.




Input Gate e Candidato $\tilde{c}_t$

- Decide quais partes da nova entrada devem **atualizar** a memória.
- Duas camadas trabalham juntas:

$$i_t = \sigma(\theta_i [h_{t-1}, x_t] + b_i)$$

$$\tilde{c}_t = \tanh(\theta_c [h_{t-1}, x_t] + b_c)$$

- $i_t \in [0, 1]$ filtra a contribuição.
- $\tilde{c}_t \in [-1, 1]$ é a proposta de atualização.




Output Gate e Estado Oculto h_t

- Decide quais partes da memória devem ser **expostas** no estado oculto:

$$o_t = \sigma(\theta_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \odot \tanh(c_t)$$

- h_t é o que sai da célula a cada passo, e também alimenta a próxima célula.
- c_t continua circulando como memória de longo prazo, em paralelo a h_t .



Resumo das Equações da LSTM

<i>Forget gate</i>	$f_t = \sigma(\theta_f [h_{t-1}, x_t] + b_f)$
<i>Input gate</i>	$i_t = \sigma(\theta_i [h_{t-1}, x_t] + b_i)$
Candidato $\tilde{c}_t$	$\tilde{c}_t = \tanh(\theta_c [h_{t-1}, x_t] + b_c)$
Memória c_t	$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$
<i>Output gate</i>	$o_t = \sigma(\theta_o [h_{t-1}, x_t] + b_o)$
Estado oculto h_t	$h_t = o_t \odot \tanh(c_t)$

- Cada peso $\theta_\bullet$ é uma matriz que opera sobre o vetor concatenado $[h_{t-1}, x_t]$.
- Os *bias* $b_\bullet$ são vetores com a mesma dimensão da saída da *gate*.

Exemplo Numérico: Configuração

- Vamos rodar um passo da LSTM com valores concretos.
- Estado inicial e entrada (escalares para simplificar):

$$c_0 = 0,5 \quad h_0 = -0,6 \quad x_0 = 0,8$$

- Pesos das quatro camadas densas, cada $\theta_{\bullet} = [\theta_h, \theta_x]$ multiplica $[h_{t-1}, x_t]^T$:

$$\theta_f = [0,5, -0,5],$$

$$b_f = 0,3$$

$$\theta_i = [0,3, -0,4],$$


$$b_i = 0,5$$

$$\theta_c = [0,1, -0,3],$$

$$b_c = 0,7$$

$$\theta_o = [-0,5, 0,4],$$

$$b_o = 0,5$$



Exemplo: *Forget Gate*

- Usando $[h_0, x_0]^T = [-0,6, 0,8]^T$:

$$f_t = \sigma([0,5, -0,5] \cdot [-0,6, 0,8]^T + 0,3)$$

$$f_t = \sigma(0,5 \cdot (-0,6) + (-0,5) \cdot 0,8 + 0,3) = \sigma(-0,4)$$

- Aplicando a *sigmoid*:

$$f_t \approx 0,4013$$

- Esse valor multiplicará $c_0 = 0,5$, mantendo cerca de 40% da memória anterior.

Exemplo: *Input Gate* e Candidato

- *Input gate*:

$$i_t = \sigma([0,3, -0,4] \cdot [-0,6, 0,8]^T + 0,5) = \sigma(0) \approx 0,5000$$

- Candidato $\tilde{c}_t$:

$$\tilde{c}_t = \tanh([0,1, -0,3] \cdot [-0,6, 0,8]^T + 0,7) = \tanh(0,4) \approx 0,3799$$

- i_t filtra cerca da metade do candidato, e $\tilde{c}_t$ é a contribuição em si.

Exemplo: Atualização da Memória

$$c_t = f_t \cdot c_{t-1} + i_t \cdot \tilde{c}_t$$

$$c_t = 0,4013 \cdot 0,5 + 0,5000 \cdot 0,3799$$

$$c_t \approx 0,2007 + 0,1900 \approx 0,3907$$

- A nova memória c_t combina parte da memória antiga (filtrada por f_t) com parte da nova proposta (filtrada por i_t).
- No caminho de c_t não há tanh nem multiplicação por matrizes, apenas operações ponto a ponto.

Exemplo: *Output Gate* e h_t

- *Output gate*:

$$o_t = \sigma([-0,5, 0,4] \cdot [-0,6, 0,8]^T + 0,5) = \sigma(1,12) \approx 0,7540$$

- Estado oculto:

$$h_t = o_t \cdot \tanh(c_t) = 0,7540 \cdot \tanh(0,3907) \approx 0,7540 \cdot 0,3719$$

$$h_t \approx 0,2804$$

- O sinal de h_t inverteu em relação a $h_0 = -0,6$, refletindo a entrada positiva $x_0 = 0,8$ filtrada pelas *gates*.

Forward Pass Otimizado

- As quatro camadas densas internas operam sobre o mesmo vetor $[h_{t-1}, x_t]$.
- Em vez de fazer quatro multiplicações de matrizes, agrupamos os pesos em uma única matriz e separamos depois:
 - is : dimensão da entrada x_t ,
 - hs : dimensão do estado oculto h_t .
- Pesos agrupados:

$$W \in \mathbb{R}^{is \times 4hs}, \quad U \in \mathbb{R}^{hs \times 4hs}, \quad b \in \mathbb{R}^{4hs}$$

$$A_t = x_t W + h_{t-1} U + b$$

$$f_t = \sigma(A_t[:, 0 : hs])$$

$$i_t = \sigma(A_t[:, hs : 2hs])$$

$$o_t = \sigma(A_t[:, 2hs : 3hs])$$

$$\tilde{c}_t = \tanh(A_t[:, 3hs : 4hs])$$

Implementação em PyTorch (1/2)

```
1 class MyLSTM(nn.Module):
2     def __init__(self, input_sz, hidden_sz):
3         super().__init__()
4         self.input_sz = input_sz
5         self.hidden_sz = hidden_sz
6         self.W = nn.Parameter(torch.Tensor(input_sz, hidden_sz * 4))
7         self.U = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz * 4))
8         self.bias = nn.Parameter(torch.Tensor(hidden_sz * 4))
9         self.init_weights() # nao mostrado
```

- As matrizes W e U contêm os pesos das quatro camadas internas concatenadas.
- Uma única chamada matricial substitui as quatro multiplicações originais.

Implementação em PyTorch (2/2)

```
1 def forward(self, x):
2     bs, seq_sz, _ = x.size()
3     HS = self.hidden_sz
4     h_t = torch.zeros(bs, HS, device=x.device)
5     c_t = torch.zeros(bs, HS, device=x.device)
6     hidden_seq = []
7     for t in range(seq_sz):
8         x_t = x[:, t, :]
9         gates = x_t @ self.W + h_t @ self.U + self.bias
10        i_t = torch.sigmoid(gates[:, :HS])
11        f_t = torch.sigmoid(gates[:, HS:HS*2])
12        g_t = torch.tanh(gates[:, HS*2:HS*3])
13        o_t = torch.sigmoid(gates[:, HS*3:])
14        c_t = f_t * c_t + i_t * g_t
15        h_t = o_t * torch.tanh(c_t)
16        hidden_seq.append(h_t.unsqueeze(0))
17    hidden_seq = torch.cat(hidden_seq, dim=0).transpose(0, 1).contiguous()
18    return hidden_seq, (h_t, c_t)
```

Overview

1. Problemas em Redes Recorrentes


2. LSTMs

3. GRUs

4. Referências

Gated Recurrent Unit

- Introduzida por Cho et al. em 2014^a.
- É considerada uma versão **simplificada** da LSTM.
- Não mantém um estado de memória c_t separado do estado oculto h_t , ambos viram um único vetor.
- Em vez das três *gates* da LSTM, a GRU tem apenas duas:
 - *reset gate* r_t ,
 - *update gate* z_t .
- Menos parâmetros, treinamento mais rápido, com desempenho competitivo em muitas tarefas.



^aKyunghyun Cho et al. "Learning phrase representations using RNN encoder-decoder for statistical machine translation". Em: arXiv preprint arXiv:1406.1078 (2014).

Equações da GRU

- *Reset gate*: decide quanto do estado anterior é usado para computar o candidato.

$$r_t = \sigma(\theta_r [h_{t-1}, x_t] + b_r)$$

- *Update gate*: decide a mistura entre o estado anterior e o candidato.

$$z_t = \sigma(\theta_z [h_{t-1}, x_t] + b_z)$$

- Candidato a estado oculto:

$$\tilde{h}_t = \tanh(\theta_h [r_t \odot h_{t-1}, x_t] + b_h)$$

- Novo estado oculto:

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

LSTM vs GRU

	LSTM	GRU
Estados que circulam	h_t e c_t	apenas h_t
Quantidade de <i>gates</i>	3 (f, i, o)	2 (r, z)
Camadas densas internas	4	3
Parâmetros (relativo)	$4 \cdot d$	$3 \cdot d$

- Em sequências longas a LSTM costuma se comportar um pouco melhor por ter o caminho dedicado para c_t .
- A GRU é mais leve e converge mais rápido, sendo uma boa escolha quando há restrição de memória ou de *compute*.

Overview

1. Problemas em Redes Recorrentes

2. LSTMs

3. GRUs

4. Referências

Referências I

- Sugere-se a leitura do Capítulo 10 de *Deep Learning*².
 - Disponível em <https://www.deeplearningbook.org/>.
- Material baseado em:
 - Capítulo 10 de *Deep Learning*, Ian Goodfellow, Yoshua Bengio e Aaron Courville.
 - *Understanding LSTM Networks*, Christopher Olah, 2015.
 - *MIT Introduction to Deep Learning*, Ava Amini, 2023.

- [1] Kyunghyun Cho et al. “Learning phrase representations using RNN encoder-decoder for statistical machine translation”. Em: [arXiv preprint arXiv:1406.1078](#) (2014).
- [2] Ian Goodfellow, Yoshua Bengio e Aaron Courville. Deep Learning. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.
- [3] Sepp Hochreiter e Jürgen Schmidhuber. “Long short-term memory”. Em: [Neural Computation](#) 9.8 (1997), pp. 1735–1780.

²Ian Goodfellow, Yoshua Bengio e Aaron Courville. Deep Learning. MIT Press, 2016. URL: <https://www.deeplearningbook.org/>.