

Aprendizado Profundo

Normalizing Flows

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory
PUCRS

junho de 2026

Visão Geral

1. Modelos Geradores – Revisão
2. Visão Geral de Normalizing Flows
3. Mudança de Variável
4. Loss
5. O que são Flows
6. Coupling Flows
7. Discreto vs. Contínuo
8. De NFs a *Flow Matching*
9. Panorama Geral

Visão Geral

1. Modelos Geradores – Revisão
2. Visão Geral de Normalizing Flows
3. Mudança de Variável
4. Loss
5. O que são Flows
6. Coupling Flows
7. Discreto vs. Contínuo
8. De NFs a *Flow Matching*
9. Panorama Geral

Modelos Geradores


- O objetivo de um **modelo gerador** é aprender uma **distribuição de probabilidade** sobre uma variável aleatória X usando um conjunto de dados observados $\{x^{(i)}\}_{i=1}^N$.
- A densidade $p_X(x)$ é parametrizada por θ .
- Dois usos fundamentais de um modelo gerador:
 - **Amostrar**: obter novos exemplos a partir do modelo.
 - **Avaliar**: calcular $p_X(x)$ para uma instância dada.

Observação

Diferentes famílias de modelos geradores são fortes em um ou outro desses aspectos; poucos fazem os dois bem.

Modelos Geradores – Voltando aos GANs

- GANs:
 - **Amostrar** p_X : conseguimos (passagem pelo gerador).
 - **Avaliar** p_X : inviável, não há densidade explícita.
- Isso motiva a busca por modelos que também permitam avaliar p_X .




Visão Geral

1. Modelos Geradores – Revisão
- 2. Visão Geral de Normalizing Flows**
3. Mudança de Variável
4. Loss
5. O que são Flows
6. Coupling Flows
7. Discreto vs. Contínuo
8. De NFs a *Flow Matching*
9. Panorama Geral

Normalizing Flows¹

- *Normalizing Flows* são modelos geradores probabilísticos que permitem **tanto amostrar quanto avaliar** $p_X(x)$.
- Consistem em **transformar** uma distribuição tratável base (e.g. $z \sim \mathcal{N}(0, 1)$) em uma outra distribuição usando **funções inversíveis**.



¹Ivan Kobyzev, Simon J. D. Prince e Marcus A. Brubaker. "Normalizing Flows: An Introduction and Review of Current Methods". Em: [IEEE TPAMI](#) 43.11 (2020), pp. 3964–3979.

Normalizing Flows – O marco de 2018: Glow²



Faces sintetizadas pelo *Glow* (2018), um *Normalizing Flow* com convoluções invertíveis 1×1 .


Por muito tempo, a referência visual

O *Glow* foi durante anos o melhor resultado de imagem de um *flow*, firmando a percepção de que NFs ficavam atrás de GANs e modelos difusores. Como veremos a seguir, isso mudou.

²Durk P. Kingma e Prafulla Dhariwal. “Glow: Generative Flow with Invertible 1×1 Convolutions”. Em: [NeurIPS](#). vol. 31. 2018.

O renascimento dos *Normalizing Flows* (2024–2025)

Trabalhos recentes mostram NFs competindo com modelos difusores:




- *TarFlow*³: *flow* autorregressivo baseado em *Transformer*. Bate o estado da arte em verossimilhança de imagens e gera amostras comparáveis às de difusão.
- *STARFlow*⁴: escala a ideia para síntese em alta resolução no espaço latente.

³Shuangfei Zhai et al. “Normalizing Flows are Capable Generative Models”. Em: [ICML](#), 2025.

⁴Jiatao Gu et al. “STARFlow: Scaling Latent Normalizing Flows for High-resolution Image Synthesis”. Em: [arXiv preprint arXiv:2506.06276](#) (2025).

Normalizing Flows – Transformação 1D

Gaussiana base $\rightarrow$ distribuição bimodal via *flow*:



- *Forward*: leva da distribuição base $p(z)$ para $p(x)$ (amostragem).
- *Inverse*: faz o caminho oposto (avaliação via mudança de variável).

Visão Geral

1. Modelos Geradores – Revisão
2. Visão Geral de Normalizing Flows
- 3. Mudança de Variável**
4. Loss
5. O que são Flows
6. Coupling Flows
7. Discreto vs. Contínuo
8. De NFs a *Flow Matching*
9. Panorama Geral

Mudança de Variável – Caso discreto

Mudança de variável no caso discreto é **trivial**. Considere o lançamento de um dado:

$$p_X(x = 1) = \frac{1}{6}$$

- Aplicando uma função inversível, por exemplo $f(x) = x^2$, o espaço amostral do experimento muda:

$$\{1, 2, 3, 4, 5, 6\} \longrightarrow \{1, 4, 9, 16, 25, 36\}$$


- Para calcularmos $p_Z(z = 9)$, basta perceber que $z = 9 \equiv x = 3$: **as probabilidades são iguais.**

Caso discreto

No discreto, cada evento mantém sua massa de probabilidade: só mudam os rótulos.

Mudança de Variável – Caso contínuo

- No contínuo, a noção fundamental passa a ser **intervalo de probabilidade**, não evento pontual.
- Ao aplicar uma função **inversível e derivável**, a densidade sofre uma **deformação**.
- A massa em um volume pode ser achatada ou alongada ao passar pela transformação.
- A altura da densidade é **inversamente proporcional** ao alargamento: área total sempre = 1.



Mudança de Variável – Equação base

A conservação de probabilidade exige que infinitesimais de probabilidade se preservem:

$$p(x) dx = p(z) dz$$

- Isso é a lei fundamental da mudança de variável em densidades.
- Intuitivamente: a área sob a curva em um intervalo transformado deve ser igual à área no intervalo original.

Mudança de Variável – Fórmula explícita

Reorganizando, expressamos $p(x)$ em função de $p(z)$:

$$p(x) dx = p(z) dz \quad \implies \quad p(x) = p(z) \left| \frac{dz}{dx} \right|$$


Por que o módulo?

Garante que:

- o resultado seja **positivo** (densidades são não negativas);
- não precisamos nos preocupar com direções de integração/derivação.

Mudança de Variável – Exemplo: log-normal

Setup: $X \sim \mathcal{N}(0, 1)$ e $Z = \exp(X)$. Qual é a densidade $p_Z(z)$?



Mudança de Variável – Solução log-normal

Passos

1. Densidade de X : $p_X(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$.
2. Como $z = \exp(x)$, a inversa é $x = \ln(z)$.
3. $P(Z \leq z) = P(X \leq \ln z)$, logo $\text{CDF}_Z(z) = \text{CDF}_X(\ln z)$.
4. Derivando: $p_Z(z) = p_X(\ln z) \frac{\partial(\ln z)}{\partial z}$.
5. Substituindo $p_X(\ln z)$ e $\frac{\partial(\ln z)}{\partial z} = \frac{1}{z}$:

$$p_Z(z) = \underbrace{\frac{1}{\sqrt{2\pi}} \exp\left(-\frac{(\ln z)^2}{2}\right)}_{p_X(\ln z)} \cdot \underbrace{\frac{1}{z}}_{\partial(\ln z)/\partial z} = \frac{1}{z\sqrt{2\pi}} \exp\left(-\frac{(\ln z)^2}{2}\right).$$

6. Essa é a densidade **log-normal**.

Mudança de Variável – Caso multidimensional

Em mais de uma dimensão, a derivada $\left| \frac{dz}{dx} \right|$ vira o **módulo do determinante da matriz Jacobiana**:

$$p_X(x) = p_Z(z) \left| \det \frac{\partial z}{\partial x} \right| = p_Z(z) \left| \det \frac{\partial f(x)}{\partial x} \right|, \quad z = f(x).$$

- O caso 1D já visto é um caso particular (determinante de uma matriz 1×1).
- Escrevendo em função do gerador $f: z \rightarrow x$ (caminho de amostragem), a forma equivalente usa o expoente -1 :

$$p_X(x) = p_Z(z) \left| \det \frac{\partial f(z, \theta)}{\partial z} \right|^{-1}.$$

- É essa forma multidimensional, com o **log-determinante**, que aparece na loss a seguir.

Visão Geral

1. Modelos Geradores – Revisão
2. Visão Geral de Normalizing Flows
3. Mudança de Variável
- 4. Loss**
5. O que são Flows
6. Coupling Flows
7. Discreto vs. Contínuo
8. De NFs a *Flow Matching*
9. Panorama Geral

Loss – *Maximum Likelihood*

Para treinar, seguimos o *framework* de maximizar a **verossimilhança** dos dados:

$$\hat{\theta} = \operatorname{argmax}_{\theta} \left[\prod_{i=1}^N P(x^{(i)} \mid \theta) \right]$$

- O produto vem da suposição de independência das amostras.
- Usualmente trabalhamos com a log-verossimilhança (soma, não produto) e a minimizamos com sinal trocado.

Loss – NLL passo a passo (1/2)

Passo 1: trocamos produto por soma negativa (NLL):

$$\hat{\theta} = \operatorname{argmax}_{\theta} \left[\prod_i P(x^{(i)} \mid \theta) \right]$$

Produtos de muitas probabilidades pequenas sofrem *underflow* numérico. Aplicando o logaritmo, o produto vira soma e a otimização fica estável.

Loss – NLL passo a passo (1/2)

Passo 1: trocamos produto por soma negativa (NLL):

$$\begin{aligned}\hat{\theta} &= \operatorname{argmax}_{\theta} \left[\prod_i P(x^{(i)} \mid \theta) \right] \\ &= \operatorname{argmin}_{\theta} \left[\sum_{i=1}^N -\log P(x^{(i)} \mid \theta) \right]\end{aligned}$$

Mudança de variável do *flow*

$$p_X(x) = p_Z(z) \left| \frac{\partial f(z, \theta)}{\partial z} \right|^{-1}$$

Vamos substituir $P(x^{(i)} \mid \theta)$ na expressão acima.

Loss – NLL passo a passo (2/2)

Passo 2: substituir p_X pela mudança de variável:

$$\hat{\theta} = \operatorname{argmin}_{\theta} \left[\sum_{i=1}^N -\log \left(P(\mathbf{z}^{(i)}) \left| \frac{\partial f(\mathbf{z}^{(i)}, \theta)}{\partial \mathbf{z}^{(i)}} \right|^{-1} \right) \right]$$

Loss – NLL passo a passo (2/2)

Passo 2: substituir p_X pela mudança de variável:

$$\begin{aligned}\hat{\theta} &= \operatorname{argmin}_{\theta} \left[\sum_{i=1}^N -\log \left(P(z^{(i)}) \left| \frac{\partial f(z^{(i)}, \theta)}{\partial z^{(i)}} \right|^{-1} \right) \right] \\ &= \operatorname{argmin}_{\theta} \left[\sum_{i=1}^N \left[\log \left| \frac{\partial f(z^{(i)}, \theta)}{\partial z^{(i)}} \right| - \log P(z^{(i)}) \right] \right]\end{aligned}$$

Dois termos, dois papéis

- $\log |\det \nabla f|$: depende de θ via a rede. Mede a deformação local de volume induzida pelo *flow*.
- $-\log P(z)$: a distribuição base é fixa (gaussiana), com densidade em forma fechada. θ entra apenas através de $z = f^{-1}(x, \theta)$.

Visão Geral

1. Modelos Geradores – Revisão
2. Visão Geral de Normalizing Flows
3. Mudança de Variável
4. Loss
- 5. O que são Flows**
6. Coupling Flows
7. Discreto vs. Contínuo
8. De NFs a *Flow Matching*
9. Panorama Geral

Flows

Um *flow* é uma função $f(x)$ com quatro propriedades essenciais:

- **Paramétrica:** queremos definir parâmetros aprendíveis.
- **Inversível:** queremos calcular o *flow* nos dois sentidos (amostragem e avaliação).
- **Diferenciável:** queremos otimizar via *backprop*.
- **Jacobiana tratável:** conseguimos computar a inversa e o determinante da Jacobiana de **maneira eficiente**.

Desafio de engenharia

Satisfazer os quatro requisitos simultaneamente é o que define um *flows*.


Flows – Composição

A classe de funções diferenciáveis e inversíveis é **fechada em composição**:

$$f = f_k \circ f_{k-1} \circ \cdots \circ f_2 \circ f_1$$

- Isso nos possibilita **projetar camadas** que computam um *flow* e empilhá-las em redes profundas.
- A expressividade vem da composição: cada camada pode ser simples desde que a composição seja rica.

Flows – Caminho direto e inverso



- Caminho direto: $f = f_4 \circ f_3 \circ f_2 \circ f_1$ transforma a distribuição base em $p(x)$ (cinza).
- Caminho inverso: $f^{-1} = f_1^{-1} \circ f_2^{-1} \circ f_3^{-1} \circ f_4^{-1}$ faz o retorno (verde).

Flows – Jacobiana da composição

Pela regra da cadeia, o determinante da Jacobiana de uma composição é o **produto dos determinantes**:

$$\left| \frac{\partial f[z, \theta]}{\partial z} \right| = \left| \frac{\partial f_k[f_{k-1}, \theta_k]}{\partial f_{k-1}} \right| \cdot \left| \frac{\partial f_{k-1}[f_{k-2}, \theta_{k-1}]}{\partial f_{k-2}} \right| \dots \left| \frac{\partial f_1[z, \theta_1]}{\partial z} \right|$$

- Por isso, basta que cada camada tenha Jacobiana fácil de calcular para que a rede inteira também tenha.
- Esse é o princípio que guia o design de arquiteturas de *flows*.

Linear Flow

Uma transformação **linear** pode ser um *Linear Flow* se a matriz admitir inversa:

$$f(x) = \theta x + b \quad f^{-1}(z) = \theta^{-1}(z - b)$$

Problemas

- **Pouco expressiva:** composição de transformações lineares continua linear.
- Determinante e inversa de matriz densa: custo $O(d^3)$.

Linear Flow – Custo por estrutura

Impondo estrutura na matriz θ , reduzimos drasticamente o custo de inverter e de calcular o determinante. Diagonal é barata mas muito restritiva; LU factorized e 1×1 convolution (Glow) são os melhores compromissos na prática.

Estrutura	Inversa	Determinante
Full	$O(d^3)$	$O(d^3)$
Diagonal	$O(d)$	$O(d)$
Triangular	$O(d^2)$	$O(d)$
Block Diagonal	$O(c^3 d)$	$O(c^3 d)$
LU Factorized	$O(d^2)$	$O(d)$
Spatial Convolution	$O(d \log d)$	$O(d)$
1×1 Convolution	$O(c^3 + c^2 d)$	$O(c^3)$

LU factorized e spatial/1×1 convolution: Kingma & Dhariwal (2018); Hoogeboom et al. (2019). d : dimensão; c : canais.


Visão Geral

1. Modelos Geradores – Revisão
2. Visão Geral de Normalizing Flows
3. Mudança de Variável
4. Loss
5. O que são Flows
- 6. Coupling Flows**
7. Discreto vs. Contínuo
8. De NFs a *Flow Matching*
9. Panorama Geral

Coupling Flows⁵

Dividir a entrada em duas metades e transformar apenas uma delas, condicionando na outra:

$$f(x) = \begin{bmatrix} x^A \\ \hat{f}(x^B | \theta(x^A)) \end{bmatrix}$$




⁵Laurent Dinh, Jascha Sohl-Dickstein e Samy Bengio. "Density Estimation using Real NVP". Em: [ICLR](#). 2017.

Coupling Flows – Inversa


Como x^A é copiado direto, temos $z^A = x^A$. Para inverter basta aplicar $\hat{f}^{-1}$ em z^B usando a mesma *coupling network* que produziu os parâmetros:

$$f^{-1}(z) = \begin{bmatrix} z^A \\ \hat{f}^{-1}(z^B \mid \theta(z^A)) \end{bmatrix}$$



Coupling Flows – Combinando com permutações

Um único *coupling layer* só transforma metade das dimensões. **Alternando permutações** (ou *linear flows*) entre as camadas, todas as dimensões são afetadas:



Cada camada: permutação $\rightarrow$ split $\rightarrow$ coupling transform $\rightarrow$ concat.

Coupling Flows – Jacobiana por blocos

Por que essa arquitetura? Porque a Jacobiana é **triangular por blocos**:

Lembrete: como ler a Jacobiana

A linha i reúne as derivadas parciais da i -ésima componente da saída, e a coluna j reúne as derivadas em relação à j -ésima componente da entrada. Em símbolos, $[Df]_{ij} = \partial f_i / \partial x_j$.

$$Df(x) = \begin{matrix} & \begin{matrix} x^A & x^B \end{matrix} \\ \begin{matrix} x^A \\ \hat{f} \end{matrix} & \begin{pmatrix} \frac{\partial x^A}{\partial x^A} & \frac{\partial x^A}{\partial x^B} \\ \frac{\partial \hat{f}}{\partial x^A} & \frac{\partial \hat{f}}{\partial x^B} \end{pmatrix} \end{matrix} = \begin{bmatrix} I & 0 \\ \frac{\partial \hat{f}}{\partial x^A} & \frac{\partial \hat{f}}{\partial x^B} \end{bmatrix}$$

- $\partial x^A / \partial x^A = I$: bloco superior-esquerdo (identidade).
- $\partial x^A / \partial x^B = 0$: bloco superior-direito (pois x^A é só copiado, não depende de x^B).

Coupling Flows – Exemplo concreto em 4D

Seja $x = (x_1, x_2, x_3, x_4)$ com $x^A = (x_1, x_2)$ e $\hat{f}(x^B) = (g_1(x_1, x_2) \cdot x_3, g_2(x_1, x_2) \cdot x_4)$.
Rotulamos as colunas pela entrada x_j e as linhas pela saída $f_i(x)$:

$$Df = \begin{matrix} & x_1 & x_2 & x_3 & x_4 \\ \begin{matrix} f_1 \\ f_2 \\ f_3 \\ f_4 \end{matrix} & \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ \frac{\partial g_1}{\partial x_1} x_3 & \frac{\partial g_1}{\partial x_2} x_3 & g_1 & 0 \\ \frac{\partial g_2}{\partial x_1} x_4 & \frac{\partial g_2}{\partial x_2} x_4 & 0 & g_2 \end{pmatrix} \end{matrix}$$

Determinante via triangularidade

$$\det Df = 1 \cdot 1 \cdot g_1 \cdot g_2 = g_1 \cdot g_2$$

Basta o **produto dos elementos diagonais do bloco inferior-direito**. Os termos da linha inferior à esquerda **não importam** para o determinante.

Coupling Flows – Determinante geral

Generalizando, o determinante da Jacobiana é:

$$|\det Df| = \left| \det \frac{\partial \hat{f}(x^B | \theta(x^A))}{\partial x^B} \right|$$

- Só depende do bloco inferior-direito.
- Se $\hat{f}$ for aplicada **elemento a elemento**, esse bloco é **diagonal** e o determinante é trivial.
- Consequência: todos os modelos modernos de *flow* para imagens (*RealNVP*, *Glow*, *Flow++*) usam alguma variante dessa ideia.

Affine Coupling Flows⁶ – Forward

A escolha mais comum de $\hat{f}$ é uma **transformação afim** elemento a elemento:

Forward pass

$$y^B = x^B \odot \exp(s(x^A)) + t(x^A), \quad y^A = x^A.$$

- A coupling network $\theta(x^A)$ produz **dois vetores**: s (log-escala) e t (translação).
- $\exp(\cdot)$ garante escala positiva e permite expressar alongamento ($s > 0$) e compressão ($s < 0$).
- Jacobiana **diagonal**: $\det = \prod_i \exp(s_i)$, logo $\log |\det| = \sum_i s_i$ (barato).

⁶Laurent Dinh, Jascha Sohl-Dickstein e Samy Bengio. “Density Estimation using Real NVP”. Em: [ICLR](#). 2017.

Affine Coupling Flows – Inverse

A inversa é **quase de graça**: note que a coupling network usa apenas x^A , que é copiado para y^A . Então podemos **reaplicá-la** na direção inversa:

Inverse pass


1. $x^A = y^A$ (cópia direta).
2. Calcule $s = s(x^A)$, $t = t(x^A)$ usando a mesma rede.
3. $x^B = (y^B - t) \odot \exp(-s)$.

Crucial

A *coupling network* pode ser **qualquer** rede neural (não precisa ser inversível!) – porque ela nunca é invertida, só reavaliada no lado correto.

Exemplo Numérico: *Forward* (1/2)

Vetor de features 4D $x = (1, 2, 3, 4)$. O *split* separa $x^A = (1, 2)$, que é **copiado**, de $x^B = (3, 4)$, que é **transformado**. A coupling network devolve $s = (0.3, -0.2)$ e $t = (-0.5, 0.5)$.




Affine transform, elemento a elemento (cada $y_i^B = x_i^B e^{s_i} + t_i$):

$$y_1^B = 3 e^{0.3} - 0.5 \approx 3.55, \quad y_2^B = 4 e^{-0.2} + 0.5 \approx 3.77, \quad \log |\det J| = s_1 + s_2 = 0.1.$$

Exemplo Numérico: *Inverse* (2/2)

A inversa parte de $f(x) = (1, 2, 3.55, 3.77)$. Como $x^A = y^A$ já está disponível, a coupling network é reavaliada (nunca invertida) para recuperar s, t e desfazer a transformação em x^B .



Desfazendo a transform, elemento a elemento (cada $x_i^B = (y_i^B - t_i) e^{-s_i}$):

$$x_1^B = (3.55 + 0.5) e^{-0.3} \approx 3.00, \quad x_2^B = (3.77 - 0.5) e^{0.2} \approx 4.00. \quad \checkmark$$

Affine Coupling Flows – PyTorch

```
1 class AffineCoupling(nn.Module):
2     def __init__(self, d, hidden=128):
3         super().__init__()
4         self.half = d // 2
5         self.net = nn.Sequential(
6             nn.Linear(self.half, hidden), nn.ReLU(),
7             nn.Linear(hidden, 2 * self.half),
8         )
9
10    def forward(self, x):
11        x_a, x_b = x[:, :self.half], x[:, self.half:]
12        s, t = self.net(x_a).chunk(2, dim=-1)
13        s = torch.tanh(s)
14        y_b = x_b * torch.exp(s) + t
15        log_det = s.sum(dim=-1)
16        return torch.cat([x_a, y_b], dim=-1), log_det
17
18    # inverse: swap + / - and exp(s) / exp(-s)
```

Ideias-chave: split em A/B ; rede prediz (s, t) a partir de A ; $\tanh$ em s estabiliza; $\log_det$ acumulado é a soma dos s .

Limitações dos *Normalizing Flows*

A exigência de inversibilidade impõe restrições aos NFs:

- **Dimensão preservada:** a bijeção obriga $\dim(z) = \dim(x)$, logo não há gargalo de compressão como no VAE. A consequência é um custo alto de memória e de compute em imagens, o que motiva arquiteturas *multi-scale* (operação *squeeze*) em RealNVP e Glow.
- **Tensão expressividade × tratabilidade:** cada camada precisa manter a Jacobiana barata, então a expressividade vem de **empilhar muitas camadas** simples, não de camadas individualmente poderosas.

Para onde isso aponta


Custo e escala são exatamente o que os *flows* contínuos (*flow matching*) e as arquiteturas de 2024–2025 atacam, como veremos a seguir.

Visão Geral


1. Modelos Geradores – Revisão
2. Visão Geral de Normalizing Flows
3. Mudança de Variável
4. Loss
5. O que são Flows
6. Coupling Flows
- 7. Discreto vs. Contínuo**
8. De NFs a *Flow Matching*
9. Panorama Geral

Discreto vs. Contínuo – *Dequantization*

- Como **imagens são quantizadas** (pixels inteiros 0–255), podemos ter problemas de singularidades ao ajustar uma densidade contínua.
- Solução: adicionar **ruído**, usualmente uniforme em $[0, 1)$, à distribuição modelada.
- Isso transforma picos discretos em uma densidade contínua passível de modelagem.



Discrete
distribution



Dequantized
distribution

Visão Geral

1. Modelos Geradores – Revisão
2. Visão Geral de Normalizing Flows
3. Mudança de Variável
4. Loss
5. O que são Flows
6. Coupling Flows
7. Discreto vs. Contínuo
- 8. De NFs a *Flow Matching***
9. Panorama Geral

Flows contínuos⁸

E se, em vez de empilhar um número finito de camadas, deixássemos a profundidade tender ao contínuo? O *flow* passa a ser indexado por um **tempo** t e definido por uma **equação diferencial**:

$$\frac{dz(t)}{dt} = f(z(t), t, \theta)$$

- Amostrar e avaliar viram **integrar a ODE** (*Neural ODE*, *FFJORD*⁷).
- A mudança de variável também vira contínua: o **log-determinante** se transforma em um **traço** integrado no tempo:

$$\frac{\partial \log p(z(t))}{\partial t} = -\text{tr}\left(\frac{\partial f}{\partial z(t)}\right)$$

- Vantagem: não precisamos mais projetar cada camada para ter Jacobiana tratável. A desvantagem é o custo de integrar a ODE durante o treino.


⁷Will Grathwohl et al. “FFJORD: Free-form Continuous Dynamics for Scalable Reversible Generative Models”. Em: [ICLR](#). 2019.

⁸Ricky T. Q. Chen et al. “Neural Ordinary Differential Equations”. Em: [NeurIPS](#). 2018.

Flow Matching – Caminho de probabilidade⁹

Integrar a ODE a cada passo de treino é caro. A ideia que destravou os *flows* contínuos foi treinar **sem simular** a ODE (*simulation-free*). Para isso, partimos de um **caminho de probabilidade** $p_t(x)$, $t \in [0, 1]$, ligando a base aos dados:

$$p_0 = \mathcal{N}(0, I) \text{ (ruído)}, \quad p_1 = p_{\text{dados}}.$$



- O modelo aprende a **transportar** amostras ao longo desse caminho, de p_0 até p_1 .
- Resta definir como se faz esse transporte.

⁹Yaron Lipman et al. "Flow Matching for Generative Modeling". Em: [ICLR](#). 2023.

Flow Matching – Campo vetorial alvo

O transporte é descrito por um **campo vetorial** $u_t(x)$ que gera o caminho p_t via uma ODE:

$$\frac{dx_t}{dt} = u_t(x_t), \quad x_0 \sim p_0.$$

- Pense em u_t como o vento que carrega cada partícula x_t . Integrando de $t = 0$ a $t = 1$, a partícula sai de p_0 e chega em p_1 .
- Se aprendermos uma rede $v_\theta(x, t) \approx u_t(x)$, basta integrar $\dot{x}_t = v_\theta(x_t, t)$ para amostrar.

Objetivo natural: *Flow Matching*

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t, x_t \sim p_t} \|v_\theta(x_t, t) - u_t(x_t)\|^2.$$

Problema

Não conhecemos u_t em forma fechada para um caminho marginal arbitrário, então essa *loss* **não é usável** diretamente.

Conditional Flow Matching

Truque: fixe uma amostra x_1 dos dados e defina:

- um **caminho condicional** $p_t(x | x_1)$ (por exemplo, uma gaussiana centrada em x_1 que encolhe com t);
- um **campo condicional** $u_t(x | x_1)$ que o gera.

Os dois têm **forma fechada** e são fáceis de amostrar. Os marginais se recuperam integrando sobre $x_1 \sim p_{\text{dados}}$. A *loss* condicional substitui o alvo desconhecido pelo condicional:

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, x_1, x_t \sim p_t(\cdot | x_1)} \|v_\theta(x_t, t) - u_t(x_t | x_1)\|^2.$$

Teorema (Lipman et al., 2023)

$\nabla_\theta \mathcal{L}_{\text{CFM}} = \nabla_\theta \mathcal{L}_{\text{FM}}$: os dois objetivos têm o **mesmo gradiente**. Treinamos com o alvo condicional e, no ótimo, v_θ aproxima o campo marginal u_t .

Rectified Flow – Caminhos retos¹⁰

Escolha mais simples possível para o caminho condicional: interpolação **linear** entre ruído $x_0 \sim p_0$ e dado $x_1 \sim p_{\text{dados}}$:

$$x_t = (1 - t) x_0 + t x_1.$$

- Derivando no tempo, $\frac{dx_t}{dt} = x_1 - x_0$, **constante** na trajetória.
- O alvo condicional é o próprio vetor de deslocamento:

$$u_t(x_t \mid x_0, x_1) = x_1 - x_0.$$

- A *loss* colapsa em uma **regressão simples**:

$$\mathcal{L}_{\text{RF}}(\theta) = \mathbb{E}_{t, x_0, x_1} \|v_{\theta}(x_t, t) - (x_1 - x_0)\|^2.$$

Por que retas importam

Trajetórias retas são o transporte de menor comprimento, então a ODE de amostragem precisa de **poucos passos** (Euler com K pequeno já gera boas amostras).

¹⁰Xingchao Liu, Chengyue Gong e Qiang Liu. “Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow”. Em: ICLR. 2023.

Rectified Flow – Treino e amostragem

Treino (por *minibatch*)

1. amostre $\mathbf{x}_0 \sim \mathcal{N}(0, \mathbf{I})$, $\mathbf{x}_1 \sim p_{\text{dados}}$, $t \sim \mathcal{U}[0, 1]$;
2. compute $\mathbf{x}_t = (1 - t) \mathbf{x}_0 + t \mathbf{x}_1$;
3. prediga $\hat{\mathbf{v}} = \mathbf{v}_{\theta}(\mathbf{x}_t, t)$;
4. minimize $\|\hat{\mathbf{v}} - (\mathbf{x}_1 - \mathbf{x}_0)\|^2$.

Amostragem (Euler, K passos)

1. $\mathbf{x} \leftarrow \mathbf{x}_0 \sim \mathcal{N}(0, \mathbf{I})$;
2. para $k = 0, 1, \dots, K - 1$:

$$\mathbf{x} \leftarrow \mathbf{x} + \frac{1}{K} \mathbf{v}_{\theta}\left(\mathbf{x}, \frac{k}{K}\right);$$

3. retorne $\mathbf{x}$ como amostra de p_1 .

- Difusão clássica costuma usar $K \approx 1000$. Com *rectified flow*, $K \in [4, 25]$ já produz amostras competitivas.
- Nenhuma simulação de ODE durante o treino, **simulation-free**.

A ideia de *flow* no estado da arte: SD3 e Flux

- *Rectified flow* é o **objetivo de treino** por trás de modelos como **Stable Diffusion 3¹¹** e **Flux**.
- A mesma intuição dos NFs, transformar uma distribuição base simples em dados por uma aplicação aprendida, está no **núcleo** dos geradores de imagem mais capazes de hoje.
- A fronteira entre *normalizing flows* e modelos difusores ficou **difusa**: ambos podem ser vistos como transporte de probabilidade ao longo de uma trajetória.

¹¹Patrick Esser et al. “Scaling Rectified Flow Transformers for High-Resolution Image Synthesis”. Em: [ICML](#). 2024.

Visão Geral

1. Modelos Geradores – Revisão
2. Visão Geral de Normalizing Flows
3. Mudança de Variável
4. Loss
5. O que são Flows
6. Coupling Flows
7. Discreto vs. Contínuo
8. De NFs a *Flow Matching*
- 9. Panorama Geral**

Normalizing Flows – Aplicações

NFs brilham onde a **densidade tratável** importa e, desde 2024, voltaram a ser competitivos também em **geração**:

Onde a densidade tratável importa

- **Detecção de anomalias:** dados anômalos têm $\log p_X(x)$ baixo (indústria, segurança de redes).
- **Inferência variacional:** substituem $q(z | x)$ do VAE por uma distribuição expressiva.
- **Física e química:** *Boltzmann Generators* amostram conformações moleculares em equilíbrio.

Geração de imagem e vídeo


TarFlow, *STARFlow* e *STARFlow-V* (2024–2025) aproximam os NFs da qualidade dos modelos difusores.

Flow matching em modelos SOTA

A formulação contínua (*rectified flow*) treina geradores de ponta como **Stable Diffusion 3** e **Flux**.

Onde NFs ficam no trilema?

- **Amostragem rápida:** ✓ (1 forward).
- **Cobertura / densidade:** ✓ (treino por MLE cobre toda a distribuição).
- **Qualidade visual:** historicamente ✗, mas NFs recentes (*TarFlow*, *STARFlow*) melhoraram nesse quesito.



- *Normalizing Flows* são modelos geradores capazes de **amostragem e avaliação da probabilidade**.
- São construídos com base em uma série de **transformações invertíveis**, com Jacobianas tratáveis.
- Em 2024–2025, NFs autônomos (*TarFlow*, *STARFlow*) passaram a igualar modelos difusores em vários *benchmarks* de imagem.
- Sua versão contínua, o *flow matching / rectified flow*, está no núcleo de geradores SOTA como SD3 e Flux.

Quando usar NF

Quando precisar de **densidade tratável**: detecção de anomalias, compressão, inferência variacional, física computacional.

Resumo

- *Normalizing Flows*: transformações **inversíveis e diferenciáveis** de uma distribuição base em uma modelada.
- Treinados por **máxima verossimilhança**, usando a fórmula de mudança de variável com o log-determinante da Jacobiana.
- *Linear flows* são limitados; estruturas como LU, 1×1 convolução reduzem custo.
- *Coupling flows* (RealNVP, Glow) dão expressividade com Jacobiana triangular.
- *Dequantization* é necessária para dados discretos (imagens).
- Desde 2024, NFs voltaram a ser competitivos em geração (*TarFlow*, *STARFlow*), e sua versão contínua (*flow matching*) treina modelos SOTA como SD3 e Flux.

Leituras Recomendadas

- Capítulo 16: Simon J. D. Prince. Understanding Deep Learning. MIT Press, 2023
- Ivan Kobyzev, Simon J. D. Prince e Marcus A. Brubaker. “Normalizing Flows: An Introduction and Review of Current Methods”. Em: [IEEE TPAMI](#) 43.11 (2020), pp. 3964–3979

Referências I

- [1] Ricky T. Q. Chen et al. “Neural Ordinary Differential Equations”. Em: [NeurIPS](#). 2018.
- [2] Laurent Dinh, Jascha Sohl-Dickstein e Samy Bengio. “Density Estimation using Real NVP”. Em: [ICLR](#). 2017.
- [3] Patrick Esser et al. “Scaling Rectified Flow Transformers for High-Resolution Image Synthesis”. Em: [ICML](#). 2024.
- [4] Will Grathwohl et al. “FFJORD: Free-form Continuous Dynamics for Scalable Reversible Generative Models”. Em: [ICLR](#). 2019.
- [5] Jiatao Gu et al. “STARFlow: Scaling Latent Normalizing Flows for High-resolution Image Synthesis”. Em: [arXiv preprint arXiv:2506.06276](#) (2025).
- [6] Durk P. Kingma e Prafulla Dhariwal. “Glow: Generative Flow with Invertible 1x1 Convolutions”. Em: [NeurIPS](#). Vol. 31. 2018.
- [7] Ivan Kobyzev, Simon J. D. Prince e Marcus A. Brubaker. “Normalizing Flows: An Introduction and Review of Current Methods”. Em: [IEEE TPAMI](#) 43.11 (2020), pp. 3964–3979.
- [8] Yaron Lipman et al. “Flow Matching for Generative Modeling”. Em: [ICLR](#). 2023.
- [9] Xingchao Liu, Chengyue Gong e Qiang Liu. “Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow”. Em: [ICLR](#). 2023.
- [10] Simon J. D. Prince. [Understanding Deep Learning](#). MIT Press, 2023.
- [11] Shuangfei Zhai et al. “Normalizing Flows are Capable Generative Models”. Em: [ICML](#). 2025.