

# Deep Learning

## Neurônio MP e Perceptron

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory  
PUCRS

junho de 2026

# Overview

---

1. Introdução
2. Neurônio MP
3. Perceptron
4. O problema XOR

# Visão Geral

---

## 1. Introdução

## 2. Neurônio MP

## 3. Perceptron

## 4. O problema XOR

# Bioinspiração

---

- Quando não sabemos como fazer algo podemos copiar!
- Temos diversos exemplos de inteligência na natureza
- Computação Bioinspirada
  - Algoritmos Genéticos
  - Computação Evolutiva
  - Redes Neurais Artificiais...



# Visão Geral

---

1. Introdução

**2. Neurônio MP**

3. Perceptron

4. O problema XOR

# MP Neuron<sup>1</sup>

---

- Importância histórica por ser o primeiro modelo computacional de um neurônio
- Possibilitou mapear a lógica proposicional em neurônios artificiais
- Possível origem do termo *neurônio artificial* e *redes neurais artificiais*
- Modelo matemático, sem implementação concreta em um dispositivo computacional




Figura: Warren S. McCulloch (a direita) e Walter Pitts (a esquerda).


---

<sup>1</sup>Warren S McCulloch e Walter Pitts. "A logical calculus of the ideas immanent in nervous activity". Em: [The bulletin of mathematical biophysics](#) 5 (1943), pp. 115–133.

# MP Neuron – Funcionamento


---

- Entradas binárias
- Estímulos podem ser:
  - Excitatórios: Ativos quando a entrada é Verdadeira
  - Inibitórios: Ativos quando a entrada é Falsa
- Neurônio dispara quando a quantidade de estímulos excitatórios ultrapassa um limiar  $\theta$




## MP Neuron – Exemplo como *AND*

---




## MP Neuron – Exemplo como *OR*

---



## MP Neuron – Entrada inibitória $X_0$ *AND* NOT $X_1$

---



# Visão Geral

---

1. Introdução
2. Neurônio MP
- 3. Perceptron**
4. O problema XOR

# Perceptron

---

Frank Rosenblatt<sup>2</sup> fez algumas modificações no Neurônio MP

$$\hat{y} = \varphi(X\theta^\top)$$

- Entradas são números reais
- Cada entrada é ponderada por um parâmetro
- Existe um algoritmo de aprendizado para definir  $\theta$
- Função de ativação  $\varphi(z) = \text{sinal}(z) = \begin{cases} +1, & z \geq 0 \\ -1, & z < 0 \end{cases}$

---

<sup>2</sup>F Rosenblatt. "The perceptron: a probabilistic model for information storage and organization in the brain". en. Em: [Psychol. Rev.](#) 65.6 (nov. de 1958), pp. 386–408.

# Perceptron

---

“(...) identities of this sort must be *learned* (...) the number of functional units in the storage system or memory, should be less than the number of forms or memories to be retained.”<sup>3</sup>

---

<sup>3</sup>F Rosenblatt. “The perceptron: a probabilistic model for information storage and organization in the brain”. en. Em: Psychol. Rev. 65.6 (nov. de 1958), pp. 386–408.

# Perceptron

---

- Classificador de imagens
- Resolução  $20 \times 20$
- 400 fotocélulas capturavam a imagem
- Pesos eram controlados por potenciômetros




Figura: Frank Rosenblatt e o Perceptron

# Algoritmo de Aprendizado do Perceptron (PLA)

---


- 1: Assuma  $X^{(i)}$  com primeira componente igual a 1 (truque do bias)
- 2: Inicialize os pesos  $\theta$  aleatoriamente
- 3: **while** existirem observações mal classificadas **do**
- 4:     Selecione  $X^{(i)}$  tal que  $\text{sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 5:     Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 6: **end while**

# Algoritmo de Aprendizado do Perceptron (PLA)

---



- Vamos ver um exemplo de treinamento com base no conjunto de dados abaixo
- A direita teremos uma representação do espaço de *features* junto da fronteira de decisão

| $X_1$ | $X_2$ | $y$ |
|-------|-------|-----|
| 1     | 1     | 1   |
| -1    | 1     | 1   |
| 1     | -1    | 1   |
| -1    | -1    | -1  |



# Algoritmo de Aprendizado do Perceptron (PLA)



- 1: Assuma  $X^{(i)}$  com primeira componente igual a 1 (truque do bias)
- 2: Inicialize os pesos  $\theta$  aleatoriamente
- 3: **while** existirem observações mal classificadas  
**do**
- 4:     Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 5:     Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 6: **end while**



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
  **do**
- 3:   Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:   Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [-1, -1, -1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
do
- 3:     Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:     Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [-1, -1, -1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas
- 3:   do
- 4:    Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 5:    Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 6:   end while



$$\theta^\top = [-1, -1, -1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
  **do**
- 3:   Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:   Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [0, -2, 0] = [-1, -1, -1] + [1, -1, 1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
do
- 3:     Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:     Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [0, -2, 0]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas
- 3: **do**
- 4:   Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 5:   Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 6: **end while**



$$\theta^\top = [0, -2, 0]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
  **do**
- 3:   Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:   Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [1, -1, 1] = [0, -2, 0] + [1, 1, 1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
**do**
- 3:     Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:     Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [1, -1, 1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas
- 3:     do
- 4:         Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 5:         Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 6:     end while



$$\theta^\top = [1, -1, 1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
do
- 3:   Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:   Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [2, 0, 0] = [1, -1, 1] + [1, 1, -1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
do
- 3:     Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:     Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [2, 0, 0]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas
- 3:     do
- 4:         Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 5:         Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 6:     end while



$$\theta^\top = [2, 0, 0]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
  **do**
- 3:   Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:   Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [1, 1, 1] = [2, 0, 0] + (-1)[1, -1, -1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)

- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
do
- 3:     Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:     Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**



$$\theta^\top = [1, 1, 1]$$



# Algoritmo de Aprendizado do Perceptron (PLA)


- 1: Inicialize os pesos  $\theta$  aleatoriamente
- 2: **while** existirem observações mal classificadas  
  **do**
- 3:   Selecione  $X^{(i)}$  tal que  $\text{ sinal}(X^{(i)}\theta^\top) \neq y^{(i)}$
- 4:   Atualize:  $\theta \leftarrow \theta + y^{(i)}X^{(i)}$
- 5: **end while**

$$\theta^\top = [1, 1, 1]$$



# Considerações sobre o PLA

- Descoberto empiricamente
- Intuição geométrica: produto escalar
  - positivo quando  $\alpha < 90^\circ$
  - negativo quando  $\alpha > 90^\circ$
- A regra de atualização de  $\theta$  ajusta o ângulo do vetor de pesos em relação às instâncias
- Sempre converge para problemas linearmente separáveis



# Visão Geral


---

1. Introdução
2. Neurônio MP
3. Perceptron
- 4. O problema XOR**

# Limitação do Perceptron

---


- O Perceptron é um modelo linear (traça um hiperplano como fronteira de decisão)
- Marvin Minsky e Seymour Papert salientaram essa limitação com o problema XOR<sup>4</sup>




---

<sup>4</sup>Marvin Minsky e Seymour Papert. "Perceptron: an introduction to computational geometry". Em: [The MIT Press, Cambridge, expanded edition 19.88](#) (1969), p. 2.

## Vamos observar esses dois Perceptrons




| $X_1$ | $X_2$ | $y$ |
|-------|-------|-----|
| -1    | -1    |     |
| -1    | 1     |     |
| 1     | -1    |     |
| 1     | 1     |     |




| $X_1$ | $X_2$ | $y$ |
|-------|-------|-----|
| -1    | -1    |     |
| -1    | 1     |     |
| 1     | -1    |     |
| 1     | 1     |     |

# Vamos observar esses dois Perceptrons



**OR**



| $X_1$ | $X_2$ | $y$ |
|-------|-------|-----|
| -1    | -1    | -1  |
| -1    | 1     | 1   |
| 1     | -1    | 1   |
| 1     | 1     | 1   |





**AND:**

| $X_1$ | $X_2$ | $y$ |
|-------|-------|-----|
| -1    | -1    | -1  |
| -1    | 1     | -1  |
| 1     | -1    | -1  |
| 1     | 1     | 1   |



# Resolvendo XOR



# Resolvendo XOR



# Resolvendo XOR



# Resolvendo XOR

---

- Quando organizamos vários Perceptrons em camadas chamamos de *MultiLayer Perceptron* (MLP)
- PLA não funciona para MLP
- Essa limitação minou o interesse por redes neurais durante anos (Inverno da IA)
- Para treinar um MLP vamos precisar usar retropropagação de erros (*backpropagation*) e descida de gradiente (*gradient descent*)

# Leituras Recomendadas

---

- Capítulo 1: Y.S. Abu-Mostafa, M. Magdon-Ismail e H.T. Lin. Learning from Data: A Short Course. AMLBook.com, 2012. ISBN: 978-1-60049-006-4
- Capítulo 1: Simon Haykin. Neural networks and learning machines, 3/E. Pearson Education India, 2009

# Referências

---

- [1] Y.S. Abu-Mostafa, M. Magdon-Ismail e H.T. Lin. Learning from Data: A Short Course. AMLBook.com, 2012. ISBN: 978-1-60049-006-4.
- [2] Simon Haykin. Neural networks and learning machines, 3/E. Pearson Education India, 2009.
- [3] Warren S McCulloch e Walter Pitts. “A logical calculus of the ideas immanent in nervous activity”. Em: The bulletin of mathematical biophysics 5 (1943), pp. 115–133.
- [4] Marvin Minsky e Seymour Papert. “Perceptron: an introduction to computational geometry”. Em: The MIT Press, Cambridge, expanded edition 19.88 (1969), p. 2.
- [5] F Rosenblatt. “The perceptron: a probabilistic model for information storage and organization in the brain”. en. Em: Psychol. Rev. 65.6 (nov. de 1958), pp. 386–408.