

Deep Learning

Backpropagation

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory
PUCRS

agosto de 2026

Overview

1. Introdução

2. Treinamento de um MLP

- 2.1 Forward Pass
- 2.2 Função de Custo
- 2.3 Backward Pass
- 2.4 Descida de Gradiente

3. Vetorização do Treinamento

Visão Geral

1. Introdução



2. Treinamento de um MLP

- 2.1 Forward Pass
- 2.2 Função de Custo
- 2.3 Backward Pass
- 2.4 Descida de Gradiente

3. Vetorização do Treinamento

MLP

- Um MLP é um aproximador universal de funções^{1,2}
- Contudo, o PLA (*Perceptron Learning Algorithm*) não funciona para um MLP



¹Kurt Hornik, Maxwell Stinchcombe e Halbert White. "Multilayer feedforward networks are universal approximators". Em: [Neural networks](#) 2.5 (1989), pp. 359–366

²George Cybenko. "Approximation by superpositions of a sigmoidal function". Em: [Mathematics of control, signals and systems](#) 2.4 (1989), pp. 303–314

Inverno das Redes Neurais

- Com a publicação de Minsky e Papert (1969) enfatizando as limitações do Perceptron[3] o interesse em redes neurais diminuiu.
 - Pouca verba de pesquisa
 - Por que pesquisar um modelo linear enquanto temos modelos lineares melhores (Regressão Linear) e diversos modelos não-lineares?
 - MLP resolve problemas não-lineares, mas ninguém sabe como treinar um MLP
- Foi apenas 20 anos depois que começaram a surgir as primeiras publicações com um método de treinamento para MLPs e redes neurais em geral³
 - Hinton não alega ter inventado o *backpropagation*, mas ele foi um dos principais responsáveis pela sua popularização

³David E Rumelhart, Geoffrey E Hinton e Ronald J Williams. "Learning Internal Representations by Error Propagation, Parallel Distributed Processing, Explorations in the Microstructure of Cognition, ed. DE Rumelhart and J. McClelland. Vol. 1. 1986". Em: Biometrika 71 (1986), pp. 599–607.

Visão Geral

1. Introdução

2. Treinamento de um MLP

- 2.1 Forward Pass
- 2.2 Função de Custo
- 2.3 Backward Pass
- 2.4 Descida de Gradiente

3. Vetorização do Treinamento

Treinando um MLP

- Vamos calcular a mão uma iteração de treino em um MLP
- **Ideia:** Aplicar a descida de gradiente
- **Função de custo:** *Half Mean Squared Error*⁴

$$J(\theta) = \frac{1}{2N} \sum_i \left(y^{(i)} - \hat{y}^{(i)} \right)^2$$

- **Regra de atualização:**

$$\theta_{t+1} = \theta_t - \eta \nabla J$$

Premissas para simplificar o problema:

- Apenas 2 camadas
- 1 neurônio em cada camada
- Desconsideramos o bias
- Temos apenas um exemplo $y = 1, X_1 = 1$

⁴O fator 1/2 é convenção: simplifica a derivada do quadrático.

Treinando um MLP

Notação e Definições



- $l \in [0, 1, 2, \dots, L]$ é o índice da camada do MLP (L é o número de camadas)
- $\mathbf{X}$ é a entrada do MLP (também pode ser chamado de $a^{(0)}$)
- $\mathbf{y}$ é a variável alvo
- $\theta_{ij}^{(l)}$ é o peso da camada l que conecta a entrada j a saída i
- $z^{(l)}$ é a **pré-ativação** da unidade, $z^{(l)} = a^{(l-1)} \theta^{(l)\top}$
- $a^{(l)}$ é a **ativação** (saída) da unidade $a^{(l)} = \varphi(z^{(l)})$

Treinando um MLP

A função de Ativação

Função Sinal:

$$\varphi(z) = \begin{cases} 1 & z \geq 0 \\ -1 & z < 0 \end{cases}$$



Treinando um MLP

A função de Ativação



Função Sinal:

$$\varphi(z) = \begin{cases} 1 & z \geq 0 \\ -1 & z < 0 \end{cases}$$

Problemas da função sinal

- Não é diferenciável em $z = 0$
- Sua derivada é 0 em todos os outros pontos

Isso impede o aprendizado via descida de gradiente.



Treinando um MLP



A função de Ativação

Função Sigmoid:

$$\varphi(z) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

Solução

A função sigmoide é uma versão “suave” da função sinal e é diferenciável em todo seu domínio.




As Etapas do Treinamento de uma Rede Neural

A cada iteração de treinamento, seguimos quatro passos:

- 1. **Forward Pass:** Computar todas as ativações da rede.
- 2. **Loss Function:** Computar o valor da *Loss Function* que quantifica o quão diferente as saídas são em relação à variável alvo.
- 3. **Backward Pass:** Computar o gradiente da *Loss Function* em relação aos parâmetros da rede.
- 4. **Optimizer:** Usar os gradientes para atualizar os pesos.

```
1 model = MLP()
2 optimizer = SGD(model.parameters(),
3                  lr=0.1)
4 x = torch.tensor(1.0)
5 y = torch.tensor(1.0)
6 model.train()
7 optimizer.zero_grad()
8 y_hat = model(x)
9 loss = (y - y_hat)**2/2
10 loss.backward()
11 optimizer.step()
```

Forward Pass




- Vamos considerar os pesos iniciais como: $\theta^{(1)} = -0.5$ e $\theta^{(2)} = 0.5$.
- Computando o loss para o par $X_1 = 1$, $y = 1$.

Passo a passo (Forward Pass):

1. $z^{(1)} = X_1 \cdot \theta^{(1)} = 1 \cdot (-0.5) = -0.5$

Forward Pass




- Vamos considerar os pesos iniciais como: $\theta^{(1)} = -0.5$ e $\theta^{(2)} = 0.5$.
- Computando o loss para o par $X_1 = 1, y = 1$.

Passo a passo (Forward Pass):

1. $z^{(1)} = X_1 \cdot \theta^{(1)} = 1 \cdot (-0.5) = -0.5$
2. $a^{(1)} = \sigma(z^{(1)}) = \sigma(-0.5) = 0.3775$

Forward Pass




- Vamos considerar os pesos iniciais como: $\theta^{(1)} = -0.5$ e $\theta^{(2)} = 0.5$.
- Computando o loss para o par $X_1 = 1$, $y = 1$.

Passo a passo (Forward Pass):

1. $z^{(1)} = X_1 \cdot \theta^{(1)} = 1 \cdot (-0.5) = -0.5$
2. $a^{(1)} = \sigma(z^{(1)}) = \sigma(-0.5) = 0.3775$
3. $z^{(2)} = a^{(1)} \cdot \theta^{(2)} = 0.3775 \cdot 0.5 = 0.18875$

Forward Pass



- Vamos considerar os pesos iniciais como: $\theta^{(1)} = -0.5$ e $\theta^{(2)} = 0.5$.
- Computando o loss para o par $X_1 = 1, y = 1$.


Passo a passo (Forward Pass):

1. $z^{(1)} = X_1 \cdot \theta^{(1)} = 1 \cdot (-0.5) = -0.5$
2. $a^{(1)} = \sigma(z^{(1)}) = \sigma(-0.5) = 0.3775$
3. $z^{(2)} = a^{(1)} \cdot \theta^{(2)} = 0.3775 \cdot 0.5 = 0.18875$
4. $\hat{y} = a^{(2)} = \sigma(z^{(2)}) = \sigma(0.18875) = 0.5470$

Resumindo

Esse é o *forward pass* da rede neural, onde calculamos as ativações e obtemos a saída da rede $\hat{y} = a^{(2)} = 0.5470$

Loss Function




Nessa etapa computamos a *Loss Function* para avaliar o desempenho da rede.

Loss: $J(\theta) = \frac{1}{2}(y - \hat{y})^2$.

$$J(\theta) = \frac{1}{2}(1 - 0.5470)^2 = 0.1026045$$

Loss Function



Nessa etapa computamos a *Loss Function* para avaliar o desempenho da rede.


Loss: $J(\theta) = \frac{1}{2}(y - \hat{y})^2$.

$$J(\theta) = \frac{1}{2}(1 - 0.5470)^2 = 0.1026045$$

Resumindo

Essa é a etapa de computar o valor da *Loss Function*. Observe que o valor da *Loss Function* não será usado diretamente nos gradientes nem na atualização dos pesos


Comparando com PyTorch



$$\hat{y} = 0.5470$$
$$J(\theta) = 0.1026045$$

```
1 class RedeSimples(nn.Module):
2     def __init__(self) -> None:
3         super().__init__()
4         self.theta_1 = nn.parameter.Parameter(
5             torch.tensor(-0.5),
6             requires_grad=True)
7         self.theta_2 = nn.parameter.Parameter(
8             torch.tensor(0.5),
9             requires_grad=True)
10
11     def forward(self, x):
12         z1 = x * self.theta_1
13         a1 = torch.sigmoid(z1)
14         z2 = a1 * self.theta_2
15         a2 = torch.sigmoid(z2)
16         return a2
17
18 x = torch.tensor(1.0)
19 y = torch.tensor(1.0)
20 model = RedeSimples()
21 y_hat = model(x)
22 loss = ((y - y_hat)**2)/2
23 print(f'y_hat: {y_hat}')
24 print(f'loss: {loss}')
25 # y_hat: 0.5470529198646545
26 # loss: 0.10258052498102188
```

Backward Pass




Nossa rede neural computa a seguinte função:

$$a^{(2)} = \sigma(\sigma(x_1 \cdot \theta^{(1)}) \cdot \theta^{(2)})$$

Logo, a função de custo é:

$$J(\theta) = \frac{1}{2}(y - a^{(2)})^2 = \frac{1}{2} \left(1 - \sigma \left(\sigma(x_1 \cdot \theta^{(1)}) \cdot \theta^{(2)} \right) \right)^2$$

Backward Pass



Nossa rede neural computa a seguinte função:

$$a^{(2)} = \sigma(\sigma(x_1 \cdot \theta^{(1)}) \cdot \theta^{(2)})$$

Logo, a função de custo é:

$$J(\theta) = \frac{1}{2}(y - a^{(2)})^2 = \frac{1}{2} \left(1 - \sigma \left(\sigma(x_1 \cdot \theta^{(1)}) \cdot \theta^{(2)} \right) \right)^2$$


Problema

Como computar o gradiente da função de custo em relação aos pesos $\theta^{(1)}$ e $\theta^{(2)}$?

$$\frac{\partial J}{\partial \theta^{(2)}} = ?$$

$$\frac{\partial J}{\partial \theta^{(1)}} = ?$$

Backward Pass



Solução: A função $J(\theta)$ é uma função composta, então usamos a regra da cadeia
Gradiente para $\theta^{(2)}$:

$$\frac{\partial J}{\partial \theta^{(2)}} = \frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial \theta^{(2)}}$$

Gradiente para $\theta^{(1)}$:

$$\frac{\partial J}{\partial \theta^{(1)}} = \frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial a^{(1)}} \frac{\partial a^{(1)}}{\partial z^{(1)}} \frac{\partial z^{(1)}}{\partial \theta^{(1)}}$$

Backward Pass

$$\frac{\partial J}{\partial \theta^{(2)}} = \frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial \theta^{(2)}}$$

- $\frac{\partial J}{\partial a^{(2)}} = a^{(2)} - y$
- $\frac{\partial a^{(2)}}{\partial z^{(2)}} = a^{(2)}(1 - a^{(2)})$
- $\frac{\partial z^{(2)}}{\partial \theta^{(2)}} = a^{(1)}$

$$\begin{aligned} \frac{\partial J}{\partial a^{(2)}} &= \frac{\partial \left(\frac{1}{2} (y - a^{(2)})^2 \right)}{\partial a^{(2)}} \\ &= (-1) \cancel{2} \frac{1}{\cancel{2}} (y - a^{(2)}) \\ &= a^{(2)} - y \end{aligned}$$

Backward Pass

$$\frac{\partial J}{\partial \theta^{(2)}} = \frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial \theta^{(2)}}$$

$$\begin{aligned} \frac{\partial a^{(2)}}{\partial z^{(2)}} &= \frac{\partial \left(\frac{1}{1+e^{-z^{(2)}}} \right)}{\partial z^{(2)}} = \frac{\partial \left((1+e^{-z^{(2)}})^{-1} \right)}{\partial z^{(2)}} \\ &= (\cancel{1})(1+e^{-z^{(2)}})^{-2} e^{-z^{(2)}} (\cancel{-1}) \\ &= \frac{1 + e^{-z^{(2)}} - 1}{(1 + e^{-z^{(2)}})^2} \end{aligned}$$

- $\frac{\partial J}{\partial a^{(2)}} = a^{(2)} - y$
- $\frac{\partial a^{(2)}}{\partial z^{(2)}} = a^{(2)}(1 - a^{(2)})$
- $\frac{\partial z^{(2)}}{\partial \theta^{(2)}} = a^{(1)}$

$$\begin{aligned} &= \frac{1}{1 + e^{-z^{(2)}}} \left(\frac{\cancel{1 + e^{-z^{(2)}}} \overset{1}{\nearrow}}{\cancel{1 + e^{-z^{(2)}}}} - \frac{1}{1 + e^{-z^{(2)}}} \right) \\ &= \sigma(z^{(2)})(1 - \sigma(z^{(2)})) = a^{(2)}(1 - a^{(2)}) \end{aligned}$$

Backward Pass

$$\frac{\partial J}{\partial \theta^{(2)}} = \frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial \theta^{(2)}}$$

- $\frac{\partial J}{\partial a^{(2)}} = a^{(2)} - y$
- $\frac{\partial a^{(2)}}{\partial z^{(2)}} = a^{(2)}(1 - a^{(2)})$
- $\frac{\partial z^{(2)}}{\partial \theta^{(2)}} = a^{(1)}$

$$\begin{aligned} \frac{\partial z^{(2)}}{\partial \theta^{(2)}} &= \frac{\partial (a^{(1)} \theta^{(2)})}{\partial \theta^{(2)}} \\ &= a^{(1)} \end{aligned}$$

Backward Pass

$$\frac{\partial J}{\partial \theta^{(1)}} = \frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial a^{(1)}} \frac{\partial a^{(1)}}{\partial z^{(1)}} \frac{\partial z^{(1)}}{\partial \theta^{(1)}}$$

- $\frac{\partial J}{\partial a^{(2)}} = a^{(2)} - y$
- $\frac{\partial a^{(2)}}{\partial z^{(2)}} = a^{(2)}(1 - a^{(2)})$
- $\frac{\partial z^{(2)}}{\partial a^{(1)}} = \theta^{(2)}$
- $\frac{\partial a^{(1)}}{\partial z^{(1)}} = a^{(1)}(1 - a^{(1)})$
- $\frac{\partial z^{(1)}}{\partial \theta^{(1)}} = \mathbf{X}_1$

Os primeiros termos são iguais aos dois primeiros termos do gradiente de $\theta^{(2)}$

Backward Pass

$$\frac{\partial J}{\partial \theta^{(1)}} = \frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial a^{(1)}} \frac{\partial a^{(1)}}{\partial z^{(1)}} \frac{\partial z^{(1)}}{\partial \theta^{(1)}}$$

- $\frac{\partial J}{\partial a^{(2)}} = a^{(2)} - y$
- $\frac{\partial a^{(2)}}{\partial z^{(2)}} = a^{(2)}(1 - a^{(2)})$
- $\frac{\partial z^{(2)}}{\partial a^{(1)}} = \theta^{(2)}$
- $\frac{\partial a^{(1)}}{\partial z^{(1)}} = a^{(1)}(1 - a^{(1)})$
- $\frac{\partial z^{(1)}}{\partial \theta^{(1)}} = \mathbf{X}_1$

$$\begin{aligned} \frac{\partial z^{(2)}}{\partial a^{(1)}} &= \frac{\partial (a^{(1)} \theta^{(2)})}{\partial a^{(1)}} \\ &= \theta^{(2)} \end{aligned}$$

Backward Pass

$$\frac{\partial J}{\partial \theta^{(1)}} = \frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial a^{(1)}} \frac{\partial a^{(1)}}{\partial z^{(1)}} \frac{\partial z^{(1)}}{\partial \theta^{(1)}}$$

- $\frac{\partial J}{\partial a^{(2)}} = a^{(2)} - y$
- $\frac{\partial a^{(2)}}{\partial z^{(2)}} = a^{(2)}(1 - a^{(2)})$
- $\frac{\partial z^{(2)}}{\partial a^{(1)}} = \theta^{(2)}$
- $\frac{\partial a^{(1)}}{\partial z^{(1)}} = a^{(1)}(1 - a^{(1)})$
- $\frac{\partial z^{(1)}}{\partial \theta^{(1)}} = \mathbf{X}_1$

$$\begin{aligned} \frac{\partial a^{(1)}}{\partial z^{(1)}} &= \frac{\partial \left(\frac{1}{1+e^{-z^{(1)}}} \right)}{\partial z^{(1)}} = \frac{\partial \left((1+e^{-z^{(1)}})^{-1} \right)}{\partial z^{(1)}} \\ &= (\cancel{1})(1+e^{-z^{(1)}})^{-2} e^{-z^{(1)}} (\cancel{-1}) \\ &= \frac{1 + e^{-z^{(1)}} - 1}{(1+e^{-z^{(1)}})^2} \\ &= \frac{1}{1+e^{-z^{(1)}}} \left(\frac{1 + e^{-z^{(1)}}}{1+e^{-z^{(1)}}} - \frac{1}{1+e^{-z^{(1)}}} \right) \\ &= \sigma(z^{(1)})(1 - \sigma(z^{(1)})) = a^{(1)}(1 - a^{(1)}) \end{aligned}$$

Backward Pass

$$\frac{\partial J}{\partial \theta^{(1)}} = \frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}} \frac{\partial z^{(2)}}{\partial a^{(1)}} \frac{\partial a^{(1)}}{\partial z^{(1)}} \frac{\partial z^{(1)}}{\partial \theta^{(1)}}$$

- $\frac{\partial J}{\partial a^{(2)}} = a^{(2)} - y$
- $\frac{\partial a^{(2)}}{\partial z^{(2)}} = a^{(2)}(1 - a^{(2)})$
- $\frac{\partial z^{(2)}}{\partial a^{(1)}} = \theta^{(2)}$
- $\frac{\partial a^{(1)}}{\partial z^{(1)}} = a^{(1)}(1 - a^{(1)})$
- $\frac{\partial z^{(1)}}{\partial \theta^{(1)}} = \mathbf{X}_1$

$$\begin{aligned} \frac{\partial z^{(1)}}{\partial \theta^{(1)}} &= \frac{\partial (X_1 \theta^{(1)})}{\partial \theta^{(1)}} \\ &= X_1 \end{aligned}$$

Backward Pass

Vamos Computar o Gradiente

$$\frac{\partial J}{\partial \theta^{(2)}} = \underbrace{(a^{(2)} - y) \cdot a^{(2)}(1 - a^{(2)})}_{\delta^{(2)}} \cdot a^{(1)}$$

$$= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.3775 = -0.04237412$$

$$\frac{\partial J}{\partial \theta^{(1)}} = \underbrace{(a^{(2)} - y) \cdot a^{(2)}(1 - a^{(2)})}_{\delta^{(2)}} \cdot \theta^{(2)} \cdot a^{(1)}(1 - a^{(1)}) \cdot X_1$$

$$= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.5 \cdot 0.3775(1 - 0.3775) \cdot 1 = -0.01318894$$

Backward Pass

Vamos Computar o Gradiente

$$\begin{aligned}\frac{\partial J}{\partial \theta^{(2)}} &= \underbrace{(a^{(2)} - y) \cdot a^{(2)}(1 - a^{(2)})}_{\delta^{(2)}} \cdot a^{(1)} \\ &= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.3775 = \mathbf{-0.04237412}\end{aligned}$$

$$\begin{aligned}\frac{\partial J}{\partial \theta^{(1)}} &= \underbrace{(a^{(2)} - y) \cdot a^{(2)}(1 - a^{(2)})}_{\delta^{(2)}} \cdot \theta^{(2)} \cdot a^{(1)}(1 - a^{(1)}) \cdot X_1 \\ &= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.5 \cdot 0.3775(1 - 0.3775) \cdot 1 = \mathbf{-0.01318894}\end{aligned}$$

Backward Pass

Vamos Computar o Gradiente

$$\frac{\partial J}{\partial \theta^{(2)}} = \underbrace{(a^{(2)} - y) \cdot a^{(2)} (1 - a^{(2)})}_{\delta^{(2)}} \cdot a^{(1)}$$

$$= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.3775 = -\mathbf{0.04237412}$$

$$\frac{\partial J}{\partial \theta^{(1)}} = \underbrace{(a^{(2)} - y) \cdot a^{(2)} (1 - a^{(2)})}_{\delta^{(2)}} \cdot \theta^{(2)} \cdot a^{(1)} (1 - a^{(1)}) \cdot X_1$$

$$= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.5 \cdot 0.3775(1 - 0.3775) \cdot 1 = -\mathbf{0.01318894}$$

Backward Pass

Vamos Computar o Gradiente

$$\frac{\partial J}{\partial \theta^{(2)}} = \underbrace{(a^{(2)} - y) \cdot a^{(2)}(1 - a^{(2)})}_{\delta^{(2)}} \cdot a^{(1)}$$

$$= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.3775 = -\mathbf{0.04237412}$$

$$\frac{\partial J}{\partial \theta^{(1)}} = \underbrace{(a^{(2)} - y) \cdot a^{(2)}(1 - a^{(2)})}_{\delta^{(2)}} \cdot \theta^{(2)} \cdot a^{(1)}(1 - a^{(1)}) \cdot X_1$$

$$= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.5 \cdot 0.3775(1 - 0.3775) \cdot 1 = -\mathbf{0.01318894}$$

Backward Pass

Vamos Computar o Gradiente

$$\frac{\partial J}{\partial \theta^{(2)}} = \underbrace{(a^{(2)} - y) \cdot a^{(2)}(1 - a^{(2)})}_{\delta^{(2)}} \cdot a^{(1)}$$

$$= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.3775 = -\mathbf{0.04237412}$$

$$\frac{\partial J}{\partial \theta^{(1)}} = \underbrace{(a^{(2)} - y) \cdot a^{(2)}(1 - a^{(2)})}_{\delta^{(2)}} \cdot \theta^{(2)} \cdot a^{(1)}(1 - a^{(1)}) \cdot X_1$$

$$= (0.5470 - 1) \cdot 0.5470(1 - 0.5470) \cdot 0.5 \cdot 0.3775(1 - 0.3775) \cdot 1 = -\mathbf{0.01318894}$$

Resumindo

No *Backward Pass* calculamos os gradientes da função de custo em relação a todos os parâmetros treináveis

Descida de Gradiente

- Usando $\eta = 0.1$: $\theta_t = \theta_{t-1} - \eta \nabla J$
- $\theta_t^{(2)} = 0.5 - 0.1(-0.042374) = \mathbf{0.5042374}$
- $\theta_t^{(1)} = -0.5 - 0.1(-0.013189) = \mathbf{-0.4986811}$

Descida de Gradiente

- Usando $\eta = 0.1$: $\theta_t = \theta_{t-1} - \eta \nabla J$
- $\theta_t^{(2)} = 0.5 - 0.1(-0.042374) = \mathbf{0.5042374}$
- $\theta_t^{(1)} = -0.5 - 0.1(-0.013189) = \mathbf{-0.4986811}$

Resumindo

Na *Descida de Gradiente* usamos o gradiente para atualizar os parâmetros treináveis

Resultado da Atualização

- Após a atualização, os pesos da rede são:

- $\theta^{(1)} = -0.4986811$
- $\theta^{(2)} = 0.5042374$

- O novo valor de $a^{(2)}$ é:

$$a^{(2)} = \sigma(\sigma(X_1 \cdot \theta^{(1)}) \cdot \theta^{(2)}) = \sigma(\sigma(1 \cdot (-0.4986811)) \cdot 0.5042374) = 0.5474$$

- O novo valor de $J(\theta)$ é:

$$J(\theta) = \frac{1}{2}(y - a^{(2)})^2 = \frac{1}{2}(1 - 0.5474)^2 = 0.1024234$$

Resultado da Atualização

- Após a atualização, os pesos da rede são:

- $\theta^{(1)} = -0.4986811$
- $\theta^{(2)} = 0.5042374$

- O novo valor de $a^{(2)}$ é:

$$a^{(2)} = \sigma(\sigma(X_1 \cdot \theta^{(1)}) \cdot \theta^{(2)}) = \sigma(\sigma(1 \cdot (-0.4986811)) \cdot 0.5042374) = 0.5474$$

- O novo valor de $J(\theta)$ é:

$$J(\theta) = \frac{1}{2}(y - a^{(2)})^2 = \frac{1}{2}(1 - 0.5474)^2 = 0.1024234$$

- O novo valor de $J(\theta)$ é menor que o anterior 0.1026045, indicando que o erro do MLP é menor

Comparando com PyTorch

$$\frac{\partial J}{\partial \theta^{(1)}} = -0.01318894$$

$$\frac{\partial J}{\partial \theta^{(2)}} = -0.04237412$$

$$\theta_t^{(2)} = 0.5042374$$

$$\theta_t^{(1)} = -0.4986811$$

```
1 optimizer = SGD(model.parameters(),
2                 lr=0.1)
3 x = torch.tensor(1.0)
4 y = torch.tensor(1.0)
5 model.train()
6 optimizer.zero_grad()
7 y_hat = model(x)
8 loss = (y - y_hat)**2/2
9 loss.backward()
10 print(f'Grad: {model.theta_2.grad}, {model.theta_1.
11         grad}')
12 optimizer.step()
13 print(f'Pesos: {model.theta_2.data}, {model.theta_1
14         .data}')
15 # Grad: -0.04237288236618042, -0.01318769808858633
16 # Pesos: 0.5042372941970825, -0.4986812174320221
```

Visão Geral


1. Introdução

2. Treinamento de um MLP

- 2.1 Forward Pass
- 2.2 Função de Custo
- 2.3 Backward Pass
- 2.4 Descida de Gradiente

3. Vetorização do Treinamento

Generalizando o Treinamento




Repare que:

- Ambas as derivadas são computadas com um termo $\delta^{(l)}$ multiplicado pela entrada da camada $\frac{\partial z^{(l)}}{\partial \theta^{(l)}}$

$$\frac{\partial J}{\partial \theta^{(2)}} = \underbrace{\frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}}}_{\delta^{(2)}} \frac{\partial z^{(2)}}{\partial \theta^{(2)}}$$

$$\frac{\partial J}{\partial \theta^{(1)}} = \underbrace{\frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}}}_{\delta^{(2)}} \underbrace{\frac{\partial z^{(2)}}{\partial a^{(1)}} \frac{\partial a^{(1)}}{\partial z^{(1)}} \frac{\partial z^{(1)}}{\partial \theta^{(1)}}}_{\delta^{(1)}}$$

Generalizando o Treinamento



Repare que:

- Ambas as derivadas são computadas com um termo $\delta^{(l)}$ multiplicado pela entrada da camada $\frac{\partial z^{(l)}}{\partial \theta^{(l)}}$
- $\delta^{(1)}$ pode ser obtido a partir de $\delta^{(2)}$

$$\frac{\partial J}{\partial \theta^{(2)}} = \underbrace{\frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}}}_{\delta^{(2)}} \frac{\partial z^{(2)}}{\partial \theta^{(2)}}$$

$$\frac{\partial J}{\partial \theta^{(1)}} = \underbrace{\frac{\partial J}{\partial a^{(2)}} \frac{\partial a^{(2)}}{\partial z^{(2)}}}_{\delta^{(2)}} \underbrace{\frac{\partial z^{(2)}}{\partial a^{(1)}} \frac{\partial a^{(1)}}{\partial z^{(1)}}}_{\delta^{(1)}} \frac{\partial z^{(1)}}{\partial \theta^{(1)}}$$

Generalizando o Treinamento

O gradiente em cada camada pode ser dividido em dois componentes:

- **Delta da Camada:** $\delta^{(l)} = \frac{\partial J}{\partial z^{(l)}}$
- **Ativação da Camada Anterior:** $a^{(l-1)}$

Backpropagation:

1. **Erro na Camada de Saída:** $\delta^{(L)} = \frac{\partial J}{\partial a^{(L)}} \odot \frac{\partial a^{(L)}}{\partial z^{(L)}}$
2. **Propagação do Erro:** $\delta^{(l)} = (\delta^{(l+1)} \theta^{(l+1)}) \odot a'^{(l)}$
3. **Gradiente do Parâmetros:** $\frac{\partial J}{\partial \theta^{(i)}} = \delta^{(i)\top} a^{(i-1)}$

Exemplo Vetorizado

- Dataset (*Batch Size* = 2)


$$X = \begin{bmatrix} 0.5 & 0.1 \\ 0.2 & 0.6 \end{bmatrix}, \quad y = \begin{bmatrix} 0.6 \\ 0.8 \end{bmatrix}$$

- Arquitetura

- Camada de Entrada: 2 unidades
- Camada Oculta 1: 3 unidades
- Camada de Saída: 1 unidade


- Pesos Iniciais

- Camada 1: $\theta^{(1)} = \begin{bmatrix} 0.5 & 0.2 \\ 0.6 & -0.1 \\ -0.4 & -0.3 \end{bmatrix}$
- Camada 2: $\theta^{(2)} = \begin{bmatrix} 0.7 & -0.1 & 0.2 \end{bmatrix}$




Exemplo Vetorizado: Forward Pass

$$\begin{aligned}Z^{(1)} &= X \cdot \theta^{(1)\top} \\&= \begin{bmatrix} 0.5 & 0.1 \\ 0.2 & 0.6 \end{bmatrix}_{2 \times 2} \cdot \begin{bmatrix} 0.5 & 0.6 & -0.4 \\ 0.2 & -0.1 & -0.3 \end{bmatrix}_{2 \times 3} \\&= \begin{bmatrix} 0.27 & 0.29 & -0.23 \\ 0.22 & 0.06 & -0.26 \end{bmatrix}_{2 \times 3} \\A^{(1)} &= \sigma(Z^{(1)}) \\&= \sigma \left(\begin{bmatrix} 0.27 & 0.29 & -0.23 \\ 0.22 & 0.06 & -0.26 \end{bmatrix}_{2 \times 3} \right) \\&= \begin{bmatrix} 0.5671 & 0.5720 & 0.4428 \\ 0.5548 & 0.5150 & 0.4354 \end{bmatrix}_{2 \times 3}\end{aligned}$$




Exemplo Vetorizado: Forward Pass

$$\begin{aligned}Z^{(2)} &= A^{(1)} \cdot \theta^{(2)T} \\&= \begin{bmatrix} 0.5671 & 0.5720 & 0.4428 \\ 0.5548 & 0.5150 & 0.4354 \end{bmatrix}_{2 \times 3} \cdot \begin{bmatrix} 0.7 \\ -0.1 \\ 0.2 \end{bmatrix}_{3 \times 1} \\&= \begin{bmatrix} 0.4283 \\ 0.4239 \end{bmatrix}_{2 \times 1} \\A^{(2)} &= \hat{y} = \sigma(Z^{(2)}) \\&= \sigma \left(\begin{bmatrix} 0.4283 \\ 0.4239 \end{bmatrix}_{2 \times 1} \right) \\&= \begin{bmatrix} 0.6055 \\ 0.6044 \end{bmatrix}_{2 \times 1}\end{aligned}$$



Exemplo Vetorizado: Cálculo da *Loss*

$$\begin{aligned} J &= \frac{1}{2} \sum (y - \hat{y})^2 \\ &= \frac{1}{2} \sum \left(\begin{bmatrix} 0.6055 \\ 0.6044 \end{bmatrix}_{2 \times 1} - \begin{bmatrix} 0.6 \\ 0.8 \end{bmatrix}_{2 \times 1} \right)^2 \\ &= 0.01914 \end{aligned}$$




Exemplo Vetorizado: *Backward Pass*

$$\begin{aligned}\delta^{(2)} &= \left(\begin{bmatrix} 0.6055 \\ 0.6044 \end{bmatrix} - \begin{bmatrix} 0.6 \\ 0.8 \end{bmatrix} \right) \odot \begin{bmatrix} 0.2389 \\ 0.2391 \end{bmatrix} \\ &= \begin{bmatrix} 0.0055 \\ -0.1956 \end{bmatrix} \odot \begin{bmatrix} 0.2389 \\ 0.2391 \end{bmatrix} \\ &= \begin{bmatrix} 0.00131 \\ -0.04676 \end{bmatrix} \\ \delta^{(1)} &= (\delta^{(2)} \cdot \theta^{(2)}) \odot \sigma'(Z^{(1)}) \\ &= \left(\begin{bmatrix} 0.00131 \\ -0.04676 \end{bmatrix} \cdot \begin{bmatrix} 0.7 & -0.1 & 0.2 \end{bmatrix} \right) \odot \sigma' \left(\begin{bmatrix} 0.27 & 0.29 & -0.23 \\ 0.22 & 0.06 & -0.26 \end{bmatrix} \right) \\ &= \begin{bmatrix} 0.00022 & -0.00003 & 0.00006 \\ -0.00809 & 0.00117 & -0.00230 \end{bmatrix}\end{aligned}$$

Exemplo Vetorizado: *Backward Pass*

$$\begin{aligned}\frac{\partial J}{\partial \theta^{(2)}} &= \delta^{(2)T} \cdot A^{(1)} \\ &= [0.00131 \quad -0.04676] \cdot \begin{bmatrix} 0.5671 & 0.5720 & 0.4428 \\ 0.5548 & 0.5150 & 0.4354 \end{bmatrix} \\ &= [-0.0252 \quad -0.0233 \quad -0.0198]\end{aligned}$$

$$\begin{aligned}\frac{\partial J}{\partial \theta^{(1)}} &= \delta^{(1)T} \cdot X \\ &= \begin{bmatrix} 0.00022 & -0.00809 \\ -0.00003 & 0.00117 \\ 0.00006 & -0.00230 \end{bmatrix} \cdot \begin{bmatrix} 0.5 & 0.1 \\ 0.2 & 0.6 \end{bmatrix} \\ &= \begin{bmatrix} -0.00150 & -0.00483 \\ 0.00022 & 0.00070 \\ -0.00043 & -0.00137 \end{bmatrix}\end{aligned}$$



Exemplo Vetorizado: *Optimizer*

Atualização dos Pesos ($\eta = 0.1$):

$$\theta_t^{(l)} = \theta_{t-1}^{(l)} - \eta \nabla_{\theta} J$$

Novos Pesos da Camada 2:

$$\begin{aligned}\theta_{new}^{(2)} &= \begin{bmatrix} 0.7 & -0.1 & 0.2 \end{bmatrix} - 0.1 \cdot \begin{bmatrix} -0.0252 & -0.0233 & -0.0198 \end{bmatrix} \\ &= \begin{bmatrix} 0.7025 & -0.0977 & 0.2020 \end{bmatrix}\end{aligned}$$

Novos Pesos da Camada 1:

$$\begin{aligned}\theta_{new}^{(1)} &= \begin{bmatrix} 0.5 & 0.2 \\ 0.6 & -0.1 \\ -0.4 & -0.3 \end{bmatrix} - 0.1 \cdot \begin{bmatrix} -0.00150 & -0.00483 \\ 0.00022 & 0.00070 \\ -0.00043 & -0.00137 \end{bmatrix} \\ &= \begin{bmatrix} 0.5002 & 0.2005 \\ 0.6000 & -0.1001 \\ -0.4000 & -0.2999 \end{bmatrix}\end{aligned}$$

Resumindo

- Podemos treinar redes neurais de múltiplas camadas usando descida de gradiente.
- O processo de treinamento consiste em repetir 4 etapas:
 1. Computar todas as saídas da rede (*Forward Pass*)
 2. Computar o quão diferente as saídas são em relação a variável alvo (*Loss Function*)
 3. Computar o gradiente do erro em relação aos parâmetros da rede (*Backward Pass*)
 4. Atualizar os pesos (*Optimizer*)
- Todo o treinamento pode ser implementado de forma vetorizada.

Leituras Recomendadas

- Primeira publicação do Backpropagation: [David E Rumelhart, Geoffrey E Hinton e Ronald J Williams](#). “Learning Internal Representations by Error Propagation, Parallel Distributed Processing, Explorations in the Microstructure of Cognition, ed. DE Rumelhart and J. McClelland. Vol. 1. 1986”. Em: [Biometrika](#) 71 (1986), pp. 599–607
- Capítulo 2: [Michael A Nielsen](#). [Neural networks and deep learning](#). Vol. 25. Determination press San Francisco, CA, USA, 2015

Referências

- [1] George Cybenko. “Approximation by superpositions of a sigmoidal function”. Em: [Mathematics of control, signals and systems](#) 2.4 (1989), pp. 303–314.
- [2] Kurt Hornik, Maxwell Stinchcombe e Halbert White. “Multilayer feedforward networks are universal approximators”. Em: [Neural networks](#) 2.5 (1989), pp. 359–366.
- [3] Marvin Minsky e Seymour Papert. “Perceptron: an introduction to computational geometry”. Em: [The MIT Press, Cambridge, expanded edition](#) 19.88 (1969), p. 2.
- [4] Michael A Nielsen. [Neural networks and deep learning](#). Vol. 25. Determination press San Francisco, CA, USA, 2015.
- [5] David E Rumelhart, Geoffrey E Hinton e Ronald J Williams. “Learning Internal Representations by Error Propagation, Parallel Distributed Processing, Explorations in the Microstructure of Cognition, ed. DE Rumelhart and J. McClelland. Vol. 1. 1986”. Em: [Biometrika](#) 71 (1986), pp. 599–607.