

Deep Learning

Tokenização em Modelos de Linguagem

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory
PUCRS

junho de 2026

Visão Geral

1. Por que a Tokenization Importa
2. Abordagens Ingênuas
3. Byte Pair Encoding (BPE)
4. WordPiece
5. Unigram Language Model (SentencePiece)
6. Byte-Level BPE
7. Comparação e Considerações Práticas
8. De Tokens a Embeddings
9. Resumo

Visão Geral


1. Por que a Tokenization Importa
2. Abordagens Ingênuas
3. Byte Pair Encoding (BPE)
4. WordPiece
5. Unigram Language Model (SentencePiece)
6. Byte-Level BPE
7. Comparação e Considerações Práticas
8. De Tokens a Embeddings
9. Resumo

O que é Tokenization?

Tokenization é o processo de converter texto bruto em uma sequência de unidades discretas (**tokens**) que um modelo pode processar.

O tokenizer define:

1. O **vocabulário**: quais tokens existem
2. A **segmentação**: como o texto é dividido em tokens
3. O **mapeamento**: tokens $\leftrightarrow$ IDs inteiros



Por que isso importa?

A tokenization **molda silenciosamente** tudo que vem a seguir:

Problemas causados pela tokenization

- O GPT não consegue contar letras de forma confiável em "strawberry" (3 r's)
- Desigualdade multilíngue: o inglês usa menos tokens que outros idiomas
- "123 + 456" pode ser dividido de forma inconsistente entre os dígitos

Trade-offs de design

- Vocabulário pequeno → sequências longas
- Vocabulário grande → embeddings esparsos
- Dificilmente encontraremos uma "granularidade correta"

O tokenizer não é um detalhe de pré-processamento; é uma decisão arquitetural.

O Problema da Fertility

Fertility = número de tokens necessários para representar uma palavra ou frase.

Idioma	Frase	Tokens GPT-2
Inglês	“Hello, how are you?”	6 tokens
Espanhol	“Hola, ¿cómo estás?”	9 tokens
Japonês	(equivalente)	14+ tokens

Consequência

Maior fertility = mais tokens = mais custo computacional, janela de contexto efetiva menor, e frequentemente pior desempenho para esse idioma.

Visão Geral

1. Por que a Tokenization Importa
- 2. Abordagens Ingênuas**
3. Byte Pair Encoding (BPE)
4. WordPiece
5. Unigram Language Model (SentencePiece)
6. Byte-Level BPE
7. Comparação e Considerações Práticas
8. De Tokens a Embeddings
9. Resumo

Nosso Exemplo Recorrente

Ao longo desta aula usamos o mesmo **corpus de treinamento**:

Palavra	Frequência no corpus
low	5
lower	2
newest	6
widest	3

Por que as frequências importam

Um tokenizer é **aprendido** a partir de um corpus. A frequência de cada palavra (e de cada par de caracteres) determina quais tokens são adicionados ao vocabulário.

Tokenization em Nível de Caractere

Ideia: Cada caractere é um token.

Exemplo Recorrente

"low lower newest widest"

→

l	o	w	_
---	---	---	---

l	o	w	e	r	_
---	---	---	---	---	---

n	e	w	e	s	t	_
---	---	---	---	---	---	---

w	i	d	e	s	t
---	---	---	---	---	---

Vocabulário: { l, o, w, _, e, r, n, s, t, i, d } $|\mathcal{V}| = 11$

✓ Vantagens

- Vocabulário reduzido (~256 para ASCII)
- Sem palavras fora do vocabulário (OOV)
- Agnóstico ao idioma

× Desvantagens

- Sequências muito longas
- Perde a semântica em nível de palavra
- O modelo precisa “aprender” a ortografia

Tokenization em Nível de Palavra

Ideia: Dividir por espaço em branco (e pontuação). Cada palavra é um token.

Exemplo Recorrente

"low lower newest widest"

→

low	lower	newest	widest
-----	-------	--------	--------

Vocabulário: { low, lower, newest, widest } $|\mathcal{V}| = 4$

✓ Vantagens

- Sequências curtas
- Tokens carregam significado semântico
- Simples de implementar

× Desvantagens

- Vocabulário gigantesco (100K+)
- Não lida com palavras OOV
- Sem compartilhamento morfológico: low e lowest são tokens sem relação

A sacada principal: Queremos algo *entre* caracteres e palavras.

⇒ **Tokenization por subwords**

Visão Geral

1. Por que a Tokenization Importa
2. Abordagens Ingênuas
- 3. Byte Pair Encoding (BPE)**
4. WordPiece
5. Unigram Language Model (SentencePiece)
6. Byte-Level BPE
7. Comparação e Considerações Práticas
8. De Tokens a Embeddings
9. Resumo

BPE

Ideia Central

Byte Pair Encoding (Sennrich et al., 2016) mescla iterativamente o par de símbolos adjacentes mais frequente.

Algoritmo

1. Começa com um vocabulário de todos os caracteres individuais
2. Conta todos os pares de símbolos adjacentes no corpus
3. Mescla o par mais frequente em um novo símbolo
4. Repete os passos 2–3 por k merges (hiperparâmetro)

Propriedades principais:

- Bottom-up, guloso, baseado em frequência
- A tabela de merges é aprendida a partir de um corpus de treinamento
- Codificação determinística na inferência (aplica os merges na ordem aprendida)

Utilizado em: GPT, GPT-2, GPT-3, RoBERTa, CodeGen, ...

BPE

Configuração do Exemplo Simplificado

Corpus de treinamento (com frequências de palavras e marcador de fim de palavra _):

Palavra	Freq	Divisão inicial						
low_	5	l	o	w	_			
lower_	2	l	o	w	e	r	_	
newest_	6	n	e	w	e	s	t	_
widest_	3	w	i	d	e	s	t	_

Vocabulário inicial: $\mathcal{V} = \{ l, o, w, _, e, r, n, s, t, i, d \}$ $|\mathcal{V}| = 11$

Vamos executar os merges passo a passo...

BPE

Merge Passo 1

Contagem de todos os pares adjacentes:

Par	Contagem	Par	Contagem	Par	Contagem	Par	Contagem
(e, s)	9	(l, o)	7	(o, w)	7	(s, t)	9
(e, w)	6	(w, _)	5	(t, _)	9	(e, r)	2
(w, e)	8	(n, e)	6	(w, i)	3	(d, e)	3
(i, d)	3	(r, _)	2				

Mais frequentes: (e, s), (s, t) e (t, _) têm contagem 9.

(Desempate: escolher (e, s) primeiro.)

Merge 1: (e, s) → **es** (contagem: 9)

low_ 5	l	o	w	_			
lower_ 2	l	o	w	e	r	_	
newest_ 6	n	e	w	es	t	_	
widest_ 3	w	i	d	es	t	_	

$\mathcal{V} = \{l, o, w, _, e, r, n, s, t, i, d, es\} \quad |\mathcal{V}| = 12$

BPE

Merges Passos 2–4

Merge 2: (es, t) → **est** (contagem: 9)

newest_	6	n	e	w	est	_
widest_	3	w	i	d	est	_

(demais inalterados)

Merge 3: (est, _) → **est_** (contagem: 9)

newest_	6	n	e	w	est_
widest_	3	w	i	d	est_

Merge 4: (l, o) → **lo** (contagem: 7)

low_	5	lo	w	_		
lower_	2	lo	w	e	r	_

$\mathcal{V} = \{l, o, w, _, e, r, n, s, t, i, d, es, est, est_, lo\}$ $|\mathcal{V}| = 15$

BPE

Merges Passos 5–7

Merge 5: (lo, w) → **low** (contagem: 7)

low_	5	low	-		
lower_	2	low	e	r	-

Merge 6: (n, e) → **ne** (contagem: 6)

newest_	6	ne	w	est_
---------	---	-----------	---	------

Merge 7: (ne, w) → **new** (contagem: 6)

newest_	6	new	est_
---------	---	------------	------

Após 7 merges, o corpus é representado como:

low	-	(5)	low	e	r	-	(2)	new	est_	(6)	w	i	d	est_	(3)
------------	---	-----	------------	---	---	---	-----	------------	------	-----	---	---	---	------	-----

Observe como **est_** é compartilhado entre “newest” e “widest”!

BPE

Codificando Novo Texto

Na inferência, aplica-se os merges aprendidos **em ordem**:

Codificando a palavra “lowest”

1. Início: l o w e s t _
2. Aplicar merge 1 (e,s)→es: l o w es t _
3. Aplicar merge 2 (es,t)→est: l o w est _
4. Aplicar merge 3 (est,_)→est_: l o w est_
5. Aplicar merge 4 (l,o)→lo: lo w est_
6. Aplicar merge 5 (lo,w)→low: low est_

Resultado: low est_ compartilha subwords com “low”, “newest”, “widest”!

Mesmo que “lowest” **nunca tenha aparecido no corpus de treinamento**, o modelo consegue compô-la a partir de subwords aprendidos.

BPE

Esboço em Python

```
import re, collections

def get_stats(vocab):
    """Conta a frequência de pares de símbolos adjacentes."""
    pairs = collections.Counter()
    for word, freq in vocab.items():
        symbols = word.split()
        for i in range(len(symbols) - 1):
            pairs[(symbols[i], symbols[i+1])] += freq
    return pairs

def merge_vocab(pair, vocab):
    """Mescla todas as ocorrências de um par no vocabulário."""
    bigram = re.escape(' '.join(pair))
    pattern = re.compile(r'(?!\S)' + bigram + r'(?!\S)')
    new_vocab = {}
    for word in vocab:
        new_word = pattern.sub(' '.join(pair), word)
        new_vocab[new_word] = vocab[word]
    return new_vocab

# Corpus de treinamento (frequências de palavras)
vocab = {'l o w _': 5, 'l o w e r _': 2,
         'n e w e s t _': 6, 'w i d e s t _': 3}

num_merges = 7
for i in range(num_merges):
    pairs = get_stats(vocab)
    best = max(pairs, key=pairs.get)
    vocab = merge_vocab(best, vocab)
    print(f"Merge {i+1}: {best} -> {' '.join(best)}")
```

Visão Geral

1. Por que a Tokenization Importa
2. Abordagens Ingênuas
3. Byte Pair Encoding (BPE)
- 4. WordPiece**
5. Unigram Language Model (SentencePiece)
6. Byte-Level BPE
7. Comparação e Considerações Práticas
8. De Tokens a Embeddings
9. Resumo

WordPiece

Ideia Central

WordPiece (Schuster & Nakajima, 2012; Wu et al., 2016) é similar ao BPE, mas seleciona merges com base na **likelihood** em vez da frequência.

Diferença principal em relação ao BPE

Em vez de mesclar o par mais *frequente*, o WordPiece mescla o par que **maximiza a likelihood dos dados de treinamento**:

$$\text{score}(x, y) = \frac{\text{freq}(xy)}{\text{freq}(x) \cdot \text{freq}(y)}$$

Isso favorece mesclar pares cuja combinação é muito mais provável do que o acaso.

Outras diferenças:

- Usa o prefixo ## para tokens de continuação: “playing” → play ##ing
- Longest-match guloso da esquerda para a direita na inferência

Utilizado em: BERT DistilBERT Electra

WordPiece

Exemplo Simplificado

Mesmo corpus, scores diferentes:

Par	freq(xy)	freq(x)·freq(y)	Score
(e, s)	9	$17 \times 9 = 153$	0.0588
(s, t)	9	$9 \times 9 = 81$	0.111
(i, d)	3	$3 \times 3 = 9$	0.333 ← highest
(n, e)	6	$6 \times 17 = 102$	0.0588
(l, o)	7	$7 \times 7 = 49$	0.143

O WordPiece mescla (i, d) primeiro, não (e, s)!

Intuição

(i, d) aparecem quase *exclusivamente* juntos → alta informação mútua.

(e, s) aparecem com frequência, mas também de forma independente → score menor.

WordPiece

Inferência: Longest Match

Na inferência, o WordPiece usa **longest-match-first guloso** da esquerda para a direita.

Exemplo: codificando “unhappiness” com um vocabulário estilo BERT

Suponha que o vocabulário contém: un, happy, ##happi, ##ness, ##ly, ...

1. Varredura da esquerda: maior correspondência = un
2. Restante: “happiness”. Maior correspondência = ##happi
3. Restante: “ness”. Maior correspondência = ##ness

Resultado: un ##happi ##ness

O prefixo ## indica “este token é uma continuação da palavra anterior” (não é o início de uma palavra).

Visão Geral

1. Por que a Tokenization Importa
2. Abordagens Ingênuas
3. Byte Pair Encoding (BPE)
4. WordPiece
- 5. Unigram Language Model (SentencePiece)**
6. Byte-Level BPE
7. Comparação e Considerações Práticas
8. De Tokens a Embeddings
9. Resumo

Unigram

Ideia Central

Unigram LM (Kudo, 2018) adota a **abordagem oposta** à do BPE:

Algoritmo

1. Começa com um vocabulário inicial **grande** (ex.: todos os substrings até certo comprimento)
2. Define um modelo de linguagem unigrama: $P(x) = \prod_{i=1}^n P(x_i)$
3. Para cada token, calcula o quanto a likelihood **cai** se ele for removido
4. Remove os tokens com a **menor perda** (menos úteis)
5. Repete até o vocabulário atingir o tamanho desejado

Diferença principal em relação ao BPE

BPE: começa pequeno, cresce (bottom-up)

Unigram: começa grande, poda (top-down)

Unigram

Exemplo Simplificado (1/2)

Corpus: “low” (freq 10), “er” (freq 10), “lower” (freq 1)

Passo 1: Começa com vocabulário de todos os substrings; $P(t) = \frac{\text{count}(t)}{N}$, onde $N = \sum_{t'} \text{count}(t')$:

Token	$P(\cdot)$	Token	$P(\cdot)$	Token	$P(\cdot)$
low	0.105	lo	0.105	l	0.105
er	0.105	ow	0.105	o	0.105
lower	0.010	we	0.010	w	0.105
owe	0.010	wer	0.010	e	0.105
lowe	0.010	ower	0.010	r	0.105

Substrings de “low” ou de “er” têm count = 11 (= 10 ocorrências da sua palavra +1 de “lower”); substrings exclusivas de “lower” têm count = 1;

$$N = 9 \times 11 + 6 \times 1 = 105.$$

Unigram

Exemplo Simplificado (2/2)

Corpus: “low” (freq 10), “er” (freq 10), “lower” (freq 1)

Passo 2: Melhor segmentação de “lower” sob este modelo:

$$P(\text{low}) \times P(\text{er}) = 0.105 \times 0.105 \approx 0.011 \quad \leftarrow \text{melhor}$$

$$P(\text{lower}) = 0.010 \quad (\text{token único; ligeiramente inferior ao par})$$

$$P(1) \times P(\text{owe}) \times P(\text{r}) = 0.105 \times 0.010 \times 0.105 \approx 0.0001$$

Passo 3: Poda do vocabulário:

$$P(\text{owe}) = 0.010, \text{ nunca entra na melhor segmentação} \rightarrow \text{podá-lo.}$$

$$P(\text{low}) = 0.105, \text{ essencial em 11 segmentações} \rightarrow \text{mantê-lo.}$$

SentencePiece

O Framework

SentencePiece (Kudo & Richardson, 2018) é um **framework**, não um algoritmo.

O que torna o SentencePiece especial?

1. **Agnóstico ao idioma:** trata a entrada como um fluxo bruto de bytes/unicode
2. **Sem pre-tokenization:** não depende de divisão por espaço em branco
3. O espaço em branco é tratado como um caractere regular (substituído por _)
4. Suporta **tanto** BPE quanto Unigram como algoritmo subjacente

Exemplo

"New York" → _New _York

O _ codifica o espaço, tornando a tokenization **totalmente reversível**.

Utilizado em: T5, LLaMA, ALBERT, XLNet, Gemma, ...

Visão Geral

1. Por que a Tokenization Importa
2. Abordagens Ingênuas
3. Byte Pair Encoding (BPE)
4. WordPiece
5. Unigram Language Model (SentencePiece)
- 6. Byte-Level BPE**
7. Comparação e Considerações Práticas
8. De Tokens a Embeddings
9. Resumo

Byte-Level BPE

Motivação

Problema: O BPE padrão opera sobre caracteres Unicode. Mas o Unicode tem 150K+ pontos de código; o vocabulário base é enorme, e scripts raros geram muitos tokens <unk>.

Solução: Byte-Level BPE (Radford et al., 2019, GPT-2)

- Opera sobre **bytes brutos** (sempre 256 tokens base)
- Todo texto pode ser codificado: **nunca há tokens desconhecidos**
- Em seguida, aplica-se os merges padrão do BPE sobre os bytes

Exemplo

O emoji “:)” em UTF-8 é 0x3A 0x29:


→ 0x3A 0x29 (2 tokens de byte)

Um caractere chinês como “[CJK]” pode ter 3 bytes UTF-8:

→ 3 tokens de byte (ou mesclados se forem suficientemente frequentes)

Utilizado em: GPT-2, GPT-3, GPT-4, Codex, LLaMA 2/3, ...

Byte-Level BPE vs. BPE Padrão



O GPT-2 usa um **mapeamento byte-para-unicode**: cada byte é representado como um caractere Unicode imprimível, de modo que o código BPE baseado em strings existente funciona sem modificações.

Visão Geral

1. Por que a Tokenization Importa
2. Abordagens Ingênuas
3. Byte Pair Encoding (BPE)
4. WordPiece
5. Unigram Language Model (SentencePiece)
6. Byte-Level BPE
- 7. Comparação e Considerações Práticas**
8. De Tokens a Embeddings
9. Resumo

OOV e Pré-tokenização

Tratamento de OOV (Out-Of-Vocabulary)

Tokens ou palavras que **não apareceram** no corpus de treinamento.

- **Caractere:** cobertura total; o vocabulário são os próprios bytes/chars, nada é OOV
- **BPE / Unigram:** decompõe até chegar nos caracteres do vocabulário base (*chars raros*)
- **WordPiece:** substitui pelo token especial [UNK] se não conseguir segmentar

Pré-tokenização

Etapa **anterior** ao algoritmo: divide o texto em “palavras” por espaço e/ou pontuação.

- **WordPiece (Sim):** o BERT sempre divide por espaço antes de aplicar o algoritmo
- **BPE (Geralmente):** o GPT-2 usa regras de pré-tokenização (ex.: nunca mescla letra com espaço)
- **SentencePiece (Opcional):** trata o espaço como caractere normal () essencial para idiomas sem separação por espaço (japonês, chinês)

Comparação de Métodos de Tokenization

	Caractere	BPE	WordPiece	Unigram
Direção	—	Bottom-up	Bottom-up	Top-down
Critério de merge	—	Frequência	Likelihood	Baseado em perda
Tratamento de OOV	Total	Chars raros	[UNK]	Chars raros
Determinístico	Sim	Sim	Sim	Não*
Pre-tokenization?	Não	Geralmente	Sim	Opcional
Modelos notáveis				
	ByT5	Família GPT	BERT	T5, LLaMA

*O Unigram pode produzir múltiplas segmentações válidas; durante o treinamento, isso pode servir como forma de **subword regularization** (data augmentation).

Qual Tokenizer Cada Modelo Usa?

Modelo	Tokenizer	Tamanho do Vocabulário
BERT	WordPiece	30,522
GPT-2	Byte-level BPE	50,257
GPT-3	Byte-level BPE (p50k_base)	50,281
GPT-4	Byte-level BPE (cl100k_base)	100,256
T5	SentencePiece (Unigram)	32,000
LLaMA 1	SentencePiece (BPE)	32,000
LLaMA 2/3	SentencePiece (BPE)	32,000 / 128,256
Gemma	SentencePiece (BPE)	256,000
Mistral	SentencePiece (BPE)	32,000
Claude	Byte-level BPE (custom)	—

Tendência: Modelos modernos estão migrando para vocabulários maiores e abordagens byte-level para melhorar a cobertura multilíngue.

Subword Regularization e BPE Dropout

Ideia: A tokenization não precisa ser determinística durante o treinamento!

Subword Regularization (Kudo, 2018)

O Unigram pode amostrar entre múltiplas segmentações válidas:

"lowest" pode ser:

- | | |
|-----|-----|
| low | est |
|-----|-----|

 (probabilidade 0,7)
- | | | |
|----|----|----|
| lo | we | st |
|----|----|----|

 (probabilidade 0,2)
- | | | | |
|---|---|---|-----|
| l | o | w | est |
|---|---|---|-----|

 (probabilidade 0,1)

BPE Dropout (Provilkov et al., 2020)

Ignora aleatoriamente alguns merges do BPE durante o treinamento:

Com dropout $p = 0,1$:

- Normal:

low	est
-----	-----
- Ignorado:

lo	w	est
----	---	-----
- Ignorado:

low	e	st
-----	---	----

Ambos atuam como **data augmentation**, tornando os modelos mais robustos a segmentações raras.

Visão Geral

1. Por que a Tokenization Importa
2. Abordagens Ingênuas
3. Byte Pair Encoding (BPE)
4. WordPiece
5. Unigram Language Model (SentencePiece)
6. Byte-Level BPE
7. Comparação e Considerações Práticas
- 8. De Tokens a Embeddings**
9. Resumo

De Token IDs a Embeddings

O tokenizer produz uma sequência de **inteiros** (IDs). O transformer precisa de **vetores densos**.

A tabela de embedding

Uma matriz $E \in \mathbb{R}^{|V| \times d}$, onde cada linha é o vetor de um token:

$$e_i = E[i] \in \mathbb{R}^d$$

`nn.Embedding` é uma **tabela de lookup**, não uma transformação linear — apenas seleciona uma linha.

ID	$e \in \mathbb{R}^d$		
0	0.12	-0.43	...
$\vdots$	$\vdots$	$\vdots$	$\vdots$
15496	0.31	-1.20	...
$\vdots$	$\vdots$	$\vdots$	$\vdots$
$ V - 1$	-0.07	0.88	...

ID 15496 $\rightarrow$ linha 15496 $\rightarrow e \in \mathbb{R}^{768}$

Pipeline completo

texto $\xrightarrow{\text{tokenizer}}$ [IDs] $\xrightarrow{\text{nn.Embedding}}$ [vetores] $\xrightarrow{+PE}$ entrada do transformer

De Token IDs a Embeddings (código)

GPT-2 com HuggingFace + PyTorch

```
from transformers import AutoTokenizer, AutoModelForCausalLM

tokenizer = AutoTokenizer.from_pretrained("gpt2")
model     = AutoModelForCausalLM.from_pretrained("gpt2")

ids = tokenizer("Olá mundo", return_tensors="pt").input_ids
# ids.shape -> (1, seq_len) -- tensor de inteiros

embs = model.transformer.wte(ids)    # nn.Embedding lookup
# embs.shape -> (1, seq_len, 768) -- tensor de floats
```

- *wte = word token embedding* — o nome usado internamente pelo GPT-2
- Após este passo, os embeddings posicionais são somados e a sequência entra na pilha de transformers
- O `model.transformer.wte` é uma instância de `torch.nn.Embedding(50257, 768)`

Quantos Parâmetros Custam os Embeddings?

$$\text{params}_{\text{embedding}} = |V| \times d$$

Modelo	$ V $	d	Params emb.	Total	% do total
GPT-2 Small	50,257	768	38,6M	117M	33%
GPT-2 Medium	50,257	1,024	51,5M	345M	15%
GPT-2 Large	50,257	1,280	64,3M	762M	8,4%
GPT-2 XL	50,257	1,600	80,4M	1,5B	5,4%
LLaMA 2 7B	32,000	4,096	131M	7B	1,9%

Conclusões

- **Vocabulário maior = mais parâmetros:** escolhas de tokenization têm custo direto no tamanho do modelo
- **Modelos menores pagam mais:** em GPT-2 Small, $\frac{1}{3}$ dos parâmetros estão na tabela de embedding
- **Weight tying:** GPT-2 e muitos outros modelos **reutilizam** a mesma matriz como camada de saída (`lm_head`), sem custo extra de parâmetros para a projeção final

Visão Geral

1. Por que a Tokenization Importa
2. Abordagens Ingênuas
3. Byte Pair Encoding (BPE)
4. WordPiece
5. Unigram Language Model (SentencePiece)
6. Byte-Level BPE
7. Comparação e Considerações Práticas
8. De Tokens a Embeddings
- 9. Resumo**

Principais Conclusões

1. **A tokenization é uma decisão arquitetural**, não uma etapa de pré-processamento
2. **Nível de caractere e de palavra** são extremos demais; métodos por subword encontram o ponto de equilíbrio
3. **BPE**: mescla os pares mais frequentes (bottom-up, baseado em frequência)
4. **WordPiece**: mescla pares maximizando a likelihood (bottom-up, baseado em probabilidade)
5. **Unigram**: começa grande, poda os tokens menos úteis (top-down, baseado em perda)
6. **SentencePiece**: um framework para tokenization agnóstica ao idioma (suporta BPE ou Unigram)
7. **Byte-level BPE**: garante cobertura total com 256 tokens base

Referências

Artigos principais:

- Sennrich, R., Haddow, B., & Birch, A. (2016). Neural Machine Translation of Rare Words with Subword Units. *ACL*.
- Schuster, M. & Nakajima, K. (2012). Japanese and Korean Voice Search. *ICASSP*.
- Wu, Y. et al. (2016). Google's Neural Machine Translation System. *arXiv:1609.08144*.
- Kudo, T. (2018). Subword Regularization. *ACL*.
- Kudo, T. & Richardson, J. (2018). SentencePiece. *EMNLP*.

Leitura complementar:

- Radford, A. et al. (2019). Language Models are Unsupervised Multitask Learners. (GPT-2)
- Xue, L. et al. (2022). ByT5: Towards a Token-Free Future. *NAACL*.
- Yu, L. et al. (2023). MegaByte: Predicting Million-Byte Sequences. *NeurIPS*.
- Provilkov, I. et al. (2020). BPE-Dropout. *ACL*.