

# Deep Learning

## *Modelos de Linguagem Decoder-Only*

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory  
PUCRS

maio de 2026

# Visão Geral

---

1. Revisão do Transformer
2. A Família GPT e o Paradigma Decoder-Only
3. Leis de Escala
4. Normalização: Layer Norm e RMS Norm
5. Aproximações de Atenção
6. Mistura de Especialistas (MoE)
7. Estratégias de Decodificação
8. Benchmarks e Avaliação de LLMs

# Overview

---

1. **Revisão do Transformer**
2. A Família GPT e o Paradigma Decoder-Only
3. Leis de Escala
4. Normalização: Layer Norm e RMS Norm
5. Aproximações de Atenção
6. Mistura de Especialistas (MoE)
7. Estratégias de Decodificação
8. Benchmarks e Avaliação de LLMs


# Arquitetura Original: Encoder-Decoder [18]

**Encoder** (esquerda):

- Lê toda a entrada **bidirecional**
- Self-attention não mascarada
- Produz representações contextuais ricas

**Decoder** (direita):

- Gera tokens **autorregressivamente**
- Self-attention **mascarada** (causal)
- **Cross-attention**: lê saída do encoder



Pergunta-chave

Precisamos do encoder para geração de linguagem?

# Multi-Head Self-Attention

Dado um token, computamos queries, keys e values:

## Atenção escalada

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Cada cabeça aprende padrões diferentes:

$$\text{MHA} = \text{Concat}(\text{head}_1, \dots, \text{head}_H) W^O$$

- $H$  cabeças  $\times d_k = d_{\text{model}}/H$
- Custo:  $O(n^2d)$  por camada
- Paralelizável sobre toda a sequência

## Máscara causal (decoder)

Posição  $i$  só pode atender a  $j \leq i$ :

$$M_{ij} = \begin{cases} 0 & j \leq i \\ -\infty & j > i \end{cases}$$

# Bloco Transformer: FFN, Resíduo e Normalização

Cada camada contém:

1. **(Masked) Self-Attention** + resíduo + norma
2. **Feed-Forward** + resíduo + norma

## FFN de dois estágios

$$\text{FFN}(x) = \max(0, xW_1 + b_1) W_2 + b_2$$

Dimensão interna:  $d_{\text{ff}} \approx 4 d_{\text{model}}$

(Valor empírico de [18]; modelos com SwiGLU partem de  $\frac{8}{3} d_{\text{model}}$ , ajustado para múltiplos convenientes. Para  $d = 4096$ : 11 008 no Llama 2, 14 336 no Llama 3 (que adota expansão maior).)

## Post-Norm (Vaswani 2017)

$$x \leftarrow \text{LN}(x + \text{SubLayer}(x))$$


GPT-2 em diante usa **Pre-Norm**:

## Pre-Norm (GPT-2+)

$$x \leftarrow x + \text{SubLayer}(\text{Norm}(x))$$

Empilhar  $N$  desses blocos =  
Transformer.

# FFN Padrão: Exemplo Numérico (ReLU)



## Exemplo numérico

$$d_{\text{model}} = 3, \quad d_{ff} = 4 \times 3 = 12$$

$$x = [1.0, 0.5, -0.5]$$

$$xW_1 = [2.0, -1.0, 0.5, \dots] \text{ (dim 12)}$$

$$\text{ReLU}(xW_1) = [2.0, 0.0, 0.5, \dots]$$

$\Rightarrow$  ReLU **zera** o valor negativo  $-1.0$ !

$$[\dots]W_2 \approx y = [0.7, -0.2, 0.4]$$

# SwiGLU: A FFN com *Gate* das LLMs mais atuais

FFN clássica usa **ReLU**:

ReLU-FFN (Vaswani 2017)

$$\text{FFN}(x) = \max(0, xW_1) W_2$$

Llama 2/3, PaLM, Mistral usam **SwiGLU** [15]:

SwiGLU-FFN

$$\text{FFN}(x) = (\text{SiLU}(xW_1) \odot xW_3) W_2$$

onde  $\text{SiLU}(z) = z \cdot \sigma(z)$  (*Swish*).

O **portão**  $xW_3$  filtra dinamicamente a informação.

Por que  $\frac{8}{3} d_{\text{model}}$ ?

SwiGLU usa **3 matrizes** em vez de 2.  
Para manter o mesmo número de parâmetros:


$$3 \times d_{\text{ff}} \cdot d = 2 \times 4d \cdot d$$

$$\Rightarrow d_{\text{ff}} = \frac{8}{3} d_{\text{model}}$$

- SwiGLU supera ReLU e GELU empiricamente
- Motivação teórica: portão aprende *quais* dimensões ativar
- Alternativas: GeGLU, ReGLU



# SwiGLU: Diagrama Computacional e Dimensões



Exemplo numérico

$$d_{\text{model}} = 3, \quad d_{ff} = \frac{8}{3} \times 3 = 8$$

$$x = [1.0, 0.5, -0.5]$$

$$xW_1 = [2.0, -1.0, 0.5, 1.2, \dots]$$

$$\text{SiLU}(xW_1) \approx [1.76, -0.27, 0.31, 1.09, \dots]$$

$$xW_3 = [0.8, 0.0, 1.2, 0.5, \dots] \text{ (portão)}$$

$$[1.76, -0.27, 0.31, 1.09, \dots]$$

$$\odot [0.8, 0.0, 1.2, 0.5, \dots]$$

$$= [1.41, 0.00, 0.37, 0.55, \dots]$$

$\Rightarrow$  portão **0.0** suprime a dim. 2!

$$[\dots]W_2 \approx y = [0.7, -0.2, 0.4]$$

# O que Encoder e Decoder fazem?

---

## Encoder: compreensão

- Processa **toda a entrada** de uma vez
- Atenção bidirecional
- Produz vetor de contexto rico
- Exemplos: BERT, RoBERTa

## Decoder: geração

- Gera **um token por vez**
- Atenção causal (só vê o passado)
- Recebe contexto via cross-attention
- Exemplos: GPT, T5-decoder

**Para LLMs, o encoder é desnecessário.**

O decoder processa o *prompt* como parte da sequência.

# Máscara Causal vs. Atenção Bidirecional

**Bidirecional (BERT/Encoder):**  
cada posição vê *toda* a sequência.

|       | $t_1$ | $t_2$ | $t_3$ | $t_4$ |
|-------|-------|-------|-------|-------|
| $t_1$ | ✓     | ✓     | ✓     | ✓     |
| $t_2$ | ✓     | ✓     | ✓     | ✓     |
| $t_3$ | ✓     | ✓     | ✓     | ✓     |
| $t_4$ | ✓     | ✓     | ✓     | ✓     |

**Causal (GPT/Decoder-Only):**  
posição  $i$  só vê  $j \leq i$ .

|       | $t_1$ | $t_2$ | $t_3$ | $t_4$ |
|-------|-------|-------|-------|-------|
| $t_1$ | ✓     | ×     | ×     | ×     |
| $t_2$ | ✓     | ✓     | ×     | ×     |
| $t_3$ | ✓     | ✓     | ✓     | ×     |
| $t_4$ | ✓     | ✓     | ✓     | ✓     |

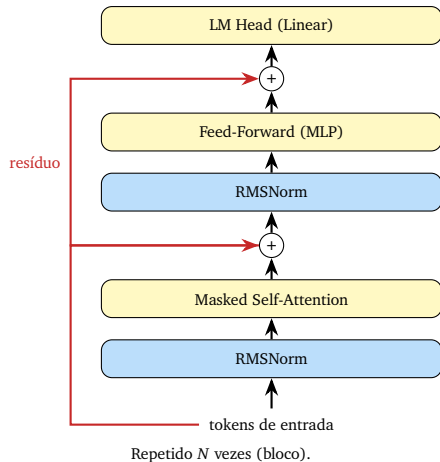
Garante que  $t_4$  não “veja o futuro” durante o treino.

# Do Encoder-Decoder para o Decoder-Only

**Ideia central:** treine apenas o decoder.

O modelo recebe o texto de entrada como *prefixo* e continua gerando autorregressivamente.

- Sem cross-attention
- Sem encoder separado
- Toda informação está nas posições anteriores
- Arquitetura mais simples



# Overview

---

1. Revisão do Transformer
- 2. A Família GPT e o Paradigma Decoder-Only**
3. Leis de Escala
4. Normalização: Layer Norm e RMS Norm
5. Aproximações de Atenção
6. Mistura de Especialistas (MoE)
7. Estratégias de Decodificação
8. Benchmarks e Avaliação de LLMs

# GPT-1: Pré-Treino + Fine-Tuning [12]

---

Radford et al. (2018), OpenAI

**Objetivo de pré-treino:** modelagem de linguagem causal

$$\mathcal{L} = - \sum_t \log P(x_t \mid x_1, \dots, x_{t-1}; \Theta)$$

Depois: *fine-tuning* supervisionado para cada tarefa.

- 117M parâmetros
- 12 camadas,  $d = 768$ , 12 cabeças
- BooksCorpus ( $\approx 800$ M tokens)
- Tokenização BPE

## Contribuição

Mostrou que pré-treino auto-supervisionado em texto melhora fortemente o fine-tuning.

## GPT-2: Geração Zero-Shot [13]

---

Radford et al. (2019)

**Hipótese:** um LM suficientemente grande aprende a realizar tarefas **sem fine-tuning**.

*“Language models are unsupervised multitask learners”*

Novidades técnicas:

- Pre-Norm ao invés de Post-Norm
- Contexto: 1024 tokens
- Vocabulário: 50257 tokens (BPE<sup>a</sup>)

---

<sup>a</sup>BPE = *Byte-Pair Encoding*: segmenta palavras em sub-palavras frequentes, reduzindo o tamanho do vocabulário.

| Versão | Params | Camadas | $d$  | $H$ |
|--------|--------|---------|------|-----|
| Small  | 117M   | 12      | 768  | 12  |
| Medium | 345M   | 24      | 1024 | 16  |
| Large  | 762M   | 36      | 1280 | 20  |
| XL     | 1.5B   | 48      | 1600 | 25  |

Dataset: WebText (40GB de texto web filtrado).

# GPT-3: Zero e Few-shot learning[3]

**Brown et al. (2020)**, 175 bilhões de parâmetros

**Few-shot prompting:** exemplos fornecidos *no contexto*, sem atualização de pesos.

## Modos de uso em contexto

- **Zero-shot:** só a instrução
- **One-shot:** 1 exemplo no prompt
- **Few-shot:** K exemplos no prompt

- 96 camadas,  $d = 12288$ , 96 cabeças
- Contexto: 2048 tokens
- Treinado em 300B tokens
- **Capacidades emergentes:** habilidades que *surgem abruptamente* com escala (aritmética, tradução, raciocínio); ausentes em modelos menores

## Mudança de paradigma

A partir do GPT-3, o fine-tuning por tarefa foi substituído pela engenharia de *prompts*.



# Bloco Transformer Decoder-Only em Detalhe

---

O bloco básico repete-se  $N$  vezes:

1. **Normalização** (Pre-Norm)
2. **Masked Self-Attention**
3. Conexão residual:  $x += \text{Attn}(\cdot)$
4. **Normalização**
5. **Feed-Forward** (MLP)
6. Conexão residual:  $x += \text{FFN}(\cdot)$

**Sem** cross-attention. Toda informação está nas  $n$  posições anteriores da sequência.

## KV-Cache

Durante inferência, K e V já calculados são armazenados.

**Sem cache:** custo  $O(n^2d)$  por token

**Com cache:** custo  $O(nd)$  por token

Essencial para geração eficiente em sequências longas.

# KV-Cache: Como Funciona na Prática

Gerando a sequência “O rato roeu a rolha”:

1. **Prefill:** alimenta o *prompt* inteiro de uma vez  
→ computa e *armazena* K, V de cada token
2. **Decode passo 1:** prediz próximo token  
→ computa K, V só do token novo  
→ reutiliza K, V dos tokens anteriores do cache
3. **Decode passo 2, 3, ...:** idem  
→ cache cresce a cada passo gerado

## Sem cache (naïve)

Para o  $n$ -ésimo token:

Recalcula K, V de todos os  $n$  tokens

Custo total:  $O(n^2d)$

## Com cache

Computa K, V apenas do token novo

Concatena com o cache existente

Custo por token:  $O(nd)$


Memória do cache  $\propto n \cdot L \cdot d_k$ , cresce com a sequência e número de camadas.

# KV-Cache: Visualização

## Prefill

---

Exemplo: “O rato roeu a rolha”, todos os K,V do prompt são computados de uma vez.




■ = token    ■ = computando agora

# KV-Cache: Visualização

## Decode (Passo 1)

Gerando "a": apenas  $K_4, V_4$  são computados;  $K_1, K_2, K_3$  vêm do cache.




■ = cache (reutilizado)   ■ = computando agora

# KV-Cache: Visualização

## Decode (Passo 2)

Gerando "rolha": apenas  $K_5, V_5$  são computados; cache cresce para 4 entradas.



■ = cache (reutilizado) ■ = computando agora

# Overview

---

1. Revisão do Transformer
2. A Família GPT e o Paradigma Decoder-Only
- 3. Leis de Escala**
4. Normalização: Layer Norm e RMS Norm
5. Aproximações de Atenção
6. Mistura de Especialistas (MoE)
7. Estratégias de Decodificação
8. Benchmarks e Avaliação de LLMs

# O que Significa “Escalar” um LLM?

---

Três eixos de escala:

1. **Parâmetros**  $N$ : tamanho do modelo
2. **Dados**  $D$ : tokens de treinamento
3. **Compute**  $C$ : FLOPs totais de treino

(FLOP = *Floating Point Operation*, unidade de custo aritmético)

Relação aproximada:

$$C \approx 6ND$$

Cada token exige  $\approx 6$  FLOPs por parâmetro:  
2 no *forward* + 4 no *backward* [10].

## Pergunta central

Dado um orçamento de compute fixo, como distribuir entre  $N$  (modelo maior) e  $D$  (mais dados)?

Isso é exatamente o que as **leis de escala** respondem.

# Leis de Escala de Kaplan et al. [10]

---

**Descoberta:** a perda de teste segue **leis de potência**:

$$L(N) \propto N^{-\alpha_N}, \quad L(D) \propto D^{-\alpha_D}$$

com  $\alpha_N \approx 0.076$ ,  $\alpha_D \approx 0.095$ .

**Recomendação:** dado compute fixo, priorize **escalar**  $N$  e use menos dados.

- Válido para modelos de 768M a 1.5B parâmetros
- Curvas de perda suaves e previsíveis
- Arquitetura (profundidade vs. largura) tem impacto menor

## Limitação

Kaplan et al. não otimizavam  $N$  e  $D$  simultaneamente; fixavam  $N$  e mediam  $L$  ótima em  $C$ .



# Chinchilla: Treinamento Compute-Ótimo [7]

Hoffmann et al. (2022), DeepMind  
Treinaram 400+ modelos variando  $N$  e  $D$   
com mesmo  $C$ .

## Resultado central

Para compute ótimo:

$$N^* \propto C^{0.5}, \quad D^* \propto C^{0.5}$$

**Dobrar compute  $\rightarrow$  dobrar  $N$  E dobrar  $D$ .**


Chinchilla (70B)  $\approx$  Gopher (280B)  
em qualidade, com 4 $\times$  menos  
compute de inferência.

## Regra prática

Para um modelo de  $N$  parâmetros,  
treine com pelo menos  $20N$  **tokens**.

Exemplo: modelo de 7B  $\rightarrow \geq 140$ B  
tokens.

# Relação Ótima Tokens/Parâmetros



- Linha azul: regra dos  $20N$  tokens (Chinchilla)
- Modelos recentes usam **muito mais dados**: Chinchilla sugere  $20N$  para  $8B = 160B$  tokens; Llama 3 usou  $15T$ ,  $\sim 93\times$  mais

Compute-ótimo  $\neq$  inferência-ótimo

Modelos menores treinados por mais tempo custam menos na inferência, preferíveis quando há muitas chamadas.

# Implicações Práticas das Leis de Escala

---

- **Llama 1** (Meta, 2023): 7B–65B treinados com 1T–1.4T tokens
- **Llama 2** (Meta, 2023): até 2T tokens, contexto 4096
- **Llama 3** (Meta, 2024): 8B e 70B com 15T tokens
- **Mistral 7B** (2023): supera Llama 2 13B com 7B parâmetros

## Lição aprendida

Treinar modelos **menores por mais tempo** é mais custo-efetivo para implantação do que modelos gigantes subtreinados.

A Chinchilla reorientou o campo: de corrida por parâmetros (GPT-3, Gopher, Megatron) para equilíbrio  $N \times D$ .

## Modelos Recentes: Parâmetros, Dados e Contexto

| Modelo       | Params | Tokens treino | Contexto | Norm    | Atenção |
|--------------|--------|---------------|----------|---------|---------|
| GPT-2 XL     | 1.5B   | ~40B          | 1 024    | Pre-LN  | MHA     |
| GPT-3        | 175B   | 300B          | 2 048    | Pre-LN  | MHA     |
| Llama 2 7B   | 7B     | 2T            | 4 096    | RMSNorm | GQA     |
| Llama 2 70B  | 70B    | 2T            | 4 096    | RMSNorm | GQA     |
| Llama 3 8B   | 8B     | 15T           | 8 192    | RMSNorm | GQA     |
| Mistral 7B   | 7B     | ~1T           | 32 768   | RMSNorm | GQA+SWA |
| Mixtral 8×7B | 46.7B  | ~1T           | 32 768   | RMSNorm | GQA+MoE |

SWA = Sliding Window Attention; MoE = Mistura de Especialistas

# Overview

---

1. Revisão do Transformer
2. A Família GPT e o Paradigma Decoder-Only
3. Leis de Escala
- 4. Normalização: Layer Norm e RMS Norm**
5. Aproximações de Atenção
6. Mistura de Especialistas (MoE)
7. Estratégias de Decodificação
8. Benchmarks e Avaliação de LLMs

# Por que Normalizar as Ativações?

---

Durante o treino de redes profundas:

- Distribuição das ativações muda a cada camada (*internal covariate shift*)
- Gradientes explodem ou desaparecem
- Taxas de aprendizado devem ser muito pequenas

**Batch Norm:** normaliza sobre o batch, problemático para sequências de tamanho variável.

## Solução para Transformers

**Layer Normalization** [2]: normaliza sobre as *features* de cada token, sem dependência do batch.

Permite treino estável de Transformers muito profundos com learning rates maiores.

## Layer Normalization [2]

---

Dado o vetor de ativações  $\mathbf{x} \in \mathbb{R}^d$  de um token:

$$\mu = \frac{1}{d} \sum_{i=1}^d x_i, \quad \sigma^2 = \frac{1}{d} \sum_{i=1}^d (x_i - \mu)^2$$

$$\hat{x}_i = \frac{x_i - \mu}{\sqrt{\sigma^2 + \epsilon}}$$

$$\text{LN}(\mathbf{x}) = \boldsymbol{\gamma} \odot \hat{\mathbf{x}} + \boldsymbol{\beta}$$

$\boldsymbol{\gamma}, \boldsymbol{\beta} \in \mathbb{R}^d$ : parâmetros aprendidos (*gain* e *bias*).

- Independente do tamanho do batch
- Funciona com sequências de tamanho variável
- Aplicada **por token** (ao longo da dimensão  $d$ )

### Nota

A normalização ocorre ao longo da dimensão de features  $d$  de cada token, não ao longo da sequência.

# Pre-Norm vs. Post-Norm

---

## Post-Norm (Vaswani 2017)

$$x \leftarrow \text{LN}(x + \text{SubLayer}(x))$$

Normalização **depois** da operação.

→ gradientes instáveis com  $N$  grande;  
requer *warm-up* lento.

## Pre-Norm (GPT-2 em diante)

$$x \leftarrow x + \text{SubLayer}(\text{LN}(x))$$

Normalização **antes** da operação.

→ treino mais estável; gradientes fluem  
melhor pela conexão residual.

**Hoje**, quase todos os LLMs usam **Pre-Norm**.

A conexão residual “bypassa” a normalização, preservando o sinal ao longo das camadas.



## RMS Norm: Simplificação do Layer Norm [21]

**Zhang & Sennrich (2019):** o re-centramento (subtração de  $\mu$ ) é desnecessário quando a invariância de escala é suficiente.

Normaliza apenas pela raiz do valor quadrático médio:

$$\text{RMS}(\mathbf{x}) = \sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2}$$

$$\text{RMSNorm}(\mathbf{x}) = \frac{\mathbf{x}}{\text{RMS}(\mathbf{x})} \odot \boldsymbol{\gamma}$$

**Sem  $\mu$ , sem  $\beta$ ,** mais simples e rápido.

- Mais rápido: sem cálculo de média
- Mesma qualidade empírica que LayerNorm
- Menos parâmetros (sem  $\beta$ )

Adotado por

Llama 1/2/3, Mistral, Mixtral, Gemma, Falcon, PaLM, ...

Citado em [17] como padrão atual para LLMs eficientes.

## Qual Normalização Cada Modelo Usa?

---

| Modelo      | Norma     | Posição   | Bias $\beta$ ? | Observação                                  |
|-------------|-----------|-----------|----------------|---------------------------------------------|
| BERT        | LayerNorm | Post-Norm | Sim            | Encoder bidirecional                        |
| GPT-2       | LayerNorm | Pre-Norm  | Sim            | Decoder-only                                |
| GPT-3       | LayerNorm | Pre-Norm  | Sim            | Decoder-only                                |
| Llama 1/2/3 | RMSNorm   | Pre-Norm  | Não            | Decoder-only                                |
| Mistral 7B  | RMSNorm   | Pre-Norm  | Não            | Decoder-only                                |
| Gemma       | RMSNorm   | Pre+Post  | Não            | “Sandwich” norm, estabiliza treino profundo |
| PaLM        | RMSNorm   | Pre-Norm  | Não            | Decoder-only                                |

**Tendência: RMSNorm + Pre-Norm para LLMs modernos.**

# Overview

---


1. Revisão do Transformer
2. A Família GPT e o Paradigma Decoder-Only
3. Leis de Escala
4. Normalização: Layer Norm e RMS Norm
- 5. Aproximações de Atenção**
6. Mistura de Especialistas (MoE)
7. Estratégias de Decodificação
8. Benchmarks e Avaliação de LLMs

# O Gargalo Quadrático da Atenção

## Custo da atenção padrão [18]:

- Memória:  $O(n^2)$ , matriz de scores
- Compute:  $O(n^2d)$ , produto  $QK^\top$

Com  $n = 32\,768$  tokens e  $H = 32$  cabeças:  
Matriz de atenção:  $32768^2 \times 32 \approx 34$  GB  
(float16)



**Motivação:** reduzir custo ao escalar o contexto [17].

# Multi-Head Attention (MHA)

## Recapitulação


---

Com  $H$  cabeças,  $d_k = d_{\text{model}}/H$ :

- $H$  projeções de Q, K, V independentes
- $H$  pares de matrizes KV em cache por camada
- Custo de KV-cache por token:  $2 \cdot H \cdot d_k \cdot L$

Para GPT-3 ( $H = 96$ ,  $d_k = 128$ ,  $L = 96$ ):

Cache =  $2 \times 96 \times 128 \times 96 \approx 2.4\text{M floats/token}$



KV-cache:  $H$  pares por camada

Gargalo em inferência: KV-cache cresce com  $n$ ,  $H$ ,  $L$ .


# Multi-Query Attention (MQA) [14]

**Shazeer (2019):** reduza K e V para **uma única cabeça** compartilhada; mantenha  $H$  cabeças de Q.

$$\text{head}_h = \text{Attn}(QW_h^Q, KW^K, VW^V)$$

**Redução de cache:**  $H \times \rightarrow 1 \times$  nos tensores K, V.

Cache por token:  $2 \cdot d_k \cdot L$  (independente de  $H$ ).



- KV-cache  $H \times$  menor
- Inferência muito mais rápida
- Leve queda de qualidade


# Grouped Query Attention (GQA) [1]

**Ainslie et al. (2023)**: compromisso entre MHA e MQA.

Divida as  $H$  cabeças de Q em  $G$  grupos. Cada grupo compartilha um par K,V.

$$G = 1 \Rightarrow \text{MQA} \quad G = H \Rightarrow \text{MHA}$$

Llama 2/3, Mistral, Mixtral usam GQA.



- $G = 8$  típico (Llama 2 70B:  $H = 64, G = 8$ )
- Cache reduzido  $H/G \times$
- Qualidade quase idêntica ao MHA

## Comparação: MHA, MQA e GQA

| Variante | Pares K,V           | Cache KV      | Qualidade     | Exemplos           |
|----------|---------------------|---------------|---------------|--------------------|
| MHA      | $H$                 | $H \cdot d_k$ | Referência    | GPT-2, GPT-3, BERT |
| MQA      | 1                   | $d_k$         | ↓ levemente   | PaLM, Falcon       |
| GQA      | $G$ ( $1 < G < H$ ) | $G \cdot d_k$ | $\approx$ MHA | Llama 2/3, Mistral |

### GQA na prática

Llama 2 70B:  $H = 64$  cabeças Q,  $G = 8$  grupos KV.  
Cache 8× menor que MHA com qualidade semelhante.

### Por que importa?

Redução do KV-cache é fundamental para servir muitos usuários simultaneamente, o cache de todos os requests cabe na GPU.



# Sliding Window Attention [8]

**Motivação:** em sequências longas, a maioria das informações úteis está **próxima** do token atual.

Cada posição  $i$  atende apenas às  $W$  posições anteriores:

$$\text{Attn}(i) \leftarrow \text{tokens em } [i - W, i]$$

Custo:  $O(n \cdot W)$  em vez de  $O(n^2)$ .

Campo receptivo em  $L$  camadas:  $L \cdot W$ .

Informação distante propaga-se por composição: camada  $l$  agrega o que camada

$l-1$  já resumiu da janela anterior.

## Configuração Mistral 7B

- Janela local:  $W = 4096$
- 32 camadas
- Campo receptivo:  
 $32 \times 4096 = 131\text{K}$
- Contexto declarado: 32K tokens

**Resultado:** Mistral 7B supera Llama 2 13B em benchmarks com 2× menos parâmetros.

## Resumo: Variantes de Atenção e Trade-offs

---

| Variante     | Compute   | Mem. KV       | Contexto longo | Qualidade     | Exemplos           |
|--------------|-----------|---------------|----------------|---------------|--------------------|
| MHA (padrão) | $O(n^2d)$ | $H \cdot d_k$ | Limitado       | Referência    | GPT-2/3            |
| MQA          | $O(n^2d)$ | $d_k$         | Moderado       | ↓ levemente   | PaLM, Falcon       |
| GQA          | $O(n^2d)$ | $G \cdot d_k$ | Moderado       | $\approx$ MHA | Llama 2/3, Mistral |
| SWA          | $O(nWd)$  | $W \cdot d_k$ | Alto           | Boa (local)   | Mistral            |

Baseado em [17]. SWA = Sliding Window Attention.

# Overview

---

1. Revisão do Transformer
2. A Família GPT e o Paradigma Decoder-Only
3. Leis de Escala
4. Normalização: Layer Norm e RMS Norm
5. Aproximações de Atenção
- 6. Mistura de Especialistas (MoE)**
7. Estratégias de Decodificação
8. Benchmarks e Avaliação de LLMs

# Motivação: Mais Parâmetros sem Mais Compute

---

## Dilema:

- Modelos maiores  $\rightarrow$  melhor qualidade
- Modelos maiores  $\rightarrow$  mais compute por token

## Ideia da Mistura de Especialistas (MoE):

Substitua a FFN densa por  $E$  redes menores (*especialistas*).

Cada token ativa apenas  $k$  especialistas ( $k \ll E$ ).

### Exemplo: Mixtral $8 \times 7B$

8 especialistas FFN


Apenas 2 ativados por token

$\rightarrow$  46.7B parâmetros totais

$\rightarrow$  compute  $\approx$  12.9B por token

Origem: **Sparsely-Gated MoE** [16] (2017), revivido em LLMs a partir de 2022.

# Arquitetura MoE: Router + Especialistas



Em cada bloco MoE:

1. Router calcula scores para cada especialista
2. Seleciona top- $k$  especialistas
3. Processa  $x$  nos  $k$  especialistas
4. Combina saídas ponderadas pelos scores

## Nota importante

As camadas de **atenção** permanecem densas.  
Somente a FFN vira MoE.

# Top- $k$ Routing: Mecanismo de Gating

Dado token  $x \in \mathbb{R}^d$  e pesos  $W_g \in \mathbb{R}^{d \times E}$ :

$$g(x) = \text{softmax}(\text{TopK}(xW_g, k))$$

onde TopK mantém os  $k$  maiores scores e zera o resto.

Saída:

$$y = \sum_{i \in \text{Top-}k} g_i(x) \text{FFN}_i(x)$$

- Mixtral usa  $k = 2$ ,  $E = 8$
- ~25% dos parâmetros ativos por token
- Backward: apenas pelos  $k$  especialistas ativos

## Expert collapse

**Causa:** o router aprende a enviar tokens ao especialista que já é o melhor, que melhora ainda mais, atraindo mais tokens, em ciclo de reforço positivo.

**Resultado:** 1–2 especialistas processam quase tudo; os demais recebem gradiente zero e nunca aprendem.

**Solução:** *Loss* auxiliar de balanceamento (próximo slide).

# Problemas de MoE: Balanceamento de Carga

Perda auxiliar de balanceamento:

$$\mathcal{L}_{\text{aux}} = \alpha \cdot E \cdot \sum_{i=1}^E f_i \cdot P_i$$

onde  $f_i$  = fração de tokens roteados ao especialista  $i$ ,

$P_i$  = score médio do router para o especialista  $i$ .

Minimizar  $\mathcal{L}_{\text{aux}}$  encoraja distribuição uniforme.

Outros desafios:

- **Instabilidade:** gradientes esparsas podem causar divergência
- **Comunicação:** especialistas distribuídos em GPUs diferentes (*model parallelism*)
- **Capacidade máxima:** tokens descartados se um especialista ficar sobrecarregado

## Mixtral

Usa  $\alpha = 0.01$ , roteamento token a token.

# Mixtral 8×7B [9]

Jiang et al. (2024), Mistral AI

Arquitetura:

- 32 camadas transformer
- Cada FFN → 8 especialistas de 14336 neurônios
- Top-2 routing por token
- GQA ( $G = 8$ ), RMSNorm, SWA
- Contexto: 32 768 tokens

| Modelo       | Params ativos | Params totais |
|--------------|---------------|---------------|
| Llama 2 13B  | 13B           | 13B           |
| Llama 2 70B  | 70B           | 70B           |
| Mistral 7B   | 7B            | 7B            |
| Mixtral 8×7B | 12.9B         | 46.7B         |

## Resultado

Mixtral 8×7B supera Llama 2 70B em benchmarks com 5.4× menos parâmetros ativos.



# MoE Sparse vs. Modelos Densos

---

| Característica        | Denso (Llama 2 70B) | Sparse MoE (Mixtral 8×7B) |
|-----------------------|---------------------|---------------------------|
| Parâmetros totais     | 70B                 | 46.7B                     |
| Parâmetros ativos     | 70B                 | 12.9B                     |
| Compute por token     | Alto                | ~ 5× menor                |
| Memória total (fp16)  | ~140 GB             | ~93 GB                    |
| Throughput (tokens/s) | Menor               | Maior                     |
| Qualidade (MMLU)      | 68.9%               | 70.6%                     |

**MoE: mais capacidade com menor custo de inferência,**  
ao custo de maior memória total e complexidade de treino.

# Overview

---

1. Revisão do Transformer
2. A Família GPT e o Paradigma Decoder-Only
3. Leis de Escala
4. Normalização: Layer Norm e RMS Norm
5. Aproximações de Atenção
6. Mistura de Especialistas (MoE)
- 7. Estratégias de Decodificação**
8. Benchmarks e Avaliação de LLMs

# Estratégias de Decodificação: Greedy, Beam, Sampling

Após o LM produzir logits  $z \in \mathbb{R}^{|V|}$ :

## Greedy

$$x_t = \arg \max_v P(v \mid x_{<t})$$

Rápido, determinístico, pode ser subótimo.

## Beam Search

Mantém  $B$  hipóteses; escolhe a de maior probabilidade conjunta.  $O(B)$  mais lento; ótimo para tradução.

## Amostragem

$$x_t \sim P(\cdot \mid x_{<t})$$

Estocástico; necessário para criatividade.

Parâmetros de controle:

- **Temperature**  $T$ :  $P_T \propto z_v/T$
- **Top-k**: restringe ao top-k tokens
- **Top-p** (nucleus): restringe ao menor conjunto com prob. acumulada  $\geq p$


# Temperature, Top- $k$ e Top- $p$

## Temperature:

$$P_T(x) = \frac{\exp(z_x/T)}{\sum_v \exp(z_v/T)}$$

- $T \rightarrow 0$ : greedy
- $T = 1$ : distribuição original
- $T > 1$ : distribuição mais uniforme

**Top- $p$ :** selecione o menor conjunto de tokens cuja probabilidade acumulada  $\geq p$  (ex:  $p = 0.9$ ), então amostra dentro desse conjunto.



# Decodificação Guiada (*Constrained Decoding*) [19]

---

**Problema:** LLMs podem gerar texto que não segue formato específico (JSON, SQL, código).

**Solução:** restringir a distribuição de saída a tokens válidos segundo uma **gramática** ou **esquema**.

**Willard & Louf (2023):** pré-compila um DFA para cada gramática, o mascaramento de tokens inválidos é  $O(1)$  por token.

## Exemplos de uso

- Geração de JSON estruturado
- SQL sem erros de sintaxe
- Extração em formato fixo
- Chamadas de API com parâmetros corretos

Implementações: outlines, guidance, llama.cpp grammar mode, vLLM structured outputs.

# Decodificação Especulativa: Ideia Geral [11]

---

**Gargalo:** LLMs grandes são lentos, cada token exige um passe completo.

**Observação:** a maioria dos tokens é fácil de prever; tokens difíceis são exceção.

**Algoritmo:**

1. **Draft model** pequeno gera  $y$  tokens
2. **Target model** verifica *em paralelo*
3. Tokens aceitos  $\rightarrow$  mantidos; primeiro rejeitado  $\rightarrow$  re-amostrado

## Propriedade chave

Saída **idêntica em distribuição** ao modelo alvo, sem perda de qualidade por construção.

## Speedup típico

2–3 $\times$  com draft 10 $\times$  menor.  
Ex: Llama 3 70B + Llama 3 8B como draft.

# Algoritmo Especulativo: Critério de Aceitação

Draft model  $M_q$ , target model  $M_p$ :

Para cada token  $\tilde{x}_t$  proposto pelo draft:

$$\text{Aceitar com prob. } \min\left(1, \frac{p(\tilde{x}_t | x_{<t})}{q(\tilde{x}_t | x_{<t})}\right)$$

Se rejeitado: re-amostre de

$$p'(x) \propto \max(0, p(x) - q(x))$$

Verifique todos os  $\gamma$  tokens **em um único passe** do modelo alvo.

- $p \geq q$ : token **sempre aceito**
- Draft e target concordam  $\rightarrow$  aceleração máxima
- Tokens difíceis: target corrige

## Complexidade

$\gamma + 1$  passos de  $M_q$  + 1 passe de  $M_p$   
 $\rightarrow$  até  $\gamma + 1$  tokens gerados.

Sem especulação:  $\gamma + 1$  passes de  $M_p$ .

## Decodificação Especulativa: Exemplo Passo a Passo

**Contexto:** completar “O gato subiu na \_\_\_\_” com  $\gamma = 3$ .

Draft  $M_q$  propõe: árvore, e, dormiu, verificados em **um único passe** de  $M_p$ .

| Token  | $q$ | $p$ | $\min\left(1, \frac{p}{q}\right)$ | Decisão             |
|--------|-----|-----|-----------------------------------|---------------------|
| árvore | 0,6 | 0,9 | <b>1,00</b>                       | sempre aceito       |
| e      | 0,7 | 0,4 | 0,57                              | aceito c/ prob. 57% |
| dormiu | 0,8 | 0,2 | 0,25                              | aceito c/ prob. 25% |

### Cenário A (todos aceitos)

3 tokens em 1 passe de  $M_p$ .  
Sem especulação: 3 passes.

### Cenário B (e rejeitado)


Re-amostra de  $p' \propto \max(0, p-q)$ ;  
somente **árvore** confirmado,  
ainda 1 passe.



## Rejeição: Distribuições $q$ e $p$ para dormiu

**Contexto:** “O gato subiu na árvore e \_\_\_\_” (árvore e e já aceitos).

Draft  $M_q$  propõe dormiu com  $q=0,8$ ; modelo alvo tem  $p=0,2$ .



### Por que dormiu é rejeitado?

$$p(\text{dormiu}) = 0,2 < q(\text{dormiu}) = 0,8$$

Aceitar com probabilidade:

$$\min\left(1, \frac{p}{q}\right) = \frac{0,2}{0,8} = 0,25$$

Neste cenário, **dormiu é rejeitado**.

### Observação

$M_p$  prefere pulou ( $p=0,4$ ), o draft superestimou a certeza em dormiu.


## Re-amostragem: $p'(x) \propto \max(0, p(x) - q(x))$

| Token  | $p$  | $q$  | $p-q$ | $p'$ (norm.) |
|--------|------|------|-------|--------------|
| dormiu | 0,20 | 0,80 | -0,60 | 0,00         |
| pulou  | 0,40 | 0,10 | +0,30 | 0,50         |
| caiu   | 0,25 | 0,05 | +0,20 | 0,33         |
| desceu | 0,15 | 0,05 | +0,10 | 0,17         |

Token selecionado de  $p'$

pulou ( $p'=0,50$ )

“O gato subiu na árvore e pulou...”



### Garantia de correção

$p'$  concentra massa onde  $M_p$  discorda de  $M_q$ , garantindo distribuição **idêntica a amostrar de  $M_p$** .

# Decodificação Especulativa: Variantes e Resultados

---

## Leviathan et al. (2023):

- Testado: T5-XXL (11B) + T5-small (60M) como draft
- Speedup 2–3× dependendo da tarefa
- HumanEval (código): maior speedup (tokens repetitivos)
- Sem degradação de qualidade

## Variantes modernas:

- **Self-speculative**: camadas rascunho do próprio modelo
- **Medusa**: múltiplas cabeças de predição em paralelo
- **Eagle**: alinha representações de draft e target

### Requisito

Benefício depende da taxa de aceitação  $\alpha$ : quanto mais similares os modelos, maior  $\alpha$  e maior o speedup.

# Overview

---

1. Revisão do Transformer
2. A Família GPT e o Paradigma Decoder-Only
3. Leis de Escala
4. Normalização: Layer Norm e RMS Norm
5. Aproximações de Atenção
6. Mistura de Especialistas (MoE)
7. Estratégias de Decodificação
- 8. Benchmarks e Avaliação de LLMs**

# Perplexidade: A Métrica Mais Simples

---

**Definição:** mede o quão “surpreso” o modelo fica ao ver o texto.

$$\text{PPL}(w_1, \dots, w_N) = \exp\left(-\frac{1}{N} \sum_{i=1}^N \log P(w_i \mid w_1, \dots, w_{i-1})\right)$$

- Menor PPL  $\rightarrow$  modelo estima melhor a distribuição do corpus
- PPL = 1: certeza absoluta; PPL =  $|V|$ : uniforme sobre o vocabulário
- Diretamente ligada à *cross-entropy loss* do treino

## Intuição

PPL = 20  $\Rightarrow$  o modelo hesita, em média, entre 20 tokens igualmente prováveis a cada passo.

# Perplexidade: Por que Não é Suficiente?

---

## Limitações da perplexidade como única métrica

- **Acurácia factual:** um modelo com PPL baixa pode ainda assim alucinar fatos
- **Raciocínio:** baixa surpresa no texto não implica capacidade de resolver problemas
- **Seguimento de instruções:** não captura se o modelo obedece comandos do usuário
- **Desempenho em tarefas reais:** PPL não prediz bem resultados em downstream tasks

⇒ Precisamos de benchmarks específicos por tarefa para avaliar LLMs adequadamente.

# Desafios na Avaliação de LLMs

---

Por que avaliar LLMs é difícil?

- Saída livre → métricas automáticas são imperfeitas
- *Data contamination*: benchmarks no pré-treino
- Capacidades emergentes: falha em instâncias simples, acerta difíceis
- Benchmarks ficam saturados rapidamente

## Categorias de avaliação

- **Múltipla escolha**: ARC, MMLU
- **Geração + verificação**: GSM8k
- **Raciocínio**: HellaSwag, WinoGrande
- **Instrução**: MT-Bench, AlpacaEval
- **Arena humana**: Chatbot Arena (Elo)

## ARC: AI2 Reasoning Challenge [4]

---

Clark et al. (2018), Allen Institute for AI  
7787 questões de múltipla escolha de  
ciências (ensino fundamental/médio).

**Duas partições:**

- **ARC-Easy:** respondidas por sistemas de recuperação simples
- **ARC-Challenge:** exigem raciocínio; falham em sistemas simples

**Exemplo (ARC-Challenge):**

*“Qual propriedade de um asteróide seria afetada de forma diferente pela gravidade de Júpiter e da Terra?”*

(A) cor (B) massa (C) volume (D) **peso**

Avaliação: 0-shot ou 25-shot.

Resultados recentes

Llama 3 8B: 79.7% (ARC-C 25-shot)

GPT-4:  $\approx 96\%$



# GSM8k: Raciocínio Matemático [5]

Cobbe et al. (2021), OpenAI

8500 problemas matemáticos de nível fundamental.

## Características:

- Resolução em múltiplos passos (2–8 operações)
- Resposta final é um número inteiro
- Avaliado com *chain-of-thought* (CoT), o

modelo mostra o raciocínio passo a passo antes da resposta final

Exemplo:

“Natalia vendeu 48 clips em abril e metade disso em maio. Total?”  $\Rightarrow 48 + 24 = 72$

| Modelo       | GSM8k (%)   |
|--------------|-------------|
| GPT-2 (1.5B) | $\approx 0$ |
| GPT-3 (175B) | 17.9        |
| Llama 2 7B   | 14.6        |
| Llama 2 70B  | 56.8        |
| Mixtral 8×7B | 74.4        |
| Llama 3 8B   | 79.6        |
| Llama 3 70B  | 93.0        |
| GPT-4        | 92.0        |

# MMLU: Massive Multitask Language Understanding [6]

Hendrycks et al. (2021), UC Berkeley

15 908 questões em **57 áreas**:

- Matemática, física, química, biologia
- Direito, medicina, economia
- História, filosofia, ciência da computação

Nível: colegial ao profissional avançado.

Avaliação: 5-shot.

| Modelo            | MMLU (%) |
|-------------------|----------|
| GPT-3 (175B)      | 43.9     |
| Llama 2 7B        | 45.3     |
| Llama 2 70B       | 68.9     |
| Mixtral 8×7B      | 70.6     |
| Llama 3 8B        | 66.6     |
| Llama 3 70B       | 79.5     |
| GPT-4             | 86.4     |
| Humano (estimado) | ≈89.8    |

## Exemplo: Conhecimento Clínico

Qual achado laboratorial é mais típico de anemia ferropriva?

(A) MCV elevado    (B) Ferritina elevada

(C) MCV reduzido e RDW elevado    (D) B12 reduzida

# HellaSwag e WinoGrande: Raciocínio de Senso Comum

---

## HellaSwag [20]

**Zellers et al. (2019)**

Completar a continuação mais plausível.

*“Alguém lava um carro. Ele esfrega o capô...”*

(A) e joga fora.

(B) por muito tempo.

**(C) com esponja verde.**

(D) e come um bolo.

GPT-3: 78.9%; Llama 3 8B: 82.0%

## WinoGrande

**Sakaguchi et al. (2021)**

Resolução de co-referência adversarial.

*“Mark é mais alto que Paul, então ele agachou na foto.”*

(Mark ou Paul agachou?)

Requer raciocínio físico/social.

Llama 3 8B: 73.0%; GPT-4:  $\approx 87\%$

# Open LLM Leaderboard: Como Comparar Modelos

---

Hugging Face mantém *leaderboard* público de LLMs avaliados em condições padronizadas:

- ARC-Challenge (25-shot)
- HellaSwag (10-shot)
- MMLU (5-shot)
- TruthfulQA (0-shot)
- WinoGrande (5-shot)
- GSM8k (5-shot)

Média dos 6 = **score composto**.

## Cuidados na interpretação

- Modelos treinados para benchmarks
- Contaminação de dados de teste
- Prompts e few-shot afetam resultados
- Saturação rápida (MMLU-Pro, ARC-AGI)

# Comparativo de Modelos nos Principais Benchmarks

| Modelo       | ARC-C | HSwag | MMLU | TruthQA | WinoG | GSM8k | Média |
|--------------|-------|-------|------|---------|-------|-------|-------|
| Llama 2 7B   | 53.1  | 78.6  | 45.3 | 39.4    | 74.0  | 14.6  | 50.8  |
| Llama 2 13B  | 59.4  | 82.1  | 54.8 | 37.4    | 77.0  | 28.7  | 56.6  |
| Llama 2 70B  | 67.3  | 87.3  | 68.9 | 44.9    | 83.7  | 56.8  | 68.2  |
| Mistral 7B   | 60.0  | 81.3  | 60.1 | 42.2    | 75.3  | 52.2  | 61.8  |
| Mixtral 8×7B | 66.4  | 86.7  | 70.6 | 46.8    | 81.2  | 74.4  | 71.0  |
| Llama 3 8B   | 79.7  | 82.0  | 66.6 | 44.0    | 73.0  | 79.6  | 70.8  |
| Llama 3 70B  | 93.0  | 92.2  | 79.5 | 52.8    | 85.3  | 93.0  | 82.6  |

Valores aproximados do Open LLM Leaderboard (2024). HSwag = HellaSwag; TruthQA = TruthfulQA; WinoG = WinoGrande.

# Benchmarks Específicos por Tarefa

---

Benchmarks gerais (MMLU, ARC...) medem conhecimento amplo, mas **não capturam** capacidades especializadas:

## Contexto longo

- **RULER**: tarefas sintéticas em janelas de 4K–128K tokens
- **NIAH**: “agulha” escondida em textos de 100K+ tokens

## Chamada de ferramentas

- **BFCL**: 2000 pares função/argumento em múltiplas linguagens
- **ToolBench**: uso de APIs reais via ReAct

## Código

- **HumanEval**: geração de código Python; métrica *pass@k*
- **SWE-bench**: resolve issues reais do GitHub

## Outros domínios

- **MT-Bench**: instrução multi-turno avaliada por GPT-4
- **MATH**: 12500 problemas de competição
- **MMMU**: multimodal (imagem + texto), 57 disciplinas

⇒ Nenhum benchmark único é suficiente: avaliação requer um portfólio de tarefas.

# Resumo da Aula

---

| Tópico                | Conceito-chave                      | Inovação / Referência | Modelo exemplo        |
|-----------------------|-------------------------------------|-----------------------|-----------------------|
| Decoder-only          | Atenção causal, sem encoder         | GPT [12]              | GPT, Llama            |
| Leis de escala        | $20N$ tokens; $N^* \propto C^{0.5}$ | Chinchilla [7]        | Llama 3               |
| Normalização          | RMSNorm + Pre-Norm                  | [2, 21]               | Llama 2/3             |
| MHA $\rightarrow$ GQA | Redução de KV-cache                 | [1]                   | Llama 2 70B           |
| Sliding Window        | Atenção local $O(nW)$               | [8]                   | Mistral 7B            |
| MoE                   | Top- $k$ routing, especialistas     | [16, 9]               | Mixtral $8 \times 7B$ |
| Decod. especulativa   | Draft + verify                      | [11]                  | Llama 3               |
| Benchmarks            | ARC, GSM8k, MMLU, HellaSwag         | [4, 5, 6]             | —                     |

# Referências I

---

- [1] Joshua Ainslie et al. “GQA: Training Generalized Multi-Query Transformer Models from Multi-Head Checkpoints”. Em: [EMNLP](#). 2023, pp. 4895–4901.
- [2] Jimmy Lei Ba, Jamie Ryan Kiros e Geoffrey E. Hinton. “Layer Normalization”. Em: [arXiv preprint arXiv:1607.06450](#) (2016).
- [3] Tom B. Brown et al. “Language Models are Few-Shot Learners”. Em: [NeurIPS](#). Vol. 33. 2020, pp. 1877–1901.
- [4] Peter Clark et al. “Think you have Solved Question Answering? Try ARC, the AI2 Reasoning Challenge”. Em: [arXiv preprint arXiv:1803.05457](#) (2018).
- [5] Karl Cobbe et al. “Training Verifiers to Solve Math Word Problems”. Em: [arXiv preprint arXiv:2110.14168](#) (2021).
- [6] Dan Hendrycks et al. “Measuring Massive Multitask Language Understanding”. Em: [ICLR](#). 2021.
- [7] Jordan Hoffmann et al. “Training Compute-Optimal Large Language Models”. Em: [NeurIPS](#). Vol. 35. 2022.
- [8] Albert Q. Jiang et al. “Mistral 7B”. Em: [arXiv preprint arXiv:2310.06825](#) (2023).
- [9] Albert Q. Jiang et al. “Mixtral of Experts”. Em: [arXiv preprint arXiv:2401.04088](#) (2024).
- [10] Jared Kaplan et al. “Scaling Laws for Neural Language Models”. Em: [arXiv preprint arXiv:2001.08361](#) (2020).
- [11] Yaniv Leviathan, Matan Kalman e Yossi Matias. “Fast Inference from Transformers via Speculative Decoding”. Em: [ICML](#). 2023, pp. 19274–19286.
- [12] Alec Radford et al. [Improving Language Understanding by Generative Pre-Training](#). Rel. técn. OpenAI, 2018. URL: <https://openai.com/blog/language-unsupervised>.
- [13] Alec Radford et al. [Language Models are Unsupervised Multitask Learners](#). Rel. técn. OpenAI, 2019. URL: <https://openai.com/blog/better-language-models>.
- [14] Noam Shazeer. “Fast Transformer Decoding: One Write-Head is All You Need”. Em: [arXiv preprint arXiv:1911.02150](#) (2019).
- [15] Noam Shazeer. “GLU Variants Improve Transformer”. Em: [arXiv preprint arXiv:2002.05202](#) (2020).
- [16] Noam Shazeer et al. “Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer”. Em: [ICLR](#). 2017.



# Referências II

---

- [17] Stanford CME295 Teaching Staff. Lecture 2: Modern LLM Architectures. Stanford CME295: Large Language Models in Practice, Fall 2025. 2025. URL: <https://cme295.stanford.edu/slides/fall25-cme295-lecture2.pdf>.
- [18] Ashish Vaswani et al. “Attention is all you need”. Em: NeurIPS. Vol. 30. 2017.
- [19] Brandon T. Willard e Rémi Louf. “Efficient Guided Generation for Large Language Models”. Em: arXiv preprint arXiv:2307.09702 (2023).
- [20] Rowan Zellers et al. “HellaSwag: Can a Machine Really Finish Your Sentence?” Em: ACL. 2019, pp. 4791–4800.
- [21] Biao Zhang e Rico Sennrich. “Root Mean Square Layer Normalization”. Em: NeurIPS. Vol. 32. 2019.