

# Deep Learning

## *Positional Encodings*

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory  
PUCRS

junho de 2026

# Visão Geral

---

## 1. Introdução e Motivação

## 2. Absolute Positional Encoding

## 3. Relative Positional Encoding

3.1 RoPE

3.2 ALiBi

3.3 NoPE

3.4 Comparação

## 4. Desafios em Contextos Longos

4.1 Perplexidade e suas Limitações em Contexto Longo

4.2 Lost in the Middle

4.3 Needle in a Haystack

## 5. Métodos de Extensão de Contexto

# Visão Geral

---

## 1. Introdução e Motivação

## 2. Absolute Positional Encoding

## 3. Relative Positional Encoding

- 3.1 RoPE
- 3.2 ALiBi
- 3.3 NoPE
- 3.4 Comparação

## 4. Desafios em Contextos Longos

- 4.1 Perplexidade e suas Limitações em Contexto Longo
- 4.2 Lost in the Middle
- 4.3 Needle in a Haystack

## 5. Métodos de Extensão de Contexto

## Por que a posição importa?

O mecanismo de *self-attention* calcula *scores* entre todos os pares:

### Score de atenção

$$\text{score}(i, j) = q_i^\top k_j / \sqrt{d}$$

O produto escalar **não depende** dos índices  $i$  ou  $j$ , apenas dos **valores** de  $q$  e  $k$ .

**Transformers são invariantes a permutação.**

Sem informação posicional:

“O gato sentou no tapete”  $\equiv$  “O tapete sentou no gato”

### O problema da permutação

| Token    | Sem PE      | Com PE                    |
|----------|-------------|---------------------------|
| “O”      | mesma repr. | pos 0 $\rightarrow$ única |
| “gato”   | mesma repr. | pos 1 $\rightarrow$ única |
| “sentou” | mesma repr. | pos 2 $\rightarrow$ única |
| “no”     | mesma repr. | pos 3 $\rightarrow$ única |
| “tapete” | mesma repr. | pos 4 $\rightarrow$ única |

# Taxonomia de *Positional Encodings*

---

## Absolute PE

- Vetor único por posição absoluta
- Sinusoidal (Vaswani et al., 2017)
- *Learned embeddings* (BERT, GPT)
- Somado ao *token embedding*

## Relative PE

- Codifica distância  $i - j$
- RoPE: rotação no espaço
- ALiBi: *bias* linear
- NoPE: máscara causal


## Extensão de Contexto

- *Fine-tune* para  $L > L_{\text{train}}$
- *Position Interpolation*
- YaRN
- LongRoPE

# Comprimento de Contexto e o Custo Quadrático

A atenção computa **todos os  $L \times L$  pares**  
→ memória e computação escalam como  $O(L^2)$ .

- Dobrar  $L \rightarrow 4\times$  mais memória para a matriz de atenção
- Um contexto de 100K *tokens* em um modelo 7B requer 80 GB+ só de atenção (em *fp16*)
- Maioria dos modelos treina com  $L = 2K-8K$  *tokens*
- Contextos longos desaceleram cada *forward pass* quadraticamente



*Ilustrativo, memória de atenção escala como  $O(L^2)$*

# Por que Extrapolação Importa: O Argumento Econômico

---


- O custo de treinamento é dominado pela atenção quadrática
  - Treinar com  $L = 2K$  custa  $4\times$  menos que  $L = 4K$
  - Treinar com  $L = 8K$  custa  $16\times$  menos que  $L = 32K$
- Se o PE puder extrapolar para sequências mais longas:
  - Treinamento mais leve com  $L$  pequeno, inferência com  $L$  maior sem perda de desempenho
  - Sem necessidade de *fine-tuning* de contexto longo
- **Problema: a maioria dos PEs absolutos NÃO extrapola bem**
  - Esta aula: por que falham e como PEs relativos / extensão de contexto corrigem isso

# O Desafio da Extrapolação

Um modelo treinado com  $L_{\text{train}} = 2\text{K}$  encontra índices de posição **nunca vistos** quando

$L_{\text{test}} > L_{\text{train}}$ .

Perplexidade dispara além do horizonte de treino:



## Como resolver:

- PE que codifique apenas distância relativa → Parte 2
- Reescalar/interpolar posições em tempo de teste → Parte 4
- Sem PE: deixar o modelo inferir → NoPE

*Ilustrativo, comportamento típico além do horizonte de treino*



# Notação e Configuração

| Símbolo    | Significado                                                |
|------------|------------------------------------------------------------|
| $d$        | Dimensão do <i>embedding</i> ( $d_{\text{model}}$ )        |
| $L$        | Comprimento da sequência                                   |
| $i$        | Posição do <i>token query</i> ( $0 \leq i < L$ )           |
| $j$        | Posição do <i>token key</i> ( $0 \leq j < L$ )             |
| $k$        | Índice de dimensão ( $0 \leq k < d/2$ )                    |
| $x_i$      | <i>Embedding</i> de entrada do <i>token</i> na posição $i$ |
| $q_i, k_j$ | Vetores <i>query</i> e <i>key</i> nas posições $i, j$      |
| $PE(i)$    | Vetor de <i>positional encoding</i> para posição $i$       |

## PE Absoluto

$x_i \leftarrow x_i + PE(i)$  (somado ao *embedding* antes da atenção)

# Visão Geral

---

## 1. Introdução e Motivação

## 2. Absolute Positional Encoding

## 3. Relative Positional Encoding

- 3.1 RoPE
- 3.2 ALiBi
- 3.3 NoPE
- 3.4 Comparação

## 4. Desafios em Contextos Longos

- 4.1 Perplexidade e suas Limitações em Contexto Longo
- 4.2 Lost in the Middle
- 4.3 Needle in a Haystack

## 5. Métodos de Extensão de Contexto

## Referência

Vaswani, A. et al. “Attention Is All You Need.” NeurIPS 2017.<sup>a</sup>

---

<sup>a</sup>Ashish Vaswani et al. “Attention is all you need”. Em: [NeurIPS](#). vol. 30. 2017.

- Introduziu a arquitetura *Transformer* (*encoder–decoder*)
- Propôs funções sinusoidais determinísticas como *positional encodings*
- Propriedade: nenhum parâmetro aprendido → custo extra zero no treino
- Em princípio, pode generalizar para comprimentos não vistos no treino
- Tornou-se o PE padrão para a maioria das variantes iniciais do *Transformer*

## PE Sinusoidal: Fórmula

Para posição  $i$  e índice de dimensão  $k$  ( $d$  = dimensão total do *embedding*):

### Fórmula do *Positional Encoding* Sinusoidal

$$\text{PE}(i, 2k) = \sin\left(\frac{i}{10000^{2k/d}}\right)$$

$$\text{PE}(i, 2k+1) = \cos\left(\frac{i}{10000^{2k/d}}\right)$$

- Dimensão  $2k$  usa **seno**; dimensão  $2k+1$  usa **coseno**, mesma frequência, defasagem de  $90^\circ$
- Base 10000 cria frequências de muito altas (dim 0) a muito baixas (dim  $d-1$ )

### Abreviação

$$\omega_k = 10000^{-2k/d} \Rightarrow \text{PE}(i, 2k) = \sin(i \cdot \omega_k), \quad \text{PE}(i, 2k+1) = \cos(i \cdot \omega_k)$$

# PE Sinusoidal: Intuição

---

## Analogia com contagem binária:

| pos | bit 2 (lento) | bit 1 (médio) | bit 0 (rápido) |
|-----|---------------|---------------|----------------|
| 0   | 0             | 0             | 0              |
| 1   | 0             | 0             | 1              |
| 2   | 0             | 1             | 0              |
| 3   | 0             | 1             | 1              |
| 4   | 1             | 0             | 0              |
| 5   | 1             | 0             | 1              |

→ PE sinusoidal é o análogo contínuo.

Cada dimensão = um “*canal de frequência*”


Low- $k$ : oscilação rápida → posição fina

High- $k$ : oscilação lenta → posição grosseira

**Nomenclatura:** low- $k$  = índice  $k$  pequeno = alta frequência; high- $k$  = índice  $k$  grande = baixa frequência.

$PE(i + \delta)$  pode ser expresso como função linear de  $PE(i)$ , permitindo ao modelo aprender *offsets* relativos a partir de PEs absolutos.

## PE Sinusoidal: Visualizando as Frequências ( $d = 16$ )



Cada  $k$  é um “relógio” em velocidade diferente: combinando frequências, cada posição tem uma assinatura única (análogo contínuo da contagem binária). **A seguir:** frase “O gato sentou no tapete” ( $L=5$ ,  $d=4$ ).

## PE Sinusoidal: Matriz para “O gato sentou no tapete”

---

Matriz PE completa para a frase exemplo ( $L = 5$ ,  $d = 4$ ):

| $i$ (token)  | dim 0  | dim 1  | dim 2 | dim 3 |
|--------------|--------|--------|-------|-------|
| 0 (“O”)      | 0.000  | 1.000  | 0.000 | 1.000 |
| 1 (“gato”)   | 0.841  | 0.540  | 0.010 | 1.000 |
| 2 (“sentou”) | 0.909  | -0.416 | 0.020 | 1.000 |
| 3 (“no”)     | 0.141  | -0.990 | 0.030 | 1.000 |
| 4 (“tapete”) | -0.757 | -0.654 | 0.040 | 0.999 |

Dimensões 0–1 ( $\omega_0=1$ ) variam rapidamente com  $i$ ; dimensões 2–3 ( $\omega_1=0.01$ ) quase não mudam nessa faixa.

Os próximos slides mostram passo a passo de onde vêm esses números.

# Cálculo Manual, PE Sinusoidal, Passo 1: Configuração

---

**Frase:** “O gato sentou no tapete”  $\rightarrow L = 5$ , posições  $i \in \{0, 1, 2, 3, 4\}$ ,  $d = 4$   
Calcular as frequências angulares  $\omega_k = 10000^{-2k/d}$ :

| $k$ | $2k/d$      | Expoente            | $\omega_k$          | Período $2\pi/\omega_k$ |
|-----|-------------|---------------------|---------------------|-------------------------|
| 0   | $0/4 = 0.0$ | $10000^0 = 1$       | $\omega_0 = 1.0000$ | $\approx 6.28$          |
| 1   | $2/4 = 0.5$ | $10000^{0.5} = 100$ | $\omega_1 = 0.0100$ | $\approx 628$           |

Com  $d = 4$  temos 2 pares de frequência ( $k = 0, 1$ ).

$k=0$ : oscilação rápida (período  $\approx 6$  tokens) |  $k=1$ : muito lenta (período  $\approx 628$  tokens).



## Cálculo Manual, PE Sinusoidal, Passo 2: Preencher a Tabela

Aplicar  $PE(i, 2k) = \sin(i \cdot \omega_k)$  e  $PE(i, 2k+1) = \cos(i \cdot \omega_k)$  aos 5 tokens:

| $i$ (token)  | dim 0 | $\sin(i \cdot \omega_0)$ | dim 1 | $\cos(i \cdot \omega_0)$ | dim 2 | $\sin(i \cdot \omega_1)$ | dim 3 | $\cos(i \cdot \omega_1)$ |
|--------------|-------|--------------------------|-------|--------------------------|-------|--------------------------|-------|--------------------------|
| 0 (“O”)      |       | $\sin(0) = 0.000$        |       | $\cos(0) = 1.000$        |       | $\sin(0) = 0.000$        |       | $\cos(0) = 1.000$        |
| 1 (“gato”)   |       | $\sin(1) = 0.841$        |       | $\cos(1) = 0.540$        |       | $\sin(0.01) = 0.010$     |       | $\cos(0.01) = 1.000$     |
| 2 (“sentou”) |       | $\sin(2) = 0.909$        |       | $\cos(2) = -0.416$       |       | $\sin(0.02) = 0.020$     |       | $\cos(0.02) = 1.000$     |
| 3 (“no”)     |       | $\sin(3) = 0.141$        |       | $\cos(3) = -0.990$       |       | $\sin(0.03) = 0.030$     |       | $\cos(0.03) = 1.000$     |
| 4 (“tapete”) |       | $\sin(4) = -0.757$       |       | $\cos(4) = -0.654$       |       | $\sin(0.04) = 0.040$     |       | $\cos(0.04) = 0.999$     |

Os valores reproduzem exatamente a matriz prevista no slide anterior. As dimensões 2 e 3 quase não mudam: o modelo usa essas dimensões para codificar posição **grosseira** (milhares de passos).

## Cálculo Manual, Passo 3: Somar PE ao *Embedding*

Token embeddings de “O gato sentou no tapete”:

| $i$ (token)  | $x[0]$ | $x[1]$ | $x[2]$ | $x[3]$ |
|--------------|--------|--------|--------|--------|
| 0 (“O”)      | 0.500  | -0.200 | 0.100  | 0.800  |
| 1 (“gato”)   | 0.300  | 0.600  | -0.400 | 0.200  |
| 2 (“sentou”) | -0.100 | 0.400  | 0.700  | -0.300 |
| 3 (“no”)     | 0.600  | -0.500 | 0.200  | 0.100  |
| 4 (“tapete”) | -0.200 | 0.300  | -0.600 | 0.500  |

Após somar o PE sinusoidal:

| $i$ | $x[0] + \text{PE}[0]$     | $x[1] + \text{PE}[1]$     | $x[2] + \text{PE}[2]$     | $x[3] + \text{PE}[3]$    |
|-----|---------------------------|---------------------------|---------------------------|--------------------------|
| 0   | $0.500 + 0.000 = 0.500$   | $-0.200 + 1.000 = 0.800$  | $0.100 + 0.000 = 0.100$   | $0.800 + 1.000 = 1.800$  |
| 1   | $0.300 + 0.841 = 1.141$   | $0.600 + 0.540 = 1.140$   | $-0.400 + 0.010 = -0.390$ | $0.200 + 1.000 = 1.200$  |
| 2   | $-0.100 + 0.909 = 0.809$  | $0.400 - 0.416 = -0.016$  | $0.700 + 0.020 = 0.720$   | $-0.300 + 1.000 = 0.700$ |
| 3   | $0.600 + 0.141 = 0.741$   | $-0.500 - 0.990 = -1.490$ | $0.200 + 0.030 = 0.230$   | $0.100 + 1.000 = 1.100$  |
| 4   | $-0.200 - 0.757 = -0.957$ | $0.300 - 0.654 = -0.354$  | $-0.600 + 0.040 = -0.560$ | $0.500 + 0.999 = 1.499$  |

✓ A mesma rede processa os 5 *tokens*; a posição fica codificada nos valores.

## PE Sinusoidal: Propriedades

---

- **Determinístico:** nenhum parâmetro aprendido, idêntico entre execuções
- **Limitado:** todos os valores em  $[-1, 1]$ , estável com normalização
- **Único por posição:** cada  $i$  gera um vetor PE distinto
- **Offsets relativos são lineares:**  $PE(i + \delta) = M(\delta) \cdot PE(i)$  para uma matriz fixa  $M$ 
  - Permite ao modelo aprender distância relativa a partir de PE absoluto
- **Teoricamente generalizável:** posições além do treino existem na mesma curva
  - Na prática, a generalização é limitada → ver próximo slide

## Learned Absolute PE

---

- **BERT, GPT iniciais:** PE é uma matriz de *embeddings* treinável  $E \in \mathbb{R}^{L_{\max} \times d}$
- Consulta por posição:  $PE(i) = E[i, :]$
- **Vantagens:** adapta-se à distribuição dos dados; sem frequências manuais
- **Desvantagens:**
  - Limite rígido em  $L_{\max}$ : posições além simplesmente não existem
  - *Overfits* ao comprimento de treino; pior OOD que sinusoidal
  - Adiciona  $L_{\max} \times d$  parâmetros ao modelo
- **Modelos modernos migraram para PE relativo (RoPE, ALiBi) →**

# Limitação do PE Absoluto

---

- O modelo vê posições absolutas durante o treino:  $i = 0, 1, \dots, L_{\text{train}} - 1$
- **Posições  $i \geq L_{\text{train}}$  são out-of-distribution:** nunca vistas no treino
- As frequências sinusoidais não extrapolam os padrões de atenção de forma confiável
- *Learned absolute PE (BERT) é ainda pior, sem forma fechada para novas posições*
- **Problema central: posição codificada independentemente do contexto**
  - “gato” na posição 0 e na posição 100 recebem vetores PE diferentes, mesmo que a relação semântica seja a mesma
- **Isso motiva os *positional encodings* relativos →**

# De Absoluto para Relativo

---

## O problema fundamental do PE absoluto:

Dois *tokens* “gato” à distância 2 de “sentou” deveriam ter o mesmo *score* de atenção, independentemente de estarem nas posições (0, 2) ou (1000, 1002).

## PE relativo codifica $i - j$ diretamente:

- O *score* de atenção depende apenas do *offset* relativo  $i - j$ , não de  $i$  ou  $j$  individualmente
- Modelos treinados com comprimento  $L$  podem generalizar para qualquer comprimento
- Três estratégias: **RoPE** (rotação), **ALiBi** (*bias* aditivo), **NoPE** (implícito)

# Visão Geral

---

## 1. Introdução e Motivação

## 2. Absolute Positional Encoding

## 3. Relative Positional Encoding

- 3.1 RoPE
- 3.2 ALiBi
- 3.3 NoPE
- 3.4 Comparação

## 4. Desafios em Contextos Longos

- 4.1 Perplexidade e suas Limitações em Contexto Longo
- 4.2 Lost in the Middle
- 4.3 Needle in a Haystack

## 5. Métodos de Extensão de Contexto

# Ideia Central: *Positional Encodings* Relativos

---

**Objetivo:** fazer o *score* de atenção depender apenas de  $(i - j)$ .

## Formulação

$\text{score}(i, j) = f(q_i, k_j, i-j)$  onde  $f$  depende de  $(i-j)$ , não de  $i$  ou  $j$  separadamente

Três estratégias:

- **RoPE**: rotacionar  $q$  e  $k$  por ângulo dependente da posição; produto escalar codifica  $i-j$
- **ALiBi**: somar penalidade linear  $-m \cdot |i-j|$  aos *logits* de atenção
- **NoPE**: sem PE; posição implícita via máscara causal

Todas alcançam generalização de comprimento em graus variados.



## Referência

Su, J. et al. “RoFormer: Enhanced Transformer with Rotary Position Embedding.” *Neurocomputing* 2024.<sup>a</sup>

---

<sup>a</sup>Jianlin Su et al. “RoFormer: Enhanced transformer with rotary position embedding”. Em: [Neurocomputing](#) 568 (2024), p. 127063.

- Codificar posição **rotacionando** os vetores *query* e *key*
- Rotação é operação linear, compatível com qualquer arquitetura *Transformer*
- O produto interno  $q_i^\top k_j$  depende apenas de  $(i - j)$  após a rotação ✓
- Adotado por LLaMA, Mistral, Falcon, Gemma e maioria dos LLMs *open-source*
- Base para métodos de extensão de contexto (YaRN, LongRoPE, etc.)

# RoPE: Ideia Central

Em vez de somar PE ao *embedding*, **rotacionar Q e K**:

## Rotação e Score

$$\tilde{q}_i = R_\theta(i) \cdot q_i \quad \tilde{k}_j = R_\theta(j) \cdot k_j$$

$$\text{score}(i, j) = \tilde{q}_i^\top \tilde{k}_j = q_i^\top R_\theta(i)^\top R_\theta(j) k_j = q_i^\top R_\theta(j-i) k_j$$

Como matrizes de rotação satisfazem  $R_\theta(i)^\top = R_\theta(-i)$  (rotação no sentido oposto), temos  $R_\theta(i)^\top R_\theta(j) = R_\theta(-i) R_\theta(j) = R_\theta(j-i)$ , **o score depende apenas do offset relativo  $j - i$ .**

- $R_\theta(m)$  é uma matriz de rotação bloco-diagonal parametrizada pela posição  $m$
- Cada bloco 2D rotaciona um par de dimensões por ângulo  $m \cdot \theta_k$
- **PE NÃO é somado à entrada, é aplicado dentro do *attention head***

## RoPE: O Bloco de Rotação 2D

Para um par de dimensões  $(q_0, q_1)$  na posição  $i$ :

### Matriz de rotação 2D

$$R_{\theta}(i) = \begin{pmatrix} \cos(i\theta) & -\sin(i\theta) \\ \sin(i\theta) & \cos(i\theta) \end{pmatrix}$$

Par rotacionado:  $[\cos(i\theta) q_0 - \sin(i\theta) q_1, \sin(i\theta) q_0 + \cos(i\theta) q_1]$

A mesma rotação é aplicada ao par correspondente de *key*, no ângulo  $j \cdot \theta$ .

**O produto escalar equivale a uma rotação por  $(j-i) \cdot \theta$ , depende só do *offset*.**

### Expansão

Somando os dois produtos componente a componente, os termos cruzados de sin/cos recombina-se em  $\cos((j-i)\theta)$  e  $\sin((j-i)\theta) \rightarrow$  depende apenas de  $(j-i)$ . *Derivação completa no próximo slide.*

## RoPE: Fórmula Completa ( $d$ Dimensões)

Para  $d$  dimensões, aplicar  $d/2$  blocos de rotação independentes:


### Frequências e rotação bloco-diagonal

$$\theta_k = 10000^{-2k/d} \quad k = 0, 1, \dots, d/2-1$$

$$R_\theta(i) = \text{block-diag}(R(i\theta_0), R(i\theta_1), \dots, R(i\theta_{d/2-1}))$$

- Mesma base 10000 do PE sinusoidal: frequências cobrem muitas ordens de magnitude
- *Low-k* ( $\theta_k \approx 1$ ): rotação rápida  $\rightarrow$  posição relativa fina
- *High-k* ( $\theta_k \approx 0$ ): rotação lenta  $\rightarrow$  posição relativa grosseira
- Eficiente: tabelas cos/sin pré-computadas; fundido com projeção Q·K

# RoPE: Espectro de Frequências



Cobertura de  $\sim 4$  ordens de magnitude em frequência. **Diversidade espectral é a base do sucesso do RoPE**: cada bloco 2D rotaciona numa velocidade diferente, permitindo codificar posições relativas finas e grosseiras simultaneamente.

# RoPE, Por que Funciona: Esboço de Prova

**Afirmção:**  $\tilde{q}_i^\top \tilde{k}_j$  depende apenas de  $(i - j)$ .

Foco em um bloco 2D com frequência  $\theta$ :

## Derivação

$$\tilde{q}_i = (\cos(i\theta) q_0 - \sin(i\theta) q_1, \sin(i\theta) q_0 + \cos(i\theta) q_1)$$

$$\tilde{k}_j = (\cos(j\theta) k_0 - \sin(j\theta) k_1, \sin(j\theta) k_0 + \cos(j\theta) k_1)$$

$$\tilde{q}_i \cdot \tilde{k}_j = (q_0 k_0 + q_1 k_1) \cos((j-i)\theta) + (q_1 k_0 - q_0 k_1) \sin((j-i)\theta)$$

$\rightarrow$  depende apenas de  $j - i$  ✓

- Cada bloco contribui um par  $(\cos, \sin)$  que depende de  $(j - i)$
- **Somando  $d/2$  blocos: score total é função de  $(q, k, j-i)$**

# Cálculo Manual, RoPE, Passo 1: Configuração

---

**Parâmetros:**  $d = 4$ ,  $\theta_0 = 1.0$ ,  $\theta_1 = 0.01$

Query em  $i = 1$ :  $q = [1, 0, 1, 0]$       Key em  $j = 3$ :  $k = [0, 1, 0, 1]$

Ângulos de rotação:

| Bloco | $\theta_k$ | Ângulo $i=1$ (query)         | Ângulo $j=3$ (key)           |
|-------|------------|------------------------------|------------------------------|
| $k=0$ | 1.0000     | $1 \times 1.00 = 1.0000$ rad | $3 \times 1.00 = 3.0000$ rad |
| $k=1$ | 0.0100     | $1 \times 0.01 = 0.0100$ rad | $3 \times 0.01 = 0.0300$ rad |

Valores trigonométricos:

| ângulo | cos    | sin   |
|--------|--------|-------|
| 1.0000 | 0.540  | 0.841 |
| 3.0000 | -0.990 | 0.141 |
| 0.0100 | 1.000  | 0.010 |
| 0.0300 | 1.000  | 0.030 |

## Cálculo Manual, RoPE, Passo 2: Aplicar Rotações

**Rotacionar**  $q = [1, 0, 1, 0]$  **em**  $i = 1$ :

| Bloco | Entrada  | Ângulo   | Fórmula                                                    | Resultado        |
|-------|----------|----------|------------------------------------------------------------|------------------|
| $k=0$ | $(1, 0)$ | 1.00 rad | $\cos \cdot 1 - \sin \cdot 0, \sin \cdot 1 + \cos \cdot 0$ | $(0.540, 0.841)$ |
| $k=1$ | $(1, 0)$ | 0.01 rad | $\cos \cdot 1 - \sin \cdot 0, \sin \cdot 1 + \cos \cdot 0$ | $(1.000, 0.010)$ |

→  $\tilde{q}(i=1) = [0.540, 0.841, 1.000, 0.010]$

**Rotacionar**  $k = [0, 1, 0, 1]$  **em**  $j = 3$ :


| Bloco | Entrada  | Ângulo   | Fórmula                                                    | Resultado          |
|-------|----------|----------|------------------------------------------------------------|--------------------|
| $k=0$ | $(0, 1)$ | 3.00 rad | $\cos \cdot 0 - \sin \cdot 1, \sin \cdot 0 + \cos \cdot 1$ | $(-0.141, -0.990)$ |
| $k=1$ | $(0, 1)$ | 0.03 rad | $\cos \cdot 0 - \sin \cdot 1, \sin \cdot 0 + \cos \cdot 1$ | $(-0.030, 1.000)$  |

→  $\tilde{k}(j=3) = [-0.141, -0.990, -0.030, 1.000]$



# RoPE: Visualizando a Rotação 2D

Bloco  $k=0$ : rotacionar  $q = (1, 0)$  por  $i \cdot \theta_0 = 1.0$  rad



Bloco  $k=0$ : *query* em  $i = 1$

Multiplicação matricial

$$\begin{pmatrix} \cos 1.0 & -\sin 1.0 \\ \sin 1.0 & \cos 1.0 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.540 \\ 0.841 \end{pmatrix}$$

- O vetor é rotacionado  $57.3^\circ$  no sentido anti-horário
- **Rotação preserva a magnitude:**  
 $|q| = |\tilde{q}| = 1 \checkmark$
- Posição codificada como ângulo de rotação, sem vetor aditivo
- $\tilde{q}_i^\top \tilde{k}_j$  depende só de  $(j-i) \cdot \theta_0$

## Cálculo Manual, RoPE, Passo 3: Produto Escalar e Verificação

$$\text{score}(i=1, j=3) = \tilde{q}(1) \cdot \tilde{k}(3):$$

### Cálculo

$$= 0.540 \cdot (-0.141) + 0.841 \cdot (-0.990) + 1.000 \cdot (-0.030) + 0.010 \cdot 1.000 = -0.929$$

**Verificação: depende apenas de  $(j - i) = 2$ ?**

Rotacionar o mesmo  $q$  em  $i = 0$  e o mesmo  $k$  em  $j = 2$  (*offset* relativo = 2):

$$\tilde{q}(0) = [1, 0, 1, 0] \quad (\text{rotação por } 0: \text{identidade})$$

$$\tilde{k}(2): \text{bloco } 0 \rightarrow (-0.909, -0.416); \quad \text{bloco } 1 \rightarrow (-0.020, 1.000)$$

$$\tilde{k}(2) = [-0.909, -0.416, -0.020, 1.000]$$

### Verificação

$$\text{score} = 1 \cdot (-0.909) + 0 \cdot (-0.416) + 1 \cdot (-0.020) + 0 \cdot 1.000 = -0.929 \quad \checkmark \text{ Mesmo score!}$$

## Referência

Press, O. et al. “Train Short, Test Long: Attention with Linear Biases Enables Input Length Extrapolation.” ICLR 2022.<sup>a</sup>

---

<sup>a</sup>Ofir Press, Noah A Smith e Mike Lewis. “Train short, test long: Attention with linear biases enables input length extrapolation”. Em: [ICLR](#). 2022.

- Nenhuma modificação nos *embeddings*: zero vetores posicionais adicionados
- Em vez disso: subtrair uma penalidade linear dos *logits* de atenção
- Penalidade proporcional a  $|i - j|$ : *tokens* distantes recebem penalidade maior
- Cada *head*  $h$  tem uma inclinação diferente  $m_h \rightarrow$  espectro de atenção local a global
- **Extrapolação zero-shot: treinado em  $L = 1K$ , funciona em  $L = 8K$**

## ALiBi: Ideia Central

---

Atenção padrão (*pre-softmax*):

$$A(i, j) = q_i^\top k_j / \sqrt{d}$$

Atenção ALiBi (*pre-softmax*):

$$A_h(i, j) = q_i^\top k_j / \sqrt{d} - m_h \cdot |i - j|$$

A penalidade  $m_h \cdot |i-j|$  cresce com a distância, *tokens* distantes são ponderados para baixo.

Diferentes *heads*  $h$  têm inclinações  $m_h$  diferentes  $\rightarrow$  espectro de atenção local a global.

- **Sem vetores de posição, custo de PE é zero**
- Em sequências longas de teste, o modelo simplesmente aplica penalidades maiores, permanece *in-distribution*

## ALiBi: Inclinações por *Head*


As inclinações formam uma sequência geométrica sobre os  $n$  *attention heads*:

$$m_h = 2^{-8h/n} \quad h = 1, 2, \dots, n$$

| $n$ heads | $h=1$ (mais íngreme) | $h=2$             | $h=3$             | $h=4$ (mais plano) |
|-----------|----------------------|-------------------|-------------------|--------------------|
| 4         | $2^{-2} = 0.2500$    | $2^{-4} = 0.0625$ | $2^{-6} = 0.0156$ | $2^{-8} = 0.0039$  |
| 8         | $2^{-1} = 0.5000$    | $2^{-2} = 0.2500$ | $2^{-3} = 0.1250$ | $2^{-4} = 0.0625$  |

- Inclinações íngremes ( $m$  grande)  $\rightarrow$  *head* atende principalmente localmente
- Inclinações planas ( $m$  pequeno)  $\rightarrow$  *head* atende a longas distâncias
- Juntos, os *heads* cobrem amplo espectro de raios de atenção
- Inclinações são hiperparâmetros fixos, não aprendidos

# ALiBi: Curvas de Decaimento por *Head*



Inclinações íngremes  $\rightarrow$  *head* atende principalmente localmente. Inclinações planas  $\rightarrow$  *head* mantém atenção em distâncias longas.

Juntos, os  $n$  *heads* cobrem todo o espectro de raios de atenção, do local ao global.

# Cálculo Manual, ALiBi, Passo 1: Configuração e Inclinações

---

**Parâmetros:**  $n_{\text{heads}} = 4$ ,  $\text{seq\_len} = 4$  (posições  $i, j \in \{0, 1, 2, 3\}$ )

Calcular inclinações (foco nos *heads* 1 e 2):

| Head $h$ | Fórmula $2^{-8h/n}$         | Valor          |
|----------|-----------------------------|----------------|
| 1        | $2^{-8 \cdot 1/4} = 2^{-2}$ | $m_1 = 0.2500$ |
| 2        | $2^{-8 \cdot 2/4} = 2^{-4}$ | $m_2 = 0.0625$ |
| 3        | $2^{-8 \cdot 3/4} = 2^{-6}$ | $m_3 = 0.0156$ |
| 4        | $2^{-8 \cdot 4/4} = 2^{-8}$ | $m_4 = 0.0039$ |

## Cálculo Manual, ALiBi, Passo 2: Matrizes de *Bias*

---

Matriz  $|i - j|$  crua (causal: triângulo superior mascarado):

| $i \backslash j$ | $j=0$ | $j=1$     | $j=2$     | $j=3$     |
|------------------|-------|-----------|-----------|-----------|
| $i=0$            | 0     | $-\infty$ | $-\infty$ | $-\infty$ |
| $i=1$            | 1     | 0         | $-\infty$ | $-\infty$ |
| $i=2$            | 2     | 1         | 0         | $-\infty$ |
| $i=3$            | 3     | 2         | 1         | 0         |

$\times m_1 = 0.25 \rightarrow$  *Bias* do head 1:

| $i \backslash j$ | $j=0$ | $j=1$     | $j=2$     | $j=3$     |
|------------------|-------|-----------|-----------|-----------|
| $i=0$            | 0     | $-\infty$ | $-\infty$ | $-\infty$ |
| $i=1$            | -0.25 | 0         | $-\infty$ | $-\infty$ |
| $i=2$            | -0.50 | -0.25     | 0         | $-\infty$ |
| $i=3$            | -0.75 | -0.50     | -0.25     | 0         |

Posições próximas ( $|i - j|$  pequeno) recebem penalidade menor que posições distantes. *Head 2* ( $m = 0.0625$ ) teria penalidades  $4\times$  menores  $\rightarrow$  raio de atenção efetivo mais longo.



## Cálculo Manual, ALiBi, Passo 3: Aplicar *Bias* e *Softmax*

Logits brutos para linha  $i=2$ :  $[2.0, 1.5, 3.0, -]$

| Head                 | Scores brutos     | Bias ALiBi            | Após bias           | softmax $\approx$    |
|----------------------|-------------------|-----------------------|---------------------|----------------------|
| $h_1$ ( $m=0.25$ )   | $[2.0, 1.5, 3.0]$ | $[-0.50, -0.25, 0]$   | $[1.50, 1.25, 3.0]$ | $[0.16, 0.13, 0.71]$ |
| $h_2$ ( $m=0.0625$ ) | $[2.0, 1.5, 3.0]$ | $[-0.125, -0.063, 0]$ | $[1.88, 1.44, 3.0]$ | $[0.21, 0.14, 0.65]$ |

Head 1 (inclinação maior): mais peso na posição  $j=2$  (o *token* imediatamente anterior).

Head 2 (inclinação menor): distribui atenção mais amplamente entre  $j \in \{0, 1, 2\}$ .

**Em tempo de teste com  $L > L_{\text{train}}$ , o *bias* simplesmente fica maior para distâncias maiores  $\rightarrow$  nenhum problema de OOD.**

# ALiBi: Propriedades

---

- Zero custo no *embedding*: nenhum vetor adicionado à entrada
- **Extrapolação zero-shot: treinado em  $L=1K$ , funciona em  $L=8K$  sem *fine-tuning***
- Modificação simples: apenas 1–2 linhas de código na atenção
- Diferentes *heads* atendem a diferentes faixas automaticamente
- **Ressalva: decaimento linear pode não ser adequado para todas as tarefas**
- **Inclinações são fixas, não aprendidas por tarefa**
- Não é trivialmente compatível com extensão de contexto baseada em RoPE

# NoPE: Artigo

---

## Referência

Kazemnejad, A. et al. “The Impact of Positional Encoding on Length Generalization in Transformers.” NeurIPS 2023.<sup>a</sup>

<sup>a</sup>Amirhossein Kazemnejad et al. “The impact of positional encoding on length generalization in transformers”. Em: [NeurIPS](#). vol. 36. 2023.

- Estudo sistemático: comparar sinusoidal, RoPE, ALiBi e **nenhum PE**
- **Achado surpreendente: modelos sem PE generalizam para sequências mais longas**
- A máscara causal de atenção codifica implicitamente a ordem dos *tokens*
- NoPE superou todos os PEs explícitos testados em *benchmarks* de generalização
- **Ressalvas: resultados dependem fortemente do tipo de tarefa e tamanho do modelo**

# NoPE: Ideia Central

---

**Não usar nenhum *positional encoding*. Deixar a máscara causal fazer o trabalho.**

- Em um *decoder* autorregressivo, a máscara de atenção é estritamente triangular inferior
- *Token* na posição  $i$  só pode atender a posições  $j \leq i$
- **O padrão de quais *tokens* podem ser atendidos é, em si, informação posicional**
- Cada camada vê um “horizonte de histórico” diferente
- O modelo aprende a explorar esse sinal de ordenação implicitamente
- Como a máscara muda suavemente com o comprimento, sequências mais longas não são OOD

# NoPE: Por que Remover PE Ajuda na Generalização de Comprimento

---

- **PE absoluto: posições  $> L_{\text{train}}$  são *out-of-distribution***
- PE relativo (RoPE): frequências calibradas para o comprimento de treino, pode degradar
- **NoPE: nenhum sinal posicional adicionado  $\rightarrow$  nada se torna OOD em comprimentos maiores**
- O único *inductive bias* posicional é o padrão da máscara, que escala naturalmente
- **Ressalva: o modelo precisa inferir posição puramente a partir do contexto**
  - Funciona bem para tarefas de linguagem com pistas contextuais ricas
  - Falha em tarefas que exigem posição absoluta (indexação, aritmética)

## NoPE: Limitações

---

- **Depende de máscara causal, não se aplica a modelos *encoder-only* (BERT)**
- **Não lida com tarefas que exigem posição absoluta**
- Convergência mais lenta, o modelo precisa aprender padrões posicionais apenas dos dados
- Empiricamente pior que RoPE em alguns *benchmarks* de contexto longo (SCROLLS, LongBench)
- Métodos de extensão de contexto para RoPE não se aplicam diretamente
- **NoPE é um *baseline* útil e forte generalizador, ainda não é o padrão para grandes LLMs**

# NoPE, Discussão: Máscara Causal como PE Implícito


Máscara causal para  $\text{seq\_len} = 4$ :

| $i \backslash j$ | $j=0$ | $j=1$ | $j=2$ | $j=3$ |
|------------------|-------|-------|-------|-------|
| $i=0$            | 1     | —     | —     | —     |
| $i=1$            | 1     | 1     | —     | —     |
| $i=2$            | 1     | 1     | 1     | —     |
| $i=3$            | 1     | 1     | 1     | 1     |


- Cada linha tem padrão de máscara único
- **Softmax normaliza sobre  $i+1$  tokens visíveis:** a magnitude média do peso de atenção escala como  $\bar{\alpha}_{ij} \approx \frac{1}{i+1} \rightarrow 0$   
próprio valor do peso codifica  $i$
- $i=0$  vê apenas ele mesmo;  $i=3$  vê todos os 4
- Esse padrão muda previsivelmente com  $L \rightarrow$  generaliza para  $L > L_{\text{train}}$
- Cada camada empilha esse sinal, modelos profundos ganham representação posicional implícita rica

# NoPE: Padrão Causal Escalando com $L$


---



$L = 4$



$L = 8$



$L = 16$

- O padrão triangular é **auto-similar**: escala continuamente com  $L$
- **Nenhuma quebra de distribuição em  $L > L_{\text{train}}$  → por isso NoPE generaliza**
- Cada linha  $i$  permanece única (vê exatamente  $i+1$  posições passadas), independente de  $L$



## Comparação: Todos os Métodos de PE

| Método              | Aprendido? | Modifica...              | Extrapolação             | Custo                   |
|---------------------|------------|--------------------------|--------------------------|-------------------------|
| Sinusoidal          | Não        | <i>Input embedding</i>   | Pobre (OOD)              | Nenhum                  |
| <i>Learned Abs.</i> | Sim        | <i>Input embedding</i>   | Falha (sem novos pos.)   | $L \times d$ parâmetros |
| RoPE                | Não        | Rotações Q, K            | Moderada                 | Tabela cos/sin          |
| ALiBi               | Não        | <i>Logits</i> de atenção | Boa ( <i>zero-shot</i> ) | Desprezível             |
| NoPE                | Não        | Nada                     | Boa (apenas máscara)     | Nenhum                  |

**RoPE** é o padrão *de facto* para grandes LLMs (equilíbrio entre qualidade e extensibilidade).

**ALiBi** oferece a melhor extrapolação *zero-shot*.

**NoPE** é um *baseline* forte para generalização de comprimento.


## Padrões de Peso de Atenção por Método

Como cada método modela a atenção em função da distância  $|i - j|$ :

| Método     | Fórmula do score                                   | Efeito em $ i-j $ grande                    |
|------------|----------------------------------------------------|---------------------------------------------|
| Sinusoidal | $q_i^\top k_j / \sqrt{d}$ ( <i>rotated embed</i> ) | Imprevisível (absoluto)                     |
| RoPE       | $f(q_i, k_j, i-j)$ via rotação                     | Decaimento suave (dependente de freq.)      |
| ALiBi      | $q_i^\top k_j / \sqrt{d} - m \cdot  i-j $          | Decaimento linear garantido por <i>head</i> |
| NoPE       | $q_i^\top k_j / \sqrt{d}$ (sem PE)                 | Aprendido pelo modelo via contexto          |

- ALiBi oferece o decaimento mais previsível, mais fácil de raciocinar sobre extrapolação
- RoPE tem decaimento dependente de frequência, adaptável via reescalonamento (LongRoPE)
- NoPE depende inteiramente do modelo aprender consciência posicional dos dados

# Padrões de Decaimento: Comparação Visual




**ALiBi:** decaimento mais previsível → extrapolação garantida. **RoPE:** decaimento suave mas dependente de frequência. Sinusoidal tende a oscilar; NoPE depende do que o modelo aprendeu.

*Curvas esquemáticas para comparação qualitativa, não valores experimentais.*

# Resultados Empíricos: Perplexidade vs. Comprimento de Contexto

Desempenho relativo em modelagem de linguagem (menor = melhor). Todos treinados em  $L = 2048$ :



*Ilustrativo; tendências relativas de Press et al. (2022), Kazemnejad et al. (2023)*

# Transição: Do Design de PE para Desafios de Uso

---

Agora temos modelos com bons *positional encodings*.  
Mas duas questões-chave permanecem:

## 1. Contexto longo realmente ajuda?

*Lost in the Middle*

→ Parte 3

## 2. Podemos estender contexto além do treino?

LongRoPE, YaRN, PI

→ Parte 4

# Visão Geral

---

## 1. Introdução e Motivação

## 2. Absolute Positional Encoding

## 3. Relative Positional Encoding

3.1 RoPE

3.2 ALiBi

3.3 NoPE

3.4 Comparação

## 4. Desafios em Contextos Longos

4.1 Perplexidade e suas Limitações em Contexto Longo

4.2 Lost in the Middle

4.3 Needle in a Haystack

## 5. Métodos de Extensão de Contexto

# Perplexidade: Definição

---

**Definição:** mede o quão “surpreso” o modelo fica ao ver o texto.

$$\text{PPL}(w_1, \dots, w_N) = \exp\left(-\frac{1}{N} \sum_{i=1}^N \log P(w_i \mid w_1, \dots, w_{i-1})\right)$$

## Vantagens

- Simples de calcular em qualquer corpus
- Permite comparar PEs em condições iguais
- Correlaciona com qualidade do modelo de linguagem

## Atenção

PPL é uma **média sobre todos os tokens**.

Tokens iniciais são previstos com contexto curto; tokens finais com contexto completo.

Contribuições locais e distantes ficam *misturadas*.

# Perplexidade Não Captura Uso Real do Contexto Longo

## O problema central

Um modelo com **PPL baixa** pode **ignorar completamente** o contexto distante, e ainda assim parecer “bom”.

## Por quê?

- A maioria dos tokens é prevista corretamente a partir de contexto **local** (bigramas, padrões sintáticos)
- PPL *dilui* falhas de longo alcance na média global
- Um modelo com PPL = 14 a 8K tokens pode **nunca usar** o que foi dito nos primeiros 6K

## O que PPL mede

Qualidade de *previsão do próximo token* em média sobre todos os tokens

## O que PPL *não* mede

Se o modelo *utiliza* informações de posições distantes ao gerar uma resposta

⇒ **Precisamos de avaliações baseadas em tarefas de recuperação de longo alcance.**



# Lost in the Middle: Artigo

---

## Referência

Liu, N. F. et al. “Lost in the Middle: How Language Models Use Long Contexts.” TACL 2024.<sup>a</sup>


---

<sup>a</sup>Nelson F Liu et al. “Lost in the middle: How language models use long contexts”. Em: [TACL 12 \(2024\)](#), pp. 157–173.

- Pergunta: onde colocar a informação relevante em um contexto longo?
- Tarefa: QA multi-documento, um documento contém a resposta
- Variou: (a) número de documentos, (b) posição do documento relevante
- Testou GPT-3.5-Turbo, GPT-4, Claude e modelos *open-source*
- **Todos os modelos exibem curva de desempenho em forma de U sobre a posição**

## Lost in the Middle: Curva de Desempenho em U

Acurácia em QA multi-documento em função da posição do documento relevante:



Pico no início e fim (*primacy / recency*), **vale no meio**.

*Redesenhado a partir de Liu et al., Lost in the Middle (TACL 2024)*

## Lost in the Middle: Por que Isso Acontece?

---

- **Efeito de primazia:** *tokens* próximos à posição 0 recebem alta atenção nas camadas iniciais
  - A máscara causal força todos os *tokens* a atender ao início da sequência
- **Efeito de recência:** os últimos *tokens* estão na “memória de trabalho” ativa da atenção
- **Tokens do meio, grande distância  $|i-j|$  de ambas as extremidades**
  - Mesmo sem decaimento explícito de PE, padrões de atenção aprendidos tendem a ser locais
- **O alcance efetivo de atenção do modelo é menor que sua janela de contexto**
- **Nota:** GPT-4, Claude e LLaMA-2 usam RoPE ou variantes, o fenômeno **não** é resolvido trocando o PE. É um padrão aprendido de atenção, não uma propriedade do *encoding*.

## *Lost in the Middle: Implicações Práticas*

---

- **Simplemente aumentar o comprimento do contexto NÃO é suficiente**
  - Um modelo com contexto 32K pode ter desempenho pior que um de 4K se a resposta estiver no meio
- **A estratégia de posicionamento dos documentos importa enormemente**
  - Colocar o contexto mais importante no início ou no fim
  - RAG (*Retrieval-Augmented Generation*): buscar apenas o trecho relevante
- **Extensão de contexto (Parte 4) precisa ser combinada com dados de treino de contexto longo**

# Needle in a Haystack: Configuração

---

## Referência

Kamradt, G. “LLMTest\_NeedleInAHaystack” (2023), *benchmark* da comunidade<sup>a</sup>

---

<sup>a</sup>Greg Kamradt. LLMTest\_NeedleInAHaystack: Pressure testing LLMs. [https://github.com/gkamradt/LLMTest\\_NeedleInAHaystack](https://github.com/gkamradt/LLMTest_NeedleInAHaystack). 2023.

- Teste de estresse sintético para recuperação em contextos longos
- **Needle**: fato curto e específico inserido em posição controlada
  - Ex: “A melhor pizzaria de Redmond é a Giovanni's.”
- **Haystack**: texto irrelevante e longo preenchendo o contexto
- **Depth %**: fração do contexto antes da *needle* (0% = início, 100% = fim)
- **Varredura**: comprimento do contexto (eixo x)  $\times$  *depth %* (eixo y)  $\rightarrow$  *heatmap* 2D

# Needle in a Haystack: Como Ler o Heatmap

## Eixos do heatmap:

- Eixo x: comprimento do contexto (1K  $\rightarrow$  128K)
- Eixo y: *depth* % da *needle*
- Cor: acurácia de recuperação

## Padrões de falha:

- Faixa vermelha em contexto longo + meio  $\rightarrow$  *Lost-in-the-Middle*
- Vermelho em todas as profundidades  $\rightarrow$  limite rígido de contexto
- Verde em todo lugar  $\rightarrow$  modelo ideal

Padrão ilustrativo (modelo fraco):

| <i>depth</i> \ comp. | 4K | 16K | 64K | 128K |
|----------------------|----|-----|-----|------|
| 10% (início)         | ✓  | ✓   | ✓   | ✓    |
| 30%                  | ✓  | ✓   | ~   | ×    |
| 50% (meio)           | ✓  | ~   | ×   | ×    |
| 70%                  | ✓  | ✓   | ~   | ×    |
| 90% (fim)            | ✓  | ✓   | ✓   | ~    |

## Needle in a Haystack: Resultados Típicos

| Modelo / PE     | Contexto | Meio a 64K                 | Padrão geral                   |
|-----------------|----------|----------------------------|--------------------------------|
| GPT-4 / RoPE    | 128K     | $\approx 90\text{--}100\%$ | Quase perfeito                 |
| GPT-3.5 / RoPE  | 16K      | 50–70%                     | Falha em longo + meio          |
| LLaMA-2 / RoPE  | 4K       | $< 20\%$ a 16K+            | Colapsa além de $L$            |
| Claude-2 / RoPE | 100K     | $\approx 80\%$             | Maioria verde, lacunas no meio |
| Modelos fracos  | varia    | $< 50\%$ meio              |                                |

- Modelos melhores (maiores, mais dados de treino de contexto longo) têm acurácia mais forte no meio
- Extensão de contexto (Parte 4) primariamente estende o eixo  $x$  (maior  $L$ )
- **Estender  $L$  sem corrigir o formato U não é suficiente para tarefas reais de contexto longo**

Valores aproximados de avaliações publicadas de Needle-in-a-Haystack

## Conclusão: Janela de Contexto $\neq$ Compreensão

---

Uma janela de contexto mais ampla é **necessária** mas **não suficiente** para bom raciocínio em contextos longos.

Para realmente se beneficiar de uma janela de contexto longa, um modelo precisa de:

- Dados de treino com dependências de longo alcance (não apenas sequências longas)
- Padrões de atenção que recuperem informação do meio do contexto de forma confiável
- Possivelmente: estratégias de recuperação ou *chunking* para trazer o conteúdo certo

**Métodos de extensão de contexto estendem a janela, não corrigem o formato U.**

O campo está ativamente combinando extensão com melhor treino de contexto longo.



# Visão Geral

---

## 1. Introdução e Motivação

## 2. Absolute Positional Encoding

## 3. Relative Positional Encoding

3.1 RoPE

3.2 ALiBi

3.3 NoPE

3.4 Comparação

## 4. Desafios em Contextos Longos

4.1 Perplexidade e suas Limitações em Contexto Longo

4.2 Lost in the Middle

4.3 Needle in a Haystack

## 5. Métodos de Extensão de Contexto

# O Problema da Extrapolação: Visão Técnica

## Por que RoPE falha além de $L_{\text{train}}$ ?

- As frequências  $\theta_k$  do RoPE são calibradas para que em  $L_{\text{train}}$  todos os ângulos de rotação sejam visitados
- Dims de alta frequência (*low-k*): ângulo  $i \cdot \theta_k$  dá muitas voltas mesmo para  $L_{\text{train}}$
- Dims de baixa frequência (*high-k*): ângulo  $i \cdot \theta_k$  quase não se move
- **Além de  $L_{\text{train}}$ : dims de baixa freq. atingem ângulos NUNCA vistos  $\rightarrow$  OOD**
- **Solução: reescalar índices de posição para manter o ângulo efetivo *in-distribution***

Ângulo efetivo

$\varphi(i, k) = i \cdot \theta_k$       Problema OOD:  $\varphi(i, k) > \max$  ângulo de treino quando  $i > L_{\text{train}}$

# Position Interpolation (PI)

## Referência

Chen, S. et al. “Extending Context Window of LLMs via Positional Interpolation.” arXiv 2023.<sup>a</sup>

<sup>a</sup>Shouyuan Chen et al. “Extending context window of large language models via positional interpolation”. Em: [arXiv preprint arXiv:2306.15595](https://arxiv.org/abs/2306.15595) (2023).

Correção mais simples: escalar os índices de posição para ficarem dentro de  $[0, L_{\text{train}}]$ .

## Reescalonamento uniforme

$$i \leftarrow i \cdot (L_{\text{train}}/L_{\text{test}})$$

- Ângulo efetivo:  $\varphi'(i, k) = i \cdot (L_{\text{train}}/L_{\text{test}}) \cdot \theta_k \rightarrow$  permanece na faixa de treino
- Requer curto *fine-tuning* ( $\sim 1000$  passos) (adaptar aos ângulos interpolados, OOD no treino)
- Alcança contexto de 8K–32K a partir de modelo treinado em 2K
- **Problema:** escalonamento uniforme comprime dims de alta freq. desnecessariamente (perde resolução fina)

# YaRN: Yet Another RoPE extension

## Referência

Peng, B. et al. “YaRN: Efficient Context Window Extension of Large Language Models.” ICLR 2024.<sup>a</sup>

<sup>a</sup>Bowen Peng et al. “YaRN: Efficient context window extension of large language models”. Em: [ICLR](#). 2024.

- **Diferentes frequências do RoPE precisam de fatores de escala diferentes**
- Dims de alta freq.: já bem cobertas, manter como estão
- Dims de baixa freq.: muito esparsas, precisam de interpolação (como PI)
- Dims intermediárias: escalonamento parcial (*NTK-aware*)
- **YaRN aplica escalonamento não-uniforme: escala diferente por dimensão**
- Corrige temperatura de atenção ( $\sqrt{d} \rightarrow \sqrt{d} \cdot t$ ) para evitar supressão de *scores*
- **Alcança 128K a partir de 2K/4K com ~400 passos de *fine-tuning*; melhor retenção de contexto curto que PI**

# LongRoPE: Artigo

---

## Referência

Ding, Y. et al. “LongRoPE: Extending LLM Context Window Beyond 2 Million Tokens.” arXiv 2024.<sup>a</sup>

---

<sup>a</sup>Yiran Ding et al. “LongRoPE: Extending LLM context window beyond 2 million tokens”. Em: [arXiv preprint arXiv:2402.13753](https://arxiv.org/abs/2402.13753) (2024).

- Alvo: estender contexto para 2 048K *tokens* (2M+) usando LLaMA-2 7B/13B
- Inovação: fatores de reescalonamento não-uniformes por dimensão via busca evolucionária
- *Fine-tuning* em dois estágios para alcançar 2M preservando qualidade em contexto curto
- **Em 2M *tokens*: ainda competitivo em *Needle-in-a-Haystack***
- Mostra que RoPE é extensível muito além de 100K com o reescalonamento correto

# LongRoPE: Problema com Escalonamento Uniforme (PI)

Por que reescalonamento uniforme (PI) tem desempenho inferior em contextos muito longos?

| Índice dim $k$   | $\theta_k$ (freq.)     | Problema c/ escala uniforme       | Tratamento ideal            |
|------------------|------------------------|-----------------------------------|-----------------------------|
| Low $k$ (0–15)   | $\approx 1$ (rápida)   | Dá muitas voltas $\rightarrow$ OK | Manter inalterado ( $s=1$ ) |
| Mid $k$ (16–55)  | $\approx 0.1$          | Parcial $\rightarrow$ OOD leve    | Escala pequena              |
| High $k$ (56–63) | $\approx 0.01$ (lenta) | OOD, problema principal           | Escala grande               |

PI aplica a mesma escala a **todas** as dimensões. *Sobre-comprime dims low- $k$  e sub-comprime mid- $k$ .*

LongRoPE: reescalonamento por dimensão


$i \cdot \theta_k \leftarrow i \cdot \theta_k / \lambda_k$        $\lambda_k$  específico por dimensão (busca evolucionária)

# LongRoPE: Reescalonamento Não-Uniforme via Busca Evolucionária

---

- **Objetivo:** encontrar fatores de escala por dimensão  $\lambda = [\lambda_0, \lambda_1, \dots, \lambda_{d/2-1}]$
- Função objetivo: minimizar perplexidade em  $L_{\text{test}}$  mantendo  $\lambda$  em faixa viável
- **Método:** busca evolucionária (CMA-ES, *Covariance Matrix Adaptation Evolution Strategy*) sobre o vetor  $\lambda$
- População de vetores  $\lambda$  candidatos avaliados por métrica de perplexidade
- Converge em poucas centenas de gerações, viável na prática
- **Resultado:** dims *low-k* recebem  $\lambda \approx 1$  (inalteradas); dims *high-k* recebem  $\lambda$  grande
- O vetor  $\lambda$  final é fixo na inferência, zero custo em tempo de execução

# LongRoPE: Original vs PI vs LongRoPE



**PI** trata todas as dimensões igualmente  $\rightarrow$  compromete *low- $k$* .

**LongRoPE** aplica  $\lambda_k$  por dimensão  $\rightarrow$  cada frequência recebe o tratamento certo.



# LongRoPE: *Fine-Tuning* em Dois Estágios

**Desafio:** *fine-tuning* direto em 2M *tokens* é computacionalmente proibitivo.

| Estágio   | Contexto     | Fatores $\lambda$        | Descrição                         |
|-----------|--------------|--------------------------|-----------------------------------|
| Base      | 4K (LLaMA-2) | $\theta_k$ (inalterado)  | Ponto de partida pré-treinado     |
| Estágio 1 | 256K         | $\lambda^{(1)}$ da busca | FT completo com dados de 256K     |
| Estágio 2 | 2048K        | $\lambda^{(2)}$ da busca | FT curto em 2M; ajustar $\lambda$ |

- Estágio 1 (256K): dados de *fine-tuning* completos;  $\lambda^{(1)}$  otimizado para 256K
- Estágio 2 (2M): dados mínimos;  $\lambda^{(2)}$  re-otimizado para alvo de 2M
- **Recuperação de contexto curto:  $\lambda$  separado para contextos curtos após estágio 2**
- **Valores  $\lambda$  diferentes para inferência curta vs. longa  $\rightarrow$  chaveamento dinâmico**

*Adaptado de Ding et al., LongRoPE (arXiv 2024)*

## LongRoPE: Resultados

| Método           | Ctx máx. | PPL em 2M     | PPL 4K | NiH 1M meio |
|------------------|----------|---------------|--------|-------------|
| LLaMA-2 original | 4K       | ≫100 (falha)  | 5.5    | < 10%       |
| PI               | 32K      | >50 (degrada) | 5.6    | 30–50%      |
| YaRN             | 128K     | ~18           | 5.7    | 65–75%      |
| LongRoPE         | 2048K    | ~9            | 5.6    | ≈ 90%       |

- LongRoPE alcança 2M com qualidade comparável em contexto curto
- *Needle-in-a-Haystack*: 90%+ de acurácia em 1M, *depth* 50%
- Abordagem em dois estágios adiciona custo modesto de *fine-tuning* vs. treino completo em 2M

Dados de Ding et al., LongRoPE (arXiv 2024)

# Métodos de Extensão de Contexto: Comparação

| Método   | Base PE | Tipo de escala     | Ctx máx. | Custo de FT         | Qual. ctx curto |
|----------|---------|--------------------|----------|---------------------|-----------------|
| PI       | RoPE    | Uniforme           | 32K–64K  | Baixo (~1K passos)  | Moderada        |
| YaRN     | RoPE    | Não-uniforme (NTK) | 128K     | Baixo (~400 passos) | Boa             |
| LongRoPE | RoPE    | Por dim (evoluída) | 2M+      | Médio (2 estágios)  | Excelente       |

- Todos os métodos fazem *fine-tune* de modelo RoPE existente, não treinam do zero
- *Trade-off*: extensão mais agressiva → mais *fine-tuning* e reescalonamento cuidadoso
- **Na prática: YaRN é o ponto ideal para a maioria dos casos (128K a baixo custo)**
- Questão aberta: combinar extensão com melhores dados de treino de contexto longo

Compilado de Chen et al. (2023), Peng et al. (2024), Ding et al. (2024)

# Resumo

---

| Método            | Tipo         | Ideia central                          | Extrapolação | Custo                |
|-------------------|--------------|----------------------------------------|--------------|----------------------|
| PE Sinusoidal     | Absoluto     | Frequências sin/cos fixas              | Pobre        | Nenhum               |
| <i>Learned</i> PE | Absoluto     | Matriz de <i>embeddings</i> treinável  | Nenhuma      | $L \times d$ parâms. |
| RoPE              | Relativo     | Rotacionar Q, K por $i \cdot \theta_k$ | Moderada     | Tabela cos/sin       |
| ALiBi             | Relativo     | <i>Bias</i> linear $-m \cdot  i-j $    | Boa          | Desprezível          |
| NoPE              | Rel./Implíc. | Apenas máscara causal                  | Boa          | Nenhum               |
| PI                | Extensão     | Escalonamento uniforme                 | 32K–64K      | FT baixo             |
| YaRN              | Extensão     | Escala não-uniforme NTK                | 128K         | FT baixo             |
| LongRoPE          | Extensão     | Escala por dim evoluída                | 2M+          | FT médio             |

# Referências I

---

- [1] Shouyuan Chen et al. “Extending context window of large language models via positional interpolation”. Em: [arXiv preprint arXiv:2306.15595](#) (2023).
- [2] Yiran Ding et al. “LongRoPE: Extending LLM context window beyond 2 million tokens”. Em: [arXiv preprint arXiv:2402.13753](#) (2024).
- [3] Greg Kamradt. [LLMTest\\_NeedleInAHaystack: Pressure testing LLMs](#). [https://github.com/gkamradt/LLMTest\\_NeedleInAHaystack](https://github.com/gkamradt/LLMTest_NeedleInAHaystack). 2023.
- [4] Amirhossein Kazemnejad et al. “The impact of positional encoding on length generalization in transformers”. Em: [NeurIPS](#). Vol. 36. 2023.
- [5] Nelson F Liu et al. “Lost in the middle: How language models use long contexts”. Em: [TACL](#) 12 (2024), pp. 157–173.
- [6] Bowen Peng et al. “YaRN: Efficient context window extension of large language models”. Em: [ICLR](#). 2024.
- [7] Ofir Press, Noah A Smith e Mike Lewis. “Train short, test long: Attention with linear biases enables input length extrapolation”. Em: [ICLR](#). 2022.
- [8] Jianlin Su et al. “RoFormer: Enhanced transformer with rotary position embedding”. Em: [Neurocomputing](#) 568 (2024), p. 127063.
- [9] Ashish Vaswani et al. “Attention is all you need”. Em: [NeurIPS](#). Vol. 30. 2017.