

# Deep Learning

*Machine Unlearning* para Modelos de Linguagem

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory  
PUCRS

junho de 2026

# Visão Geral

---

1. Motivação: Por Que Esquecer?
2. A Tarefa de *Unlearning*
3. Métodos de *Unlearning*
4. Benchmarks e Tooling
5. Encerramento e Referências

# Visão Geral

---

1. **Motivação: Por Que Esquecer?**

2. A Tarefa de *Unlearning*

3. Métodos de *Unlearning*

4. Benchmarks e Tooling

5. Encerramento e Referências


# LLMs Memorizam o Corpus de Pré-treino

---

Modelos de linguagem grandes são treinados em terabytes de texto da web. Esse corpus carrega:

- Dados pessoais de usuários (e-mails, posts, perfis)
- Obras protegidas por direitos autorais (livros, código, artigos)
- Conteúdo tóxico, vieses sociais, fatos errados
- Capacidades perigosas (síntese de armas, exploração de software)

O modelo é o **subproduto irredutível** desse corpus: tudo o que entrou influencia o que sai.



# O Caso *Harry Potter*<sup>1</sup>

---

## Prompt ao Llama-2-7B:

Mr. and Mrs. Dursley, of number four,  
Privet Drive, were proud to say...

## Continuação do modelo:

...that they were perfectly normal,  
thank you very much. They were the last  
people you'd expect to be involved in  
anything strange or mysterious...

### Observação

O modelo reproduz **verbatim** a abertura do livro 1 da saga, palavra por palavra. Sinal claro de que o corpus de treino contém o texto integral.

### Implicação legal

Distribuir o modelo equivale, para fins práticos, a distribuir uma cópia recuperável do livro.

---

<sup>1</sup>Ronen Eldan e Mark Russinovich. "Who's Harry Potter? Approximate Unlearning in LLMs". Em: [arXiv preprint arXiv:2310.02238](https://arxiv.org/abs/2310.02238) (2023).

# Direito ao Esquecimento e Disputas de *Copyright*

---

## GDPR Art. 17 (*Right to be Forgotten*)

Cidadão da UE pode exigir que um controlador de dados **remova** suas informações pessoais. Para LLMs treinados em dados pessoais, isso é tecnicamente difícil.

## *Lawsuits* em curso (2023–2025)

- *New York Times* vs. OpenAI / Microsoft
- Authors Guild vs. OpenAI
- Getty Images vs. Stability AI
- Reddit vs. Anthropic

## Pergunta operacional


Como remover, de um modelo já treinado, a influência de um subconjunto específico do corpus, sem retreinar do zero?

# Por Que Não Retreinar do Zero?

Retreinar é a solução de referência (*oracle*). Mas:

- Llama-2-7B:  $\approx 184\,000$  GPU-horas A100
- GPT-4: estimado em milhões de GPU-horas
- Cada novo pedido de remoção implicaria reiniciar tudo


*Unlearning* aproximado faz a mesma coisa em **1 GPU-hora** por pedido ((Eldan e Russinovich, 2023)).



Fator de aceleração:  $\sim 10^5$ .

# Vinheta Histórica: *Who's Harry Potter?*<sup>2</sup>

Eldan & Russinovich (Microsoft, 2023) propõem o primeiro *pipeline* de *unlearning* aplicado a LLMs em escala. Aplicam ao Llama-2-7B com o forget set sendo o corpus completo dos 7 livros de *Harry Potter*.



## Resultado e ressalva

O modelo passa a tratar *Harry Potter* como personagem genérico, perde a capacidade de completar trechos literais e mantém desempenho em MMLU, Hellaswag, ARC. Porém, o método é **ad-hoc**: depende de detectar entidades e gerar substitutos manualmente. Serviu como prova de conceito; hoje superado por métodos baseados em otimização.

<sup>2</sup>Ronen Eldan e Mark Russinovich. “Who’s Harry Potter? Approximate Unlearning in LLMs”. Em: [arXiv preprint arXiv:2310.02238](https://arxiv.org/abs/2310.02238) (2023).



# Outras Motivações Além de *Copyright*

---

## Detoxificação

Remover associações tóxicas, vieses ou linguagem ofensiva absorvidas do corpus (RealToxicityPrompts, BOLD).

## Correção de fatos errados

Modelo aprendeu uma data, capital ou autoria incorreta; *unlearning* pontual pode corrigir sem retreinar.

## Defesa contra *jailbreak*

Apagar a capacidade do modelo de produzir certos tipos de conteúdo, mesmo sob *prompts* adversariais.

## Capacidades perigosas (WMDP)

*Weapons of Mass Destruction Proxy*: benchmark que mede conhecimento perigoso (química, bio, ciber). Foco crescente em *unlearning* de **capacidades**, não só de fatos.

# Definição Informal de *Unlearning*

---

## Objetivo

Tornar o modelo  $\theta$  **comportamentalmente indistinguível** de um modelo  $\theta^*$  que nunca viu o subconjunto  $D_f$  a ser esquecido, sem retreinar do zero.

- “Indistinguível” não é em parâmetros, é nas **distribuições de saída**
- Sobre  $D_f$ : o modelo deve agir como se nunca tivesse lido aquilo
- Sobre o restante: utilidade preservada

Próxima seção: formalização e métricas para medir tudo isso.

# Visão Geral

---

1. Motivação: Por Que Esquecer?

**2. A Tarefa de *Unlearning***

3. Métodos de *Unlearning*

4. Benchmarks e Tooling

5. Encerramento e Referências

## Formalização e o *Oracle* $\theta^\star$

Seja  $D = D_r \cup D_f$  o corpus de treino, com:

- $D_f$ : *forget set* (a esquecer)
- $D_r$ : *retain set* (a preservar)


Modelo original:  $\theta = \mathcal{A}(D)$ .

**Oracle:**  $\theta^\star = \mathcal{A}(D_r)$ , hipotético modelo retreinado do zero apenas em  $D_r$ .

Buscamos  $\theta_u = U(\theta, D_f, D_r)$  tal que:

$$p_{\theta_u}(\cdot | x) \approx p_{\theta^\star}(\cdot | x) \quad \forall x \text{ relacionado a } D_f$$

**Não exigimos** igualdade em parâmetros, nem “acerto” do oracle (ele também não responde sobre HP).



## Forget Set vs Retain Set no Caso Harry Potter

$D_f$ , *forget set*

Texto integral dos 7 livros, capítulos, parágrafos, frases textuais.

(*"Mr. and Mrs. Dursley..."*)

$D_r$ , *retain set*

HP FanWiki, Wikipédia, resenhas, análises acadêmicas, fan-fiction sobre o universo.

(*"Hogwarts é uma escola de magia."*)

### Distinção essencial

Queremos esquecer o **texto** dos livros, não o **conceito** do mundo. Um modelo unlearned pode ainda dizer "Hogwarts é uma escola fictícia de magia" (vem do FanWiki), sem reproduzir o parágrafo de abertura do livro 1.

# O Que Esperamos do Modelo *Unlearned*?

---

Quatro propriedades, frequentemente em tensão:

## Forget Quality

A distribuição de saída de  $\theta_u$  em consultas sobre  $D_f$  é **estatisticamente indistinguível** da distribuição de  $\theta^*$ . Não é acurácia, é equivalência distribucional.

## Utility

Desempenho preservado em  $D_r$  e em *benchmarks* gerais (MMLU, HellaSwag, GSM8K).

## Privacy

Resistente a *membership inference attacks* e a *extraction attacks*: o atacante não consegue saber se um trecho estava em  $D_f$ .

## Robustness


Resistente a *relearning attacks*: poucos passos de *fine-tuning* em uma amostra residual não devem trazer o conhecimento de volta.

# A Tensão Fundamental: *Forget* vs *Utility*

Toda técnica de *unlearning* navega um *trade-off*:

- Apagar muito  $D_f$  tende a degradar  $D_r$
- Preservar  $D_r$  tende a deixar  $D_f$  memorizado
- Modelo trivial **constante** ( $p_\theta(\cdot | x) = \text{uniforme}$ ): *forget* perfeito, *utility* zero
- Modelo original sem unlearning: *utility* máxima, *forget* zero

Métodos competem na **fronteira de Pareto**.



# Métrica TOFU 1: *Truth Ratio*<sup>3</sup>

## Definição

$$R_{\text{truth}}(q) = \frac{\frac{1}{|S_{\text{pert}}|} \sum_{a' \in S_{\text{pert}}} P_{\theta}(a' | q)^{1/|a'|}}{P_{\theta}(\tilde{a} | q)^{1/|\tilde{a}|}}$$

$\tilde{a}$ : paráfrase da resposta correta.  $S_{\text{pert}}$ : paráfrases erradas. Raiz  $|a|$ -ésima dá média geométrica por *token*.

**Exemplo (HP).**  $q$ : “Who is Harry Potter’s best friend?”  $\tilde{a}$ : “Ron Weasley.”

$S_{\text{pert}}$ : {“Draco Malfoy.”, “Hagrid.”, “Hermione Granger.”}.

Probabilidades por *token*:  $P_{\theta}(\tilde{a}) = 0.60$ ; paráfrases erradas {0.05, 0.10, 0.15}.

$$R_{\text{truth}} = \frac{(0.05 + 0.10 + 0.15)/3}{0.60} = \frac{0.10}{0.60} \approx 0.17$$

$R_{\text{truth}} \ll 1 \Rightarrow$  modelo ainda lembra de HP. *Unlearning* ideal:  $R_{\text{truth}} \rightarrow 1$ .

<sup>3</sup>Pratyush Maini et al. “TOFU: A Task of Fictitious Unlearning for LLMs”. Em: [COLM](#). arXiv:2401.06121. 2024.



## Métrica TOFU 2: *Forget Quality* via Teste KS

**Ideia.** “Indistinguível do *oracle*” significa: as listas de *truth ratios* de  $\theta_u$  e de  $\theta^*$  sobre as perguntas em  $D_f$  vêm da **mesma distribuição**. Operacionalizado por teste de Kolmogorov–Smirnov de duas amostras.

**Exemplo trabalhado.** 5 *forget questions* de HP:

$$\theta_u : \{0.9, 1.1, 0.8, 1.0, 1.2\} \quad \theta^* : \{0.7, 1.0, 0.9, 1.1, 0.8\}$$

Construir  $F_u$  e  $F^*$  (ECDFs em saltos de  $1/5 = 0.2$ ), achar  $D = \sup_x |F_u(x) - F^*(x)|$ . Suponha  $D = 0.20$ . Para  $n = m = 5$ ,  $p$ -valor  $\approx 0.99$ .

### Conclusão

Não rejeitamos  $H_0$ : distribuições compatíveis, *Forget Quality* alta.

Contra-exemplo: se  $\theta_u = \{0.1, 0.1, 0.1, 0.1, 0.1\}$  (modelo ainda lembra),  $D = 1.0$ ,  $p \approx 0.008$ , rejeitamos.

## Métrica TOFU 3: *Model Utility* (Média Harmônica)

### Definição

Média harmônica de 9 sub-pontuações: 3 conjuntos (*Real Authors*, *World Facts*, *Retain Authors*)  $\times$  3 critérios (ROUGE-L, prob. da resposta correta, *truth ratio* remapeado para  $[0, 1]$ ).

**Exemplo (3 sub-pontuações).** ROUGE = 0.70,  $P_{\text{true}} = 0.50$ ,  $R_{\text{truth}}^{(0,1)} = 0.60$ .


$$\text{Utility} = \frac{3}{1/0.70 + 1/0.50 + 1/0.60} = \frac{3}{5.096} \approx 0.59$$

### Por que média harmônica?

Penaliza coordenadas baixas. Se um termo cai para 0.05,  $\text{Utility} = 3/(1/0.70 + 1/0.50 + 1/0.05) \approx 0.13$ , toda a média desaba. Força o método a preservar **todos** os eixos.

# Métricas MUSE: Avaliação em Seis Dimensões<sup>4</sup>

---



Três grupos: *deployer-side* (o que o usuário vê), *data-owner-side* (o que o titular pode auditar), operacionais (escala e tempo).

---

<sup>4</sup>Weijia Shi et al. "MUSE: Machine Unlearning Six-Way Evaluation for Language Models". Em: [arXiv preprint arXiv:2407.06460](#) (2024).

## Métrica MUSE 1: VerbMem (Memorização Literal)

**Definição.** ROUGE-L entre a continuação gerada por  $\theta_u$  a partir de um prefixo de  $D_f$  e o trecho original do livro. **Queremos baixo.**

**Exemplo trabalhado.** Prefixo: ``Mr. and Mrs. Dursley of number four Privet Drive''.

- Gabarito (8 *tokens*): were proud to say that they were perfectly
- $\theta_u$  gera: lived in a quiet street near the city

LCS entre as duas: **nenhum token em comum**, LCS = 0, ROUGE-L = 0.00. *VerbMem* perfeito.

### Contra-exemplo (vazamento)

$\theta_u$  gera: were proud to say that they perfect ones.

LCS = were proud to say that they (6 *tokens*).

Precision = 6/8, Recall = 6/8,  $\Rightarrow$  *VerbMem* = 0.75. Vazamento literal alto.

## Métrica MUSE 2: KnowMem no *Forget Set*

**Definição.** ROUGE-L entre resposta de  $\theta_u$  e gabarito, em *QA factual* cuja resposta requer ter lido  $D_f$ . **Queremos baixo.**

**Exemplo trabalhado.** 4 perguntas sobre os livros:

| Pergunta                      | Resposta de $\theta_u$ | ROUGE-L |
|-------------------------------|------------------------|---------|
| “Best friend of Harry?”       | <i>I do not know.</i>  | 0.00    |
| “Hogwarts house of Harry?”    | <i>Some house.</i>     | 0.00    |
| “Voldemort’s name at school?” | <i>Tom.</i>            | 0.33    |
| “Wand of Harry?”              | <i>Phoenix wand.</i>   | 0.40    |

$$\text{KnowMem(forget)} = \frac{0.00 + 0.00 + 0.33 + 0.40}{4} = 0.18$$

Bom esquecimento. Note que *Tom Riddle* é *Voldemort*: o 0.33 vem de o modelo dizer “Tom” (parcialmente correto, vazamento residual).

## Métrica MUSE 3: *Utility* (KnowMem no *Retain Set*)

**Definição.** Mesma fórmula de KnowMem, aplicada a perguntas cujas respostas vêm do *retain set*. **Queremos alto.**

**Exemplo trabalhado.** 4 perguntas sobre o universo HP, do FanWiki:

| Pergunta (FanWiki)            | Resposta de $\theta_u$                    | ROUGE-L |
|-------------------------------|-------------------------------------------|---------|
| “Hogwarts is a school of...?” | <i>magic</i>                              | 0.80    |
| “Quidditch is played on...?”  | <i>broomsticks</i>                        | 1.00    |
| “Three Unforgivable Curses?”  | <i>Avada Kedavra, Cruciatus, Imperius</i> | 0.90    |
| “House founded by Salazar?”   | <i>Slytherin</i>                          | 1.00    |

$$\text{Utility} = \frac{0.80 + 1.00 + 0.90 + 1.00}{4} = 0.93$$

### O ponto-chave do MUSE

KnowMem(forget) = 0.18 vs Utility = 0.93: o modelo esqueceu o **texto** dos livros mas preservou o **universo**.

## Métrica MUSE 4: PrivLeak via *Membership Inference*

---

**Definição.** Atacante decide se um trecho  $x$  estava em  $D_f$  usando  $\mathcal{L}(x; \theta_u)$  (loss do modelo) como *score*. *PrivLeak* = AUC desse classificador. **Idealmente**  $\text{AUC} \rightarrow 0.5$  (atacante chuta).

**Exemplo trabalhado.** 4 *in-members* ( $D_f$ ) e 4 *out-members* (nunca vistos), *loss* ordenada:

| <i>rank</i> | $x$   | grupo      | <i>loss</i> | <i>rank</i> | $x$   | grupo      | <i>loss</i> |
|-------------|-------|------------|-------------|-------------|-------|------------|-------------|
| 1           | $x_1$ | <i>in</i>  | 0.8         | 5           | $x_5$ | <i>in</i>  | 1.9         |
| 2           | $x_2$ | <i>out</i> | 1.1         | 6           | $x_6$ | <i>out</i> | 2.2         |
| 3           | $x_3$ | <i>in</i>  | 1.3         | 7           | $x_7$ | <i>in</i>  | 2.5         |
| 4           | $x_4$ | <i>out</i> | 1.6         | 8           | $x_8$ | <i>out</i> | 2.8         |

$$\text{AUC} = (\# \text{pares (in, out) com } \text{loss}(\text{in}) < \text{loss}(\text{out})) / (4 \times 4) = 14/16 = 0.875.$$

*Members* têm *loss* sistematicamente menor: o modelo ainda “lembra”. Vazamento alto. *Unlearning* ideal entrega  $\text{AUC} \approx 0.5$ .

## Métrica MUSE 5: Scalability

---

**Definição.** Como *Forget Quality* e *Utility* evoluem ao crescer  $|D_f|$ ? Método é “escalável” se a queda for sublinear no logaritmo de  $|D_f|$ .

**Exemplo trabalhado.** Aplicar SimNPO em *forget sets* de 3 tamanhos:

| $ D_f $ | <i>Forget Quality</i> (FQ) | Utility | FQ $\times$ Utility |
|---------|----------------------------|---------|---------------------|
| 50      | 0.90                       | 0.85    | <b>0.77</b>         |
| 500     | 0.72                       | 0.71    | <b>0.51</b>         |
| 5000    | 0.41                       | 0.48    | <b>0.20</b>         |

- Aumento de  $|D_f|$  em  $\sim 2$  ordens de grandeza derruba o produto FQ  $\times$  Utility de 0.77 para 0.20
- Queda mais que linear no log: método **não escala bem**
- Em produção, isso significa que apagar capítulos individuais é fácil, apagar livros inteiros é difícil



## Métrica MUSE 6: Sustainability

---

**Definição.** Como o modelo degrada ao receber *requests* **sequenciais** de *unlearning*  $D_{f,1}, \dots, D_{f,t}$ ?

**Exemplo.** 5 requests de SimNPO,  $|D_{f,i}| = 50$ :

| $t$ | Utility | KnowMem( $f_t$ ) |
|-----|---------|------------------|
| 1   | 0.90    | 0.15             |
| 2   | 0.85    | 0.17             |
| 3   | 0.76    | 0.20             |
| 4   | 0.62    | 0.28             |
| 5   | 0.41    | 0.38             |

Taxa média de degradação de Utility por request:

$$(0.90 - 0.41)/4 \approx 0.12$$

### Diagnóstico

Degradação **sobreaditiva** a partir de  $t = 3$ : método não sustentável. Operadores em produção, sob *requests* contínuos (GDPR), precisam de *sustainability* alta.

# Visão Geral

---

1. Motivação: Por Que Esquecer?

2. A Tarefa de *Unlearning*

**3. Métodos de *Unlearning***

4. Benchmarks e Tooling

5. Encerramento e Referências

# Taxonomia: Onde Aplicar o *Unlearning*?

---

## Training-time

Modificar o pré-treino.

Inviável em LLMs prontos.

## Post-training

*Fine-tuning* leve sobre  $\theta$ .

Foco desta aula.

## Inference-time

*Prompts*, filtros, *system prompts*.

Não altera  $\theta$ .

- *Inference-time* é frágil: jailbreak quebra; não passa em testes de *membership inference*
- *Training-time* exige acesso ao corpus completo e custo de retreino
- *Post-training* é o que tem visto progresso real em 2024–2025

# Notação Compartilhada Para os Quatro Métodos

## *Loss de next-token prediction*

$$\mathcal{L}_{\text{NLL}}(D, \theta) = -\mathbb{E}_{(x,y) \sim D} [\log p_{\theta}(y \mid x)]$$

Os métodos a seguir minimizam combinações de termos sobre  $D_f$  e  $D_r$ :

- **IDK**: *fine-tuning* supervisionado com respostas substituídas
- **GA**: subir gradiente em  $D_f$ , descer em  $D_r$
- **NPO**: *preference optimization* sem positivos
- **SimNPO**: NPO sem modelo de referência

Todos compartilham o mesmo regime: dezenas a centenas de *steps* de *fine-tuning*, sem retreino.

## Método 1, IDK: Trocar Respostas por “*I Don't Know*”

---

**Ideia.** Não basta o modelo “não saber”, queremos que ele **responda** “não sei” quando perguntado sobre  $D_f$ . Construímos  $D_f^{\text{IDK}}$  substituindo cada resposta por uma variação de “I don't know”.

**Exemplo (HP).**

- Pergunta: ``Quem é o melhor amigo de Harry Potter?''
- Resposta original (em  $D_f$ ): ``Ron Weasley.''
- Resposta IDK (em  $D_f^{\text{IDK}}$ ): ``I'm not sure.''


Conjunto de respostas IDK típico

``I don't know.'', ``I'm not sure.'', ``I cannot answer that.'', ``I have no information on this.'', ...

## IDK: *Loss* de Treinamento

### Função de custo

$$\mathcal{L}_{\text{IDK}}(\theta) = \mathcal{L}_{\text{NLL}}(D_r, \theta) + \mathcal{L}_{\text{NLL}}(D_f^{\text{IDK}}, \theta)$$



Treinamento estável: é puramente *supervised fine-tuning* (SFT) com rótulos modificados.

# IDK: Pontos Fortes e Fracos

---

## Fortes

- Simples de implementar
- Estável (SFT padrão)
- Preserva utility bem (vimos no plot de Pareto: ponto próximo à origem do eixo *forget*)
- Robusto a hyperparams

## Fracos

- O modelo aprende a **frase** “I don’t know”, não a esquecer o conteúdo
- Vulnerável a *prefix-leak attacks*: se o atacante força o modelo a continuar um trecho dos livros (não fazer perguntas), o conteúdo memorizado vaza
- *Forget Quality* fraca em TOFU

## Lição

IDK é uma **política de resposta**, não um *unlearning* verdadeiro. Apaga o sintoma (responder), não a causa (memorização).

## Método 2, *Gradient Ascent* (GA): Inverter o Treino

---

**Ideia.** O treino fez **descida** do gradiente sobre todo  $D$ . Para esquecer  $D_f$ , basta **subir** o gradiente sobre  $D_f$ :

$$\theta \leftarrow \theta + \eta \nabla_{\theta} \mathcal{L}_{\text{NLL}}(D_f, \theta)$$

Equivalente a descer em  $-\mathcal{L}_{\text{NLL}}(D_f, \theta)$ .

### Intuição geométrica

Se o modelo encontrou um mínimo de  $\mathcal{L}_{\text{NLL}}$  ao ver  $(x, y) \in D_f$ , agora forçamos  $\theta$  na direção contrária, “desfazendo” aquele *step*.

Apesar da simplicidade conceitual, há um problema sério, em dois *slides* a frente.



## GA com Termo de *Retain*

Versão padrão usada na prática (variante **GA + retain**):

$$\mathcal{L}_{\text{GA}}(\theta) = \underbrace{-\mathcal{L}_{\text{NLL}}(D_f, \theta)}_{\text{esquecer}} + \lambda \underbrace{\mathcal{L}_{\text{NLL}}(D_r, \theta)}_{\text{preservar}}$$

### Hyperparam $\lambda$

- $\lambda$  pequeno: privilegia esquecimento, sacrifica utility
- $\lambda$  grande: privilegia utility, esquecimento parcial
- Tipicamente  $\lambda \in [1, 10]$

Sem o termo de *retain*, o método é **instável de imediato** (próximo *slide*).


# GA: Catastrophic Collapse

**Problema.**  $\mathcal{L}_{\text{NLL}}$  é ilimitada  
superiormente: basta que  $p_{\theta}(y | x) \rightarrow 0$   
para  $\mathcal{L}_{\text{NLL}}(x, y) \rightarrow +\infty$ . Então  $-\mathcal{L}_{\text{NLL}}$  é  
ilimitada inferiormente.

Subir o gradiente sem freio empurra os  
*logits* de  $D_f$  para  $-\infty$ . O modelo passa a  
gerar texto incoerente em **qualquer**  
entrada, mesmo as de  $D_r$ .

## Catastrophic collapse

Após poucas épocas, o modelo desmorona.  
*Forget* alto, mas *utility* colapsa para zero.



*Forget* sobe rapidamente, *utility* colapsa.

## Método 3, NPO: Inspiração em DPO<sup>5</sup>

---

Lembrete sobre DPO (*Direct Preference Optimization*). Pares de preferência  $(y_w, y_l)$ , modelo de referência  $p_{\text{ref}}$ :

$$\mathcal{L}_{\text{DPO}}(\theta) = -\mathbb{E} \left[ \log \sigma \left( \beta \log \frac{p_{\theta}(y_w | x)}{p_{\text{ref}}(y_w | x)} - \beta \log \frac{p_{\theta}(y_l | x)}{p_{\text{ref}}(y_l | x)} \right) \right]$$

### Adaptação para *unlearning*

Em *unlearning*, só temos respostas **negativas** ( $y_l$ ): aquilo que queremos não emitir. Não há  $y_w$ . NPO (*Negative Preference Optimization*) descarta o termo de  $y_w$  e mantém apenas o termo de  $y_l$ .

---

<sup>5</sup>Rafael Rafailov et al. “Direct preference optimization: Your language model is secretly a reward model”. Em: [NeurIPS](#). vol. 36. 2023.

# NPO: A *Loss*<sup>6</sup>

## Função de custo

$$\mathcal{L}_{\text{NPO}}(\theta) = -\frac{2}{\beta} \mathbb{E}_{(x,y) \sim D_f} \left[ \log \sigma \left( -\beta \log \frac{p_{\theta}(y | x)}{p_{\text{ref}}(y | x)} \right) \right]$$

### Vantagem fundamental sobre GA.

- Sigmoid  $\sigma$  **satura** quando  $p_{\theta}(y | x) \ll p_{\text{ref}}(y | x)$ : gradiente vai a zero
- Não há *catastrophic collapse*: o método “para sozinho” quando o item já foi esquecido
- $p_{\text{ref}}$  tipicamente é o próprio  $\theta$  inicial (modelo antes do *unlearning*)

Acoplado ao termo  $\lambda \mathcal{L}_{\text{NLL}}(D_r, \theta)$  para preservar utility.

---

<sup>6</sup>Ruiqi Zhang et al. “Negative Preference Optimization: From Catastrophic Collapse to Effective Unlearning”. Em: [arXiv preprint arXiv:2404.05868](https://arxiv.org/abs/2404.05868) (2024).


## NPO: O Limite, *Reference-Model Bias*

O peso efetivo de cada amostra de  $D_f$  no gradiente depende de  $p_{\text{ref}}(y | x)$ .

Amostras que o modelo de referência já achava **improváveis** recebem gradiente **muito maior**.

### Consequência

Em *forget sets* heterogêneos, NPO descalibra: amostras “raras” dominam o gradiente; amostras “típicas” (o que realmente queremos esquecer em HP) recebem peso baixo.



## Método 4, SimNPO: Simplicidade Prevalece<sup>7</sup>

---

**Ideia central.** Eliminar a dependência de  $p_{\text{ref}}$ , inspirado em SimPO (Meng, Xia e Chen, 2024): trocar a razão  $p_{\theta}/p_{\text{ref}}$  por uma normalização **por comprimento** da sequência.

Por que isso é uma ideia boa?

- Sem  $p_{\text{ref}}$ : sem viés de referência
- Sem armazenamento extra do modelo de referência (metade da memória de *fine-tuning*)
- A normalização  $1/|y|$  controla o crescimento da *log-prob* com o comprimento, similar à média geométrica vista no *truth ratio*

---

<sup>7</sup>Chongyu Fan et al. “Simplicity Prevails: Rethinking Negative Preference Optimization for LLM Unlearning”. Em: [NeurIPS](#). arXiv:2410.07163. 2025.

## SimNPO: A *Loss*

### Função de custo

$$\mathcal{L}_{\text{SimNPO}}(\theta) = -\frac{2}{\beta} \mathbb{E}_{(x,y) \sim D_f} \left[ \log \sigma \left( -\frac{\beta}{|y|} \log p_{\theta}(y | x) - \gamma \right) \right]$$

Componentes:

- $\beta$ : temperatura (mesmo papel de DPO/NPO)
- $\gamma$ : *margin* alvo (controla a “intensidade” do esquecimento desejado)
- $1/|y|$ : normalização por comprimento, evita que respostas longas dominem o gradiente
- Sem  $p_{\text{ref}}$

Acoplado, como NPO, a  $\lambda \mathcal{L}_{\text{NLL}}(D_r, \theta)$  para preservar utility.

# SimNPO: Resultados Empíricos

---

## Achados centrais reportados em (Fan et al., 2025):

- Em TOFU (forget 1%, 5%, 10%): SimNPO domina NPO em *Forget Quality* a iso-utility
- Em MUSE-Books e MUSE-News: melhor balanço VerbMem/KnowMem/Utility
- Mais robusto a *relearning attacks* que NPO e GA
- Não sofre *catastrophic collapse*, ainda que mais agressivo no esquecimento

### Atenção pedagógica

Os números exatos (Tabelas 2–6 do paper) variam por benchmark, modelo-base e regime de *forget*. Para uso em sala, consulte a tabela específica do paper antes de citar dígitos.



# Visão Geral

---

1. Motivação: Por Que Esquecer?

2. A Tarefa de *Unlearning*

3. Métodos de *Unlearning*

**4. Benchmarks e Tooling**

5. Encerramento e Referências

# Por Que Precisamos de Benchmarks Dedicados?

---

- Não temos acesso ao oracle  $\theta^*$  em geral (custaria retreinar)
- Não temos acesso ao corpus de pré-treino limpo
- Comparar métodos sem dataset comum é impossível

## Estratégia TOFU

Construir  $D_f$   **sintético**  com identidades fictícias. Treina-se o modelo neste  $D_f + D_r$  sintético, então temos oracle real (modelo treinado só em  $D_r$ ).

## Estratégia MUSE

Usar corpus  **real**  (HP, BBC News). Não tem oracle exato, mas usa métricas que não precisam de oracle (VerbMem, KnowMem, PrivLeak).

# Benchmark TOFU, Construção<sup>8</sup>

---

**Dataset.** 200 “autores fictícios” sintéticos, 20 pares Q&A cada, total 4000 exemplos. Os autores e suas obras **não existem** no pré-treino dos LLMs públicos (verificável por busca).

## Pipeline experimental

1. Pré-fine-tune do modelo base em todos os 4000 exemplos  $\Rightarrow \theta$
2. Pedir que ele esqueça um subconjunto  $D_f$
3. Comparar com oracle  $\theta^*$  treinado só em  $D \setminus D_f$

**Três níveis de severidade:** *forget* 1%, 5%, 10% dos autores.

Restrição: o orçamento de *compute* para esquecer deve ser  $O(|D_f|)$ , não  $O(|D|)$ .

---

<sup>8</sup>Pratyush Maini et al. “TOFU: A Task of Fictitious Unlearning for LLMs”. Em: [COLM](#). arXiv:2401.06121. 2024.

# Benchmark TOFU, Métricas e Resultado-Chave

---

## Métricas (vistas em Seção 2)

- *Forget Quality*: teste KS sobre *truth ratio*
- *Model Utility*: média harmônica de 9 sub-pontuações em *Real Authors*, *World Facts*, *Retain Authors*

## Resultado central do paper original

Nenhum dos baselines avaliados (GA, GA+retain, IDK, KL, PO) atinge *Forget Quality* alta sem destruir *Utility*. O “ponto ideal” do plot de Pareto é **vazio** no estado-da-arte de janeiro/2024. Isso motivou toda a literatura subsequente.

SimNPO (final de 2024) e métodos posteriores começam a popular essa região.

# Benchmark MUSE, Construção<sup>9</sup>

---

**Corpora.** Dois domínios reais:

## MUSE-Books

$D_f$  = corpus integral dos 7 livros *Harry Potter*.

$D_r$  = HP FanWiki (universo, personagens, magia, mas **sem citações textuais** dos livros).

## MUSE-News

$D_f$  = artigos da BBC News de um período específico.

$D_r$  = artigos relacionados não cobertos pelo *forget set*.

**Modelo-alvo.** ICLM-7B (*In-Context Language Model*) primeiro *fine-tuned* no  $D_f$ , garantindo que o modelo realmente memorizou o conteúdo a ser esquecido.

Mais realista que TOFU porque usa domínio com estrutura linguística e enciclopédica genuína.

---

<sup>9</sup>Weijia Shi et al. “MUSE: Machine Unlearning Six-Way Evaluation for Language Models”. Em: [arXiv preprint arXiv:2407.06460](https://arxiv.org/abs/2407.06460) (2024).

## Benchmark MUSE, Resultado-Chave

---

**Achado central.** Avaliando 8 algoritmos (GA, GA+retain, NPO, NPO+retain, KL, PO, *Task Vector*, WHP):

- Quase todos conseguem reduzir *VerbMem* (memorização literal) significativamente
- Apenas **um** método mantém *PrivLeak* próximo de 0.5 (privacidade real)
- **Todos** degradam *Utility* de forma mensurável
- **Todos** falham em *Sustainability* sob requests sequenciais

### Lição

Em 2024, *unlearning* de LLMs em domínio real é um problema **aberto**. Métodos resolvem 1–2 das 6 dimensões; nenhum resolve as 6. Daí o interesse em SimNPO e em frameworks de avaliação como OpenUnlearning.

# OpenUnlearning, Framework Unificado<sup>10</sup>

---

Repositório *one-stop* para avaliação de métodos de *unlearning* em LLMs:

- Integra TOFU, MUSE, WMDP
- 13 métodos (incluindo IDK, GA, NPO, SimNPO)
- 16 métricas
- 450+ *checkpoints* públicos
- Substitui o repositório original do TOFU

[github.com/locuslab/open-unlearning](https://github.com/locuslab/open-unlearning)

**Methods:** IDK, GA, NPO, SimNPO, ...

**Benchmarks:** TOFU, MUSE, WMDP

**Metrics:** Verb-Mem, KS, AUC, ...

**Models:** Llama, Phi, ICLM, ...


---

<sup>10</sup>Vineeth Dorna et al. “OpenUnlearning: Accelerating LLM Unlearning via Unified Benchmarking of Methods and Metrics”. *Em: NeurIPS Datasets and Benchmarks*. arXiv:2506.12618. 2025.

# Como Rodar um Experimento Hoje

---

Pipeline conceitual com OpenUnlearning, sem código:



Para a turma que quer experimentar

Comece com ICLM-7B + MUSE-Books + SimNPO em uma única GPU A100. *Tempo de execução típico: 1–3 horas por configuração.*



# Visão Geral

---

1. Motivação: Por Que Esquecer?

2. A Tarefa de *Unlearning*

3. Métodos de *Unlearning*

4. Benchmarks e Tooling

**5. Encerramento e Referências**

# Desafios em Aberto

---

## Robustez

*Relearning attacks*: poucas centenas de *tokens* de *fine-tuning* podem trazer o conhecimento de volta. Como garantir **esquecimento durável**?

## Escalabilidade

$|D_f|$  realista (livros inteiros, anos de e-mails, milhões de documentos) ainda quebra todos os métodos.

*Capacidades vs fatos*: *unlearning* de fatos (como em TOFU) é mais simples que *unlearning* de capacidades (como em WMDP), que envolve apagar habilidades difusas.

## Sustainability

GDPR implica fluxo **contínuo** de requests. Operação em produção exige sustainability  $\rightarrow 1$ .

## Garantias formais

Diferencial *unlearning*: análogo de privacidade diferencial. Quando teremos **provas** de que o modelo esqueceu, e não apenas evidências empíricas?

# Referências I

---

- [1] Vineeth Dorna et al. “OpenUnlearning: Accelerating LLM Unlearning via Unified Benchmarking of Methods and Metrics”. Em: [NeurIPS Datasets and Benchmarks](#). arXiv:2506.12618. 2025.
- [2] Ronen Eldan e Mark Russinovich. “Who’s Harry Potter? Approximate Unlearning in LLMs”. Em: [arXiv preprint arXiv:2310.02238](#) (2023).
- [3] Chongyu Fan et al. “Simplicity Prevails: Rethinking Negative Preference Optimization for LLM Unlearning”. Em: [NeurIPS](#). arXiv:2410.07163. 2025.
- [4] Pratyush Maini et al. “TOFU: A Task of Fictitious Unlearning for LLMs”. Em: [COLM](#). arXiv:2401.06121. 2024.
- [5] Yu Meng, Mengzhou Xia e Danqi Chen. “SimPO: Simple preference optimization with a reference-free reward”. Em: [NeurIPS](#). Vol. 37. 2024.
- [6] Rafael Rafailov et al. “Direct preference optimization: Your language model is secretly a reward model”. Em: [NeurIPS](#). Vol. 36. 2023.
- [7] Weijia Shi et al. “MUSE: Machine Unlearning Six-Way Evaluation for Language Models”. Em: [arXiv preprint arXiv:2407.06460](#) (2024).
- [8] Ruiqi Zhang et al. “Negative Preference Optimization: From Catastrophic Collapse to Effective Unlearning”. Em: [arXiv preprint arXiv:2404.05868](#) (2024).