

Deep Learning

Modelos Encoder-Only e Sentence Embeddings

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory
PUCRS

abril de 2026

Visão Geral

1. Paradigmas Arquiteturais do Transformer
2. De Embeddings Estáticos a Contextuais
3. Tarefas em Nível de *Token*
4. BERT
5. De *Tokens* a Sentenças: *Sentence Embeddings*
6. Aprendizado Contrastivo
7. SBERT: *Sentence-BERT*
8. Tarefas e Avaliação de *Sentence Embeddings*
9. Encerramento

Overview

1. Paradigmas Arquiteturais do Transformer
2. De Embeddings Estáticos a Contextuais
3. Tarefas em Nível de *Token*
4. BERT
5. De *Tokens* a Sentenças: *Sentence Embeddings*
6. Aprendizado Contrastivo
7. SBERT: *Sentence-BERT*
8. Tarefas e Avaliação de *Sentence Embeddings*
9. Encerramento

As Três Famílias de Transformers

Desde o início da arquitetura *Transformer* deu origem a três famílias:

Encoder-Decoder

- T5, BART, mT5
- *Seq2seq*: entrada $\rightarrow$ saída
- *Cross-attention* liga os dois lados
- Tradução, sumarização


Decoder-Only

- GPT, LLaMA, Mistral
- Atenção **causal** (mascarada)
- Geração autorregressiva
- *Chatbots*, *code completion*

Encoder-Only


- BERT, RoBERTa, DeBERTa
- Atenção **bidirecional**
- Foco em *compreensão*
- Classificação, busca, NER

Padrões de Atenção: Visualizando a Diferença



- **Encoder:** cada *token* vê **todos** os outros → representação rica em contexto
- **Decoder:** cada *token* vê apenas o passado → geração autorregressiva
- **Enc-Dec:** *decoder* consulta *encoder* via *cross-attention*

Qual Família Usar? Uma Árvore de Decisão



- Tarefas de *compreensão* (classificação, busca, NER, STS) → **encoder-only**
- Geração aberta (*chat*, *code*, criação) → **decoder-only**
- Tradução / sumarização em que entrada e saída são muito diferentes → **encoder-decoder**

O Ramo da Compreensão

Enquanto modelos *decoder-only* (GPT, LLaMA) trabalham com *geração de texto*, modelos *encoder-only* trabalham em com:

- Como transformar texto em vetores *densos e contextuais*
- Como usar esses vetores para tarefas discriminativas
- Como treinar embeddings de **frases inteiras** que alimentam sistemas de busca semântica e RAG

Onde usamos *encoder-only*?

- *Retrieval* para RAG
- Busca semântica
- Classificação de palavras/sentenças
- *Reranking* barato
- *Clustering* e deduplicação
- Detecção de conteúdo

Overview

1. Paradigmas Arquiteturais do Transformer
- 2. De Embeddings Estáticos a Contextuais**
3. Tarefas em Nível de *Token*
4. BERT
5. De *Tokens* a Sentenças: *Sentence Embeddings*
6. Aprendizado Contrastivo
7. SBERT: *Sentence-BERT*
8. Tarefas e Avaliação de *Sentence Embeddings*
9. Encerramento

Por que Precisamos de *Word Embeddings*?

Representação *one-hot*:

- Vocabulário de $|V| = 50k \rightarrow$ vetores de 50k dimensões
- **Esparsa** (um único 1, resto zeros)
- Ortogonal: $\cos(\text{rei}, \text{rainha}) = 0$
- Nenhuma semântica capturada

Word embedding:

- Vetor de baixa dimensão ($d = 300, 768, \dots$)
- **Denso** (todas as entradas ativas)
- Palavras semanticamente próximas $\rightarrow$ vetores próximos
- Aprendido a partir de grandes *corpora*

Hipótese distribucional (Harris, 1954)

“*You shall know a word by the company it keeps.*”, palavras que aparecem em contextos similares tendem a ter significado similar.

Embeddings Estáticos: Word2Vec e GloVe

Word2Vec¹

- **Skip-gram**: prever palavras do contexto a partir da palavra central
- **CBOW**: prever palavra central a partir do contexto
- Resultado: uma matriz $E \in \mathbb{R}^{|V| \times d}$

GloVe²


- Fatoração de matriz de co-ocorrência global
- Combina estatística global (como LSA) com janelas locais (como W2V)
- Resultado: uma matriz $E \in \mathbb{R}^{|V| \times d}$

Cada palavra é representada por *UM* único vetor, independente do contexto.

¹Tomas Mikolov et al. “Distributed Representations of Words and Phrases and their Compositionality”. Em: Advances in Neural Information Processing Systems. Vol. 26. 2013.

²Jeffrey Pennington, Richard Socher e Christopher D. Manning. “GloVe: Global Vectors for Word Representation”. Em: Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2014, pp. 1532–1543.

A Visualização Clássica



- Direções no espaço codificam **relações semânticas**
- Mas: **um único vetor por palavra**, independente do contexto

O Problema da Polissemia

Duas frases em português

1. “Ele sacou dinheiro no **banco** da esquina.”
2. “Ela sentou no **banco** do parque.”

Embeddings estáticos:

- $\mathbf{v}_{\text{banco}}^{(1)} = \mathbf{v}_{\text{banco}}^{(2)}$
- O vetor é uma *média* dos dois sentidos
- O modelo “confunde” instituição financeira com assento

Embeddings contextuais:

- $\mathbf{v}_{\text{banco}}^{(1)} \neq \mathbf{v}_{\text{banco}}^{(2)}$
- Cada ocorrência recebe um vetor diferente
- O contexto *molda* o vetor final

A função que gera o *embedding* deve depender do contexto $f(\text{palavra}, \text{contexto}) \rightarrow \mathbb{R}^d$.


A Ponte: ELMo (2018)³

Ideia: em vez de uma tabela *lookup*, use um **modelo de linguagem bidirecional** pré-treinado.

Duas LSTMs profundas:

- Uma da esquerda para direita $p(w_t|w_{<t})$
- A outra da direita para a esquerda $p(w_t|w_{>t})$
- *Embedding* final = combinação linear das camadas das duas LSTMs

Primeiros embeddings verdadeiramente contextuais a ganhar tração em NLP.



Duas LSTMs empilhadas, direções opostas.

³Matthew E. Peters et al. "Deep Contextualized Word Representations". Em: *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language* 2018, pp. 2227–2237.

Embeddings Contextuais via *Transformers*

Com a chegada do *Transformer*, as LSTMs do ELMo foram substituídas por **camadas de self-attention**:

- Cada *token* atende a **todos** os outros da sequência
- A representação final de cada *token* é uma mistura de todos os outros, ponderada pelos *scores* de atenção
- Paralelizável (ao contrário de LSTMs)
- Captura dependências de longo alcance sem o *vanishing gradient*

Formalizando

Dado um *token* w_i na posição i , o *embedding* contextual na camada ℓ é:

$$\mathbf{h}_i^{(\ell)} = f_{\ell}(\mathbf{h}_0^{(\ell-1)}, \mathbf{h}_1^{(\ell-1)}, \dots, \mathbf{h}_{L-1}^{(\ell-1)}, i)$$

onde f_{ℓ} é uma camada *Transformer encoder* (self-attention + FFN).

“Banco” em dois contextos

sacou no banco da esquina $\rightarrow \mathbf{h}^{(1)} = [0.8, -0.3, 0.6, \dots]$

sentou no banco do parque $\rightarrow \mathbf{h}^{(2)} = [-0.2, 0.7, -0.5, \dots]$

$$\cos(\mathbf{h}^{(1)}, \mathbf{h}^{(2)}) \approx 0.15$$

$$\cos(\mathbf{h}^{(1)}, \mathbf{h}_{\text{agência}}) \approx 0.82$$

- A **mesma palavra** produz **vetores diferentes** em contextos diferentes
- No primeiro contexto, “banco” fica próximo de “agência”, “caixa”, “conta”
- No segundo, fica próximo de “cadeira”, “praça”, “sentar”


Overview

1. Paradigmas Arquiteturais do Transformer
2. De Embeddings Estáticos a Contextuais
- 3. Tarefas em Nível de *Token***
4. BERT
5. De *Tokens* a Sentenças: *Sentence Embeddings*
6. Aprendizado Contrastivo
7. SBERT: *Sentence-BERT*
8. Tarefas e Avaliação de *Sentence Embeddings*
9. Encerramento

A Receita Geral

Para qualquer tarefa em nível de *token*:

1. Passe a frase por um *encoder* pré-treinado
2. Extraia os *embeddings* contextuais $\mathbf{h}_1, \dots, \mathbf{h}_L$
3. Adicione uma pequena cabeça linear $W \in \mathbb{R}^{d \times C}$
4. $\text{logits}_i = W^\top \mathbf{h}_i$
5. *Softmax* sobre C classes




Fine-tuning da Cabeça de Classificação

A cabeça tem tipicamente $< 1\%$ dos parâmetros totais. Quase todo o conhecimento vem do *pré-treino*.

Tarefa: *Named Entity Recognition* (NER)

Classificar cada *token* em uma categoria de entidade (Pessoa, Local, Organização, ...).

Esquema BIO: **B**egin, **I**nside, **O**utside de uma entidade.



- **Entidades multi-token** (“Porto Alegre”) são capturadas por **B-** seguido de **I-**
- Cabeça linear $W \in \mathbb{R}^{d \times C}$ com $C = 2k + 1$ (um B- e um I- por tipo, mais O), onde k é o número de categorias presentes no NER
- *Benchmark* clássico: CoNLL-2003⁴

⁴Erik F. Tjong Kim Sang e Fien De Meulder. “Introduction to the CoNLL-2003 Shared Task: Language-Independent Named Entity Recognition”. Em: [Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003](#). 2003, pp. 142–147.

Tarefa: *Part-of-Speech Tagging* (POS)

Classificar cada *token* em uma categoria gramatical (substantivo, verbo, adjetivo, ...).

O	gato	preto	dorme	tranquilamente
DET	NOUN	ADJ	VERB	ADV

- Problema clássico de NLP, resolvido com **altíssima precisão** por encoders modernos ($> 97\%$)
- *Embeddings contextuais* são ideais: a mesma palavra pode ter *tag* diferente em contextos diferentes
 - O **jogo** de ontem foi muito disputado.
 - Eu **jogo** playstation todas as terças-feiras
- *Universal Dependencies*: esquema de *tags* compartilhado entre > 100 línguas

Tarefa: *Extractive Question Answering* (SQuAD)⁵

Dado uma frase no seguinte formato: **Contexto** [SEP] **Pergunta** [SEP], identificar o **trecho** do parágrafo que responde a pergunta.

Exemplo

“[CLS] A PUCRS foi fundada em 1948 na cidade de Porto Alegre. [SEP] Quando a PUCRS foi fundada? [SEP]”

Resposta: 1948 $\rightarrow$ *span* com início no *token* 5, fim no *token* 5

Duas saídas: posição de início e posição do final da resposta.

- $\mathbf{w}_{\text{start}}, \mathbf{w}_{\text{end}} \in \mathbb{R}^d$
- $p_{\text{start}}(i) = \text{softmax}(\mathbf{w}_{\text{start}}^\top \mathbf{h}_i)$
- $p_{\text{end}}(i) = \text{softmax}(\mathbf{w}_{\text{end}}^\top \mathbf{h}_i)$
- Treino: cross-entropy nos índices de início e fim

⁵Pranav Rajpurkar et al. “SQuAD: 100,000+ Questions for Machine Comprehension of Text”. Em: *Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2016, pp. 2383–2392.

Por que Embeddings Contextuais Dominam Essas Tarefas?

Com embeddings estáticos (pré-2018):

- Necessário *feature engineering*, regras feitas a mão
- Desempenho limitado pela ambiguidade lexical
- NER no CoNLL-2003: $\sim 90\%$ F1 com modelos específicos

Com embeddings contextuais:

- Uma camada linear acima do *encoder*
- Resolução de ambiguidade é “gratuita” (já contextual)
- NER no CoNLL-2003: $> 94\%$ F1 com BERT
- SQuAD: humano $\approx 91\%$, BERT-Large $\approx 93\%$

A lição

Pré-treinar um **encoder** em grande escala + cabeça linear pequena na tarefa alvo tornou-se a **receita padrão** de NLP entre 2018 e 2022.

Overview

1. Paradigmas Arquiteturais do Transformer
2. De Embeddings Estáticos a Contextuais
3. Tarefas em Nível de *Token*
- 4. BERT**
5. De *Tokens* a Sentenças: *Sentence Embeddings*
6. Aprendizado Contrastivo
7. SBERT: *Sentence-BERT*
8. Tarefas e Avaliação de *Sentence Embeddings*
9. Encerramento

BERT: *Bidirectional Encoder Representations*⁶

Contribuições principais:

- Usa apenas a **pilha encoder** do *Transformer*
- Pré-treino **bidirecional** com dois objetivos novos:
 - *Masked Language Modeling* (MLM)
 - *Next Sentence Prediction* (NSP)
- “*Fine-tuning*”: mesmo modelo + cabeça pequena resolve > 11 tarefas de NLP
- *State-of-the-art* em quase todos os *benchmarks* da época

Por que “bidirecional”?

GPT-1 (2018) era unidirecional (causal). BERT mostrou que, para *compreensão*, ver **o futuro** da frase melhora drasticamente. Mas: **não pode gerar texto** diretamente.

⁶Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. Em: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language* 2019, pp. 4171–4186.

Arquitetura: Pilha de Encoders do *Transformer*

BERT = N camadas de *encoder*, cada uma com:

- *Multi-head self-attention* **bidirecional** (sem máscara causal)
- *Feed-forward network* (GELU)
- *Layer Norm* + conexões residuais

Duas versões oficiais:

	Base	Large
Camadas (L)	12	24
<i>Hidden</i> (d)	768	1024
<i>Heads</i> (h)	12	16
Parâmetros	110M	340M

Task Head

Encoder Layer L

⋮

Encoder Layer 2

Encoder Layer 1

Input Embeddings

Dados de Pré-Treino

BERT foi pré-treinado em:

- **BooksCorpus:** $\sim 800\text{M}$ palavras de livros não publicados
- **Wikipedia inglesa:** $\sim 2,5\text{B}$ palavras (só texto, sem tabelas/listas)

Total: $\sim 3,3\text{B}$ palavras, ~ 16 GB de texto.

Por que esses dados?

- **Gratuitos e de alta qualidade**
- Contêm estruturas de longa distância (sentenças contíguas) $\rightarrow$ útil para NSP
- Linguagem formal e variada

Tokenização: WordPiece

BERT usa **WordPiece**.

Recapitulação rápida


- Vocabulário de $\sim 30k$ *subwords*
- Palavras raras quebradas em prefixos conhecidos + sufixos marcados com ##
- Exemplo: tokenização $\rightarrow$ token ##iza ##ção
- Resolve o problema de OOV (*out-of-vocabulary*) sem explodir o vocabulário

Tokens especiais adicionados pelo tokenizer do BERT:

- [CLS]: marca o início da sequência
- [SEP]: separador de segmentos
- [PAD]: preenchimento para lotes
- [MASK]: usado apenas no pré-treino (MLM)
- [UNK]: *token* desconhecido (raro com WordPiece)

Representação de Entrada do BERT

O *embedding* final de cada *token* é a **soma** de três componentes:



$$\mathbf{x}_i = E_{\text{token}}(w_i) + E_{\text{segment}}(s_i) + E_{\text{position}}(i)$$

Tudo é aprendido (inclusive a posição, ao contrário do PE sinusoidal).

O Token [CLS]

[CLS] é um *token* **sempre** prefixado à sequência.

Papel:

- Não é uma palavra real, começa como um *embedding* aleatório aprendido
- Ao longo das L camadas, acumula informação de **toda a frase** via *self-attention*
- Seu estado final $\mathbf{h}_{[\text{CLS}]}^{(L)}$ é usado como **representação agregada da sequência**
- Cabeças de **classificação** de sentença ligam-se a ele

Observação

$\mathbf{h}_{[\text{CLS}]}$ do BERT não é um bom *sentence embedding*.

[SEP] e *Segment Embeddings*

BERT pode receber uma ou **duas** sentenças:

Formato para uma sentença

[CLS] o gato dorme [SEP]

Formato para duas sentenças (par)

[CLS] o gato dorme [SEP] no tapete vermelho [SEP]

- [SEP] marca **fronteiras** entre segmentos
- **Segment embeddings**: E_A adicionado aos *tokens* da primeira sentença, E_B aos da segunda
- Permite tarefas de **pares de sentença**: NLI, similaridade, paráfrase, QA

Insight: sem *segment embeddings*, o modelo não saberia se um *token* pertence à pergunta ou ao contexto em uma tarefa de QA.

Comprimento Fixo e *Padding*

BERT tem um comprimento máximo fixo de 512 *tokens*.

Por quê fixo?

- *Position embeddings* aprendidos: só existem para posições $0, \dots, 511$
- Atenção $O(L^2) \rightarrow$ custo proibitivo para L grande
- *Batching* eficiente requer forma uniforme

Como uniformizar um *batch*?

- Frases **curtas** $\rightarrow$ ***padding*** com [PAD] até o comprimento desejado
- Frases **longas** $\rightarrow$ ***truncagem*** (ou *sliding window*)
- *Attention mask* indica quais posições são reais


Máscara de atenção

[CLS]	o	gato	[SEP]	[PAD]	[PAD]	[PAD]	[PAD]
1	1	1	1	0	0	0	0

Posições com 0 recebem $-\infty$ nos *logits* de atenção e são efetivamente ignoradas.

Objetivo #1: *Masked Language Modeling* (MLM)

Ideia: esconder aleatoriamente 15% dos *tokens* e pedir ao modelo que os recupere.



modelo deve prever: “sentou”

- Perda: *cross-entropy* sobre o vocabulário para **cada posição mascarada**
- O modelo aprende **atenção bidirecional**: pode olhar para a esquerda E direita
- Contraste com GPT: que só vê a esquerda → **sinal de treino mais fraco por token**

$$\mathcal{L}_{\text{MLM}} = -\frac{1}{|M|} \sum_{i \in M} \log p(w_i \mid \mathbf{w}_{\setminus M})$$

onde M é o conjunto de posições mascaradas.

A Regra 80/10/10 do MLM

Dos 15% *tokens* selecionados para máscara, **nem todos** viram [MASK]:

Distribuição

- 80%: substituído por [MASK]
- 10%: substituído por **palavra aleatória**
- 10%: **mantido** como está

Em todos os casos, o modelo deve prever a palavra original.

Por que essa mistura?

- [MASK] só existe no pré-treino, nunca no *fine-tuning* → **desalinhamento**
- 10% aleatórios forçam o modelo a ser “cético” sobre *tokens* visíveis
- 10% intactos garantem representações úteis para *tokens* não-mascarados

Exemplo

- | | |
|--|-----|
| • “O gato [MASK] no tapete” | 80% |
| • “O gato banana no tapete” | 10% |
| • “O gato sentou no tapete” (inalterado) | 10% |

MLM: Exemplo Numérico

Frase: “A capital da França é Paris” (6 *tokens*)

1. $15\% \times 6 \approx 1$ *token* selecionado. Suponha que seja “*Paris*”.
2. Com probabilidade 80% $\rightarrow$ “A capital da França é [MASK]”
3. *Forward pass* pelo BERT $\rightarrow$ estado oculto $\mathbf{h}_{[\text{MASK}]} \in \mathbb{R}^{768}$
4. Cabeça linear $\rightarrow$ *logits* sobre o vocabulário ($|V| \approx 30\text{k}$)
5. *Softmax* $\rightarrow$ distribuição de probabilidade

Topo das predições (hipotético):

<i>Token</i>	Probabilidade
Paris	0,71
Lyon	0,08
Marselha	0,04
Berlim	0,02
...	...

Perda: $-\log 0,71 \approx 0,34$ na posição mascarada.

Objetivo #2: *Next Sentence Prediction* (NSP)

Ideia: dado um par de sentenças (A, B) , prever se B é a sentença que **segue** A no texto original, ou se é uma sentença aleatória.

Exemplo positivo (IsNext)

A: “Ele abriu a porta do carro.”

B: “Em seguida, entrou e ligou o motor.”

Exemplo negativo (NotNext)

A: “Ele abriu a porta do carro.”

B: “Mercúrio é o menor planeta do sistema solar.”

Arquitetura:

- Entrada: [CLS] A [SEP] B [SEP]
- Cabeça binária sobre $\mathbf{h}_{[\text{CLS}]}^{(L)}$
- *Cross-entropy* binária

Motivação: treinar o modelo a entender **relações entre sentenças** (útil para NLI, QA, ...).

Spoiler: RoBERTa⁷ mostrou que **NSP não ajuda**, modelos de *word embedding* e *sentence embedding* mais modernos não usam essa tarefa.

⁷Yinhan Liu et al. “RoBERTa: A Robustly Optimized BERT Pretraining Approach”. Em: [arXiv preprint arXiv:1907.11692](https://arxiv.org/abs/1907.11692) (2019).

Perda Total de Pré-Treino

As duas perdas são combinadas em um único escalar:

$$\mathcal{L}_{\text{BERT}} = \mathcal{L}_{\text{MLM}} + \mathcal{L}_{\text{NSP}}$$

- O **mesmo** *forward pass* gera ambas as perdas
- $\mathcal{L}_{\text{MLM}}$ usa as posições mascaradas
- $\mathcal{L}_{\text{NSP}}$ usa a posição [CLS]
- *Backprop* ocorre conjuntamente, com os gradientes somados

Treinamento original

- 1M passos de 256 sequências, ~ 40 épocas
- 4 TPU *pods*, ~ 4 dias para BERT-Base
- *Adam* com *warmup* linear

Fine-Tuning: Uma Cabeça, Muitas Tarefas

Depois do pré-treino, o BERT pode ser **adaptado** a uma tarefa específica treinando por poucas épocas com uma **cabeça nova**.

Receita genérica:

1. Carregar pesos pré-treinados
2. Substituir a cabeça MLM / NSP por uma cabeça específica da tarefa (inicializada aleatoriamente)
3. Treinar **tudo** de ponta a ponta por 2–5 épocas
4. *Learning rate* baixa ($\sim 2 \times 10^{-5}$)





Surpreendentemente geral

O **mesmo modelo base** resolve:

- Classificação de frase (SST-2, CoLA)
- Pares de frase (NLI, paráfrase)
- Marcação de *token* (NER, POS)

Só muda a cabeça e o formato da entrada.

Quatro Formatos de *Fine-Tuning*



- (a) e (b) usam $\mathbf{h}_{[CLS]}$ como representação da (pair de) frase
- (c) usa os vetores por *token* $\mathbf{h}_i$
- (d) usa dois vetores globais $\mathbf{w}_{start}, \mathbf{w}_{end}$ para classificar cada posição

Feature Extraction vs Fine-Tuning

Duas estratégias para usar um modelo pré-treinado:

Feature Extraction (pesos congelados)

- Congela BERT, treina só a cabeça
- Muito mais rápido e barato
- Pode **cachear** os *embeddings*
- Desempenho geralmente menor
- Útil quando temos poucos dados ou pouca GPU

Fine-Tuning (pesos descongelados)

- Treina BERT **inteiro** + cabeça
- *Learning rate* pequena (2×10^{-5})
- Melhor desempenho
- Custo: $\sim 10\times$ mais GPU
- Risco de *overfitting* com poucos dados

Ainda há possibilidade de usar adaptadores LORA para treinar apenas um subconjunto pequeno de parâmetros.

O Ecossistema BERT: Principais Variantes

- **RoBERTa** [8]: Remove NSP, mais dados (160 GB), mascaramento dinâmico, *batch* maior. **Resultado:** +2 pts no GLUE.
- **ALBERT** [7]: Compartilhamento de parâmetros entre camadas + fatoração do *embedding*. **Resultado:** -90% parâmetros.
- **DeBERTa** [5]: *Disentangled attention* (conteúdo e posição separados) + *enhanced mask decoder*. **Resultado:** SOTA em SuperGLUE.
- **ELECTRA** [3]: Substitui MLM por *Replaced Token Detection*: discrimina *tokens* reais de gerados. **Resultado:** mesmo desempenho com ~25% do *compute*.
- Todos são **encoder-only** e mantêm a receita pré-treino → *fine-tuning*
- ELECTRA: treina **todas** as posições, não só os 15% mascarados → sinal denso
- DeBERTa-v3 ainda é competitivo em classificação e NLI

Overview

1. Paradigmas Arquiteturais do Transformer
2. De Embeddings Estáticos a Contextuais
3. Tarefas em Nível de *Token*
4. BERT
- 5. De *Tokens* a Sentenças: *Sentence Embeddings***
6. Aprendizado Contrastivo
7. SBERT: *Sentence-BERT*
8. Tarefas e Avaliação de *Sentence Embeddings*
9. Encerramento

Motivação: Um Vetor por Sentença

Muitas aplicações precisam de **um único vetor** que represente uma sentença ou documento inteiro:

Aplicações

- **Busca semântica:** encontrar documentos similares a uma consulta
- **RAG:** recuperar contexto relevante para um LLM
- **Clustering:** agrupar documentos por tópico
- **Deduplicação:** detectar paráfrases
- **Classificação:** *zero-shot* com *embeddings* comparados a rótulos
- **Recomendação:** *item-to-item*

Requisitos:

- **Rápido:** milhões de vetores pré-computados, consulta em milissegundos
- **Compacto:** 384–1024 dimensões
- **Semanticamente** estruturado: similaridade cosseno deve refletir similaridade de significado

BERT *out-of-the-box* resolve isso?

Não muito bem, como veremos.

Abordagens Ingênuas

Como extrair **um** vetor de BERT para uma sentença?

[CLS] pooling

- Usar $\mathbf{h}_{[\text{CLS}]}^{(L)}$
- “Parece o certo”: ele foi projetado para classificação
- **Ruim** para similaridade

Mean pooling

- $\frac{1}{L} \sum_i \mathbf{h}_i^{(L)}$
- Simples, robusto
- Usa a máscara para ignorar [PAD]
- Empiricamente **melhor** que [CLS]

Max pooling

- $\max_i \mathbf{h}_i^{(L)}$ por dimensão
- Captura “*features* mais salientes”
- Menos usada na prática

Descoberta de [15]

BERT vanilla + [CLS] performa *pior* que GloVe em *Semantic Textual Similarity* (STS) usando similaridade cosseno!

Por Que [CLS] *Vanilla* Falha em Similaridade?

O que o [CLS] aprende?

- No pré-treino: **NSP** $\rightarrow$ “esta é a próxima frase?”
- Esse é um sinal *binário* e ruidoso
- Não há incentivo para **estruturar o espaço** de forma que frases similares fiquem próximas

Consequência:

- O espaço de [CLS] é **anisotrópico**: todos os vetores ficam em um cone estreito
- Distâncias cosseno são pouco informativas
- Frases completamente diferentes podem ter cosseno $> 0,9$

Logo...


BERT foi treinado para *token-level* MLM e classificação NSP — **não** para similaridade semântica.

Para obter bons *sentence embeddings* precisamos de um **novo objetivo de treino**.


Bi-Encoder vs Cross-Encoder

Duas formas de comparar duas frases com um *encoder*:

Bi-Encoder



Cross-Encoder



Bi-Encoder:

- Codifica *A* e *B* **independentemente**
- *A* pode ser pré-computado e armazenado
- Consulta: 1 *forward pass* por *B* + busca em vetor
- **Rápido**, escala para bilhões

Cross-Encoder:

- Vê os dois **juntos**, atenção cruzada *full*
- Melhor desempenho (mais informação)
- 1 *forward pass* **por par** $\rightarrow O(n^2)$
- **Inviável** para busca em escala

A Diferença de Velocidade: 65 horas → 5 segundos

Experimento de [15]:

- Corpus: 10 000 frases
- Tarefa: encontrar os pares mais similares
- Pares possíveis: $\binom{10\,000}{2} = 49\,995\,000$

Cross-encoder BERT

~ 65 horas para computar todas as similaridades par-a-par.


Bi-encoder SBERT

- Codificar as 10k frases: ~ 5 segundos
- Comparar todos os pares: ~ 0,01 segundos (matriz dot-product)

Mais de 40 000× mais rápido. Esse é o problema que SBERT resolve.

Arquitetura Híbrida: *Retrieve* + *Rerank*

Na prática, usa-se os dois em uma **pipeline em dois estágios**:



- **Bi-encoder** filtra bilhões → centenas em milissegundos
- **Cross-encoder** reordena as centenas com alta precisão
- Usa o melhor dos dois mundos: escala e qualidade
- Padrão em sistemas modernos de *retrieval* (Google, *semantic search* empresarial, RAG)

Overview

1. Paradigmas Arquiteturais do Transformer
2. De Embeddings Estáticos a Contextuais
3. Tarefas em Nível de *Token*
4. BERT
5. De *Tokens* a Sentenças: *Sentence Embeddings*
- 6. Aprendizado Contrastivo**
7. SBERT: *Sentence-BERT*
8. Tarefas e Avaliação de *Sentence Embeddings*
9. Encerramento


Intuição: Puxar os Similares, Empurrar os Diferentes

O **aprendizado contrastivo** treina um *encoder* f_θ tal que:

$$\cos(f_\theta(x), f_\theta(x^+)) \gg \cos(f_\theta(x), f_\theta(x^-))$$

- x : *anchor*
- x^+ : positivo (semanticamente similar)
- x^- : negativo (diferente)

Não precisa de rótulos explícitos, basta **pares positivos**.



Direção do gradiente: puxa x^+ para perto, empurra x^- para longe.

De Onde Vêm os Pares Positivos?

Pares *naturais* (supervisão fraca)

- Pergunta $\leftrightarrow$ resposta (StackExchange, Quora)
- Título $\leftrightarrow$ corpo (notícias, artigos)
- Parágrafos adjacentes
- Pares *query* $\leftrightarrow$ *click* de *logs*
- Traduções (mesma frase em línguas diferentes)

Pares *anotados* (supervisão forte)

- NLI (SNLI, MultiNLI): *entailment* $\rightarrow$ positivo, *contradiction* $\rightarrow$ negativo
- Duplicatas do Quora
- MS MARCO: *query* $\rightarrow$ passagem relevante (relevância humana)
- Paráfrases geradas por humanos

Escala importa

Modelos modernos (e5, bge) treinam com **centenas de milhões** de pares positivos coletados da web com supervisão fraca, depois fazem *fine-tuning* em dados anotados.

Triplet Loss

Originário do **FaceNet**⁸ para reconhecimento facial.

Formulação

$$\mathcal{L}_{\text{triplet}} = \max\left(0, \|f(x) - f(x^+)\|_2^2 - \|f(x) - f(x^-)\|_2^2 + \alpha\right)$$

onde $\alpha > 0$ é a **margem**.

- A perda é zero quando o positivo está pelo menos α mais próximo que o negativo
- **Margem** evita colapso trivial (todas as representações iguais)
- Funciona, mas precisa de **triplos** (x, x^+, x^-) construídos explicitamente
- Limitação: **um único negativo por anchor** $\rightarrow$ pouco sinal por *step*

A continuação natural é usar **muitos** negativos de uma vez...

⁸Florian Schroff, Dmitry Kalenichenko e James Philbin. “FaceNet: A Unified Embedding for Face Recognition and Clustering”. Em: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015, pp. 815–823.

InfoNCE / Multiple Negatives Ranking Loss⁹

Formulação

Para um *batch* de N pares (x_i, x_i^+) e todos os outros exemplos como negativos:

$$\mathcal{L}_{\text{NCE}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(f(x_i), f(x_i^+))/\tau)}{\sum_{j=1}^N \exp(\text{sim}(f(x_i), f(x_j^+))/\tau)}$$

- sim : produto escalar ou cosseno
- τ : **temperatura** (tipicamente $\tau = 0,05$ a $0,1$)
- **In-batch negatives**: cada x_j^+ com $j \neq i$ atua como negativo para x_i
- Equivale a um problema de **classificação** de N vias: “qual dos N candidatos é o verdadeiro par?”

⁹Aaron van den Oord, Yazhe Li e Oriol Vinyals. “Representation Learning with Contrastive Predictive Coding”. Em: [arXiv preprint arXiv:1807.03748](https://arxiv.org/abs/1807.03748) (2018).

In-Batch Negatives: Exemplo Visual

Batch de 4 pares: $(q_1, d_1), (q_2, d_2), (q_3, d_3), (q_4, d_4)$.

	d_1	d_2	d_3	d_4
q_1	+			
q_2		+		
q_3			+	
q_4				+

- Matriz $S_{ij} = \text{sim}(f(q_i), f(d_j))/\tau$
- Aplica-se *softmax* em cada **linha**
- Alvo: classe i (a diagonal) $\rightarrow$ *cross-entropy*
- Os 3 elementos **fora da diagonal** de cada linha são **negativos** “grátis”
- *Batches* grandes ($N = 256, 1024, \dots$) $\rightarrow$ mais negativos $\rightarrow$ gradiente mais informativo


Negativos Aleatórios Saturam

No início do treino, negativos aleatórios são informativos: quase todos dão gradiente.

Depois de algumas épocas:

- A maioria dos negativos aleatórios é **trivialmente diferente** do *anchor*
- Já estão longe no espaço
- Gradiente próximo de zero → **sem sinal de aprendizado**
- O modelo “atinge um platô”

Precisamos de negativos que o modelo ainda confunda com positivos.



Ilustrativo: negativos aleatórios saturam, negativos duros continuam informativos.

Hard Negative Mining

Ideia: buscar ativamente negativos que estão **próximos** do *anchor* no espaço atual.

Estratégia 1: BM25 / léxica

- Para cada *query*, pegue documentos **não relevantes** mas com **alta sobreposição lexical**
- Rápido e sem modelo
- Usado em DPR^a

^aVladimir Karpukhin et al. “Dense Passage Retrieval for Open-Domain Question Answering”. Em: [Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing](#), 2020, pp. 6769–6781.

Estratégia 2: auto-mineração

- Usa o **checkpoint atual** para codificar o corpus
- Seleciona os *top-k* vizinhos mais próximos (excluindo o positivo)
- Atualiza os negativos **periodicamente**
- Usado em ANCE^a

^aLee Xiong et al. “Approximate Nearest Neighbor Negative Contrastive Learning for Dense Text Retrieval”. Em: [International Conference on Learning Representations](#). 2021.

Ordenado por dificuldade: léxica < auto-minerada < adversarial.

A Armadilha dos *False Negatives*

Nem todo “negativo próximo” é realmente negativo.

Exemplo

Query: “Qual a capital do Brasil?”

Positivo rotulado: “Brasília é a capital.”

“Negativo” minerado: “A cidade de Brasília foi inaugurada em 1960 como capital.”

O segundo parágrafo é **tão relevante** quanto o positivo, mas não foi anotado. Treiná-lo como negativo ensina o modelo errado.

Mitigações

- Filtrar negativos com *score* muito alto (pode ser falso negativo)
- Usar um **cross-encoder** para re-verificar
- *Consistency filtering* entre modelos
- **In-batch** com lotes grandes é menos suscetível (muitos negativos, baixa probabilidade de colisão)

Notas Práticas: Temperatura e Tamanho de *Batch*

Temperatura τ

- τ pequeno (*e.g.* 0,05) $\rightarrow$ *softmax* “afiada”, foca nos mais difíceis
- τ grande (*e.g.* 0,2) $\rightarrow$ distribuição mais plana, gradiente mais suave
- **Hiperparâmetro crítico:** valores errados podem impedir convergência
- Valor típico: 0,05–0,1

Tamanho de *batch* N

- Mais *in-batch* negatives $\rightarrow$ melhor treino
- Modelos SOTA usam $N = 1024\text{--}16\,384$
- Técnicas: *gradient cache*, *GradCache*, *cross-batch* negatives
- **Lei empírica:** desempenho escala com $\log N$

Receita moderna

Temperatura aprendida (τ como parâmetro treinável) + *batches* grandes + mistura de positivos naturais e minerados difíceis. Similar ao *CLIP* em visão computacional.

Overview

1. Paradigmas Arquiteturais do Transformer
2. De Embeddings Estáticos a Contextuais
3. Tarefas em Nível de *Token*
4. BERT
5. De *Tokens* a Sentenças: *Sentence Embeddings*
6. Aprendizado Contrastivo
- 7. SBERT: *Sentence-BERT***
8. Tarefas e Avaliação de *Sentence Embeddings*
9. Encerramento

SBERT: O Primeiro *Sentence Encoder* Prático¹⁰

Problema

BERT *vanilla* é lento demais para busca semântica em escala (cross-encoder $O(n^2)$) e seus *embeddings* ingênuos são **piores que GloVe** em STS.


Solução

Fazer **fine-tuning supervisionado** no BERT usando uma arquitetura **siamesa** que produz embeddings densos, rápidos e semanticamente estruturados.

Impacto: a *library sentence-transformers* popularizou a técnica e hoje é a base de quase todos os sistemas de busca semântica em produção.

¹⁰Nils Reimers e Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. Em: *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2019, pp. 3982–3992.

Arquitetura Siamesa do SBERT



- **Dois** *forward passes* com o **mesmo** BERT
- *Mean pooling* sobre os *tokens* (ignorando *padding*)
- A função-objetivo depende da tarefa de treinamento

Três Objetivos de Treinamento

(1) Classificação (NLI)

Concatenar $(\mathbf{u}, \mathbf{v}, |\mathbf{u} - \mathbf{v}|)$ e alimentar um classificador linear de 3 classes:

$$y = W^T [\mathbf{u}; \mathbf{v}; |\mathbf{u} - \mathbf{v}|]$$

Usado em SNLI + MultiNLI ($\sim 1\text{M}$ pares).

(2) Regressão (STS)

Perda MSE entre o cosseno e o *score* humano:

$$\mathcal{L} = (\cos(\mathbf{u}, \mathbf{v}) - s_{\text{humano}})^2$$

Usado no STS-Benchmark.

(3) Triplet

$$\mathcal{L} = \max(0, \|\mathbf{u}_a - \mathbf{u}_p\| - \|\mathbf{u}_a - \mathbf{u}_n\| + \alpha)$$

Usado quando se tem triplas (*anchor*, positivo, negativo).

Receita no paper: treinar primeiro em NLI (classificação), depois fazer *fine-tuning* em STS (regressão) $\rightarrow$ melhor *transfer*.

Resultados do SBERT

Modelo	Spearman em STS-b
GloVe (média)	58,02
BERT [CLS] <i>vanilla</i>	20,29
BERT <i>mean pooling</i>	46,35
SBERT-base	79,23
SBERT-large	79,19

- **BERT *vanilla* é pior que GloVe** → motivação original
- **SBERT** melhora $\sim 30+$ pontos sobre BERT, ~ 20 sobre GloVe
- Mesma arquitetura base, apenas **mudou o objetivo de treino**

Lição fundamental: o **objetivo de treino** importa tanto quanto a arquitetura.

Aplicações do SBERT (e Descendentes)

Busca semântica

- Substitui BM25 ou o complementa
- Base de motores de busca empresariais
- Indexação com FAISS / HNSW

RAG (*Retrieval-Augmented Generation*)

- Recupera contexto para LLMs
- Reduz alucinações
- Permite atualizações sem re-treino

Deduplicação

- Detecção de quase-duplicatas em grandes corpora
- Limpeza de dados de treino para LLMs

Recomendação item-a-item

- Produtos, artigos, *posts*
- “Mais como este” baseado em texto

Análise de tópicos

- Clustering + visualização
- *BERTopic*, *Top2Vec*

O Legado do SBERT

Os melhores modelos de *embedding* de hoje seguem a **mesma receita** do SBERT.

Família	Organização	Característica distintiva
e5 [18]	Microsoft	Pré-treino contrastivo fraco + <i>fine-tuning</i> supervisionado
bge [19]	BAAI	Multilíngue, forte <i>retrieval</i> , variante <i>reranker</i>
GTE	Alibaba	Foco em generalização entre domínios
Nomic	Nomic AI	Código aberto, dados públicos, alto <i>context length</i>
Jina	Jina AI	<i>Long context</i> (8k+), multilíngue

- Todos usam **aprendizado contrastivo** em **centenas de milhões** de pares
- Maioria usa **hard negative mining**
- **Top-10 do MTEB** inclui modelos de $\sim 7\text{B}$ parâmetros, treinados com *instruction tuning*
- A receita SBERT (2019) continua fundamentalmente válida

O Legado do SBERT

A receita que dominou o campo

1. Comece de um *encoder* pré-treinado (BERT, RoBERTa, ...)
 2. Arquitetura siamesa com *mean pooling*
 3. Aprendizado contrastivo com **in-batch negatives**
 4. *Hard negative mining* para a fase final
 5. Treinar em dados diversos e supervisionados
- Funciona do tamanho de 110M até 7B parâmetros
 - Funciona em inglês, português, multilingue
 - Base de todos os sistemas de RAG em produção
 - Ainda é a forma **mais eficiente** de comparar textos em escala

Overview

1. Paradigmas Arquiteturais do Transformer
2. De Embeddings Estáticos a Contextuais
3. Tarefas em Nível de *Token*
4. BERT
5. De *Tokens* a Sentenças: *Sentence Embeddings*
6. Aprendizado Contrastivo
7. SBERT: *Sentence-BERT*
- 8. Tarefas e Avaliação de *Sentence Embeddings***
9. Encerramento

Tarefa: *Retrieval* (Busca Semântica)

Objetivo: dado uma *query*, encontrar os documentos mais relevantes em um corpus de milhões/bilhões. **Pipeline offline:**

1. Codifica todo o corpus em vetores
2. Armazena em um índice vetorial (FAISS, HNSW, ScaNN)

Pipeline online:

1. Codifica a *query*
2. Busca *top-k* por similaridade cosseno
3. Retorna os documentos (ou passa para um *reranker*)

Fundamental para RAG

RAG (*Retrieval-Augmented Generation*):

1. Recupera documentos relevantes (**bi-encoder**)
2. Alimenta um LLM com eles
3. LLM gera resposta *grounded*

Tarefa: *Clustering*

Objetivo: agrupar documentos semanticamente similares **sem rótulos**. **Pipeline:**

1. Codifica os documentos
2. Aplica k -means, *agglomerative clustering* ou HDBSCAN
3. Extrai tópicos / rótulos por *cluster*

Aplicações:

- Descoberta de tópicos em *feedback* de usuários
- Organização de *base* de conhecimento
- Detecção de spam / clones
- Visualização exploratória (com UMAP/t-SNE)

Tarefa: Classificação via *Linear Probe*

Ideia: congelar o *encoder*, treinar apenas um classificador linear sobre os *embeddings*.

Receita:

1. Codifica n exemplos rotulados em vetores
2. Treina *logistic regression* ou SVM
3. Avalia em *test set*

Benchmark de qualidade de embeddings

O *linear probe accuracy* é uma medida padrão de **quão útil** um *embedding* é para tarefas *downstream*:

- Alta acurácia $\rightarrow$ informação linear-separável presente
- Baixa acurácia $\rightarrow$ *embedding* ruim ou precisa de cabeça não-linear

Tarefa: *Semantic Textual Similarity (STS)*¹¹

Prever um *score* de similaridade em $[0, 5]$ para um par de frases.

Exemplos do *benchmark* STS

Frase A	Frase B	Score
Um homem está tocando piano.	Um cara toca teclado.	4,2
Um gato preto dorme.	Um cão branco corre.	0,8
A menina está comendo.	A garota está jantando.	3,9

- **Avaliação: correlação de Spearman** entre cosseno predito e *score* humano
- Mede quão bem o espaço de *embeddings* reflete similaridade semântica
- Não requer *fine-tuning*: avalia diretamente a similaridade cosseno

¹¹Daniel Cer et al. “SemEval-2017 Task 1: Semantic Textual Similarity Multilingual and Crosslingual Focused Evaluation”. Em: [Proceedings of the 11th International Workshop on Semantic Evaluation \(SemEval-2017\)](#). 2017, pp. 1–14.

Spearman vs Pearson: Por quê?

Pearson: correlação **linear**

$$r = \frac{\text{cov}(x, y)}{\sigma_x \sigma_y}$$

Exige que a relação entre x e y seja **linear**.

Spearman: correlação **monotônica**

$$\rho = \text{Pearson}(\text{rank}(x), \text{rank}(y))$$

Exige apenas que a **ordem** seja preservada.

Por que Spearman em STS?

- *Scores* humanos em $[0, 5]$ são subjetivos; a escala **não é linear**
- Cosseno $\in [-1, 1]$ vive numa escala diferente, só o **ranking** importa
- Queremos que pares mais similares fiquem **acima** de pares menos similares

Spearman vs Pearson: Exemplo

- Suponha que o modelo preveja **o quadrado** do *score* humano ($\hat{y} = y^2$)
- **Pearson** $\approx 0,96$ (penaliza a não-linearidade).
- **Spearman** = 1,00 (ordem idêntica)
- Com curvatura maior, Pearson degrada ainda mais, apesar do ranking **continuar perfeito**.

Humano	y	1	2	3	4	5
Modelo	$\hat{y}$	1	4	9	16	25

Tarefa 5: *Natural Language Inference* (NLI)¹²

Tarefa: dada uma *premissa* P e uma *hipótese* H , classificar em:

- **Entailment:** P implica H
- **Contradiction:** P e H se contradizem
- **Neutral:** nem uma coisa nem outra

Premise	Hypothesis	Rótulo
Um homem joga futebol.	Uma pessoa pratica esporte.	entailment
Um homem joga futebol.	Ele está dormindo.	contradiction
Um homem joga futebol.	Ele é profissional.	neutral

Duplo papel: NLI é (1) tarefa de avaliação e (2) fonte de sinal de treino para SBERT, através do mapeamento *entailment* $\rightarrow$ positivo, *contradiction* $\rightarrow$ negativo duro.

¹²Samuel R. Bowman et al. “A Large Annotated Corpus for Learning Natural Language Inference”. Em: *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2015, pp. 632–642.

MTEB: *Massive Text Embedding Benchmark*

¹³ O **MTEB** é o *benchmark* padrão moderno para *sentence embeddings*.

- 8 tarefas de *embedding*
 - Classification
 - Clustering
 - Pair Classification
 - Reranking
 - Retrieval
 - STS
 - Summarization
 - *Bitext Mining* (multilíngue)
- > 60 *datasets*
- > 100 línguas
- *Leaderboard* público no Hugging Face

Por que ele mudou o jogo

Antes do MTEB, cada *paper* escolhia seu próprio *benchmark* favorito.

O MTEB forçou avaliação **uniforme** e revelou que modelos “*SOTA em STS*” eram muito mais fracos em *retrieval*.

Um **embedding generalista** é aquele que vai bem em **todas** as categorias.

¹³Niklas Muennighoff et al. “MTEB: Massive Text Embedding Benchmark”. Em: *Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics*. 2023, pp. 2014–2037.

Overview

1. Paradigmas Arquiteturais do Transformer
2. De Embeddings Estáticos a Contextuais
3. Tarefas em Nível de *Token*
4. BERT
5. De *Tokens* a Sentenças: *Sentence Embeddings*
6. Aprendizado Contrastivo
7. SBERT: *Sentence-BERT*
8. Tarefas e Avaliação de *Sentence Embeddings*
- 9. Encerramento**

Recap: Quando Usar o Quê

Encoder-only

- Classificação de texto
- NER, POS, QA extrativa
- **Busca semântica / RAG retrieval**
- *Clustering*, deduplicação
- Quando latência e custo importam
- Modelos pequenos (30M–7B) são suficientes

Decoder-only

- Geração aberta
- *Chat*, criação de conteúdo
- *Reasoning*, código
- *In-context learning* e *few-shot*
- Quando qualidade de geração importa mais que latência
- Modelos grandes (7B+) dominam

Sistemas reais usam os dois: encoder-only para indexar e buscar, decoder-only para gerar a resposta final (RAG).

Takeaways

1. **Contextual embeddings** (BERT, RoBERTa) resolvem a polissemia que atormentava Word2Vec/GloVe, e são a base de quase todas as tarefas de compreensão de texto.
2. **BERT** popularizou a receita *pré-treino MLM* → *fine-tuning*. A contribuição duradoura não é o modelo em si, mas o **paradigma**.
3. **BERT vanilla é ruim para similaridade de frases**. Precisamos treinar explicitamente para isso → **aprendizado contrastivo**.
4. **SBERT** mostrou como: arquitetura siamesa, *mean pooling*, perda contrastiva com *in-batch negatives* e *hard negative mining*.
5. Modelos de *embedding* modernos (**e5**, **bge**, **GTE**, **Nomic**) seguem a mesma receita em escala.

Referências I

- [1] Samuel R. Bowman et al. “A Large Annotated Corpus for Learning Natural Language Inference”. Em: [Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing \(EMNLP\)](#). 2015, pp. 632–642.
- [2] Daniel Cer et al. “SemEval-2017 Task 1: Semantic Textual Similarity Multilingual and Crosslingual Focused Evaluation”. Em: [Proceedings of the 11th International Workshop on Semantic Evaluation \(SemEval-2017\)](#). 2017, pp. 1–14.
- [3] Kevin Clark et al. “ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators”. Em: [International Conference on Learning Representations](#). 2020.
- [4] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. Em: [Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human I](#) 2019, pp. 4171–4186.
- [5] Pengcheng He et al. “DeBERTa: Decoding-enhanced BERT with Disentangled Attention”. Em: [International Conference on Learning Representations](#). 2021.
- [6] Vladimir Karpukhin et al. “Dense Passage Retrieval for Open-Domain Question Answering”. Em: [Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing \(EMNLP\)](#). 2020, pp. 6769–6781.
- [7] Zhenzhong Lan et al. “ALBERT: A Lite BERT for Self-supervised Learning of Language Representations”. Em: [International Conference on Learning Representations](#). 2020.
- [8] Yinhan Liu et al. “RoBERTa: A Robustly Optimized BERT Pretraining Approach”. Em: [arXiv preprint arXiv:1907.11692](#) (2019).
- [9] Tomas Mikolov et al. “Distributed Representations of Words and Phrases and their Compositionality”. Em: [Advances in Neural Information Processing Systems](#). Vol. 26. 2013.

Referências II

- [10] Niklas Muennighoff et al. “MTEB: Massive Text Embedding Benchmark”. Em: [Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics](#). 2023, pp. 2014–2037.
- [11] Aaron van den Oord, Yazhe Li e Oriol Vinyals. “Representation Learning with Contrastive Predictive Coding”. Em: [arXiv preprint arXiv:1807.03748](#) (2018).
- [12] Jeffrey Pennington, Richard Socher e Christopher D. Manning. “GloVe: Global Vectors for Word Representation”. Em: [Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing \(EMNLP\)](#). 2014, pp. 1532–1543.
- [13] Matthew E. Peters et al. “Deep Contextualized Word Representations”. Em: [Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human I](#) 2018, pp. 2227–2237.
- [14] Pranav Rajpurkar et al. “SQuAD: 100,000+ Questions for Machine Comprehension of Text”. Em: [Proceedings of the 2016 Conference on Empirical Methods in Natural Language Processing \(EMNLP\)](#). 2016, pp. 2383–2392.
- [15] Nils Reimers e Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. Em: [Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing \(EMNLP\)](#). 2019, pp. 3982–3992.
- [16] Florian Schroff, Dmitry Kalenichenko e James Philbin. “FaceNet: A Unified Embedding for Face Recognition and Clustering”. Em: [Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition \(CVPR\)](#). 2015, pp. 815–823.
- [17] Erik F. Tjong Kim Sang e Fien De Meulder. “Introduction to the CoNLL-2003 Shared Task: Language-Independent Named Entity Recognition”. Em: [Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL 2003](#). 2003, pp. 142–147.

Referências III

- [18] Liang Wang et al. “Text Embeddings by Weakly-Supervised Contrastive Pre-training”. Em: [arXiv preprint arXiv:2212.03533](#) (2022).
- [19] Shitao Xiao et al. “C-Pack: Packed Resources For General Chinese Embeddings”. Em: [Proceedings of SIGIR 2024](#) (2024).
- [20] Lee Xiong et al. “Approximate Nearest Neighbor Negative Contrastive Learning for Dense Text Retrieval”. Em: [International Conference on Learning Representations](#). 2021.