

# Deep Learning

## Inicialização de Pesos: Explosão e Dissipação de Gradientes

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory  
PUCRS

maio de 2026

# Visão Geral

---

1. Por que inicialização importa
2. Estudo de caso: MNIST com tanh
3. Forward pass: média da pré-ativação
4. Forward pass: variância da pré-ativação
5. Exercício teórico
6. Inicialização He / Kaiming
7. Voltando ao MNIST
8. Forward + Backward
9. Diretrizes práticas


# Overview

---

1. Por que inicialização importa
2. Estudo de caso: MNIST com tanh
3. Forward pass: média da pré-ativação
4. Forward pass: variância da pré-ativação
5. Exercício teórico
6. Inicialização He / Kaiming
7. Voltando ao MNIST
8. Forward + Backward
9. Diretrizes práticas

## Recap: nem toda ativação preserva o gradiente

- Sigmoid e tanh **saturam** para  $|z|$  grande, com derivada tendendo a zero.
- ReLU e variantes preservam gradiente no lado positivo.
- A combinação **inicialização**  $\times$  **ativação** controla a magnitude do sinal que se propaga em forward e em backward.



## No início do treino, só os pesos definem o sinal

---

- Antes da primeira atualização, a rede não foi ajustada aos dados.
- A magnitude das ativações em cada camada é determinada inteiramente pelos pesos iniciais e pelas funções de ativação.
- Se a magnitude crescer ou encolher exponencialmente camada após camada, o gradiente faz o mesmo.

## Vanishing e exploding gradients

---

- **Vanishing gradient:** gradientes encolhem a cada camada, camadas iniciais não recebem sinal de aprendizagem.
- **Exploding gradient:** gradientes crescem a cada camada, atualizações ficam instáveis numericamente.
- Ambos os casos quebram a descida de gradiente.
- A inicialização **certa** mantém a variância das pré-ativações aproximadamente constante ao longo das camadas.

# Overview


---

1. Por que inicialização importa
- 2. Estudo de caso: MNIST com tanh**
3. Forward pass: média da pré-ativação
4. Forward pass: variância da pré-ativação
5. Exercício teórico
6. Inicialização He / Kaiming
7. Voltando ao MNIST
8. Forward + Backward
9. Diretrizes práticas

# Setup do estudo de caso




- Dataset: MNIST, dígitos manuscritos.
- Arquitetura: MLP com 5 camadas, todas com 300 unidades tanh, saída softmax com 10 classes.
- Tamanho do *batch*: 100 imagens.
- Vamos olhar o histograma das ativações  $A^{[1]}, \dots, A^{[4]}$  em cada camada oculta.




## Tentativa 1: $\theta = 0$

- Pesos iniciais zerados.
- Toda unidade computa a mesma pré-ativação.
- Todas as ativações colapsam em 0.
- Por simetria, qualquer atualização afeta todas as unidades igualmente: a rede nunca quebra a simetria.



## Tentativa 2: $\theta \sim \mathcal{N}(0, 1)$


- Pesos com variância 1.
- As pré-ativações de cada camada explodem em magnitude.
- A tanh **satura** em  $\pm 1$ .
- Em camadas internas, quase todas as unidades estão na região de derivada nula.



Massa concentrada em  $\pm 1$ : zona morta da tanh.

## Tentativa 3: $\theta \sim \mathcal{U}(-1, 1)$

- Variância  $\sigma_{\theta}^2 = 1/3$ , menor que o caso anterior.
- Mesmo assim, as ativações **encolhem** a cada camada.
- Em  $A^{[4]}$  a distribuição é uma agulha em zero.
- Sintoma de *vanishing* em forward.



## Precisamos calibrar $\sigma_{\theta}^2$ por camada

---

- Inicializações ad-hoc falham de formas opostas dependendo da escala.
- A escala certa depende do número de unidades de entrada de cada camada e da função de ativação utilizada.
- Visualização interativa que motiva a derivação:

[deeplearning.ai: Initialization notes](#)

# Overview

---

1. Por que inicialização importa
2. Estudo de caso: MNIST com tanh
- 3. Forward pass: média da pré-ativação**
4. Forward pass: variância da pré-ativação
5. Exercício teórico
6. Inicialização He / Kaiming
7. Voltando ao MNIST
8. Forward + Backward
9. Diretrizes práticas

## Definição da pré-ativação por camada

---

$$z_i^{(l)} = b_i^{(l)} + \sum_{j=1}^{n^{(l-1)}} \theta_{ij}^{(l)} \varphi(z_j^{(l-1)})$$

- $z^{(l)}$ : pré-ativação da camada  $l$ .
- $b^{(l)}$ : bias, **inicializado em 0**.
- $\theta^{(l)}$ : pesos,  $\theta_{ij}^{(l)} \sim \mathcal{N}(0, \sigma_\theta^2)$ .
- $\varphi$ : ativação (tomamos ReLU como referência).

### Hipóteses

$\theta_{ij}^{(l)}$  independentes entre si e independentes de  $\varphi(z_j^{(l-1)})$ . A distribuição de  $z_j^{(l-1)}$  é simétrica em zero.

## Esperança: separar bias do somatório

---

Aplicando a linearidade da esperança:

$$E[z_i^{(l)}] = E[b_i^{(l)}] + E\left[\sum_{j=1}^{n^{(l-1)}} \theta_{ij}^{(l)} \varphi(z_j^{(l-1)})\right].$$

- Como inicializamos  $b_i^{(l)} = 0$ ,  $E[b_i^{(l)}] = 0$ .
- Sobra a esperança do somatório, que reescrevemos como soma das esperanças.

$$E[z_i^{(l)}] = \sum_{j=1}^{n^{(l-1)}} E\left[\theta_{ij}^{(l)} \varphi(z_j^{(l-1)})\right].$$

## Esperança: independência $\theta \perp \varphi$

---

Como  $\theta_{ij}^{(l)}$  é independente de  $\varphi(z_j^{(l-1)})$ ,

$$E\left[\theta_{ij}^{(l)} \varphi(z_j^{(l-1)})\right] = E[\theta_{ij}^{(l)}] E[\varphi(z_j^{(l-1)})].$$

- Por construção,  $\theta_{ij}^{(l)} \sim \mathcal{N}(0, \sigma_\theta^2)$ , logo  $E[\theta_{ij}^{(l)}] = 0$ .
- O produto inteiro é zero, independentemente de  $\varphi$ .

$$E[z_i^{(l)}] = \sum_{j=1}^{n^{(l-1)}} 0 \cdot E[\varphi(z_j^{(l-1)})] = 0.$$

## Resultado intermediário

---

Média das pré-ativações é zero

$$E[z_i^{(l)}] = 0 \quad \text{para toda camada } l.$$

- Vamos usar este resultado para calcular a variância em seguida.
- Como  $E[z_i^{(l)}] = 0$ , temos  $\text{Var}[z_i^{(l)}] = E[(z_i^{(l)})^2]$ .

# Overview

---

1. Por que inicialização importa
2. Estudo de caso: MNIST com tanh
3. Forward pass: média da pré-ativação
- 4. Forward pass: variância da pré-ativação**
5. Exercício teórico
6. Inicialização He / Kaiming
7. Voltando ao MNIST
8. Forward + Backward
9. Diretrizes práticas

## Variância: ponto de partida

---

$$\sigma_{z^{(l)}}^2 = E\left[(z_i^{(l)})^2\right] - \cancel{(E[z_i^{(l)}])^2} \overset{0}{=} E\left[\left(b_i^{(l)} + \sum_j \theta_{ij}^{(l)} \varphi(z_j^{(l-1)})\right)^2\right].$$

- Como  $b_i^{(l)} = 0$ , expandimos sem o termo do bias.
- Cross-terms entre pesos diferentes desaparecem por independência e  $E[\theta] = 0$ .

$$\sigma_{z^{(l)}}^2 = \sum_{j=1}^{n^{(l-1)}} E\left[(\theta_{ij}^{(l)})^2\right] E\left[\varphi(z_j^{(l-1)})^2\right].$$

## Identificando $\sigma_\theta^2$

---

Como  $\theta_{ij}^{(l)} \sim \mathcal{N}(0, \sigma_\theta^2)$  e  $E[\theta] = 0$ :

$$E\left[(\theta_{ij}^{(l)})^2\right] = \text{Var}[\theta_{ij}^{(l)}] = \sigma_\theta^2.$$

Substituindo:

$$\sigma_{z^{(l)}}^2 = \sigma_\theta^2 \sum_{j=1}^{n^{(l-1)}} E\left[\varphi(z_j^{(l-1)})^2\right].$$

- Falta calcular  $E[\varphi(z)^2]$  para  $\varphi = \text{ReLU}$ .

## Para ReLU sobre $z$ simétrica em zero

---

Vamos provar (próximo slide) que, se  $z$  é simétrica em zero com variância  $\sigma_z^2$ ,

$$E[\text{ReLU}(z)^2] = \frac{\sigma_z^2}{2}.$$

- ReLU corta os valores negativos, mantendo metade da massa.
- A simetria garante que a metade positiva tem o mesmo segundo momento da distribuição inteira, dividido por 2.

## Variância da pré-ativação em função de $\sigma_\theta^2$ e $\sigma_{z^{(l-1)}}^2$

Aplicando o resultado anterior,  $E[\varphi(z_j^{(l-1)})^2] = \sigma_{z^{(l-1)}}^2 / 2$  para toda unidade  $j$ :

$$\sigma_{z^{(l)}}^2 = \sigma_\theta^2 \sum_{j=1}^{n^{(l-1)}} \frac{\sigma_{z^{(l-1)}}^2}{2} = \frac{n^{(l-1)}}{2} \sigma_\theta^2 \sigma_{z^{(l-1)}}^2.$$

### Recorrência para a variância

$$\sigma_{z^{(l)}}^2 = \frac{n^{(l-1)}}{2} \sigma_\theta^2 \sigma_{z^{(l-1)}}^2$$

- Se a constante  $\frac{n^{(l-1)}}{2} \sigma_\theta^2$  for maior que 1, exploding.
- Se for menor que 1, vanishing. Queremos exatamente 1.

# Overview

---

1. Por que inicialização importa
2. Estudo de caso: MNIST com tanh
3. Forward pass: média da pré-ativação
4. Forward pass: variância da pré-ativação
- 5. Exercício teórico**
6. Inicialização He / Kaiming
7. Voltando ao MNIST
8. Forward + Backward
9. Diretrizes práticas

## Exercício: segundo momento de ReLU

---

### Enunciado

Seja  $a$  uma variável aleatória contínua, simétrica em torno de  $E[a] = 0$ , com variância  $\text{Var}[a] = \sigma^2$ . Mostre que

$$E[\text{ReLU}(a)^2] = \frac{\sigma^2}{2}.$$

- Lembre que  $\text{ReLU}(a) = \max(0, a)$ .
- Use  $E[a^2] = \text{Var}[a] + (E[a])^2 = \sigma^2$ .
- Use a simetria de  $a$  em torno de zero.

## Solução

---

Pela definição de ReLU:

$$E[\text{ReLU}(a)^2] = \int_{-\infty}^{\infty} \max(0, a)^2 p(a) da = \int_0^{\infty} a^2 p(a) da.$$

Pela simetria de  $p$  em torno de zero,  $\int_{-\infty}^0 a^2 p(a) da = \int_0^{\infty} a^2 p(a) da$ . Logo,

$$E[a^2] = 2 \int_0^{\infty} a^2 p(a) da \implies \int_0^{\infty} a^2 p(a) da = \frac{E[a^2]}{2} = \frac{\sigma^2}{2}.$$

$$E[\text{ReLU}(a)^2] = \frac{\sigma^2}{2}.$$

# Overview

---

1. Por que inicialização importa
2. Estudo de caso: MNIST com tanh
3. Forward pass: média da pré-ativação
4. Forward pass: variância da pré-ativação
5. Exercício teórico
- 6. Inicialização He / Kaiming**
7. Voltando ao MNIST
8. Forward + Backward
9. Diretrizes práticas

## Condição: variância igual a cada camada

---

Queremos  $\sigma_{z^{(l)}}^2 = \sigma_{z^{(l-1)}}^2$  para todo  $l$ . Da recorrência,

$$\sigma_{z^{(l-1)}}^2 = \frac{n^{(l-1)}}{2} \sigma_{\theta}^2 \sigma_{z^{(l-1)}}^2 \implies \frac{n^{(l-1)}}{2} \sigma_{\theta}^2 = 1.$$

He / Kaiming

$$\boxed{\sigma_{\theta}^2 = \frac{2}{n^{(l-1)}}} \quad \theta_{ij}^{(l)} \sim \mathcal{N}\left(0, \frac{2}{n^{(l-1)}}\right).$$

- $n^{(l-1)}$  é o número de *fan-in* da camada (entradas).
- Padrão de fato para ReLU e GELU.

# Origem da inicialização He<sup>1</sup>

---

- Apresentada em 2015 por Kaiming He et al. para redes muito profundas com ReLU.
- Permitiu treinar redes com mais de 30 camadas convolucionais sem *batch norm*.
- Variante uniforme:  $\theta \sim \mathcal{U}\left(-\sqrt{6/n}, \sqrt{6/n}\right)$ , que tem a mesma variância  $2/n$ .

---

<sup>1</sup>Kaiming He et al. "Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification". Em: [ICCV](#). 2015.

## Inicialização Xavier (Glorot)<sup>2</sup>

---

- Antes de He, Glorot e Bengio (2010) fizeram o mesmo argumento para **tanh** ao redor de zero.
- Para tanh,  $\varphi(z) \approx z$  perto da origem, então  $E[\varphi(z)^2] \approx \sigma_z^2$  sem o fator 1/2.
- Isso leva a  $\sigma_\theta^2 = 1/n^{(l-1)}$ .

$$\boxed{\sigma_\theta^2 = \frac{1}{n^{(l-1)}}} \quad \theta_{ij}^{(l)} \sim \mathcal{N}\left(0, \frac{1}{n^{(l-1)}}\right).$$

- Padrão para sigmoid, tanh e softmax.

---


<sup>2</sup>Xavier Glorot e Yoshua Bengio. "Understanding the difficulty of training deep feedforward neural networks". Em: [AISTATS](#). 2010.

# Overview

---





1. Por que inicialização importa
2. Estudo de caso: MNIST com tanh
3. Forward pass: média da pré-ativação
4. Forward pass: variância da pré-ativação
5. Exercício teórico
6. Inicialização He / Kaiming
- 7. Voltando ao MNIST**
8. Forward + Backward
9. Diretrizes práticas

## Mesmo MLP, agora com inicialização He



- Histogramas das ativações  $A^{[1]}, \dots, A^{[4]}$  ficam estáveis ao longo das camadas.
- A magnitude não cresce nem encolhe, e a tanh não satura.
- A rede consegue treinar.

# Comparação visual das quatro inicializações



# Overview

---

1. Por que inicialização importa
2. Estudo de caso: MNIST com tanh
3. Forward pass: média da pré-ativação
4. Forward pass: variância da pré-ativação
5. Exercício teórico
6. Inicialização He / Kaiming
7. Voltando ao MNIST
- 8. Forward + Backward**
9. Diretrizes práticas

## O argumento simétrico para o gradiente

---

- O mesmo raciocínio aplicado à variância dos gradientes em *backward* leva a uma condição análoga.
- Em vez de  $n^{(l-1)}$  (*fan-in*), aparece  $n^{(l)}$  (*fan-out*):  $\sigma_{\theta}^2 = 2/n^{(l)}$ .
- Os dois lados nem sempre são compatíveis (camadas com formas diferentes).

## Compromisso *fan\_avg*

---

Glorot propôs balancear forward e backward usando a média de  $n^{(l-1)}$  e  $n^{(l)}$ :

$$\sigma_{\theta}^2 = \frac{2}{n^{(l-1)} + n^{(l)}} \quad (\text{Xavier})$$

$$\sigma_{\theta}^2 = \frac{4}{n^{(l-1)} + n^{(l)}} \quad (\text{He, fan\_avg})$$

- Conhecido como *fan\_avg* em frameworks.
- Em camadas onde  $n^{(l-1)} = n^{(l)}$ , recupera as fórmulas originais.

A versão He original do paper (He et al. 2015) usa apenas *fan\_in* ( $2/n^{(l-1)}$ ); a variante *fan\_avg* acima é a implementada por padrão em PyTorch e Keras.

# Overview

---

1. Por que inicialização importa
2. Estudo de caso: MNIST com tanh
3. Forward pass: média da pré-ativação
4. Forward pass: variância da pré-ativação
5. Exercício teórico
6. Inicialização He / Kaiming
7. Voltando ao MNIST
8. Forward + Backward
- 9. Diretrizes práticas**

## Qual inicialização usar?

---

| Ativação principal    | Inicialização recomendada | Variância $\sigma_{\theta}^2$ |
|-----------------------|---------------------------|-------------------------------|
| ReLU, Leaky ReLU, ELU | He / Kaiming              | $2/n^{(l-1)}$                 |
| GELU                  | He / Kaiming              | $2/n^{(l-1)}$                 |
| Sigmoid, tanh         | Xavier / Glorot           | $1/n^{(l-1)}$                 |
| Softmax (saída)       | Xavier / Glorot           | $1/n^{(l-1)}$                 |

- Bias sempre inicializado em 0 (ou em valor pequeno positivo para ReLU, evita unidades mortas no início).

# Em PyTorch

---

- He (Kaiming): `torch.nn.init.kaiming_normal_(tensor, mode='fan_in')`
- Xavier (Glorot): `torch.nn.init.xavier_normal_(tensor)`
- Padrão dos módulos `nn.Linear` e `nn.Conv2d`: **Kaiming uniform** com `fan_in`,  $a = \sqrt{5}$ . Bom o suficiente na maioria dos casos.
- Para arquiteturas grandes (transformers, ResNet), inicializações específicas por bloco (DeepNorm, MUP) podem dar resultados ainda melhores.

# Leituras Recomendadas

---

- Capítulo 7 de [Simon J. D. Prince. Understanding Deep Learning. MIT Press, 2023](#)
- Xavier (Glorot e Bengio, 2010): (Glorot e Bengio, 2010)
- Kaiming (He et al., 2015): (He et al., 2015)
- Visualização interativa: [deeplearning.ai/ai-notes/initialization](https://deeplearning.ai/ai-notes/initialization)

# Referências I

---

- [1] Xavier Glorot e Yoshua Bengio. “Understanding the difficulty of training deep feedforward neural networks”. Em: [AISTATS](#). 2010.
- [2] Kaiming He et al. “Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification”. Em: [ICCV](#). 2015.
- [3] Simon J. D. Prince. [Understanding Deep Learning](#). MIT Press, 2023.