

# Deep Learning

*Treinamento de LLMs: do Pré-treinamento ao Alinhamento*

Lucas Silveira Kupssinskü

Machine Learning Theory and Applications Laboratory  
PUCRS

junho de 2026

# Visão Geral

---

1. Pré-treinamento
2. Fine-tuning Supervisionado (SFT)
3. RLHF com PPO
4. Direct Preference Optimization (DPO)
5. Outros Métodos de Alinhamento
6. Otimizações de Treinamento
7. Ajuste Eficiente em Parâmetros (PEFT)

# Visão Geral

---

1. **Pré-treinamento**
2. Fine-tuning Supervisionado (SFT)
3. RLHF com PPO
4. Direct Preference Optimization (DPO)
5. Outros Métodos de Alinhamento
6. Otimizações de Treinamento
7. Ajuste Eficiente em Parâmetros (PEFT)

## Objetivo: *Next-Token Prediction*

O pré-treinamento de LLMs se baseia em **modelagem de linguagem causal**: dado um prefixo de tokens, prever o próximo.

*Loss Function: Cross Entropy*

$$\mathcal{L}_{\text{LM}}(\theta) = -\frac{1}{T} \sum_{t=1}^T \log P_{\theta}(x_t \mid x_1, \dots, x_{t-1})$$

| Contexto         | → | Alvo   |
|------------------|---|--------|
| 0 gato           | → | sentou |
| 0 gato sentou    | → | no     |
| 0 gato sentou no | → | tapete |

Uma única sequência de comprimento  $T$  gera  $T-1$  pares (contexto, alvo).

**Propriedade chave:** o corpus de texto é a própria supervisão: não há necessidade de anotação humana.

# Datasets de Pré-treinamento

---

## Grandes corpora públicos

- **Common Crawl**: rastreamento da web, bruto e ruidoso
- **C4** (*Colossal Clean Crawled Corpus*): versão filtrada do CC
- **The Pile**: 825 GB de texto diversificado (livros, código, arXiv, GitHub)
- **ROOTS** (BigScience): corpus multilíngue (46 idiomas, 1.6 TB)
- **FineWeb** (HuggingFace): 15 T de tokens filtrados da web

## Etapas de processamento

1. **Filtragem**: remoção de conteúdo ruim e spam (heurísticas + classificadores)
2. **Deduplicação**: remoção de documentos duplicados ou quase-duplicados
3. **Tokenização**: conversão para tokens
4. **Shuffling**: evitar correlações temporais no gradiente

**Regra geral:** qualidade > quantidade — corpus menor e limpo supera corpus bruto.

# Tokenização e Vocabulário

A tokenização converte texto bruto em sequências de *tokens*.

## Tamanho do vocabulário e impacto

- Vocabulário menor  $\Rightarrow$  sequências mais longas, mais computação
- Vocabulário maior  $\Rightarrow$  matriz de embedding maior, cobertura melhor
- Modelos modernos: 32 k – 200 k tokens (BPE ou Unigram)

## Comparação de vocabulários

| Modelo  | Vocab   | Algoritmo           |
|---------|---------|---------------------|
| GPT-2   | 50 257  | BPE                 |
| LLaMA-2 | 32 000  | BPE (sentencepiece) |
| LLaMA-3 | 128 256 | BPE                 |
| BERT    | 30 522  | WordPiece           |
| T5      | 32 100  | Unigram             |

O *tokenizer* é **treinado antes** do modelo, no mesmo corpus, e permanece fixo durante o treinamento.

# Pré-treinamento: *Warm-up* do LR

---

## 1. *Warm-up* do LR

- LR cresce linearmente de 0 até  $\eta_{\max}$
- Dura tipicamente 1–2% do treino total
- Evita explosão de gradiente no início e estabiliza a norma dos parâmetros

**Otimizador padrão:** AdamW com  $\beta_1=0.9$ ,  $\beta_2=0.95$ ,  $\epsilon=10^{-8}$ , *weight decay*  $\lambda=0.1$ , *gradient clipping* em 1.0.


# Pré-treinamento: *Cosine Decay* do LR

## 2. *Cosine Decay*

- LR decai de  $\eta_{\max}$  a  $\eta_{\min}$

$$\eta_t = \eta_{\min} + \frac{\eta_{\max} - \eta_{\min}}{2} \left( 1 + \cos \frac{\pi t}{T} \right)$$

- Transição suave evita instabilidades





## Pré-treinamento: *Batch Ramp-up*

---

### 3. *Batch Ramp-up*

- *Batch size* cresce ao longo do treino
- Início: mini-batches pequenos para convergência rápida
- Fim: batches grandes para melhor generalização

# Visão Geral

---

1. Pré-treinamento
- 2. Fine-tuning Supervisionado (SFT)**
3. RLHF com PPO
4. Direct Preference Optimization (DPO)
5. Outros Métodos de Alinhamento
6. Otimizações de Treinamento
7. Ajuste Eficiente em Parâmetros (PEFT)

# SFT: Ajuste para Seguir Instruções

Após o pré-treinamento, o modelo sabe “completar texto”, mas não necessariamente **seguir instruções** de forma útil.

O *Supervised Fine-Tuning* (SFT), ou *Instruction Tuning*, ajusta o modelo em pares (instrução, resposta) de alta qualidade.

## Função de perda do SFT

$$\mathcal{L}_{\text{SFT}}(\theta) = - \sum_{t \in \mathcal{R}} \log P_{\theta}(x_t \mid x_{<t})$$

onde  $\mathcal{R}$  são **apenas os tokens da resposta** (não do prompt/instrução).

Mascarar o prompt evita que o modelo memorize instruções em vez de aprender a responder.

## Exemplo de amostra de SFT

[INSTRUÇÃO: mascarado]

Explique o que é retropropagação.

[RESPOSTA: perda calculada aqui]

Retropropagação é o algoritmo que calcula gradientes...

# Datasets para Instruction Tuning

## Datasets clássicos

- **FLAN** [1]: 1.8k tarefas NLP; diversidade > volume
- **ShareGPT**: conversas reais de usuários do ChatGPT; qualidade variável
- **LIMA** [10]: 1.000 exemplos **muito bem curados**  $\approx$  52k do Alpaca
- **OpenHermes**: mistura de ShareGPT, GPT-4 e outros; qualidade alta e consistente

## Quantidade vs. Qualidade

| Dataset          | Exemplos  | Qualidade   |
|------------------|-----------|-------------|
| Alpaca (GPT-3.5) | 52 000    | Baixa-Média |
| ShareGPT         | 90 000    | Média       |
| LIMA             | 1 000     | Alta        |
| OpenHermes-2.5   | 1 000 000 | Alta        |

**Lição do LIMA:** “1000 exemplos cuidadosamente selecionados superam 52000 gerados automaticamente.”

## Chat Templates e Tokens Especiais

---

Modelos de chat usam **tokens especiais** para delimitar turnos da conversa, permitindo multi-turno e controle de papéis. Tokens comuns

- `<|im_start|>`, `<|im_end|>` (ChatML / Qwen)
- `[INST]`, `[/INST]` (LLaMA-2 chat)
- `<|start_header_id|>` (LLaMA-3)
- `<s>` (BOS), `</s>` (EOS)

O template define **onde calcular a perda**: apenas nos tokens gerados pelo assistente.

**Exemplo: formato ChatML**

```
<|im_start|>system Você é um assistente útil. <|im_end|>
<|im_start|>user Explique redes neurais. <|im_end|>
<|im_start|>assistant [loss calculada aqui] Redes neurais são...<|im_end|>
```

# SFT vs. Pré-treinamento: Diferenças de Otimização

## Pré-treinamento

- LR alto:  $10^{-4} - 3 \times 10^{-4}$
- Centenas de bilhões de tokens
- *Batch size* muito grande (milhões de tokens)
- *Weight decay*: 0.1
- Foco: **absorver conhecimento**

## Fine-tuning (SFT)

- LR baixo:  $10^{-6} - 2 \times 10^{-5}$
- Milhares a milhões de exemplos
- *Batch size* menor (128–512 sequências)
- Poucas épocas (1–3) para evitar *overfitting*
- Foco: **adaptar comportamento**

## Risco de *Catastrophic Forgetting*


LR alto ou muitas épocas podem fazer o modelo “esquecer” conhecimento adquirido no pré-treinamento. Use LR baixo e monitore *benchmarks* gerais ao longo do SFT.

# Visão Geral

---

1. Pré-treinamento
2. Fine-tuning Supervisionado (SFT)
- 3. RLHF com PPO**
4. Direct Preference Optimization (DPO)
5. Outros Métodos de Alinhamento
6. Otimizações de Treinamento
7. Ajuste Eficiente em Parâmetros (PEFT)

# Pipeline Completo do RLHF [8]



**Etapa 1:** amostrar pares de respostas do modelo SFT

**Etapa 2:** humanos escolhem a resposta preferida

**Etapa 3:** treinar o RM com *Bradley-Terry*

**Etapa 4:** usar PPO para otimizar a política, maximizando recompensa do RM com penalidade KL em relação ao SFT



# Dados de Preferência: Pares Escolhido/Rejeitado

## Formato dos dados para RLHF, DPO e variantes

**Prompt  $x$ :** *“Explique o que é aprendizado de máquina de forma simples.”*

### Resposta escolhida $y_w$ (✓)

*“Aprendizado de máquina é um método pelo qual computadores aprendem padrões a partir de dados, sem serem explicitamente programados para cada tarefa.”*

Tripla:  $(x, y_w, y_l)$  — usada por RLHF, DPO, GRPO

### Resposta rejeitada $y_l$ (✗)

*“ML é quando você faz o computador aprender coisas. É tipo uma coisa de dados. Basicamente é inteligência artificial mas diferente.”*

HH-RLHF [8], UltraFeedback (64k), OpenHermes

# Treinamento do *Reward Model*

O *Reward Model* (RM) é treinado para **prever preferência humana** entre pares de respostas para o mesmo prompt.

**Coleta de dados:** para cada prompt  $x$ , amostram-se duas respostas  $(y_w, y_l)$  onde  $y_w$  é a preferida pelos anotadores.

## Função de perda do RM (Bradley-Terry)

$$\mathcal{L}_{\text{RM}} = -\mathbb{E}_{(x, y_w, y_l)} \left[ \log \sigma(r_\phi(x, y_w) - r_\phi(x, y_l)) \right]$$

onde  $r_\phi(x, y)$  é o *scalar reward* predito.

## Datasets de comparações humanas

| Dataset             | Pares | Fonte   |
|---------------------|-------|---------|
| HH-RLHF (Anthropic) | 170k  | Humanos |
| WebGPT Comparisons  | 19k   | Humanos |
| SHP                 | 385k  | Reddit  |
| UltraFeedback       | 64k   | GPT-4   |

O RM geralmente parte do **mesmo modelo SFT** com uma cabeça de regressão escalar adicionada.

## Exemplo Numérico: *Reward Model*

**Prompt**  $x$ : “Explique o que é uma rede neural.”    **Humanos preferem**  $y_w$  (detalhada) sobre  $y_l$  (vaga).

### Cenário A: RM bem treinado

| Resposta          | $r_\phi(x, y)$ |
|-------------------|----------------|
| $y_w$ (detalhada) | +2.1           |
| $y_l$ (vaga)      | -0.8           |

$$\Delta r = (+2.1) - (-0.8) = +2.9$$

$$\sigma(\Delta r) \approx 0.948$$

$$\mathcal{L}_{\text{RM}} = -\log(0.948) \approx 0.053$$

✓ RM concorda com o rótulo humano

### Cenário B: RM mal treinado

| Resposta          | $r_\phi(x, y)$ |
|-------------------|----------------|
| $y_w$ (detalhada) | -0.8           |
| $y_l$ (vaga)      | +2.1           |

$$\Delta r = (-0.8) - (+2.1) = -2.9$$

$$\sigma(\Delta r) \approx 0.052$$

$$\mathcal{L}_{\text{RM}} = -\log(0.052) \approx 2.96$$

× RM discorda; gradiente grande

# Função Objetivo do PPO com Penalidade KL

O PPO otimiza a política  $\pi_\theta$  para maximizar recompensa enquanto permanece próximo da política SFT de referência  $\pi_{\text{ref}}$ .

## Objetivo RLHF-PPO

$$J(\theta) = \mathbb{E}_{x,y \sim \pi_\theta} [r_\phi(x, y) - \beta \text{KL}(\pi_\theta \| \pi_{\text{ref}})]$$

## Clip Surrogate do PPO

$$L^{\text{CLIP}} = \mathbb{E}_t [\min(r_t A_t, \text{clip}(r_t, 1-\epsilon, 1+\epsilon) A_t)]$$

onde  $r_t = \pi_\theta / \pi_{\text{old}}$  e  $A_t$  é a vantagem.

## Papel do coeficiente KL $\beta$

|                 |                                                                 |
|-----------------|-----------------------------------------------------------------|
| $\beta$ pequeno | Liberdade para maximizar reward; risco de <i>reward hacking</i> |
|-----------------|-----------------------------------------------------------------|

|                |                                                           |
|----------------|-----------------------------------------------------------|
| $\beta$ grande | Permanece próximo do SFT; pode não melhorar o alinhamento |
|----------------|-----------------------------------------------------------|

## Instabilidades típicas:

- *Reward hacking*: modelo “engana” o RM
- *KL explosion*: divergência excessiva da política

# Visão Geral

---

1. Pré-treinamento
2. Fine-tuning Supervisionado (SFT)
3. RLHF com PPO
- 4. Direct Preference Optimization (DPO)**
5. Outros Métodos de Alinhamento
6. Otimizações de Treinamento
7. Ajuste Eficiente em Parâmetros (PEFT)

# DPO: Motivação

## Problema com RLHF-PPO:

- Requer treinamento de um *Reward Model* separado
- Otimização RL é instável e sensível a hiperparâmetros
- Precisa manter 4 modelos em memória simultaneamente (política, referência, RM, *value function*)

**Ideia do DPO** (Rafailov et al., 2023):

*Eliminar o RM explícito reparametrizando o problema de otimização diretamente em termos da política.*

O DPO mostra que a solução ótima do RLHF implica uma correspondência fechada entre reward e a política ótima.

## Comparação de infraestrutura

| Componente             | RLHF | DPO |
|------------------------|------|-----|
| Reward Model           | ✓    | ✗   |
| Value Function         | ✓    | ✗   |
| Política de referência | ✓    | ✓   |
| Geração online         | ✓    | ✗   |
| Dados de comparação    | ✓    | ✓   |

## Derivação da Função de Perda do DPO [9]

Da solução ótima do RLHF:  $r^*(x, y) = \beta \log \frac{\pi^*(y|x)}{\pi_{\text{ref}}(y|x)} + \beta \log Z(x)$ . Substituindo no modelo Bradley-Terry,  $Z(x)$  **cancela**:

### Perda DPO

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(x, y_w, y_l)} \left[ \log \sigma \left( \beta \log \frac{\pi_{\theta}(y_w|x)}{\pi_{\text{ref}}(y_w|x)} - \beta \log \frac{\pi_{\theta}(y_l|x)}{\pi_{\text{ref}}(y_l|x)} \right) \right]$$

### Interpretação intuitiva

A perda aumenta  $\pi_{\theta}(y_w|x)$  e diminui  $\pi_{\theta}(y_l|x)$ , **ponderado pela mudança relativa em relação à referência**. Sem Reward Model explícito — o modelo de linguagem é o reward model.

**Datasets:** UltraFeedback (64k), Anthropic-HH (170k), TL;DR (93k) — formato (prompt, chosen, rejected).

### Gradiente implícito

O DPO aumenta a probabilidade relativa de  $y_w$  mais agressivamente quando o RM implícito **subestima**  $y_w$ , e vice-versa.

# Visão Geral

---

1. Pré-treinamento
2. Fine-tuning Supervisionado (SFT)
3. RLHF com PPO
4. Direct Preference Optimization (DPO)
- 5. Outros Métodos de Alinhamento**
6. Otimizações de Treinamento
7. Ajuste Eficiente em Parâmetros (PEFT)



## GRPO: *Group Relative Policy Optimization* [4]

---

Proposto no DeepSeek-R1 (DeepSeek-AI, 2025), o GRPO elimina a *value function* do PPO substituindo-a por uma **estimativa de baseline por grupo**.

$$J_{\text{GRPO}} = \mathbb{E} \left[ \frac{1}{G} \sum_{i=1}^G \hat{A}_i \cdot \min(r_i, \text{clip}(r_i, 1-\epsilon, 1+\epsilon)) \right]$$

onde  $\hat{A}_i = \frac{r_i - \text{mean}(\{r_j\})}{\text{std}(\{r_j\})}$  e  $G$  é o tamanho do grupo de amostras.

- Sem *value function*: menos parâmetros, menos memória
- Estimativa de vantagem simples e estável
- Funciona bem com *reward* esparsos (verificação matemática)
- Permite raciocínio de *chain-of-thought* emergente

**Resultado:** DeepSeek-R1 alcança desempenho competitivo com OpenAI o1 em AIME e MATH usando GRPO com verificação automática de respostas.

## Exemplo Numérico: GRPO

**Problema:** “Quanto é  $12 \times 7$ ?” (resposta correta: 84) Grupo de  $G = 4$  respostas amostradas.

| $i$ | Resposta $y_i$ | $r_i$ | $\hat{A}_i$ |
|-----|----------------|-------|-------------|
| 1   | “84” (correto) | 1     | +1.0        |
| 2   | “82” (errado)  | 0     | -1.0        |
| 3   | “84” (correto) | 1     | +1.0        |
| 4   | “76” (errado)  | 0     | -1.0        |

$$\bar{r} = \frac{1+0+1+0}{4} = 0.5, \quad \sigma_r = 0.5$$

$$\hat{A}_i = \frac{r_i - 0.5}{0.5}$$

### Efeito na política

- $\hat{A}_i > 0$ : resposta **melhor que a média**  $\Rightarrow$  política **reforçada**
- $\hat{A}_i < 0$ : resposta **pior que a média**  $\Rightarrow$  política **penalizada**

Sem *value function*: o baseline é a **média das recompensas do grupo**. Com recompensas binárias e metade do grupo acertando,  $\hat{A}_i \in \{-1, +1\}$ .

## SimPO: *Reward* Sem Modelo de Referência [7]

### SimPO

**Motivação:** DPO depende do modelo de referência, o que pode ser ineficiente.

$$\mathcal{L}_{\text{SimPO}} = -\log \sigma \left( \frac{\beta}{|y_w|} \log \pi_{\theta}(y_w|x) - \frac{\beta}{|y_l|} \log \pi_{\theta}(y_l|x) - \gamma \right)$$

- Sem modelo de referência ( $\pi_{\text{ref}}$ )
- *Length-normalized reward*: divide pelo comprimento para evitar viés
- Margem  $\gamma$  garante separação entre escolhida e rejeitada

# Tabela Comparativa dos Métodos de Alinhamento


| Método   | Precisa de RM | Precisa de pares | Online | Sem ref. | Caso de uso típico              |
|----------|---------------|------------------|--------|----------|---------------------------------|
| RLHF-PPO | ✓             | ✓                | ✓      | ×        | Alinhamento geral (InstructGPT) |
| DPO      | ×             | ✓                | ×      | ×        | Alinhamento simples, eficiente  |
| IPO      | ×             | ✓                | ×      | ×        | DPO mais robusto a ruído        |
| SimPO    | ×             | ✓                | ×      | ✓        | Sem dependência de referência   |
| GRPO     | ✓*            | ×                | ✓      | ×        | Raciocínio matemático/código    |

\* GRPO usa reward verificável automaticamente (ex.: checar resposta matemática), não um RM neural separado.

## Tendência atual

Para a maioria dos casos, **SFT + DPO** é o pipeline padrão. PPO é reservado para cenários onde a geração *online* traz ganhos claros. GRPO cresce para tarefas de raciocínio com reward verificável.

# Resumo: Pipeline Completo de Treinamento de LLMs



## Pré-treino

GPT-3, LLaMA, Falcon  
Datasets: The Pile, C4  
Flash Attention, Precisão Mista

## SFT + Alinhamento

InstructGPT, ChatGPT  
LLaMA-Chat, Mistral-Instruct  
Qwen-Chat, DeepSeek-R1

## Pesquisa ativa

DPO e variantes  
GRPO para raciocínio  
*Constitutional AI* (Anthropic)

# Visão Geral

---

1. Pré-treinamento
2. Fine-tuning Supervisionado (SFT)
3. RLHF com PPO
4. Direct Preference Optimization (DPO)
5. Outros Métodos de Alinhamento
- 6. Otimizações de Treinamento**
7. Ajuste Eficiente em Parâmetros (PEFT)

# Precisão Mista: Por que Usar Menos Bits?

Treinar em **precisão total** (fp32) consome 16 bytes por parâmetro (pesos + gradientes + estados Adam).

## Motivação

Reduzir a precisão de fp32 para fp16/bf16 durante as operações principais permite:

- **2× menos memória** para pesos e ativações
- **2–8× throughput** em Tensor Cores modernos
- Treinamento de modelos maiores com o mesmo hardware

**Atenção:** precisão insuficiente causa *overflow/underflow* e instabilidade.

## Throughput de GEMM por precisão

| GPU      | FP32       | BF16/FP16    |
|----------|------------|--------------|
| A100 SXM | 312 TFLOPS | 624 TFLOPS   |
| H100 SXM | 67 TFLOPS  | 1 979 TFLOPS |
| RTX 4090 | 83 TFLOPS  | 330 TFLOPS   |

GEMM = multiplicação de matrizes

Tensor Cores das GPUs Volta+ são otimizados para operações em fp16/bf16 (o hardware processa dois elementos por clock em vez de um).

# Representações de Ponto Flutuante em Deep Learning

Layout de bits ■ Sinal ■ Expoente ■ Mantissa



Impacto dos campos

- Expoente: intervalo dinâmico
- Mantissa: precisão entre valores

Alcance representável  
(valores positivos)

| Formato  | Mín. normal                    | Máx. finito                  |
|----------|--------------------------------|------------------------------|
| FP32     | $\approx 1,18 \times 10^{-38}$ | $\approx 3,4 \times 10^{38}$ |
| FP16     | $\approx 6,1 \times 10^{-5}$   | 65 504                       |
| BF16     | $\approx 1,18 \times 10^{-38}$ | $\approx 3,4 \times 10^{38}$ |
| FP8 E4M3 | $\approx 1,56 \times 10^{-2}$  | 448                          |
| FP8 E5M2 | $\approx 6,1 \times 10^{-5}$   | 57 344                       |


## Comparação chave

**BF16** = mesmo expoente do FP32 (8 bits), evita overflow de gradientes; **FP16** = mais mantissa (10 bits) mas range  $\sim 10^{10} \times$  menor que FP32. **FP8 E5M2** (mais range): gradientes. **FP8 E4M3** (mais precisão): pesos/ativações.



# Precisão Mista Automática (AMP)

Pesos mestres: cópia dos parâmetros em fp32 usada pelo otimizador. Forward/backward usam cópia em fp16/bf16 (rápido em *Tensor Cores*), mas o AdamW acumula na cópia mestre em fp32 para não descartar gradientes minúsculos.



## Loss Scaling (necessário com FP16)

Gradientes em fp16 sofrem **underflow** (valores pequenos → zero). Solução: escalar a loss:

$$\tilde{\mathcal{L}} = S \cdot \mathcal{L}, \quad g_{\text{fp32}} = (\tilde{g}_{\text{fp16}})/S$$

$S$  é ajustado dinamicamente: sobe se sem overflow, desce se overflow detectado.

## BF16 dispensa *loss scaling*

Mesmo intervalo dinâmico do FP32 ⇒ sem risco de overflow em gradientes. Preferir BF16 em GPUs Ampere+.

# Flash Attention: O Gargalo de Memória [3]

O mecanismo de atenção padrão materializa a matriz  $S = QK^T \in \mathbb{R}^{N \times N}$  inteira na HBM:


$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V$$

## Problema de IO

Para  $N = 4096$ , fp16:  $S \approx 32 \text{ MB/camada}$ .  
Com 32 camadas: **GBs de transfers HBM**,  
que é lenta.

O bottleneck **não é computação**, é **memória**: cada elemento de  $S$  deve ser escrito e lido da HBM pelo menos 2 vezes (forward + backward).

## Hierarquia de memória da GPU



# Flash Attention: Tiling na SRAM

**Ideia central:** dividir Q, K, V em **blocos** que cabem na SRAM e processar atenção bloco a bloco, sem materializar  $S = QK^T$  na HBM.


## Online Softmax

O softmax requer ver todos os escores para normalizar. Solução: manter estatísticas acumuladas por bloco:

$$m_i^{\text{new}} = \max(m_i^{\text{old}}, \max_j s_{ij})$$

$$\ell_i^{\text{new}} = e^{m_i^{\text{old}} - m_i^{\text{new}}} \ell_i^{\text{old}} + \sum_j e^{s_{ij} - m_i^{\text{new}}}$$

Matematicamente equivalente ao softmax global.



# Online Softmax: Exemplo Numérico

**Scores:**  $s = [3, 1, 2, 4]$  em dois blocos:  $B_1 = [3, 1]$ ,  
 $B_2 = [2, 4]$

## Processamento por blocos:

**Bloco**  $B_1 = [3, 1]$

$$m^{(1)} = \max(3, 1) = 3$$

$$\ell^{(1)} = e^{3-3} + e^{1-3} = 1.000 + 0.135 = 1.135$$

**Bloco**  $B_2 = [2, 4]$  ( $m^{(1)} = 3$ )

$$m^{(2)} = \max(3, 4) = 4$$

$$\begin{aligned}\ell^{(2)} &= \underbrace{e^{3-4}}_{\text{rescale}} \cdot \ell^{(1)} + e^{2-4} + e^{4-4} \\ &= 0.368 \times 1.135 + 0.135 + 1.000 \\ &= 1.553\end{aligned}$$

## Softmax global (referência):

$$\begin{aligned}\ell &= e^{3-4} + e^{1-4} + e^{2-4} + e^{4-4} \\ &= 0.368 + 0.050 + 0.135 + 1.000 \\ &= 1.553 \checkmark\end{aligned}$$

### Por que isso importa?

Sem subtração do máximo:

$$s = [1000, 1001] \Rightarrow e^{1000} = \infty$$

Online:  $s - m = [-1, 0]$

$$\Rightarrow e^{-1} + e^0 = 1.368 \checkmark \text{ sem overflow}$$

O fator  $e^{m^{(1)} - m^{(2)}}$  rescala o acumulador anterior para o novo máximo global.

## Flash Attention 2 e Versões Modernas [2]

### Flash Attention 2 (Dao, 2023)

Melhorias sobre a v1:

- **Menos operações de rescale:** reduz FLOPs do softmax online em  $\sim 2\times$
- **Paralelismo na dimensão de sequência:** divide o trabalho tanto pelas heads quanto pelo comprimento
- **Causal masking eficiente:** pula a metade superior da matriz em geração autoregressiva
- **Resultado:**  $2\text{--}4\times$  mais rápido que FA1 em sequências  $\geq 1\text{k}$  tokens

### Flash Attention 3 (2024, H100)

Projetado para GPUs Hopper (H100):

- Usa **WGMMA** e **TMA**: primitivas de hardware do H100 para GEMMs e carregamentos assíncronos
- Pipeline: calcula GEMM enquanto carrega o próximo bloco em paralelo (sobreposição compute/IO)
- Suporte nativo a **FP8**: atenção em 8 bits
- $\sim 1,5\text{--}2\times$  mais rápido que FA2 no H100

**Adoção:** FA2 padrão em PyTorch 2.0+, vLLM e HuggingFace.

# Visão Geral

---

1. Pré-treinamento
2. Fine-tuning Supervisionado (SFT)
3. RLHF com PPO
4. Direct Preference Optimization (DPO)
5. Outros Métodos de Alinhamento
6. Otimizações de Treinamento
- 7. Ajuste Eficiente em Parâmetros (PEFT)**

# Motivação: Custo do *Fine-tuning* Completo

Fazer *fine-tuning* completo de um LLM exige armazenar em GPU:

- **Pesos do modelo:**  $\sim 2$  bytes/parâmetro (fp16)
- **Gradientes:** mesmo tamanho dos pesos
- **Estados do otimizador (AdamW):**  $\sim 12$  bytes/parâmetro
- **Ativações:** proporcional ao *batch size*

Exemplo: modelo de 7B parâmetros

Pesos + gradientes + otimizador  $\approx$  **112 GB**: fora do alcance de GPUs de consumo (RTX 4090: 24 GB).

## Memória por parâmetro

| Componente         | fp32            | fp16/bf16                          |
|--------------------|-----------------|------------------------------------|
| Pesos              | 4 bytes         | 2 bytes                            |
| Gradientes         | 4 bytes         | 2 bytes                            |
| Adam $m$ (1ª mom.) | 4 bytes         | —                                  |
| Adam $v$ (2ª mom.) | 4 bytes         | —                                  |
| <b>Total</b>       | <b>16 bytes</b> | <b><math>\sim 16</math> bytes*</b> |

\* estados Adam mantidos em fp32 mesmo com pesos em fp16

**Solução PEFT:** treinar apenas uma fração pequena dos parâmetros, mantendo o modelo base congelado.

# LoRA: *Low-Rank Adaptation* [6]

Hu et al. (2022) propõem decompor a atualização de pesos em um produto de matrizes de **baixa rank**:

## Decomposição LoRA

Para uma camada  $W_0 \in \mathbb{R}^{d \times k}$  congelada, adicionamos um desvio treinável:

$$h = W_0 x + \frac{\alpha}{r} B A x$$

onde  $B \in \mathbb{R}^{d \times r}$ ,  $A \in \mathbb{R}^{r \times k}$ ,  $r \ll \min(d, k)$  e  $\alpha$  é um fator de escala.

- A inicializado com distribuição normal; B com zeros
- Somente A e B são atualizados durante o treino

## Configurações típicas

| Hiperparâmetro      | Valor típico | Notas                    |
|---------------------|--------------|--------------------------|
| rank $r$            | 4-64         | Menor = menos parâmetros |
| $\alpha$            | $r-2r$       | Controla a escala        |
| <i>lora_dropout</i> | 0.05         | Regularização            |
| Camadas alvo        | Q, V, ff     | Projeções de atenção     |


**Exemplo:** LLaMA-7B com  $r=16$ , adaptando Q e V: apenas 0,17% dos parâmetros são treináveis, redução de memória de  $\sim 3\times$ .

Adaptar também as projeções de saída (O, *gate*, *up*, *down*) melhora o desempenho ao custo de mais parâmetros.



# LoRA: Decomposição de Baixo *Rank* — Visualização

Atualização de pesos: modelo congelado + adaptadores



Contagem de parâmetros

modelo 7B:  $d=k=4096$ ,  $r=16$

| Matriz                 | Dim.         | Params                            |
|------------------------|--------------|-----------------------------------|
| $W_0$                  | $d \times k$ | 16,7M ( <i>frozen</i> )           |
| $B$                    | $d \times r$ | 65k                               |
| $A$                    | $r \times k$ | 65k                               |
| <b>Total treinável</b> |              | <b>130k</b>                       |
| fração                 |              | <b><math>\approx 0,8\%</math></b> |

**Deploy:** fundir  $W_0 + \frac{\alpha}{r} BA$  antes de servir  $\rightarrow$  zero overhead de inferência.

# QLoRA: LoRA com Base Quantizada em 4 Bits [5]

Dettmers et al. (2023) combinam LoRA com quantização do modelo base, permitindo ajustar modelos de 65B em uma única GPU de 48 GB.

## Componentes chave do QLoRA

1. **NF4** (*NormalFloat 4-bit*): minimiza o erro de quantização para pesos com distribuição normal (vs. INT4 uniforme)
2. **Dupla quantização**: quantizar também as constantes de quantização, economizando  $\approx 0,37$  bits/parâmetro extra
3. **Paged Optimizers**: memória unificada CPU/GPU para absorver picos durante o treino

## Comparação de memória (modelo 7B)

| Método         | VRAM (treino) | Precisão   |
|----------------|---------------|------------|
| Full FT (fp16) | ~112 GB       | fp16       |
| LoRA (fp16)    | ~40 GB        | fp16       |
| QLoRA (NF4)    | ~10 GB        | NF4 + fp16 |

**Custo:** pequena degradação de qualidade ( $\approx 0,1-0,2$  pontos em benchmarks) em troca de acessibilidade em hardware de consumo.

**Implementação:** bibliotecas bitsandbytes + peft do HuggingFace.

# Comparação dos Métodos PEFT

| Método  | Params. treináveis | VRAM (7B) | Desempenho | Complexidade | Caso de uso típico                  |
|---------|--------------------|-----------|------------|--------------|-------------------------------------|
| Full FT | 100%               | ~112 GB   | Máximo     | Baixa        | Dados abundantes, hardware dedicado |
| LoRA    | 0,1–1%             | ~40 GB    | Alto       | Baixa        | Ajuste geral, produção              |
| QLoRA   | 0,1–1%             | ~10 GB    | Alto*      | Média        | Hardware de consumo (GPU única)     |

\* Pequena degradação vs. LoRA em fp16


## Recomendação prática

Para a maioria dos cenários, **QLoRA** é o padrão para ajuste em hardware limitado; **LoRA em bf16** quando há mais VRAM disponível. *Full fine-tuning* apenas quando há hardware dedicado e dados abundantes.

# Quantização para PEFT: NF4 vs. INT4

## NormalFloat 4-bit (NF4)

Tipo de dado de 4 bits projetado para pesos de redes neurais, que tipicamente seguem  $\mathcal{N}(0, \sigma^2)$ . Em vez de espaçamento uniforme (INT4), os 16 valores representáveis do NF4 são posicionados nos **quantis da distribuição normal**:  $q_i = Q_F^{-1}\left(\frac{i}{15}\right)$ ,  $i = 0, \dots, 15$ . Mais resolução perto de zero, onde há mais pesos; menos resolução nas caudas.



**QLoRA:** pesos base em NF4 (congelados); adaptadores LoRA em bf16 (treináveis). Menor erro de quantização que INT4 com os mesmos 4 bits.

# Referências I

---

- [1] Hyung Won Chung et al. “Scaling instruction-finetuned language models”. Em: [JMLR](#) 25 (2024), pp. 1–53.
- [2] Tri Dao. “FlashAttention-2: Faster attention with better parallelism and work partitioning”. Em: [ICLR](#). 2024.
- [3] Tri Dao et al. “FlashAttention: Fast and memory-efficient exact attention with IO-awareness”. Em: [NeurIPS](#). Vol. 35. 2022, pp. 16344–16359.
- [4] DeepSeek-AI. “DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning”. Em: [arXiv preprint arXiv:2501.12948](#) (2025).
- [5] Tim Dettmers et al. “QLoRA: Efficient finetuning of quantized LLMs”. Em: [NeurIPS](#). Vol. 36. 2023.
- [6] Edward J Hu et al. “LoRA: Low-rank adaptation of large language models”. Em: [ICLR](#). 2022.
- [7] Yu Meng, Mengzhou Xia e Danqi Chen. “SimPO: Simple preference optimization with a reference-free reward”. Em: [NeurIPS](#). Vol. 37. 2024.
- [8] Long Ouyang et al. “Training language models to follow instructions with human feedback”. Em: [NeurIPS](#). Vol. 35. 2022, pp. 27730–27744.
- [9] Rafael Rafailov et al. “Direct preference optimization: Your language model is secretly a reward model”. Em: [NeurIPS](#). Vol. 36. 2023.
- [10] Chunting Zhou et al. “LIMA: Less is more for alignment”. Em: [NeurIPS](#). Vol. 36. 2023.